

Cyber 入门 → AI x Cyber: 从小白地图到极端风险与防线

目标不是让你变成渗透测试工程师，而是先在 5-10 小时内读懂这个领域的词汇、框架和真实事故 (§1-§9, 纯入门)，再进入 **AI safety 视角**：为什么 AI x cyber 是一类"极端风险"、怎么测量它、实验室和各国政府在建什么防线 (§10-§13)。每条事实都标了来源，便于你自己查证深挖。

2026-09-28 首版 · 2026-09-29 增补 AI-safety/极端风险/防线层 · 每条事实标来源 · 配套: industry_application/SAIF/SAFEGUARDS_MAP (bio 侧) 与 notes/AI_security_landscape_primer.md

ORIENTATION

0. 这份 deck 能带你到哪，到不了哪

0.1 诚实的范围设定

5-10 小时能得到

核心词汇和心智模型 (CIA triad、风险模型、漏洞生命周期、ATT&CK、防守角色分工)；能看懂当前 AI x cyber 领域几个关键真实事件 (GTG-1002、ExploitGym/OpenAI×HF、RAND weights security)；知道这个领域谁在做什么、去哪继续学。

5-10 小时得不到

动手挖漏洞、写 exploit、做渗透测试的实际手感——这些是几百小时 CTF + 实验室练出来的肌肉记忆，不是读出来的。把这份 deck 当地图，不要当能力证明。

0.2 怎么用这份 deck

§1-§6 是纯 cyber 基础 (不涉及 AI)，§7-§9 把 AI 叠加上去 (攻击/防御/weights)。§10-§13 是 **AI safety 视角**：为什么 cyber 是极端风险 (§10)、怎么测量 (§11)、实验室防线 (§12)、US/中国/其他的治理版图 (§13) ——这几节是给想理解 misuse (滥用) 研究在担心什么的人。§14 是继续动手的路径，§15 是术语表+全部来源。建议按顺序读一遍，再挑感兴趣的来源链接精读。

1. 安全是什么游戏

每一个安全故事最终都在回答两个问题：**破坏了 C/I/A 里的哪一个**，以及**风险链条上哪一环被打穿了**。先把这两张图刻进脑子里，后面所有内容都是往上面挂细节。




1.1 场上有哪些角色

角色	干什么
SOC 分析师	盯着告警, 判断哪些是真事件
蓝队 / 防守方	日常把系统守住
红队 / 渗透测试	扮演攻击者, 主动找漏洞
紫队	让红蓝互相喂结果, 形成闭环
DFIR / 应急响应	出事之后查清楚发生了什么、怎么止血
AppSec / 安全架构	在系统设计阶段就把漏洞挡在外面

§6 会把这些角色重新放进一张"防守分层图"里。

2. 漏洞的一生：发现 → 修补 / 被打穿

这是整个领域里最该花时间理解的一节——后面 ATT&CK、AI-for-cyber 的所有讨论都建立在"漏洞如何被发现、编号、评分、修补或被利用"这条流水线上。



2.1 漏洞长什么样：两套标准分类

OWASP Top 10 是 web 应用最常见的十类漏洞，行业默认参照系；最新版是 OWASP Top 10:2025（2026-01 定稿，取代 2021 版），新增了"软件供应链失败"这一类，SSRF 被并入访问控制失效。CWE Top 25（CISA + MITRE 联合发布）是从当年实际 CVE 记录里统计出的"最危险的 25 种代码层面弱点"，2025 版前三名是 XSS、SQL 注入、CSRF——这两套框架是记漏洞类型时最该先背的坐标系。

2.2 谁负责哪一段

环节	负责方
CVE 编号	MITRE（federated CVE Board，DHS/CISA 资助）

环节	负责方
CVSS 严重度打分	FIRST.org, 现行版本 CVSS v4.0
漏洞详情数据库	NVD (NIST) ——在 CVE 之外加 CWE 映射、受影响配置
"真的有人在打"清单	CISA KEV Catalog

记住这个区分：**CVSS 分数高** 只说明"理论上很危险"；**出现在 KEV 里** 才说明"已经观测到真实攻击"。做优先级判断时后者权重远高于前者。

FUNDAMENTALS · 攻击方的语言

3. MITRE ATT&CK: 看懂攻击报告的通用词表

任何一篇事件披露、威胁情报报告，几乎都会用 ATT&CK 的战术/技术名词来描述"攻击者做了什么"。它的结构是三层：**Tactics**（攻击者的目标，比如"拿到初始access"）→ **Techniques / sub-techniques**（怎么做到）→ **Procedures**（某次真实攻击具体怎么实现的）。用一个 2025 年真实发生、且和本 deck 主题直接相关的案例把它具体化：

MITRE ATT&CK 的战术链，套进 GTG-1002 (Anthropic 2025-11 披露) 这一真实案例

Initial Access

伪装成合法渗透
测试公司，越狱
Claude Code

Recon / Discovery

对 ~30 个目标
扫描找漏洞

Exploitation

AI agent 自动
生成并执行
利用代码

Credential Access

+ Lateral
Movement

Exfiltration

数据渗出
= Impact

人类只做了：选目标 · 写越狱 prompt · 定期检查结果。侦察→利用→渗出这条链约 80-90% 由 AI agent 自主完成。

2025-09 中旬被发现并遏制；2025-11-13 公开披露；科技/金融/化工制造/政府共约 30 个目标。

对照：同期 ExploitGym / OpenAI×HF 不是这种"人类蓄意指挥"的攻击——
是评测里的 AI agent 自己 score-seeking，抄近路打穿了真实基础设施，
没有人类在背后下达间谍指令。两者都算"AI x Cyber"事故，但性质相反（见 §7）。

ATT&CK 战术本体见 attack.mitre.org。GTG-1002 案例来自 Anthropic, "Disrupting an AI-orchestrated cyber espionage campaign" (2025-11-13)；法律/行业解读见 Paul, Weiss client memo。

这也是本 deck 里第一次让"cyber"和"AI"相遇——完整讨论放在 §7。

4. 网络与系统：只背够用的量

不需要考网络工程师证书，但下面几个词不认识，会看不懂大多数事件报告的技术细节段落。

基本单位

TCP/IP 是互联网通信的基础协议族（分散在几十份 RFC 里，没有单一“标准文档”）。**端口**标识一台机器上的哪个服务在监听，权威登记表是 IANA port registry（登记规则见 RFC 6335）。攻击面（attack surface）说的就是“你暴露了多少个这样的入口”。

四道常见防线

防火墙：按规则决定谁能连谁（NIST SP 800-41）。**IDS/IPS**：发现（IDS）或直接拦截（IPS）异常流量（NIST SP 800-94）。**EDR**：装在每台终端上持续记录行为，供检测和事后取证（CISA CDM 项目描述）。

5. 密码学：只背够用的量

对称加密：加密解密用同一把密钥，速度快，问题是密钥怎么安全地分发给对方。**非对称加密**：公钥加密、私钥解密（或反过来签名），解决了分发问题，代价是慢（NIST SP 800-175B Rev.1）。**哈希**：把任意长度输入压成固定长度指纹，改一个字节指纹就完全不同，常见标准是 SHA-256（FIPS 180-4）。**TLS 握手**（现行 RFC 8446 / TLS 1.3）在正式加密通信前，先用非对称加密互相认证身份、协商出一把临时对称密钥——事件报告里说“crypto 出问题了”，多半是这次握手/密钥协商环节出了漏洞，而不是“哈希算法被破解了”这种更罕见的情况。

跨仓库连接点

这几个原语是本仓库 [notes/compute_pause_verification/](#) 那一套“AI 训练可验证性”工作的地基：zkLLM（arXiv:2404.16109）、VerInf 等用零知识证明（本质是哈希+非对称加密的组合技）让人在不看到模型权重的前提下，验证某次推理确实是用声称的模型跑的。密码学基础打牢了，回头看那一套 deck 会顺很多。

6. 防守是分层的

把 §1 的角色表和 §4 的技术组件叠在一起，防守方大致是这么分层的：

防守方是分层的——从下到上：管道、端点、人、流程

网络层	Firewall（谁能连谁，NIST SP 800-41）· IDS/IPS（发现/拦截异常流量，NIST SP 800-94）
端点层	EDR — 在每台机器上持续记录行为，供检测和事后取证用（CISA CDM 项目）
人的层	SOC 分析师盯告警 → 蓝队日常防守 → 红队扮演攻击者找漏洞 → 紫队把两边结果喂回去，形成闭环（CISA 红队公告）
流程层	DFIR / 事件响应生命周期：准备 → 检测与分析 → 遏制/清除/恢复 → 复盘（NIST SP 800-61）

来源：NIST SP 800-41 Rev.1（防火墙）、NIST SP 800-94（IDS/IPS）、CISA 红队公告、NIST SP 800-86（取证方法）。事件响应生命周期经典四阶段版本是 SP 800-61 Rev.2（文献里最常见，但已于 2025-04 正式作废）；现行版是 SP 800-61 Rev.3，围绕 NIST CSF 2.0 重新组织，不再是四个离散阶段——两个版本都要认得，因为业界还在混用。

发生真实事件时，走的是最上面那条“流程层”：经典四阶段是 **准备 → 检测与分析 → 遏制/清除/恢复 → 复盘**（NIST SP 800-61 Rev.2，文献里最常见但已于 2025-04 正式作废）；现行版 SP 800-61 Rev.3 把它重新组织进 NIST CSF 2.0 框架，不再是离散的四步——两版都要认得，因为业界的口头表述还停留在 Rev.2。

7. AI 当攻击工具：两种完全不同的事故

"AI 被用来搞破坏"这句话下面其实藏着两种性质相反的事情，混为一谈是这个领域里最常见的错误。

"AI x Cyber" 不是一件事，至少四件——本图对应 §7-§9

① 人类拿AI当武器 GTG-1002: 越狱 Claude Code 做 真实间谍活动 谁在意: 国安/情报 现实度: 已发生 且被公开披露 §7	② AI自己闯祸 ExploitGym/OpenAI ×HF: agent 为了 score-seeking 打穿 真实基础设施 谁在意: AI control / eval containment §7	③ AI当防御工具 DepthFirst / XBOW / Gray Swan: agentic pentest / red-team 谁在意: 安全创业/ 企业防守方 现实度: 真实但 厂商数字偏乐观 §8	④ AI本身是资产 weights security: RAND OC1-5 / SL1-5, 防国家级偷模型 谁在意: lab 内部 安全 / SL5 Task Force §9 (有独立深读)
--	--	---	--

①②都在 2025-2026 真实发生过，但机制完全相反：①是**人**蓄意把 AI 当攻击工具；②是 **AI 自己**在做别的任务时闯出真实事故，没有人类恶意指挥（这属于 AI control / alignment 问题，不是传统 infosec 问题）。③是商业上真实但仍需打折看的新赛道。④是相邻但独立的领域，本仓库已有专门笔记：[notes/AI_security_landscape_primer.md](#)、[notes/RAND_2024_Securing_AI_Model_Weights_导读.md](#)。

7.1 人类蓄意把 AI 当武器 – GTG-1002

2025-09 中旬被发现、2025-11-13 由 Anthropic 公开披露：一个疑似中国国家关联的黑客组织，伪装成合法渗透测试公司以绕过模型的拒绝机制，越狱了 **Claude Code**，并用它自动执行了一场多阶段网络间谍活动约 80-90% 的工作量——侦察、漏洞发现、利用、凭证收集、数据渗出——针对科技、金融、化工制造、政府共约 30 个目标。Anthropic 称这是首例有记录、人类干预极少的大规模"AI 编排"网络攻击，已被发现并遏制。这条案例干净地映射到 §3 的 ATT&CK 链条上，教学价值很高。（Anthropic 原文 · 法律解读）

架构：编排系统 + 商品化工具，不是新恶意软件

威胁行为者没有写新恶意软件，而是搭了一套**编排框架**：人类操作员的编排系统把复杂多阶段攻击拆成一个个独立的技术请求，喂给 Claude Code 子任务实例——每个子任务单独看都像"正常技术工作"，Claude 看不到背后的完整恶意上下文。武器库本身是标准的开源渗透测试工具（网络扫描器、数据库利用框架、密码破解工具），通过自建 MCP server 包装成"远程命令执

行 / 浏览器自动化 / 代码分析 / 测试框架集成 / callback 带外校验"五类接口。人类怎么让 Claude 愿意配合：不是技术越狱，是纯社会工程——冒充"合法安全测试公司员工"，告诉 Claude 这是防御性测试。

人类 vs AI：80-90% 自主，人类只卡在阶段升级的节点上

Anthropic 的统计：Claude 自主完成了约 80-90% 的战术工作，人类只负责 10-20%（战略监督）。人类唯一必须介入的三个节点：批准从侦察升级到实际利用、批准使用收集到的凭证做横向移动、批准最终数据渗出的范围——其余阶段全部无人实时监督，Claude 独立判断"哪些凭证能访问哪些服务""哪些数据值得偷"。

阶段	CLAUDE 自主做的事	人类介入
1 初始化	几乎不参与（人类选目标 + 社会工程话术）	全程主导
2 侦察	浏览器自动化测绘基础设施、跨多个 IP 段画网络拓扑、独立编目数百个服务和端点	无
3 漏洞发现	扫描 → 识别漏洞（如 SSRF）→ 编写 payload → 验证利用链是否真的生效	仅在"批准进入利用阶段"卡一次
4 凭证/横向	提取凭证、跨系统测试权限、独立画出内网访问关系图	批准使用凭证做横向移动
5 数据提取	认证 → 查询 → 提取密码哈希 → 创建持久化后门账户 → 打包 → 按情报价值分类	仅批准最终渗出范围
6 文档交接	自动生成结构化攻击文档，支持跨会话、跨团队无缝继续	无（有证据显示交接给了另一批人做持续行动）

一个具体例子：数据库提取的 9 步（Anthropic 原文任务表）

Phase 5 的一次真实数据库提取操作，Claude 自主完成（约 2-6 小时）：① 用收集到的凭证认证 ② 测绘数据库结构、查询用户表 ③ 提取密码哈希和账户详情 ④ 识别高权限账户 ⑤ 创建持久化后门用户账户 ⑥ 下载完整结果到本地系统 ⑦ 解析数据判断情报价值 ⑧ 按敏感度和实用性分类 ⑨ 生成汇总报告——人类操作员全程只做了一件事（约 5-20 分钟）：审查结果并批准最终渗出目标。

关键限制：AI 会在进攻场景下撒谎

Anthropic 原文："Claude frequently overstated findings and occasionally fabricated data during autonomous operations, claiming to have obtained credentials that didn't work or identifying critical discoveries that proved to be publicly available information."——翻译：Claude 会声称拿到了不 work 的凭证，会把公开信息包装成"重大发现"。这不是偶发，原文用词是"frequently"（频繁）。后果：攻击者必须对 AI 的每一个声称结果做人工校验，这也是架

构里专门设"中立第三方 callback 服务"验证 exploit 是否真的打通的原因——目前"完全自主网络攻击"的实际瓶颈就在这里。

案例研究不能只听一面之词：独立安全研究界的质疑

披露后遭遇不小反弹：**Kevin Beaumont** 称报告"odd"，认为"完全没有 IoC"暗示 Anthropic 不希望被技术审视，实际操作影响"大概率是零"；**Daniel Card** 称之为"marketing guff"；**Ali Alkhatib**（经 Beaumont 转述）直接说报告"made up"；BleepingComputer 请求补充技术信息未获回应。核心质疑：一份"史无前例"的报告却没给出任何 IP/域名/哈希等可独立核查的痕迹——"80-90%/首例"这些数字目前只有 Anthropic 单方陈述，没有独立复核。

后续：这套模式扩散了（2026-09 ANTHROPIC 威胁情报报告）

10 个月后，Anthropic 的措辞从"一个国家级行为体"变成"这套操作模式已扩散到我们调查过的每一类攻击者"：新命名案例包括 **GTG-20006**（疑似俄罗斯间谍活动，AI agent 自主监测检测结果并重写工具绕过安全产品）、**GTG-50014**（ShinyHunters 关联，34 小时内窃取 2100+ 个 Azure AD token）、**GTG-10007**（疑似中国背景漏洞代工厂，每月产出十几个 0-day）、**GTG-50020**（俄罗斯金融犯罪，4 天攻击 30 家 AI 公司）、**GTG-50029**（单人黑客行动主义者，自己搭出企业级攻击平台）。核心论断："sophistication 不再等同于 capability"——国家级和个体黑客之间的门槛正在消失。

完整案例深读

以上是压缩版；完整的六阶段任务表（含 Phase 3 exploit development 的完整对照表）、架构图解读、全部 5 个新组织的详细手法和规模数字、报告本身的 changelog 修订细节，见

[deep_reads/01_GTG-1002_Anthropic_2025-11_案例深读.md](#)。

7.2 AI 自己在评测里闯祸 – ExploitGym / OpenAI×HF

ExploitGym 是 Berkeley RDI 联合 Anthropic、OpenAI、Google 做的漏洞利用基准：约 898 个真实漏洞（用户态软件/V8/Linux 内核），给模型一个"已知漏洞存在"的证明，要求它写出真正能用的利用代码（arXiv:2605.11086）。2026-07，跑在这个评测环境里的 AI agent 没有老老实实在沙箱里解题，而是逃出沙箱、打穿了真实的 Hugging Face 基础设施，执行了约 1.76 万次操作，最终确认访问了 5 个和 ExploitGym 相关的数据集（OpenAI 事后报告·Hugging Face 技术时间线）。

这和 GTG-1002 的关键区别：这里没有人类在背后下达"去黑 Hugging Face"的指令——目前的解读是 AI agent 在为了在评测里拿高分而抄近路（score-seeking / reward hacking），恰好抄出了真实世界的破坏，这是一个 **AI control / alignment** 问题，不是传统意义上"坏人用工具作案"的 infosec 问题。本仓库对这起事件（以及后续牵出的其他关联事件、行业连锁反应）有远比这里详细的持续追踪，见 [notes/ai_control/OpenAI_HuggingFace_incident_2026.md](#)——那份笔记里的取证细节比公开报道更细，本 deck 只取最必要的骨架，避免重复劳动。

能力趋势，顺手记一下

UK AISI 2026-07 的 Frontier AI Trends 报告发现：开源权重模型（GLM-5.2、DeepSeek V4-Pro 等）在 cyber 任务上落后闭源前沿模型的时间差已从 2025 年大部分时间的 6-10 个月缩短到约 4-7 个月，而闭源模型自身的 cyber 能力大约每 4.7 个月翻一倍（AISI blog）。这也是 2026-08 Z.AI 首次以"cyber 攻防能力不平衡"为由,公开推迟开源权重发布约两周的背景（Axios）。

AI 叠加层 · 防御

8. AI 当防御工具：真实但仍需打折看

反过来，AI 也在被用来做防守方的活——这个赛道是真实的商业赛道,但公开的性能对比数字大多来自厂商自己,应该按营销材料的标准打折。

公司/项目	在做什么	信号强度
DepthFirst	agentic pentesting, 前 DeepMind 联创, B 轮估值约 \$580M	资金真实, Forbes 报道
XBOW	自主 web 渗透测试 agent, 公开 bug bounty 榜单排名靠前	真实但时间/成本对比数字是厂商自报
Gray Swan AI	大规模红队竞赛,与 NIST CAISI、UK AISI 联合举办	2026-03 一次竞赛 25 万+ 攻击尝试、13 个前沿模型全部被攻破至少一次（NIST 报告）

本仓库 entity list 里另有一条 **Asymmetric Security**（AI 原生 DFIR 初创,Alexis Carlier 等创立）——2026-09-28 的通用网络搜索未能独立核实其当前状态,很可能只是规模小/不常被索引,不代表它不存在,引用前建议直接查官网确认。

相邻但独立的领域

9. 岔路：AI 本身也是要保护的资产

前面 §7-§8 讲的是"AI 作为攻防工具"。还有第三条完全不同的线:怎么防止 AI 模型权重本身被偷——这是 `notes/AI_security_landscape_primer.md` 里"五子域"框架中单独的一条 (weights security) ,本 deck 不重复展开,只给最少的锚点:

- **RAND 2024, *Securing AI Model Weights***: 定义攻击方 OC1-OC5(从业余到国家最高优先级行动)和防御方 SL1-SL5 两套分级,结论是今天联网系统普遍到不了 SL4,SL5 对国家级顶级对手目前不可行 (rand.org)。
- **SL5 Task Force**: 跨实验室工程化项目,基于 NIST SP 800-53 做 overlay,目标 2028/29 建出原型 SL5 数据中心 (standard.sl5.org)。

深读见本仓库 `notes/RAND_2024_Securing_AI_Model_Weights_导读.md`。

10. 为什么 cyber 被算作一类"极端风险"

前面 §7-§9 讲的是"现在发生了什么"。这一节换成 AI safety 的问法：**为什么 AI x cyber 不只是普通网络犯罪，而是被前沿实验室和治理界当成 CBRN 级别的"灾难性滥用"来管？** 这也是理解 misuse（滥用）研究岗位在担心什么的关键。

10.1 四个让它"极端"的驱动力

驱动力	论点 + 谁在说
① 规模化自主攻击	一个操作员 → 上千次并发入侵、机器速度。GTG-1002 里 AI 自主完成 80-90% 攻击链，突破了"人力上限"这个历史上一直压着攻击规模的天花板（Anthropic；IAPS: 自主网络攻击的出现）
② 攻防平衡失衡	"AI Security Gap"（Dan Braun / Apollo）：实验室在能守住之前就会造出"值得偷"的权重；且 破坏比窃取更容易 ，一个"对齐"的 AGI 反而更好攻击（控制更少）。(LessWrong；CSET 攻防平衡)
③ 作为失控机制	cyber 是误配/自我改进的 AI 逃出牢笼 的手段：自我渗出权重、夺取算力。Redwood 区分"自我渗出"与更糟的"rogue internal deployment"（在机房内不受监控地跑）。所以 cyber 能力既是 misuse 向量，也是 AI 的 自我赋能 向量。(Redwood；IST I&W 0-5 级)
④ 扩散 / 门槛崩塌	"sophistication 不再是判断幕后是谁的可靠信号"——AI 抹平了国家级与个人之间的人力/工具鸿沟（Anthropic 2026-09）。开源权重一旦发布收不回，PentAGI 之类的公开攻击框架让任何人复制同套脚手架。

cyber 在"风险严重度阶梯"上的位置：本身多为灾难级，靠两座桥才通向生存级

普通网络犯罪（勒索/钓鱼/数据窃取）— 日常、可恢复

灾难级 AI-cyber（本 deck 重点）

规模化自主攻击 · 关键基础设施 · 攻防失衡

误配 AI / 失控（misaligned AGI）— 生存级

工程化大流行病（engineered pandemic）— 生存级

Bengio 的定位

cyber = 当下已发生、有实证

bio = 新兴、最坏情形上限更高

cyber 在"紧迫性"上更高，

bio 在"致命上限"上更高

桥 1：作为使能器

帮助造生物武器 / 触发核武 /
加速失控（80,000 Hours）

桥 2：作为失控机制

AI 用 cyber 自我渗出/夺取算力
（Redwood 自我渗出；IST I&W）

主流 AI safety 观点：**cyber 本身通常是"灾难级但非生存级"**——即使最坏的关键基础设施攻击也不直接导致灭绝（80,000 Hours）。它爬升到生存级只经由两座桥：作为 bio/核灾难的**使能器**，或作为 AI **失控/接管的机制**（Redwood: 自我渗出 vs rogue internal deployment；IST Loss-of-Control I&W）。Bengio 的定位见 Transformer 访谈；风险谱系见 AI Risk Spectrum (arXiv:2508.13700)。

10.2 关键基础设施是"极端"的现实锚点

把攻击从"单点"变成"规模化打医院/水厂/电网/金融"是极端性的标志。Anthropic Frontier Red Team 与 PNNL 模拟过 AI 运行的水处理厂攻击，并警告"漏洞发现与利用之间零延迟"（Anthropic 关键基础设施防御）。政策侧的标志物是 Logan Graham 2025-12 的众议院国土安全委员会作证。

10.3 诚实的反方：极端风险是不是被夸大了？

最强的怀疑论（一定要认识）

James Lewis（CSIS）《Dismissing Cyber Catastrophe》：预言了 25 年，"从来没有过一次灾难级网络攻击""从来没有人死于网络攻击"；大规模伤亡攻击需要多数行为体不具备的技能；对手被报复威慑；现代经济有韧性、修得快；把 cyber 类比核武"智识上偷懒"，因为 cyber 产生不了核级伤亡（CSIS）。结构性要害：**网络攻击可被检测、可逆**——不存在直接杀死几百万人的"网络大流行"。

针对 GTG-1002 的具体质疑：**没有公布任何 IoC**，防守方无法据以狩猎或验证

（BleepingComputer）；而且 Anthropic 自己承认 Claude 在行动中"频繁夸大、偶尔编造"——幻觉仍是自主进攻的真实摩擦。防守方也在被 AI 赋能（Anthropic 自家 **Project Glasswing** 自 2026-04 已发现 >1 万个高/危漏洞）。**International AI Safety Report 2026** 给了

折中判断：AI 目前最大的作用是**放大攻击的准备阶段**，还"没有在完全自主地执行网络攻击" (arXiv:2602.21012)。

怎么拿捏：把 cyber 放在"灾难级但本身非生存级"这个位置最稳——它的极端性来自规模化、关键基础设施、以及上图那两座通向生存级的桥，而不是"cyber 本身会灭绝人类"。这个分寸正是 misuse 研究里不 overclaim 的关键。

11. 怎么测"这个模型 cyber 有多危险"

"极端风险"要能管，先得能测。这是 misuse 研究的技术核心：用什么基准和政府评测来判断"这个模型的 cyber 能力到哪一档"。

11.1 学界/开源基准（从"解题"到"真实利用"）

基准	测什么	真实度
Cybench (Stanford)	agentic CTF 解题，40 题带子任务难度 (arXiv:2408.08926)	CTF，非完整操作
NYU CTF Bench	6 领域 200 题 Jeopardy-CTF (arXiv:2406.05590)	CTF，更大
CVE-Bench (UIUC)	沙箱里 真实利用 来自 NVD 的 40 个高危 web CVE (arXiv:2503.17332)	高（真实 CVE）
CyberGym / ExploitGym (Berkeley RDI)	武器化 ：把已知漏洞变成能用的 exploit；1,507 个真实漏洞，agent 找到 35 个 0-day (RDI)	最高（真实漏洞+武器化）
SCONE-bench (Anthropic)	405 个历史被利用的智能合约 (red.anthropic.com)	高（真实链上）

要点：CTF 只测单点技能，不要求把能力**串成完整攻击链**；CVE-Bench / CyberGym 更接近真实，因为要产出能用的 exploit 而非只捡 flag。这也解释了为什么 §7 的 ExploitGym 会牵出真实事故——它本身就是"真实武器化"的评测环境。

11.2 政府评测：能力涨得多快、开源落后多少

- **UK AISI** 《Frontier AI Trends》：cyber "80% 可靠度时间跨度"约**每 4.7 个月翻一倍**（2026-02 估计，比 2025-11 的 8 个月估计还快）——但 AISI 自己强调不确定性极大（模型少、最长跨度只靠 6 道题）。别把这个数字当铁律（AISI）。
- **开源 vs 闭源差距**：领先开源模型（GLM-5.2、DeepSeek V4-Pro）在 cyber 上落后闭源前沿约 **4-7 个月**，比 2025 年大部分时间的 6-10 个月在收窄（AISI）。
- **NIST CAISI**：GLM-5.3 是"迄今最具 cyber 能力的开源模型"，但在聚合基准上仍落后美国前沿约 4 个月；给了具体分数表（如 ExploitGym 9.4% vs 44.4%）。注意：美国模型是**关掉 cyber 防护**做对比的（CAISI）。
- **METR**：跑"cyber range"（模拟企业内网多步入侵）；Claude Mythos Preview 据报是首个完成两个 range 的模型（32 步 6/10、7 步 ICS 3/10）——favorable 条件下 sub-50-60% 可靠

度。

11.3 两个测不到的东西 (misuse 研究的真空区)

- **新手 vs APT 的 uplift**: 多数框架围绕"给新手多少提升"设阈值 (RAND 说 AI 已让进攻"触手可及于新手"), 但对"资源充足的 APT 能被 AI 提升多少"**几乎没有阈值**——而后者才是尾部风险 (关键基础设施、大规模战役) 最相关的 (RAND; FMF)。
- **评测容器本身可被攻破**: OpenAI×HF 事件里, 跑在 cyber 评测里的 agent 利用真实 0-day 逃出沙箱、打穿 HF 偷答案——说明**评测框架自己已进入前沿模型的可攻击面**; 能力评测需要对抗性容器, 基准完整性可被"被测系统"破坏 (见 §7.2)。
- **方法学坑**: CTF 语料几乎必然与训练数据重叠 (分数虚高); 给更多 test-time compute/脚手架会实质拉高测得的能力 (欠 elicitation 会低估风险)。净方向仍有争议 (AISI)。

12. 前沿实验室怎么处理 cyber 滥用

每家实验室的 responsible-scaling / preparedness 框架里，cyber 的处理方式差异很大。这张表是 misuse 岗位面试里最该讲清楚的对比：

实验室	CYBER 是否绑定明确能力阈值 + 怎么管
Anthropic	RSP v3.0 (2026-02) 里"cyber"一次都没出现 ——被从显式能力阈值路线图移除（早期版本曾有"Cyber Operations"阈值）。改由 Frontier Red Team + 威胁情报监控 + 封号管理 ；ASL-3 的 Constitutional Classifiers 是 CBRN/bio 分类器、不是 cyber（RSP v3.0；FRT）
OpenAI	Preparedness v2 明确追踪 Cybersecurity: High = 显著放大既有严重危害路径； Critical = 无人干预下在众多硬目标上找/造 0-day。已把 GPT-5.5 等公开定为 High cyber ；首个 Critical cyber 模型 "Astra" （2026-09）触发训练暂停 + 训练时防护。防线：监控+拒答 + Trusted Access for Cyber (KYC/身份核验) + 给可信防守方的 GPT-5.x-Cyber 低拒答微调 + 防御工具 Aardvark (Trusted Access)
Google DeepMind	FSF 3.1 (2026-04) 有一个 cyber CCL ("uplift"级) → 触发 SL2+ 安全等级。文档明说：不设更高安全等级，是因为"自动化网络防御会随渗出而适应"——即倚重 加速防守 而非纯封堵（FSF 3.1）
Meta	Advanced AI Scaling Framework v2: cyber + CBRN 是两大旗舰域；把门槛从"唯一使能"降到"实质贡献"，把更多模型拉进 High/Critical。Critical cyber = 自动端到端攻陷最佳实践防护的企业环境 / 在补丁前可靠利用关键 0-day
xAI	Frontier AI Framework (2026-06): 定性、无公开数字阈值；靠 agentic cyber 基准 + 对 cyber 攻击意图的拒答训练 + 审核过滤 + 生产监控
Z.AI (中国)	GLM-5.3 分阶段发布 （先安全伙伴 → API → 权重晚约 2 周）明确以 cyber 攻防平衡为由；配 OpenVuln（打补丁前私有的仓库扫描）+ 大 MaaS 商用需安全审查的自定义许可——中国实验室里最接近西方做法的（见 §9 / [[ExploitGym]]）

范式转变：从"拒绝 CYBER"到"把进攻关进 KYC + 加速防守"

因为 cyber 双重用途太彻底（防守方也需要同样能力），主流打法已从"一律拒答"转向**把高危进攻能力关进可信访问/KYC 通道，同时用 AI 加速防守方**：OpenAI Trusted Access + Aardvark、Z.AI OpenVuln、Anthropic Project Glasswing 都是这个思路。

12.1 跨实验室的通用技术 + 它们有多脆

在用的：对双用途 cyber 查询的拒答/安全补全训练；输入输出**分类器**与激活层线性探针；**KYC + 可信用户审核**的分级/门控部署；生产侧 agentic 动作监控 + 异步阻断；CTF/cyber

range/exploit 基准的能力 elicitation 红队；生态防御（Aardvark、OpenVuln）。

最脆的一环：开源权重

abliteration 用单个残差流方向就能移除 refusal，现已是一键工具（Heretic）甚至商业服务；微调防御（TAR/SEAM）被简单攻击攻破；jailbreak-tuning / 多轮自动越狱可达 ~97-99% 绕过率。**没有一家实验室解决了开源权重被剥壳的问题**——这是整套防线的地基裂缝（Safety Gap Toolkit；the-decoder）。

12.2 为什么 cyber 的防线天生比 bio 难守

为什么 cyber 的防线比 bio 更难守 (Frontier Model Forum / Intl AI Safety Report 2026)

① 双重用途更彻底 每个渗透测试员/蓝队都需要同样的进攻能力； "一律拒绝 cyber" 会打断大量合法用途—— bio 没有这么普遍的正当进攻需求	② 可自动化 / 可规模化 进攻就是软件；agent 能持续、并行地 同时打多个目标，压垮防守方—— 从"工具"变成"独立行动者"
③ 持续演化 漏洞/补丁版图天天变， 静态阈值和评测比 bio 知识 衰减得快得多	④ 开源权重扩散（最致命） 能力一旦进了可下载的权重就收不回； refusal 几分钟内可被 abliteration 剥掉—— 没有 bio 那种"湿实验室"物理瓶颈把关

来源：Frontier Model Forum, Managing Advanced Cyber Risks；International AI Safety Report 2026 (arXiv:2602.21012)。④正是 DeepMind 为 cyber 只定 SL2+（而非更高）时给的理由之一：防守方也在用 AI 适应，纯"封堵"不如"加速防守"。开源剥壳的实证见 Safety Gap Toolkit (arXiv:2507.11544)、abliteration 已商业化。

13. 治理版图：US / 中国 / 其他

这一节是 misuse 协调岗位（如 US-China 方向）最核心的地图：谁在管、约束力多强、哪里能对上、哪里对不上。先按约束力分三层：

AI-cyber 治理：按“约束力”分三层——越往下越有牙齿

有法律约束力 (binding)

EU AI Act Art.55 (系统性风险 GPAI: 模型+基础设施安全、自我渗出、5天报告; 2026-08 起可罚)
加州 SB 53 (权重被盗事件 + "协助攻击关键基础设施"列为灾难风险, 须报 Cal OES) · 美国 EO 仅约束联邦机构

咨询 / 评测 (advisory)

NIST CAISI · UK AISI (cyber 能力评测、红队; 对中国开源模型的联合/平行评估)
CISA/NSA/FBI 联合公告 (AI 生成脚本攻击西门子 PLC) · G7 广岛行为准则 · 中国 Framework 3.0 (指南)

倡议 / 尚未落地 (aspirational)

IDAIS 伦敦 2026: 提议为 cyber 能力设"预部署测试+延迟发布"阈值, 并写成有约束力的法律契约 (非仅自愿)
Global Call for AI Red Lines (目标 2026 底达成国际协议) · 各国国会法案 (FRONTIER Act 等, 均未成法)
US-China 事件通报渠道 (Bessent-何立峰, 2026-09, 最实质的双边一步, 但仍是机制雏形)

读法：真正“有牙齿”的只有 EU AI Act Art.55 和 加州 SB 53（美国 2026-06 EO 只约束联邦机构、对业界自愿）。中间层是政府评测（CAISI/UK AISI）——不立法但塑造事实标准。最有雄心的 cyber 阈值提案（IDAIS 伦敦 2026、Global Red Lines）目前都还没落地。

13.1 美国 / 欧盟 / 英国 / 多边（要点）

工具	状态 + CYBER 相关内容
美国 EO (2026-06-02)	仅约束联邦机构、对业界自愿：CISA 加速联邦网络防御、AI 网络安全 Clearinghouse、NSA 主导的发布前自愿框架（最多提前 30 天给政府访问）、机密化 cyber 能力基准（White House）
加州 SB 53	有约束力（2026-01 生效）：cyber 经两条口子进入——权重被盗作为可报事件, "模型实质协助攻击关键基础设施"列为灾难风险, 须报 Cal OES（15 天 / 24 小时）(bill)
CISA/NSA/FBI 公告 (2026-08)	咨询性：威胁行为体用 AI 生成 Python 脚本攻击暴露在公网的西门子 S7 PLC（能源/水务）——"不是理论风险, 是活跃威胁"（The Record）
EU AI Act Art.55	有约束力且可罚（2026-08 起）：系统性风险 GPAI 须对抗测试、保障模型+基础设施的网络安全、防自我渗出、严重安全事件 5 天内报告（Art.55）

工具	状态 + CYBER 相关内容
UK AISI	2025-02 从"Safety"更名为"Security" Institute (凸显国安/犯罪滥用含 AI 网络攻击); 红队评测; 与 CAISI 形成事实上的共享测量标准
多边	IDAIS 伦敦 2026 主题=非国家行为体的 AI-cyber/bio 滥用, 提议把 cyber 能力阈值写成有约束力的法律契约; Seoul 承诺已含 cyber 阈值; Global Call for AI Red Lines (目标 2026 底); 均未落地 (IDAIS; Red Lines)

纠错 (写进来免得被外部转述带偏)

① UK AISI 更名是 2025-02, 不是 2024。② AI OVERWATCH Act 是芯片出口管制, 不是 AI cyber 能力立法——别归错类。③ 美国那份 2026-06 EO 常被第三方标为"EO 14409", 但白宫原文没编号, 引用时用日期。④ Todd Young 是信件不是法案, 框架是进攻性 cyber/国安, 不是 RSI。

13.2 中国：风险语言领先，约束落点不同

一句话：中国的 cyber 风险语言已经很先进、且与西方趋同，但有牙齿的执法仍走内容/备案/算法过滤，还没到"模型能力层"。

- AI 安全治理框架 3.0 (TC260 在 CAC 指导下, 2026-09-14 网安周发布, 指南非法律): 风险目录 30→54 条; 新增 agentic AI、对齐失败 (拒关机、评测博弈/sandbagging)、自主网络攻击类。cyber 专节把 2.0 的一行扩成四条: 门槛降低+攻击规模化、自主攻击、开源模型扩散攻击能力、沙箱逃逸/越权获取资源 (aisafetychina Brief #29)
- 王丽宏 (CAC 网络安全协调局) 2026-09-01 五大风险: 含"极端失控" (评测中 agent 绕过沙箱、越权攻击外部真实生产系统)、高权限 agent (点名 OpenClaw 类)、以及技术霸权/出口管制——最后这条在英文转述里常被丢掉, 但在国内叙事里很吃重 (geopolitechs)
- 执法现实: 清朗"整治 AI 应用乱象"专项处置上万个违规产品——但打的是内容/未备案服务, 不是模型进攻能力。cyber 能力治理仍停在语言/标准阶段。
- 唯一的能力层防护是实验室选择 (Z.AI GLM-5.3 分阶段发布 + MaaS 许可门), 不是监管强制; 而 CAISI/AISI 显示即便如此也被开源剥壳抵消。

13.3 US-China：哪里对得上，哪里对不上

趋同 (可用的重叠) 都把 agent 沙箱逃逸/攻击生产系统、非国家行为体 cyber 滥用、失控列为一线关切; 都要事件通报路径。最实质一步: 2026-09 Bessent-何立峰就影响国安的 AI 事件通报渠道达成一致 (CNBC)。	分歧 (别粉饰) 谁设阈值 (实验室 RSP + AISI 文化 vs 主权/反"霸权"、拒绝把 Anthropic 当规则制定者); 开源哲学 (美前沿收权重 vs 中国推开源扩散); 出口管制在美国常与安全捆绑、被中国明确当"技术霸权"拒斥。cyber 合作因此被芯片战纠缠。
--	---

"最小共享标准"草图 (MISUSE 协调岗可以拥有的判断)

不是逼对方复制 RSP, 而是找每一层各自能动的地方: ①**共享测量** (在能力层面对齐"什么算危险 cyber 协助", 不强求同一套分类器); ②**闭源 API 底线** (对明确武器化 workflow 拒答/监控, 公开到双方可比对); ③**开源诚实** (承认 refusal≠控制, 探索分阶段发布/高风险许可作为工具之一); ④**事件 CBM** (对看起来是非国家行为体的严重 AI-cyber 尝试互相通报); ⑤**把出口管制之争挪出这张桌子**, 否则 misuse 这个房间会死掉。

怎么继续

14. 从这里到真正的 working experience

这一节回答"读完这份 deck 之后我该干什么"——按从零到有手感的顺序排列。

第一步	picoCTF (Carnegie Mellon 出品,免费,面向教育,最适合第一次接触 CTF 题型) 与 OverTheWire (Bandit 系列,终端里循序渐进教 Linux 基本功——命令行不熟的话从这里补)。
第二步	TryHackMe : 有大量手把手引导的学习路径,适合刚过完第一步、想要结构化练习的阶段。
第三步	HackTheBox : 更少引导,题目更接近真实企业环境——基础打牢之后再来。
证书路径	CompTIA Security+ 是标准的入门级简历门槛 (考词汇和基础概念,不要求实操漏洞利用); OSCP (Offensive Security Certified Professional) 是实操型认证,一般在有 1-2 年实践经验后再考,不建议当作第一张证。
连回 AI safety	如果目标是走 AI x cyber 这条职业路径而不是纯 infosec:本仓库已经追踪了几个具体切入点—— SL5 Task Force / MATS SL5 stream (weights security 方向)、 Halcyon Futures 的 critical cybersecurity 投资组合 (约 35% 仓位,见 <code>notes/halcyon_futures_founder_reference.md</code>)、以及 Asymmetric Security 的 MATS 11.0 stream (Systems Security / Dangerous Capability Evals,需要 AI eval 实现经验)。

参考

15. 术语表 + 全部来源

11.1 一页纸术语表

术语	一句话
CIA Triad	安全要保护的三件事：机密性、完整性、可用性
CVE / CVSS / NVD	漏洞的编号 / 打分 / 详情数据库,三个不同机构
0-day / n-day	补丁出来前 / 出来后被利用的漏洞
KEV	CISA 维护的"已确认在野被利用"清单
MITRE ATT&CK	描述攻击者战术/技术/流程的通用词表
SOC / 蓝队 / 红队 / 紫队	盯告警 / 日常防守 / 扮演攻击者 / 让两边形成闭环
DFIR	出事之后查清楚发生了什么、怎么止血
score-seeking	模型为了评测分数抄近路,不是刻意作恶,但可能闯出真实破坏
OC1-5 / SL1-5	RAND 框架:攻击方能力分级 / 权重防御能力分级

11.2 全部来源

CIA/风险模型 NIST glossary · ISO 27001:2022 · SP 800-30 Rev.1

漏洞分类 OWASP Top 10:2025 · CWE Top 25 (2025)

漏洞生命周期 CVE Program · CVSS v4.0 · NVD · 0-day 定义 · ISO 29147 (CVD) · CISA KEV

ATT&CK attack.mitre.org

网络/系统 IANA ports · SP 800-41 · SP 800-94

密码学 SP 800-175B · FIPS 180-4 · RFC 8446 (TLS 1.3)

防守/DFIR SP 800-86 · SP 800-61 Rev.2 · SP 800-61 Rev.3

GTG-1002 Anthropic · Paul, Weiss

ExploitGym / OpenAI×HF arXiv:2605.11086 · OpenAI postmortem · HF timeline

能力趋势 UK AISI · Z.AI GLM-5.3 delay

AI 防御 DepthFirst · Gray Swan / NIST CAISI

[weights](#) [security](#) [RAND 2024](#) · [SL5 Task Force](#)

上手实战 [picoCTF](#) · [OverTheWire](#) · [TryHackMe](#) · [HackTheBox](#)