

OpenAI 的 719 篇 AI 数学论文：从零读懂它们在说什么

2026-10-06, OpenAI 一次性公开了一个未发布内部模型生成的 **722 篇数学手稿 (372 个结果族)**, 其中声称解决了准黎曼猜想、Unique Games 猜想、矩阵乘法指数 $\omega \leq 9/4$ 、Thompson 群不可顺从、平面不能 5 着色等一批几十年的名题; 第二天因一个符号错误撤回 3 篇。数学界称之为 "Mathocalypse"。这份 deck 的目标: **只用线性代数 + 微积分 + 高中数学**, 把其中 10 个代表性结果各自讲到"能判断它有多大、多难、为什么重要、核实到哪一步"。

2026-10-08 首版; 10-09 改版 (10 个结果合并为从零详解的单一版本, Part II 前瞻重写为 §17-§23) · repo 快照 [openai/math@fd4aeeb](https://github.com/openai/math@fd4aeeb) (含 10-07 撤稿与修补) · 每条事实标来源; [P] = 读过一手材料 (论文/repo/Lean 源码), [R] = 二手报道, Δ = 未核实或有冲突 · 研究底稿保存在作者的研究笔记中, 未随本 deck 公开

ORIENTATION

0. 这份 deck 能带你到哪, 到不了哪

读完能得到

对 10 个头条结果各有一个"阶梯式"理解: 从一个你能手算的玩具例子出发, 一级一级走到真正的命题; 知道这个问题此前卡了多少年、卡在哪; 知道 OpenAI 具体声称了什么、Lean 形式化覆盖到哪、人类专家目前怎么说; 以及它对数学、对 AI、对 AI safety 各意味着什么。

读完得不到

判断任何一个证明是否正确的能力。这 10 个结果里, 截至 10-08 **没有一个**有人类领域专家公开表示"我读完并确认了"。本 deck 里的"核实"只到两层: ① 我们静态审查了 Lean 源码与陈述; ② 汇总了公开反应。都标注了来源和可信度。

0.1 阅读路径

§1 先补三样基础 (数学家在做什么、什么叫"开放问题"、怎么判断一个结果有多大)。§2-§3 是事件本身和"Lean 到底保证了什么"——**这两节决定你该怎么读后面所有的"声称"**。§4-§13 是 10 个结果, 每节都从最基础的概念讲起, 配可以手算的小例子和【检查】练习, 结构相同: 先说结论 → 从零搭概念 → OpenAI 声称了什么 → 核实到什么程度 → 如果为真意味着什么, 可以按兴趣跳读。§14 是撤稿案例, §15-§16 是横向总结和对 AI 的含义。**Part II (§17-§23) 是前瞻**: 如果数学被 AI 大规模解决, 或者 AI 的其他能力也突破, 计算机与密码、物理与化学、生物与医学、AI 本身、经济与治理分别会发生什么。§17 先用历史和三条能力曲线校准; §18-§22 每节挑出该领域真正重要的问题, 逐个讲清"瓶颈是不是数学、AI 能改变什么、

更深远的影响是什么、大概什么时候”；§23 是全景、Top 10 和时间线。§24 是各方反应，§25 是开放问题和继续学习的路线，§26 是术语表与来源。

0.2 一张速查表

§	结果 (FAMILY 编号)	卡了多久	LEAN	一句话
4	准黎曼猜想 (003)	~125 年	有	ζ 在 $\text{Re } s > 7/8$ 整块无零点
5	π 的无理性指数 = 2 (017)	~70 年	有 Δ	π 不能被分数"异常好"地逼近
6	矩阵乘法 $\omega \leq 9/4$ (107)	57 年	有	一次下降 0.12, 此前 12 年只降 0.0017
7	Unique Games 猜想 (102)	24 年	有	一大批近似算法的"最优性"变成定理
8	$L = RL = BPL$ (103)	~30 年	有	小内存计算里随机性毫无用处
9	平面不能 5 着色 (158)	76 年 (下界上次推进在 2018)	有	平面色数 $\in \{6, 7\}$
10	Thompson 群 F 不可顺从 (248)	47 年	有	两个方向都有人"证明"过又撤回的名题
11	Navier–Stokes 爆破 (9 月单独发布)	千禧年问题	有	只覆盖"带外力"分支; 归属有争议
12	相对论 Vlasov–Maxwell (362)	40 年	有	等离子体模型的大初值整体光滑性 (单粒子种类)
13	Mézard–Parisi 公式 (221)	25 年	有	稀疏自旋玻璃的自由能公式 (偶数元情形)
14	Hodge 相关撤稿 (032 等)	—	无	一个符号错误撤掉 3 篇: 未形式化的风险

FUNDAMENTALS · 先补课

1. 数学家到底在做什么

一句话：**研究抽象对象的结构，并用证明确立关于它们的真理**。区分数学、科学、工程的关键是"怎么知道一件事是对的"：数学靠逻辑证明（一旦证明永远成立），科学靠实验（可能被推翻），工程靠"能用、测出来够好"。

1.1 四个词

词	意思	这次事件里的例子
猜想 conjecture	大家相信但没人证明的命题	Unique Games 猜想 (Khot 2002)
定理 theorem	已被证明的命题	Goemans–Williamson 的 0.878 算法
反例 counterexample	一个具体对象，说明某个"对所有...都成立"的猜想是错的	9 维 Borsuk 反例；本批约 20% 的结果是反例/否认
形式化 formalization	把证明写成计算机能逐步检查的代码（本批用 Lean 4）	本批约 300/719 个顶层结果有 Lean 证明

1.2 两种数学文化

Fields 奖得主 Gowers 在 The Two Cultures of Mathematics（2000）里把数学家分成**解题者**（攻克具体难题，比如 Erdős 问题）和**理论建构者**（发明新概念、新框架，比如"群""流形"）。Thurston 在 On Proof and Progress in Mathematics（1994）里进一步说：数学的目的不是产出定理，而是**增进人类的理解**。这两篇是读懂这次争论的钥匙——AI 这次大规模攻破的是"解题者文化"那一侧，Tao 说的"Math 1.0 结束"正是在这里。

1.3 怎么判断一个结果"有多大"：五个问题

1. **卡了多久、谁试过？** 一个 50 年无人解决、顶尖专家多次失败的问题，和一个刚提出两年的问题，分量完全不同。
2. **是"最后一步"还是"跳了一大步"？** 矩阵乘法 ω 从 2.3713 到 2.3711 是前者，到 2.25 是后者。
3. **能解锁多少别的结果？** Unique Games 一旦成立，几百篇"若 UGC 则....."的论文同时变成定理。
4. **方法新不新？** 新方法往往比结论本身更重要，因为它能被复用。
5. **题目是谁选的、失败了多少？** 这是本次事件最容易被忽略的一问，见 §2.3 和 §15。

2. 发生了什么

日期	事件
2025-07	OpenAI 实验模型与 Google DeepMind Gemini Deep Think 在 IMO 2025 达到金牌分数 (35/42) ——"有标准答案的竞赛题"被攻破。 [R]
2026-09-08	OpenAI 宣布约 1 万个 agent、88 小时证明了 3D Navier–Stokes 的"带外力有限时间爆破" (166 页 + Lean)，引发归属争议 (§11)。 [P] [R]
2026-09 下旬	普林斯顿 IAS 主持的 Advisory Group on Mathematics and AI (成员含 Terence Tao) 发布 AI 数学成果的出版建议。 [R]
2026-10-06	openai/math 发布：722 篇手稿 / 372 个结果族，Apache-2.0，附 Lean 库与 10 份删节版推理摘要。 [P]
2026-10-07	撤回 3 篇 (同一符号错误连锁)，修补 14 篇，13 篇更新引用，新增 6 个形式化 → 719 篇 ，"顶层结果形式化 300/719 ≈ 42%"。AHM (Association for Human Mathematics) 声明经 Tao 博客转载；Scott Aaronson 发文 "The Mathocalypse"。 [P] [R]
2026-10-08	Tao 博客发 Lozano-Robledo 客座文 What should we tell our students?。 [P]

2.1 怎么产出的


README 原文 [P]： "The vast majority of results were obtained with the same procedure using an unreleased internal OpenAI model. On average, each result used three hours of ChatGPT Pro thinking compute... the model was posed approximately 4,000 problems... requiring an appropriate level of significance led to the catalog." 也就是：**约 4,000 道开放题 → 按"够重要"筛选 → 372 族**。OpenAI 发言人对 Scientific American 说几乎所有结果都来自"交给单个 agent 的单个 prompt" [R]；MIT 的 Andrew Sutherland 回应："在模型能被复现之前，'一发入魂'应视为未验证——要看收据。"

例外：README 承认 ζ 零点无零区 (§4) 和 CM 阿贝尔簇的 Hodge 猜想 (§14) 不是走这个固定流程产出的，并且 Re $s > 11/12$ 那份写作经过人工编辑。具体例外是什么 (更多算力？人工引导？) 没有披露 △。

2.2 数字对账

说法	真实含义
"722 篇" vs "719 篇"	发布时 722；10-07 撤回 3 篇后 719。早期新闻用 722。
"372 族" vs "377"	目录编号 001–377，其中 045/061/070/123/163 空缺，实际 372 族。
"~42% 已形式化"	300 个顶层结果 ÷ 719 篇手稿——分子分母单位不同。按族算， $242/372 \approx 65\%$ 的族有 Lean 范围说明文档。
"162 篇完整 + 73 篇部分形式化"	部分媒体的说法，未找到出处 △。

372 个结果族按学科分布（橙色 = 本 deck 深讲了其中至少一个结果）



来源：openai/math overview.pdf 的 17 个学科小节，逐条计数（合计 372）。编号 045/061/070/123/163 空缺，原因未公开。

2.3 必须先记住的一件事：选择效应

Epoch AI 的 FrontierMath Erdős（2026-09）选了 68 个预先登记为开放的 Erdős 问题，要求 Lean 证明，结果 GPT-6 Astra 只解出 2 个（ $\approx 3\%$ ），其他模型 0 个。OpenAI 这次是事后筛选：4,000 题里留下"够重要"的、没公开失败清单。粗算命命中率 $\leq 9\%$ （按族）——但两边题目难度不可比。两个数字都对，只是回答的问题不同：前者问"随便给一道开放题它能做出来吗"，后者问"给它 4,000 道，能挑出多少好结果"。

3. "有 Lean 证明"到底保证了什么

Lean 是一种"证明助手": 你把定理和证明写成代码, 一个很小的内核逐步检查每一步推理。只要内核没 bug、只用了公认的公理, 通过检查就意味着"这个 Lean 陈述为真"。它和人类审稿的区别类似于"编译器 + 类型系统"和"code review"的区别——后者会漏, 前者不会漏它检查的那部分。

"有 Lean 证明"到底保证了什么: 从下往上的信任栈

① Lean 内核逐步检查证明 本 repo: sorry = 0, 自加 axiom = 0, native_decide = 0	强
② 只用 3 条标准公理 Comparator 416 个配置全部只允许 propext / Quot.sound / Classical.choice	强
③ Lean 陈述 = 论文想说的那句话? 挑战文件由 OpenAI (agent) 自己写; 要靠人逐行读几十行定义	要人审
④ 依赖库与补丁里的定义对不对? 24 个补丁 (最大 ~2MB) + 11 个来源不明的 lana-agents/* 依赖库	未审
⑤ 没有形式化的那 ~58% 完全没有机器检查—10-07 撤回的 3 篇 Hodge 相关论文就在这里	无

①② 是机器能保证的; ③④⑤ 仍然要靠人。审计数据来自本 deck 对 `lean/OAI/` (122,458 个 .lean 文件、约 2,600 万行) 的源码 grep 与 Comparator 配置统计 (2026-10-08, commit fd4aeeb); 未实际编译。

3.1 我们对 Lean 库做的静态审计 [P]

检查项	结果	含义
sorry (未完成证明)	0	没有"先空着"的步骤
axiom 声明	0 (命中全在注释里)	没有偷偷加公理
native_decide / implemented_by / extern	0	没有"信任编译器"的后门
decide +kernel	≈131 万行, 5,848 个文件	大量有限计算由内核完成——仍在可信范围内, 但证明极其庞大
Comparator 配置	416 个, 全部只允许三条标准公理; 仅 2 个开启第二独立内核 nanoda	见下文
lean/patches/	24 个补丁, 打在第三方依赖库上 (不是 Lean 内核, 也不是 Mathlib), 最大约 2 MB	补丁会改依赖库里的定义与证明 △
依赖	30 个, 其中 11 个来自来源不明的 <code>lana-agents/*</code>	信任链上的开放点 △
formalization.yaml	<code>review: status: unchecked</code>	OpenAI 自己标注: 未经审查

范围: lean/OAI/ 共 122,458 个 .lean 文件、约 2,600 万行; 只做了源码 grep 与配置统计, 未实际编译 (全库编译需数 GB 内存与 Linux 沙箱)。独立复核: Dave Goldblatt 用 Comparator + nanoda 两个内核跑通了 ζ 的 7/8 证明 (约 63 分钟) [repo]; 另有第三方复查了 9/4 矩阵乘法定理的陈述 [repo]。

3.2 Comparator: 防的是什么、不防什么

Lean FRO 的 Comparator 拿一个"挑战文件" (只有定理陈述, 证明处写 `sorry`, 只引用 Mathlib 等可信库) 和一个"解答模块"做比对: 解答里的定理必须和挑战里的陈述是**同一个类型**, 且只用允许的公理。它防的是"在证明里偷换陈述、改定义、加公理"。它**不防**: 挑战文件本身写的陈述是否忠实于论文想说的话——而挑战文件是 OpenAI (的 agent) 自己写的。所以本 deck 每一节的"核实状态", 重点都在**逐行读陈述**。

一个活生生的反面例子

OpenAI 的平面着色论文脚注提到: 2026-05 有一份手稿宣称平面色数 = 7 并附有"形式化定理"——但那个定理把一个错误的密度上界当成了假设。形式化本身没错, 错的是被证明的命题。[P, 经 OpenAI 论文转述; 原稿未读 △] 这和 AI 里的"规格博弈" (specification gaming) 是同一类问题: 系统完美满足了写下来的规格, 但规格不是你真正想要的。

4. 准黎曼猜想 (Quasi-Riemann Hypothesis): 素数分布的"噪声上限"

数论 · OpenAI 编号 family 003。前提只需要：会算乘方和对数、知道求和符号 Σ 、知道什么是函数。凡是用到的新概念都会先讲。文中所有数字都由脚本实算或有出处。标记：[P] = 直接读过的一手材料（论文、repo 文件、Lean 源码），[R] = 二手转述， $\triangle$ = 未能核实或有疑点。

【检查】是可以自己动手算的小练习，答案在章末。预计阅读时间：60–90 分钟。可以分三次读：§4.1–4.3（素数和误差）、§4.4–4.6（ ζ 函数和零点）、§4.7–4.10（OpenAI 的结果和意义）。

4.0 先说结论：这一章要讲明白的一件事

素数 (2, 3, 5, 7, 11, ...) 看起来是乱撒的，但整体上非常有规律。数学家能写出一个公式，精确预测"x 以内大约有多少个素数"。真正难的问题是：**这个预测最多会错多少？**

这一章要讲清楚的是一条因果链：

预测的误差有多大 $\Leftarrow$ 由一组"波"决定 $\Leftarrow$ 每个波对应 ζ 函数的一个"零点" $\Leftarrow$ 零点离某条线越远，误差越大。

黎曼猜想说：所有零点都整整齐齐排在一条线上，所以误差尽可能小。没人能证明。

准黎曼猜想是一个弱得多的版本：它不要求零点都在那条线上，只要求它们**不要太靠右**。这个弱版本 125 年来也没人证明。OpenAI 声称证明了它。

读完这一章，你应该能用自己的话讲出：

- "零点"和"素数计数的误差"到底是什么关系；
- 为什么"无零区越来越窄"和"有一块固定宽度的无零区"之间是质的差别；
- OpenAI 声称的结果如果为真，具体意味着什么、不意味着什么。

4.1 素数：数一数，找规律

4.1.1 素数是什么，为什么重要

素数是只能被 1 和自己整除的大于 1 的整数：2, 3, 5, 7, 11, 13, 17, 19, 23, 29, ...

它们重要，是因为**每个整数都能唯一地拆成素数的乘积**（算术基本定理）：

- $12 = 2 \times 2 \times 3$

• $360 = 2 \times 2 \times 2 \times 3 \times 3 \times 5$

所以素数是整数的"原子"。你每天用的 HTTPS 加密（RSA）就建立在一个事实上：两个大素数乘起来很容易，但把乘积拆回去极难。

4.1.2 数一数

记 $\pi(x)$ = "不超过 x 的素数有多少个"。这里的 π 只是一个名字，和圆周率无关，是历史遗留的记号。

x	$\pi(x)$ (真实个数)
10	4 (2, 3, 5, 7)
100	25
1,000	168
1,000,000	78,498
1,000,000,000	50,847,534

素数越往后越稀疏：100 以内四个数里就有一个素数，100 万附近每 1000 个数里只有大约 72 个（这是按下一节的 $1/\ln x$ 规律估算的；脚本实数：999,001 到 1,000,000 这 1000 个数里实际有 65 个素数）。

4.1.3 第一个规律：密度约等于 $1/\ln x$

高斯（Gauss）在十几岁时盯着素数表发现：在 x 附近，大约每 $\ln x$ 个数里有一个素数。

这里 $\ln$ 是自然对数，以 $e \approx 2.718$ 为底。 $\ln(1,000,000) \approx 13.8$ ，意思是 100 万附近大约每 14 个数里有一个素数。上面实算是每 1000 个数 65 个，约每 15 个一个，很接近。

【检查 1】 $\ln(1000) \approx 6.9$ 。按这个规律，1000 附近每 1000 个数里大约有几个素数？

4.1.4 素数定理

把"密度 $1/\ln t$ "从 2 积分到 x ，就得到 x 以内素数个数的预测：

$$\pi(x) \approx Li(x) = \int_2^x dt / \ln t$$

$Li(x)$ 叫"对数积分"。不熟悉积分也没关系，把它理解成"把每个位置的密度 $1/\ln t$ 加起来"就行。

x	真实 $\pi(x)$	粗略预测 $x/\ln x$	精确预测 $Li(x)$	Li 的误差
1,000	168	145	177	+9
1,000,000	78,498	72,382	78,627	+129

x	真实 $\pi(x)$	粗略预测 $x/\ln x$	精确预测 $\text{Li}(x)$	Li 的误差
1,000,000,000	50,847,534	48,254,942	50,849,235	+1,701

($\text{Li}(10^9)$ 用的是文献标准值；其余由脚本计算。)

素数定理 (1896 年由 Hadamard 和 de la Vallée Poussin 独立证明) 说: $\pi(x)$ 和 $\text{Li}(x)$ 的**比值** 趋近于 1。从表里能看到: 误差的绝对值在变大 ($9 \rightarrow 129 \rightarrow 1,701$), 但相对于总数越来越微不足道 (10^9 时只差万分之 0.3)。

4.2 真正的问题: 误差到底有多大?

4.2.1 两种"误差在变小"的说法, 强度完全不同

素数定理只说"误差 / $x \rightarrow 0$ ", 也就是相对误差趋于 0。但它没说**趋于 0 有多快**。

一种直观的衡量方式是: 误差大概是 x 的多少次方?

- 如果误差 $\approx x^{0.5} = \sqrt{x}$: 10^9 时 $\sqrt{x} \approx 31,623$ 。上表里的真实误差 1,701 比这还小。
- 如果误差 $\approx x^{0.875} = x^{(7/8)}$: 10^9 时约 7,500 万, 比真实误差大得多。

注意: **真实误差**和**能证明的误差上限**是两回事。数值上看, 真实误差小得很 (大约 $\sqrt{x}$ 量级)。但数学家需要的是**证明**: "对所有 x , 误差一定不超过某某"。这一章讲的全部内容, 都是关于**能证明的上限**。

4.2.2 "幂次节约": 为什么 $x^{(7/8)}$ 是质变

1958 年以来能证明的最好上限, 大致形如:

$$\text{误差} \leq x \cdot \exp(-c \cdot (\ln x)^{0.6}) \quad (c \text{ 是某个小常数})$$

把它和 $x^{(7/8)}$ 比较, 看"误差 / x " (相对误差) 怎么随 x 变化。为了比较趋势, 下面取 $c = 1$ (真实的 c 更小, 旧上限实际还要更差):

x	旧上限的相对误差 $\exp(-(\ln x)^{0.6})$	新上限的相对误差 $x^{(-1/8)}$
10^{100}	$10^{(-11.4)}$	$10^{(-12.5)}$
10^{1000}	$10^{(-45.2)}$	$10^{(-125)}$
10^{10000}	$10^{(-180)}$	$10^{(-1250)}$

(脚本实算。)

旧上限也在变小, 但比任何" x 的负次方"都慢。新上限是" x 的负 1/8 次方", 越往后差距越大。数学家把这叫**幂次节约** (power saving): 误差比 x 小一个固定的幂次。

为什么这很重要：数论里很多更复杂的问题，都要把素数定理的误差代进去再做运算。如果误差只比 x 小"一点点"（旧上限那种），代进去之后经常被别的误差淹没；如果小一个固定的幂次，就有余量去做各种推论。

4.3 关键的转折：误差是由"波"组成的

这是黎曼 1859 年的天才想法，也是整章最重要的一步。

4.3.1 先用声音做类比

一段声音（比如一个和弦）可以拆成若干个纯音（正弦波）的叠加，每个纯音有两个属性：

- **频率：**振动多快
- **振幅：**声音多大

这叫**傅里叶分解**。你学神经科学时见过的 EEG 频谱（alpha 波 8–12 Hz、beta 波.....）就是同一个思想：把复杂信号拆成不同频率的波。

4.3.2 黎曼的发现

黎曼发现，素数计数的误差也能这样拆：

$$(\text{素数的加权计数}) = (\text{平滑的主项}) - \sum (\text{一个个"波"}) - (\text{一些小修正})$$

（为了公式干净，数学家通常用一个加权版本的素数计数 $\psi(x)$ ，每个素数 p 按 $\ln p$ 计重。它和 $\pi(x)$ 本质上是一回事。）

主项是平滑的，大约就是 x 。误差全部来自那些"波"，而且：

- **每个波对应 ζ 函数的一个零点**（§4.5 解释什么是零点）。
- 零点写成 $\rho = \beta + i\gamma$ 的形式，有两个坐标 β 和 γ 。
- **γ 决定这个波的频率**（振动多快）。
- **β 决定这个波的振幅随 x 增长多快：**这个波的大小约为 x^β 。

所以：

- 如果所有零点的 β 都等于 $1/2$ ，每个波的大小约为 $\sqrt{x}$ ，误差就约为 $\sqrt{x}$ 。这正是**黎曼猜想**。
- 如果有某个零点的 β 接近 1，它对应的波的大小接近 x ，几乎和主项一样大，误差就会非常大。
- 如果能证明**所有零点的 β 都不超过 θ** ，那误差就不超过约 x^θ 。

一句话：零点的 β 坐标（零点有多"靠右"）直接决定了素数计数的误差有多大。这就是为什么数论学家这么关心"零点在哪里"。

4.3.3 为什么会出现复数

要描述这些"波"，需要用到复数。下一节先把复数讲清楚。

4.4 复数：5 分钟版

4.4.1 复数是平面上的点

实数排在一条线上。**复数是平面上的点**：横坐标叫实部，纵坐标叫虚部。

$$s = \sigma + i \cdot t \quad \sigma \text{ 是横坐标 (实部, 记作 } \operatorname{Re} s), t \text{ 是纵坐标 (虚部, 记作 } \operatorname{Im} s)$$

i 是一个满足 $i^2 = -1$ 的符号。不用纠结它"存不存在"，把它当作"往纵向走一步"的标记就够了。

4.4.2 乘以一个复数 = 缩放 + 旋转

复数最有用的性质：**乘以一个复数，等于把一个点绕原点旋转再缩放**。例如乘以 i 就是逆时针转 90 度： $1 \rightarrow i \rightarrow -1 \rightarrow -i \rightarrow 1$ ，转了一圈。

4.4.3 x 的复数次方 = "大小部分" $\times$ "转圈部分"

对正实数 x 和复数 $\beta + i\gamma$ ：

$$x^{(\beta+i\gamma)} = x^\beta \times (\cos(\gamma \cdot \ln x) + i \cdot \sin(\gamma \cdot \ln x))$$

- x^β 是大小部分：随 x 增长，增长多快由 β 决定。
- $\cos(\gamma \cdot \ln x) + i \cdot \sin(\gamma \cdot \ln x)$ 是转圈部分：它的长度永远是 1，只是在单位圆上转。转得多快由 γ 决定。

这就是§4.3 说的"波"： β 控制振幅 (x^β)， γ 控制频率 (在 $\ln x$ 的尺度上振荡)。

4.5 ζ 函数和它的零点

4.5.1 ζ 函数的定义

$$\zeta(s) = 1/1^s + 1/2^s + 1/3^s + 1/4^s + \dots$$

$s = 2$ 时： $\zeta(2) = 1 + 1/4 + 1/9 + 1/16 + \dots = \pi^2/6 \approx 1.6449$ (欧拉 1734 年算出，这里的 π 是圆周率)。

$s = 1$ 时： $\zeta(1) = 1 + 1/2 + 1/3 + 1/4 + \dots$ ，这是"调和级数"，**发散到无穷**。脚本实算：前 1000 项和 ≈ 7.49 ，前 100 万项和 ≈ 14.39 ，增长很慢，但永不停止。

4.5.2 欧拉乘积： ζ 怎么"知道"素数

欧拉发现：

$$\zeta(s) = 1/(1-2^{-s}) \times 1/(1-3^{-s}) \times 1/(1-5^{-s}) \times 1/(1-7^{-s}) \times \dots \quad (\text{对所有素数相乘})$$

为什么成立：每个因子 $1/(1-p^{-s})$ 可以展开成 $1 + 1/p^s + 1/p^{2s} + \dots$ (几何级数)。把所有素数的这些展开式乘起来，每一项都形如 $1/(p_1^a \cdot p_2^b \cdot \dots)^s$ 。由于每个整数只有**唯一**的素因数分解，每个 $1/n^s$ 恰好出现一次，乘出来正好是 $\zeta(s)$ 。

手算 $s = 2$ (脚本核对过)：

- 只乘 $p = 2, 3, 5$ 三个因子： $(4/3)(9/8)(25/24) = 1.5625$
- 乘上 100 以内所有素数的因子：1.6419
- 真值 $\pi^2/6 = 1.6449$

所以 **ζ 函数把"所有整数"和"所有素数"连在一起**，这是整个故事的桥梁。

一个漂亮的推论 (欧拉对"素数有无穷多个"的证明)： $s = 1$ 时左边是调和级数，发散到无穷。如果素数只有有限个，右边只是有限个有限数的乘积，不可能是无穷。所以素数必须有无穷多个。

4.5.3 "解析延拓"：把定义扩展到整个平面

上面的求和只在 s 的实部 > 1 时收敛 (加得出一个有限的数)。但黎曼需要在整个复平面上谈论 $\zeta(s)$ 。

用一个类比来理解怎么扩展：

$$1 + x + x^2 + x^3 + \dots = 1/(1-x)$$

左边只在 $|x| < 1$ 时收敛 (例如 $x = 2$ 时左边是 $1+2+4+8+\dots$ ，发散)，但右边 $1/(1-x)$ 在除了 $x = 1$ 以外的任何地方都有意义 ($x = 2$ 时等于 -1)。我们可以**用右边来定义**原本只在 $|x| < 1$ 时有意义的东西，这就叫**解析延拓** (analytic continuation)。

数学上可以证明，这样的延拓如果存在，就是唯一的。黎曼用类似但更复杂的手法，把 $\zeta(s)$ 延拓到了整个复平面 (除了 $s = 1$ 这一点)。

4.5.4 零点

零点就是让 $\zeta(s) = 0$ 的复数 s 。

- **平凡零点：** $s = -2, -4, -6, \dots$ ，来自延拓公式的一个简单因子，没什么神秘的。

- **非平凡零点**：其余所有零点。它们都落在 $0 < \text{Re } s < 1$ 的竖条里，这个竖条叫**临界带**（critical strip）。

前三个非平凡零点（上半平面）大约是：

$$\frac{1}{2} + 14.13i, \quad \frac{1}{2} + 21.02i, \quad \frac{1}{2} + 25.01i$$

它们的实部都恰好是 $1/2$ 。

4.5.5 黎曼猜想

黎曼猜想 (1859)：所有非平凡零点的实部都等于 $1/2$ 。

数值验证已经检查了**超过十万亿个零点**，全部在 $\text{Re } s = 1/2$ 这条线上（Gourdon 2004 年验证了前 10^{13} 个零点 $\triangle$ 具体数字以原文为准）。但验证再多个也不是证明。它是 Clay 千禧年七大难题之一，悬赏 100 万美元。

把§4.3 和这里连起来：**黎曼猜想 $\Leftrightarrow$ 所有波的振幅都是 $\sqrt{x} \Leftrightarrow$ 素数计数的误差约为 $\sqrt{x}$ 。**

4.6 无零区：在无法证明黎曼猜想时，能证明什么

既然证明不了"所有零点都在 $1/2$ 这条线上"，数学家退一步问：**至少能证明零点不会出现在哪里吗？** 一块被证明没有零点的区域叫**无零区**（zero-free region）。

4.6.1 第一步： $\text{Re } s = 1$ 这条线上没有零点 (1896)

素数定理的证明，本质上就是证明了 $\text{Re } s = 1$ 这条竖线上没有零点。

用到的关键技巧是一个三角恒等式：

$$3 + 4\cos \theta + \cos 2\theta \geq 0 \quad (\text{对所有 } \theta \text{ 成立})$$

【检查 2】 用 $\cos 2\theta = 2\cos^2\theta - 1$ 证明： $3 + 4\cos \theta + \cos 2\theta = 2(1 + \cos \theta)^2$ ，所以它永远 ≥ 0 。（脚本在 $[0, 2\pi]$ 上扫了 6,284 个点，最小值是 1.4×10^{-14} ，即 0 加上舍入误差。）

这个恒等式结合欧拉乘积，可以推出：如果 $1 + iy$ 是零点，就会导出矛盾。

4.6.2 第二步： $\text{Re } s = 1$ 左边一条"越来越窄"的带子 (1899、1958)

de la Vallée Poussin (1899) 把结果推进了一点：不仅 $\text{Re } s = 1$ 上没有零点，它**左边一条窄带**里也没有：

$$\text{无零区: } \text{Re } s > 1 - c / \ln(t) \quad (t \text{ 是高度, 即虚部})$$

注意分母里的 $\ln t$ ：高度 t 越大，这条带子越窄。

- $t = 100$ 时，宽度约 $c / 4.6$
- $t = 10^{10}$ 时，宽度约 $c / 23$
- $t \rightarrow \infty$ 时，宽度 $\rightarrow 0$

Vinogradov–Korobov (1958) 把带子加宽了一点（分母从 $\ln t$ 变成 $(\ln t)^{2/3}$ 再乘一个更小的因子），但仍然随高度缩向 0。这是此后 60 多年的最好结果。

4.6.3 为什么"越来越窄"和"固定宽度"是质的差别

回到§4.3：误差由所有零点的波叠加而成，**最靠右的零点**决定误差的量级。

- 如果无零区越来越窄：理论上，在越来越高的地方，可能存在 β 越来越接近 1 的零点。没法排除它们，所以误差上限只能比 x 小"一点点"，这就是§4.2 的 $\exp(-c(\ln x)^{0.6})$ 。
- 如果有一个**固定宽度**的无零区，比如 $\operatorname{Re} s > 7/8$ 整片没有零点：所有零点的 β 都 $\leq 7/8$ ，每个波都 $\leq x^{(7/8)}$ ，误差上限就变成 $x^{(7/8)}$ 量级，也就是§4.2 的**幂次节约**。

准黎曼猜想就是这样一个命题：

存在某个 $\theta < 1$ ，使得 $\operatorname{Re} s > \theta$ 的整个区域里 ζ 没有零点。

它比黎曼猜想 ($\theta = 1/2$) 弱得多，但 2026 年之前，**没有人能证明任何一个 $\theta < 1$** 。

下图把§4.5 和本节的内容画在同一张复平面上：已知零点、越往上越窄的经典无零区，以及 OpenAI 声称的固定宽度无零区。



蓝点是 ζ 的前三个非平凡零点（都在 $\operatorname{Re} s = 1/2$ 上，黎曼猜想说全部如此）。灰色带是 de la Vallée Poussin 型无零区的示意（宽度随高度 t 缩向 0，曲线形状为示意，常数取 0.1）。红色区域 $\operatorname{Re} s > 7/8$ 是 OpenAI family 003 声称的"固定宽度"无零区——此前从未有人证明过任何固定宽度的竖带。

4.6.4 为什么经典方法做不到

§4.6.1 的 " $3 + 4\cos \theta + \cos 2\theta \geq 0$ " 型论证，从欧拉乘积在 $\operatorname{Re} s > 1$ 的性质出发，往左"渗透"一点点。但这种渗透的能力随高度 t 衰减，所以只能得到越来越窄的带子。要得到固定宽度，需要一个**本质上不同的机制**。

另一条路线叫"零点密度估计"（例如 Guth–Maynard 2024 的重要突破，arXiv:2405.20552）：它能证明" $\operatorname{Re} s > \sigma$ 的零点**很少**"，但不能证明"**一个都没有**"。OpenAI 论文的引言也专门点出了这个区别 [P]。而对误差上限来说，哪怕只有一个零点的 β 接近 1，也足以把误差拉大。

4.7 Dirichlet L 函数和 Siegel 零点

OpenAI 的结果不只关于 ζ ，还包括所有 **Dirichlet L 函数**。

4.7.1 等差数列里的素数

除了 2，所有素数都是奇数，所以要么形如 $4k+1$ (5, 13, 17, ...)，要么形如 $4k+3$ (3, 7, 11, 19, ...)。

脚本实算：

- 100 以内： $4k+1$ 型 11 个， $4k+3$ 型 13 个
- 1000 以内： $4k+1$ 型 80 个， $4k+3$ 型 87 个

两类大约各占一半（ $4k+3$ 型多数时候略多一点，但并非总是： $x = 26,861$ 时 $4k+1$ 型第一次反超。这个现象叫 Chebyshev 偏差）。Dirichlet 在 1837 年证明了：对任何模 q 和与 q 互素的 a ，形如 $qk + a$ 的素数都有无穷多个，而且长期看各类平分。

4.7.2 Dirichlet L 函数

为了分别研究每一类，Dirichlet 构造了 ζ 的变体：

$$L(s, \chi) = \chi(1)/1^s + \chi(2)/2^s + \chi(3)/3^s + \dots$$

χ （读作 chi）叫"特征"，是一个把整数映射到某些复数的函数，作用是"挑出"和"区分"不同的剩余类。例如模 4 的非平凡特征： $\chi(\text{奇数 } 4k+1) = 1$ ， $\chi(\text{奇数 } 4k+3) = -1$ ， $\chi(\text{偶数}) = 0$ 。

和 ζ 一样，L 函数的零点控制着"模 q 的各类素数"的分布误差。

4.7.3 Siegel 零点：一个困扰了 90 年的幽灵

对某些特殊的 L 函数，经典方法无法排除一种可能：它有一个**非常非常靠近 1 的实数零点**。这种假想中的零点叫 **Siegel 零点**（或 Landau–Siegel 零点）。

如果它存在，后果很奇怪：相应模下的素数会极度偏向某些剩余类。虽然大家普遍相信它不存在，但没人能排除。

更麻烦的是，1935 年 Siegel 的相关定理是"不可有效计算的" (ineffective)：它证明了某个常数**存在**，却完全无法告诉你这个常数**有多大**。这导致一批问题，比如"虚二次域的类数至少有多大"，只能得到"存在一个界"，而算不出具体的数。

准黎曼猜想如果对所有 Dirichlet L 函数成立，Siegel 零点就被自动排除了： $\text{Re } s > 7/8$ 整片都没有零点，当然也不会有靠近 1 的零点。

4.8 OpenAI 声称了什么

4.8.1 主结果

论文 *The Quasi-Riemann Hypothesis: A Zero-Free Half-Plane $\Re s > 7/8$* (2026-09-30, 199 页) 的摘要 [P]：

"We prove that all finite-order Hecke L-functions over $\mathbb{Q}(\sqrt{-3})$ and all Dirichlet L-functions are zero-free in the half-plane $\Re s > 7/8$... In particular, the Riemann zeta function is zero-free in this half-plane, proving the quasi-Riemann hypothesis."

翻译： **ζ 和所有 Dirichlet L 函数，在 $\text{Re } s > 7/8$ 这整个半平面里都没有零点。**

论文自己特意强调："The Riemann hypothesis remains open." 黎曼猜想说零点都在 $1/2$ ，这里只证明了它们都 $\leq 7/8$ 。从 $7/8$ 到 $1/2$ 之间仍然是一大片未知。

同一个家族 (family 003) 里还有两份：一份用另一种方法证明了 $11/12$ 的版本 (49 页，README 说写作经过了人工编辑)；一份 9 页的论文，单独证明了 Siegel 零点被一致排除。

4.8.2 方法的直觉 (只读了引言，以下是简化版)

- 换一个数系。**不在普通整数里做，而是在"Eisenstein 整数" $\mathbb{Z}[\omega]$ 里做， ω 是一个三次单位根，满足 $\omega^3 = 1$ ， $\omega \neq 1$ 。可以把它想成平面上的三角形格点 (普通整数是一条线上的点，高斯整数是正方形格点，Eisenstein 整数是三角形格点)。这个数系对应的域记作 $\mathbb{Q}(\sqrt{-3})$ 。
- 构造一个量，用两种方法算。**作者用"三次 theta 级数"的 Fourier 系数构造了一个和 (论文叫它"完成和"，completed sum)，它可以用两条独立的路线计算：一条用"反射公式"，一条用"Poisson 求和"。第二条路线的结果里会出现 $1/L(s, \eta)$ 这样的项，也就是 L 函数的倒数。
- 矛盾。**如果某个 L 函数在 $\text{Re } s > 7/8$ 有零点， $1/L$ 在那里就会爆掉，两种算法给出的结果就不可能一致。可以类比成：用两台独立的秤称同一件东西，如果某个假设会让两台秤读数不同，这个假设就是错的。
- 转移到普通的 Dirichlet L 函数。**利用一个分解公式 $L_F(s, \chi \circ N) = L(s, \chi) \cdot L(s, \chi X_{-3})$ ，在 $\mathbb{Q}(\sqrt{-3})$ 上的结论就能"拆"回普通整数上的 L 函数，包括 ζ 。

技术上分两步：先用较简单的版本得到 $11/12$ ，再加入额外的修正项推进到 $7/8$ 。用到的工具包括六次大筛法、Heath-Brown 对三次和的估计，以及 Dunn–Radziwiłł 2024 年在 Annals 上关于 Patterson 猜想的结果。

4.9 它被核实到什么程度

4.9.1 Lean 陈述：一行，你可以自己读懂

repo 里的"挑战陈述"文件 `lean/ComparatorChallenges/QuasiRiemannHypothesis.lean`
(只 import Mathlib) [P]:

```
theorem riemannZeta_ne_zero_of_seven_eighths_lt_re {s : ℂ} (hs : (7/8 : ℝ) < s.re) :  
  riemannZeta s ≠ 0
```

逐词翻译：

- `theorem ...`：定理的名字，字面意思是"实部大于 7/8 时 ζ 不为零"。
- `{s : ℂ}`：s 是一个复数 ($\mathbb{C}$ 是复数集合)。
- `(hs : (7/8 : ℝ) < s.re)`：假设 hs 是"s 的实部 $> 7/8$ "。
- `riemannZeta s ≠ 0`：结论是" $\zeta(s)$ 不等于 0"。

所以这一行说的就是：**对任何复数 s，如果它的实部大于 7/8，那么 $\zeta(s) \neq 0$ 。**这正是准黎曼猜想。

这里的 `riemannZeta` 是 Mathlib (Lean 的社区数学库) 里长期维护的**标准定义**，不是 OpenAI 自己写的。这一点很重要：如果定义是自己写的，就可能"偷换概念"。

4.9.2 证明本身

- 证明约 2,926 个 Lean 文件、48.7 万行 [P]。
- 我们 grep 过：没有 `sorry` ("这步先空着")，没有自己加的公理，没有 `native_decide` (信任编译器的后门) [P]。
- 独立复核：Dave Goldblatt 用 Lean FRO 的 Comparator 工具，加上另一个独立实现的检查内核 (nanoda)，把这个证明跑通了，约 63 分钟；`#print axioms` 只列出三条标准公理 (`propext`、`Quot.sound`、`Classical.choice`) [P]。复核仓库：davegoldblatt/openai-zeta-proof-check。
- ⚠ **剩余风险**：依赖库补丁 `lean/patches/PrimeNumberTheoremAnd-lean4341.patch` 约有 4 万行，其中删掉了上游的两个 `sorry` 并补上了证明。也就是说，所谓"依赖库"里有一部分是 OpenAI 自己的代码。(PrimeNumberTheoremAnd 正是下文 Kontorovich 发起的素数定理形式化项目。) Lean 内核会检查这些证明，但定义如果被改动，可能影响陈述的含义。这一点还没人逐行审过。
- **形式化只覆盖无零区本身**。Comparator 检查的是四个陈述： ζ 、Dirichlet L 函数、 $\mathbb{Q}(\sqrt{-3})$ 上 Hecke L 函数的 7/8 无零区，以及 Siegel 零点的一致间隙。范围说明 `lean/docs/003.md` 原话是 "The paper's later applications are not included" [P]。所以 §4.10.2 的最小二次非剩余上界和开平方算法只有论文里的人类可读证明，没有 Lean 证明。

4.9.3 人类专家

- Alex Kontorovich (Rutgers, 他本人发起了素数定理的 Lean 形式化项目 PrimeNumberTheoremAnd): "Quasi-RH?!?!?! Are you kidding me? If a human did this, it would be an instant Fields Medal..." [R] (X 帖子, 我们经 officechai 转引, 原帖未能抓取)
- Levent Alpöge (Anthropic): "Big, big, big, big props for quasiriemann and no Siegel zeroes." [R] (X 帖子, 经 Latent Space 转引)
- **△ 截至 2026-10-08, 没有任何人类专家公开表示读完并核对了这 199 页论文。上面两条都是表态, 不是审读意见。**

4.9.4 怎么理解"机器已证明, 但人没读懂"

如果你相信两件事: (1) Mathlib 对 ζ 的定义是对的, (2) Lean 内核没有 bug, 那么这个定理在机器意义上已经被证明了, 可信度比一篇没人审过的论文高一个量级。剩下的风险集中在构建链上: 补丁和依赖库都由 OpenAI 提供 (见 9.2)。

但数学界通常还要求**理解**: 为什么成立? 方法能不能推广? 这就是 Tao 说的 "Math 1.0 结束" 的含义: 结论可以先被机器确认, 理解可能要很久以后才跟上。

4.10 如果为真, 意味着什么 (以及不意味着什么)

4.10.1 对数学

1. **素数定理第一次有了幂次节约的误差上限**: $\pi(x) - \text{Li}(x) = O(x^{7/8} \cdot (\ln x)^2)$ 。这是 125 年来素数分布理论最大的单步推进之一。
2. **Siegel 零点被排除**: 1935 年以来挡在一大批"常数能否有效计算"问题前面的障碍解除, 一大批"存在但算不出来"的常数变成可以计算的, 例如虚二次域类数的有效下界 (§4.7.3)。
3. **从 1 推到 7/8 是质变, 但离 1/2 还很远**。黎曼猜想依然开放。

4.10.2 对计算机科学: 模 p 开平方

论文的推论之一是"最小二次非剩余"的上界。先解释这个概念。

二次剩余: 模 p 意义下"是某个数的平方"的数。以 $p = 7$ 为例:

- $1^2 = 1, 2^2 = 4, 3^2 = 9 \equiv 2, 4^2 = 16 \equiv 2, 5^2 = 25 \equiv 4, 6^2 = 36 \equiv 1 \pmod{7}$
- 所以模 7 的平方数是 $\{1, 2, 4\}$, 它们叫二次剩余; 剩下的 $\{3, 5, 6\}$ 叫**二次非剩余**。
- **最小的二次非剩余是 3。**

【检查 3】模 23 的二次剩余是哪些? 最小的二次非剩余是几? (答案见章末)

为什么重要: 在模 p 下开平方 (给定 a , 找 x 使 $x^2 \equiv a$), 有一个经典算法 (Tonelli-Shanks), 它需要先找到**任意一个**二次非剩余。随机挑一个数, 有一半概率是非剩余, 所以随机算法很

快。但**确定性**算法（不掷骰子）要保证"从 2 开始往上试，很快就能试到一个非剩余"，这就需要知道最小非剩余有多小。

论文的 Corollary 1.2 推出：最小二次非剩余 $\leq C \cdot (\ln p)^{32}$ （C 是绝对常数；论文说 32 只是一个可行的取值，没有去优化）[P]。也就是说，从 2 往上试，最多试 $(\ln p)^{32}$ 量级个数就一定能找到，于是开平方就有了**无条件的**确定性多项式时间算法。以前这个结论要假设"广义黎曼猜想"成立。

同一个固定宽度的无零区还让 **Miller 素性测试**（Miller 1976，原本也依赖广义黎曼猜想）变成无条件的确定性多项式时间算法。这一条写在同族 11/12 论文的引言里 [P]；7/8 论文的 Corollary 1.2 本身只写了非剩余上界和开平方。由于 7/8 比 11/12 强，结论同样成立。

再提醒一次（见 9.2）：这些推论都不在 Lean 形式化的范围内。

对实际密码学没有影响：

- 实践中一直用随机化算法，本来就很快。
- 素性测试的确定性多项式算法早在 2002 年就有了（AKS）。
- RSA 和椭圆曲线密码的安全性依赖"分解大数难""离散对数难"，和这个结果无关。

4.10.3 对 AI

这是"AI 在人类公认的硬核开放问题上拿到结果，并且结果有机器验证"的最强案例之一。它也带来一个新局面：**199 页论文 + 48 万行 Lean**，可信度主要压在"内核和定义是否正确"上，而不是"有没有人读懂"。人类审稿的带宽成了新瓶颈。

4.11 自测题

读完后试着回答。如果答不上来，回到对应小节再读一遍。

1. 用一句话说明：为什么零点的"实部"会影响素数计数的误差？（§4.3）
2. de la Vallée Poussin 的无零区和准黎曼猜想的无零区，形状上有什么根本区别？为什么这个区别重要？（§4.6.2–4.6.3）
3. 为什么说"零点密度估计"再好，也不能代替无零区？（§4.6.4）
4. Siegel 零点是什么？准黎曼猜想为什么能排除它？（§4.7.3）
5. Lean 陈述 `riemannZeta s ≠ 0` 前面那个假设 `hs` 说的是什么？（§4.9.1）
6. 这个结果为什么不影响 RSA 的安全性？（§4.10.2）

附：【检查】答案

- **检查 1：**每 1000 个数约 $1000/6.9 \approx 145$ 个素数。真实情况是 1000 以内有 168 个，量级吻合。

- **检查 2**: $\cos 2\theta = 2\cos^2\theta - 1$, 代入得 $3 + 4\cos \theta + 2\cos^2\theta - 1 = 2\cos^2\theta + 4\cos \theta + 2 = 2(\cos \theta + 1)^2 \geq 0$ 。
- **检查 3**: 模 23 的二次剩余是 {1, 2, 3, 4, 6, 8, 9, 12, 13, 16, 18} (11 个, 正好是 22 的一半), 最小的二次非剩余是 **5** (脚本核对)。

附：术语表

术语	一句话解释
素数定理	x 以内素数个数约为 $\text{Li}(x)$, 比值趋于 1
幂次节约	误差比 x 小一个固定的幂次, 例如 $x^{(7/8)}$
复数	平面上的点; 乘法 = 缩放 + 旋转
ζ 函数	$1/1^s + 1/2^s + \dots$, 通过欧拉乘积和素数相连
解析延拓	把只在部分区域有定义的函数, 唯一地扩展到更大的区域
零点	使函数值等于 0 的点
临界带	$0 < \text{Re } s < 1$ 的竖条, 非平凡零点都在这里
黎曼猜想	所有非平凡零点的实部都是 $1/2$
无零区	被证明没有零点的区域
准黎曼猜想	存在固定的 $\theta < 1$, $\text{Re } s > \theta$ 处没有零点
Dirichlet L 函数	ζ 的变体, 用来研究等差数列里的素数
Siegel 零点	假想中某些 L 函数的、非常靠近 1 的实零点
二次剩余	模 p 意义下是某个数的平方的数

附：想继续深入

- **3Blue1Brown**, *Visualizing the Riemann zeta function and analytic continuation* (YouTube): §4.5.3"解析延拓"的动画版, 强烈推荐。
- **3Blue1Brown**, *But what is the Fourier Transform?*: §4.3"把信号拆成波"的直觉。
- **Barry Mazur & William Stein**, *Prime Numbers and the Riemann Hypothesis* (剑桥大学出版社, 2016): 专门写给非数学专业读者的书, 前半本只需要高中数学。
- 原始论文: <https://github.com/openai/math/blob/main/preprints/The-Quasi-Riemann-Hypothesis-September-30-2026/paper.pdf>
- 同族论文: 11/12 版本 <https://github.com/openai/math/blob/main/preprints/The-Quasi-Riemann-Hypothesis-October-5-2026/paper2.pdf> ; Siegel 零点 <https://github.com/openai/math/blob/main/preprints/Uniform-exclusion-of-Landau-Siegel-zeros-October-1-2026/paper.pdf>

- Lean 范围说明: <https://github.com/openai/math/blob/main/lean/docs/003.md> ; 挑战陈述: <https://github.com/openai/math/blob/main/lean/ComparatorChallenges/QuasiRiemannHypothesis.lean>
- Dave Goldblatt 的独立复核: <https://github.com/davegoldblatt/openai-zeta-proof-check>

数论 · FAMILY 017 (+ 005)

5. π 能被分数逼近得多好: 无理性指数 $\mu(\pi) = 2$

数论 · OpenAI 编号 family 017 (§5.7.4 附带同批的 family 005: Catalan 常数)。前提只需要: 会算分数、乘方和对数, 知道无穷求和"收敛"是什么意思。凡是用到的新概念都会先讲。文中所有数字都由脚本实算 (Python + mpmath, π 取 3000 位精度) 或有出处。标记: [P] = 直接读过的一手材料 (论文、repo 文件、Lean 源码), [R] = 二手转述, $\triangle$ = 未能核实或有疑点。

【检查】是可以自己动手算的小练习, 答案在章末。预计阅读时间: 60–80 分钟。可以分三次读: §5.1–5.3 (分数逼近、连分数、Dirichlet)、§5.4–5.6 (无理性指数、 π 的历史、Flint Hills 级数)、§5.7–5.9 (OpenAI 的结果、核实和意义)。

5.0 先说结论: 这一章要讲明白的一件事

π 是无理数, 写不成分数。但可以用分数逼近它: 3、22/7、355/113.....分母越大, 逼近越准, 这很平常。真正的问题是:

跟分母的大小相比, π 能被逼近得"多好"?

这一章要讲清楚的是一条链:

任何无理数都能被逼近到"误差 $\approx 1/q^2$ " (Dirichlet, 人人都有) $\Rightarrow$ 问题变成"能不能比 $1/q^2$ 好得多, 而且好无穷多次" $\Rightarrow$ 用一个数 μ (无理性指数) 衡量这种"超常逼近"的能力 $\Rightarrow$ 几乎所有实数 $\mu = 2$, 但对具体的 π , 70 年来只能证明 $\mu \leq 7.1$ 。

OpenAI 声称证明了 $\mu(\pi) = 2$, 也就是说: π 在这件事上和"随便挑的一个实数"一样普通, 不存在无穷多个"好得离谱"的分数逼近。顺带解决了一个流行谜题: Flint Hills 级数 $\sum 1/(n^3 \sin^2 n)$ 收敛。

读完这一章, 你应该能用自己的话讲出:

- "被分数逼近得多好"怎么精确地度量, 为什么基准线是 $1/q^2$;
- 为什么"几乎所有数 $\mu = 2$ "很容易证, 而" π 的 $\mu = 2$ "极难证;
- OpenAI 的证明在用什么套路 (一句话: "一个非零整数至少是 1"), 以及它被核实到了什么程度;
- 这个结果不意味着什么 (不是超越性、不是"正规数"、不是"连分数有界")。

5.1 用分数逼近 π：从 3 到 355/113

5.1.1 一张表

π = 3.14159265358979...。历史上著名的几个分数：

分数	来历	误差 π - p/q	1/q²	q² × 误差
3/1	古代	1.42×10 ⁻¹	1	0.142
314/100	小数截断	1.59×10 ⁻³	1×10 ⁻⁴	15.9
22/7	阿基米德"约率"	1.26×10 ⁻³	2.04×10 ⁻²	0.062
333/106		8.32×10 ⁻⁵	8.90×10 ⁻⁵	0.935
355/113	祖冲之"密率" (5 世纪)	2.67×10 ⁻⁷	7.83×10 ⁻⁵	0.0034
103993/33102		5.78×10 ⁻¹⁰	9.13×10 ⁻¹⁰	0.633

(脚本实算。)

5.1.2 为什么要除以"分母成本"

误差变小本身不稀奇：分母允许到 10⁶，你随便取 3141593/1000000 也能把误差压到 10⁻⁷ 左右。所以只看误差是不公平的，要看**相对于分母大小**的误差。

看 314/100 和 22/7：两者误差差不多（都约 10⁻³），但 22/7 只用了分母 7，而 314/100 用了分母 100。22/7 "性价比"高得多。

一个自然的度量是：**误差相当于分母的几次方的倒数**？如果 |π - p/q| ≈ q^(-ν)，我们就说这个逼近的"有效指数"是 ν。ν 越大，逼近越"超常"。

- 314/100：误差 ≈ 100^(-1.4)，ν ≈ 1.4。小数截断大约只有 ν ≈ 1 的水平（误差 ~ 1/q）。
- 22/7：ν ≈ 3.43（脚本实算）。
- 355/113：ν ≈ 3.20（脚本实算）。这就是"密率"神奇的地方：用三位数的分母，得到了约 10⁻⁷ 的精度（小数点后 6 位全对）。

表的最后一列 q² × 误差 是另一个角度：如果它 < 1，说明误差比 1/q² 还小。355/113 的这一列是 0.0034，也就是比 1/q² 好了约 **290 倍**。

【检查 1】用计算器验证：355/113 = 3.14159292...，和 π 差多少？113² 是多少？误差乘以 113² 大约是多少？

5.2 连分数：寻找"最佳逼近"的机器

上表里的 3、22/7、333/106、355/113 不是凑出来的，它们是一台机器的输出。这台机器叫**连分数** (continued fraction)。

5.2.1 算法：取整、取倒数、重复

对一个数 x ：

1. 写下整数部分 a_0 ，剩下小数部分 r 。
2. 把 r 取倒数 $1/r$ ，再写下它的整数部分 a_1 ，剩下新的小数部分。
3. 重复。

拿 π 手算前两步：

- $\pi = 3 + 0.14159\dots$ ，所以 $a_0 = 3$ 。
- $1/0.14159\dots = 7.0625\dots$ ，所以 $a_1 = 7$ 。
- $1/0.0625\dots = 15.996\dots$ ，所以 $a_2 = 15$ 。

继续下去（脚本实算）：

```
 $\pi = [3; 7, 15, 1, 292, 1, 1, 1, 2, 1, 3, 1, 14, 2, 1, 1, 2, 2, 2, 2, \dots]$ 
```

意思是 $\pi = 3 + 1/(7 + 1/(15 + 1/(1 + 1/(292 + \dots))))$ 。

5.2.2 截断 = 好分数

在某一位截断，就得到一个分数，叫**渐近分数**（convergent）：

- 截在 $[3] \rightarrow 3$
- 截在 $[3; 7] \rightarrow 3 + 1/7 = 22/7$
- 截在 $[3; 7, 15] \rightarrow 333/106$
- 截在 $[3; 7, 15, 1] \rightarrow 355/113$
- 截在 $[3; 7, 15, 1, 292] \rightarrow 103993/33102$

经典定理（Lagrange 等，18 世纪）：渐近分数是"最佳逼近"，分母不超过 q 的所有分数里，没有谁比它更接近 x 。

5.2.3 下一个数字越大，当前这个分数越准

这是本章最有用的一条经验规律：

渐近分数 p/q 的误差约等于 $1 / (a_{\text{next}} \times q^2)$ ，其中 a_{next} 是连分数里**紧跟在截断处后面**的那个数（叫"部分商"）。

- $22/7$ 后面紧跟 15：误差 $\approx 1/(15 \times 49) \approx 1.4 \times 10^{-3}$ ，实际 1.26×10^{-3} 。
- $355/113$ 后面紧跟 **292**：误差 $\approx 1/(292 \times 12769) \approx 2.7 \times 10^{-7}$ ，实际 2.67×10^{-7} 。

- 333/106 后面紧跟 1：误差 $\approx 1/(1 \times 106^2)$ ，和 $1/q^2$ 同一量级，一点也不"超常" ($q^2 \times \text{误差} = 0.935$)。

所以，问"π 能否被超常地逼近"，等价于问"π 的连分数里会不会出现特别巨大的部分商"。292 是一次，以后还会不会有更离谱的？

5.2.4 对照组：几个"长相规整"的数

数	连分数（脚本实算）	规律
黄金比 $\phi = (1+\sqrt{5})/2$	[1; 1, 1, 1, 1, ...]	全是 1，最难逼近的数
$\sqrt{2}$	[1; 2, 2, 2, 2, ...]	永远是 2
e	[2; 1, 2, 1, 1, 4, 1, 1, 6, 1, 1, 8, ...]	1, 1, 2k 的模式，缓慢增长
π	[3; 7, 15, 1, 292, 1, 1, 1, 2, ...]	没有已知规律

对 $\sqrt{2}$ 、e 这样有规律的数，部分商的大小一眼可见，所以"能被逼近得多好"可以直接算出来。π 的连分数**没有任何已知规律**，这正是难点的根源：你没法盯着它的连分数去证明"以后永远不会出现一个超级大的数"。

【检查 2】手算 355/113 的连分数。（提示：355 = 3 × 113 + 16，然后对 113/16 继续。）

5.3 Dirichlet 定理：指数 2 是人人都有

5.3.1 结论

Dirichlet 逼近定理 (1842)：对任何无理数 x，有无穷多个分数 p/q 满足 $|x - p/q| < 1/q^2$ 。

也就是说，有效指数 2 是"免费的"，任何无理数都能做到。这就是为什么基准线是 $1/q^2$ 而不是别的。

5.3.2 证明：抽屉原理，可以手算

取一个整数 Q，比如 Q = 10。看 $0 \cdot \pi, 1 \cdot \pi, 2 \cdot \pi, \dots, 10 \cdot \pi$ 这 11 个数的小数部分（脚本实算）：

q	$q\pi$ 的小数部分
0	0.000
1	0.142
2	0.283
3	0.425
4	0.566
5	0.708

q	$q\pi$ 的小数部分
6	0.850
7	0.991
8	0.133
9	0.274
10	0.416

把 $[0, 1)$ 切成 10 个长度 0.1 的抽屉。11 个数放进 10 个抽屉，**至少有两个在同一个抽屉里**。看表： $q = 1$ (0.142) 和 $q = 8$ (0.133) 都在 $[0.1, 0.2)$ 里。

两者相减： $8\pi - 1\pi = 7\pi$ ，小数部分只差 0.009。这说明 7π 离某个整数很近： $7\pi \approx 21.991$ ，离 22 只差 0.0089。于是

$$|7\pi - 22| < 1/10 \quad \Rightarrow \quad |\pi - 22/7| < 1/(7 \times 10) \leq 1/7^2$$

一般地， Q 个抽屉、 $Q+1$ 个数，总能找到 $q \leq Q$ 使 $|qx - p| < 1/Q$ ，于是 $|x - p/q| < 1/(qQ) \leq 1/q^2$ 。让 Q 越来越大，就能得到无穷多个这样的分数。证毕。

【检查 3】在上表里再找一对落在同一个抽屉的 q 。它们的差是多少？给出的是哪个分数？

5.3.3 能不能比 $1/q^2$ 更好？

脚本实算：在分母 $2 \leq q \leq 100,000$ 的所有既约分数里，数一数满足 $|\pi - p/q| < q^{-(\nu)}$ 的有几个：

ν	满足的分数个数	它们的分母
2	8	6, 7, 106, 113, 33102, 33215, 66317, 99532
2.2	2	7, 113
2.5	2	7, 113
3	2	7, 113

$\nu = 2$ 时个数一直在增加（Dirichlet 保证它无穷多）。 ν 只比 2 大一点时还剩几个（脚本实算：分母 6、106、33102、33215、66317、99532 的有效指数在 2.01–2.11 之间）； $\nu \geq 2.2$ 时，10 万以内只剩 $22/7$ 和 $355/113$ 两个“早期奇迹”。

$\mu(\pi) = 2$ 说的就是：对任何 $\nu > 2$ （哪怕 2.0001），这样的分数只有**有限多个**。早期可以有几个奇迹，但奇迹不能无穷无尽地出现。

5.4 无理数指数 μ ：定义和一个"动物园"

5.4.1 定义

无理数指数 (irrationality exponent, 也叫 irrationality measure) $\mu(x)$ = 所有满足 " $|x - p/q| < q^{-(\mu+1)}$ 有无穷多个解"的 μ 的上确界。

白话： $\mu(x)$ 是 x 能被"无穷多次超常逼近"的最高指数。 μ 越大， x 越容易被分数逼近得很好，在这个意义上越"接近有理数"。

连分数版本 (标准结论)： $\mu(x) = 2 + \limsup (\ln a_{n+1} / \ln q_n)$ 。也就是说， **$\mu = 2$ 当且仅当部分商 a_{n+1} 的增长比 q_n 的任何正次方都慢。**

脚本实算一个例子： π 连分数前 1000 项里最大的部分商是 20776 (第 431 项)，它前面那个渐近分数的分母有 216 位。这次逼近的有效指数只有 **2.020**。分母这么大，即使出现了一个两万多的一部分商，对指数的贡献也微不足道。相比之下，355/113 的有效指数是 3.20，那是"分母很小时运气好"。

5.4.2 动物园

数	μ	谁证明的
有理数	1	平凡
任何无理数	≥ 2	Dirichlet 1842 (§5.3)
$\sqrt{2}$ 等二次无理数	2	Liouville 型论证，见 4.3
任何代数无理数 (如 $\sqrt[3]{2}$)	2	Roth 1955 ，获 1958 年 Fields 奖
e	2	由它规律的连分数直接算出
几乎所有实数 (勒贝格测度意义)	2	Khinchin (1920 年代)，见 4.5
Liouville 数 $\sum 10^{-k!}$	∞	Liouville 19 世纪中叶
π	已知 ≤ 7.10 ； OpenAI 声称 = 2	见 §5.5、§5.7

5.4.3 一个可以手算的证明：为什么 $\sqrt{2}$ 不能被超常逼近

这个小证明里藏着整章 (包括 OpenAI 证明) 的核心套路，值得慢慢看。

对任何分数 p/q ，看整数 $p^2 - 2q^2$ ：

- 它**不是 0** (因为 $\sqrt{2}$ 是无理数)。
- 它是**整数**。
- 所以 $|p^2 - 2q^2| \geq 1$ 。

另一方面， $p^2 - 2q^2 = q^2 (p/q - \sqrt{2})(p/q + \sqrt{2})$ 。所以

$$|\sqrt{2} - p/q| = |p^2 - 2q^2| / (q^2 \cdot (p/q + \sqrt{2})) \geq 1 / (q^2 \cdot (p/q + \sqrt{2})) \approx 1/(2.83 q^2)$$

误差永远不会小于大约 $0.35/q^2$ ，所以有效指数不超过 2， $\mu(\sqrt{2}) = 2$ 。

手算 $p/q = 7/5$ ： $p^2 - 2q^2 = 49 - 50 = -1$ ，绝对值恰好是 1。预测误差 $= 1/(25 \times (1.4 + 1.41421)) = 0.01421$ ，实际 $|1.41421 - 1.4| = 0.01421$ 。（脚本还验证了： $\sqrt{2}$ 的渐近分数的 $q^2 \times$ 误差一直稳定在 0.35 左右。）

核心套路：

构造一个和逼近有关的量。**算术上**：它是非零整数，所以 ≥ 1 。**分析上**：如果逼近太好，它会 < 1 。两者矛盾。

记住这句话，§5.7 会再遇到它。

5.4.4 Liouville 数： $\mu = \infty$ 的怪物

$L = \sum 10^{(-k!)} = 0.110001000000000000000001000...$ （1 出现在小数点后第 1, 2, 6, 24, 120, ... 位）。

把它在某个 1 之后截断，得到的分数误差极小（脚本实算）：

- 截到第 2 位： $q = 10^2$ ，误差 $\approx 10^{-6} = q^{-3}$
- 截到第 6 位： $q = 10^6$ ，误差 $\approx 10^{-24} = q^{-4}$
- 截到第 24 位： $q = 10^{24}$ ，误差 $\approx 10^{-120} = q^{-5}$

有效指数 3, 4, 5, ... 无限增长，所以 $\mu(L) = \infty$ 。Liouville 用这类数构造出了历史上第一批**被证明是超越数**的数（因为代数数的 μ 是有限的， $\mu = \infty$ 的数就一定不是代数数）。

这一点理解难度至关重要：Liouville 数是超越数， $\mu = \infty$ 。 π 也是超越数（Lindemann 1882）。所以**" π 是超越数"这个事实本身对 $\mu(\pi)$ 毫无帮助**，任何只用到" π 是超越数"的论证都会被 Liouville 数推翻。要证 $\mu(\pi) = 2$ ，必须用到 π 独有的结构。

5.4.5 为什么"几乎所有数 $\mu = 2$ "很容易证

在 $[0, 1]$ 里随机扔一个点 x 。对固定的 q ，" x 离某个 p/q 小于 $q^{-(v)}$ "的区域，总长度大约是 q 个小区间 $\times$ 每个长 $2q^{-(v)} = 2q^{(1-v)}$ 。

把所有 q 加起来： $\sum 2q^{(1-v)}$ 。当 $v > 2$ 时，指数 $1 - v < -1$ ，这个和**收敛**（就是 §4 讲过的 $\zeta(v-1)$ 乘以 2， $s > 1$ 时 $\zeta(s)$ 有限）。概率论里有个 Borel–Cantelli 引理：如果一串事件的概率之和有限，那么几乎必然只有有限多个事件发生。所以几乎每个 x 都只有有限多个指数 v 的超常逼近， $\mu(x) \leq v$ 。 v 可以任意接近 2，于是几乎所有 x 都有 $\mu = 2$ 。

这个论证完全没法用在 π 上：它说的是"一个随机的数"，而 π 是一个特定的数。就像"几乎所有人都不是左撇子"不能告诉你某个具体的人是不是左撇子。这就是这类问题的典型形状：**典型行为一眼可知，具体实例极难证明**（" π 是正规数"也是这种形状，至今未解）。

5.5 π 的上界史：70 年从 42 到 7.1

5.5.1 时间线

年份	作者	证明的 $\mu(\pi)$ 上界	出处
1953	Mahler	42（并称最终可做到 30）	<i>On the approximation of π</i> , Indag. Math. 15
1974	Mignotte	21（所有分母）/ 20（最终）	Bull. SMF Mém. 37
1993	Hata	8.01604539...	Acta Arith. 63
2008	Salikhov	7.606308...	Russ. Math. Surveys 63(3)
2020	Zeilberger–Zudilin	7.103205334137...	Moscow J. Comb. Number Theory 9(4); arXiv:1912.06345
2026-09	Bai（预印本）	7.101862832357	arXiv:2609.11276 $\triangle$ 未经同行评审
2026-09-24	OpenAI（声称）	= 2	本章§5.7

（上表数值以 OpenAI 论文 §1.1 的综述为准，并与本 deck 作者的研究笔记交叉核对。）

注意最后两步之间的跨度：前 70 年是 $42 \rightarrow 7.10$ ，每一步都是大量精细工作；然后一步跳到 2，而且是**精确值**，不是又一个上界。

5.5.2 旧方法的天花板

此前所有上界都来自同一个框架（Zudilin 的综述 arXiv:math/0404523 讲得很清楚）：

- 构造一系列整数系数的"线性形式" $a_n\pi - b_n$ ，要求它**很小但不是 0**。通常用精心设计的积分来构造。
- 两个量互相拉扯：
 - 线性形式衰减得多快（越快越好）；
 - 系数 a_n 增长得多快（越慢越好）。为了让系数是整数，往往要乘上 $\text{lcm}(1, 2, \dots, n)$ 这样的大数来"清分母"，这个代价很大。
- 标准引理：如果衰减率是 $e^{(-\beta n)}$ 、系数增长是 $e^{(\alpha n)}$ ，就得到 $\mu \leq 1 + \alpha/\beta$ 。

要得到 $\mu = 2$ ，需要 α 和 β 几乎相等，也就是"清分母的代价"几乎为零。对 π 已知的所有积分构造，这个比值都离 1 很远。Zeilberger–Zudilin 那一代工作是在这个框架里拧螺丝（优化积分的参数），每次只能挪一点点。

5.5.3 为什么 Roth 的方法不能直接用

Roth 定理对所有代数数给出 $\mu = 2$ ，方法是**多变量**的：同时取好几个分母相差极大的逼近 $p_1/q_1, p_2/q_2, \dots$ ，构造一个多变量多项式，用§5.4.3 那种"非零整数 ≥ 1 "的套路导出矛盾。

但 Roth 的证明本质上用到 x 满足一个整系数多项式方程 (x 是代数数)。 π 不是代数数，所以没有那个方程可用。而§5.4.4 说过，你也不能只用" π 是超越数"。OpenAI 的推理摘要里恰好记录了模型撞上这堵墙的一刻 (原文逐字)：

"Wait this would work for any transcend, contradiction with Liouville. Examine."

意思是：它发现自己的某个论证如果成立，会对**所有超越数**成立，但 Liouville 数是反例，所以论证一定有漏洞。

5.6 一个具体后果：Flint Hills 级数

5.6.1 级数是什么

$$\sum 1/(n^3 \sin^2 n) = 1/(1^3 \sin^2 1) + 1/(2^3 \sin^2 2) + 1/(3^3 \sin^2 3) + \dots \quad (n \text{ 是弧度})$$

问题：它收敛吗？这个问题由 Pickover 推广普及，流行了二十多年；Alekseyev 2011 (arXiv:1104.5100) 做了系统讨论，一直没解决。


5.6.2 为什么它和 π 的逼近有关

分母里有 $\sin n$ 。当整数 n 非常接近 π 的某个整数倍 $k\pi$ 时， $\sin n$ 非常小，这一项就会爆大。而" $n \approx k\pi$ "就是" $n/k \approx \pi$ "，也就是 **n/k 是 π 的一个好的分数逼近**。

脚本实算部分和：

n	这一项	部分和
1	1.412	1.412
3	1.860	3.423
21	0.00015	3.555
22 (22/7)	1.199	4.754
354	3.2×10^{-8}	4.807
355 (355/113)	24.60	29.406
1,000	1.5×10^{-9}	30.175
103,993 (103993/33102)	2.4×10^{-6}	30.3145
1,000,000	8.2×10^{-18}	30.3145

把 $n \leq 400$ 的部分和画出来：



每一次跳跃都发生在 n 是 π 某个"超好"分数逼近的分子时 ($\sin n$ 很小)。级数收不收敛取决于这种跳跃有多频繁、多大——也就是取决于 π 的无理指数。数值由本 deck 的 build 脚本直接计算。

整条曲线是阶梯形：平时几乎不动，每当 n 撞上 π 的一个超好逼近的分子，就跳一下。 $n = 355$ 那一项单独贡献了 24.6，是前 100 万项总和的 81%。

【检查 4】解释 $n = 355$ 那一项为什么约等于 24.6。(提示： $\sin(355) = \sin(355 - 113\pi)$ ，而 $355 - 113\pi \approx 3.01 \times 10^{-5}$ ； $\sin$ 很小的角 $\approx$ 角本身。)

5.6.3 收敛与否完全由 $\mu(\pi)$ 决定

- 如果 π 有无穷多个"太好"的逼近，就会有无穷多次足够大的跳跃，级数发散。
- 如果超常逼近足够稀少，跳跃加起来有限，级数收敛。

两个已发表的判据把它精确地连到 $\mu(\pi)$ ：

- Alekseyev 2011：如果级数收敛，那么 $\mu(\pi) \leq 5/2$ 。
- Meiburg 2022 (arXiv:2208.13356)：如果 $\mu(\pi) < 5/2$ ，那么级数收敛。

所以只要证明 $\mu(\pi) < 2.5$ ，问题就解决了。但已知最好的是 7.10，差得远。OpenAI 的推理摘要显示，模型一开始的目标正是 $\mu < 5/2$ ，后来才发现可以一路推到 2 (见 §5.7.3)。

OpenAI 论文的 Flint Hills 推论 (Corollary 1.2) 走的就是这条路：主定理给出 $\mu(\pi) = 2 < 5/2$ ，再套用 Meiburg 已发表的人类结果，得到收敛 [P]。论文 §5 还自己给了一个短证明 (把整数 n 按最近的 $q\pi$ 分组，用 $|\sin n| \geq (2/\pi) \cdot |n - q\pi|$ 控制每组)，并推出更一般的结论： $\sum 1/(n^a |\sin n|)$ 收敛，当且仅当 $a > \max\{1, b\}$ 。

5.7 OpenAI 声称了什么

5.7.1 主结果

论文 *The irrationality exponent of π is 2* (OpenAI, 2026-09-24, 23 页) 的摘要 [P]:

"We prove the conjecture that the irrationality exponent of π is 2. As a consequence, the classical Flint–Hills series $\sum_{n \geq 1} 1/(n^3 \sin^2 n)$ converges, with angles in radians."

主定理 (Theorem 1.1) 的精确说法:

对每个实数 $\nu > 2$, 存在整数 $Q(\nu)$, 使得对一切整数 p 和一切 $q \geq Q(\nu)$, 都有 $|\pi - p/q| \geq q^{-(\nu)}$ 。

论文自己特别交代了三点 (都很重要):

1. 不要求 p/q 是既约分数。
2. **$Q(\nu)$ 不可有效计算**: "the argument does not give it effectively"。也就是说, 它证明了"从某个分母开始, 再也没有指数 ν 的超常逼近", 但不告诉你从哪里开始。
3. **$\mu = 2$ 不等于"部分商有界"**: "an exponent of 2 is different from a uniform positive lower bound of the form c/q^2 , or equivalently from bounded continued-fraction partial quotients"。后者 (π 的连分数部分商是否有界) 仍未解决。

论文还记录了同领域的其他声明: Mantzakouras 与 López Zapata 的 Flint Hills 收敛声明已于 2026-09 撤回; Carella 声称 $\mu(\pi) = 2$ 以及更强的"部分商有界", OpenAI 论文在脚注里指出其更强结论的证明有一处符号错误 (这是 OpenAI 一方的说法 $\triangle$, 没有第三方确认)。

论文说 Waldschmidt 在 *Open Diophantine problems* (Moscow Math. J. 4(1), 2004, p. 265) 里把这个结论记录为猜想。

5.7.2 方法的直觉 (只读了论文引言和论文 §5, 以下是简化版)

回忆 §5.4.3 的套路: "非零整数 ≥ 1 , 但逼近太好会让它 < 1 "。OpenAI 的证明是这个套路的一个非常重型的版本。

1. **反证**。固定一个 $\nu > 2$, 假设 π 有无穷多个指数 ν 的超常逼近。
2. **挑几个, 分母拉得很开**。从这无穷多个里挑出 m 个, 分母一个比一个大得多: $q_1 \ll q_2 \ll \dots \ll q_m$ 。这一步和 Roth 一样 (多变量、分母分离)。
3. **用上 π 独有的结构: 它是指数函数的周期**。 $e^{(2\pi i)} = 1$, 所以 $2\pi i \cdot j$ 是指数函数的"周期", 也是对数函数多值性的来源。作者把超常逼近 p_i/q_i 变成 $2i \cdot j \cdot p_i/q_i$, 这些数逼近真正的周期 $2\pi i \cdot j$ 。这一步回答了 §5.4.4 的问题: 证明用的不是" π 是超越数", 而是" π 和 $\exp/\log$ 的这一具体关系", Liouville 数没有这种结构。
4. **构造一个大行列式**。考虑多变量多项式 $P(Y, X_1, \dots, X_m)$, 沿着"对数曲线" $Y = 1 + t, X_i = c_i + \log(1 + t)$ 展开, 取泰勒系数, 排成一个大矩阵。论文第 2 节的新定理 ("分离权重插值", 用到

代数几何里的 blowup、ampleness 等工具) 保证这个矩阵满秩, 于是能挑出一个**非零**行列式。

5. **算术下界**。矩阵元素都在 $\mathbb{Q}(i)$ 里 (形如 $a + bi$, a, b 是分数)。乘掉分母后, 行列式是一个非零的"高斯整数", 绝对值 ≥ 1 。
6. **分析上界**。把近似值 $2i \cdot j \cdot p_i/q_i$ 换回真正的周期 $2\pi i \cdot j$, 很多行会变成同一些函数的泰勒系数, 彼此几乎相关, 行列式会因此大幅抵消 (论文称为"quadratic saving"); 剩下的项则带有极小的逼近误差 $|\pi - p_i/q_i|$ 作为因子。结果: 行列式的绝对值 < 1 。
7. **矛盾**。 ≥ 1 且 < 1 不可能, 所以假设错误, 指数 v 的超常逼近只有有限多个。

为什么能推到任意 $v > 2$: 维数 m (挑几个逼近) 可以随 v 增大。维数越高, "抵消节约"增长得越快, 最终压过任何 $v > 2$ 带来的代价。为什么 $Q(v)$ 算不出来: 论证从"假设有无穷多个"出发, 挑出的逼近没有具体位置, 这和 Roth 定理的"不可有效性"是同一个来源。

5.7.3 推理摘要: AI 是怎么走到这一步的

OpenAI 公开了一份 42 页的"删节版思维链摘要" (0) [P]。脚本读过全文目录, 结构如下:

- **摘要的第一部分 (第 1–44 节)**: 目标只是 Flint Hills 需要的 $\mu < 5/2$ 。模型试过 BBP 公式、模形式、Padé 逼近、Chudnovsky 级数、p-adic 对数、椭圆函数等几十条路线, 反复撞上它自己反复称为"高度 vs 分母代价" (height barrier) 的那堵墙, 也就是§5.5.2 说的"清分母的代价"。中途多次参考 OpenAI 自己的 Catalan 常数手稿里的行列式思路 (摘要原文反复出现 "OpenAI's Catalan determinants", 这篇手稿见§5.7.4)。最后用加权插值行列式拿到 $\mu \leq 62/25 = 2.48$, 从而 Flint Hills 收敛。§5.32–5.44 的标题几乎都是 "audit"、"stress-testing", 即反复自查这一步。
- **摘要的第二部分 (§5.45)**: "takes the earlier report's interpolation-and-determinant technique as a starting point and claims exponent two, explicitly without assuming the earlier approximation bound"。在同一技术上调参数、升维数, 推到 $\mu = 2$ 。

这份文件本身就是一个很好的研究过程案例: 目标设定得很保守 (2.5), 结果在审计中发现技术本身的上限是 2。

5.7.4 同批的另一个结果: Catalan 常数是无理数 (family 005)

推理摘要里反复借用的"Catalan 手稿", 是同一批发布里的另一篇: *Catalan's constant is irrational* (2026-09-24, 44 页) [P]。它和 π 的结果是一对: 方法上 π 借了它的行列式, 问题上它卡在§5.5.2 同一堵墙上。

是什么。Catalan 常数 $G = 1 - 1/3^2 + 1/5^2 - 1/7^2 + \dots \approx 0.91597$ 。它是 Dirichlet β 函数 $\beta(s) = 1 - 1/3^s + 1/5^s - \dots$ 在 $s = 2$ 的值 (这里的 β 是函数名, 和§5.5.2 的衰减率 β 无关)。换个说法, 它就是 §4 §5.7.2 那个模 4 特征的 Dirichlet L 函数在 $s = 2$ 的值。

为什么难。用§5.5.2 的语言：要证明一个常数是无理数，需要一系列整系数线性形式 $a_n G - b_n$ ，它不为 0 但趋于 0。1978 年 Apéry 用这种办法证明了 $\zeta(3)$ 是无理数（van der Poorten 讲述这段故事的文章题为 *A proof that Euler missed*）。同样的思路对 G 失效：Zudilin 构造过 Apéry 式的递推，分数 b_n/a_n 收敛到 G 很快，但清分母之后线性形式**不趋于 0**，"清分母的代价"赢了 [P, 论文 §1.1 转述]。此前最好的只是家族型结果： $\beta(2), \beta(4), \dots, \beta(10)$ 这五个数里至少有一个是无理数（Rivoal–Zudilin 2003 先证明了到 $\beta(14)$ ，Zudilin 2019 缩到 $\beta(12)$ ，Lai–Zhou 2022 缩到 $\beta(10)$ ），但说不出是哪一个。

OpenAI 声称： G 是无理数。Lean 方面，`lean/docs/005.md` 写明主张已形式化，挑战陈述是 `Irrational ( $\sum' j : \mathbb{N}, (-1 : \mathbb{R})^j / ((2 * j + 1 : \mathbb{N}) : \mathbb{R})^2$ )`，同样只用 Mathlib 的标准概念 [P]。解答约 981 个文件、57.4 万行，grep 无 `sorry` [P]。△ 它同样**没有**登记在 `formalization.yaml` 里；而且和 π 不同，它依赖 OpenAI 用补丁加进 PrimeNumberTheoremAnd 库的 Catalan 模块（就是 §4 §5.9.2 那个约 4 万行的补丁；这部分我们没有 grep，也没有运行 comparator）。

如果成立：这是 Apéry 之后近半个世纪里，"单个经典常数是无理数"这类结果中最重要的之一。

5.8 它被核实到什么程度

5.8.1 Lean 陈述：你可以自己读懂

repo 里的"挑战陈述"文件 `lean/ComparatorChallenges/PiExponent.lean`（只 import Mathlib；范围说明见 `lean/docs/017.md`）[P]：

```
theorem main :
  (∀ v : ℝ, 2 < v → ∃ Q : ℤ, 2 ≤ Q ∧
    ∀ p q : ℤ, Q ≤ q →
      (q : ℝ) ^ (-v) ≤ |Real.pi - (p : ℝ) / (q : ℝ)|) ∧
  sSup {v : ℝ | 0 < v ∧
    Set.Infinite {r : ℚ | 2 ≤ r.den ∧
      0 < |Real.pi - (r : ℝ)| ∧
      |Real.pi - (r : ℝ)| < (r.den : ℝ) ^ (-v)}} = 2
```

逐段翻译：

- **第一部分** (`∧` 之前)：
 - `∀ v : ℝ, 2 < v →`：对任何大于 2 的实数 v ,
 - `∃ Q : ℤ, 2 ≤ Q ∧`：存在一个整数门槛 $Q \geq 2$,
 - `∀ p q : ℤ, Q ≤ q →`：对所有整数 p 和所有 $\geq Q$ 的整数 q ,
 - `(q : ℝ) ^ (-v) ≤ |Real.pi - p/q|`： π 和 p/q 的距离至少是 q^{-v} 。
 - 这正是 Theorem 1.1。注意它只说"存在 Q "，不给出 Q ，和论文的"不可有效"一致。

- **第二部分 ($\wedge$ 之后):**

- $\{r : \mathbb{Q} \mid 2 \leq r.\text{den} \wedge 0 < |\pi - r| \wedge |\pi - r| < r.\text{den}^{(-v)}\}$: 所有分母 ≥ 2 、满足指数 v 超常逼近的有理数的集合 (Lean 的 $\mathbb{Q}$ 自动是既约分数, `r.den` 是分母)。
- `Set.Infinite ...`: 这个集合是无穷集。
- `sSup {v | 0 < v  $\wedge$  ...} = 2`: 所有"有无穷多解"的 v 的上确界等于 2。这就是 §5.4.1 μ 的定义, 逐字对应。

两个值得注意的细节:

- 陈述里只用了 **Mathlib 的标准定义** (`Real.pi`、`sSup`、`Set.Infinite`、 $\mathbb{Q}$)，没有 OpenAI 自己定义的概念。这比"用自定义定义写陈述"可信得多。
- Lean 里 `sSup` 有一个"垃圾值"约定: 对空集或无上界的集合, 它返回 0。这里结论是 $= 2$ 而不是 $= 0$, 所以不会落进这个陷阱。

5.8.2 证明本身 (脚本在本地 `sparse clone` 上统计, `snapshot fd4aeeb`) [P]

- 解答目录 `lean/OAI/NumberTheory/PiExponent/`: 869 个 .lean 文件, 94,948 行 (约 9.5 万行)。
- `grep`: `sorry` 0 处, `native_decide` 0 处, 自定义 `axiom` 0 处。
- `comparator` 配置 `PiExponent.json` 只允许三个标准公理 (`propext`、`Quot.sound`、`Classical.choice`)。
- 解答只 import Mathlib 和它自己目录下的文件, 不依赖 `lean/patches/` 里任何打过补丁的外部库 (脚本检查了全部 import)。对比 §4: 准黎曼猜想的证明依赖一个约 4 万行的补丁库, 这是它的主要剩余风险之一; π 这一份没有这个问题。
- 入口文件 `Main.lean` 里还有一条 `flint_hills_summable`: 用 Mathlib 的 `Summable` 写出 $\sum 1/(n^3 \sin^2 n)$ 收敛, 并给出了证明。但官方范围说明 `lean/docs/017.md` 写的是 Flint Hills "outside this selected statement", 也就是它不在 **comparator 检查的陈述里**。准确的说法是: Flint Hills 的 Lean 证明在 repo 里存在, 但没有经过和主定理同等的"陈述—证明"比对流程。

5.8.3 没有做到的事 ($\triangle$)

- $\triangle$ 这份形式化没有登记在 `lean/formalization.yaml` 里 (我们 `grep` 了 `PiExponent` 和 `017`, 都没有), 可能是 10-07 更新时漏登记。
- $\triangle$ 我们没有自己编译运行 `comparator`; 也没有找到第三方复核 (§4 里 Dave Goldblatt 的独立检查只针对 ζ 那份)。
- 2026-10-07, Google DeepMind 的 `formal-conjectures` 仓库出现一个 issue (#6909, 作者 mo271), 建议把其中的 `flint_hills_series_converges` 标为已解决, 但 issue 自己注明 "prepared with AI assistance and may contain mistakes", 请人先核对。截至我们查看时没有评论。

- **△ 截至 2026-10-08，没有找到任何具名的丢番图逼近 / 超越数论专家公开评论这篇论文的正确性。** John D. Cook 2026-10-07 的博客只做了科普，没有评价证明 [R]。

5.8.4 怎么理解

和准黎曼猜想相比，这一份在"机器验证"维度上更干净：陈述只用 Mathlib 标准概念、读起来就是教科书定义；证明不依赖补丁库；规模（约 9.5 万行）也小得多。如果你相信 Mathlib 对 π 、实数幂、上确界的定义没问题，以及 Lean 内核没有 bug，那么 " $\mu(\pi) = 2$ " 在机器意义上的可信度非常高。剩下的缺口是流程上的（没人跑过第三方 comparator）和理解上的（没有人类专家公开说读懂了证明）。

5.9 如果为真，意味着什么（以及不意味着什么）

5.9.1 对数学：意味着什么

1. **一个被正式记录的猜想被解决：** π 在逼近性质上是"典型的"，和几乎所有实数一样。70 年的上界竞赛 ($42 \rightarrow 7.10$) 以"精确值"的方式结束。
2. **Flint Hills 级数收敛：**一个流行了二十多年的谜题得解，还附带更一般的 $\sum 1/(n^a |\sin n|^b)$ 的完整收敛判据。
3. **方法可能比结论更重要。**"沿对数曲线的分离权重插值 + 行列式"如果能推广，下一批目标会是 $\log 2$ 、 $\zeta(3)$ 、其他对数值的无理数指数（推理摘要第 43 节提到模型"considered an extension to algebraic logarithms"，但这是推测性方向，没有结论 △）。同一类行列式技术在同批的 Catalan 常数手稿里也用上了 (§5.7.4)。

5.9.2 对数学：不意味着什么

常被混淆的说法	和 $\mu(\pi) = 2$ 的关系
π 是无理数	早已知道 (Lambert 1761)。 $\mu = 2$ 远强于"无理"
π 是超越数	早已知道 (Lindemann 1882)。而且超越数可以有 $\mu = \infty$ (Liouville 数)，两者互不推出
π 的连分数部分商有界	仍未解决。 论文明确说 $\mu = 2$ 不等于这一点
π 是正规数（每种数字串出现频率相同）	仍未解决 ，是完全不同的问题
能算出"从哪个分母开始不再有超常逼近"	不能 ， $Q(v)$ 不可有效计算
$22/7$ 、 $355/113$ 这样的好逼近不存在	当然存在。 $\mu = 2$ 只说"指数 > 2 的奇迹"只有有限多个

5.9.3 对计算机科学

几乎没有直接影响。

- 浮点数的三角函数要做"参数约减" (把大数 x 减到 $[-\pi/4, \pi/4]$ 区间), 最坏情况取决于某个浮点数离 $\pi/2$ 的倍数有多近。但这是**有限范围**的问题 (double 的范围是有限的), 工程上早已用连分数把最坏情况直接算出来 (见 J.-M. Muller, *Elementary Functions*, 参数约减一章 $\triangle$ 具体章节以原书为准)。一个"渐近的、不给门槛的"定理不会改变这些具体数字。
- 和密码学、复杂度理论没有关系。

5.9.4 对 AI

1. 这是 "AI 解决一个被文献正式记录的经典猜想" 的一个相对**容易检验**的案例: 陈述短、只用标准定义、Lean 证明不依赖补丁库。如果你想向别人说明"这批结果里哪些最可信", 它比准黎曼猜想 (§4) 更好举例。
2. 推理摘要展示了一个值得研究的过程特征: 保守目标 (2.5) + 长时间失败探索 (40 多节) + 大量自我审计, 最后发现技术的真正上限。对研究 AI 的研究过程本身 (以及 eval 设计) 有参考价值。
3. 生态层面: 同月有 Bai 的 7.1018 预印本 (本 deck 作者的研究笔记记录: Bai 在致谢中提到 OpenAI 模型协助 $\triangle$ 未复核原文)、被撤回的 Flint Hills 声明、formal-conjectures 上 AI 起草的 issue。"AI 协助的数学声明"数量在激增, 人类专家的审读带宽仍是瓶颈, 和 §4 的结论一致。

5.10 自测题

读完后试着回答。如果答不上来, 回到对应小节再读一遍。

1. 为什么不能只看误差大小来评价一个分数逼近? "有效指数 v "是怎么定义的? (§5.1.2)
2. 355/113 为什么特别准? 用连分数的语言解释。 (§5.2.3)
3. 用抽屉原理说明为什么每个无理数都有 $\mu \geq 2$ 。 (§5.3.2)
4. "非零整数 ≥ 1 "这个套路, 在 $\sqrt{2}$ 的证明和 OpenAI 的证明里分别对应什么量? (§5.4.3、§5.7.2)
5. 为什么" π 是超越数"不能帮助证明 $\mu(\pi) = 2$? OpenAI 的证明用了 π 的什么结构? (§5.4.4、§5.7.2)
6. 为什么 Flint Hills 级数的部分和是阶梯形? $\mu(\pi) < 5/2$ 为什么足以让它收敛? (§5.6)
7. Lean 陈述的第二部分 `sSup {...} = 2` 对应 μ 定义里的哪几个词? (§5.8.1)
8. $\mu(\pi) = 2$ 能推出" π 的连分数部分商有界"吗? 能推出" π 是正规数"吗? (§5.9.2)

附:【检查】答案

- **检查 1:** $355/113 = 3.14159292\dots$, 与 π 差约 2.67×10^{-7} ; $113^2 = 12769$; 乘积约 0.0034, 即比 $1/q^2$ 好了约 290 倍。
- **检查 2:** $355 = 3 \times 113 + 16$, 所以 $355/113 = 3 + 16/113 = 3 + 1/(113/16)$; $113 = 7 \times 16 + 1$, 所以 $113/16 = 7 + 1/16$ 。合起来 $355/113 = [3; 7, 16]$ 。(π 本身是 $[3; 7, 15, 1, \dots]$, 而 $[3; 7, 15, 1]$

= [3; 7, 16], 两种写法是同一个分数。)

- **检查 3:** $q = 2$ (0.283) 和 $q = 9$ (0.274) 都在 $[0.2, 0.3)$ 里, 差是 7, 又得到 $22/7$ 。($q = 3$ 和 $q = 10$ 都在 $[0.4, 0.5)$, 差也是 7。 $Q = 10$ 时抽屉原理只能"看到"分母 ≤ 10 的分数, 最好的就是 $22/7$ 。)
- **检查 4:** $\sin(355) = \sin(355 - 113\pi) \approx 3.01 \times 10^{-5}$ (脚本实算 $355 - 113\pi = 3.0144 \times 10^{-5}$)。 $\sin^2 \approx 9.09 \times 10^{-10}$; $355^3 \approx 4.47 \times 10^7$; 乘积 ≈ 0.0407 , 倒数 ≈ 24.6 。

附：术语表

术语	一句话解释
有效指数 ν	若 $ x - p/q \approx q^{-(\nu)}$, 这个逼近的"超常程度"就是 ν
连分数	反复"取整、取倒数"得到的展开 $[a_0; a_1, a_2, \dots]$
渐近分数	连分数截断得到的分数, 是同等分母下的最佳逼近
部分商	连分数里的各个 a_i ; 越大说明它前一个渐近分数越准
Dirichlet 逼近定理	每个无理数都有无穷多个 $ x - p/q < 1/q^2$ 的逼近
无理性指数 $\mu(x)$	能被"无穷多次"以 $q^{-(\nu)}$ 精度逼近的最大 ν
代数数	某个整系数多项式的根, 如 $\sqrt{2}$ 、 $\sqrt[3]{2}$
超越数	不是代数数的数, 如 π 、 e 、Liouville 数
Roth 定理	所有代数无理数 $\mu = 2$ (1955, Fields 奖)
Liouville 数	$\mu = \infty$ 的数, 例如 $\sum 10^{-(k!)}$
线性形式 $a\pi - b$	旧方法构造的"很小但非零"的量, 用来给 μ 定上界
不可有效 (ineffective)	证明了某个常数存在, 但无法算出它的值
Flint Hills 级数	$\sum 1/(n^3 \sin^2 n)$, 收敛性由 $\mu(\pi)$ 决定
部分商有界 (badly approximable)	$ x - p/q \geq c/q^2$ 对所有分数成立; 比 $\mu = 2$ 更强
正规数	每种数字串在展开中出现频率都相同的数; 与 μ 无关
Catalan 常数 G	$1 - 1/3^2 + 1/5^2 - \dots$; OpenAI 同批声称证明它是无理数 (§5.7.4)

附：想继续深入

- **Numberphile**, *The Golden Ratio (why it is so irrational)* (YouTube, Ben Sparks) : §5.2.4"黄金比是最难逼近的数"的直观版本, 讲的就是连分数全是 1。
- **Mathologer**, *Infinite fractions and the most irrational number* (YouTube): 连分数和逼近, 动画清楚。

- **A. Ya. Khinchin**, *Continued Fractions* (Dover 重印): 薄薄一本, §5.2–5.4 和§5.4.5 的经典来源, 大学数学即可读。
- **Wadim Zudilin**, *An essay on irrationality measures of π and other logarithms*, arXiv:math/0404523: §5.5.2"线性形式框架"的权威综述。
- **Michel Waldschmidt**, *Open Diophantine problems*, Moscow Math. J. 4(1), 2004: <https://webusers.imj-prg.fr/~michel.waldschmidt/articles/pdf/odp.pdf> (p. 265 记录了这个猜想)
- Zeilberger–Zudilin, arXiv:1912.06345; Alekseyev, arXiv:1104.5100; Meiburg, arXiv:2208.13356。
- 原始论文: <https://github.com/openai/math/blob/main/preprints/The-irrationality-exponent-of-pi-is-2-September-24-2026/paper.pdf>
- 推理摘要: https://github.com/openai/math/blob/main/reasoning_traces/irrationality-exponent-of-pi.pdf
- Lean 范围说明: <https://github.com/openai/math/blob/main/lean/docs/017.md> ; 挑战陈述: <https://github.com/openai/math/blob/main/lean/ComparatorChallenges/PiExponent.lean>
- Catalan 常数论文 (§5.7.4): <https://github.com/openai/math/blob/main/preprints/Catalans-constant-is-irrational-September-24-2026/paper.pdf> ; Lean 范围说明: <https://github.com/openai/math/blob/main/lean/docs/005.md>
- formal-conjectures issue #6909: <https://github.com/google-deepmind/formal-conjectures/issues/6909>
- John D. Cook 科普: <https://www.johndcook.com/blog/2026/10/07/irrationality-exponent-of-pi/>

6. 矩阵乘法到底能多快: $\omega \leq 9/4$

前提只需要: 会矩阵乘法、会算对数 ($\log_2 8 = 3$ 这种)、知道"复杂度 $O(n^3)$ "是什么意思。张量、秩、"张量特征"这些新概念都会先讲。文中所有数字都由脚本实算(脚本: `精讲/scripts/03_matmul.py`, 用 sympy 做符号验算)或有出处;【检查】是可以自己动手算的小练习, 答案在章末。 $\triangle$ = 我没能完全核实。预计阅读时间: 60–90 分钟。可以分三次读: §6.1–6.3 (Strassen 和 ω)、§6.4–6.7 (张量、近似、渐近谱)、§6.8–6.10 (OpenAI 的结果和意义)。和 §4 (准黎曼猜想) 不同的一点: 这篇论文只有 **13 页**, 而且我通读了全文(不只是引言)。所以§6.8 能把证明的骨架完整讲出来。

6.0 先说结论：这一章要讲明白的一件事

两个 $n \times n$ 矩阵相乘，教科书做法要 n^3 次乘法。1969 年 Strassen 发现可以更少。从那以后，理论计算机科学一直在问：**最少需要 n 的几次方？** 这个"几次方"叫 ω （矩阵乘法指数）。

这一章要讲清楚的是一条因果链：

ω 有多小 $\Leftarrow$ 矩阵乘法"张量"的秩随 n 增长多快 $\Leftarrow$ (Strassen 的对偶定理) 所有"张量特征"在矩阵乘法上取值多大 $\Leftarrow$ OpenAI: 用**多项式乘法**这个更简单的张量，把每个特征的取值都夹住了。

结果： $\omega \leq 9/4 = 2.25$ 。此前人类的最好结果约 2.3712 (2026-08)，而且已经 35 年只在小数点后第三位挪动。

读完这一章，你应该能用自己的话讲出：

- 为什么"2x2 少用一次乘法"就能改写整个 n^3 ；
- ω 的精确含义，以及为什么它和"张量的秩"是一回事；
- OpenAI 这 13 页的证明大致走了哪几步，为什么它和过去 35 年的"激光法"不是一条路；
- 为什么这个结果对 GPU 和 LLM 训练没有任何直接加速。

6.1 矩阵乘法：数一数要做几次乘法

6.1.1 教科书算法

$C = A \cdot B$ ， C 的每个元素是一行乘一列：

$$c_{ij} = a_{i1} \cdot b_{1j} + a_{i2} \cdot b_{2j} + \dots + a_{in} \cdot b_{nj}$$

C 有 n^2 个元素，每个要 n 次乘法、 $n-1$ 次加法。合计 **n^3 次乘法 + $(n^3 - n^2)$ 次加法**。2x2 的情况：8 次乘法，4 次加法。

6.1.2 为什么理论家只盯着"乘法"

你可能觉得奇怪：加法也要花时间，为什么只数乘法？原因在递归 (§6.2 马上会看到)：当 a 、 b 本身是矩阵块时，"块的加法"只要 $(n/2)^2$ 次运算，而"块的乘法"要递归下去，代价大得多。**在递归里，乘法次数决定指数，加法只影响常数。**

6.1.3 和你日常的联系

LLM 训练里绝大部分 FLOPs 都是 GEMM（通用矩阵乘）。cuBLAS、CUTLASS 里的 GEMM 用的就是 n^3 算法，只是把它切成适合 Tensor Core 和共享内存的小块（tiling）。这一点到本章结束都不会变，§6.10.2 解释原因。

6.2 Strassen 1969: 7 次就够

6.2.1 七个乘积

设 $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$, $B = \begin{bmatrix} e & f \\ g & h \end{bmatrix}$ 。只做 7 次乘法：

$$\begin{aligned} M1 &= (a+d)(e+h) & M2 &= (c+d)e & M3 &= a(f-h) & M4 &= d(g-e) \\ M5 &= (a+b)h & M6 &= (c-a)(e+f) & & & M7 &= (b-d)(g+h) \end{aligned}$$
$$\begin{aligned} C11 &= M1+M4-M5+M7 & C12 &= M3+M5 \\ C21 &= M2+M4 & C22 &= M1-M2+M3+M6 \end{aligned}$$

验算 C12: $M3 + M5 = af - ah + ah + bh = af + bh$ ✓。(脚本用 sympy 把四个元素全部展开核对过，四个都对。)

【检查 1】手算验证 $C21 = M2 + M4 = ce + dg$ 。

代价：乘法从 8 次降到 7 次，加减法从 4 次涨到 18 次。看起来不划算，对吧？

6.2.2 关键：公式里没有用到 $ab = ba$

注意这 7 个乘积里，每次乘法都是"左边只含 A 的元素，右边只含 B 的元素"，而且从没交换过乘法顺序。所以 $a\dots h$ 可以**本身就是矩阵块**（矩阵乘法不满足交换律，但这里用不到）。于是：

- 把 $n \times n$ 矩阵切成 4 个 $(n/2) \times (n/2)$ 的块；
- 做 7 次"块乘法"（每次递归调用自己）+ 18 次"块加法"；
- 递归式： $T(n) = 7 \cdot T(n/2) + 18 \cdot (n/2)^2$ 。

展开递归：每往下一层，乘法个数 $\times 7$ ，规模 $\div 2$ 。一共 $\log_2 n$ 层，所以乘法总数 $= 7^{(\log_2 n)} = n^{(\log_2 7)}$ 。

$$\log_2 7 = 2.807354\dots \text{ (脚本实算)}$$

省下的 1 次乘法在每层递归里复利放大。下表是 $n = 2^k$ 、一路递归到 1×1 时的实算对比：

n	朴素乘法数 n^3	Strassen 乘法数 7^k	比值	朴素总运算	Strassen 总运算 (含 18 次块加法)	比值
2	8	7	0.875	12	25	2.08
16	4,096	2,401	0.586	7,936	15,271	1.92
128	2,097,152	823,543	0.393	4,177,920	5,666,497	1.36
1024	1,073,741,824	282,475,249	0.263	2,146,435,072	1,971,035,287	0.918
4096	6.87×10^{10}	1.38×10^{10}	0.201	1.37×10^{11}	9.68×10^{10}	0.704

(脚本实算。)两件事值得注意：

1. 只数乘法，Strassen 马上就赢；算上加法，**要到 $n = 1024$ 才开始赢**（如果一直递归到 1×1 ）。实际实现会在块小到一定程度（比如 64）后改用朴素算法，交叉点会提前，但"渐近更快 $\neq$ 小规模更快"这个现象在本章会反复出现。
2. 这只是运算次数。真实硬件上还有访存和数值稳定性，§6.10.2 再说。

6.3 ω ：矩阵乘法指数

6.3.1 定义

ω = 所有满足下面条件的 τ 的下确界：对任意 $\varepsilon > 0$ ， $n \times n$ 矩阵乘法都能用 $O(n^{(\tau+\varepsilon)})$ 次算术运算（+、-、 $\times$ ）完成。

拆开说：

- "下确界"： ω 本身不一定能达到，但能无限逼近。
- " $+\varepsilon$ "：允许多一点点余量。这样 $n^2 \cdot \log n$ 这种也算作指数 2。
- $O(\dots)$ 里的常数可以随 ε 变得任意大。这一条是§6.10"银河算法"的根源。
- 这里是在复数（或任意固定的域）上精确计算，不考虑浮点误差和数字的位数。

6.3.2 为什么 $2 \leq \omega \leq 3$

- $\omega \leq 3$ ：教科书算法。
- $\omega \geq 2$ ：输出有 n^2 个数，每个都要至少被算一次。（读入 $2n^2$ 个输入也要这么多步。）
- Strassen 证明了 $\omega \leq 2.807$ 。

主流猜想： $\omega = 2$ 。也就是说矩阵乘法几乎可以和"把数据读一遍"一样快。没人能证明，也没人能证明 $\omega > 2$ 。

6.3.3 为什么值得关心

很多基本问题的最优算法复杂度可以直接写成 n^ω ：解线性方程组、矩阵求逆、行列式、LU 分解、图的传递闭包、二分图最大匹配等 [P]（标准结果，见 Bürgisser–Clausen–Shokrollahi 的教材，"想继续深入"一节）。线性规划求解器也在其中：Cohen–Lee–Song (*Solving Linear Programs in the Current Matrix Multiplication Time*, STOC 2019, arXiv:1810.07896) 的内点法，在当前的 ω 下解 n 个变量的线性规划大约只要 n^ω 时间（忽略对数因子）[P]。 ω 降了，它们的理论复杂度一起降。

6.4 张量：把"一个算法"变成"一个数"

这一节是整章的基础。它把"设计算法"这件事，换成"求一个三维数组的秩"。

6.4.1 从矩阵的秩说起

一个矩阵的秩 = 最少能写成几个"外积" (列向量 × 行向量) 之和。例如 $[[1,2],[2,4]] = [1,2]^T \cdot [1,2]$, 秩 1。

6.4.2 矩阵乘法张量

把矩阵乘法写成一个三元的"大多项式" (trilinear form, 三线性形式):

$$T_n = \sum_{\{i,j,k\}} x_{ij} \cdot y_{jk} \cdot z_{ki}$$

x 代表 A 的元素, y 代表 B 的元素, z 是"C 的第 (i,k) 个位置"的占位符。这个式子的意思是: "A 的 (i,j) 元素乘 B 的 (j,k) 元素, 贡献到 C 的 (i,k) 位置。"把系数排成一个三维数组, 就是一个**张量** (可以理解为三维的矩阵)。它的三组变量 x、y、z 叫**三条腿** (legs)。

2×2 时 T_2 有 $2^3 = 8$ 项, 对应教科书算法的 8 次乘法。

6.4.3 张量的秩 = 最少乘法次数

张量的秩 $R(T)$ = 最少能写成几个"秩 1 项"之和, 每个秩 1 项形如:

$$(x \text{ 的某个线性组合}) \cdot (y \text{ 的某个线性组合}) \cdot (z \text{ 的某个线性组合})$$

对照 Strassen 的 $M1 = (a+d)(e+h)$: 前两个括号正是"x 的线性组合"和"y 的线性组合", 第三个括号记录 M1 被加到 C 的哪些位置 (C11 和 C22)。**一个秩 r 的分解 = 一个只用 r 次乘法的算法**, 反之亦然 (这种算法叫"双线性算法")。所以:

$$\text{Strassen 1969} \Leftrightarrow R(T_2) \leq 7. \text{ (Winograd 1971 证明了 7 是最优的, } R(T_2) = 7 [P]. \text{)}$$

6.4.4 张量积 = 递归

把 T_n 和 T_m "相乘" (张量积, 每条腿的下标配成对), 得到的恰好是 $T_{\{nm\}}$ 。这就是 §6.2.2"块套块"递归的代数版本。于是 $R(T_{\{nm\}}) \leq R(T_n) \cdot R(T_m)$, 并且:

$$\text{只要找到一个 } k \times k \text{ 的分解用 } r \text{ 次乘法, 就有 } \omega \leq \log_k r.$$

尺寸 k	乘法数 r	来源	$\log_k r$ (脚本实算)
2	8	朴素	3.0000
2	7	Strassen 1969	2.8074
3	23	Laderman 1976	2.8540
4	49	Strassen 用两次	2.8074
4	48	AlphaEvolve 2025 (复数域)	2.7925
4	47	AlphaTensor 2022 (仅 GF(2), 即模 2 运算)	2.7773

注意：靠"找一个固定小尺寸的好分解"，至今最好也只到 2.77 左右。所有低于这个数的 ω 上界，都来自 §6.5–6.7 的"渐近"方法。

【检查 2】如果有人找到了 4×4 用 46 次乘法的分解，能推出 $\omega \leq$ 多少？

6.4.5 另一个张量：多项式乘法（OpenAI 证明的主角）

两个多项式相乘： $(x_0 + x_1 t) \cdot (y_0 + y_1 t) = x_0 y_0 + (x_0 y_1 + x_1 y_0) t + x_1 y_1 t^2$ 。把它写成张量：

$$C(a, b) = \sum_{\{i < a, j < b\}} x_i \cdot y_j \cdot z_{\{i+j\}}$$

a, b 是两个输入多项式的系数个数，输出有 $a + b - 1$ 个系数。朴素做法要 $a \cdot b$ 次乘法。但它的秩只有 $a + b - 1$ ：

- 在 $a + b - 1$ 个不同的点上分别求两个多项式的值，相乘（ $a + b - 1$ 次乘法）；
- 再用插值把乘积多项式的系数还原回来（插值只用加法和乘常数，不算"变量 $\times$ 变量"的乘法）。

$a = b = 2$ 的情况就是 **Karatsuba 技巧**：3 次乘法 $P_0 = x_0 y_0$ ， $P_1 = (x_0 + x_1)(y_0 + y_1)$ ， $P_2 = x_1 y_1$ ，中间系数 = $P_1 - P_0 - P_2$ （脚本核对：展开得 $x_0 y_1 + x_1 y_0$ ✓）。这也是 FFT 快速乘法的思想来源。

要点：多项式乘法的秩是完全已知的（ $a + b - 1$ ），矩阵乘法的秩是未知的。 OpenAI 的整个证明就是"用已知的东西去夹未知的东西"。

【检查 3】用"在 $t = 0, 1, -1$ 三点求值"的办法，为 $(x_0 + x_1 t)(y_0 + y_1 t)$ 设计另一个 3 次乘法的算法，写出中间系数怎么还原。

6.5 近似也算数：边界秩与"退化"

6.5.1 一个奇怪的例子

看这个小张量（和矩阵乘法无关，只是演示）：

$$W = x_0 y_0 z_1 + x_0 y_1 z_0 + x_1 y_0 z_0$$

可以证明它的秩是 3。但看这个表达式（ ε 是一个小参数）：

$$\begin{aligned} & [(x_0 + \varepsilon x_1)(y_0 + \varepsilon y_1)(z_0 + \varepsilon z_1) - x_0 y_0 z_0] / \varepsilon \\ & = W + \varepsilon \cdot (x_0 y_1 z_1 + x_1 y_0 z_1 + x_1 y_1 z_0) + \varepsilon^2 \cdot x_1 y_1 z_1 \end{aligned}$$

（脚本用 sympy 展开核对过。）左边只有 2 个秩 1 项，当 $\varepsilon \rightarrow 0$ 时它趋向 W 。所以 W 可以被"秩 2 的东西"任意逼近。这叫 W 的**边界秩**（border rank）是 2。

6.5.2 Bini 的插值：近似算法可以变成精确算法

Bini 等人 1979 年发现 2×2 矩阵乘法的某个变体有这种"近似省乘法"的现象，Bini 1980 证明了一个关键事实 [P]：**近似算法在渐近意义下和精确算法一样好**。做法是：把含 ϵ 的表达式看成 ϵ 的多项式，取几个不同的 ϵ 值分别计算，再插值出 ϵ^0 那一项。代价只是一个和 n 无关的倍数，在指数里消失。

6.5.3 "退化" (degeneration)：给变量配权重

上面的 ϵ 技巧有一个更系统的版本，OpenAI 的证明里反复使用：

- 1. 给每个变量一个整数**权重** w ；
- 2. 把每个变量乘上 ϵ^w ；
- 3. 每一项的总权重 = 三个变量权重之和；**只保留总权重最小的那些项**，其余项带着更高次的 ϵ ，在极限里消失。

用这种办法从 A 得到 B ，记作 $A \rightsquigarrow B$ 。Bini 的插值保证： B 不会比 A "更难"。这是一个很强的工具：**你可以通过巧妙配权重，从一个大张量里"切"出想要的小张量，同时把不要的项全部扔掉**。

6.6 五十年历史：小数点后第三位的战争

6.6.1 渐近和不等式与激光法

- **Schönhage 1981**：如果你能用比单独计算更便宜的代价**同时**算若干个**互相独立**的矩阵乘法，也能推出 ω 的上界 ("渐近和不等式")。注意"独立"指三条腿上的变量全都不共享，这叫**完全直和** (full direct sum)。
- **Strassen 1986–87：激光法 (laser method)**。找一个本身不是矩阵乘法、但秩很低的张量，取它的很高次幂 (张量积自己乘很多次)，再从里面"切"出大量互相独立的矩阵乘法。像激光一样，从杂乱的光里筛出同相位的部分。
- **Coppersmith–Winograd 1990**：找到一个特别好的起始张量 (CW 张量)，配合组合学里的"无三项等差数列集合"做切割，得到 2.3755。

从 1986 年到 2026 年 8 月，近 40 年里 ω 上界的进展几乎全部来自对激光法的改进 (下表 1986 年之后的每一行)。

6.6.2 时间线

年份	作者	ω 上界	和上一行相比的降幅 (脚本实算)
1969	Strassen	2.8074	—
1978	Pan	2.796	0.011
1979	Bini 等 (边界秩)	2.780	0.016
1981	Schönhage (渐近和不等式)	2.522	0.258

年份	作者	ω 上界	和上一行相比的降幅（脚本实算）
1986	Strassen（激光法）	2.479	0.043
1990	Coppersmith–Winograd	2.3755	0.104
2014	Le Gall（此前有 Stothers 2010、Vassilevska Williams 2012）	2.3728639	0.0026
2021	Alman–Vassilevska Williams	2.3728596	0.0000043
2023	Duan–Wu–Zhou	2.371866	0.00099
2024	Vassilevska Williams–Xu–Xu–Zhou	2.371552	0.00031
2024	Alman–Duan–Vassilevska Williams–Xu–Xu–Zhou	2.371339	0.00021
2026-08	Dupont 等（含 AlphaEvolve）	2.371177	0.00016
2026-09-24	OpenAI 声称（任意域，仍是激光法框架）[P]	2.371054886	0.00012
2026-09-24	OpenAI 声称（复数域）[P]	2.258	0.113
2026-10-02	OpenAI 声称（复数域，本章主角）[P]	2.25 = 9/4	0.008

（2026-08 之前的数值都是同行评审结果 [P]；Dupont 等的 2.371177 是 arXiv 2608.16884 预印本，OpenAI 的 9/4 论文自己也引用它作为此前纪录。OpenAI 的三行取自 openai/math 仓库里的论文原文，都还没有经过同行评审。）

脚本实算的几个对比：


- 1990 → 2024 的 34 年：一共降了 0.0041。
- 2014 → 2026-08 的 12 年：一共降了 0.0017。
- 2026-08 → 9/4：一步降了 **0.121**。

6.6.3 激光法撞上的墙

Ambainis–Filmus–Le Gall（STOC 2015）[P] 证明：基于 CW 张量的幂、用这一类激光法分析，**不可能低于约 2.3078**。后来 Alman–Vassilevska Williams 等给出了更一般的壁垒 [P] △（具体数值没有逐一核对）。所以 2.25 不可能是"激光法再优化一点"，必须走另一条路。这正是 Aaronson 说的 "via a completely different approach"。

下图把§6.6.2 的时间线和这道壁垒画在一起：OpenAI 的 2.25 落在虚线（约 2.3078）下面。

矩阵乘法指数 ω 的上界：57 年的历史



数据：Strassen 1969；Pan/Bini/Schönage 1978–81；Strassen 1986；Coppersmith–Winograd 1990；Le Gall 2014；Alman–Vassilevska Williams 2021；Duan–Wu–Zhou 2023；Alman 等 2024 (arXiv:2404.16349)；Dupont 等 2026-08 (arXiv:2608.16884，借助 AlphaEvolve)。2014→2026 共下降约 0.0017；OpenAI 的 2.25 一次下降约 0.12，而且低于已知的激光法壁垒——所以它必须是另一种方法（论文用的是 Strassen 的"渐近谱"路线）。

6.7 Strassen 的渐近谱：用"测量"代替"构造"

这一节是理解 OpenAI 证明的钥匙，也是本章最抽象的部分。我尽量用工程类比讲清楚，但会在类比失真处标出来。

6.7.1 张量之间的"谁比谁强"

说 $A \geq B$ (B 是 A 的"限制", restriction)，意思是：对 A 的三条腿分别做线性代换，就能得到 B 。直观地说，会算 A 就会算 B 。例如：

- $R(T) \leq r$ 等价于 " r 个独立的数乘 $\geq T$ "（把 r 记作 " r 个互不相干的 xyz 之和"）。
- 把 T_n 里所有 $i \neq j$ 的项丢掉，剩下 n 个独立的数乘，所以 $T_n \geq n$ 。

6.7.2 张量特征：一种"一致的测量仪"

张量特征 (tensor character，也叫渐近谱里的一个"点") 是一个把张量映射成非负实数的函数 λ ，满足四条：

性质	含义	工程类比
$\lambda(1) = 1$	单个数乘的值是 1	单位校准
$\lambda(A \oplus B) = \lambda(A) + \lambda(B)$	独立任务并行，值相加	吞吐可加
$\lambda(A \otimes B) = \lambda(A) \cdot \lambda(B)$	嵌套（递归），值相乘	递归开销相乘
$A \geq B \Rightarrow \lambda(A) \geq \lambda(B)$	会算 A 就会算 B，所以 A 的值不小	单调

由这四条立刻推出：**对任何非零张量， $1 \leq \lambda(A) \leq R(A)$** 。所以每个特征都给出秩的一个下界。

例子：展平秩 (flattening rank)。把三维数组的一条腿竖着放、另两条腿拼成一行，得到一个普通矩阵，取它的矩阵秩。这满足全部四条，是三个最简单的特征。对 T_n ，展平秩是 n^2 。

6.7.3 每个特征在矩阵乘法上的值都是 $n^{(3t)}$

论文 §2.1 用一个小技巧证明：对任何特征 λ ，存在一个数 $t > 0$ ，使得

$$\lambda(T_n) = n^{(3t)} \quad \text{对所有 } n \text{ 成立}$$

(证明思路： T_n 可以拆成三个"点积"张量的张量积，每个点积在 λ 下是 m 的某个幂；乘起来就是 $n^{(p_X + p_Y + p_Z)}$ ，记 $3t = p_X + p_Y + p_Z$ 。)

例如展平秩： $\lambda(T_n) = n^2 \Rightarrow 3t = 2, t = 2/3$ 。

6.7.4 Strassen 的对偶定理：测量足以决定一切

Strassen 1986–88 [P] 证明了一个深刻的定理 (OpenAI 论文附录 A 重新证明了它需要的特例)：

矩阵乘法的秩指数 $\omega \leq 3 \cdot (\text{所有特征的 } t \text{ 中最大者})$ 。更准确地说：如果 $R(T_d)$ 很大，就一定存在某个特征 λ 能"检测"到它，即 $\lambda(T_d)$ 也很大。

类比：这很像线性规划的对偶，或者 Farkas 引理：要么存在一个好算法，要么存在一张"证书" (一个特征) 证明它不存在。所以要证明"好算法存在" (ω 小)，你**不需要构造算法**，只需要证明"任何证书都说不出它不存在"，即**所有特征的 t 都 $\leq 3/4$** 。

这是本章最重要的一个转折：

- 激光法：**构造**一个具体的大张量分解。
- 渐近谱：**限制所有可能的测量**，再用对偶定理推出算法存在。

诚实的说明：渐近谱这条路 Strassen 1980 年代就提出了，难点在于没人知道所有特征长什么样。在复数域上，已知的无穷族只有 Christandl–Vrana–Zuiddam (JAMS 2023) 的"量子泛函" [P]。OpenAI 的证明**绕开了**这个难点：它不需要知道特征长什么样，只用那四条性质推不等式。

如果 $\omega = 2$ 猜想成立，那么所有特征在矩阵乘法上都有 $t = 2/3$ (和展平秩一样)。9/4 的结果说的是： $t \leq 3/4$ 。

6.8 OpenAI 声称了什么

6.8.1 主结果

的摘要只有一句：

"We prove that the exponent of matrix multiplication over the complex numbers is at most $9/4$." [P]

定理 1.1: "For every $\varepsilon > 0$, two $n \times n$ complex matrices can be multiplied using $O_\varepsilon(n^{9/4+\varepsilon})$ arithmetic operations. In particular, $\omega \leq 9/4$."

论文自己也说: "Theorem 1.1 concerns the asymptotic arithmetic exponent; its proof does not specify a competitive finite matrix size."

同一家族 (编号 107) 还有两份手稿:

- *Complex Matrix Multiplication Below 2.258 and Rectangular Bounds* (2026-09-24, 83 页): 特征 0 的域上 $\omega < 2.258$, "对偶指数" $\alpha > 0.465$, $\omega(1, 0.709, 1) < 2.092$ 。9/4 出来后, 2.258 被它覆盖了。
- *Staggered extraction for exact matrix multiplication over every field* (2026-09-24, 35 页): **任意域** (含有限域、正特征) 上 $\omega < 2.371054886006746$ 。仍在激光法框架里, 比 Dupont 等多改进约 1.2×10^{-4} 。

6.8.2 证明的骨架 (我读了全文, 以下是忠实的简化版)

整个证明只用到 §6.4–6.7 的工具。分五步。

第 1 步: 把"共享一条腿"的块分开 (论文 §3, 分离引理)。

激光法的老难题是: 切出来的小块常常共享变量, 不是完全独立的。OpenAI 的核心构造处理这样一种情形: M 个块在 y 、 z 两条腿上各自独立, 但**共享** x 腿。做法:

- 复制 $5M$ 份, 每份用一个 $L = 5M$ 次单位根 ζ 的不同幂次做相位 (这是一个有限傅里叶变换), 给每个 x 变量打上一个"暂定标签" g ;
- 再用 §6.5.3 的"配权重": x 的权重 g^2 , y 的权重 $hu - h^2$, z 的权重 $-hv$ 。在傅里叶变换保留下来的项上, 总权重恰好等于 $(g - h)^2$;
- 只保留权重为 0 的项, 也就是 $g = h$: 每个块拿到了自己专属的 x 副本, 块与块完全独立了。附带地, 每块还多出一个长度 M 的"点积"。

这一步的直觉: 用平方 $(g-h)^2 \geq 0$ 作为"惩罚", 让标签对不上的项在 $\varepsilon \rightarrow 0$ 时全部消失。结合"按频率计数"的标准技巧, 得到一个熵不等式 (推论 3.2)。

第 2 步: 只看多项式乘法。 对任意一个特征 λ , 定义多项式乘法张量 $C(a, b)$ 的"对称化取值" $P(a, b)$ (把三条腿的 6 种排列都算一遍、把 6 个取值相乘, 再开 $1/(6t)$ 次方; 见论文式 4.4)。它满足三条简单性质 (式 4.5):

- $P(a, b) = P(b, a)$;
- $P(1, b) = b$ ($C(1, b)$ 就是一个点积);
- **$P(a, b) \leq (a + b - 1)^{(1/t)}$** : 因为多项式乘法的秩是 $a + b - 1$ (§6.4.5), 而特征 $\leq$ 秩。

这里 t 正是§6.7.3 里那个" λ 在矩阵乘法上的指数"。

第 3 步：两条新不等式（论文 §4）。

- **离散凹性**: $2P(a, b) \geq P(a, b+1) + P(a, b-1)$ 。(用一个"行列式滤链"把 $C(a, b) \otimes$ 点积 退化成 $C(a, b+1)$ 和 $C(a, b-1)$ 两块, 再用第 1 步。)
- **移位三倍**: $P(a, 3h + a - 1) \geq 3 \cdot P(a, h)$ 。(把 $C(a, 3h+a-1)$ 的 $y、z$ 下标切成左、中、右三段, 配权重后恰好留下三个 $C(a, h)$ 的副本。)

移位三倍可以手算最小例子: $a = 2、h = 1$, 即 $C(2, 4)$, 共 8 项 $x_i \cdot y_j \cdot z_{\{i+j\}}$ 。 y 切成左 $\{0\}$ 、中 $\{1, 2\}$ 、右 $\{3\}$; z 切成左 $\{0, 1\}$ 、中 $\{2\}$ 、右 $\{3, 4\}$ 。中段 y 权重 $+1$, 中段 z 权重 -1 , 其余 0:

项 (x, y, z)	权重	结果
(0,0,0)、(1,0,1)	0	左块保留
(0,2,2)、(1,1,2)	$+1-1 = 0$	中块保留
(0,3,3)、(1,3,4)	0	右块保留
(0,1,1)、(1,2,3)	+1	消失

(脚本逐项核对, 和论文图 1 一致。) 三块在 $y、z$ 上互不相交, 共享 x , 正好是第 1 步能处理的形状。

【检查 4】 不看表, 自己算一下 (0,1,1) 这一项为什么权重是 $+1$ 。

第 4 步：纯粹的数列论证（论文 §5，引理 5.1）。 只用"对称 + $P(1,b) = b$ + 凹性 + 移位三倍", 就能推出对角线增长:

$$P(a, a) \geq a^{(4/3)}$$

这一步完全是初等的: 凹性说明增量递减, 三倍说明增量不能减得太快, 两者夹出一个递推 $H_a \geq (1 + 1/(3(a-1))) \cdot H_{\{a-1\}}$, 再用 $(1 + 1/(3m))^3 \geq 1 + 1/m$ 收尾。脚本核对了这个下界链 (例如 $a = 1000$ 时, 论文的中间下界给出 $P(a,a) \geq 16,790$, 而 $a^{(4/3)} = 10,000$)。

第 5 步：两头一夹。 第 2 步给上界, 第 4 步给下界:

$$a^{(4/3)} \leq P(a, a) \leq (2a - 1)^{(1/t)}$$

当 $a \rightarrow \infty$, 左边像 $a^{1.333}$, 右边像 $a^{(1/t)}$ 。要对所有 a 成立, 必须 $1/t \geq 4/3$, 即 $t \leq 3/4$ 。

脚本实算: 如果某个特征的 $t = 0.8$, 这个不等式在 $a = 32,761$ 时就会被违反; $t = 0.76$ 时要到 $a \approx 3.8 \times 10^{22}$ 。

于是对**每一个**特征都有 $\lambda(T_d) = d^{(3t)} \leq d^{(9/4)}$ 。再用 §6.7.4 的对偶定理, 秩指数 $\leq 9/4$, 所以 $\omega \leq 9/4$ 。

6.8.3 为什么最后的答案是一个有理数

激光法的界来自一个数值优化问题的最优值, 所以是 2.3728639 这种"算出来的"无理数。这里的 $9/4 = 3 \times 3/4$, $3/4$ 来自" $4/3$ 次方的增长", 而 $4/3$ 又来自"三倍"这个构造里的 3。所以 Aaronson 说: "a *rational* exponent for once (!)" [R]。

6.8.4 "不给出具体尺寸"到底意味着什么

论文最后一段把 " $\omega \leq 9/4$ " 转换成算法: 由秩指数的定义, **存在**某个固定的 u 和一个 T_u 的分解, 乘法次数 $r < u^{(9/4+\delta)}$, 然后像 Strassen 一样递归。但证明**没有告诉你 u 是多少, 也没有给出这个分解**, 因为 §6.7.4 的对偶定理用到了紧致性和不动点定理 (Schauder-Tychonoff), 本质上是存在性证明。

这对工程意味着什么, 可以用已知的下界估一下 (脚本实算):

- $u = 2$: $R(T_2) = 7 > 2^{2.25} \approx 4.76$, 不可能。
- $u = 4$: 需要 $r \leq 22$, 但 Bläser 2003 证明了 $R(T_n) \geq 2.5n^2 - 3n$ [P] $\triangle$ (出处细节未复核), $n = 4$ 时下界是 28。不可能。
- 按这个下界, **u 至少要 34**, 才可能存在满足要求的分解。实际的 u 可能远大于此, 没人知道。

论文的 Remark 5.2 补充: 这个分解的系数可以取成代数数 (落在某个数域里)。所以原则上可以靠有限搜索找到它, 但没有任何实际可行性。(这是我的推断 $\triangle$ 。)

一篇 Aaronson 博客下的评论 (Bram Cohen, #42) 说这个结果 "isn't constructive"。这个判断是对的, 但他说的 "ramsey type thing" 不准确: 非构造性来自对偶定理里的紧致性 + 不动点论证, 不是 Ramsey 型组合论证。

6.9 它被核实到什么程度

6.9.1 Lean 陈述: 先读模型, 再读定理

和 §4 (准黎曼猜想) 不同, 这里的 ω 不是 Mathlib 里现成的定义, 而是 challenge 文件

`lean/ComparatorChallenges/MatrixMultiplication.lean` 自己写的。所以**审查定义**比审查定理更重要。以下是我读 Lean 源码后的逐块翻译 [P]:

- `Gate`：一个"门"只有五种：`constant`（常数）、`input`（读一个输入）、`add`、`sub`、`mul`（对两个已有寄存器做运算）。
- `Gate.cost`：常数和输入成本 0，加、减、乘各成本 1（源码原文：`.constant _ => 0`、`.input _ => 0`，`.add`、`.sub`、`.mul` 都是 `=> 1`）。所以这是标准的"算术运算次数"模型。（乘以常数也要用 `mul` 门，所以也计成本 1。）
- `Program`：门的序列，每个门只能引用前面的寄存器。这就是"直线程序"（straight-line program），没有循环、没有分支、没有除法。
- `MatrixAlgorithm F a b c`：一个程序，加上"输出矩阵的每个位置取哪个寄存器"。
- `Correct`：对所有输入矩阵 A、B，输出都等于 `A * B`（Mathlib 的标准矩阵乘法）。
- `AdmissibleExponent F  $\tau$` ：对任意 $\varepsilon > 0$ ，存在常数 C，使得对每个 $n \geq 1$ ，都存在一个正确程序，成本 $\leq C \cdot n^{(\tau+\varepsilon)}$ 。
- `omega F := sInf { $\tau$  | AdmissibleExponent F  $\tau$ }`：下确界。

然后定理本身：

```
theorem complex_omega_le_nine_quarters :
  Arithmetic.omega  $\mathbb{C} \leq (9 : \mathbb{R}) / 4$ 
```

完整名字是 `OAI.MatrixMultiplication.complex_omega_le_nine_quarters`。翻译：在复数域上，按上面这个模型定义的矩阵乘法指数 $\leq 9/4$ 。这和 §6.3.1 的定义一致。注意它是"非一致"的（每个 n 可以有不同的程序，不要求有一个统一的算法生成它们），这也是文献里 ω 的标准定义（非一致的代数复杂度）。我的判断：模型和文献一致，没有隐藏假设。

一个值得注意的规格陷阱（对 AI 安全的人特别有意思）：在 Lean/Mathlib 里，空集的 `sInf` 规定为 0，没有下界的集合的 `sInf` 也规定为 0。所以如果某个定义写错了，导致"没有任何程序被判定为正确"，那么 `omega = 0`，"`omega  $\leq 9/4$` " 就会平凡地成立。我检查了这一点：解答里证明了 `omega_le_three`（朴素算法可行，集合非空）和 `admissibleExponent_two_le`（任何可行指数 ≥ 2 ，集合有下界），并且 `9/4` 的推导走的是 `csInf_le`，需要真的给出可行指数。所以这个陷阱被排除了。

同一个 challenge 文件里还有两个定理： $\alpha > 93/200$ 和 $\omega(\mathbb{C}; 1, 0.709, 1) < 523/250$ 。

6.9.2 证明本身

- `9/4` 定理的 Lean 证明在 `OAI/LinearAlgebra/MatrixMultiplication/AuxiliarySeparation/`（73 个文件、10,895 行）。从它的 `Main.lean` 出发算 import 闭包，项目内部共 129 个文件、约 20,700 行（脚本实算，含共享的 Arithmetic、Tensor、Polynomial 等目录）。整个矩阵乘法目录（含 2.258 和矩形界）是 509 个文件、约 8.3 万行。

- 我 grep 过：没有 `sorry`、没有自定义 `axiom`、没有 `native_decide` (grep 命中 `admit` 的三处都是注释里的英文单词 "admits")。
- Comparator 配置只允许三个标准公理： `propext`、`Quot.sound`、`Classical.choice`。注意配置里 `"enable_nanoda": false`，即这个 challenge 没有开启第二个独立内核。
- **外部依赖**：附录 A 的不动点定理用到了第三方库 `fixed-point-theorems-lean4` (harfe, Brouwer 不动点定理)。OpenAI 为它打了一个移植补丁 (约 77 行新增、63 行删除)，我看过，主要是适配 Lean 4.34 的 import 和语法，没有看到 `sorry` 或新公理。
- 一个文档小疑点：scope 说明 `lean/docs/107.md` 只列了 2.258 和 staggered 两篇论文，没有列 9/4 论文；但 9/4 定理确实在 `AuxiliarySeparation/Main.lean` 里被证明 (文件注释写着 "Theorem 1.1")。

6.9.3 独立复查

- **erenciracioglu-dotcom/openai-math-9-4-lean-check** [R]：在 Windows 11 上用 Lean v4.34.1 编译通过了这三个定理，用 `pp.all` 比对 challenge 陈述和解答陈述完全一致，报告只依赖三个标准公理。但它自己说明："It does **not** replace Comparator: there was no sandbox and no second, independent kernel replay." 另外它用的是 openai/math 的 commit `adc7f12`，不是本笔记用的 `fd4aeeb` $\triangle$ (两个 commit 之间这部分有没有变化，我没比对)。
- 我自己**没有**编译。

6.9.4 人类专家

- Scott Aaronson ("The Mathocalypse", 2026-10-07)："Matrix multiplication in $n^{(9/4+o(1))}$ time—a rational exponent for once (!), and via a completely different approach than was used for $O(n^{(2.373)})$ and so forth" [R]。这是一句评论，不是核验。
- **截至 2026-10-08，我没找到激光法 / 张量领域的专家 (Vassilevska Williams、Alman、Le Gall、Zuiddam、Christandl 等) 公开表示读过并核对了这篇论文 $\triangle$ 。**vibemathed.com 的条目也写着 "No independent mathematician has checked this yet" [R]。
- 一个有利因素 (我的判断)：这篇只有 13 页，用的都是标准工具，附录 A 还把需要的对偶定理特例完整证了一遍。它是整个 openai/math 发布里**最可能在几周内被人类专家完整读懂的头条结果之一**。

6.9.5 剩余风险

1. 自定义的计算模型：我读过，认为它忠实 (§6.9.1)。但这是"一个人读一遍"的程度。
2. 没有第二内核复查。
3. 第三方不动点库的正确性：Lean 内核会检查它的证明，风险主要在定义层面，很低。
4. 正确性之外的风险：结论正确但人类还没理解"为什么这条路以前没人走通"。

6.10 如果为真，意味着什么（以及不意味着什么）

6.10.1 对数学和理论计算机

1. **35 年来最大的单步推进**：从 2.3712 到 2.25，降幅是此前 12 年总和的约 70 倍（脚本实算：0.121 vs 0.0017）。
2. **绕开了激光法壁垒** (§6.6.3)，证明 Strassen 的渐近谱路线是可行的，而且可以用得很"初等"。
3. 所有复杂度写成 n^ω 的算法 (§6.3.3) 的理论上界一起下降。
4. **$\omega = 2$ 是不是更近了？** 这是推测。这个方法的瓶颈在哪里（ $4/3$ 这个增长率是不是方法本身的极限）、能不能推到 2，论文没讨论 Δ 。
5. **只针对复数域**（以及经由论文 Remark 5.2 的代数系数论证）。正特征的域上，OpenAI 只声称了 2.371054886。

6.10.2 对 GPU 和 LLM 训练：没有直接影响

这是工程师最容易误会的地方，所以说得具体一点：

1. **我们连 Strassen 都很少用。** §6.2.2 的表显示，算上加法，纯 Strassen 要到 $n \approx 1024$ 才在运算次数上赢。在真实硬件上还有：(a) 额外的块加法需要额外的显存读写，访存模式也不规整，而 GEMM 的瓶颈经常是显存带宽和 Tensor Core 吞吐；(b) Tensor Core 只加速"乘加"，块加法得不到加速；(c) 数值稳定性比朴素算法差（Higham 的教材有专门分析）。有研究在 CPU 上做出了实用的 Strassen 加速（Huang 等，"Strassen's Algorithm Reloaded", SC16），但主流深度学习库不用它。
2. **9/4 算法是"银河算法" (galactic algorithm)**：渐近更快，但只在大得离谱的输入上才赢。论文不给常数，所以下面只是**假设性**的计算（脚本实算）：如果 9/4 算法的常数是 C 、朴素算法是 $2n^3$ ，交叉点约为 $n \approx (C/2)^{4/3}$ 。 $C = 10^6$ 时 $n \approx 4 \times 10^7$ ，一个这样的 fp16 矩阵就要约 3×10^{15} 字节（3 PB）。而真实常数没人知道，而且 §6.8.4 说了，连基础分解的尺寸 u 都至少是 34、具体分解都不知道。
3. **激光法那些 2.37 的算法同样是银河算法。**所以这不是 9/4 特有的问题： **$\omega < 2.77$ 左右的所有结果，至今都没有一个在实践中用得上。**
4. **比较一下 AlphaTensor / AlphaEvolve**：AlphaTensor（Fawzi 等，*Nature* 610, 2022）[P] 和 AlphaEvolve（2025， 4×4 复矩阵 48 次乘法）[R] 找的是**固定小尺寸**的低秩分解。这种东西能直接写进内核，带来常数级的加速（AlphaTensor 论文里就针对具体 GPU 优化过分解）。 ω 关心的是 $n \rightarrow \infty$ 时的指数。两者几乎是两个不同的问题。Dupont 等（2026-08）用 AlphaEvolve 优化激光法里的参数，这是 AI 第一次参与刷新 ω 上界的纪录，但幅度只有 1.6×10^{-4} 。

6.10.3 对 AI

- 这是一种"新想法", 不是"更大的优化"。和 Dupont 等"用 AI 调参数挤出 1.6×10^{-4} "相比, 9/4 的证明换了一条路线, 而且最终论证短到可以手写。如果它经得住检验, 它是"AI 产生了人类 35 年没找到的数学思路"的最清楚的例子之一。
- 13 页 + 约 2 万行 Lean 的组合, 很适合做人类核验的试金石。和 §4 准黎曼猜想的 199 页 + 48 万行 Lean 不同, 这里人类专家完全可以独立读完。之后几周专家怎么评价, 是判断"整个 openai/math 发布可信度"的一个好信号。
- 规格审查比证明审查更关键 (§6.9.1): Lean 证明可信的前提是"计算模型写对了"。这正是 AI 安全里"spec gaming"问题在数学里的版本, 而这里的审查只需要读 100 行定义。

6.11 自测题

读完后试着回答。如果答不上来, 回到对应小节再读一遍。

1. 为什么 Strassen 的 7 次乘法公式可以递归使用? 关键是它没用到哪条性质? (§6.2.2)
2. "一个秩 r 的张量分解"和"一个用 r 次乘法的算法"是什么关系? (§6.4.3)
3. 多项式乘法张量 $C(a, b)$ 的秩为什么是 $a + b - 1$? 它和 Karatsuba 有什么关系? (§6.4.5)
4. 张量特征要满足哪四条性质? 为什么每个特征都 $\leq$ 秩? (§6.7.2)
5. 激光法和渐近谱路线, 哪个是"构造", 哪个是"测量"? 为什么后者能绕开已知壁垒? (§6.6.3、§6.7.4)
6. OpenAI 证明的最后一步, 是哪两个不等式夹出了 $t \leq 3/4$? (§6.8.2 第 5 步)
7. 在 Lean 里, 为什么" slnf 空集 = 0"会构成规格风险? 这里是怎么排除的? (§6.9.1)
8. 为什么 $\omega \leq 9/4$ 不会让你的 GPU 训练更快? 至少说出三个原因。(§6.10.2)

附:【检查】答案

- 检查 1: $M_2 + M_4 = (c+d)e + d(g-e) = ce + de + dg - de = ce + dg \checkmark$ 。
- 检查 2: $\omega \leq \log_4 46 \approx 2.7618$ (脚本实算)。比 Strassen 的 2.8074 好, 但远不如激光法的 2.37。
- 检查 3: 在 $t = 0$ 求值: $P_0 = x_0 y_0$; $t = 1$: $P_1 = (x_0 + x_1)(y_0 + y_1)$; $t = -1$: $P_2 = (x_0 - x_1)(y_0 - y_1)$ 。乘积多项式是 $c_0 + c_1 t + c_2 t^2$, 所以 $P_1 = c_0 + c_1 + c_2$, $P_2 = c_0 - c_1 + c_2$ 。于是 $c_0 = P_0$, $c_1 = (P_1 - P_2)/2$, $c_2 = (P_1 + P_2)/2 - P_0$ 。除以 2 是乘常数, 不算"变量 $\times$ 变量"的乘法。
- 检查 4: $(0, 1, 1)$ 的 y 下标 1 在中段, 权重 +1; z 下标 1 在左段 $\{0, 1\}$, 权重 0。总权重 +1 > 0 , 所以在 $\varepsilon \rightarrow 0$ 时消失。

附: 术语表

术语

一句话解释

ω (矩阵乘法指数)

$n \times n$ 矩阵乘法所需算术运算次数的最优指数, $2 \leq \omega \leq 3$

术语	一句话解释
双线性算法	每次乘法都是"A 元素的线性组合 × B 元素的线性组合"的算法
张量	三维数组；这里等价于一个三线性形式 $\sum c \cdot x \cdot y \cdot z$
腿 (leg)	张量的三组变量 x 、 y 、 z 之一
张量的秩	最少能写成几个秩 1 项之和，等于双线性算法的最少乘法次数
边界秩	允许用含 ε 的表达式逼近时的最小秩
退化 (degeneration)	给变量配 ε 的幂次权重，只保留最低权重项
限制 (restriction)	对三条腿做线性代换得到另一个张量； $A \geq B$ 表示"会算 A 就会算 B"
完全直和	三条腿上变量都互不共享的若干张量之和
激光法	从某个低秩张量的高次幂里切出大量独立矩阵乘法的方法 (Strassen 1986)
渐近谱 / 张量特征	满足归一、可加、可乘、单调的"测量函数"全体；Strassen 证明它们决定了渐近复杂度
展平秩	把张量摊成矩阵后的秩，是最简单的张量特征
银河算法	渐近更快，但只在大得不现实的输入上才赢的算法
直线程序	没有循环和分支的运算序列；Lean 形式化用它建模算法

附：想继续深入

- **原始论文** (13 页，可以通读)： <https://github.com/openai/math/blob/main/preprints/Matrix-Multiplication-Nine-Fourths-October-2-2026/paper.pdf>
- **Lean 陈述** (约 100 行，建议亲自读一遍定义)：
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/MatrixMultiplication.lean>
- **独立 Lean 复查**： <https://github.com/erenciracioglu-dotcom/openai-math-9-4-lean-check>
- **Quanta Magazine**, *New Breakthrough Brings Matrix Multiplication Closer to Ideal* (2024-03-07)：Duan-Wu-Zhou 那一步的通俗报道，有激光法的直观图。
<https://www.quantamagazine.org/new-breakthrough-brings-matrix-multiplication-closer-to-ideal-20240307/>
- **Markus Bläser**, *Fast Matrix Multiplication* (Theory of Computing Graduate Surveys 5, 2013)：最好的入门综述，免费。 <https://theoryofcomputing.org/articles/gs005/>
- **J. M. Landsberg**, *The complexity of matrix multiplication: developments since 2014* (arXiv 1811.11667)：偏几何视角的综述。
- **Bürgisser, Clausen, Shokrollahi**, *Algebraic Complexity Theory* (Springer 1997)：第 14–15 章讲张量秩、激光法和渐近谱，是标准教材。
- **Christandl, Vrana, Zuiddam**, *Universal points in the asymptotic spectrum of tensors* (JAMS 36, 2023; arXiv 1709.07851)：§6.7"已知的特征长什么样"。

- **Ambainis, Filmus, Le Gall**, 激光法壁垒 (STOC 2015): <https://arxiv.org/abs/1411.5414>
- **Alman 等**, *More Asymmetry Yields Faster Matrix Multiplication* (SODA 2025): <https://arxiv.org/abs/2404.16349>
- **Dupont 等**, *Improving the matrix multiplication exponent with modern optimization and AlphaEvolve* (2026-08): <https://arxiv.org/abs/2608.16884>
- **Fawzi 等**, *Discovering faster matrix multiplication algorithms with reinforcement learning* (AlphaTensor, *Nature* 610, 2022)
- **Huang, Smith, Henry, van de Geijn**, *Strassen's Algorithm Reloaded* (SC16): Strassen 在真实硬件上什么时候值得用。
- **Scott Aaronson**, *The Mathocalypse* (2026-10-07): <https://scottaaronson.blog/?p=10169>
- **3Blue1Brown**, *Linear transformations and matrices* (YouTube, Essence of Linear Algebra 第 3–4 集): 如果想先把"矩阵乘法 = 线性变换的复合"的直觉补牢。

理论计算机 · FAMILY 102

7. 唯一博弈猜想 (Unique Games): 近似算法的"天花板"在哪

前提只需要: 知道什么是图(点和边)、会算模运算 ($7 \bmod 3 = 1$)、知道"多项式时间"大致是"随规模温和增长"、对 P vs NP 有个模糊印象。凡是用到的新概念都会先讲。文中所有数字都由脚本实算(脚本: `精讲/scripts/04_ugc.py`) 或有出处;【检查】是可以自己动手算的小练习, 答案在章末。 $\triangle$ = 我没能完全核实。预计阅读时间: 60–90 分钟。可以分三次读: §7.1–7.4 (NP 难、近似、0.878、PCP)、§7.5–7.7 (什么是 unique game、为什么重要、24 年的拉锯)、§7.8–7.10 (OpenAI 的结果、核实、意义)。

7.0 先说结论: 这一章要讲明白的一件事

很多重要的优化问题(把网络切成两半、选最少的哨兵看住所有路……)被认为**没有快速的精确算法**。退而求其次, 我们问: **快速算法最多能保证做到最优解的百分之几?**

对其中最经典的 Max-Cut 问题, 1995 年有人给出一个能保证 **87.8%** 的算法。另一边, 1997–2001 年有人证明保证 **94.1%** 以上是 NP 难的。中间这 6 个百分点, 30 年没人知道真相在哪里。

这一章要讲清楚的是一条因果链:

近似能做到多好 $\Leftarrow$ 由"区分几乎能满足和远远不能满足"有多难决定 $\Leftarrow$ 最关键的一种约束系统叫 Unique Games $\Leftarrow$ 唯一博弈猜想 (UGC) 说: 这种区分是 NP 难的。

如果 UGC 成立, 那么 87.8% 就**恰好**是 Max-Cut 的极限, 而且同一个论证能一次性确定一大类问题的近似极限。Khot 在 2002 年提出它, 24 年来没人能证明或推翻。OpenAI 声称证明了

它，并附上了 Lean 形式化证明。

读完这一章，你应该能用自己的话讲出：

- 为什么"完全能满足"的 unique game 很容易，而"几乎能满足"的被猜想是难的；
- UGC 和 0.878 这个数之间具体是什么关系；
- OpenAI 的结果如果为真，意味着什么，以及它**不**意味着什么（它和 P vs NP 无关）。

7.1 P vs NP 与 NP 难：5 分钟版

7.1.1 "容易验证"不等于"容易找到"

数独：给你一个填好的盘面，检查对不对只需要几秒；从空盘面开始填，却可能要试很久。

- **P**：能在多项式时间（比如 n^2 、 n^3 步）**找到**答案的问题。
- **NP**：给你一个候选答案，能在多项式时间**验证**它对不对的问题。

P vs NP 问的是：凡是容易验证的，是否都容易找到？几乎所有人相信 **$P \neq NP$** ，但没人证明（Clay 千禧年难题之一）。

7.1.2 归约与 NP 难

归约：把问题 A 的任何实例，快速地翻译成问题 B 的实例，使得 B 的答案就是 A 的答案。如果能这样做，"B 有快速算法"就推出"A 有快速算法"，所以 B 至少和 A 一样难。

3SAT：给一堆形如 " $(x_1 \text{ 或 非 } x_2 \text{ 或 } x_3)$ " 的条款，每个条款 3 个变量，问能不能给变量赋真/假，使所有条款同时成立。Cook-Levin 定理（1971）说：NP 里的每个问题都能归约到 3SAT。

NP 难：如果 3SAT 能归约到问题 B，就说 B 是 NP 难的。意思是：**除非 $P = NP$ ，否则 B 没有多项式时间算法。**

这一章所有"X 是 NP 难的"都要读成"除非 $P = NP$ ，否则 X 做不到"。它们都**不**证明 $P \neq NP$ ，只是把 X 的命运和 P vs NP 绑在一起。

7.2 退而求其次：近似算法

7.2.1 Max-Cut

给一张图，把顶点分成两组（比如涂成黑和白），一条边如果两端颜色不同就算"被切"。**Max-Cut** 问：最多能切多少条边？判断"能否切到 $\geq k$ 条"是 Karp 1972 年列出的 21 个 NP 完全问题之一。

脚本实算（暴力枚举所有涂色）：

图	边数	最大切	随机涂色期望切	随机 / 最优
三角形	3	2	1.5	0.750
5-环（五边形）	5	4	2.5	0.625
Petersen 图	15	12	7.5	0.625

三角形为什么最多切 2 条：三个点只有两种颜色，必有两个点同色，它们之间那条边切不到。

7.2.2 近似比和"随便做就有 1/2"

一个 α -近似算法：多项式时间内，总能给出至少" $\alpha \times$ 最优值"的解。

随机涂色：每个点独立地抛硬币决定颜色。一条边两端颜色不同的概率是 1/2，所以期望切到"边数的一半"。因为最优值不可能超过边数，随机涂色至少是 **1/2-近似**。

1/2 这个数从 1976 年（Sahni–Gonzalez）起一直是最好的保证，直到 1995 年。

【检查 1】一张 4-环（正方形，4 条边）的最大切是几？随机涂色期望切几条？

7.2.3 另一个主角：顶点覆盖（Vertex Cover）

在图里选最少的点，使每条边至少有一个端点被选中（想象在路口放哨兵，看住所有路）。

一个 1970 年代就有的简单算法：反复找一条两端都没选的边，**把两端都选上**。最优解至少要是选这条边的一端，而我们选了两端，所以最多是最优的 **2 倍**。这就是 **2-近似**。

50 年来，没人能做到"1.99 倍"。

7.3 Goemans–Williamson：把顶点变成向量

7.3.1 松弛：先解一个更宽松的问题

Max-Cut 难在每个点只能取两个值（黑 = +1，白 = -1）。一条边 (i, j) 被切，当且仅当 $x_i \cdot x_j = -1$ ，所以切到的边数 = $\sum (1 - x_i x_j) / 2$ 。

Goemans–Williamson（1995）的想法：**把每个 ± 1 换成一个单位向量 v_i** ，把乘积 $x_i x_j$ 换成内积 $v_i \cdot v_j$ ：

最大化 $\sum_{\text{边}} (1 - v_i \cdot v_j) / 2$ 约束：每个 v_i 都是长度为 1 的向量

这叫**半定规划（SDP）**，可以在多项式时间内（近似地）解出来。因为 ± 1 是"一维单位向量"，原问题的每个解都是它的解，所以 **SDP 的最优值 $\geq$ 真正的最大切**。直觉上：边的两端被推得越"相反"（夹角越接近 180°）越好。

7.3.2 随机超平面：把向量变回黑白

解出向量以后，随机选一个过原点的平面，把空间劈成两半：在一侧的点涂黑，另一侧涂白。

关键事实：**两个夹角为 θ 的向量，被随机平面分开的概率恰好是 θ/π** 。二维里最好想：随机一条过原点的直线，落在两向量"之间"的概率就是 $\theta/180^\circ$ 。

脚本用 100 万次随机平面验证：

夹角	理论 θ/π	模拟
90°	0.5000	0.4994
120°	0.6667	0.6659
150°	0.8333	0.8337

7.3.3 0.878 是怎么来的

对每条边比较两个量：

- SDP 给它的"分数"： $(1 - \cos \theta)/2$ ；
- 取整后它真正被切的概率： θ/π 。

只要对**每个**夹角，后者都至少是前者的 α 倍，整张图就至少是 SDP 值的 α 倍，也就至少是最优值的 α 倍。所以保证 = 这个比值在所有夹角上的最小值：

$$\alpha_{\text{GW}} = \min \text{ over } \theta \text{ of } (\theta/\pi) / ((1 - \cos \theta)/2) = \min 2\theta / (\pi(1 - \cos \theta))$$

脚本实算（数值最小化）：

夹角 θ	SDP 分数	被切概率	比值
60°	0.250	0.333	1.333
90°	0.500	0.500	1.000
120°	0.750	0.667	0.889
133.56°	0.845	0.742	0.8786 (最小)
150°	0.933	0.833	0.893
180°	1.000	1.000	1.000

$\alpha_{\text{GW}} = 0.878567...$ ，在 $\theta \approx 133.56^\circ$ （内积 $\rho \approx -0.689$ ）处取到。这个数和 OpenAI 的 Max-Cut 论文式 (1.1) 给出的 0.878567... 一致。

7.3.4 一个例子：五边形

5-环的 SDP 最优解是把 5 个向量在平面上每隔 $144^\circ (= 4\pi/5)$ 摆一个。脚本实算：

- $\text{SDP 值} = 5 \times (1 - \cos 144^\circ)/2 = 4.5225$;
- 真正的最大切 = 4;
- 随机平面期望切 $5 \times 144/180 = 4.000$ 。

所以在五边形上 SDP 值比真实最优高了一截 ($4/4.5225 = 0.8845$)。这种"SDP 过于乐观"的差距叫**整性间隙** (integrality gap)。Feige–Schechtman (2002) 构造了让这个比值无限逼近 0.878 的图, 所以**单靠这个 SDP 加任何取整方法都不可能超过 0.878**。但这只说明"这一个算法"到头了, 不说明"所有算法"到头了。

7.4 近似也可能是难的: PCP 定理

7.4.1 PCP 定理的直觉

PCP 定理 (Arora–Safra; Arora–Lund–Motwani–Sudan–Szegedy, 1992 年会议, 1998 年期刊; Dinur 2007 给了组合证明) 说的事情听起来像魔术:

任何数学证明都可以改写成一种特殊格式, 使得审稿人**只随机抽看其中常数个比特**, 就能以很高把握判断证明对不对: 正确的证明一定通过; 错误的证明, 无论怎么写, 都会以至少一半的概率被抓住。

7.4.2 为什么它和"近似"有关

把 PCP 换个说法: 存在一个从 3SAT 出发的归约, 得到一个约束系统, 满足

- 原公式可满足 $\Rightarrow$ 约束系统**全部**能满足;
- 原公式不可满足 $\Rightarrow$ 约束系统**最多**满足一个固定比例 $s < 1$ 。

这叫**间隙** (gap)。现在假如有一个算法能保证 $\alpha > s$ 的近似比, 就能拿它区分这两种情况, 也就能解 3SAT。所以: **有间隙 $\Rightarrow$ 近似到间隙之上是 NP 难的**。

接下来几十年的游戏, 就是把这个间隙做得越来越"尖锐", 让它恰好卡在已知算法的位置上。

7.4.3 Max-Cut 的缺口

Håstad (2001, JACM) 加上 Trevisan–Sorkin–Sudan–Williamson 的"小部件", 证明: **Max-Cut 近似到 $16/17 \approx 0.941$ 以上是 NP 难的**。


于是:



0.878 和 0.941 之间是谁? 更好的算法, 还是更强的难度证明? 这就是 UGC 要回答的。

下图上半部分是同一条数轴；下半部分是§7.5–7.7 要讲的 unique games "完备度阶梯"（2018 年证明到约 $1/2$ ，UGC 要的是 $1 - \epsilon$ ），可以先扫一眼，读完§7.7 再回来看。

Max-Cut 的近似比：多项式时间能保证切到"最优值的多少倍"？



Unique Games 的"完备度"阶梯：能证明 NP 难的是哪种实例？

$\approx 1/2$ 完备度
2-to-2 定理 2018



$1-\epsilon$ 完备度 = UGC
OpenAI 2026-09 声称 + Lean

完全可满足（完备度 = 1）的实例
沿边传播就能多项式时间解，
所以难点只在"几乎可满足"

来源：Goemans–Williamson, JACM 1995；Håstad, JACM 2001；Khot, STOC 2002；Khot–Kindler–Mossel–O'Donnell, SICOMP 2007；Khot–Minzer–Safra, FOCS 2018。

顶点覆盖也有类似的缺口：算法是 2，NP 难的下界是 Dinur–Safra（2005, *Annals*）的 **1.3606**，2018 年提高到 $\sqrt{2} \approx 1.414$ （Khot–Minzer–Safra，见§7.7.2）。

7.5 Unique Games 是什么

7.5.1 标签游戏

一个**标签约束系统**：

- 一张图；
- 一个"字母表"：每个顶点要从 $\{0, 1, \dots, k-1\}$ 里选一个标签；
- 每条边带一个约束，规定两端的标签怎样才算"相容"。

目标：选标签，使满足的约束比例（叫这个实例的**值**）尽量高。

PCP 定理的标准产物"Label Cover"就是这种形式，只是约束是"多对一"的：一端定了，另一端有好几个选择。

7.5.2 "唯一"：一端定了，另一端唯一确定

Unique Game：每条边的约束是一个**置换**（一一对应）。一端选了某个标签，另一端**恰好只有一个**标签能满足这条边。

最常见、也是这一章用的例子：**模 k 的差分方程**

$$x_i - x_j \equiv c \pmod{k}$$

给定 x_j , x_i 就被唯一确定为 $x_j + c$ 。(OpenAI 论文用的是"平移约束" $a(v) = a(u) + c$, 只是把模 k 的数换成了 0/1 向量的按位异或, 本质一样。)

7.5.3 手算：三角形，模 3

三个变量 a, b, c , 标签 $\{0, 1, 2\}$:

实例 A: $b - a \equiv 1, c - b \equiv 1, a - c \equiv 1 \pmod{3}$ 。绕一圈相加: $0 \equiv 3 \equiv 0$, 没有矛盾。取 $a = 0$, 传播得 $b = 1, c = 2$, 检查 $a - c = -2 \equiv 1 \checkmark$ 。**全部满足, 值 = 1。**

实例 B: 把最后一条改成 $a - c \equiv 2$ 。绕一圈相加: $0 \equiv 1 + 1 + 2 = 4 \equiv 1$, 矛盾。所以三条不可能同时成立, 但去掉任何一条就能满足。**值 = 2/3。**(脚本暴力枚举 27 种标签确认。)

一般规律: 在一个环上, 把约束常数绕一圈加起来, 如果不是 $0 \pmod{k}$, 这个环上至少有一条约束必然被违反。

【检查 2】四个变量 $x_0 \dots x_3$, 模 5, 约束: $x_1 - x_0 \equiv 2, x_2 - x_1 \equiv 3, x_3 - x_2 \equiv 1, x_0 - x_3 \equiv 4, x_2 - x_0 \equiv 0$ 。全部能满足吗? 如果把最后一条改成 $x_2 - x_0 \equiv 1$ 呢?

7.5.4 为什么"完全能满足"的很容易

如果一个 unique game 能被**全部**满足, 有一个简单的多项式时间算法:

1. 在每个连通块里任选一个点, 试它的 k 个标签之一;
2. 沿着边传播: 每条边都唯一决定邻居的标签;
3. 遇到矛盾就换下一个起始标签; k 个都试过还不行, 就说明不能全部满足。

每次尝试只要扫一遍图, 总共 k 次。对比一下暴力枚举: 100 个变量、模 3, 要试 $3^{100} \approx 10^{47.7}$ 种 (脚本实算)。

这和 3SAT 完全不同: 3SAT 就算"全部能满足"也很难找到解。**所以 UGC 不能谈"可满足 vs 不可满足", 只能谈"几乎可满足 vs 远远不可满足"。**这就是 UGC 里 $1 - \epsilon$ 的由来。

7.5.5 为什么"几乎能满足"可能很难

一旦有少量约束是"错的", 传播就会把错误带到很远。脚本做了一个实验: 2000 个点、每点平均 6 条边的随机图, 模 7; 先埋一个标准答案, 再随机篡改一部分约束; 然后从随机起点用传播法 (广度优先) 定标签, 试 20 个起点:

篡改比例	埋入答案的值	传播法平均值	传播法最好值
0%	1.000	1.000	1.000
1%	0.990	0.958	0.982

篡改比例	埋入答案的值	传播法平均值	传播法最好值
5%	0.947	0.728	0.845
10%	0.901	0.610	0.709

(脚本实算；随机图里有极少数孤立点，标签默认取 0，对结论无影响。)

原因：一个点的标签是沿一条路径从起点"传"过来的，路径上只要经过一条坏边，后面整片都会错位。

要诚实地说明：这个实验只说明"传播法"不行，不说明问题本身难。对这种**随机**的带噪实例，更聪明的算法（比如 SDP）其实能做得很好。UGC 说的是：**存在**一些精心构造的实例，任何多项式时间算法都分不清"它是 99% 可满足"还是"它只有 1% 可满足"。

7.5.6 UGC 的精确陈述

唯一博弈猜想 (Khot 2002)：对任意 $\epsilon > 0$ 和 $\delta > 0$ ，都存在一个字母表大小 k ，使得对字母表为 k 的 unique game，区分下面两种情况是 NP 难的：

- YES：值 $\geq 1 - \epsilon$ （几乎全部能满足）；
- NO：值 $\leq \delta$ （几乎全部不能满足）。

注意**量词顺序**：先给定 ϵ 、 δ ，**再**选字母表大小 k 。如果反过来允许 k 随实例增长，就有已知的算法能解（Charikar–Makarychev–Makarychev 2006 的 SDP 算法能拿到约 $1 - O(\sqrt{\epsilon \log k})$ ， k 小时就很好）。OpenAI 论文第 1.2 节专门讨论了这一点。

7.6 为什么 UGC 重要：一个猜想管一大片

UGC 的魅力在于：假设它成立，很多问题的**精确**近似极限就能被算出来，而且往往**恰好等于某个已知算法**。

问题	最好的算法	无条件 NP 难（2026 年前）	假设 UGC
Max-Cut	0.878 (GW 1995)	$16/17 \approx 0.941$ (Håstad 2001)	0.878 就是极限 (KKMO 2004/07)
顶点覆盖	2	$\sqrt{2} \approx 1.414$ (KMS 2018)	2 就是极限 (Khot–Regev 2003/08)
所有约束满足问题 (CSP)	基本 SDP + 取整	各不相同	基本 SDP 就是最优算法 (Raghavendra 2008)

几个关键结果：

- **KKMO** (Khot–Kindler–Mossel–O'Donnell, FOCS 2004, SICOMP 2007)：UGC $\Rightarrow$ Max-Cut 超过 α_{GW} 是 NP 难的。他们需要一个概率论命题"多数最稳定" (Majority Is Stablest) 后

来由 Mossel–O'Donnell–Oleszkiewicz (2005, *Annals* 2010) 证明。GW 算法里那个奇怪的 133.56° 夹角，恰好对应难度归约里的"噪声"参数，算法和难度在同一个数上相遇。

- **Khot–Regev** (CCC 2003, *JCSS* 2008): $\text{UGC} \Rightarrow$ 顶点覆盖做不到 $2 - \epsilon$ 。那个 1970 年代"选两端"的笨算法就是最优的。
- **Raghavendra** (STOC 2008): $\text{UGC} \Rightarrow$ 对**每一个** CSP，同一个通用的 SDP 算法就是最优的多项式时间近似算法。一个算法加一个猜想，决定了一整类问题。

这就是为什么 UGC 被说成"近似算法领域的地图"。Khot 因此获得 2014 年 Nevanlinna 奖。

7.7 24 年的拉锯：支持与怀疑

7.7.1 怀疑：亚指数时间算法 (2010)

Arora–Barak–Steurer (FOCS 2010, *JACM* 2015) 给出一个算法：对字母表为 k 、 n 个变量、值 $\geq 1 - \epsilon^c$ 的 unique game (c 是某个固定常数)，能在 $\exp(k \cdot n^\epsilon)$ 时间内找到满足 $1 - \epsilon$ 的标签。

这为什么让人怀疑 UGC? 因为一般相信 3SAT 需要接近 2^n 的时间，而 UG 只需要 2 的" n 的小次方"。脚本实算对比：

n	3^n (暴力)	$2^{(n^{0.1})}$	$2^{(n^{1/3})}$	n^3
100	$10^{47.7}$	3	$10^{1.4}$	10^6
1,000	10^{477}	4.0	$10^{3.0}$	10^9
1,000,000	10^{477121}	15.8	$10^{30.1}$	10^{18}

如果 UGC 成立，从 3SAT 到 UG 的归约必须把实例**放大**到很大的多项式规模（否则 3SAT 也会有亚指数算法）。这不矛盾，但说明 UG 即使难，也"难得不彻底"。一部分研究者因此倾向于相信 UGC 是假的。

7.7.2 支持：2-to-2 定理 (2018)

2-to-2 约束：比 unique 宽松一点，一端定了，另一端有 2 个可选标签。Khot–Minzer–Safra 及 Dinur–Khot–Kindler–Minzer–Safra 在 2017–2018 年的一系列工作（最后一块是 KMS FOCS 2018 关于 Grassmann 图扩张性的定理）证明：**几乎可满足的 2-to-2 游戏是 NP 难的。**

推论：

- **完备度约 $1/2$** 的 unique game 是 NP 难的：区分"值 $\geq 1/2 - \epsilon$ "和"值 $\leq \delta$ "。被称为"半个 UGC"。
- 顶点覆盖 $\sqrt{2} - \epsilon$ 是 NP 难的。

剩下的难点：把完备度从 $1/2$ 推到 $1 - \epsilon$ 。OpenAI 论文第 1.3 节也说："Obtaining Unique Games completeness arbitrarily close to one was a separate problem."

7.7.3 2026 年 9 月：一场赛跑

据 Quanta (2026-10-07) 报道，MIT 的 Dor Minzer 和学生 Yumou Fei、Shuo Wang 听到 OpenAI 即将发布 UGC 证明的传闻后，在 2026-09-14 抢先贴出了 Khot 2-to-1 猜想的一个 4-to-1 变体的证明。O'Donnell 评价："They solved the problem in the old-fashioned way, with their minds, and wrote it with their own fingers." [R]

7.8 OpenAI 声称了什么

7.8.1 主结果

论文 *The Unique Games Theorem* (2026-09-23, 58 页, 作者署名 "OpenAI") 的摘要：

"We prove the Unique Games Conjecture. For every fixed $\epsilon, \delta \in (0, 1/2)$, we give a deterministic polynomial-time reduction from 3SAT to Unique Games over a fixed finite alphabet, with completeness at least $1 - \epsilon$ and soundness at most δ ." [P]

翻译：对任何固定的 ϵ, δ ，有一个确定性的多项式时间归约，把 3SAT 翻译成字母表固定的 **unique game**：可满足的公式变成值 $\geq 1 - \epsilon$ 的实例，不可满足的变成值 $\leq \delta$ 的实例。这正是 §7.5.6 UGC 的陈述。

定理 1.1 还说了更强的形式：字母表是 0/1 向量空间 F_2^s ，每条约束都是平移；图是简单、二部、无权的。论文说这是 UGC 的一个已知等价形式 (引用 KKMO)，所以"更强"不是"偷换"。

7.8.2 同一家族 (family 102) 的其他论文

论文	页数	结论
A Direct Proof of Optimal Max-Cut Hardness	38	Max-Cut 超过 α_{GW} 是 NP 难的
The Factor-Two Hardness Threshold for Vertex Cover	25	顶点覆盖做不到任何 < 2 的常数倍
Constant-factor hardness of Min-UnCut	—	任意常数倍都是 NP 难的
Constant-factor hardness of directed feedback vertex set	—	任意常数倍都是 NP 难的

仓库 CONTENTS.md 说这 4 篇是**独立的直接归约**，"use established PCP and Label Cover hardness results"，不依赖 UGC 论文。也就是说，就算 UGC 那篇有错，Max-Cut 0.878 和顶点覆盖 2 这两个最有名的推论还有一条独立的路。复杂性理论学者 Dana Moshkovitz 的评论 (Aaronson 在 "The Mathocalypse" 评论 #2 里转贴，开头写明 "Additional commentary from Dana on the UGC proof") 说："The Unique Games Conjecture is true, though it wasn't really needed for the proof of its most famous corollaries"，括号里举的例子是 Max-Cut 和其他约束满足问题的最优近似难度 [R]。指的就是这 4 篇直接归约。

另外, **family 105** (*Perfect completeness for 2-to-1 games*) 声称证明了 Khot 的 2-to-1 猜想 (完美完备度版本)。UGC 论文脚注 1 说它"不是本证明的输入"。

7.8.3 方法的直觉 (只读了引言, 以下是简化版)

1. **起点**: Håstad 的"几乎可满足的奇偶方程组"难度结果 (每个方程 $x + y + z \equiv b \pmod{2}$)。
2. **2-to-2 那条路为什么卡在 1/2**: Barak–Kothari–Steurer 的"矩阵短码"里, 诚实的证明在一次随机的秩一扰动下, 答案保持不变的概率是 $(1 + 2^{-(\ell)})/2$, 也就是约 1/2。所以完备度只能做到 1/2。
3. **关键的新想法: 换一种噪声**。论文构造了一个非线性的"编码器" C 和一种特殊噪声 μ : 诚实答案在这种噪声下几乎不变 (变化概率 $\leq$ 任意小的 p), 但任何"作弊"的、高秩的线性观察仍然以至少 1/8 的概率察觉到噪声。可以类比成: 设计一种抖动, 让正确的读数几乎不受影响, 却能让伪造的读数露馅。这样完备度就能推到 $1 - \varepsilon$, 同时保留 2-to-2 那套用于可靠性的结构工具。
4. **可靠性 (不可满足的公式值 $\leq \delta$)**: 沿用 KMS 2018 的 Grassmann 扩张定理 (以"逆短码定理"的形式) 提取出一个策略, 再用并行重复 (Dinur–Steurer 2014) 把成功率压到 $\exp(-c \cdot k^{1/3})$, 从而推出矛盾。
5. **收尾**: 去掉权重和重复边, 得到简单、无权、二部的实例。

7.9 它被核实到什么程度

7.9.1 Lean 陈述: 比准黎曼猜想长得多, 但仍然可读

准黎曼猜想 (§4) 的 Lean 陈述只有一行, 因为 Mathlib 里已经有 ζ 函数。UGC 不同: Mathlib 里**没有** "unique game"、"3SAT 编码" 或 "多项式时间归约到图" 的现成定义, 所以挑战文件 `ComparatorChallenges/UniqueGamesTheorem.lean` (239 行) 要自己把这些都定义出来。核心定理 (完整名字 `OAI.UniqueGamesTheorem.theorem11`; 以下是我读 Lean 源码后的翻译 [P]):

```
theorem theorem11 (ε δ : ℝ)
  (hε : 0 < ε) (hεhalf : ε < 1 / 2)
  (hδ : 0 < δ) (hδhalf : δ < 1 / 2) :
  Nonempty (Explicit.MachineOutputContract.BinaryGapReduction ε δ)
```

逐词翻译:

- `(ε δ : ℝ)`: ε 和 δ 是实数。
- `hε`、`hδ`: 假设 $0 < \varepsilon < 1/2$, $0 < \delta < 1/2$ 。
- `Nonempty (BinaryGapReduction ε δ)`: 结论是"存在一个满足下面所有条件的归约"。

`BinaryGapReduction ε δ` 是一个结构体, 要求同时给出:

字段	意思
<code>alphabet</code> 、 <code>dimension</code> 、 <code>coordinates</code>	字母表大小 $k \geq 2$ ，并且等同于 F_2^* (0/1 向量)
<code>construct : List Bool → Instance alphabet</code>	输入一串比特 (3SAT 公式的编码)，输出一个 unique game
<code>simpleBipartite</code>	输出的图是简单二部图
<code>translations</code>	每条约束都是平移 $a(v) = a(u) + c$
<code>computation : Turing.TM2ComputableInPolyTime</code> ...	<code>construct</code> 能被 Mathlib 里的多带图灵机在多项式时间内算出
<code>finiteAlphabet</code>	图灵机的带字母表有限
<code>completeness</code>	输入是可满足公式 $\Rightarrow$ 存在标签，满足比例 $\geq 1 - \epsilon$
<code>soundness</code>	输入不是可满足公式 $\Rightarrow$ 所有标签，满足比例 $\leq \delta$

几个值得注意的细节：

- 置换用"正表 + 逆表 + 两条互逆证明"表示，所以确实是一一对应。
- 重复边按出现次数计数，没有隐藏权重。
- 输入串如果根本解析不出公式，算作"不可满足"，归约也必须输出值 $\leq \delta$ 的实例。这是更苛刻的要求，不是放水。
- 限制 $\epsilon, \delta < 1/2$ 不影响结论：UGC 关心的正是小的 ϵ, δ 。
- 完备度写成 $\geq 1 - \epsilon$ 而不是 $= 1$ ，这是对的：§7.5.4 说过，完全可满足的情况是容易的。

我的判断：这是 UGC 的忠实编码，而且是更强的形式。 一个需要读者自己补的外部事实：定理说的是"从 3SAT 归约过来"，"所以是 NP 难的"还需要 Cook-Levin 定理 (3SAT 是 NP 完全的)，这一步不在这个陈述里，但它是教科书结果，没有争议。

7.9.2 证明本身

- 解答目录 `OAI/Computability/UniqueGames/`：478 个 Lean 文件、186,782 行（脚本实数）。
- `grep` `sorry`、`axiom`、`admit`、`native_decide`、`implemented_by`、`unsafe`：0 命中。Comparator 配置只允许三条标准公理 (`propext`、`Quot.sound`、`Classical.choice`)。
- 证明里除了 Mathlib，不导入仓库里其他目录的东西。由于 Mathlib 里没有 PCP 定理，PCP 定理、Håstad 的结果、KMS 的 Grassmann 扩张定理、并行重复、图灵机的多项式时间实现应该都在这 478 个文件里从头形式化了。子目录名 (`PCP/` 104 个文件、`Inverse/` 39 个文件里有 `KMS...`、`Repetition/`、`Machines/` 144 个文件) 和这个判断一致。△ 这是从目录结构和导入关系推断的，我没有逐个打开核对。

- Max-Cut 和顶点覆盖的直接证明也有 Lean: `MaxCut/` 372 个文件、186,763 行; `VertexCover/` 354 个文件、66,335 行。Max-Cut 陈述里 α_{GW} 直接定义为 `sInf` of $2 \cdot \arccos \rho / (\pi(1 - \rho))$, 就是 §7.3.3 那个公式 ($\arccos \rho = \theta$)。
- **没做的事**: 我没有编译。UGC 这一族的 Comparator 配置 `enable_nanoda: false`, 也就是没有开启第二个独立内核复检。和准黎曼猜想 (§4) 不同, 我没找到任何第三方公开复跑过这个证明 $\triangle$ 。仓库 `formalization.yaml` 自己写着 `review: status: unchecked`。

7.9.3 人类专家

- Lance Fortnow (博客 "Open No More", 2026-10-07): "if they hold up, we've seen more progress in TCS in the last 24 hours than in the previous three decades combined." [R]
- Mark Braverman (Princeton, Quanta 2026-10-07): "Math by press release is not that healthy for math." [R]
- Quanta 的报道说这篇证明 "didn't undergo any human editing or review by independent experts"。[R]
- Dana Moshkovitz (复杂性理论学者, Aaronson 的妻子) 的看法是经 Aaronson 博客转贴的私下短信和评论, 不是正式评审 [R]。正文里她说: "Basically the paper is so horribly written that it's impossible to read it without AI help"; 评论 #2 里又说 "the writeup is poorly written"。她对方法的描述是 "The UGC proof invents a completely new bizarre code with a noise test" (对应 §7.8.3 第 3 步那个新的编码器和噪声)。后来 Aaronson 在评论 #94 说 "Dana tells me she now mostly understands the proof of the UGC"。Implicator 等媒体的二手转述措辞不一 $\triangle$, 以 Aaronson 博客原文为准。
- Khot 本人: 截至 2026-10-08 我没找到公开表态 $\triangle$ 。
- **截至 2026-10-08, 没有任何人类专家公开表示读完并核对了这 58 页论文。**

7.9.4 剩余风险

1. **陈述层面**: 我逐行读过, 没发现问题, 但我不是复杂性理论专家。最值得专家复查的是 `TM2ComputableInPolyTime` 的用法 (输入、输出编码是否合理, 多项式是否真的和输入无关), 以及 3SAT 编码有没有让问题变简单的漏洞。
2. **编译层面**: 依赖第三方或自己复跑。没有 nanoda 复检。
3. **理解层面**: 这和 §4 准黎曼猜想是同一个局面。机器意义上可能已经证明了, 但没人能讲清楚 "为什么那种非线性噪声能行"。论文写得很难读, 这会拖慢人类理解。

7.10 如果为真, 意味着什么 (以及不意味着什么)

7.10.1 对理论计算机科学

1. **一大批条件性结论变成定理**: Max-Cut 的 0.878、顶点覆盖的 2、Raghavendra 的 "SDP 对所有 CSP 最优" 等。过去 20 年写着 "假设 UGC, 则....." 的数以百计的论文, 前提被拿掉了。

2. **近似算法的地图基本画完了**：对很多问题，"能做到"和"做不到"之间的缺口闭合了。GW 1995 年的算法被证明是最优的。
3. **亚指数算法不再是反例**：UGC 为真和 ABS 的 $\exp(n^\epsilon)$ 算法并存。这意味着 3SAT 到 UG 的归约必然产生规模极大的多项式（论文说多项式的次数和常数只依赖 ϵ 、 δ ，但没给具体数）。

7.10.2 它不意味着什么

- **不解决 P vs NP**。所有结论都是"X 是 NP 难的"，也就是"除非 $P = NP$ ，否则 X 做不到"。如果明天有人证明 $P = NP$ ，这些难度结论全部作废。Fortnow 在同一篇博客里也说这些结果没有让我们更接近解决 P vs NP [R]。
- **不影响实际工程**。工业界做图划分、聚类用的是启发式算法，在真实数据上往往远好于最坏情况的 0.878。UGC 说的是**最坏情况下的保证**。
- **不推翻任何已知算法**。它只证明"已有的算法不能再改进了"。

7.10.3 对 AI

- 这是 OpenAI 这批结果里**最接近 AI 研究者日常**的一个：它的核心对象（SDP 松弛、随机取整、PCP 风格的验证）都是计算机科学的基本工具。
- 一个联想（**我的推测，不是已有结论**）：辩论式可扩展监督（Irving-Christiano-Amodei 2018, arXiv:1805.00899）的复杂性理论底子交互式证明和 PCP："一个弱验证者能否只看少量信息，就判断强证明者的论证"。UGC 刻画的是"有一点点噪声就无法高效区分"的边界。对"弱监督者 + 强模型"的协议设计来说，它提示**完美一致**和**几乎一致**之间可能存在本质的计算难度差异。
- 和 §4 准黎曼猜想一样，这里出现了"58 页难读的论文 + 18.7 万行 Lean"的组合。信任的瓶颈从"证明对不对"转移到了"**陈述有没有编码对**"，这正是 §7.9.1 在做的规格审查（spec review）。

7.11 自测题

读完后试着回答。如果答不上来，回到对应小节再读一遍。

1. "X 是 NP 难的"这句话，准确地说是什么意思？它证明了 $P \neq NP$ 吗？ (§7.1.2)
2. 为什么随机涂色至少是 $1/2$ -近似？ (§7.2.2)
3. GW 算法里，0.878 是哪两个量的比值在什么时候取到的最小值？ (§7.3.3)
4. PCP 定理里的"间隙"为什么能推出近似难度？ (§7.4.2)
5. 为什么完全能满足的 unique game 可以多项式时间解，而 3SAT 不行？ (§7.5.4)
6. UGC 里"先给 ϵ 、 δ ，再选字母表大小"的顺序为什么重要？ (§7.5.6)
7. 2-to-2 定理已经证明了什么，还差什么？ (§7.7.2)
8. Lean 陈述里 `soundness` 字段说的是啥？如果输入串根本不是合法的公式编码，会怎样？ (§7.9.1)
9. 为什么说即使 UGC 那篇论文有错，Max-Cut 0.878 的最优性也可能仍然成立？ (§7.8.2)

附：【检查】答案

- **检查 1**：4-环是二部图，黑白交替涂，4 条边全切，最大切 = 4。随机涂色期望切 $4 \times 1/2 = 2$ 条。
- **检查 2**：前四条构成环 $x_0 \rightarrow x_1 \rightarrow x_2 \rightarrow x_3 \rightarrow x_0$ ，常数和 $2 + 3 + 1 + 4 = 10 \equiv 0 \pmod{5}$ ，没有矛盾。第五条 $x_2 - x_0 \equiv 0$ ：沿环 $x_2 - x_0 = 2 + 3 = 5 \equiv 0 \checkmark$ 。所以全部能满足，例如 $(x_0, x_1, x_2, x_3) = (0, 2, 0, 1)$ 。改成 $x_2 - x_0 \equiv 1$ 后，环 $x_0 \rightarrow x_1 \rightarrow x_2 \rightarrow x_0$ 的和是 $2 + 3 - 1 = 4 \not\equiv 0$ ，至少违反一条，最多满足 4/5（脚本暴力枚举 625 种标签确认）。

附：术语表

术语	一句话解释
P / NP	能快速找到答案的问题 / 能快速验证答案的问题
归约	把问题 A 快速翻译成问题 B，使 B 的快速算法能解 A
NP 难	3SAT 能归约到它；除非 $P = NP$ ，否则没有多项式时间算法
3SAT	每个条款 3 个变量的布尔可满足性问题
Max-Cut	把顶点分两组，让跨组的边最多
顶点覆盖	选最少的点，覆盖所有边
α -近似	多项式时间内总能达到最优值的 α 倍
半定规划（SDP）	把 ± 1 变量放松成单位向量的优化问题，可多项式时间求解
随机超平面取整	随机切一刀，把向量变回黑白
α_{GW}	0.878567..., GW 算法的保证
整性间隙	松弛的最优值和真实最优值之间的比值差距
PCP 定理	证明可以改写成只需随机抽查常数个比特就能验证的形式
间隙	YES 实例值 $\geq c$ ，NO 实例值 $\leq s$ ， $c > s$
完备度 / 可靠性	YES 情况能满足的比例 / NO 情况最多能满足的比例
Label Cover	PCP 定理的标准产物，每条边有"多对一"约束的标签问题
Unique Game	每条边约束是置换（一端定了另一端唯一）的标签问题
UGC	区分值 $\geq 1 - \epsilon$ 和 $\leq \delta$ 的 unique game 是 NP 难的
2-to-2 定理	2018 年证明的"半个 UGC"（完备度约 1/2）
亚指数时间	比任何 $2^{(n^c)}$ ($c > 0$ 固定) 都快，比多项式慢

附：想继续深入

- **Ryan O'Donnell**, *Analysis of Boolean Functions* (剑桥大学出版社, 2014; 免费在线版 <https://analysisofbooleanfunctions.net/>) : 第 7 章讲 PCP 和 Håstad, 第 11 章讲"多数最稳定"和 KKMO。是理解 UGC 难度证明最好的教材。△ 章节号凭记忆, 以目录为准。
- **Williamson & Shmoys**, *The Design of Approximation Algorithms* (剑桥, 2011; 免费 PDF <http://www.designofapproxalgs.com/>) : 第 6 章讲 GW 算法, 第 16 章讲近似难度和 UGC。△ 章节号凭记忆。
- **Subhash Khot**, "On the Unique Games Conjecture" (综述, CCC 2010) : 提出者本人的综述。 <https://cs.nyu.edu/~khot/papers/UGCSurvey.pdf>
- **Erica Klarreich**, "Approximately Hard: The Unique Games Conjecture" (Simons Foundation, 2011) : 面向大众的科普。
- **Quanta**, "As AI Closed In on 'Unique Games' Proof, Researchers Raced to Beat the Machines" (2026-10-07) : <https://www.quantamagazine.org/as-ai-closed-in-on-unique-games-proof-researchers-raced-to-beat-the-machines-20261007/>
- **Lance Fortnow**, "Open No More" (2026-10-07) : <https://blog.computationalcomplexity.org/>
- **Scott Aaronson**, "The Mathocalypse" (2026-10-07) : <https://scottaaronson.blog/?p=10169>
- 经典原始文献: Goemans–Williamson, *JACM* 42 (1995); Håstad, *JACM* 48 (2001); Khot, STOC 2002; KKMO, *SICOMP* 37 (2007); Khot–Regev, *JCSS* 74 (2008); Raghavendra, STOC 2008; Arora–Barak–Steurer, FOCS 2010 / *JACM* 62 (2015); Khot–Minzer–Safra, FOCS 2018。
- 原始论文: <https://github.com/openai/math/blob/main/preprints/The-Unique-Games-Theorem-September-23-2026/paper.pdf>
- Max-Cut 直接证明: <https://github.com/openai/math/blob/main/preprints/A-Direct-Proof-of-Optimal-Max-Cut-Hardness-September-23-2026/paper.pdf>
- Lean 陈述: <https://github.com/openai/math/blob/main/lean/ComparatorChallenges/UniqueGamesTheorem.lean>

理论计算机 · FAMILY 103 (+ 109)

8. $L = RL = BPL$ (小内存计算里, 随机性没有用)

前提只需要这些: 知道 $\log_2$ 是什么, 知道"算法的运行时间随输入规模 n 增长"这种说法, 见过矩阵乘法。新概念都会先讲再用。文中所有数字都由脚本实算或有出处 (脚本: `精讲/scripts/05_bpl_toy.py`、`05_bpl_spec.py`, numpy 实现)。【检查】是可以自己动手算

的小练习，答案在章末。标记：**[已确立]** = 发表过、有同行评审的结果；**[OpenAI 声称]** = openai/math 仓库里的手稿；**[推测]** = 我的判断；**[P]** = 读过一手材料（论文、仓库文件或 Lean 源码）；**[R]** = 二手报道（博客、新闻）；**△** = 我没能完全核实，或来源之间有冲突。预计阅读时间：60–90 分钟。可以分三次读：§8.1–8.3（内存复杂度和随机性）、§8.4–8.6（随机游走、Reingold、去随机化史）、§8.7–8.9（OpenAI 的结果、核实状态和意义，最后附同一批里的整数乘法结果）。

8.0 先说结论：这一章要讲明白的一件事

设想一台内存极小的机器：输入可以随便读，但工作内存只够存**几个指针**。这台机器如果能掷硬币，能不能解决更多问题？

这一章要讲清楚下面这条因果链：

小内存机器的整个计算 $\iff$ 一张"配置图"上的随机游走 $\iff$ 接受概率 = 一个大矩阵的幂次之和 $\implies$ 去随机化 = 用很少的内存把这个概率算准 $\implies$ 难点在于"算准"需要的精度和递归层数会把内存吃掉。

L 是确定性小内存计算能解决的问题，**BPL** 是"小内存 + 掷硬币 + 允许小概率出错"能解决的问题。几乎所有人都相信 $L = BPL$ ，但 1999 年以来最好的无条件结果只到"**BPL** 能用 $(\log n)^{1.5}$ 的内存确定性模拟"，离 $\log n$ 一直差一个 $\sqrt{\log n}$ 的因子。

OpenAI 声称把这个差距完全消掉了： **$L = RL = BPL$** 。这个结论本身从来没有多少人怀疑，难的是证明。它有 Lean 形式化，但截至 2026-10-08，没有人类专家公开说自己读完并核对了这篇 108 页的论文。

读完这一章，你应该能用自己的话讲出：

- 为什么" $O(\log n)$ 比特内存"大约等于"能存常数个指针"，以及为什么这样的机器一定在多项式时间内停机；
- 随机游走为什么能用极小的内存解决无向图连通性，又为什么同样的办法在有向图上会失效；
- "种子长度"为什么是这个领域的核心指标，Nisan 的 $\log^2 n$ 和目标 $\log n$ 之间差在哪里；
- OpenAI 的结论如果为真，意味着什么、**不意味着什么**（不意味着 $P = BPP$ ，也不意味着 $L = NL$ ）。

8.1 空间复杂度：内存是一种资源

8.1.1 时间和空间

衡量算法有两把尺子：

- **时间**：走了多少步。
- **空间**：同一时刻最多占用多少比特的**工作内存**。

这里有个关键约定：**输入不算在空间里**。输入放在一条"只读带"上，机器可以来回读，但不能写。只有"工作带"（可读可写的草稿纸）计入空间。这样才能讨论"比输入还小的内存"。

工程上的类比是**流式处理加随机访问**：数据放在一块只读的大盘上，你可以 seek 到任何位置去读，但本地 RAM 只有几十个字节。

8.1.2 对数空间 L：能存常数个指针

L (logspace) = 确定性机器、工作内存 $O(\log n)$ 比特就能判定的问题。

为什么是 $\log n$? 因为一个能指向输入中任意位置的指针，需要 $\lceil \log_2 n \rceil$ 比特。 $O(\log n)$ 比特就是"常数个指针或计数器"。

输入长度 n	$\log_2 n$ (一个指针)	$(\log_2 n)^{1.5}$	$(\log_2 n)^2$
10^3	10	31	99
10^6	20	89	397
10^9	30	163	894
10^{12}	40	252	1,589

(脚本实算，单位是比特。) 输入有 10^9 字节时，L 允许的内存只有几十到几百比特，相当于几个寄存器。 $(\log n)^2$ 和 $(\log n)^{1.5}$ 这两列后面会反复出现，它们是去随机化历史上的两个里程碑。

【检查 1】输入是 10^9 个顶点的图。存一个顶点编号需要几个比特？存"当前顶点 + 目标顶点 + 一个步数计数器（最多数到 n^3 ）"一共大约几个比特？

8.1.3 一个重要事实：对数空间的确定性机器一定在多项式时间内停机

机器在某一时刻的全部状态叫**配置** (configuration)：控制状态 + 各个读写头的位置 + 工作带的内容。工作带只有 $c \cdot \log n$ 比特，所以内容最多有 $2^{(c \cdot \log n)} = n^c$ 种；读头位置有 n 种；控制状态是常数种。所以**配置总数是 n 的多项式**。

一台确定性机器如果停机，就不可能把同一个配置经历两次（否则会死循环）。所以它的步数不超过配置数，也就是多项式时间。

这个"配置数是多项式"的事实是整章的基石。 后面所有内容都可以看成在一张多项式大小的"配置图"上做事。

8.2 随机性能买到什么

8.2.1 例子：多项式恒等式检验

给你两个用公式写出的多项式，问它们是否恒等。比如 $(x+y)^2$ 和 $x^2 + 2xy + y^2$ 。

这个例子手动展开就能判断。难的情况是：多项式写成一个很紧凑的公式或电路，展开后会有指数多项（比如一个 $n \times n$ 行列式，展开后有 $n!$ 项）。这时候**确定性的**快速算法至今未知，这就是 **PIT 问题**（polynomial identity testing）。[已确立]

随机算法很简单：**随机代入几个数，看两边是否相等。**

- 如果恒等，代什么都相等。
- 如果不恒等，两边的差是一个非零多项式，它的根很少。Schwartz–Zippel 引理说：从大小为 $|S|$ 的集合里随机取值，一个 d 次非零多项式取到 0 的概率 $\leq d/|S|$ 。[已确立]

手算例子：错误的"恒等式" $(x+y)^2 = x^2 + y^2$ 。两边的差是 $2xy$ ，是 2 次多项式。 x 和 y 都从 $\{0, \dots, 99\}$ 中随机取，共 10,000 种组合。

【检查 2】有多少种组合会让两边恰好相等（也就是"骗过"随机检验）？

脚本实算：199 种，占 1.99%。Schwartz–Zippel 的上界是 $d/|S| = 2/100 = 2\%$ ，吻合。随机代一次，被骗的概率不到 2%；独立代 10 次，被骗的概率不到 $2\%^{10} \approx 10^{-17}$ 。

8.2.2 P 和 BPP

- **P**：确定性多项式时间能解决的问题。
- **BPP**：多项式时间 + 随机比特，每个输入上出错概率 $\leq 1/3$ 的问题。

1/3 这个数不重要，因为可以**放大**：独立跑 k 次，取多数票。

重复次数 k	多数票出错概率（单次正确率 2/3）	计数器需要的比特
1	3.3×10^{-1}	1
11	1.2×10^{-1}	4
51	6.9×10^{-3}	6
101	2.7×10^{-4}	7
201	5.5×10^{-7}	8

（脚本实算，二项分布尾部求和。）注意最后一列：放大只需要一个计数器，**对小内存机器同样可用**。这是 BPL 的定义里阈值取 2/3 还是 0.51 都无所谓的原因。

主流猜想是 $P = BPP$ ，也就是随机性不带来本质提升。证据很强：Impagliazzo–Wigderson 1997 证明了，只要某些问题需要指数大小的电路（一个大家普遍相信的"难度假设"），就有 $P = BPP$ 。[已确立] 但**无条件**证明 $P = BPP$ 被认为极难：Kabanets–Impagliazzo 2004 证明了，哪怕只是把 PIT 去随机化，也会推出一些我们目前完全证不出来的电路下界。[已确立]

这就是"难度换随机性"（hardness vs. randomness）的框架：**去随机化和证明下界几乎是同一件事**。时间版本被这道墙挡住了。空间版本没有已知的同类障碍，所以 $L = BPL$ 一直被看

作"最有希望无条件证出来的去随机化猜想"。

8.3 RL 和 BPL: 小内存 + 掷硬币

8.3.1 定义

机器多了一个能力: 每一步可以拿到一枚新的公平硬币。限制是:

- 工作内存 $O(\log n)$ 比特;
- 对**所有**硬币序列, 都在多项式时间内停机;
- **硬币是一次性的**: 读完就没了, 想再用必须自己存到工作带上, 而工作带只有 $\log n$ 比特。

最后一条很关键。时间版的 BPP 可以把随机串存下来反复读, 小内存机器不行。它只能"边掷边用", 像一个在线的、单遍的流。

两种出错方式:

- **RL** (单边错): 答案是"否"时一定拒绝; 答案是"是"时至少以 $1/2$ 概率接受。
- **BPL** (双边错): 答案是"是"时至少以 $2/3$ 概率接受; 答案是"否"时至多以 $1/3$ 概率接受。

已知的包含关系 [已确立]:

$L \subseteq RL \subseteq BPL \subseteq L^{(3/2)}$ (Saks-Zhou 1999)
 $RL \subseteq NL \subseteq L^2$ (Savitch 1970)

NL 是"非确定性"对数空间 (机器可以"猜")。有向图的可达性是 NL 的代表问题。

8.3.2 整个计算 = 一张图上的随机游走

用§8.1.3 的事实: 随机机器在输入 x 上的所有配置是多项式多个。把每个配置画成一个点; 如果从配置 u 掷一枚硬币能走到配置 v , 就从 u 向 v 连一条边, 权重 $1/2$ 。

于是**机器在 x 上的运行** = 在这张配置图上从起点出发的随机游走; **接受概率** = 游走在时限内到达"接受"配置的概率。

手算例子: 一个只有 3 个状态的玩具机器, 每步掷一枚硬币:

- 状态 0: 正面去 0, 反面去 1
- 状态 1: 正面去 2, 反面去 0
- 状态 2: 吸收 (一直留在 2), 代表"接受"

写成转移矩阵 T , 从 $v = (1, 0, 0)$ 开始, 每走一步就算 $v \leftarrow vT$:

步数	P(在 0)	P(在 1)	P(在 2)
1	0.5	0.5	0
2	0.5	0.25	0.25
3	0.375	0.25	0.375
4	0.3125	0.1875	0.5

(脚本实算；另外把 $2^4 = 16$ 种硬币序列全部穷举了一遍，恰好 8 种走到状态 2，和矩阵算出的 0.5 一致。)

【检查 3】只用手算，验证第 2 步的分布 (0.5, 0.25, 0.25)。

这就把问题变成了线性代数：**接受概率 = 转移矩阵的若干次幂作用在起始向量上**。OpenAI 论文开头也是这样做的：它把机器转成一个矩阵 S ，接受概率是 $(I - S)^{-1}e$ 的一个分量，等价于 $\sum_j S^j e$ (§8.7.2)。

8.3.3 为什么"直接算"不在 L 里

既然只是矩阵幂，确定性地算出来不就行了？问题是**内存**：

- 矩阵是 $n^c \times n^c$ 的，存不下，只能需要哪一项就现算哪一项。
- 用"反复平方"求 T^t 时， T^t 的每一项依赖 $T^{t/2}$ 的项， $T^{t/2}$ 的每一项又依赖 $T^{t/4}$ 的项.....递归有 $\log t \approx O(\log n)$ 层，每一层都要记住自己算到哪了 ($O(\log n)$ 比特)，再加上数值精度的位数。
- 总空间 $\approx$ 层数 $\times$ 每层 $= O(\log n) \times O(\log n) = O(\log^2 n)$ 。

这就是 Borodin–Cook–Pippenger 1983 证明的"随机对数空间 $\subseteq$ 确定性 $\log^2$ 空间"背后的直觉，和 Savitch 定理的"递归栈"是同一个结构。[已确立] **整个领域 40 年的工作，就是想把这个"层数 $\times$ 每层"压下去。**

8.4 无向图连通性：随机游走的经典胜利

8.4.1 问题

USTCON (undirected s-t connectivity)：给一张无向图和两个点 s 、 t ，问它们是否连通。

用 BFS/DFS 很容易，但需要一个"已访问"数组，占 n 比特。只有 $O(\log n)$ 比特时怎么办？

8.4.2 随机游走算法 (AKLLR 1979)

Aleliunas、Karp、Lipton、Lovász、Rackoff 在 1979 年给出了一个极简的算法 [已确立]：

```

v ← s
重复 N 步：
    如果 v = t, 回答"连通"
```

$v \leftarrow v$ 的一个随机邻居
回答"不连通"

只需要记"当前顶点 v "和"步数计数器", $O(\log n)$ 比特。如果 s 、 t 不连通, 它永远不会走到 t , 所以**不会把"否"说成"是"**; 如果连通, 只要 N 足够大, 就能高概率走到。这正好是 RL 的单边错形式。

他们证明的关键界: 在连通图上, 随机游走访问遍所有顶点的期望步数 (**覆盖时间**, cover time) $\leq 2|E|(n-1)$, 其中 $|E|$ 是边数。由于 $|E| \leq n^2$, 所以 $\leq n^3$ 量级。取 $N = 4n^3$, 用马尔可夫不等式就能把失败概率压到 $1/2$ 以下。

8.4.3 脚本实测

小例子: 6 个顶点, 边是 0-1、0-2、1-2、2-3、3-4、4-5 (一个三角形接一条尾巴)。从 0 走到 5。

一次实际模拟的轨迹 (脚本, 随机种子 1):

```
0 1 0 2 0 2 1 2 3 4 3 2 1 0 2 1 0 2 1 0 1 2 0 1 0 1 2 3 2 1 0 1 2 1 0 2 0 1 2 1 0 2 3 2
0 2 0 2 3 4 3 4 5
```

走了 52 步。它在三角形里绕了很久, 因为从 2 出发只有 $1/3$ 的概率往尾巴走, 走到 3 后又有 $1/2$ 的概率退回来。

20,000 次模拟的平均: 从 0 到 5 约 29.1 步, 覆盖全图约 30.4 步。上界 $2|E|(n-1) = 2 \cdot 6 \cdot 5 = 60$, 实测在界内。

几类图的命中时间:

图	n	实测 / 精确的期望步数	对照
路径 (从一端到另一端)	10	81.7 (模拟)	精确值 $(n-1)^2 = 81$
路径	40	1,523.7 (模拟)	$(n-1)^2 = 1,521$
"棒棒糖" ($n/2$ 个点的完全图 + $n/2$ 个点的尾巴)	40	8,019 (解线性方程组, 精确)	$n^3 = 64,000$, 比值 0.125
棒棒糖	80	64,039 (精确)	$n^3 = 512,000$, 比值 0.125

(脚本实算。)棒棒糖图是随机游走最糟的情形: 游走在完全图里打转, 很少进入尾巴, 进入后又容易退回来。Brightwell-Winkler 1990 证明了 n 个点的图上最大命中时间约为 $(4/27)n^3 \approx 0.148n^3$ (团占 $2/3$ 时取到)。[已确立, $\triangle$ 常数凭文献记忆, 未打开原文核对] 我们的"各占一半"版本是 $0.125n^3$, 同一量级。所以 **n^3 步一般够用, 也基本不能更少。**

8.4.4 为什么同样的办法在有向图上失败

考虑一张有向图：顶点 $0, 1, \dots, n$ ，从 i 出发有两条边，一条到 $i+1$ ，一条回到 0 。目标是 n 。

从 0 出发的随机游走要连续 n 次都选"前进"才能到达，期望步数是 $2^{(n+1)} - 2$ ：

n	期望步数（精确解线性方程组）
5	62
10	2,046
20	2,097,150
30	2,147,483,646

（脚本实算，与公式完全吻合。）**指数级**。所以随机游走解决不了有向图可达性。有向可达性是 NL 完全的，它是否在 L 里（ $L = NL?$ ）至今开放，**与本章的结果无关**。

【检查 4】对 $n = 2$ 手算这个期望值。提示：记 h_i 为从 i 出发到达 n 的期望步数， $h_n = 0$ ， $h_i = 1 + \frac{1}{2}h_{i+1} + \frac{1}{2}h_0$ 。

无向图为什么好：无向边可以原路返回，随机游走不会被"单向陷阱"困住。线性代数上，无向图的转移矩阵是对称的（经过归一化后），它的特征值都是实数，"混合"速度由谱间隙控制，这是§8.5 的主角。

8.5 Reingold 2005：无向连通性在 L 里（ $SL = L$ ）

8.5.1 历史

AKLLR 之后，大家想去掉 USTCON 的随机性：

- Nisan–Szemerédi–Wigderson 1992： $O(\log^{1.5} n)$ 空间 [已确立]
- Armoni–Ta–Shma–Wigderson–Zhou 2000： $O(\log^{4/3} n)$ 空间 [已确立]
- **Reingold 2005**： $O(\log n)$ 空间，即 $USTCON \in L$ 。[已确立] STOC 2005, JACM 2008，获 Gödel 奖。

SL（symmetric logspace）是以 USTCON 为完全问题的类，所以这个结果也写成 **SL = L**。这是"拿掉一个具体问题的随机性"的里程碑，但只针对无向图这一种结构。

8.5.2 扩张图：连通得"非常好"的图

扩张图（expander）是度数很小（每个点只连常数条边）却连通得极好的图：任何一小块顶点集合，都有很多边连到外面。

衡量方式是**谱间隙**：随机游走转移矩阵的最大特征值是 1，第二大特征值 λ_2 ，间隙 $= 1 - \lambda_2$ 。间隙越大，随机游走越快"忘掉"起点。大致上，混合需要的步数 $\propto (\log n) / \text{间隙}$ 。

n	环（每点度 2）的间隙	1/间隙	随机 4-正则图的间隙	1/间隙
64	0.00482	208	0.162	6.2
256	0.00030	3,320	0.138	7.2
1024	0.00002	53,122	0.134	7.4

（脚本实算，numpy 求特征值；随机 4-正则图用两个随机置换的并构造。）环的间隙按 $1/n^2$ 掉到 0，随机 4-正则图的间隙稳定在常数（理论最优值 $1 - 2\sqrt{3}/4 \approx 0.134$ ，即 Ramanujan 界，实测已经贴着它了）。

扩张图的直径只有 $O(\log n)$ 。 所以如果图是常数度的扩张图，可以穷举所有长度为 $O(\log n)$ 的路径：每一步只有常数种选择，一条路径用 $O(\log n)$ 比特就能描述，总共 $d^{O(\log n)} = \text{多项式条}$ 。一个计数器挨个试即可，不需要随机性。

8.5.3 Reingold 的想法：把任意图"改造"成扩张图

难点是输入的图不一定是扩张图。Reingold 用两种操作反复改造它（每个连通分量分别改造）：

1. **平方（powering）**：新图里，两点相邻当且仅当原图里它们之间有长度为 2 的路径。谱间隙大约翻倍（ λ_2 变成 λ_2^2 ），代价是度数平方。
2. **zig-zag 积**（Reingold–Vadhan–Wigderson 2000）：用一个小的固定扩张图"替换"每个顶点，把度数降回常数，间隙只损失一个常数因子。[已确立]

交替做 $O(\log n)$ 轮，间隙从 $1/\text{poly}(n)$ 增长到常数。

为什么不吃内存：改造后的图**从不显式存储**。要查"新图里顶点 v 的第 i 个邻居"，就递归地向上一层图发查询。关键是 zig-zag 的设计让每一层只多花**常数**比特（而不是 $\log n$ 比特）。
 $O(\log n)$ 层 $\times$ $O(1)$ 比特 = $O(\log n)$ 。

对照§8.3.3："层数 $\times$ 每层"里，Reingold 把"每层"从 $\log n$ 压到了常数。工程类比：多层虚拟地址翻译，每一层只需记几个比特的偏移，而不是一个完整地址。

局限：zig-zag 和平方都依赖图的对称性（无向）。一般 BPL 计算的配置图是有向的，Reingold–Trevisan–Vadhan 2006 把它推广到了"正则^{有向}图"等特殊情形，但没有覆盖一般情形。[已确立]

8.6 一般 BPL 的去随机化：27 年卡在 $3/2$ 附近

8.6.1 伪随机生成器和"种子长度"

一个最朴素的去随机化办法：**把所有随机串都试一遍，数一数接受的比例**。BPL 机器读 $\text{poly}(n)$ 个随机比特，有 $2^{\text{poly}(n)}$ 种随机串，太多了。

伪随机生成器（PRG）的想法：用一个短的**种子**（seed）生成一长串"看起来随机"的比特。"看起来随机"是相对于某一类观察者说的：对任何一台小内存机器，用伪随机串和用真随机串得到的接受概率几乎相同。

有了种子长度为 s 的 PRG，去随机化就是：枚举全部 2^s 个种子，每个跑一遍，统计。需要的空间约为 $s + O(\log n)$ 。

种子长度	需要枚举的种子数	去随机化的结果
$\text{poly}(n)$ （真随机）	$2^{\text{poly}(n)}$	无用
$O(\log^2 n)$ （Nisan 1992）	$n^{O(\log n)}$ （拟多项式）	$\text{BPL} \subseteq L^2$
$O(\log n)$ （梦想）	$\text{poly}(n)$	$L = \text{BPL}$

所以**整个问题可以归结为：对小内存机器，能不能造出种子长度 $O(\log n)$ 的 PRG？** 这个问题 30 多年没有解决。

8.6.2 Nisan 的生成器（1992）：为什么是 $\log^2$

Nisan 的核心观察是：小内存机器记不住自己用过哪些随机比特，所以可以安全地"复用"。[已确立]

构造方式（简化）：

- 种子 = 一个 $O(\log n)$ 比特的随机串 x ，加上 k 个随机哈希函数 $h_1, \dots, h_k$ ，每个 $O(\log n)$ 比特。
- 第 1 层：输出 $x, h_1(x)$ 。
- 第 2 层：输出 $x, h_1(x), h_2(x), h_2(h_1(x))$ 。
- 每加一层，输出长度翻倍。

直觉：机器读完前半段后，它的状态只有 $O(\log n)$ 比特，几乎"忘了"前半段的具体内容；所以后半段用"前半段过一次哈希"代替，机器察觉不到。

要输出 $\text{poly}(n)$ 个比特，需要 $k = O(\log n)$ 层，每层一个 $O(\log n)$ 比特的哈希函数，种子总长 $O(\log n) \times O(\log n) = O(\log^2 n)$ 。又是"层数 $\times$ 每层"。

Nisan 1994 又证明了这个模拟可以同时做到多项式时间和 $O(\log^2 n)$ 空间 ($\text{BPL} \subseteq \text{SC}$)。[已确立]（注：Borodin–Cook–Pippenger 1983 已经用矩阵方法得到了 $\log^2$ 空间，但没有多项式时间。）

8.6.3 Saks–Zhou 1999：3/2

Saks 和 Zhou 把 Nisan 的 $\log n$ 层切成 $\sqrt{\log n}$ 段，每段 $\sqrt{\log n}$ 层。每段用 Nisan 的方法近似算出一个矩阵幂，然后把结果的低位**随机地舍入**掉。这样每段的结果几乎不依赖具体用了哪组

哈希函数，于是**所有段可以共用同一组哈希函数**。[已确立；这里的描述是大幅简化，△ 细节请看原文]

空间：一组哈希函数 $\sqrt{\log n} \times \log n$ ，加上递归 $\sqrt{\log n}$ 段 $\times$ 每段 $\log n$ ，合计 **$O(\log^{1.5} n)$** 。

8.6.4 之后的进展和停滞

年份	结果	确定性空间
1983	Borodin–Cook–Pippenger	$\log^2 n$
1992	Nisan PRG	$\log^2 n$
1999	Saks–Zhou	$\log^{1.5} n$
2021	Hoza（加权伪随机性）	$\log^{1.5} n / \sqrt{(\log \log n)}$
2026	OpenAI（声称）	$\log n$

（Hoza 的界据 OpenAI 论文 §1.1 引用的 [19, Theorem 1.6 and Corollary A.5] 和我的记忆；本 deck 作者的研究笔记里原先标了 △，这次核对了论文的引用，两者一致。）

Hoza 2021 只省下了 $\sqrt{(\log \log n)}$ ，对 $n = 10^9$ 也就是省掉约 2.2 倍。一般 BPL 的指数在 3/2 附近卡了 27 年。

中间还发现了很多"特殊结构"上的胜利：Reingold（无向图）、Reingold–Trevisan–Vadhan（正则定向图）、Ahmadinejad 等（Eulerian 图上高精度地算随机游走概率）、Cohen–Doron–Sberlo–Ta-Shma（长随机矩阵乘积）。[已确立] 另外，Cheng–Hoza 2022 证明了：只要有一个对数空间可枚举的"命中集"（只保证找到一个接受的输入，比 PRG 弱），就能推出 $L = BPL$ 。[已确立] 这些都说明，问题的"形状"已经被摸得很清楚，就差最后一步。

8.7 OpenAI 声称了什么

8.7.1 主结果

论文 *Exact Derandomization of Logarithmic Space: $L = RL = BPL$* （2026-09-23，108 页，作者署名 "OpenAI"，仓库里的第 103 号结果族）[P]。摘要只有一句：

"We prove $L = RL = BPL$, resolving the derandomization problem for polynomial-time randomized logarithmic space."

翻译：每一个"多项式时间 + 对数空间 + 有界出错概率"的随机计算，都能用确定性对数空间模拟。

论文还给出一个**更强的定量版本**（定理 1.2）：对任何这样的随机机器 M 和输入 x ，可以确定性地把接受概率估计到 $2^{(-q)}$ 的精度，用 $O(\log n + q)$ 的空间和 $\text{poly}(n) \cdot 2^{O(q)}$ 的时间。 $q =$

$O(\log n)$ 时，就是任意多项式倒数的精度都能在对数空间里算出来。这比"判断概率是大于 $2/3$ 还是小于 $1/3$ "强得多，它连"没有间隙"的概率都能估计。

此外第 13 节给出一个**编译器**：输入一台随机机器的源程序和它的时间/空间界，输出一个确定性判定器和显式的资源界。

8.7.2 方法的直觉（我只读了论文的引言 §1–§2，以下是简化版）

1. **变成矩阵求逆**（论文 §2）。把机器在输入 x 上的配置图写成矩阵 S （每个配置带一个时间戳，边只指向更晚的时间，所以 S 是"严格向前"的、幂零的）。接受概率是 $p_0 = (I - S)^{-1}e$ 在起点处的值， e 标记接受配置。这和§8.3.2 的玩具例子是同一件事。
2. **"修正与副本层级"**（论文 §4）。作者用一串变换把 S 替换成新的矩阵 $C_1, C_2, \dots$ ，每一步把一部分转移概率"转移"到奖励向量里（利用恒等式 $I - D = (I + E)(I - C)$ ），同时复制一些顶点来分散大的矩阵项。经过 $O(\log n)$ 个阶段后，只要沿着一条"主副本"路径读出累计奖励，就能以多项式倒数的误差得到接受概率。
3. **只用 $O(\log n)$ 个随机比特估计**（论文 §5–§9）。这些矩阵不显式存储，而是用一个**共享的有限随机环境** σ （长度 $O(\log n)$ 的编码）做抽样估计。论文证明：在超过 $3/4$ 的 σ 上，估计值是准的；而且对**每一个** σ （包括估计不准的那些），估计过程都会在 $O(\log n)$ 空间内停机。
4. **枚举 + 取中位数**（论文 §12）。 σ 只有 $O(\log n)$ 比特，所以全部 σ 只有多项式个。挨个枚举，取中位数，和 $1/2$ 比较。这一步就是§8.6.1"枚举种子"的思路，只不过它不是造一个通用 PRG，而是针对这一个估计器把随机性压到了 $O(\log n)$ 比特。
5. **让递归不吃内存**（论文 §9–§11）。用短的**指纹**（多项式求值 + 仿射哈希）代替完整的顶点地址做比较；用一个共享的"催化"比特向量；用 Cook–McKenzie 的"沿轮廓遍历树"技巧找回入边，而不用栈。每个递归调用保留的数据被控制在 $A(w - w') + D(t - j)$ 比特以内，沿调用链**伸缩求和**（telescoping），总和是 $O(\log n)$ 。

把第 5 步和§8.3.3、§8.5.3 对照：它仍然是"层数 $\times$ 每层"的问题，解法是让每层花费的比特数和"递归预算的下降量"挂钩，整条调用链加起来不超过一个 $O(\log n)$ 的总预算。工程类比：一个递归调用栈，但每一帧的大小受一个全局配额约束，配额沿栈向下递减。

两个让我意外的细节：

- 论文 §6 的"条件平均"的混合界，依赖 Shalom 1999 关于 **Kazhdan 性质 (T)** 的结果（一个群论里的深刻性质）。[OpenAI 声称] 群论工具出现在小内存去随机化里，这在已有文献里不常见。[推测]
- "共享催化比特向量"让人想到近年的**催化计算**（catalytic computing）：借一块已经写满数据的内存来用，用完原样还回去。Cook–Mertz 用它把树求值问题的空间降到 $O(\log n \cdot \log \log n)$ ，Ryan Williams 2025 在此基础上证明了"时间 t 的计算可以用约 $\sqrt{t \log t}$ 空间模拟"。[已确立] 如果 OpenAI 的证明成立，催化技巧可能又一次是关键零件。[推测， $\triangle$ 没读到论文 §11 的细节]

8.8 它被核实到什么程度

8.8.1 Lean 陈述：你可以自己读懂

lean/ComparatorChallenges/LogspaceEquality.lean 的最后一行是 [P]:

```
theorem exact_logarithmic_space_derandomization :  
  L = RL ∧ RL = BPL
```

逐词翻译：

- `L = RL ∧ RL = BPL`：L 等于 RL，并且 RL 等于 BPL。

这一行太短了，真正的内容全在**定义**里。和准黎曼猜想 (§4) 不同，这里的 L、RL、BPL **不是** Mathlib 的标准定义（Mathlib 里没有这些复杂度类），而是 OpenAI 在挑战文件里自己写的。所以要审的是定义。下面是我逐条读的结果：

定义	它说了什么	是否符合教科书
<code>Machine q w h</code>	有限状态机，h 个只读输入头，w 条二进制工作带；每步读一个硬币 b	是，标准多带图灵机
<code>readInput</code>	输入两端有端标记	是
<code>step</code>	已输出（停机）的配置不再变化	是
<code>spaceThrough</code>	到时刻 t 为止，每条工作带访问过的不同格子数之和	是，而且比较严格（访问过的空白格也算）
<code>LogSpace</code>	存在 $c > 0$ ，对所有输入、所有硬币序列、所有时刻，空间 $\leq c \cdot \lceil \log_2(n+2) \rceil$	是
<code>Deterministic</code>	转移函数不依赖硬币	是
<code>acceptanceProbability</code>	在时钟 t 时， 2^t 种硬币串里停在"接受"的比例	是
<code>L</code>	确定性 + 对数空间 + 对每个输入都在某个时刻给出正确答案	是（没写时间界，但§8.1.3 说明确定性对数空间停机机器自动是多项式时间）
<code>RL</code>	对数空间 + 对所有硬币序列在 $c \cdot (n+2)^k$ 步内停机 + 是则概率 $\geq 1/2$ ，否则概率 = 0	是
<code>BPL</code>	同上，阈值 2/3 和 1/3	是

我的判断：符合标准定义。 一个值得注意的选择是"所有硬币序列都在多项式时间内停机"，这是标准的 BPL；如果去掉时间限制，得到的是另一个类（论文 §1.1 也专门强调了"空间界"和"同时的时空界"的区别）。这与作者研究笔记的结论一致。

8.8.2 Comparator 配置

`LogspaceEquality.json` 锁定了 20 个定义（从 `Word` 到 `BPL`，我数过）[P]：输入、语言和硬币带，读写头的移动，机器的初始配置、步进和运行，空间计数，对数空间、确定性、停机判定，接受概率，多项式时钟，以及 `L`、`RL`、`BPL` 本身。意思是解答文件不能偷偷换掉其中任何一个，比如把"空间"或"接受概率"改成一个更好证明的版本。允许的公理只有 Lean 的三条标准公理（`propext`、`Quot.sound`、`Classical.choice`）。

注意：这个配置里 `"enable_nanoda": false`，也就是没有要求用第二个独立内核复查。（整个仓库 416 个配置里只有 2 个开启了 nanoda，作者对仓库全部配置的统计。）

8.8.3 证明本身（我查到的，[P]）

- 解答目录 `lean/OAI/Computability/Logspace/`：39 个文件，约 4.3 万行（commit `fd4aeeb`，脚本 `wc -l` 实算）。
- `grep` `sorry | axiom | admit | native_decide | implemented_by | unsafe`：0 命中。
- 除了 `Mathlib` 之外，不从仓库里其他 `OAI.*` 目录导入任何东西。所以不存在"依赖库里藏着自定义代码"的问题，这一点比准黎曼猜想干净。
- 顶层证明只有三行： `$L \subseteq RL$` （平凡）， `$RL \subseteq BPL$` （平凡，放大一下）， `$BPL \subseteq L$` （全部难度都在这里）。
- 没做的事：**我没有编译它，也没有跑 Comparator。△ 我没有找到任何第三方针对这一族公开重跑 Comparator 的记录（准黎曼猜想 (§4) 有 Goldblatt 的独立复查，这一族没有）。
- 论文的编译器和显式运行时间界不在 Lean 陈述里。scope 文档 `lean/docs/103.md` 原话："The paper's explicit compiler and numerical running-time bounds are not separately stated in this Comparator target." 定理 1.2（任意精度估计）也没有被形式化。

8.8.4 人类专家（截至 2026-10-08）

- Scott Aaronson**（博客 "The Mathocalypse", 2026-10-07）：" $L=BPL$ (i.e., probabilistic logspace and deterministic logspace are the same thing), one of the great derandomization conjectures short of $P=BPP$." 又说："its truth was never in serious doubt, there was a whole subcommunity focused on proving this." [R]
- Lance Fortnow**（博客 "Open No More", 2026-10-07）把它列为"A full derandomization of randomized log space", 并说："And none of these results get us any closer to settling $P \neq NP$." [R]
- Ran Raz**（Princeton, 据 *Scientific American* 2026-10-08 报道）："We have strong reasons to believe that, but we don't know how to prove it", 以及此前 "I didn't see any directions that were promising". [R, △ 引语经网页抓取工具转述，语境（指的是 $L = BPL$ 本身还是更一般的去随机化）以原文为准]
- 没有任何人类专家公开表示读完并核实了这 108 页。Aaronson 对整批结果的说法是："it also appears that no human has understood just about any of these proofs yet." [R]

8.8.5 一个需要标注的不一致

△ Fortnow 的 "OpenAI Math: TCS Selection" 页面 (lance.fortnow.com, 标注 10-07) 对 103 号没有显示 Lean 标记, 而仓库 commit fd4aeeb (10-07 22:20 PT) 里有完整的 Lean 挑战和解答。history.md 写着 10-07 "新增 6 个形式化", 所以一个可能的解释是 103 的 Lean 是那天才加入的, Fortnow 的页面基于更早的快照。我没能确认是哪 6 个 (仓库只有一个合并提交, 看不到逐文件历史)。这个判断只基于网页抓取工具的摘要, 没有亲眼看页面。

8.8.6 怎么理解这里的信任结构

和准黎曼猜想相比: **定义是自写的**, 但只有 142 行, 我逐条读过, 符合标准; **证明是自包含的** (只依赖 Mathlib), 没有大规模补丁; **结论是普遍相信的**, 所以"结论对"不能反过来说明"证明对", 可信度几乎全部压在 Lean 内核和"有没有人真的编译通过"上 (△ 尚无第三方报告)。

8.9 如果为真, 意味着什么 (以及不意味着什么)

8.9.1 对复杂性理论

1. **第一个无条件"完全去掉随机性"的自然计算资源类。** 在"对数空间 + 多项式时间"这个范围里, 掷硬币一点用都没有。这回答了 AKLLR 1979 年就明确提出的问题。
2. **它不蕴含 $P = BPP$ 。** 时间版本被"去随机化 $\Rightarrow$ 电路下界"那道墙挡着 (§8.2.2), 空间版本的证明绕过了它, 但没有拆掉它。PIT 的确定性多项式时间算法依然未知。
3. **它不蕴含 $L = NL$, 更离 P vs NP 很远。** Fortnow 说得很直接: "none of these results get us any closer to settling $P \vee NP$ " (§8.8.4)。有向图可达性 (§8.4.4) 依然不知道能否在对数空间里解决。新的包含关系图是:

$$L = RL = BPL \subseteq NL \subseteq L^2$$

1. **定理 1.2 可能比 1.1 更有用。** 能在对数空间里高精度估计随机游走概率, 意味着很多小空间线性代数问题 (比如对 Laplacian 求解、马尔可夫链的平稳分布) 可能有新的确定性算法。[推测]
2. **技术可能比结论更重要。** Aaronson 说结论"从来没人认真怀疑过", 所以领域真正想要的是**证明方法**, 尤其是其中"低空间、高精度的线性代数": 在只有 $O(\log n)$ 比特内存的条件下, 把矩阵幂和 $(I - S)^{-1}$ 这样的量算到很高的精度 (§8.7.2)。可惜目前没人读懂它。如果证明成立却没人能提炼出可复用的思想, 这会是一个很奇怪的局面: 问题关闭了, 但领域没学到东西。[推测]

8.9.2 对工程

对实际系统几乎没有直接影响: 实践中的随机算法 (哈希、采样、Bloom filter) 本来就够快, 也多不在"对数空间"这个极端设定里。定理只保证确定性替代算法**存在**, 多项式的次数和常数很可能是天文数字。[推测] 流式算法的含义也有限: 流式模型只能单遍读输入, L 允许反复读。

8.9.3 对 AI

- 和其他头条结果一样，这是"AI 在公认的硬核开放问题上给出证明，并附带机器检查"的案例。
- 它的特点是**结论大家都信，难在证明**。这类问题对 AI 也许特别合适：方向明确，不需要"猜对结论"，需要的是把一个 108 页的复杂构造在每一步都做对，而 Lean 正好能逐步检查。[推测]
- 对 AI 安全研究的启示，和本 deck §16 一样：有了 Lean 之后，信任的瓶颈从"证明对不对"转移到**陈述和定义有没有写对**。这一族的定义是自写的，所以§8.8.1 那张表就是一次规格审查 (spec review)。这和审计 AI 智能体的行为规格是同一种工作。

8.9.4 旁注：同一批里的整数乘法低于 $n \log n$ (family 109)

同一天 (2026-09-23) 还有一篇理论计算机论文，问的是一个更日常的问题：**两个 n 位的整数相乘，最少要多少步？** 它用的计算模型和§8.8.1 一样，也是多带图灵机，所以放在这里一起讲。

年份	谁	步数	状态
—	小学竖式	n^2	[已确立]
1962	Karatsuba	$n^{1.585}$ (把一次乘法拆成 3 次而不是 4 次半长乘法, $\log_2 3 \approx 1.585$)	[已确立]
1971	Schönhage–Strassen	$n \log n \log \log n$ (用快速傅里叶变换), 并 猜想 $n \log n$ 是最优的	[已确立]
2019	Harvey–van der Hoeven (arXiv 2019, <i>Annals of Mathematics</i> 2021)	$O(n \log n)$	[已确立]
2026	OpenAI	$O(n (\log n)^{(1-2^{(-182))})}$	[OpenAI 声称]

OpenAI 声称了什么 [P]：论文 *Integer multiplication below $n \log n$* (2026-09-23, 73 页) 的摘要："We give a deterministic algorithm that multiplies two n -bit integers in $O(n(\lg n)^{(1-\kappa)})$ worst-case time, with $\kappa = 2^{(-182)}$, on one fixed finite-alphabet Turing machine with a fixed finite number of one-dimensional tapes." 也就是说，在多带图灵机上比 $n \log n$ 再省一个 $(\log n)^{(2^{(-182)})}$ 的因子。论文自己也承认："The constants and thresholds in the construction are extremely large; the algorithm is intended to establish a bit-complexity bound."

核实：这一篇**没有 Lean 形式化**，仓库里没有它的 Comparator 目标 [P]，所以没有任何机器检查，可信度完全取决于有没有人读懂这 73 页。我也没有找到专家针对它的公开评论 $\triangle$ 。

怎么看：

- **实际意义为零。** $2^{(-182)} \approx 1.6 \times 10^{-55}$ 。粗算一下：即使两个数各有 10^{100} 位，省下的因子 $(\log n)^{(2^{(-182)})}$ 也只比 1 大约 10^{-54} 。这种节省只在天文规模上才看得见。

- 但它推翻了一个 50 多年的猜想。Schönhage–Strassen 1971 年猜想 $n \log n$ 是最优的；这篇论文声称，至少在多带图灵机这个计算模型下不是。这个限定语很重要，论文摘要原话是 "in this model"。在别的计算模型里 $n \log n$ 是不是最优，是另外的问题。
- 和本节主结果正好相反： $L = BPL$ 是"结论大家都信，难在证明"，而且有 Lean；整数乘法是推翻一个流传已久的猜想，却没有 Lean。同一批结果里，信任的来源可以完全不同，这也是§8.8 要花那么多篇幅讲 Lean 的原因。[推测]

8.10 自测题

读完后试着回答。答不上来就回到对应小节再读一遍。

1. 为什么"工作内存 $O(\log n)$ 比特"约等于"能存常数个指针"？为什么这样的确定性机器一定在多项式时间内停机？ (§8.1.2、§8.1.3)
2. RL 和 BPL 的区别是什么？为什么"硬币读完就没了"这个限制很重要？ (§8.3.1)
3. 随机游走算法为什么能在无向图上工作、在有向图上失败？各给一个数字。 (§8.4.3–8.4.4)
4. Reingold 的算法里，"层数 $\times$ 每层"分别是多少？它和 Nisan 生成器的"层数 $\times$ 每层"差在哪？ (§8.5.3、§8.6.2)
5. 为什么"种子长度 $O(\log n)$ 的 PRG"就足以推出 $L = BPL$ ？ (§8.6.1)
6. OpenAI 的 Lean 陈述里， L 、 RL 、 BPL 是谁定义的？这和准黎曼猜想 (§4) 的情况有什么不同？为什么这一点重要？ (§8.8.1)
7. 为什么 $L = BPL$ 不蕴含 $P = BPP$ ？ (§8.2.2、§8.9.1)
8. 整数乘法那篇为什么说"推翻了一个 50 多年的猜想"，同时"实际意义为零"？它的可信度和 $L = BPL$ 有什么不同？ (§8.9.4)

附：【检查】答案

- **检查 1：** $\lceil \log_2 10^9 \rceil = 30$ 比特。当前顶点 30 + 目标顶点 30 + 计数器 ($n^3 = 10^{27}$ ，需要 $\lceil \log_2 10^{27} \rceil = 90$ 比特) = 150 比特，不到 20 字节。
- **检查 2：** 两边相等 $\Leftrightarrow 2xy = 0 \Leftrightarrow x = 0$ 或 $y = 0$ 。 $x = 0$ 有 100 种， $y = 0$ 有 100 种， $(0, 0)$ 重复算了一次，共 199 种（脚本核对）。
- **检查 3：** 第 1 步后是 $(0.5, 0.5, 0)$ 。第 2 步：状态 0 的 0.5 一半留在 0、一半去 1；状态 1 的 0.5 一半去 2、一半回 0。所以 $P(0) = 0.25 + 0.25 = 0.5$ ， $P(1) = 0.25$ ， $P(2) = 0.25$ 。
- **检查 4：** $h_2 = 0$ ； $h_1 = 1 + \frac{1}{2} \cdot 0 + \frac{1}{2} h_0$ ； $h_0 = 1 + \frac{1}{2} h_1 + \frac{1}{2} h_0$ ，即 $h_0 = 2 + h_1$ 。代入得 $h_1 = 1 + \frac{1}{2}(2 + h_1) = 2 + \frac{1}{2} h_1$ ，所以 $h_1 = 4$ ， $h_0 = 6 = 2^3 - 2$ 。

附：术语表

术语	一句话解释
空间复杂度	同一时刻最多占用多少比特工作内存（输入不算）
L	确定性、 $O(\log n)$ 比特工作内存能判定的问题
NL	非确定性对数空间；有向图可达性是其代表问题
RL	对数空间 + 多项式时间 + 硬币，单边错（"否"永不接受）
BPL	对数空间 + 多项式时间 + 硬币，双边错（ $\geq 2/3$ vs $\leq 1/3$ ）
BPP	多项式时间 + 硬币，双边错
配置	机器某一时刻的全部状态；对数空间机器只有多项式个配置
PIT	多项式恒等式检验；有简单的随机算法，确定性多项式算法未知
USTCON	无向图 s-t 连通性
覆盖时间	随机游走访问遍所有顶点的期望步数
扩张图	度数小但连通性极好的图；谱间隙为常数
谱间隙	$1 - \lambda_2$ ，衡量随机游走"忘掉起点"的速度
zig-zag 积	把高度数扩张图降成常数度、同时基本保持间隙的图运算
伪随机生成器（PRG）	把短种子拉长成"对某类观察者看起来随机"的比特串
种子长度	PRG 需要的真随机比特数； $O(\log n)$ 即可枚举
去随机化	把随机算法变成确定性算法
难度换随机性	"存在难的函数" $\Rightarrow$ "可以去随机化"的一类定理
催化计算	借用一块已满的内存做计算，用完原样归还
Comparator	Lean FRO 的工具，检查解答证明的是挑战文件里那个陈述，且只用允许的公理

附：想继续深入

- **Sanjeev Arora & Boaz Barak**, *Computational Complexity: A Modern Approach*（剑桥大学出版社，2009）：第 4 章（空间复杂度）、第 7 章（随机计算）、第 21 章（扩张图和 Reingold 算法）。草稿免费：<https://theory.cs.princeton.edu/complexity/>
- **Salil Vadhan**, *Pseudorandomness*（Foundations and Trends in TCS, 2012）：第 2 章（随机游走和 USTCON）、第 4 章（扩张图）、第 7–8 章（PRG）。免费：<https://people.seas.harvard.edu/~salil/pseudorandomness/>
- **William Hoza**, *Recent Progress on Derandomizing Space-Bounded Computation*（BEATCS 综述，2022）：L vs BPL 领域现状最好的入门综述。△ 链接请自行搜索确认。

- 原始文献：AKLLR, FOCS 1979；Nisan, *Combinatorica* 12(4), 1992；Saks & Zhou, *JCSS* 58(2), 1999；Reingold, *JACM* 55(4), 2008；Hoza, APPROX/RANDOM 2021, LIPIcs 207:28。
- 原始论文：<https://github.com/openai/math/blob/main/preprints/Exact-Derandomization-of-Logarithmic-Space-L-equals-RL-equals-BPL-September-23-2026/paper.pdf>
- Lean 陈述：
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/LogspaceEquality.lean>
； scope: `lean/docs/103.md`
- 整数乘法 (family 109) 原始论文：
<https://github.com/openai/math/blob/main/preprints/Integer-multiplication-below-n-log-n-September-23-2026/paper.pdf>；之前的纪录：Harvey & van der Hoeven, *Integer multiplication in time $O(n \log n)$* , *Annals of Mathematics* 193(2), 2021。
- 反应：Aaronson <https://scottaaronson.blog/?p=10169>；Fortnow <https://blog.computationalcomplexity.org/2026/10/open-no-more.html>；Fortnow 选单 <https://lance.fortnow.com/openai-math-tcs.htm>；*Scientific American* <https://www.scientificamerican.com/article/the-most-exciting-claims-from-openais-heap-of-new-proofs/>

组合 · FAMILY 158 (+ 156)

9. 平面着色数 $\chi \geq 6$ (Hadwiger–Nelson 问题)

前提只需要：知道什么是图（顶点 + 边）、会用勾股定理算两点距离、知道 cos/sin。测度、遍历论这些词第一次出现时都会先讲。文中所有数字都由脚本实算（脚本：`精讲/scripts/06_coloring.py`，结果抄在正文里）或有出处；【检查】是可以自己动手算的小练习，答案在章末。标记：[P] = 读过一手材料（论文、openai/math 仓库文件或 Lean 源码）；[R] = 二手报道（博客、新闻）； Δ = 我没能核实，或来源之间有冲突；"推测" = 我自己的判断。预计阅读时间：50–80 分钟。可以分三次读：§9.1–9.4（图着色、下界 4、上界 7）、§9.5–9.7（2018 年的突破、“怪集合”和选择公理、为什么 6 难）、§9.8–9.10（OpenAI 的结果、核实、意义，最后附同一批里的 Borsuk 猜想反例）。

9.0 先说结论：这一章要讲明白的一件事

问题本身小学生都能听懂：给平面上的每一个点涂一种颜色，要求距离恰好为 1 的任意两点颜色不同。最少要几种颜色？这个最少的颜色数叫“平面的色数”，记作 $\chi(\mathbb{R}^2)$ 。

1950 年起大家就知道答案在 4 到 7 之间，然后卡了 68 年。2018 年下界被推到 5。OpenAI 声称把它推到 6，于是答案只剩 6 或 7。

这一章要讲清楚的是一条因果链：

下界靠"找一个涂不了色的有限点集" (Moser 菱形对 $\rightarrow$ de Grey 的 1581 点图) $\Leftarrow$ 原则上总能这么找 (de Bruijn-Erdős 紧性定理) $\Leftarrow$ 但需要的点集可能大到搜不到 $\Leftarrow$ OpenAI 换了一条路：先把"任意怪涂法"变成"可测的涂法" (遍历论)，再用几何把 5 色可测涂法排除掉，最后一步又回到 7 个点的 Moser 菱形对。

读完这一章，你应该能用自己的话讲出：

- 为什么 3 色不够 (手画 7 个点就能证明)，为什么 7 色够 (六边形铺砌)；
- 为什么"颜色类不可测"是这个问题里真正的难点，以及它和选择公理的关系；
- OpenAI 的证明在结构上做了什么、Lean 陈述为什么一眼能核对，以及它**没有**解决什么 (6 还是 7)。

9.1 图着色：CS 里的老朋友

9.1.1 定义

一个**图**是一些顶点加一些边。**合法着色** (proper coloring)：给每个顶点一种颜色，有边相连的两个顶点颜色必须不同。一个图最少需要的颜色数叫它的**色数** $\chi(G)$ 。

你在 CS 里见过它：

- **寄存器分配**：变量是顶点，"同时活着"的两个变量连边，颜色是寄存器。色数 = 最少要几个寄存器。
- **排课/排考试**：课是顶点，有同一个学生的两门课连边，颜色是时间段。

判断一个一般的图能不能 3 着色是 NP 完全问题。这一点后面会用到：靠计算机硬搜，规模一大就搜不动。

9.1.2 几个手算玩具

- 一条边：需要 2 色。
- **三角形** (3 个点两两相连)：2 色不够。脚本枚举了全部 $2^3 = 8$ 种涂法，合法的有 **0** 种。所以三角形需要 3 色。
- 一般地，如果图里有 k 个点两两相连 (叫 k -团)，就至少要 k 色。但反过来不成立：色数可以比最大团大。下面的 Moser 菱形对就是例子：它没有 4-团，却要 4 色。

【检查 1】一个 5 个点围成的环 (5-圈，每个点只和左右邻居相连)，最少要几色？为什么 2 色不够？

9.2 把整个平面变成一张图

9.2.1 单位距离图

现在把平面上的每一个点都当成一个顶点（有不可数无穷多个），两个点之间连边当且仅当它们的距离恰好等于 1。这张巨大的图叫平面的单位距离图，它的色数就是 $\chi(\mathbb{R}^2)$ 。

等价的说法：把平面分成 k 块（每块一种颜色），要求每一块里都没有两点距离恰好为 1。最少分几块？

注意两点：

- 距离是“恰好 1”，不是“小于 1”。距离 0.999 或 1.001 的两点可以同色。
- 对颜色块的形状没有任何要求。可以是漂亮的六边形，也可以是用选择公理造出来、根本画不出来的怪集合。这一点是整个问题的核心难点，§9.6 专门讲。

9.2.2 最初几步

- $\chi \geq 2$ ：任意两个相距 1 的点就要 2 色。
- $\chi \geq 3$ ：画一个边长为 1 的正三角形，三个点两两相距 1，就是§9.1.2 的三角形，2 色不够。

下界的套路从这里就定下来了：在平面上找一个有限的点集，点之间的单位距离边构成一个图，证明这个有限图不能用 k 色涂，那平面就不能用 k 色涂（因为平面的任何合法涂法限制到这几个点上，也是这个小图的合法涂法）。

9.3 下界 4: Moser 菱形对 (1961)

9.3.1 第一步：菱形强迫两个尖顶同色

拿两个边长为 1 的正三角形拼成一个菱形： $O=(0,0)$ ， $B=(1/2, \sqrt{3}/2)$ ， $C=(1,0)$ ， $T=(3/2, \sqrt{3}/2)$ 。O-B-C 是一个三角形，B-C-T 是另一个，共用边 BC。

只有 3 种颜色时：O、B、C 两两相邻，三色各占一个；T 和 B、C 都相邻，所以 T 只能用剩下那种颜色，也就是 O 的颜色。**结论：3 色时 O 和 T 一定同色。**脚本核对：这个菱形的合法 3 着色共 6 种，每一种都有 O 和 T 同色。

O 和 T 的距离是 $\sqrt{3} \approx 1.732$ （脚本实算），不是 1，所以它们同色本身不违规。

9.3.2 第二步：再来一个菱形，转一下

把整个菱形绕 O 转一个角度 θ ，得到第二个菱形 O、 B_2 、 C_2 、 T_2 。同样的道理， T_2 也必须和 O 同色。现在选 θ ，让 T 和 T_2 的距离恰好为 1。

两个尖顶都在以 O 为圆心、半径 $\sqrt{3}$ 的圆上，夹角为 θ ，它们的距离平方是：


$$|T - T_2|^2 = (\sqrt{3})^2 + (\sqrt{3})^2 - 2 \cdot 3 \cdot \cos \theta = 6 - 6 \cos \theta$$

令它等于 1，得 $\cos \theta = 5/6$ ， $\theta \approx 33.56^\circ$ （脚本实算）。

这时 T 和 T_2 都必须和 O 同色，可它们彼此距离为 1，必须不同色。**矛盾。所以 3 色不够， $\chi \geq 4$ 。**

下图把两个菱形、11 条单位长度的边和上面这段推理画在了一起（图里两个尖顶记作 T_1 、 T_2 ）。
右下角是平面色数已知范围的变化，后面几节会逐一讲到。

Moser 菱形对 (1961): 7 个点、11 条长度为 1 的边 $\Rightarrow$ 3 种颜色不够



推理 (3 色时)
O、B₁、C₁ 两两相距 1 $\rightarrow$ 三种颜色各占一个
 T_1 与 B₁、C₁ 都相距 1 $\rightarrow T_1$ 只能和 O 同色
同理 T_2 也和 O 同色
但 T_1 、 T_2 相距 1 $\rightarrow$ 矛盾 $\Rightarrow \chi \geq 4$

平面色数 χ 的已知范围
1950–61 $4 \leq \chi \leq 7$ (菱形对 + 六边形 7 色铺砌)
2018 $5 \leq \chi \leq 7$ (de Grey, 1581 点的有限图)
2026-09 $6 \leq \chi \leq 7$ (OpenAI 声称, Lean 已形式化)

坐标由 build 脚本计算：两个"两个单位正三角形拼成的菱形"共享顶点 O，尖顶 T 距 O 为 $\sqrt{3}$ ；把其中一个绕 O 转 $2 \cdot \arcsin(1/(2\sqrt{3})) \approx 33.6^\circ$ ，使两个尖顶恰好相距 1。

9.3.3 脚本核对

脚本按上面的坐标造出 7 个点：

点	坐标（四位小数）
O	(0, 0)
B ₁	(0.5, 0.866)
C ₁	(1, 0)
T ₁	(1.5, 0.866)
B ₂	(−0.062, 0.9981)
C ₂	(0.8333, 0.5528)
T ₂	(0.7713, 1.5508)

然后检查所有 21 对点的距离，恰好为 1 的有 **11 对**：两个菱形各 5 条边，加上 T_1 – T_2 。没有意外多出来的单位距离。

再暴力枚举：

- 3 色： $3^7 = 2187$ 种涂法，合法的 **0** 种。

- 4 色：合法的 **384** 种 ($= 4! \times 16$ ，即不计颜色名字的话有 16 种本质不同的涂法)。

所以这个 7 点 11 边的图色数恰好是 4。它叫 **Moser 菱形对** (Moser spindle, Moser 兄弟 1961 年发表)。

【检查 2】上面用了 $|T - T_2|^2 = 6 - 6\cos \theta$ 。请用余弦定理自己推一遍，并验证 $\cos \theta = 5/6$ 时距离确实是 1。

记住这个 7 点图：OpenAI 的 62 页证明的最后一步，用的还是它。

9.4 上界 7：六边形铺砌

下界靠"找一个涂不了的小图"，上界则要**给出一种对整个平面都合法的涂法**。

9.4.1 构造

1. 用正六边形把平面铺满（蜂巢）。论文取六边形的外接圆半径 $r = 2/5$ 。
2. 同一个六边形里任意两点的距离不超过它的直径 $2r = 0.8 < 1$ 。所以一个六边形可以整块涂一种颜色，块内不会出现距离为 1 的点对。
3. 用 7 种颜色按周期给六边形上色，使同色的两个不同六边形离得足够远。论文里同色六边形中心至少相距 $\sqrt{21} \cdot r \approx 1.833$ ，所以两块里的点至少相距 $(\sqrt{21} - 2) \cdot r \approx 1.033 > 1$ （脚本实算）。
4. 边界上的点随便归给相邻的某一块即可（论文的处理，Lean 版本也覆盖了边界）。

9.4.2 "7 种颜色"从哪来

六边形的中心构成一个三角形格点。论文用复数写它：格点是 $a \cdot (m + n \cdot \omega)$ 的形式， $\omega = e^{(2\pi i/3)}$ 是三次单位根（§4 §9.8.2 的 Eisenstein 整数又出现了）。

乘以 $(2 - \omega)$ 得到一个"放大并转了一下"的子格点，它占原格点的 $1/7$ ，因为 $|2 - \omega|^2 = 7$ （脚本实算：7.0000000000000001，最后一位是浮点误差）。原格点按"属于子格点的哪一个平移副本"分成 7 类，每类一种颜色。脚本里这对应一个很简单的规则：中心 $a \cdot (m + n\omega)$ 的颜色是 $(m + 2n) \bmod 7$ 。

9.4.3 脚本核对

脚本随机撒了 **20 万** 对相距恰好为 1 的点（每对先随机取一点，再随机取一个方向走 1），用上面的规则涂色，**同色的对数是 0**。

【检查 3】 r 不能随便取。要让构造成立，需要 $2r < 1$ 且 $(\sqrt{21} - 2) \cdot r > 1$ 。 r 的允许范围是多少？

所以 $4 \leq \chi(\mathbb{R}^2) \leq 7$ 。这个区间从 1950 年（Nelson 得到 4，Isbell 得到 7，当时都没发表，Soifer 后来整理了史料；Hadwiger 1961 年正式发表）一直保持到 2018 年。

9.5 2018 年：de Grey 把下界推到 5

9.5.1 一个业余数学家的突破

2018 年 4 月，Aubrey de Grey（以衰老生物学研究出名，数学是业余爱好）在 arXiv 发表 *The chromatic number of the plane is at least 5* (arXiv:1804.02385)。做法仍然是§9.2.2 的套路：用很多个 Moser 菱形对之类的零件拼出一个巨大的有限单位距离图，证明它**不能 4 着色**。修正后的图有 **1581 个顶点**，"不能 4 着色"这一步由计算机验证。

9.5.2 之后的跟进：把证据变小、变得可读

年份	谁	做了什么	来源
2018	Heule	用 SAT 求解器加"不可满足核"提取，得到 553 个顶点的 5 色图	arXiv:1805.12181
2018/2020	Exoo, Ismailescu	独立给出 $\chi \geq 5$ 的另一个证明	arXiv:1805.00157
2020	Parts	把图缩小到 509 个顶点（图最小化）	arXiv:2010.12665
2020	Parts	给出一个人可以手工核对的 $\chi \geq 5$ 证明	arXiv:2010.12661

这一阶段还有众包项目 Polymath16（由 Dustin Mixon 在其博客上组织），上面这些工作和它交织在一起。

509 点从哪来：按 OpenAI 论文引言的说法，SAT 加不可满足核得到的是 Heule 的 **553 点**；**509 点**是 Parts 用图最小化得到的。两者都和 Polymath16 有关。

9.5.3 为什么这条路越来越难

一个 n 个顶点的图用 k 色，可能的涂法有 k^n 种（脚本实算数量级）：

图	顶点	颜色	$k^n \approx$
Moser 菱形对	7	3	$10^{3.3}$
Parts	509	4	10^{306}
Heule	553	4	10^{333}
de Grey	1581	4	10^{952}

SAT 求解器当然不会逐个枚举，它靠剪枝。但要证明"一个都没有"，求解器必须把整个空间都排除掉，而且 5 色时的图预计还要大得多。从 4 推到 5 已经需要上千点的图；从 5 推到 6，没人知道需要多大的图，Polymath16 期间也没有人找到过。

9.5.4 一个保底的定理：de Bruijn–Erdős 紧性

既然要找的有限图可能大得离谱，那它**一定存在吗**？答案是肯定的，这是 **de Bruijn–Erdős 定理 (1951)**：

一个（可以是无穷的）图能用 k 色涂，当且仅当它的**每一个有限子图**都能用 k 色涂。

所以"平面不能 5 着色"等价于"存在某个有限单位距离图不能 5 着色"。但这个定理的证明是**非构造性**的：它保证这样的有限图存在，却不告诉你它长什么样、有多大。

这里有一个对 CS 人很自然的类比：它像"如果每个有限的约束子集都可满足，整个无穷约束系统就可满足"。证明要用到无穷乘积空间的紧性（Tychonoff 定理），而那需要**选择公理**（下一节讲）。OpenAI 论文 §4 把这一步明确写出来了："using product compactness in ZFC"。

9.6 真正的难点：怪集合、可测性和选择公理

9.6.1 什么是"可测"

粗略地说，平面上的一个集合是**可测**的，意思是它有一个合理的"面积"。所有你能画出来的形状（多边形、圆盘、它们的可数并、加上一些更复杂但"有规律"的集合）都可测。

但在通常的集合论（ZFC，即带**选择公理**的公理系统）里，可以构造出**不可测**集合：它没有任何合理的面积，你永远画不出来，只能证明它存在。最有名的例子是 Vitali 集合，以及 Banach–Tarski 悖论（一个球切成有限块，重拼成两个同样大的球；切出来的块就是不可测的）。

选择公理说的是：给你无穷多个非空的盒子，你总能从每个盒子里各挑一个元素，即使你写不出挑选规则。绝大多数数学家默认接受它。

9.6.2 可测色数：一个不同的问题

如果要求每种颜色的点集都可测，得到的最少颜色数叫**可测色数** $\chi_m(\mathbb{R}^2)$ 。显然 $\chi_m \geq \chi$ （多了一条限制，只会更难涂）。

- **Falconer (1981)**： $\chi_m(\mathbb{R}^2) \geq 5$ 。用的工具是"密度点"：一个可测集合里几乎每一点附近，该集合都占满了几乎 100% 的面积。在这样的点周围，单位圆上很难避开同色点，再配合旋转论证得到矛盾。

也就是说，在"可测"的限制下，5 早在 1981 年就被证明了，比 de Grey 早 37 年。难的是去掉"可测"这个条件。

9.6.3 一个让人警惕的例子

OpenAI 论文引言引用了 Payne (2009) 的一个例子，很能说明问题：考虑平面上的一个子图，只在两点的差恰好是"坐标都是有理数的单位向量"时连边（例如 $(3/5, 4/5)$ ）。

- 允许任意涂法时，这个图 **2 色**就够；
- 要求可测时，它**至少要 5 色**。

所以"可测涂法"和"任意涂法"不能想当然地划等号，哪怕两者的距离约束看起来一模一样。(△我没有读 Payne 原文，这里转述的是 OpenAI 论文 §1 的原话。)

9.6.4 Shelah–Soifer：答案可能依赖公理

Shelah 和 Soifer 在 *Axiom of choice and chromatic number of the plane* (J. Combin. Theory Ser. A 103 (2003) 387–391) 里构造了一些"距离图"，它们的色数**取决于你用哪套公理**：在 ZFC 里是 2，而在"去掉选择公理、换成'所有实数集合都可测'"的公理系统 (ZF + DC + LM, Solovay 1970 年证明，只要假设存在一个"不可达基数"，这个系统就是相容的) 里是不可数的。

他们还提出了一个条件性定理，大意是：如果所有有限单位距离图都能 4 着色，那么平面色数在 ZFC 里是 4，而在 ZF+DC+LM 里至少是 5 (因为那个世界里所有涂法都可测，Falconer 的结果就适用)。(△条件定理的精确表述我是根据 Soifer 后来的综述转述的，没有逐字核对原文。)

这个条件定理的前提已经被 de Grey 推翻了，但它揭示的可能性还在：**"平面到底要几色"可能没有一个与公理无关的答案**。这也是为什么 OpenAI 论文开头特意写明"working throughout in ZFC"。

9.6.5 "好看"的涂法：答案已经知道是 7

如果要求颜色块是"地图式"的 (边界是规则曲线)，情况又不同：

- Townsend (1981 宣布、2005 发表细节)：地图式涂法至少要 **6** 色。
- Sokolov–Voronov (2025, arXiv:2502.01958)：在一个"多边形、局部有限"的框架下，至少要 **7** 色。

也就是说，对**"能画出来"的涂法，答案就是 7**。剩下的问题是：怪集合能不能比好看的涂法省颜色？

9.7 为什么 ≥ 6 难：两条路都堵着

到 2026 年之前，局面是这样的：

路线	能做到什么	卡在哪
有限图 + 计算机 (de Grey、Heule、Parts)	$\chi \geq 5$	6 色需要的有限图可能巨大，没人找到
可测/密度点 (Falconer)	$\chi_m \geq 5$	只对可测涂法成立，管不到怪集合
规则边界 (Townsend、Sokolov–Voronov)	地图式 ≥ 6 、多边形形式 $= 7$	要求边界规则，管不到一般可测集合，更管不到怪集合

要推到 6，需要同时跨过两道坎：

1. 从任意涂法到可测涂法：怎么让怪集合"变得可以分析"？
2. 从可测涂法到几何矛盾：可测集合的边界可以极其不规则，不能直接当成地图来画。

OpenAI 的论文正好对应这两步。

9.8 OpenAI 声称了什么

9.8.1 主结果

论文 *The Euclidean plane is not five-colorable* (OpenAI, 2026-09-23, 62 页, Family 158) 的摘要 [P]:

"We prove that every coloring of the Euclidean plane with five colors has a monochromatic unit-distance pair, with no regularity assumption on the color classes. Consequently, the chromatic number of the plane is either six or seven."

翻译：平面的任何 5 色涂法里，一定有两个相距为 1 的同色点，而且对颜色块不作任何正则性要求。所以平面色数是 6 或 7。

论文 Theorem 1.1 写作 $6 \leq \chi(\mathbb{R}^2) \leq 7$ ，并紧接着说："The remaining alternatives six and seven are unresolved."

一个常见误解：容易以为这个结果是"找一个更大的有限图再用 SAT 验证"。**不是**。此前下界的标准套路都是"找一个有限图，证明它不能 k 着色" (§9.2.2 的套路，也是 de Grey 那条路)，而这篇全文没有给出任何一个不能 5 着色的有限图。它走的是遍历论加测度论，这正是它出人意料的地方。

9.8.2 证明的两半

论文把证明拆成两个定理：

- **Theorem 1.3 (转移定理)**：对每个 k ，"存在合法的 k 着色" $\Leftrightarrow$ "存在**弱可测** k 着色"。对所有 k 都成立，不只是 5。
- **Theorem 1.4**：不存在弱可测 5 着色。

合起来：如果有合法的 5 着色，由 1.3 就有弱可测 5 着色，和 1.4 矛盾。

"弱可测 k 着色"是什么 (Definition 1.2 的白话版)：每个颜色块都可测，并且"同色的单位距离点对"在测度意义下是零，也就是说允许有例外的同色对，但例外少到面积为零、可以忽略。这比"合法着色"弱（允许零测度的违规），又比"任意着色"规则（必须可测）。

9.8.3 第一半的直觉：把怪涂法"平均"成统计规律

以下是我按论文 §1.1 做的简化转述，技术细节远多于此。

1. **先缩到一个可数的点集上**。取所有坐标是代数数（像 $\sqrt{2}$ 、 $(1+\sqrt{5})/2$ 这类多项式方程的根）的点，记作 E 。它只有可数多个点，但在平面上稠密，并且对"乘一个单位长度的代数复数"（即代数角度的旋转）封闭。
2. **对平移和旋转做平均**。把怪涂法限制到 E 上，再对所有平移和旋转"取平均"，得到一个**随机涂法**，它的统计规律在任何平移、旋转下都不变。能这样平均，依赖这些群是**可顺从的**（amenable，粗略说就是"能公平地取平均"）。这正好接上 §10 的主题：§10 细讲什么是可顺从，而那里的 Thompson 群 F (family 248) 被证明的恰恰是**不可顺从**。

对你熟悉的东西做类比：这像把一段非常不规则的信号，变成一个**平稳随机过程**。单个样本可能很怪，但它的统计（例如自相关函数）是规则的。

1. **用谱定理做"傅里叶分解"**。平稳过程可以按频率分解（类比 EEG 的功率谱）。这里的"频率"分两类：普通的连续频率（对应平面上的正常波 $\exp(i\xi \cdot z)$ ），和一类只在可数点集 E 上有意义的"野"频率。
2. **刚性定理 (Theorem 2.3)**：任何在旋转下不变、并且不落在普通频率上的分布，一定是**完全均匀的噪声**（Haar 测度）。均匀噪声在任何非零平移下的相关都是 0，所以把它扔掉，不会破坏"单位距离点对不同色"这个相关性条件。这一步的证明用到了 **Furstenberg–Zimmer 的紧扩张结构**，这是遍历论里证明 Szemerédi 定理时发展出来的工具。
3. **剩下的普通频率部分可以延拓到整个平面**，得到真正的可测函数，再取每点最可能的颜色，就是一个弱可测涂法。

反方向（弱可测 $\Rightarrow$ 合法）用的是 Falconer 式的密度点论证加上 §9.5.4 的 de Bruijn–Erdős 紧性。

9.8.4 第二半的直觉：用几何排除 5 色

同样是简化转述：

1. **"调色板"**：在每个点 x 周围看单位圆，记录圆上各方向出现哪些颜色。论文证明，几乎每个这样的调色板**最多只有 2 种颜色**（论文 §5）。
2. **颜色之间的"交界图"**：把 5 种颜色当顶点，记录哪些颜色之间有大量的过渡。论文证明这个图里有一个**圈**（论文 §6–7，用到磨光、阈值化和一个平面覆盖的拓扑论证）。
3. **5 种颜色上的圈只能长 3、4 或 5**，论文 §8 逐一排除：
 - 5-圈：一个"6 位角度词"的组合矛盾；
 - 4-圈：一个奇偶性矛盾；
 - 3-圈：会留下一块只用 3 种颜色的开区域，然后用一个有理数坐标的"放置证书"，把 **Moser 菱形对的 7 个点**放进这块区域。§9.3 已经证明 7 个点 3 色不够，矛盾。

Lean 代码里能直接看到这块"三色区域"的定义

(`OAI/Geometry/PlaneColoring/Moser.lean`):

```
def ThreeLabelRegion (x y : ℝ) : Prop :=
  0 < x^2 + y^2 ∧ x^2 + y^2 < 4 ∧
  y^2 * (3 * x^2 - y^2)^2 < (x^2 + y^2)^3 * (1 - (x^2 + y^2) / 4) * (x^2 + y^2 - 1)^2
```

它是一个用多项式不等式描述的平面区域，菱形对的点要逐个验证落在里面。**整个 62 页论证从 1961 年的 7 点玩具出发，最后又回到它。**

9.8.5 两个附带的东西

- **推论 1.5 ("坏的比例"有正下界)**：存在常数 $\delta > 0$ ，使得任何 5 色涂法里，"随机放一根长为 1 的针，两端同色"的比例至少是 δ 。但论文自己说："The graph and the positive constant here are existential." 也就是 δ 只知道存在，不知道具体多大，因为它来自那个不知道长什么样的有限 6 色图。
- **脚注 1 (Reed 2026-05 手稿)**：Reed 宣称 $\chi = 7$ 并附有"形式化定理"。OpenAI 论文指出，那个定理把一个错误的密度上界当作假设放进去了（反例：半开弧 $\{e^{it} : 0 \leq t < \pi/3\}$ ），所以形式化本身没错，错在被证明的命题。△ 我没有读 Reed 原稿，只看到 OpenAI 的转述。这个例子在 §9.9 会用到。

9.9 它被核实到什么程度

9.9.1 Lean 陈述：两行，你可以自己读懂

文件 `lean/ComparatorChallenges/EuclideanFiveColor.lean` (快照 fd4aeeb) [P]:

```
def ProperColoring (colorCount : ℕ) (coloring : ℂ → Fin colorCount) : Prop :=
  ∀ point otherPoint : ℂ, ‖point - otherPoint‖ = 1 → coloring point ≠ coloring otherPoint

theorem no_proper_five_coloring : ¬ ∃ coloring : ℂ → Fin 5, ProperColoring 5 coloring
```

逐词翻译：

- `coloring : ℂ → Fin colorCount`：一个涂法就是一个函数，把每个复数（即平面上的点， $\mathbb{C}$ 当平面用）映射到 $\{0, 1, \dots, \text{colorCount}-1\}$ 中的一个颜色。**函数可以是任意的**，没有"可测""连续"之类的要求。
- `∀ point otherPoint : ℂ`：对平面上任意两点。
- `‖point - otherPoint‖ = 1 →`：如果它们的距离（复数差的模长）恰好是 1，
- `coloring point ≠ coloring otherPoint`：那么颜色不同。这就是"合法着色"。
- `¬ ∃ coloring : ℂ → Fin 5, ProperColoring 5 coloring`：**不存在任何合法的 5 色涂法。**

这正好就是 Hadwiger–Nelson 问题"5 色不够"的原始表述，没有偷加可测性，也没有额外前提，所以**这个陈述忠实于原问题**。仓库的范围说明 `lean/docs/158.md` 也明说下界 "applies to arbitrary colorings, with no measurability or continuity assumption" [P]。和 §4 的准黎曼猜想相比，这里甚至不依赖 Mathlib 里某个复杂函数（如 ζ ）的定义是否正确，只用到复数、模长和有限集合。**这是整个 OpenAI 仓库里人类最容易审核的陈述之一。**

上界也形式化了：`ComparatorChallenges/PlaneColoring.lean` 里的 `properColoring_seven`，平面用的是 `EuclideanSpace  $\mathbb{R}$  (Fin 2)`，`dist x y = 1  $\rightarrow$  c x  $\neq$  c y`。证明文件 `Seven.lean` 只有 68 行。

9.9.2 证明本身（我们自己跑得统计，[P]）

- 证明入口 `OAI/Geometry/PlaneColoring/Five.lean`。脚本沿 `import` 追踪了它在 OAI 目录内的全部传递依赖：**70 个文件，30,406 行**。
- 在这 70 个文件里 grep：没有 `sorry`、`admit`、自定义 `axiom`、`native_decide`。
- 最后的组装正好对应论文的两半：

```
theorem no_proper_five_coloring :  $\neg \exists c : \mathbb{C} \rightarrow \text{Fin } 5, \text{ ProperColoring } 5 \ c := \text{by}$ 
  rintro (c, hc)
  obtain (d, hd, hw) := proper_to_borel_weak hc          -- 转移定理 (Theorem 1.3)
  exact no_measurable_weak_five_coloring hd hw          -- 几何障碍 (Theorem 1.4)
```

- Comparator 配置（`EuclideanFiveColor.json`）只允许三条标准公理：`propext`、`Quot.sound`、`Classical.choice`。注意：
 - `Classical.choice` 就是 Lean 里的**选择公理**。所以这个形式化证明的是"在带选择公理的数学里，平面不能 5 着色"，和论文的"in ZFC"一致。§9.6.4 说的"换一套公理答案可能不同"，这个证明不涉及。
 - `"enable_nanoda": false`：**没有**启用独立的第二个检查内核。§4 的准黎曼猜想有人用 nanoda 独立复核过，这一个截至 2026-10-08 我们没有找到公开的独立复核记录 $\triangle$ 。
- 我们**没有自己编译**这个证明，以上是读源码的结果。

9.9.3 人类专家

- **Gil Kalai** (2026-10-07 博客)："The new manuscript raises the lower bound to six, leaving six and seven as the two possible answers." 同一篇文章的免责部分写着 "even Lean verification may have issues"。[R]
- **截至 2026-10-08，没有找到 de Grey、Polymath16 成员或其他组合几何专家公开表示读完并核对了这 62 页。**
- OpenAI 仓库 2026-10-07 的 history 里列出了 3 篇撤回和 14 篇修订，**这篇不在其中**。README 公布推理摘要的 10 个家族里**也没有 158 号**。

9.9.4 剩余风险怎么看

- **陈述风险：很低。** 两行，任何人都能对照原问题核对，见 9.1。
- **证明风险：取决于 Lean 内核和 Mathlib。** 证明里用到的测度论、谱定理等都来自 Mathlib 或这 70 个文件；内核会逐步检查。只要内核没 bug，陈述又没问题，结论就成立。
- **理解风险：高。** 遍历论加几何拓扑，62 页，目前没有人类专家公开读完。
- **Reed 的反面教材：**Reed 的"形式化定理"之所以不算数，是因为错误被藏在**假设**里。OpenAI 这个陈述没有假设，`no_proper_five_coloring` 前面什么前提都没有，所以不存在同样的问题。这正说明了"人审陈述、机器审证明"的分工里，人那一半到底该审什么。

9.10 如果为真，意味着什么（以及不意味着什么）

9.10.1 对数学

1. $\chi(\mathbb{R}^2) \in \{6, 7\}$ 。这是 2018 年以来第一次推进，也是第一次不靠有限图推进下界。
2. **转移定理本身可能比"6"更重要：**它对所有 k 成立，等于说"任意涂法"和"弱可测涂法"在这个问题上是一回事。以后研究这个问题，可以直接在可测的世界里用分析工具，不用担心怪集合。（这是我的判断，属推测。）
3. **一个新的开放问题：**由 de Bruijn–Erdős，一定存在一个不能 5 着色（也就是至少要 6 色）的有限单位距离图，但没人知道它长什么样、有多大。把它找出来（例如用 SAT 求解器），可以得到一个完全独立、可以有限验证的证明。这对"AI + SAT"是一个很自然的后续目标（推测）。

9.10.2 不意味着什么

- **没有决定 6 还是 7。** 论文明说这两种可能都未解决。
- §9.6.5 说"好看的涂法要 7 色"，所以如果答案是 6，那一定要用到怪集合或极不规则的可测集合。有人会据此猜答案是 7，但这只是直觉，不是证据（推测）。
- **不涉及选择公理之外的世界。** 证明在 ZFC（Lean 里是 `Classical.choice`）中进行。在"所有集合都可测"的世界里情况如何，§9.6.4 的问题仍然存在。直觉上，那个世界里所有涂法都可测，Theorem 1.4 的几何部分似乎就够了，但它的证明有没有用到超出 DC 的选择，我没有核查 $\triangle$ （推测）。
- **没有给出 δ 的数值，**也没有给出任何具体的 6 色有限图。

9.10.3 对 AI 和 AI 安全

- 这是"人审陈述、机器审证明"最理想的形态：**陈述两行，证明三万行**，人只需审核那两行。和准黎曼猜想 (§4) 相比，它连"Mathlib 的 ζ 定义对不对"这层信任都不需要。
- Reed 的反例说明另一面：**Lean 只保证"给定的陈述被证明了"**，陈述及其假设仍要人把关。这和奖励模型里的规约博弈（specification gaming）是同一类问题：优化器满足了你写下的规约，不一定满足你想要的东西。

- 方法上的"出人意料"（遍历论 + 几何拓扑，而不是更大的有限图）值得注意：如果属实，它是"模型找到了领域内没人走过的路线"的例子，而不是"在已知路线上算得更快"。是否真的没人走过，需要领域专家判断 $\triangle$ 。

9.10.4 旁注：同一批里的 Borsuk 猜想反例 (family 156)

同一天 (2026-09-23) 还有一篇离散几何论文，它的问题是平面着色的近亲。

玩具：一个圆盘能不能切成 2 块，使每块的直径（块内最远两点的距离）都严格变小？不能：不管怎么切，总有一块含有一对对径点（某条直径的两端），这一块的直径没有变小。切成 3 块（三个 120° 扇形）就可以。

Borsuk 1933 年的问题： $\mathbb{R}^d$ 中任何有界集合，是否总能切成 $d+1$ 块直径更小的部分？ $d = 2、3$ 时答案是"能"（ $d = 2$ 是 Borsuk 本人证明的， $d = 3$ 是 Perkal 1947、Eggleston 1955）[R]。

Kahn–Kalai 1993 在 1325 维给出了反例，猜想被否定。此后反例的维数一路下降，最近几步是：65 (Bondarenko) $\rightarrow$ 64 (Jenrich–Brouwer 2014) $\rightarrow$ 63 (Grinsztajn 2026 年 5 月的作者手稿) [P, 据 OpenAI 论文的文献综述和参考文献]。63 维那一步据报道借助了 GPT-5.5 Pro [R, $\triangle$ 我没能找到一手来源核实]。另外，arXiv:2608.12561 (Yibo Ji, 2026-08) 给出了另一个 63 维反例，摘要说构造和证明"generated entirely by ChatGPT using GPT 5.6 Sol", 作者本人核验了结果 [P]。

和平面着色的关系：对有限点集，"切成 k 块、每块直径都更小"等价于"把距离恰好等于直径的点对连边，这张图能 k 着色"：一块的直径变小，就是说这一块里没有两点恰好相距"直径"那么远。平面着色禁止的是"距离恰好为 1"，Borsuk 问题禁止的是"距离恰好等于直径"，两者都是给一张"距离图"着色。Kahn–Kalai 的反例就是一个这样的有限点集，色数被证明很大。

OpenAI 声称了什么 [P]：论文 *A nine-dimensional counterexample to Borsuk's covering assertion* (2026-09-23, 18 页)。

- 取 $\mathbb{R}^4$ 中所有单位向量 u ，构成投影矩阵 uu^T （把向量投影到 u 所在直线上的 4×4 矩阵），用 Frobenius 距离（把矩阵当成 16 个数的向量算欧氏距离）。
- 这些矩阵都是迹为 1 的对称矩阵。4x4 对称矩阵有 10 个自由参数，迹 = 1 再去掉一个，所以它们落在一个 **9 维**空间里。
- 这个集合的直径是 $\sqrt{2}$ （两条直线互相垂直时取到），并且**不能用 10 块直径更小的集合覆盖**。所以 Borsuk 猜想在 9 维就不成立，一下从 63 维降到 9 维。论文的推论 7.1 还把构造推广到所有 $d \geq 9$ 。
- 论文明说它不确定反例的最小维数。由于 $d \leq 3$ 时猜想成立，**4–8 维仍然开放**。
- 论文自己指出，"投影矩阵"这个嵌入是经典的：Kalai 讲解 Kahn–Kalai 构造时用的就是 $x \mapsto x \otimes x$ （也就是 xx^T ）。新东西是对这个**连续集合证明覆盖障碍**，用的是 mod 2 度数、单纯复形，最后是一段有限组合论证。

核实 [P]: 有 Lean 形式化 (`lean/ComparatorChallenges/BorsukNine.lean`)。陈述同样很短, 人可以直接读: 在 4×4 矩阵空间里定义 `projectorSet`, 断言它是紧集、包含在 `traceOneSymmetric` (迹为 1 的对称矩阵) 里、直径等于 `Real.sqrt 2`, 并且 `¬ HasTenSmallCover`, 即不存在 10 块直径都小于 $\sqrt{2}$ 的覆盖。

怎么看 (推测): 它和本节的平面着色结果用的是同一种思路: 不再去找更大的有限点集, 而是换成一个漂亮的连续对象 (这里是 $\mathbb{R}^4$ 中所有直线组成的空间, 即实射影空间 $\mathbb{RP}^3$), 再用拓扑或分析把它排除掉。

9.11 自测题

读完后试着回答。如果答不上来, 回到对应小节再读一遍。

1. 为什么在平面上找到一个不能 k 着色的有限点集, 就能推出 $\chi(\mathbb{R}^2) > k$? (§9.2.2)
2. 用三句话复述 Moser 菱形对为什么证明了 3 色不够。 (§9.3)
3. 六边形 7 着色里, $r = 2/5$ 满足了哪两个不等式? 分别保证了什么? (§9.4)
4. de Bruijn–Erdős 定理说了什么? 为什么它保证了有限 6 色图存在, 却不帮你找到它? (§9.5.4)
5. Falconer 1981 年就证明了"5", 为什么 de Grey 2018 年的"5"仍然是突破? (§9.6.2)
6. OpenAI 证明的两半分别是什么? 哪一半对所有颜色数 k 都成立? (§9.8.2)
7. Reed 的"形式化定理"和 OpenAI 的 `no_proper_five_coloring` 在可信度上的根本区别是什么? (§9.8.5、§9.9.4)
8. 为什么说 Borsuk 问题和平面着色是"近亲"? OpenAI 的 9 维反例是什么集合, 为什么它落在 9 维空间里? (§9.10.4)

附:【检查】答案

- **检查 1:** 3 色。2 色时颜色只能沿着环交替出现 (红蓝红蓝.....), 奇数长度的环走一圈回到起点时, 起点要和自己的邻居同色, 矛盾。一般地, 图能 2 着色当且仅当它没有奇数长度的圈。
- **检查 2:** T 和 T_2 到 O 的距离都是 $\sqrt{3}$, 夹角 θ 。余弦定理: $|T - T_2|^2 = 3 + 3 - 2 \cdot \sqrt{3} \cdot \sqrt{3} \cdot \cos \theta = 6 - 6\cos \theta$ 。 $\cos \theta = 5/6$ 时等于 $6 - 5 = 1$, 距离为 1。
- **检查 3:** $2r < 1 \Rightarrow r < 1/2$; $(\sqrt{21} - 2)r > 1 \Rightarrow r > 1/(\sqrt{21} - 2) \approx 0.3872$ (脚本实算)。所以 $0.3872 < r < 0.5$, 论文取的 $r = 0.4$ 在范围内。

附: 术语表

术语	一句话解释
合法着色	相邻顶点颜色不同的涂法
色数 $\chi(G)$	合法着色最少需要的颜色数

术语	一句话解释
单位距离图	顶点是平面上的点，距离恰好为 1 的两点连边
$\chi(\mathbb{R}^2)$	平面单位距离图的色数，即 Hadwiger–Nelson 问题的答案
Moser 菱形对	7 点 11 边的单位距离图，不能 3 着色，证明 $\chi \geq 4$
de Bruijn–Erdős 定理	无穷图能 k 着色 $\Leftrightarrow$ 每个有限子图都能 k 着色（需选择公理）
SAT 求解器	判断一组布尔约束能否同时满足的程序，用来验证有限图不能 k 着色
可测集合	有合理"面积"的集合
可测色数 χ_m	要求颜色块都可测时的最少颜色数；Falconer 证明 ≥ 5
选择公理	总能从无穷多个非空集合里各挑一个元素；能造出不可测集合
弱可测着色	颜色块可测，同色单位点对的测度为零（允许零测度例外）
可顺从（amenable）	一个群上"能公平地取平均"的性质
遍历论	研究"长期平均"和不变统计规律的数学分支
Haar 测度	群上完全均匀的分布；对应"纯噪声"
调色板（palette）	某点周围单位圆上出现的颜色集合

附：想继续深入

- **原始论文**：<https://github.com/openai/math/blob/main/preprints/The-Euclidean-plane-is-not-five-colorable-September-23-2026/paper.pdf>（先读第 1 节和 §1.1 的 Figure 1，其余是技术细节）
- **Lean 陈述**：
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/EuclideanFiveColor.lean>
 ；范围说明 [lean/docs/158.md](#)
- **Gil Kalai 2026-10-07 博客**：<https://gilkalai.wordpress.com/2026/10/07/updates-sharing-ai-progress-on-mathematics-amazing-and-my-lecture-plans/>
- **Gil Kalai 2018 年对 de Grey 的介绍**（入门最好的一篇）：
<https://gilkalai.wordpress.com/2018/04/10/aubrey-de-grey-the-chromatic-number-of-the-plane-is-at-least-5/>
- **de Grey 2018**：<https://arxiv.org/abs/1804.02385>；**Heule 553 点**：
<https://arxiv.org/abs/1805.12181>；**Parts 人工可验证证明**：<https://arxiv.org/abs/2010.12661>
- **Quanta Magazine**, *Decades-Old Graph Problem Yields to Amateur Mathematician*（2018-04，关于 de Grey 的通俗报道）
- **Alexander Soifer**, *The Mathematical Coloring Book*（Springer, 2009；2024 第二版）：这个问题的完整历史，包括 Shelah–Soifer 和选择公理那几章（"What If We Had No

Choice?")。

- **Shelah & Soifer**, *Axiom of choice and chromatic number of the plane*, J. Combin. Theory Ser. A 103 (2003) 387–391。
- **Payne**, *Unit distance graphs with ambiguous chromatic number*:
<https://arxiv.org/abs/0707.1177>
- **Sokolov & Voronov**, 地图式涂法至少 7 色: <https://arxiv.org/abs/2502.01958>
- **Terence Tao**, *254A Lecture 9: Ergodicity* (论文引用的遍历论入门):
<https://terrytao.wordpress.com/2008/02/04/254a-lecture-9-ergodicity/>
- **Borsuk 9 维反例 (family 156)**: 论文
<https://github.com/openai/math/blob/main/preprints/A-nine-dimensional-counterexample-to-Borsuks-covering-assertion-September-23-2026/paper.pdf> ; Lean 陈述
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/BorsukNine.lean> ;
范围说明 `lean/docs/156.md`
- **Jenrich & Brouwer**, 64 维反例: <https://arxiv.org/abs/1308.0206> ; **Grinsztajn**, *A 63-dimensional counterexample to Borsuk's conjecture* (作者手稿, 2026-05, OpenAI 论文的参考文献 [7]; $\triangle$ 我没有找到公开链接); **Yibo Ji**, 另一个 63 维反例:
<https://arxiv.org/abs/2608.12561> ; **Kalai**, *Some old and new problems in combinatorial geometry I: Around Borsuk's problem* (Surveys in Combinatorics 2015); 综述:
https://en.wikipedia.org/wiki/Borsuk%27s_conjecture

群论 · FAMILY 248

10. Thompson 群 F 不可顺从: 一个"证明了又撤回"了几十年的问题

群论 · openai/math 发布中的 family 248。前提只需要：会做分数运算、知道什么是函数和函数复合 $f(g(x))$ 、知道向量的长度和内积。**不需要任何群论**，凡是用到的新概念都会先讲。文中所有数字都由脚本实算（`精讲/scripts/07_thompson.py`，用 Python 的 `Fraction` 精确计算）或有出处；【检查】是可以自己动手算的小练习，答案在章末。标记：**[P]** = 读过的一手材料（论文 PDF、Lean 文件、arXiv 原稿及撤回说明）；**[R]** = 二手报道或转述； $\triangle$ = 未核实或有冲突。截至 2026-10-08。预计阅读时间：60–90 分钟。可以分三次读：§10.1–10.3（群、自由群、“公平平均”）、§10.4–10.5（Banach–Tarski、Thompson 群本身）、§10.6–10.9（OpenAI 的证明、核实和意义）。

10.0 先说结论：这一章要讲明白的一件事

有些无限的“操作集合”（数学上叫**群**）上，可以定义一种**公平的平均**：整体挪一下，平均值不变。整数就可以。另一些群上则**不可能**有这种平均，最典型的是“自由群”，它不能公平平均的

原因是：它可以被切开、挪一挪，拼成**两份**自己。这件事就是著名的 Banach–Tarski 悖论（一个球切成几块拼成两个球）背后的机制。

数学家很长时间以为"不能公平平均"总是因为群里藏着一个自由群。1980 年起这被反例推翻，但 Thompson 群 F 这个最自然、最有名的候选者，一直没人能判定：它不含自由群，却又不属于任何"显然能平均"的类型。1979 年 Geoghegan 猜它**不能**平均。此后 47 年，两个方向都有人宣布过证明，又一个个被发现错了、撤回。

这一章要讲清楚的是一条因果链：

F 能公平平均 $\Rightarrow F$ 里有"几乎不漏"的有限集合 (Følner 集) $\Rightarrow$ 在这样的集合上取平均，能给一个"把每个点都推开至少 $\frac{1}{2}$ "的映射造出近似不动点 $\Rightarrow$ 矛盾。所以 F 不能公平平均。

OpenAI 在 2026-09-23 的一篇 13 页论文里给出了这个论证，并且有 Lean 形式化。

读完这一章，你应该能用自己的话讲出：

- "可顺从" (amenable) 到底是什么意思，为什么它和 Banach–Tarski 悖论是一回事；
- Thompson 群 F 的两个生成元长什么样，能手算它们的复合；
- 为什么 F 是这个领域最有名的"试金石"，以及它的历史为什么让 Lean 验证格外有价值；
- OpenAI 的证明用的是哪个"借来的"现象（无穷维空间里没有不动点的映射），以及这个结果意味着什么、不意味着什么。

10.1 群：一组可以复合、可以撤销的操作

10.1.1 先看一个具体的例子：正方形的对称

拿一张正方形卡片，四个角标上 A、B、C、D。有哪些操作能把它放回原来的轮廓里（角的标签可以换位置）？

- 转 0° 、 90° 、 180° 、 270° （4 个旋转）；
- 沿竖直轴、水平轴、两条对角线翻转（4 个翻转）。

一共 8 个操作。脚本从"转 90° （记为 r ）"和"沿竖直轴翻（记为 s ）"出发，反复组合，恰好生成了这 8 个，不多不少。

这 8 个操作有几个性质：

1. **可以复合**：先做一个、再做一个，结果还是这 8 个之一。记 $r \circ s$ 为"先 s 后 r "（和函数复合 $f(g(x))$ 的顺序一致，右边的先做）。
2. 有"什么都不做"：转 0° ，记为 e （单位元）。
3. **每个操作都能撤销**：转 90° 的撤销是转 270° ；每个翻转的撤销是它自己。
4. **结合律**： $(a \circ b) \circ c = a \circ (b \circ c)$ 。函数复合天然满足。

但**顺序有关系**：脚本实算， $r \circ s$ 和 $s \circ r$ 把四个角送到不同的位置（一个让 A、C 互换，一个让 B、D 互换）。所以群一般**不可交换**。

10.1.2 第二个例子：整数加法

所有整数 $\mathbb{Z} = \{\dots, -2, -1, 0, 1, 2, \dots\}$ ，"操作"是"加上某个数"。复合就是相加，单位元是 0，撤销 +3 的是 -3。这是一个**无限群**，而且可交换。

10.1.3 定义

群 = 一个集合 G ，加上一种把两个元素合成一个的运算，满足：有单位元、每个元素有逆、满足结合律。

你可以一直把群想成"某个对象的全部对称操作"。这一章所有的群都是这种情况：正方形的对称、整数的平移、 $[0,1]$ 区间的某些拉伸 (§10.5)。

10.1.4 生成元和关系

很多群可以由**少数几个操作**拼出全部元素，这几个操作叫**生成元**。

- 正方形的 8 个对称由 r 和 s 生成。
- $\mathbb{Z}$ 由 "+1" 一个元素生成（-1 是它的逆，任何整数都是若干个 +1 或 -1 拼起来）。

生成元之间往往有**关系**，例如正方形里 $r \circ r \circ r \circ r = e$ （转四次回到原位）、 $s \circ s = e$ 。关系让不同的"拼法"得到同一个元素。

10.2 自由群 F_2 ：没有任何关系的群

10.2.1 约化词

取两个生成元 a 、 b ，以及它们的逆 a^{-1} 、 b^{-1} （下面也写作 A 、 B ）。**自由群 F_2** 的元素就是由这四个字母拼成的"词"，唯一的化简规则是：相邻的 a 和 a^{-1} （或 b 和 b^{-1} ）可以抵消。抵消完的词叫**约化词**。除此之外**没有任何关系**： $abab^{-1}$ 和 $baba^{-1}$ 是不同的元素， ab 和 ba 也不同。

数一数长度为 n 的约化词有多少个：第一个字母有 4 种选择；之后每个字母不能是前一个字母的逆，所以有 3 种选择。于是长度为 n 的词有 $4 \cdot 3^{n-1}$ 个。

长度 n	长度恰为 n 的词 ("球面")	长度 $\leq n$ 的词 ("球")	球面 / 球
0	1	1	1.000
1	4	5	0.800
2	12	17	0.706
3	36	53	0.679
5	324	485	0.668
10	78,732	118,097	0.667

(脚本逐个枚举约化词计数。球的大小 $= 2 \cdot 3^n - 1$ 。)

两个要点：

- 元素个数随 n **指数增长** (大约 $2 \cdot 3^n$)。对比： $\mathbb{Z}$ 里长度 $\leq n$ 的元素只有 $2n+1$ 个； $\mathbb{Z}^2$ 里 (用 L1 距离) 只有 $2n^2+2n+1$ 个， $n=10$ 时是 221。
- **最外层占了全部的约 2/3**，而且这个比例不随 n 变小。 $\mathbb{Z}$ 的最外层只有 2 个点，占比 $2/(2n+1) \rightarrow 0$ 。

【检查 1】长度恰为 2 的约化词有 12 个。把它们全部写出来 (提示：aa, ab, aB, ...)。

10.2.2 Cayley 图：把群画出来

把群的每个元素画成一个点；如果 g 右乘一个生成元得到 g' ，就在 g 和 g' 之间连一条边。这张图叫 **Cayley 图**。

- $\mathbb{Z}$ (生成元 $+1$)：一条无限长的直线。
- $\mathbb{Z}^2$ (生成元 $(1,0)$ 、 $(0,1)$)：无限的方格网。
- F_2 (生成元 a 、 b)：一棵**每个点都分出 4 条边的无限树**。因为没有关系，从原点出发走不同的路永远不会回到同一点，所以没有圈。

用网络的语言说： $\mathbb{Z}^2$ 像二维网格，节点数随半径多项式增长； F_2 像 4 叉扩散树，**大部分节点都在边缘**。这个性质是下面一切的关键。

10.3 可顺从：能不能"公平地取平均"

10.3.1 问题从哪里来

在有限群上取平均很简单：把每个元素的值加起来除以元素个数。这个平均是"公平的"：把整个群挪一下 (每个元素都左乘同一个 h)，只是换了个顺序加，平均值不变。

在无限群上就麻烦了。 $\mathbb{Z}$ 上没有"均匀分布"：每个整数的概率都相同，就只能是 0，加起来不是 1。

数学家的办法是放宽要求，只要一个**均值** (mean)：一个给每个有界函数 $\phi: G \rightarrow \mathbb{R}$ 打一个分数 $M(\phi)$ 的规则，满足

1. **线性**： $M(\phi + \psi) = M(\phi) + M(\psi)$ ， $M(c\phi) = c \cdot M(\phi)$ ；
2. **正**： ϕ 处处 ≥ 0 时， $M(\phi) \geq 0$ ；
3. **归一**：常数函数 1 的均值是 1；
4. **左不变**：把函数整体挪一下 (ϕ 换成 $g \mapsto \phi(hg)$)，均值不变。

如果一个群上存在这样的 M ，就叫它**可顺从** (amenable)；否则叫**不可顺从**。这正是 OpenAI 论文和 Lean 陈述里使用的定义 (见 §10.7)。

直观上，M 是"在整个群上均匀撒一把沙子"的理想化。只要求**有限可加**（不要求可数可加），这才使得 $\mathbb{Z}$ 这样的群有机会满足。

10.3.2 Følner 判据：找一个"几乎不漏"的有限集合

上面的定义很抽象（M 一般写不出来，存在性要用选择公理）。Følner 1955 年给了一个等价的、组合味的判据：

群 G 可顺从 $\iff$ 对任意有限个"挪动" h 和任意小的 $\epsilon > 0$ ，都能找到一个有限集合 A，使得 $|hA \Delta A| / |A| < \epsilon$ 。

这里 $hA = \{h \cdot a : a \in A\}$ 是 A 整体挪一下的结果， Δ 是"对称差"（只在一边出现的元素）。 $|hA \Delta A| / |A|$ 衡量"挪一下之后，有多大比例的元素变了"。直觉是：如果 A 挪一下几乎不变，在 A 上取平均就近似于一个公平的平均；让 A 越来越大、越来越"不漏"，取极限就得到 M。

脚本实算：

群	集合 A	A	挪动 h	$ hA \Delta A / A $
$\mathbb{Z}$	$\{-n, \dots, n\}$, $n=10$	21	+1	0.0952
$\mathbb{Z}$	$n=1000$	2,001	+1	0.0010
$\mathbb{Z}^2$	$(2n+1) \times (2n+1)$ 方块, $n=10$	441	(1,0)	0.0952
$\mathbb{Z}^2$	$n=100$	40,401	(1,0)	0.0100
F_2	长度 ≤ 4 的球	161	a	1.006
F_2	长度 ≤ 10 的球	118,097	a	1.000

$\mathbb{Z}$ 和 $\mathbb{Z}^2$ 的比例 $\rightarrow 0$ ，所以可顺从。 F_2 的球挪一下，比例**趋于 1**：大约一半的元素跑出去了、同样多的新元素跑进来（ $|hA \Delta A|$ 把两边都算上）。原因就是§10.2 说的"大部分元素都在边缘"。

【检查 2】 $\mathbb{Z}$ 上 $A = \{-n, \dots, n\}$ ， $h = +1$ 。 $hA \Delta A$ 是哪两个元素？由此验证比例 $= 2/(2n+1)$ 。

10.3.3 但"球不行"不等于"所有集合都不行"

上表只试了球。Følner 判据要求的是**存在某个 A**。原则上 F_2 里可能有某个形状古怪的集合比球好得多。要证明 F_2 不可顺从，需要一个对**所有集合**都成立的论证。最干净的是下面这个。

F_2 可以拼成两份自己。记 $W(a) =$ "以 a 开头的约化词"，类似定义 $W(a^{-1})$ 、 $W(b)$ 、 $W(b^{-1})$ 。那么：

- $F_2 = \{e\} \cup W(a) \cup W(a^{-1}) \cup W(b) \cup W(b^{-1})$ ，五块互不相交。
- 但 **$W(a) \cup a \cdot W(a^{-1})$ 已经是整个 F_2** ：任何不以 a 开头的词 w，在前面补一个 a^{-1} 后， $a^{-1}w$ 以 a^{-1} 开头（不会被抵消），而 $w = a \cdot (a^{-1}w)$ 。
- 同理 $W(b) \cup b \cdot W(b^{-1})$ 也是整个 F_2 。

(脚本对长度 ≤ 7 的所有词检查了这两条, 全部成立; 长度 ≤ 8 的球里, 四块 W 各有 3,280 个词。)

现在假设 F_2 上有一个公平均值 M 。把"属于某集合"看作取值 0/1 的函数, M 给每块一个"份额"。由左不变性, $a \cdot W(a^{-1})$ 的份额等于 $W(a^{-1})$ 的份额。于是:

- $M(W(a)) + M(W(a^{-1})) \geq M(\text{整个 } F_2) = 1$;
- $M(W(b)) + M(W(b^{-1})) \geq 1$;
- 加起来四块的份额 ≥ 2 , 但它们是 F_2 的互不相交的一部分, 总份额 ≤ 1 。矛盾。

所以 **F_2 不可顺从**。这个"用几块拼出两份自己"叫**悖论分解** (paradoxical decomposition)。Tarski 1938 年证明了: 一个群不可顺从, **当且仅当它有悖论分解**。所以"不能公平平均"和"能复制自己"是同一件事的两面。

另外: 一个群含有不可顺从的子群, 它自己也不可顺从 (这是标准事实)。所以任何含 F_2 的群都不可顺从。

10.4 Banach–Tarski 悖论和 von Neumann 的问题

10.4.1 悖论

Banach–Tarski (1924): 三维空间里一个实心球, 可以切成有限多块, 只靠旋转和平移, 重新拼成**两个**和原来一样大的实心球。

这不违反物理, 因为切出来的块是不可测的"怪集合" (需要选择公理), 没有体积可言。它的数学根源正是§10.3.3 的悖论分解: 三维旋转群 $SO(3)$ 里**藏着一个 F_2** (取两个绕不同轴、转角选得合适的旋转, 它们之间没有任何关系)。把 F_2 的"一份变两份"搬到球面上, 就得到悖论。

10.4.2 von Neumann 1929

von Neumann 问: 为什么三维有这种悖论, 二维 (平面) 没有? 他的回答是: **关键不在空间, 而在操作群**。平面的旋转和平移构成的群是可顺从的, 可以在上面公平平均, 于是平面上能定义一个"有限可加、在运动下不变"的面积, 悖论不可能发生; 三维的运动群含 F_2 , 不可顺从, 悖论就有了空间。"可顺从"这个概念 (德文 messbar, 英文 amenable 是 Day 后来起的名字) 就是这样诞生的。

10.4.3 von Neumann–Day 问题

既然"含 $F_2 \Rightarrow$ 不可顺从", 自然要问反过来:

不可顺从的群, 是否一定含 F_2 ?

这通常叫 von Neumann 问题或 von Neumann–Day 问题 (Day 1957 年明确提出)。答案是否, 但反例来得很艰难:

年份	作者	反例	特点
1980	Ol'shanskii	"Tarski 怪物"群	无限群，但每个真子群都是有限循环群；构造极其复杂
1982	Adyan	大奇数指数的自由 Burnside 群	每个元素的某个固定次方都是单位元
2002	Ol'shanskii–Sapir	有限表示的反例	第一个能用有限个生成元和有限条关系写下的反例
2013	Monod	实直线上的"分段射影"同胚群	第一批"自然"的反例，长得很像 Thompson 群
2016	Lodha–Moore	Monod 群的一个有限表示子群	有限表示、 无挠 （没有有限阶元素）

（Monod: *Groups of piecewise projective homeomorphisms*, PNAS 2013; Lodha–Moore: *A nonamenable finitely presented group of piecewise projective homeomorphisms*, Groups Geom. Dyn. 10 (2016) 177–200。）

注意：常见的说法是"反例都很怪，F 将是第一个自然的反例"。这在 2013 年以前是对的；**2013 年后 Monod 和 Lodha–Moore 已经给出了自然的、有限表示且无挠的反例**。所以 F 的意义不是"第一个自然反例"，而是"**这个领域最著名、被研究最多的那个群终于有了答案**"。

10.5 Thompson 群 F

10.5.1 定义

F = 所有满足以下条件的函数 $f: [0,1] \rightarrow [0,1]$ ：

1. 连续、严格递增， $f(0) = 0$ ， $f(1) = 1$ ；
2. **分段线性**，只有有限个断点；
3. 断点的横坐标都是**二进有理数**（形如 $k/2^n$ ，例如 $1/2$ 、 $3/4$ 、 $5/8$ ）；
4. 每一段的**斜率都是 2 的整数次幂**（..., $1/4$, $1/2$, 1 , 2 , 4 , ...）。

群运算是函数复合。

可以验证：两个这样的函数复合后还是这样的函数；逆函数（把图像沿对角线翻过来）也是。所以 F 确实是一个群。它是无限群：比如把 $[0,1]$ 往左压的程度可以任意大。

F 由 Richard Thompson 1965 年引入（最初是为了逻辑学里的问题），McKenzie–Thompson 1973 年给出早期发表的构造；Cannon–Floyd–Parry 1996 年的综述 *Introductory notes on Richard Thompson's groups* 是标准入门文献。

10.5.2 两个生成元，具体写出来


x_0 ：断点 $(0,0) \rightarrow (1/2,1/4) \rightarrow (3/4,1/2) \rightarrow (1,1)$ 。

区间	映到	斜率
$[0, \frac{1}{2}]$	$[0, \frac{1}{4}]$	$\frac{1}{2}$
$[\frac{1}{2}, \frac{3}{4}]$	$[\frac{1}{4}, \frac{1}{2}]$	1
$[\frac{3}{4}, 1]$	$[\frac{1}{2}, 1]$	2

直观上：把左半段压缩一半，把最右的四分之一拉长一倍，中间平移。整体效果是把点"往左推"。

下图左边就是 x_0 的图像：三段折线都在虚线 $y = x$ 下方，所以每个内部点都被往左推。右边回顾§10.3: "能否公平平均"在 $\mathbb{Z}$ 和 F_2 上的对比。


左：Thompson 群 F 的生成元 x_0 · 右："能否公平取平均"的直觉



$\mathbb{Z}$: 可顺从

$A = \{-n, \dots, n\}$ 平移 +1 只变 2 个元素: $2/(2n+1) \rightarrow 0$

自由群 F_2 : 不可顺从



半径 n 的球约 3^n 个点, 约 $2/3$ 在边界 (红) 上: 比例不趋于 0

x_0 把 $[0, \frac{1}{2}]$ 压到 $[0, \frac{1}{4}]$ 、 $[\frac{1}{2}, \frac{3}{4}]$ 平移到 $[\frac{1}{4}, \frac{1}{2}]$ 、 $[\frac{3}{4}, 1]$ 拉到 $[\frac{1}{2}, 1]$; F 由 x_0 和 x_1 两个元素生成。 F 不含自由群 F_2 (Brin–Squier 1985), 所以"含 $F_2 \Rightarrow$ 不可顺从"这把标准钥匙对它没用——这正是这个问题拖了 47 年的原因之一。

x_1 : 在 $[0, \frac{1}{2}]$ 上什么都不做; 在 $[\frac{1}{2}, 1]$ 上做一个"缩小版的 x_0 ". 断点 $(0,0) \rightarrow (\frac{1}{2}, \frac{1}{2}) \rightarrow (\frac{3}{4}, \frac{5}{8}) \rightarrow (\frac{7}{8}, \frac{3}{4}) \rightarrow (1,1)$, 斜率依次是 1、 $\frac{1}{2}$ 、1、2。

Cannon–Floyd–Parry 证明了: F 的每个元素都能由 x_0 、 x_1 和它们的逆拼出来。

10.5.3 手算复合

用分数精确计算 (脚本核对):

- $x_0(3/8)$: $3/8$ 落在 $[0, \frac{1}{2}]$, 斜率 $\frac{1}{2}$, 结果 $3/16$ 。
- $x_0 \circ x_1$ (先 x_1 后 x_0) 的断点: $(0,0) \rightarrow (\frac{3}{4}, \frac{3}{8}) \rightarrow (\frac{7}{8}, \frac{1}{2}) \rightarrow (1,1)$, 斜率 $\frac{1}{2}$ 、1、4。
- $x_1 \circ x_0$ (先 x_0 后 x_1) 的断点: $(0,0) \rightarrow (\frac{1}{2}, \frac{1}{4}) \rightarrow (\frac{7}{8}, \frac{5}{8}) \rightarrow (15/16, \frac{3}{4}) \rightarrow (1,1)$, 斜率 $\frac{1}{2}$ 、1、2、4。
- 两者不同, 所以 F **不可交换**。具体例子: $x_1(x_0(7/8)) = 5/8$, $x_0(x_1(7/8)) = 1/2$ 。

- x_0^{-1} 的断点: $(0,0) \rightarrow (1/4,1/2) \rightarrow (1/2,3/4) \rightarrow (1,1)$, 斜率 2、1、 $1/2$ (就是把 x_0 的每个断点坐标对调)。

【检查 3】算 $x_0 \circ x_0$ 的断点和斜率。(提示: 先算 $x_0(1/2)$ 和 $x_0(3/4)$, 再把它们代进 x_0 ; 还要找出哪个点被第一次 x_0 送到了 $3/4$ 。)

10.5.4 关系：为什么 F 不是自由群

F 有关系。最直观的一条来自"支撑不相交的函数可以交换": 如果 f 只在 $[0, 3/4]$ 上动, g 只在 $[3/4, 1]$ 上动, 那先做哪个都一样。

脚本实算：

- $u = x_0 \circ x_1^{-1}$ 的断点是 $(0,0) \rightarrow (1/2,1/4) \rightarrow (3/4,3/4) \rightarrow (1,1)$, 在 $[3/4, 1]$ 上是恒等。
- $v = x_0^{-1} \circ x_1 \circ x_0$ 的断点是 $(0,0) \rightarrow (3/4,3/4) \rightarrow (7/8,13/16) \rightarrow (15/16,7/8) \rightarrow (1,1)$, 在 $[0, 3/4]$ 上是恒等。
- 所以 u 和 v 交换: $u \circ v = v \circ u$ 。脚本检查了 $u^{-1}v^{-1}uv = \text{恒等}$, 成立; 把 v 换成 $x_0^{-2} \circ x_1 \circ x_0^2$ 也成立。

这两条就是 F 的**全部**定义关系 (Cannon–Floyd–Parry): F 由 2 个生成元、2 条关系**有限**表示。

关系让球变小了。用 x_0 、 x_1 及其逆做生成元, 数一数长度 $\leq n$ 的不同元素 (脚本用精确断点去重):

n	F 的球	F_2 的球
1	5	5
4	161	161
5	475	485
6	1,381	1,457
8	11,237	13,121

前 4 层一模一样, 第 5 层开始少了 10 个。原因是: 最短的关系 $u^{-1}v^{-1}uv$ 长度是 $2+3+2+3 = 10$, 所以两个长度为 5 的不同词第一次可能代表同一个元素。F 仍然是指数增长 (第 8 层仍有 7,280 个新元素), 但指数增长本身不决定可顺从性 (有些指数增长的群是可顺从的)。

10.5.5 为什么 F 是这个领域的试金石

两个标准工具在 F 上**都失效**:

- "含 $F_2 \Rightarrow$ 不可顺从"用不上: Brin–Squier 1985 年证明 F 不含任何非交换的自由子群 (Inventiones 79)。

- "由交换群和有限群拼出来 $\Rightarrow$ 可顺从"也用不上：F 不是"初等可顺从"群（Cannon–Floyd–Parry 定理 4.10）。

所以 F 落在两种标准判定方法的缝里。再加上它定义简单、性质很好（Brown–Geoghegan 1984 年证明它有很强的有限性），它成了 von Neumann–Day 问题之后最受关注的单个群。Geoghegan 1979 年猜想 F **不可顺从**（记录在 Cannon–Floyd–Parry 1996 第 227 页）。

历史上的声称与撤回（以下每条都有一手来源 [P]：arXiv 原稿和作者的撤回说明）：

时间	声称	方向	结局
2009-02	Akhmedov, arXiv:0902.3849	不可顺从	作者撤回（v8, 2013-12, 指向新稿 1310.4395）
2009-06	Shavgulidze, arXiv:0906.0107（相关论文已在期刊发表）	可顺从	Moore 2011（arXiv:1102.0747）列出具体的错误，写道认真研究过的人有共识："the errors are serious and do not seem to be repairable", 并指出 Math Reviews 上的书评不准确
2011-12	Beklaryan, arXiv:1112.1942	不可顺从	作者 2012-11 撤回，理由是 "a crucial error in Theorem B*"
2012-09	Justin Moore , arXiv:1209.2063	可顺从	作者 2012-10-01 撤回："Azer Akhmedov pointed out a serious error in Lemma 4.13. This error appears to be both serious and irreparable."
2013/2021	Akhmedov, arXiv:1310.4395v3	不可顺从	OpenAI 论文只说它"claims"; $\triangle$ 我没有找到它被社区接受的证据，问题在 2026 年前普遍被列为开放

同时也有扎实的部分结果，例如 Moore 2013 证明：**如果** F 可顺从，它的 Følner 集合必须大得惊人（"塔型"增长，*Groups Geom. Dyn.* 7）。

注意 Moore 的撤回：他是这个问题上最权威的专家之一，仍然在三周内的同行检查中被发现了致命错误。这是理解"为什么这个结果配上 Lean 很重要"的关键背景。

10.6 OpenAI 声称了什么

10.6.1 主结果 [P]

论文 *Thompson's group F is nonamenable*（署名 OpenAI, openai/math 发布中的 family 248, 2026-09-23, **全文含附录只有 13 页**：证明在第 1–7 页，第 8–11 页是附录，第 12–13 页是参考文献）。摘要全文：

"We prove that Thompson's group F is nonamenable. This confirms Geoghegan's conjecture and resolves the amenability problem for F."

主定理：**Theorem 1.1. Thompson's group F is not amenable.**

论文第 1 页如实列出了上面那些失败的历史声称，并特意说明 Moore 撤回的是另一篇论文，不是他发表的 Ramsey 刻画。

10.6.2 借来的工具：一个"处处推开"的映射

先回忆一个经典定理。

Brouwer 不动点定理：在有限维的闭球（线段、圆盘、实心球……）上，任何连续映射 f 都至少有一个不动点 $f(x) = x$ 。直觉：你没法把一个圆盘连续地揉一揉、放回圆盘里，同时让每个点都挪了位置。

在无穷维空间里这条定理失效。无穷维的例子是 ℓ^2 ：所有平方和有限的无穷序列 $(x_1, x_2, x_3, \dots)$ ，长度是 $\sqrt{x_1^2 + x_2^2 + \dots}$ 。Kakutani 的经典例子：

$$f(x) = (1 - \|x\|, x_1, x_2, x_3, \dots) \quad (\text{把序列右移一格，在开头补上 } 1 - \|x\|)$$

它把单位球映到单位球里，而且**没有不动点**（不动点要求所有坐标相等，又要平方和有限，只能全是 0，但那样开头一格是 1，矛盾）。

但这个例子不够强：它的"挪动距离"可以**任意小**。脚本实算：取 $x = (t, t, \dots, t)$ (N 个坐标)， $t = 1/(1+\sqrt{N})$ ，则 $f(x) - x$ 只在第 $N+1$ 个坐标上是 t ：

N	挪动距离 $\ f(x) - x\ $
1	0.500
100	0.091
10^4	0.0099
10^6	0.0010

所以 Kakutani 的 f 有"近似不动点"。

Benyamini–Sternfeld (1983) 证明了更强的事：在任何无穷维赋范空间的单位球上，存在一个 **Lipschitz** 映射 f （不会把两点拉开超过 L 倍），使得**每个点都被挪动至少 $\delta > 0$** 。这样的 f 连近似不动点都没有。OpenAI 论文的附录 A 在 $L^2([0,1]; \mathbb{R}^2)$ 上自己构造了一个 $\delta = \frac{1}{2}$ 的版本（用一条无穷维空间里的曲线和它周围的"管子"），并且附录里每一个 Lipschitz 估计都写出来了。

10.6.3 证明的骨架 (§10.2, 约 5 页)

整体策略一句话：**如果 F 有几乎不漏的有限集合 A ，那么在 A 上取平均，能给上面那个 f 造出近似不动点。**这与"每个点都被挪动至少 δ "矛盾。

分五步，尽量用直觉讲：

1. **给 $[0,1]$ 的"二进划分"涂颜色。**一个划分就是把 $[0,1]$ 切成若干个 $[k/2^i, (k+1)/2^i]$ 形的小格。事先选好 D 个互不相邻的"父区间" $I_1 < \dots < I_D$ 。对一个划分 T ，看它在每个父区间里的部分，拉伸回 $[0,1]$ 得到一个更小的划分 $T_{\{I_j\}}$ 。递归定义 T 的"颜色"（单位球里的一个向量）：

$$\begin{aligned} p(T) &= f((p(T_{\{I_1\}}) + \dots + p(T_{\{I_D\}})) / D) && \text{(如果 } T \text{ 在每个 } I_j \text{ 处都切得开)} \\ p(T) &= 0 && \text{(否则)} \end{aligned}$$

每次限制到子区间，格子数严格变少，所以递归一定终止。

1. **让 F 的元素产生划分。** F 的元素 g 把均匀划分的每个小格送到一个二进区间（论文 Lemma 2.1），于是每个 g 带来一族颜色： $X_i(g)$ 是第 i 个父区间的颜色， $Y_{ij}(g)$ 是第 i 个父区间里第 j 个"孙区间"的颜色。递归定义直接给出 **$X_i = f(z_i)$** ，其中 z_i 是 $Y_{i1}, \dots, Y_{iD}$ 的平均。再记 $m =$ 所有 X_i 的平均。

1. **F 能把任何一对分开的区间搬到任何另一对**（Lemma 2.2：中间的空隙用二进小格重新填满，按顺序一一对应地线性映射）。所以对任意两个分开的区间 $I < J$ ，都有一个 F 的元素 $h_{\{I,J\}}$ 把它们搬到参照对 (I_1, I_2) ，而且颜色跟着精确地搬过去。设 S 是这些 $h_{\{I,J\}}$ 组成的**有限集合**，它是事先固定好的，和 A 无关。

1. **用 Følner 集合取平均。**设 $\eta = A$ 在 S 下最大的漏出比例 $|hA \Delta A|/|A|$ 。在 A 上取平均时，"把 g 换成 hg "几乎不改变平均值，误差至多 η 。所以：**任意两个分开的区间，它们颜色的内积在 A 上的平均值，都和同一个常数 α 相差不超过 η 。**这就像说：在一个几乎平移不变的样本上，所有"分开的位置对"看起来都一样相关。

1. **方差估计，然后矛盾。**展开 $\|z_i - m\|^2$ 。它的内积项里，绝大部分是"分开的区间对"，平均值都约等于 α ，正负相互抵消；只有占比 $1/D$ 的"嵌套对"（孙区间和它自己的父区间）不受控制，但它们的内积绝对值至多 1。算下来（论文式 2.16）：

$$\text{在 } A \text{ 上平均的 } \|z_i - m\|^2 \leq 4/D + 4(1 - 1/D) \cdot \eta$$

另一方面， m 也是 $f(z_i)$ 的平均，用凸性和 Lipschitz 性：

$$\delta^2 \leq \|m - f(m)\|^2 \leq (L^2/D) \cdot \sum \|z_i - m\|^2$$

合起来： $\delta^2 \leq L^2 \cdot (4/D + 4(1-1/D) \cdot \eta)$ 。整理得到（Proposition 2.3）：

$$\eta \geq (6^2/L^2 - 4/D) / (4(1 - 1/D))$$

只要事先把 D 取得比 $4L^2/\delta^2$ 大，右边就是一个正数，而且和 A 无关。也就是说：**F 的每一个有限集合 A ，在这个固定的有限集 S 下，都至少漏掉一个固定的正比例。**这直接违反 Følner 判据，所以 F 不可顺从。

数值感觉（脚本实算， L 是假设值，论文没有给出附录映射 L 的具体数字 Δ ）： $\delta = 1/2$ 时需要 $D > 16L^2$ 。若 $L = 10$ ，取 $D = 3,200$ ，下界约 3.1×10^{-4} ；取 $D = 1,601$ （刚过门槛），下界约 3.9×10^{-7} 。这个比例很小，但证明只需要它是正数、而且与 A 无关。

这个证明为什么出人意料：之前的尝试大多在 F 本身的组合结构里找东西（树、图、Ramsey 性质、高度函数）。这里关键的“不可能性”来自**无穷维几何**， F 只负责提供“能把任意一对区间搬到任意一对”的灵活性，以及二进划分的自相似递归。

10.6.4 两个推论（依赖伴随论文）

论文第 3 节推出两个推论： F 有一个“几乎等距但不能被酉化”的表示（依赖 OpenAI 另一篇论文 *Unitarizability implies amenability for discrete groups*）； F 的 Cayley 图上的渗流有 $p_c < p_u$ （依赖另一篇关于渗流的 OpenAI 论文）。论文明确说这两个推论**不用于**主定理的证明。 Δ 这两篇伴随论文我们没有核实。

10.7 它被核实到什么程度

10.7.1 Lean 陈述：自己定义 F ，你可以逐行读懂

和 §4 的准黎曼猜想不同，这个陈述**不依赖 Mathlib 里现成的 F** （Mathlib 没有），而是在挑战文件 `ComparatorChallenges/ThompsonNonamenability.lean`（89 行，含 import）里从头定义了所有东西。核心是：

```
def IsDyadic (x : ℝ) : Prop := ∃ (k : ℤ) (n : ℕ), x = (k : ℝ) / (2 : ℝ) ^ n

structure DyadicPLWitness (f : IntervalHomeomorph) where
  pieceCount : ℕ -- 有几段
  knots : Fin (pieceCount + 1) → UnitInterval -- 断点列表
  strictMono_knots : StrictMono knots -- 断点从小到大
  first : knots 0 = 0; last : knots (最后) = 1
  dyadic : ∀ i, IsDyadic (knots i) -- 断点是二进有理数
  exponent : Fin pieceCount → ℤ -- 每段一个整数指数
  affine : ... (f x) = f(knot_i) + 2^(exponent i) * (x - knot_i) -- 每段斜率是 2 的幂
  ...

def F := {f : IntervalHomeomorph // StrictMono f ∧ HasDyadicPLPieces f}

structure InvariantMean (G) [Group G] where
```

```

toLinearMap : BoundedReal G →1[ℝ] ℝ      -- 线性
positive : ∀ f, (∀ g, 0 ≤ f g) → 0 ≤ toLinearMap f      -- 正
normalized : toLinearMap 1 = 1      -- 归一
left_invariant : ∀ h f, toLinearMap (leftPull h f) = toLinearMap f      -- 左不变

theorem thompson_F_nonamenable_composition :
  ∃ group : Group F, let I := group;
    (∀ (h g : F) (x : UnitInterval),
      (h * g).val.toHomeomorph x = h.val.toHomeomorph (g.val.toHomeomorph x)) ∧
    ¬ Nonempty (InvariantMean F)

```

(中间的定义略去了几行技术字段；完整文件在仓库里。)

逐词翻译：

- `IntervalHomeomorph`：[0,1] 到自身的同胚（连续、可逆、逆也连续）。
- `F`：满足"严格递增"且"有一份二进分段线性的证据"的同胚。这就是§10.5.1 的定义，一条不少。
- `BoundedReal G`：G 上的有界实函数（Mathlib 的 ℓ_∞ ）。`leftPull h f` 是函数 $g \mapsto f(hg)$ 。
- `InvariantMean`：§10.3.1 的四条：线性、正、归一、左不变。
- 定理说：**存在**一个 F 上的群结构，它的乘法**就是函数复合**（ $h * g$ 作用在 x 上等于 $h(g(x))$ ），并且在这个群结构下**不存在**不变均值。

为什么"存在一个群结构"不是漏洞：群的乘法一旦被规定为复合，单位元和逆元就被唯一确定了，所以这个"存在"只是"F 在复合下确实是群"的意思，没有作弊空间。乘法约定 $hg = h \circ g$ 也和论文一致。

我们的判断：陈述忠实于论文的定理 1.1 [P]。另外，Lean 证明里有一个文件

`StandardCharacterization.lean`，证明了挑战文件里的定义和"教科书式"的写法等价；还有 `MeanToFølner.lean`，在 Lean 里**自己证明了**"有不变均值 $\Rightarrow$ 有 Følner 集"这一方向，所以论文引用的 Følner 判据也被机器检查了，而不是当作公理。

10.7.2 证明本身

- 证明在 `lean/OAI/GroupTheory/Thompson/` 下，**68 个文件、9,457 行**（约 9,500 行；脚本对 snapshot fd4aeeb 实数）[P]。其中 22 个文件（名字以 `Analytic`、`Tube` 开头）在构造附录 A 的映射。
- `grep` 过：这个目录里没有 `sorry`、没有 `axiom` 声明、没有 `native_decide`。
- `Comparator` 配置只允许 Lean 的三条标准公理（`propext`、`Quot.sound`、`Classical.choice`），`enable_nanoda` 是 `false`（没有开启第二个独立内核复查）。
- **我们没有在本地编译，也没有运行 Comparator**。"Lean 已验证"目前是 OpenAI 的声称，加上我们对源码的静态检查。

- 和 §4 的准黎曼猜想不同：截至 2026-10-08，我们没有找到任何第三方独立跑通这个证明的公开记录（准黎曼猜想有 Dave Goldblatt 用 Comparator + nanoda 的独立复核）。△

10.7.3 人类专家 [R]

- Gil Kalai (2026-10-07 博文) 引用了他 2009 年介绍 Thompson 群的博文，并写道 "The new manuscript announces that Thompson's group (F) is nonamenable." 用的是 "announces" (宣布)，措辞中性。
- 群论学者 Xiaolei Wu (proofsandprompts.com 汇编)："So Thompson's group F is non-amenable. OK, I had tried it many times using ChatGPT, but I guess I didn't have the newest model or enough tokens."
- 截至 2026-10-08，没有找到 Geoghegan、Moore、Akhmedov 等核心人物的公开评论，也没有任何具名专家公开表示已读完并核实论文。△

10.7.4 剩余风险

1. **陈述风险很低**：挑战文件不到 90 行，只依赖 Mathlib 的标准对象（实数、同胚、 ℓ_∞ 、线性映射），定义可以逐行对照教科书。这是"人审陈述、机器审证明"分工的理想形态。
2. **编译和工具链风险**：我们没有自己编译；没有第二内核复查。这类风险通常很小，但不是零。
3. **论文与 Lean 的对应**：Lean 证明的是定理 1.1 本身，所以即使论文写法有瑕疵，主结论也不受影响。两个推论（6.4 节）不在 Lean 覆盖范围内。
4. **一个特殊的好消息**：这篇论文的核心证明只有约 5 页，用到的工具（Hilbert 空间内积、凸性、Lipschitz 估计、二进区间）都是标准的。和 199 页的准黎曼猜想论文 (§4) 相比，它是人类专家最有可能在短期内完整读懂并独立确认的头条结果之一。（这是推测。）

10.8 如果为真，意味着什么（以及不意味着什么）

10.8.1 对数学

1. 一个 47 年的问题（1979→2026）得到了解决，答案与 Geoghegan 的猜想一致：F 不可顺从。
2. F 成为 von Neumann–Day 问题最著名的反例：不可顺从，却不含 F_2 。但如 §10.4.3 所说，它不是第一个自然反例（Monod 2013、Lodha–Moore 2016 在前）。
3. **方法上的意外**：把"群上的平均"翻译成"无穷维单位球上的不动点问题"，再借 Benyamini–Sternfeld 这类泛函分析的反直觉现象得出矛盾。这条路线是否能用于其他群（例如其他分段线性/分段射影同胚群）是一个自然的开放问题。（推测。）
4. **它不意味着**：论文没有给出针对某个具体生成元集合的显式常数（Lean 文档 docs/248.md 原文："No explicit boundary constant or prescribed generating set is given."）；也没有回答 F 的其他著名问题。

10.8.2 对 AI 和"验证"这件事

这是"为什么 Lean 重要"的最佳案例，原因很具体：

- 这个问题的人类历史就是一串"宣布证明 → 被发现错误 → 撤回"，两个方向都有，最权威的专家也撤回过 (§10.5.5 的表)。按过去的经验，一篇新的 13 页声称，社区可能要几年才能形成共识。
- 有了 Lean，信任对象从"作者"换成了"内核 + 一份 89 行 (含 import)、能逐行审的陈述"。
- 同时它也提醒我们 Lean 不能做什么：它不能判断这个结果的**意义**，不能判断方法能否推广，也不能替代人类对"为什么成立"的理解。

对你 (AI 安全研究者) 来说，这个案例还有一层：这是一个"AI 在人类长期失败的问题上给出短证明，人类可以在短时间内复核"的样本。它和"AI 给出 48 万行、人类几乎无法复核的证明" (§4 的准黎曼猜想) 构成了**可监督性**光谱的两端。(推测，但值得记下来。)

10.9 自测题

读完后试着回答。如果答不上来，回到对应小节再读一遍。

1. 用一句话说明"可顺从"是什么意思。(§10.3.1)
2. 为什么 F_2 的球不是好的 Følner 集合？为什么这还不足以证明 F_2 不可顺从？ (§10.3.2–10.3.3)
3. $W(a) \cup a \cdot W(a^{-1}) = F_2$ 为什么能推出 F_2 上没有公平均值？ (§10.3.3)
4. Banach–Tarski 悖论在三维成立、在二维不成立，von Neumann 认为根本原因是什么？ (§10.4.2)
5. 为什么 F 落在"两种标准判定方法的缝里"？ (§10.5.5)
6. Kakutani 映射和 Benyamini–Sternfeld 映射都没有不动点，区别在哪里？为什么 OpenAI 的证明需要后者？ (§10.6.2)
7. Lean 陈述里"存在一个群结构"为什么不是漏洞？ (§10.7.1)

附：【检查】答案

- **检查 1**：aa, ab, aB, AA, Ab, AB, bb, ba, bA, BB, Ba, BA。aA、Aa、bB、Bb 不算，因为会抵消成空词。每个首字母后面有 3 种选择， $4 \times 3 = 12$ (脚本核对)。
- **检查 2**： $hA = \{-n+1, \dots, n+1\}$ ，和 A 相比多了 $n+1$ 、少了 $-n$ ，所以 $hA \Delta A = \{-n, n+1\}$ ，2 个元素，比例 $2/(2n+1)$ 。 $n=10$ 时是 $2/21 \approx 0.0952$ ，和表一致。
- **检查 3**： $x_0(1/2) = 1/4$ ， $x_0(3/4) = 1/2$ 。再做一次 x_0 ： $x_0(1/4) = 1/8$ ， $x_0(1/2) = 1/4$ 。还要找被第一次 x_0 送到 $3/4$ 的点： x_0 在 $[3/4, 1]$ 上是 $y = 1/2 + 2(x - 3/4)$ ，令 $y = 3/4$ 得 $x = 7/8$ 。所以 $x_0 \circ x_0$ 的断点是 **(0,0) → (1/2, 1/8) → (3/4, 1/4) → (7/8, 1/2) → (1,1)**，斜率 $1/4$ 、 $1/2$ 、**2**、**4** (脚本核对)。斜率仍然都是 2 的幂，断点仍然是二进有理数，所以它还在 F 里。

附：术语表

术语	一句话解释
群	一组可以复合、有单位元、每个元素可撤销的操作
生成元	能拼出整个群的少数几个元素
关系	生成元之间的等式，使不同的拼法代表同一元素
自由群 F_2	两个生成元、没有任何关系的群
Cayley 图	把群元素画成点、按生成元连边得到的图； F_2 的是 4 叉树
不变均值	给有界函数打分的规则：线性、正、归一、左移不变
可顺从 (amenable)	存在不变均值；等价于有 Følner 集合
Følner 集合	挪一下只有极小比例元素改变的有限集合
悖论分解	把群切成几块、挪一挪拼成两份自己；等价于不可顺从 (Tarski)
von Neumann–Day 问题	不可顺从的群是否一定含 F_2 ? 答案：否
Thompson 群 F	$[0,1]$ 上二进断点、斜率为 2 的幂的分段线性递增同胚，按复合构成的群
不动点	满足 $f(x) = x$ 的点
Lipschitz 映射	两点距离至多被放大 L 倍的映射
Benyamini–Sternfeld	无穷维单位球上存在把每个点都挪开至少 δ 的 Lipschitz 映射

附：想继续深入

- **原始论文** (13 页，第 2 节是你完全能读的)：
<https://github.com/openai/math/blob/main/preprints/Thompsons-group-F-is-nonamenable-September-23-2026/paper.pdf>
- **Lean 陈述**：
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/ThompsonNonamenability.lean>
；范围说明：<https://github.com/openai/math/blob/main/lean/docs/248.md>
- **Cannon, Floyd, Parry**, *Introductory notes on Richard Thompson's groups*,
L'Enseignement Math. 42 (1996) 215–256: F 的标准入门，§10.5 的生成元和关系都出自这里。
- **Terence Tao**, *The Banach–Tarski paradox* (讲义, UCLA): 第 3.3 和 4 节的悖论分解与可顺从性的完整推导。搜索 "Tao Banach-Tarski paradox notes"。
- **Juschenko**, *Amenability of discrete groups by examples* (AMS Mathematical Surveys and Monographs, 2022): 可顺从性的现代教材，有 F 的专章。△ 章节号未核对。

- 历史一手来源：Moore 关于 Shavgulidze 的说明 <https://arxiv.org/abs/1102.0747>；Moore 撤回稿 <https://arxiv.org/abs/1209.2063>；Akhmedov <https://arxiv.org/abs/0902.3849> 和 <https://arxiv.org/abs/1310.4395>；Beklaryan <https://arxiv.org/abs/1112.1942>
- von Neumann–Day 的自然反例：Monod PNAS 2013 (*Groups of piecewise projective homeomorphisms*)；Lodha–Moore <https://arxiv.org/abs/1308.4250>
- Gil Kalai 2009 年介绍 F 的博文：<https://gilkalai.wordpress.com/2009/05/01/the-thompson-group/>；2026 年的更新：<https://gilkalai.wordpress.com/2026/10/07/updates-sharing-ai-progress-on-mathematics-amazing-and-my-lecture-plans/>
- 反应汇编：<https://proofsandprompts.com/2026/10/08/100-reactions-to-100-solutions/>

偏微分方程 · 9 月单独发布 (+ FAMILY 376)

11. Navier–Stokes：流体会不会在有限时间里"炸掉"（带外力的有限时间爆破）

偏微分方程 · OpenAI 2026-09-08 单独发布的结果（不在 10 月 openai/math 的 372 个 family 里），外加 10 月发布中与之相关的 family 376（受迫 NS 中的通用计算，§11.7.5）。前提只需要：会求导、知道偏导数 $\partial/\partial x$ 的意思、知道向量和点积。不需要学过偏微分方程（PDE），PDE 从头讲。文中所有数字都由脚本实算或有出处；【检查】是可以自己动手算的小练习，答案在章末。标记：[P] = 我亲自读过的一手材料（论文 PDF、Lean 文件、Clay 官方文本）；[R] = 二手报道； Δ = 未核实或有争议。截至 2026-10-08。预计阅读时间：60–90 分钟。可以分三次读：§11.1–11.3（PDE、流体方程、什么叫爆破）、§11.4–11.6（为什么难、历史、Clay 题面）、§11.7–11.9（OpenAI 的结果和相关的 family 376、核实、意义）。

11.0 先说结论：这一章要讲明白的一件事

Navier–Stokes (NS) 方程描述水、空气怎么流动，工程上天天在用。但最基本的问题没人能回答：从光滑、温和的初始状态出发，流速会不会在有限时间内变成无穷大？

这一章要讲清楚的是一条因果链：

方程里有一项"流体自己推自己"的非线性项，它会把速度越推越陡 $\Leftarrow$ 粘性在把它抹平 $\Leftarrow$ 两者谁赢，取决于尺度 $\Leftarrow$ 在 3 维里，我们手里唯一的"全局账本"（能量）在越来越小的尺度上越来越管不住 $\Leftarrow$ 所以没人能证明粘性总会赢，也没人能造出它输的例子。

Clay 在 2000 年把它列为千禧年难题，给出四个可选表述 (A)–(D)，证出任一即算解决：(A) (B) 是"无外力时解永远光滑"，(C)(D) 是"存在某个光滑外力，使解在有限时间坏掉"。

OpenAI 在 2026-09-08 声称证明了 (C) 和 (D)：一个光滑、只在有限时空范围内起作用的外力，让从静止开始的流体在 $t = 1$ 时某点速度变成无穷大，总能量始终有界；附约 64 万行

Lean。同一天还发布了可能更重要的 **无外力 3D Euler（无粘性流体）从光滑初值爆破**。

读完这一章，你应该能用自己的话讲出：

- PDE 是什么，"光滑解永远存在"和"有限时间爆破"各是什么意思；
- 为什么能量守恒挡不住 3 维的爆破（超临界缩放，带数字）；
- Clay 的 (A)–(D) 各说了什么，外力 f 在 (C)/(D) 里扮演什么角色；
- OpenAI 的结果按 Clay 官方文本**形式上**算不算解决，离"拿到奖金"还差哪几道关，以及为什么很多分析学家认为真正的问题还是 (A)/(B)。

11.1 什么是 PDE：从热方程开始

11.1.1 ODE 和 PDE

你熟悉的微分方程，比如 $y'(t) = -y(t)$ ，未知量是一个随时间变化的数 $y(t)$ 。这叫常微分方程（ODE）。

偏微分方程（PDE）的未知量是**一整个场**：每个位置 x 、每个时刻 t 都有一个值 $u(x, t)$ 。方程同时涉及对时间的导数 $\partial u / \partial t$ 和对空间的导数 $\partial u / \partial x$ 。

把空间切成小格，每格一个未知数，相邻格子互相影响：PDE 就是"**无穷多个耦合的 ODE**"，像一个每个节点只和邻居通信的分布式系统。

11.1.2 最简单的 PDE：热方程

一根细铁棒， $u(x, t)$ 是位置 x 在时刻 t 的温度。热方程是：

$$\partial u / \partial t = k \cdot \partial^2 u / \partial x^2$$

右边的 $\partial^2 u / \partial x^2$ 是"曲率"：如果某点比两边邻居都热（像山峰），它是负的，温度就下降；比邻居都冷（像山谷），它是正的，温度就上升。所以**热方程就是"每个点向邻居平均值靠拢"**。

离散成格子更好理解。格距 Δx ，时间步 Δt ，记 $r = k\Delta t / \Delta x^2$ ，一步更新是：

$$\text{新值}_i = \text{旧值}_i + r \cdot (\text{旧值}_{i-1} - 2 \cdot \text{旧值}_i + \text{旧值}_{i+1})$$

手算一步 ($r = 0.25$ ，脚本核对过)：7 个格子 `[0, 0, 0, 1, 0, 0, 0]`，中间那个是一个热点。

- 中间： $1 + 0.25 \cdot (0 - 2 + 0) = 0.5$
- 两个邻居： $0 + 0.25 \cdot (0 - 0 + 1) = 0.25$
- 结果：`[0, 0, 0.25, 0.5, 0.25, 0, 0]`，总和仍然是 1。

热点被摊开了，但总热量不变。

【检查 1】从 `[0, 0, 0.25, 0.5, 0.25, 0, 0]` 再走一步 ($r = 0.25$)，结果是什么？总和是多少？

11.1.1.3 数值模拟：热方程会把一切抹平

脚本实算： $k = 1$ ，初始温度在 $|x| < 0.5$ 处为 1、其他地方为 0（一个"方块"，边缘是无限陡的台阶），用上面的格式在 1001 个格点上推进。

t	中心温度（数值）	中心温度（精确解）	总热量	最陡的斜率
0	1.0000	1.0000	0.990	100（网格允许的最陡台阶）
0.01	0.9996	0.9996	0.990	2.82
0.1	0.7316	0.7364	0.990	0.83
0.5	0.3794	0.3829	0.990	0.22

（总热量是 0.990 而不是 1，是因为网格上的方块宽 0.99。）

要记住：**热方程只会让东西变平滑**，无穷陡的台阶瞬间变成光滑曲线，斜率一路下降；它是线性的，不可能自己"爆"。NS 里的**粘性项**数学上就是"对速度做热方程"，站在"光滑"这一边。

11.2 流体：速度场和 NS 方程逐项拆解

11.2.1 速度场

流体的未知量是**速度场** $u(x, t)$ （每点每刻一个 3 维向量）和**压力** $p(x, t)$ （一个数）。

一个 2 维例子： $u(x, y) = (-y, x)$ 。在点 (1, 0) 速度是 (0, 1)，向上；在 (0, 1) 速度是 (-1, 0)，向左。画出来是**绕原点逆时针转**的刚体旋转，离中心越远转得越快（速度大小 = 半径 r ）。

11.2.2 不可压缩：散度为零

水几乎压不缩。数学上写成**散度为零**：

$$\nabla \cdot u = \partial u_1 / \partial x + \partial u_2 / \partial y + \partial u_3 / \partial z = 0$$

散度衡量"一个小区域里净流出多少"。散度为 0 = 流进多少就流出多少，体积不变。

【检查 2】计算 $u = (-y, x)$ 和 $w = (x, y)$ 的散度。哪个是不可压缩的？ w 画出来是什么样子？

11.2.3 NS 方程：牛顿第二定律，写给一小团流体

Clay 官方题面（Fefferman 撰写）的原话是："Equation (1) is just Newton's law $f = ma$ for a fluid element" [P]。方程是：

$$\underbrace{\partial \mathbf{u} / \partial t + (\mathbf{u} \cdot \nabla) \mathbf{u}}_{\text{加速度 } \mathbf{a}} = \underbrace{\nu \Delta \mathbf{u}}_{\text{粘性}} - \underbrace{\nabla p}_{\text{压力}} + \underbrace{\mathbf{f}}_{\text{外力}} \quad \nabla \cdot \mathbf{u} = 0$$

逐项看：

左边：一小团流体的加速度。 它有两部分：

- $\partial \mathbf{u} / \partial t$ ：站在固定点看，速度随时间的变化。
- $(\mathbf{u} \cdot \nabla) \mathbf{u}$ ：这团流体**移动到了速度不同的地方**带来的变化。即使流场不随时间变（定常流），顺着流线走的流体也可能在转弯、加速。

$(\mathbf{u} \cdot \nabla) \mathbf{u}$ 是 $\mathbf{u}$ 乘以 $\mathbf{u}$ 的导数，**关于 $\mathbf{u}$ 是二次的**，这就是 NS 的**非线性**来源，也是全部困难的来源。直观上：流体"自己推着自己走"。

用旋转流手算这一项。 对 $\mathbf{u} = (-y, x)$ ， $(\mathbf{u} \cdot \nabla) \mathbf{u}$ 的第一个分量是 $u_1 \cdot \partial u_1 / \partial x + u_2 \cdot \partial u_1 / \partial y = (-y) \cdot 0 + x \cdot (-1) = -x$ ；第二个分量是 $(-y) \cdot 1 + x \cdot 0 = -y$ 。所以 $(\mathbf{u} \cdot \nabla) \mathbf{u} = (-x, -y)$ ，**指向圆心，大小为 r** 。这正是高中物理的向心加速度 $v^2/r = r^2/r = r$ 。

右边第一项：粘性 $\nu \Delta \mathbf{u}$ 。 $\Delta = \partial^2 / \partial x^2 + \partial^2 / \partial y^2 + \partial^2 / \partial z^2$ ，和热方程右边是同一个东西。相邻流速不同（剪切）时互相拖拽，把速度差抹平。

右边第二项：压力 $-\nabla p$ 。 从高压推向低压。在不可压缩流里，压力是"为了让 $\nabla \cdot \mathbf{u} = 0$ 时刻成立而自动调节出来的力"，即不可压缩约束的拉格朗日乘子。

右边第三项：外力 $\mathbf{f}$ 。 比如重力、搅拌器、电磁力。**这一项是理解 OpenAI 结果的关键**，§11.6 专门讲。

【检查 3】对旋转流 $\mathbf{u} = (-y, x)$ ，取 $\nu > 0$ 、 $\mathbf{f} = 0$ 。(a) 计算 $\Delta \mathbf{u}$ 。(b) 这个流是定常的 ($\partial \mathbf{u} / \partial t = 0$)，方程要求 $(\mathbf{u} \cdot \nabla) \mathbf{u} = -\nabla p$ 。找出压力 p 。压力在中心高还是边缘高？

11.2.4 雷诺数：非线性和粘性谁大

一个尺度为 L 、速度为 U 的流动：

- 非线性项把速度搬运一个尺度的时间约为 L/U ；
- 粘性把这个尺度上的差异抹平的时间约为 L^2/ν 。

两者之比叫**雷诺数** $Re = UL/\nu$ 。 Re 大，非线性主导（湍流）； Re 小，粘性主导（像蜂蜜一样平稳）。

脚本实算（水 $\nu \approx 1.0 \times 10^{-6} \text{ m}^2/\text{s}$ ，空气 $\approx 1.5 \times 10^{-5} \text{ m}^2/\text{s}$ ）：1 m/s 的水流过 0.1 m 的管子， $Re = 10^5$ ；30 m/s 的空气流过 4 m 的汽车， $Re = 8 \times 10^6$ 。

记住这个量，§11.4 会用到：爆破的问题就是，能不能在越来越小的尺度上，让雷诺数不降反升。

11.3 "光滑解永远存在"和"有限时间爆破"

11.3.1 先看 ODE 玩具：方程完美，解却会坏

对比两个看起来很像的方程，初值都是 $y(0) = 1$ ：

t	$y' = y$ 的解 e^t	$y' = y^2$ 的解 $1/(1-t)$
0.5	1.649	2
0.9	2.460	10
0.99	2.691	100

（脚本实算；用 RK4 数值积分 $y' = y^2$ 到 $t = 0.99$ 得到 100.0000000001，和精确解一致。）

e^t 在每个有限时刻都有限； $1/(1-t)$ 在 $t = 1$ 时变成无穷大，这叫有限时间爆破。方程右边 y^2 再光滑不过，坏掉的是解："越大长得越快"，增长率本身在增长。

11.3.2 加上阻尼：谁赢取决于初值


现在加一个"粘性"式的阻尼： $y' = y^2 - y$ 。用代换 $z = 1/y$ 可以精确解出： $z(t) = 1 + (z_0 - 1)e^t$ ， y 爆破当且仅当 z 碰到 0。

初值 y_0	结果（脚本实算）
0.5	衰减， $y(3) \approx 0.047$
1.0	不动，永远 = 1（平衡点）
1.1	爆破， $t^* = \ln 11 \approx 2.398$
2.0	爆破， $t^* = \ln 2 \approx 0.693$

小初值阻尼赢，大初值非线性赢。对照§11.2.3 的 NS 方程： y^2 扮演非线性的"自我输运"项 $(u \cdot \nabla)u$ ， $-y$ 扮演粘性项 $\nu \Delta u$ ，外力 f 暂时取 0。3 维 NS 的已知理论正好是这个形状：Fefferman 的题面写道，3 维中"(A) and (B) hold provided the initial velocity u^0 satisfies a smallness condition"，并且对大初值，光滑解至少在一段短时间 $[0, T)$ 内存在 $[P]$ 。大初值能不能一直光滑下去，就是千禧年问题。

下图左边把§11.3.1–11.3.2 的曲线画在一起（图里把未知量记作 x ， $\dot{x}$ 就是 dx/dt ）： e^t 增长但永不爆破； $1/(1-t)$ 在 $t = 1$ 爆破； $y' = y^2 - y$ 从初值 2 出发在 $t = \ln 2 \approx 0.693$ 爆破，从初值 $\frac{1}{2}$ 出发衰减到 0。右边是§11.6 要细讲的 Clay 四个分支：OpenAI 声称的是带外力的 (C)/(D)，无外力的 (A)/(B) 仍然开放。

手算的"有限时间爆破": 方程光滑, 解却在有限时刻冲到无穷



- $\dot{x} = x: e^t$, 增长但永不爆
- $\dot{x} = x^2: 1/(1-t)$, $t \rightarrow 1$ 爆破
- $\dot{x} = x^2 - x$, $x_0=2$: $t=\ln 2$ 爆破
- $\dot{x} = x^2 - x$, $x_0=\frac{1}{2}$: 衰减到 0

Clay 的四个分支 (证出任一即算)

- (A) $\mathbb{R}^3$, 无外力: 永远光滑
- (B) $\mathbb{T}^3$, 无外力: 永远光滑
- (C) $\mathbb{R}^3$, 可选光滑外力: 会爆破
- (D) $\mathbb{T}^3$, 可选光滑外力: 会爆破

OpenAI 9/8 声称 (C)/(D); (A)/(B) 仍开放

左: x^2 项像 Navier-Stokes 的非线性"自我输运", $-x$ 项像粘性阻尼。小初值时阻尼赢 (蓝), 大初值时非线性赢 (橙)——这正是 3D NS 已知理论的形状: 小初值有整体光滑解, 大初值未知。曲线由 build 脚本按解析解计算。右: Clay 官方问题陈述 (Fefferman) 的四个分支。

11.3.3 一个 PDE 玩具: Burgers 方程

把 NS 砍到 1 维、去掉压力: $u_t + u \cdot u_x = \nu \cdot u_{xx}$ 。初值 $u = -\sin x$ 。无粘性时, $x=0$ 处的斜率满足 $(u_x)' = -(u_x)^2$, 和 $y' = y^2$ 同构, 得 $u_x(0, t) = -1/(1-t)$, $t=1$ 时斜率无穷大 (激波)。有粘性时, 脚本用谱方法模拟, 最陡斜率被封顶在约 $1/(2\nu)$: $\nu=0.1$ 时 3.7 ($1/(2\nu)=5$), $\nu=0.01$ 时 48.4 (50), $\nu=0.003$ 时 164.9 (166.7)。 ν 越小顶越高, 但总是有限 (1 维粘性 Burgers 可经 Cole-Hopf 变换化成热方程, 严格证明不爆)。

3 维 NS 的问题是: 粘性还能不能这样封顶? 3 维多了一个机制: 涡拉伸。涡管被拉长变细, 像花样滑冰收手臂一样转得更快 (角动量 $r \cdot u_\theta$ 守恒: 半径缩 10 倍, 转速变 10 倍)。这个正反馈在 1、2 维都不存在。

11.3.4 精确地说"爆破"

"光滑"指所有阶导数都存在且连续 (C^∞)。整体光滑解: 对所有 $t \geq 0$ 光滑且能量有界。有限时间爆破: 解在 $[0, T)$ 上光滑, 但 $t \rightarrow T$ 时某处速度或其导数 $\rightarrow \infty$ 。Fefferman 的题面记录: 对 NS ($\nu > 0$), 爆破时速度本身必须无界 [P], 所以 OpenAI 定理写的是 " $\limsup \|u(t)\|_\infty = \infty$ "。真实的水不会有无穷大速度, 分子尺度会先让连续介质模型失效; 爆破是关于这个数学模型的结论。

11.4 为什么 3 维这么难: 能量与超临界缩放

11.4.1 能量: 唯一的全局账本

不加外力时, NS 有一个漂亮的恒等式: 总动能 $E(t) = \frac{1}{2} \int |u|^2 dx$ 只减不增 (粘性把动能变成热)。非线性项 $(u \cdot \nabla)u$ 对总能量的贡献恰好为 0, 它只在不同尺度之间搬运能量, 不制造

能量。

所以我们有一个对所有时间都成立的上界： $E(t) \leq E(0)$ 。问题是： **这个上界够不够阻止爆破？**

11.4.2 缩放对称性

NS 有一个对称性：如果 $u(x, t)$ 是解，那么对任何 $\lambda > 0$,

$$u_\lambda(x, t) = \lambda \cdot u(\lambda x, \lambda^2 t)$$

也是解（压力和外力相应变换）。 $\lambda > 1$ 的意思是"把同一个流动缩小到 $1/\lambda$ 的尺寸，加快到 λ^2 倍的速度播放，流速变成 λ 倍"。

λ	尺寸	时间	流速	3D 能量	2D 能量
1	1	1	$\times 1$	$\times 1$	$\times 1$
10	1/10	1/100	$\times 10$	$\times 0.1$	$\times 1$
100	1/100	1/10 ⁴	$\times 100$	$\times 0.01$	$\times 1$
1000	1/1000	1/10 ⁶	$\times 1000$	$\times 0.001$	$\times 1$

能量那一列的来历： $\int |\lambda u(\lambda x)|^2 dx$ ，令 $y = \lambda x$ ，在 3 维中 $dx = dy/\lambda^3$ ，所以能量乘以 $\lambda^2/\lambda^3 = 1/\lambda$ 。

【检查 4】按同样的方法算 2 维的能量因子，验证它是 1。

3D 那一系列是关键：把一个"爆破结构"缩小 1000 倍、加速到 1000 倍流速，所需的能量反而只要原来的千分之一。能量上界对小尺度几乎没有约束力。这叫**超临界**（supercritical）。2D 中能量不随缩放变，叫**临界**，所以 2D 的 NS 早就被证明整体光滑（Ladyzhenskaya，见 Fefferman 题面 [P]）。

11.4.3 用雷诺数再说一遍

固定总能量 $E = 1$ 、粘性 $\nu = 1$ 。一团尺寸为 L 的流动，速度最大能有多大？

- 3D：能量 $\approx U^2 L^3 \leq 1$ ，所以 $U \leq L^{(-3/2)}$ ，雷诺数 $Re = UL/\nu \leq L^{(-1/2)}$ 。
- 2D：能量 $\approx U^2 L^2 \leq 1$ ，所以 $U \leq 1/L$ ， $Re \leq 1$ 。

尺寸 L	3D 允许的最大 Re	2D 允许的最大 Re
1	1	1
10 ⁻²	10	1
10 ⁻⁶	1,000	1
10 ⁻⁸	10,000	1

（脚本实算。）

2D：能量把每个尺度上的雷诺数都压在 1 以下，粘性永远有资格赢。3D：尺度越小，能量允许的雷诺数越大，**粘性在小尺度上可能输**。能量没有排除爆破，也没有证明爆破，它就是"不够用"。这就是 3D NS 问题的核心。

11.4.4 Tao 的"超临界屏障"（2016）

Tao（JAMS 29, 2016；arXiv:1402.0290）构造了一个"平均版 NS"：保留能量恒等式和缩放，只把非线性项换成平均过的版本，并证明它**会**爆破。推论：只用"能量 + 一般调和估计"的论证不可能证明 (A)/(B)，必须用到真实非线性项的精细结构。他还提出一个**纲领**：在真实流体里搭出"逻辑门"，让流体像自复制机器一样把能量一次次传给更小、更快的自身副本，从而在**无外力** NS 里爆破。这个纲领至今没有实现。（§11.7.5 的 family 376 让人想到这个纲领，但两者不是一回事。）

11.5 90 年的部分结果

年份	结果	意义
1934	Leray (Acta Math. 63)：任意有限能量初值都有整体 弱解	弱解只在"积分平均"意义下满足方程，允许奇点；光滑性、唯一性都未知
1982	Caffarelli–Kohn–Nirenberg (CPAM 35)：奇点集的抛物 1 维 Hausdorff 测度为 0	奇点"不能形成一条时空曲线" (Fefferman 原话 [P])，但孤立点没被排除
2003	Escauriaza–Seregin–Šverák ： L^3 范数有界就不爆	爆破必须让 L^3 范数发散
2016	Tao ：平均版 NS 爆破	见 4.4 节
2019	Buckmaster–Vicol (Annals 189)：某类弱解不唯一	弱解太"软"
2014 / 2022	Luo–Hou 数值 (PNAS)； Chen–Hou 计算机辅助证明 (arXiv:2210.07191)：带 边界 的 3D 轴对称 Euler 从光滑初值爆破	需要固体壁，不在全空间 $\mathbb{R}^3$
2021	Elgindi (Annals 194)： $\mathbb{R}^3$ 上 Euler 对 $C^{(1,\alpha)}$ 初值爆破	初值不是 C^∞
2023 起	Córdoba–Martínez-Zoroa (arXiv:2309.08495 等)：带外力的 3D Euler 爆破，外力光滑度有限	"外力路线"的开创者：越来越细的涡层逐级放大
2025	DeepMind 等 (arXiv:2509.14185)：用神经网络找到 Boussinesq、IPM 等方程的 不稳定 自相似奇点，精度接近机器精度	为无边界情形的计算机辅助证明铺路
2026-08	Buckmaster–Alpöge ：IPM、Boussinesq、3D Euler 在 光滑外力 下爆破，Lean 验证；9 月 7 日（美东时间）公开	把 Córdoba–Martínez-Zoroa 的路线推到光滑外力 [P, Buckmaster 声明]

这张表里反复出现的模式：**Euler（无粘性）比 NS 容易爆；带边界、低光滑度、带外力都比"全空间、 C^∞ 、无外力"容易**。每放宽一个条件，就有人能做出爆破。千禧年问题 (A)/(B)

是所有条件都不放宽的版本。

11.6 Clay 的题面：四个分支，以及外力 f 的角色

11.6.1 官方原文 [P]

Fefferman 的题面 (<https://www.claymath.org/wp-content/uploads/2022/06/navierstokes.pdf>) 先规定"物理上合理"的条件：初值和外力的所有导数快速衰减（条件 4、5），解在 $\mathbb{R}^3 \times [0, \infty)$ 上 C^∞ （6），能量一致有界（7）；周期情形用条件 8–11。然后：

"To give reasonable leeway to solvers while retaining the heart of the problem, we ask for a proof of one of the following four statements."

分支	区域	外力	要证明什么
(A)	$\mathbb{R}^3$	$f \equiv 0$	任意光滑衰减初值 $\rightarrow$ 存在整体光滑、能量有界的解
(B)	周期环面 $\mathbb{R}^3/\mathbb{Z}^3$	$f \equiv 0$	同上，周期版
(C)	$\mathbb{R}^3$	存在光滑衰减的 f	存在某个初值和外力，使光滑能量有界的整体解不存在
(D)	$\mathbb{R}^3/\mathbb{Z}^3$	存在光滑周期 f	同上，周期版

两点：(A)/(B) 是"对所有初值都好"，(C)/(D) 是"存在一个坏例子"，正反两个方向；(A)/(B) 规定 $f \equiv 0$ ，(C)/(D) 允许你自己挑外力，只要光滑且衰减。Fefferman 还写道，Euler 方程 ($v = 0$) 的对应问题"also open and very important"，但不在奖金清单上 [P]。

11.6.2 为什么"可以挑外力"让问题变了形状

OpenAI 论文第 2 节自己点明了这一点 [P]：

"For any incompressible flow u and pressure p , we can always define the external force f to be the residual in (1.1). The Navier–Stokes equations then hold by construction. The challenge is to choose a flow that blows up while this residual remains smooth."

人话：随便画一个会爆的不可压缩流，代进 NS 左边减右边，差多少让 f 补多少，方程自动成立。难点只有一个：补差的外力必须保持光滑，在爆破时刻也不能坏。

用 ODE 玩具看清楚这个难点：

- 线性方程 $y' = -y + g(t)$ ：想让 $y = 1/(1-t)$ 爆破，需要的外力是 $g = y' + y = 1/(1-t)^2 + 1/(1-t)$ ，它自己也爆了，不光滑。事实上线性方程配光滑外力永远不会爆破。
- 非线性方程 $y' = y^2 + g(t)$ ：同样的 $y = 1/(1-t)$ ， $g = y' - y^2 = 1/(1-t)^2 - 1/(1-t)^2 = 0$ 。外力是 0，完全光滑。

所以爆破必须靠非线性项自己抵消奇异部分，外力只补光滑的余量。在 NS 里要让所有发散部分到任意阶导数都抵消，这就是那 166 页在做的事。

【检查 5】对 $y' = -y + g(t)$ ，如果 g 在 $[0, 2]$ 上光滑有界（比如 $|g| \leq 1$ ）， $y(0) = 0$ ， $y(t)$ 能在 $t = 1$ 爆破吗？提示：比较 $y' \leq -y + 1$ 。

11.6.3 那么 (C) 比 (A) 容易吗？

Clay 在 2000 年把 (C) 和 (A) 并列，认为四个分支都 "retaining the heart of the problem"。但 2023 年以后 Córdoba–Martínez-Zoroa 打开的 "外力路线" 表明，**外力能承担大量 "工程" 工作**：在需要的时间、地点注入能量、"种下" 扰动。Buckmaster 在声明里说这条路线 "is the route Luis and Diego opened"，并把下一步目标称为 "a path to unforced Euler" [P]。连这条路线的推进者，也把 "无外力" 看作更深一层的问题。

换句话说，(C)/(D) 把问题变成了 "能否造一个会爆的流，同时让残差外力保持光滑"。这比 "流体自己会不会爆" (无外力的 (A)/(B)) 弱得多，多数分析学家认为真正的问题是 (A)/(B) [R]。二手报道的概括：外力路线是 "a route the written problem permits but that most working mathematicians exclude from the question they care about" [R, Implicator]。△ 这是记者的概括，不是对分析学家的系统调查。

11.7 OpenAI 声称了什么

11.7.1 主定理 [P]

论文 *Finite time blowup for Navier–Stokes*，署名 "OpenAI"，166 页，PDF 生成于 2026-09-08 12:06 PDT (<https://cdn.openai.com/pdf/32d9f210-8b73-45e0-91bc-82a30aef8a9a/navier-stokes.pdf>)。它是**单独发布**的：不在 10 月 6 日 openai/math 发布的 372 个 family 里，论文放在 OpenAI 的 CDN 上，约 64 万行的 Lean 证明在独立仓库 openai/NavierStokesAndEuler (§11.8.2)。摘要：

"For every positive viscosity, we construct a solution of the three-dimensional incompressible Navier–Stokes equations that starts from rest and develops unbounded velocity in finite time while maintaining uniformly bounded kinetic energy."

Theorem 1.1 的内容：对每个 $\nu > 0$ ，存在

- 一个外力 $f \in C_c^\infty(\mathbb{R}^3 \times (0, \infty))$ ：光滑，并且在空间和时间上都只在一块有界区域里非零 ("紧支撑")；
- 速度和压力 u, p 在 $\mathbb{R}^3 \times [0, 1)$ 上光滑，初值 $u(\cdot, 0) = 0$ (从静止开始)，并且始终局限在一个固定的有界区域 K 内；
- 能量 $\sup \|u(t)\|_{L^2} < \infty$ ，速度 $\limsup_{t \uparrow 1} \|u(t)\|_{L^\infty} = \infty$ 。

论文原文: "This establishes alternative (C) in the Millennium problem statement ... Compact support also yields the corresponding construction on T^3 ... establishing alternative (D)" (Corollary 10.6)。

任意粘性的手算。 论文先在 $\nu = 1$ 时构造, 再用缩放 $u_\nu(x, t) = \sqrt{\nu} \cdot u(x/\sqrt{\nu}, t)$ 推到任意 ν 。爆破时刻不变。

【检查 6】验证: 把 $u_\nu = \sqrt{\nu} \cdot u(x/\sqrt{\nu}, t)$ 代入, $\partial u_\nu/\partial t$ 、 $(u_\nu \cdot \nabla)u_\nu$ 、 $\nu \Delta u_\nu$ 三项都等于 $\sqrt{\nu}$ 乘以原来对应的项。

11.7.2 机制的直觉 (读了论文第 2 节, 以下是简化版)

- 1. **一根越来越细、越来越快的涡柱。** 原点附近的涡核里, 流体螺旋向内、沿轴向上下流出。角动量守恒让向内的流体转得更快; 不可压缩性让流进来的流体沿轴流走, 向内流动才能持续。
- 2. **自相似收缩。** 记 $\tau = 1 - t$ 。核的半径 $\ell_r \sim \tau^{(1/2)}$, 高度 $\ell_z \sim \tau^{(1/2-h)}$, h 是固定小数, $0 < h < 1/100$ 。涡柱越来越细长。
- 3. **问题:** 核心外的过渡环带留下一个"残差", 补它所需的外力在 $t \rightarrow 1$ 时发散。
- 4. **解决: 在环带里加振荡脉冲。** 脉冲的速度平均为 0, 但**二次乘积**(动量通量)平均不为 0。两族脉冲精心排列, 让非线性通量**正好抵消**残差里发散的部分。每个脉冲由指数小的外力"种下", 再靠背景剪切长大。
- 5. **外部:** 纯旋转、满足热方程的流动, 不需要外力; 再光滑截断到有界区域。

这正是 6.2 节的"非线性项自己抵消奇异部分", 只是要在 3 维里对所有阶导数做到。

11.7.3 数字感受: 涡核怎么收缩

取 $h = 0.005$ (论文只要求 $0 < h < 1/100$, 这个值是我为演示选的), 按论文给出的标度律算 (脚本实算, $\nu = 1$, 常数因子取 1):

$\tau = 1 - t$	核半径 ℓ_r	核高度 ℓ_z	速度 $\sim \tau^{(-1/2-h)}$	核的能量 $\sim \tau^{(1/2-3h)}$	旋转雷诺数 $\tau^{(-h)}$
10^{-2}	0.1	0.102	10.2	0.107	1.023
10^{-4}	0.01	0.0105	104.7	0.0115	1.047
10^{-8}	10^{-4}	1.10×10^{-4}	1.10×10^4	1.3×10^{-4}	1.096
10^{-12}	10^{-6}	1.15×10^{-6}	1.15×10^6	1.5×10^{-6}	1.148

- **速度 $\rightarrow \infty$, 核的能量 $\rightarrow 0$:** 正是§11.4 的超临界, 小尺度上用越来越少的能量达到越来越大的速度。
- 速度比纯缩放 $\tau^{(-1/2)}$ 多出因子 $\tau^{(-h)}$, 即**旋转雷诺数**。它趋于无穷, 但极慢: τ 从 10^{-2} 到 10^{-12} , 只从 1.02 涨到 1.15。爆破是在"刚好比临界多一点点"的边缘上实现的。
- 和已知定理一致: 奇点是一个点 (原点, $t = 1$), 不违反 CKN; L^3 范数的三次方 $\sim \tau^{(-4h)}$, 在 $\tau = 10^{-12}$ 时约 1.74, 在发散, 符合 ESS 的必要条件 (Δ ESS 针对无外力情形, 这里只作直觉检

查)。

11.7.4 同时发布的 Euler 结果

同一个 Lean 仓库还形式化了第二篇论文 *Finite time blowup for the Euler equation* (57 页, <https://cdn.openai.com/pdf/315b36cd-ec98-4023-8342-93345194ece1/euler.pdf>) [P]:

"We exhibit finite-time blowup for the three-dimensional incompressible, unforced Euler equations from smooth, compactly supported, divergence-free initial data."

对比§11.5: Chen–Hou 需要边界, Elgindi 的初值只有 $C^{(1,\alpha)}$, Córdoba–Martínez-Zoroa 和 Buckmaster–Alpöge 需要外力。这个结果把这些放宽全部去掉, 只剩"没有粘性"与千禧年问题不同。Fefferman 说 Euler 的对应问题"also open and very important" [P]。我的判断 (推测): 论离大家真正关心的问题有多近, 它可能比带外力 NS 分量更重。△ 我没有找到任何专家对这篇论文的具名技术评价。

规模 [R]: 约 1 万个并发智能体, 88 小时; Wikipedia 引用 270 万条消息、1300 亿输出 token, 另有报道说"近 500 万"条 △。 `formalization.yaml` 记录模型为 "GPT-6 Astra"、框架 Codex [P]。

11.7.5 相关: 受迫 NS 中的通用计算 (family 376)

10 月的 openai/math 发布里有一个和"外力"直接相关的结果族: family 376, *Universal computation in forced Navier–Stokes flows*。它由一组预印本组成, 代表作是 *A Fixed Particle Test for Computation in a Forced Viscous Flow* (2026-09-27) [P]。

声称 [P]: 固定一个平坦的 3 维环面、一个正的可计算粘性、从静止开始的流体、一个指定的流体粒子, 以及一个固定的开区域 ("探测器")。对任意给定的图灵机和输入, 可以写出一个光滑外力的有限"程序", 使这个粒子进入探测器**当且仅当**这台图灵机停机。停机问题不可判定, 所以"这个粒子会不会到达那里"这个可达性问题也**不可判定**。

论文自己说得很坦白 [P]: "There is an elementary way to force a chosen smooth incompressible velocity: subtract its viscous term from its material acceleration. The mathematical work lies in choosing that velocity from the finite instruction table." 这就是 §11.6.2 的"残差外力"技巧: 想要什么流, 就让外力补差。真正的工作在于设计这个流: 它要逐条执行指令, 保留可逆所需的信息, 并且在不停机的运行中始终碰不到探测器。论文也写明, 它"not a regularity theorem for general Navier–Stokes data"。

和 Tao 纲领 (§11.4.4) 的关系 (我们的判断): 它让人想到 Tao 2016 的纲领, 即让流体自己搭出计算机, 把能量一次次传给更小的自身副本, 从而爆破。但 376 把"编程"放在外力里, 外力承担了全部编程工作, 所以它**不推进**那条无外力爆破纲领, 更接近"受迫流体的可控性 / 不可判定性"一类结果。截至 2026-10-09, 仓库里这一族列出的 9 篇预印本全文都没有引用 Tao 2016 [P]。它引用的前驱是 Cristopher Moore 的广义移位 (1990–91)、Bennett 的可逆计算

(1973), 以及 Cardona–Miranda–Peralta–Salas–Presas 在调整过度量的 3 维球面上构造的图灵完备定常 Euler 流 (PNAS 2021) [P]。

Lean [P]: `lean/docs/376.md` 列出 6 个 Comparator 陈述, 覆盖其中 4 篇预印本的选定结论, 其中包括 $\mathbb{R}^3$ 上的版本: 一个光滑、紧支撑的流动, 从静止出发, 位于 (4,0,0) 的粒子进入固定开盒 $(-1,2)^3$ 当且仅当机器停机。覆盖范围逐篇不同, 例如 *Geometric Programs for Solenoidal Forcing* 一文的固定粒子停机检测器明确不在形式化范围内。△ 我们没有逐个读这 6 个陈述文件, 也没有编译。

11.8 它被核实到什么程度

11.8.1 Lean 陈述: 题面不是 OpenAI 写的

题面文件 `ComparatorChallenges/NavierStokes.lean` 开头写明, 它复制自 **Google DeepMind 的 Formal Conjectures 项目** (commit `8bf45ed`), 只改了 import、命名空间和记号 [P]。题面若由求解方自己写, 就可能悄悄放宽条件; 这里出自第三方。△ 我没有逐行 diff 上游。

分支 (C) 的陈述:

```
theorem navier_stokes_breakdown_R3 (nu : ℝ) (hnu : nu > 0) :
  ∃ (u₀ : ℝ³ → ℝ³) (f : ℝ³ → ℝ → ℝ³),
    InitialVelocityConditionDecay u₀ ∧ ForceConditionDecay f ∧
    ¬ (∃ v p, NavierStokesExistenceAndSmoothnessRn nu u₀ f v p)
```

逐词翻译:

- `(nu : ℝ) (hnu : nu > 0)`: 对任意正的粘性 ν ,
- `∃ (u₀ ...) (f ...)`: 存在初值 u_0 和外力 f ,
- `InitialVelocityConditionDecay u₀`: u_0 光滑、散度为 0、所有导数快速衰减 (Clay 条件 4),
- `ForceConditionDecay f`: f 光滑, 所有时空导数 $\leq C/(1+|x|+t)^K$ (条件 5),
- `¬ (∃ v p, ...)`: 使得**不存在** v 、 p 同时满足 NS (1)、散度为 0 (2)、初值 (3)、 C^∞ (6)、能量一致有界 (7)。

我逐条对过 Clay 原文: (4)–(7) 全在; 周期版 (D) 含 (8)–(11), 并按 Clay 勘误要求压力也周期 [P]。**题面结构与 Clay (C)/(D) 一致。**注意 (C) 要的是"**不存在**任何整体光滑解", 不只是"我造的解会爆"; 这需要光滑解的唯一性 (Theorem 1.1 的 "Consequently..." 一句), Lean 里也证了。

11.8.2 证明本身

- 仓库 `openai/NavierStokesAndEuler` (快照 `f9e8bc5`, 2026-09-10): **2,659 个 .lean 文件** (NS 816、Euler 1,839) [P], 约 64 万行 (作者研究笔记的统计)。
- `formalization.yaml`: sorry 数 0, 只用 `propext`、`Classical.choice`、`Quot.sound` 三条标准公理; Comparator 开启 `enable_nanoda`, 即再用一个独立实现的内核检查 [P]。review 状态写的是 "**self-assessed**" (自评)。
- △ 我没有运行 `lake build` 或 Comparator, 也没找到第三方公开跑通 NS Comparator 的报告 (§4 的准黎曼猜想有 Goldblatt 的独立复核)。

11.8.3 人类专家和机构

- **Clay** (09-11, 主席 Martin Bridson) [R]: 据报道称 "the Navier–Stokes problem has apparently been settled", 同时评估会 "deliberately unhurried" (原句 "The process is deliberately unhurried, but we will provide updates")。Clay 仍把 NS 列为未解决: 官网问题页截至今天仍标 "Active" (我 10-08 核对过)。Clay 规则要求在合格刊物发表, 再加两年接受期 (§11.9.1)。
- **Gómez-Serrano** (NPR, 09-22) [R]: "The paper is not written for humans ... as of today, the paper doesn't teach us much."
- **Fefferman** [R]: "The heroes of the story ... are Córdoba and Martínez-Zoroa." △ 未找到原始出处。
- △ 截至 2026-10-08, 没有任何人类专家公开表示读完并核对了这 166 页论文, 也没有期刊投稿的报道。

11.8.4 优先权争议 (简述)

- **Buckmaster 的声明** (<https://cims.nyu.edu/~tristanb/statement.pdf>) [P]: Buckmaster (NYU) 和 Alpöge 8 月 15 日得到光滑外力下的 Boussinesq 和 3D Euler 爆破, 8 月 22 日 Lean 验证, 9 月 7 日 (美东时间) 连同 IPM 的结果一起公开。声明原文只写 "Today"; 9 月 7 日据 Wikipedia [R], 声明 PDF 的元数据是 2026-09-08 02:38 UTC, 即美东 9 月 7 日晚 [P], 按 UTC 算是 9 月 8 日。他们也大量用了 LLM (Claude、Codex)。他把路线的功劳归于 Córdoba 和 Martínez-Zoroa。关于 OpenAI, 他叙述 9 月 6 日通话中 "Eventually it was agreed that [the first prompt] had been sent in the past few days, after information about our work had reached OpenAI", 同时写明 "I am not accusing anyone of anything."
- **OpenAI 的回应** [R]: "it is impossible for Dr. Buckmaster's Codex prompts over the last two months to have influenced the system in any way"。
- **双方说法不一** △: Buckmaster 的叙述是, OpenAI 在他们的进展传到 OpenAI 之后才发出第一条提示词; OpenAI 否认的是他的 Codex 提示词影响过系统。两者针对的问题并不相同 (一个关于时间先后, 一个关于他们的用户数据是否被用到), 目前都没有第三方核实。
- **引用** [P]: 我读的 PDF (生成于 09-08 12:06 PDT) **已经引用** Córdoba–Martínez-Zoroa 的三篇工作 [6–8]; **没有引用** Buckmaster–Alpöge。

11.8.5 剩余风险

1. **Mathlib 定义**：Laplacian、gradient 等来自 Mathlib，"垃圾值约定"可能让陈述偏离原意；但题面要求处处 C^∞ ，影响很小。
2. **工具链**：Lean 4.34.0-rc2 是预发布版本 [P]；nanoda 双内核降低了风险。
3. **人类理解**：没人能说清这个方法能否推广到无外力情形。

11.9 如果为真，意味着什么（以及不意味着什么）

11.9.1 按 Clay 的文本，这算不算"解决了千禧年问题"？

分三层回答。

第一层：题面。算。 官方文本 "we ask for a proof of one of the following four statements", (C) 是其中之一 [P]。奖金规则第 5(b) 条还写明："In the case of the P versus NP Problem and the Navier-Stokes Problem, a resolution in either direction will be evaluated by the standard evaluation procedure" [P, https://www.claymath.org/wp-content/uploads/2022/03/millennium_prize_rules_0.pdf]。两个方向同等有效。

第二层：奖金程序。还差得远。 规则第 4 条要求同时满足 [P]：

- (a) 发表在"合格刊物"上（目前没有投稿报道 $\triangle$ ）；
- (b) 发表后至少过去 **2 年**；
- (c) 在全球数学界获得 "general acceptance"，由 CMI 自行判断；
- (d) 令人满意地回答了官方题面提出的问题。

之后 CMI 还要组成至少 3 人的委员会审查（第 7 条）。第 8(b) 条：CMI 会 "pay special attention to the question of whether a Prize solution depends crucially on insights published prior to the solution"，可以把前人列入获奖名单，这对 Córdoba-Martínez-Zorúa 和 Buckmaster-Alpöge 直接相关。第 8(c) 条：对正确性或归属无法下结论时，可以不授奖。另据报道 OpenAI 表示不申领奖金 [R]。推测：即使明年发表，按"发表后 2 年"，最早也要 2029 年前后才有结论。

第三层：数学界关心的问题。大多数人会说没有。 "流体自己会不会爆"仍然完全开放。OpenAI 的结果没有回答无外力情形，也没有实现 Tao 的纲领 (§11.4.4；§11.7.5 的 family 376 也没有)。

"规格博弈"的说法要小心。 很容易把这件事比作 AI 里的规格博弈 (specification gaming)：满足了题目的字面要求，却没回答提问者真正关心的问题。但这不是作弊：Fefferman 在 2000 年是有意放入 (C) 的，认为它 "retaining the heart of the problem" (§11.6.1)。更准确的说法是：**出题人当年认为 (C) 和 (A) 一样难，2023 年以后的进展表明外力路线比预想的好走。** 题面和意图的差距是事后显现的，不是求解方钻了出题人没想到的空子。

11.9.2 对数学、物理和 AI

1. **数学**：如果成立，这是第一个光滑外力、全空间、 C^∞ 设定下的 NS 爆破：粘性不是万能的。同时发布的无外力 Euler 爆破（7.4 节）如果成立，可能是更大的消息。方法上，用振荡脉冲的二次通量"合成"所需应力，和 Euler 凸积分（Daneri–Székelyhidi）有亲缘关系，论文自己也这么说 [P]。
2. **物理和工程**：对天气预报、湍流模拟和工程几乎没有直接影响。NS 求解器从不依赖整体光滑性定理；真实流体在接近奇点前，分子尺度就让连续介质模型失效。结论是"**模型本身**在人为设计的外力下会坏"，不是"真实的水会出现无穷大速度"。
3. **AI**：三道独立的闸门：形式化通过 $\neq$ 题面忠实 $\neq$ 数学界接受。这里第二道因为用了第三方题面而比较可靠，第三道还远没走完。Buckmaster 说 LLM 让一个数学家加一个模型"can now do all this work in a month"，称之为"a Deep Blue-Kasparov moment" [P]。当 AI 实验室能在听到某个方向有进展后迅速投入大量算力，优先权和署名规范该怎么适应，是一个现实问题。

11.10 自测题

1. 用一句话说明：为什么 $y' = y^2$ 会在有限时间爆破，而 $y' = y$ 不会？ (§11.3.1)
2. NS 方程里哪一项是非线性的？它的物理意义是什么？ (§11.2.3)
3. 为什么说 3D NS 的能量是"超临界"的？用缩放 $\lambda = 1000$ 的数字说明。 (§11.4.2–11.4.3)
4. Clay 的 (A) 和 (C) 在"外力"和"量词（任意/存在）"上分别有什么不同？ (§11.6.1)
5. 为什么"可以自己挑外力"并不让问题变得平凡？关键的困难是什么？ (§11.6.2)
6. OpenAI 的 Lean 题面是谁写的？为什么这一点重要？ (§11.8.1)
7. 按 Clay 规则，从现在到可能颁奖，至少还要经过哪几步？ (§11.9.1)
8. family 376 的流体"计算机"为什么不推进 Tao 的无外力爆破纲领？ (§11.7.5)

附：【检查】答案

- **检查 1**： $[0, 0.0625, 0.25, 0.375, 0.25, 0.0625, 0]$ ，总和 1（脚本核对）。例如中间： $0.5 + 0.25 \cdot (0.25 - 1 + 0.25) = 0.375$ 。
- **检查 2**： $\nabla \cdot (-y, x) = \partial(-y)/\partial x + \partial x/\partial y = 0 + 0 = 0$ ，不可压缩。 $\nabla \cdot (x, y) = 1 + 1 = 2 \neq 0$ ：w 是从原点向外"喷"的流，每个小区域都在净流出，体积在膨胀。
- **检查 3**：(a) $u = (-y, x)$ 的每个分量都是一次函数，二阶导数全为 0，所以 $\Delta u = 0$ ：刚体旋转没有剪切，粘性不起作用。(b) 由 2.3 节， $(u \cdot \nabla)u = (-x, -y)$ ，所以 $\nabla p = (x, y)$ ， $p = (x^2 + y^2)/2 + \text{常数}$ 。**边缘高、中心低**：压力差从外往里推，提供向心力。OpenAI 论文描述涡核时说的"Pressure decreases toward the axis, supplying the leading centripetal force"就是这件事。
- **检查 4**：2 维中 $dx = dy/\lambda^2$ ，能量因子 $\lambda^2/\lambda^2 = 1$ 。
- **检查 5**：不能。 $y' \leq -y + 1$ 且 $y(0) = 0$ ，可以推出 $y \leq 1 - e^{(-t)} < 1$ ；同理 $y \geq -1$ 。线性方程配有界外力，解一直有界。

- **检查 6:** $\partial u_v / \partial t = \sqrt{v} \cdot \partial u / \partial t$ 。 $(u_v \cdot \nabla) u_v$: 速度因子 $\sqrt{v} \times \sqrt{v}$, 导数 ∇ 作用在 $x/\sqrt{v}$ 上带来 $1/\sqrt{v}$, 合计 $\sqrt{v}$ 。 $v \Delta u_v$: $v \times \sqrt{v} \times (1/\sqrt{v})^2 = \sqrt{v}$ 。 三项一致。

附：术语表

术语	一句话解释
ODE / PDE	未知量是一个随时间变化的数 / 一整个场
热方程	$\partial u / \partial t = k \Delta u$, 每个点向邻居平均值靠拢, 只会使东西变平滑
散度 $\nabla \cdot u$	小区域里的净流出; $= 0$ 表示不可压缩
物质导数	$\partial u / \partial t + (u \cdot \nabla) u$, 一小团流体自身的加速度
粘性 $v \Delta u$	相邻流层互相拖拽, 数学上是速度的热方程
雷诺数 Re	UL/v , 非线性与粘性的强弱之比
弱解	只在积分平均意义下满足方程的解, 允许奇点 (Leray 1934)
缩放对称性	$u_\lambda = \lambda u(\lambda x, \lambda^2 t)$ 仍是解
超临界	守恒量 (能量) 在小尺度上越来越管不住
涡拉伸	涡管被拉长变细、转得更快, 3D 才有
Euler 方程	$v = 0$ 的 NS, 无粘性流体
Clay (A)–(D)	千禧年问题的四个可选表述, 证出任一即可
不可判定	没有任何算法能对所有输入都给出正确的是/否答案; 图灵机停机问题是典型例子

附：想继续深入

- **Clay 官方题面** (Fefferman, 5 页, 强烈推荐全文读): <https://www.claymath.org/wp-content/uploads/2022/06/navierstokes.pdf>
- **Clay 奖金规则**: https://www.claymath.org/wp-content/uploads/2022/03/millennium_prize_rules_0.pdf
- **OpenAI NS 论文**: <https://cdn.openai.com/pdf/32d9f210-8b73-45e0-91bc-82a30aef8a9a/navier-stokes.pdf> (先读第 1–2 节, 约 6 页, 几乎不需要 PDE 背景)
- **OpenAI Euler 论文**: <https://cdn.openai.com/pdf/315b36cd-ec98-4023-8342-93345194ece1/euler.pdf>
- **Lean 仓库**: <https://github.com/openai/NavierStokesAndEuler>; 题面上游: <https://github.com/google-deepmind/formal-conjectures/blob/main/FormalConjectures/Millennium/NavierStokes.lean>
- **Buckmaster 声明**: <https://cims.nyu.edu/~tristanb/statement.pdf>

- **family 376** (受迫 NS 中的通用计算) 代表作：
<https://github.com/openai/math/blob/main/preprints/A-Fixed-Particle-Test-for-Computation-in-a-Forced-Viscous-Flow-September-27-2026/manuscript.pdf> ; Lean 范围说明：<https://github.com/openai/math/blob/main/lean/docs/376.md>
- **Terence Tao**, arXiv:1402.0290 (JAMS 2016) 引言讲清了"超临界屏障"; 更通俗的是他的博客 *Why global regularity for Navier-Stokes is hard* (2007)。
- **DeepMind 等**, *Discovery of Unstable Singularities*, arXiv:2509.14185
- **Chen & Hou**, *Stable nearly self-similar blowup of the 2D Boussinesq and 3D Euler equations with smooth data I: Analysis*, arXiv:2210.07191
- **Córdoba & Martínez-Zorúa**, *Blow-up for the incompressible 3D-Euler equations with uniform $C^{1,1/2-\varepsilon} \cap L^2$ force*, arXiv:2309.08495
- **Bertozzi & Majda**, *Vorticity and Incompressible Flow* (剑桥, 2002): Fefferman 题面推荐的教科书。
- 二手报道 (未逐字核对): Quanta 2026-09-08 <https://www.quantamagazine.org/ai-has-solved-one-of-maths-1-million-millennium-prize-problems-20260908/> ; Wikipedia "Navier–Stokes priority controversy" https://en.wikipedia.org/wiki/Navier%E2%80%93Stokes_priority_controversy ; Clay 09-11 声明转述 <https://the-decoder.com/clay-mathematics-institute-says-the-navier-stokes-millennium-prize-problem-has-apparently-been-settled/> ; Implicator <https://www.implicator.ai/clay-institute-navier-stokes-openai-proof-claim/>

数学物理 · FAMILY 362

12. 相对论 Vlasov–Maxwell：等离子体模型会不会自己坏掉

前提只需要：会求导、知道向量的点积和叉积、知道"微分方程描述随时间的变化"。没学过偏微分方程 (PDE) 和等离子体物理也没关系，用到的新概念都会先讲。文中所有数字都由脚本实算或有出处；[P] 表示读过一手材料 (论文、repo、Lean 源码)， $\triangle$ 表示未核实或有冲突。

【检查】是可以自己动手算的小练习，答案在章末。预计阅读时间：60–90 分钟。可以分三次读：§12.1–12.4 (等离子体、相空间、方程本身)、§12.5–12.7 (相对论、"解坏掉"是什么意思、40 年的历史)、§12.8–12.10 (OpenAI 的结果、核实和意义)。

12.0 先说结论：这一章要讲明白的一件事

等离子体 (聚变堆里、太阳风里那种被电离的气体) 有一个标准的数学模型：**相对论 Vlasov–Maxwell 方程组**。它说的是：带电粒子被电磁场推着走，粒子的运动又产生电流，电流反过来改变电磁场。这个闭环是非线性的。

数学家想知道的问题是：从一个正常的初始状态出发，这个模型的解会不会在有限时间内“坏掉”？也就是某个量突然变成无穷大，方程从此失去意义。

这一章要讲清楚的是一条因果链：

解会不会坏掉 $\Leftarrow$ (Glassey–Strauss 1986) 只取决于“最快的粒子的动量会不会在有限时间内冲到无穷大” $\Leftarrow$ 如果能证明“动量每翻一倍都要花至少 $c/\log P$ 的时间” $\Leftarrow$ 这些时间加起来是一个发散的级数（类似调和级数 $1 + 1/2 + 1/3 + \dots$ ），所以有限时间内不可能翻倍无穷多次。

OpenAI 声称 (family 362, 2026-09-23, 49 页论文 + 约 9 万行 Lean) [P]：在**三维、单一粒子种类**的情形下，对任意大小、没有任何对称性要求的光滑初值，解**永远不会坏掉**（整体存在、光滑、唯一）。这是一个大约 40 年的开放问题。

读完这一章，你应该能用自己的话讲出：

- 为什么等离子体要用“相空间密度” $f(t, x, v)$ 而不是普通的密度来描述；
- 为什么整个难题可以归结为“粒子动量会不会在有限时间内爆掉”，以及“翻倍时间之和发散”为什么就够了；
- OpenAI 的结果被核实到什么程度、和 §4 准黎曼猜想（ ζ 函数）相比多了什么风险；
- 它对聚变工程意味着什么（几乎没有直接影响），以及为什么。

12.1 等离子体：为什么要关心

12.1.1 什么是等离子体

把气体加热到足够高的温度，原子中的电子会被打出来，气体变成一锅**带正电的离子 + 带负电的电子**。这就是等离子体，常被称为物质的“第四态”。

两个你熟悉的例子：

- **聚变堆**（托卡马克，如 ITER）：堆芯温度的量级是 10 keV。换算成温度：1 eV 对应约 11,604.5 K，所以 10 keV $\approx$ **1.16 亿 K**（脚本实算）。
- **太阳风**：太阳不断向外吹出的等离子体，典型速度约 400 km/s（ $\triangle$ 这是常引用的典型值，实际在约 300–800 km/s 间变化）。换算成光速的比例：400 / 299,792 $\approx$ **0.0013**（脚本实算）。

12.1.2 “无碰撞”：为什么不能用流体方程

普通气体里分子每秒碰撞无数次，碰撞让局部的速度分布很快变成“热平衡”的钟形曲线，于是可以只用密度、平均速度、温度这几个量描述（这就是流体力学，比如 §11 的 Navier–Stokes）。

高温稀薄的等离子体不一样：粒子两次碰撞之间能跑非常远的距离，在很多情形下比装置尺寸还大（ $\triangle$ 具体数值随密度和温度变化很大，这里只说量级关系）。碰撞来不及把速度分布“抹

平", 同一个位置上可能同时有一群快粒子和一群慢粒子, 甚至两股方向相反的粒子流。只记录平均速度会丢掉关键信息。

所以要换一种描述方式: 不只记录"这里有多少粒子", 还要记录"这里的粒子各自以什么速度在跑"。这就是下一节的相空间。

12.2 相空间与分布函数 $f(t, x, v)$

12.2.1 相空间: 位置 + 速度一起记

一个粒子的状态由两样东西决定: 它在哪 (x) 和它往哪跑、跑多快 (v)。把这两者放在一起, 就得到一个点 (x, v) , 所有可能的 (x, v) 组成的空间叫相空间。

- 在一维直线上, x 是一个数, v 是一个数, 相空间是一个二维平面。
- 在真实三维空间里, x 有 3 个分量, v 有 3 个分量, 相空间是 6 维的。再加上时间, $f(t, x, v)$ 是一个 7 个变量的函数。

分布函数 $f(t, x, v)$ 的意思是: 在时刻 t , 相空间里 (x, v) 附近单位体积内大约有多少粒子。把 f 对所有速度积分, 就回到普通的密度:

$$\rho(t, x) = \int f(t, x, v) dv$$

(位置 x 处一共有多少粒子, 不管速度)

12.2.2 玩具例子: 为什么只看位置不够

直线上 4 个粒子, 两种情况:

	粒子位置	粒子速度
情况 A (对冲的两股束流)	0, 0, 1, 1	+1, -1, +1, -1
情况 B (静止)	0, 0, 1, 1	0, 0, 0, 0

在 $t = 0$ 时, 只看位置, 两种情况完全一样: 位置 0 有 2 个, 位置 1 有 2 个。

但到 $t = 2$ 时 (每个粒子按 $x + v \cdot t$ 移动):

- 情况 A: 粒子跑到 2, -2, 3, -1, 散开了;
- 情况 B: 粒子还在 0, 0, 1, 1。

所以普通密度 ρ 无法预测未来, 相空间密度 f 才能。物理上, "对冲束流"正是等离子体里会引发不稳定性的典型构型 (双流不稳定性), 流体描述看不到它。

12.2.3 把直方图画在相空间里 (脚本实算)

再来一个稍大的例子。12 个粒子，位置 x 在 0 到 4 之间，速度取 ± 0.5 或 ± 1 。按位置每 1 个单位一格统计：

位置格	$[-1,0)$	$[0,1)$	$[1,2)$	$[2,3)$	$[3,4)$	$[4,5)$
$t = 0$ 每格粒子数	0	3	3	4	2	0
$t = 1$ 每格粒子数 (每个粒子移动 $v \times 1$)	1	0	5	3	2	1

(脚本实算，粒子数据见脚本 `精讲/scripts/09_vlasov_maxwell.py`。)

如果你只有 $t = 0$ 那一行的 4 个数字，是推不出 $t = 1$ 那一行的；如果你有每个格子里"速度分别是多少的粒子各几个"（也就是相空间的二维直方图），就能推出来。**f 就是这个二维直方图在格子无限小、粒子无限多时的极限。**

12.3 Vlasov 方程：粒子沿轨迹走，f 跟着搬家

12.3.1 先看没有力的情况（自由流动）

没有任何力时，每个粒子匀速直线运动： $x(t) = x_0 + v \cdot t$ ，速度不变。相空间里的"一团粒子"只是被平移、被剪切，粒子数不会凭空增减。所以

$$f(t, x, v) = f_0(x - v \cdot t, v)$$

意思是："t 时刻在 (x, v) 的粒子，就是 0 时刻在 $(x - vt, v)$ 的那个粒子。"

把这个式子对 t 求导，可以验证它满足

$$\partial f / \partial t + v \cdot \partial f / \partial x = 0$$

【检查 1】设 $f_0(x, v) = e^{-(x^2)} \cdot g(v)$ ，自由流动下 $f(t, x, v) = e^{-(x-vt)^2} \cdot g(v)$ 。直接求 $\partial f / \partial t$ 和 $\partial f / \partial x$ ，验证 $\partial f / \partial t + v \cdot \partial f / \partial x = 0$ 。

12.3.2 加上力：Vlasov 方程

有力 F 作用时，速度也会变： $dv/dt = F$ （这里把质量取为 1）。f 依然是"沿着粒子轨迹不变"，只是轨迹弯了。写成方程：

$$\partial f / \partial t + v \cdot \nabla_x f + F \cdot \nabla_v f = 0$$

- $\nabla_x f$ 是 f 对位置三个分量的偏数组成的向量， $\nabla_v f$ 是对速度三个分量的。

- 三项的意思： f 随时间的变化 + 粒子位置移动带来的变化 + 粒子速度被力改变带来的变化 = 0。

这就是 **Vlasov 方程** (1938)，也叫"无碰撞 Boltzmann 方程"：右边如果加上一个碰撞项，就是 Boltzmann 方程。

一个重要推论： f 沿轨迹不变，所以 f 的**最大值永远不会变大** ($0 \leq f \leq f_0$ 的最大值)。论文 Lemma 3.1 就是这一条。这意味着"粒子在相空间里挤成无穷密"这种坏事不会发生，危险只能来自别处。

12.3.3 力从哪里来：洛伦兹力

带电粒子受的力是**洛伦兹力**（电荷和质量都归一化为 1）：

$$\mathbf{F} = \mathbf{E} + \mathbf{v} \times \mathbf{B}$$

- $\mathbf{E}$ 是电场，直接推粒子；
- $\mathbf{B}$ 是磁场，通过叉积 $\mathbf{v} \times \mathbf{B}$ 让粒子**转弯**。 $\mathbf{v} \times \mathbf{B}$ 永远垂直于 $\mathbf{v}$ ，所以磁场**只改方向、不做功**，不改变粒子的速率。

【检查 2】取 $\mathbf{v} = (1, 0, 0)$ ， $\mathbf{B} = (0, 0, 1)$ 。算 $\mathbf{v} \times \mathbf{B}$ ，并验证它和 $\mathbf{v}$ 的点积为 0。

12.4 Maxwell 方程组：粒子怎么反过来产生场

12.4.1 四条方程的白话版

取光速 $c = 1$ 、并把各种常数吸收掉（论文用的就是这种归一化），Maxwell 方程组是：

$\partial \mathbf{E} / \partial t - \nabla \times \mathbf{B} = -\mathbf{j}$	（电流 $\mathbf{j}$ 和变化的磁场产生电场的变化）
$\partial \mathbf{B} / \partial t + \nabla \times \mathbf{E} = 0$	（变化的电场产生磁场的变化，法拉第定律）
$\nabla \cdot \mathbf{E} = \rho$	（电荷是电场的"源头"，高斯定律）
$\nabla \cdot \mathbf{B} = 0$	（没有"磁荷"）

白话版：

- $\nabla \cdot$ (**散度**)：一个场从某点"往外冒"的量。 $\nabla \cdot \mathbf{E} = \rho$ 说"哪里有电荷，电场就从哪里冒出来"。
- $\nabla \times$ (**旋度**)：一个场在某点"打转"的量。前两条说的是"电场和磁场互相通过打转来驱动对方"。这种互相驱动以**光速**向外传播，就是电磁波（光、无线电）。

12.4.2 自洽耦合：非线性的闭环

把粒子和场接起来：

$$\rho(t, \mathbf{x}) = \int f \, d\mathbf{v} \quad (\text{电荷密度: 把所有速度的粒子加起来})$$

$$\mathbf{j}(t, \mathbf{x}) = \int (\text{粒子的速度}) \cdot f \, d\mathbf{v} \quad (\text{电流: 粒子带着电荷跑})$$

于是形成一个闭环:

f 决定 ρ 和 $\mathbf{j} \rightarrow \rho$ 和 $\mathbf{j}$ 通过 Maxwell 方程决定 $\mathbf{E}$ 、 $\mathbf{B} \rightarrow \mathbf{E}$ 、 $\mathbf{B}$ 通过洛伦兹力决定粒子怎么动 $\rightarrow$ 粒子运动又改变 f 。

单独看, Vlasov 方程对 f 是线性的 (给定 $\mathbf{E}$ 、 $\mathbf{B}$ 的话), Maxwell 方程对 $\mathbf{E}$ 、 $\mathbf{B}$ 也是线性的。**非线性完全来自这个闭环**: 力 $\mathbf{E} + \mathbf{v} \times \mathbf{B}$ 本身依赖于 f 。这和 §11 Navier–Stokes 里 "速度场输运自己" 是同一类结构。

12.4.3 两条"守恒量"

这个系统有两样东西永远不变 (论文第 3 节用的就是它们):

- **粒子数** (f 沿轨迹不变, 相空间体积不变);
- **总能量** = 所有粒子的动能 + 电磁场能量 $\frac{1}{2} \int (|\mathbf{E}|^2 + |\mathbf{B}|^2) d\mathbf{x}$ 。

所以 "总能量爆掉" 是不可能的。要坏, 只能是 **能量往极少数粒子身上、或者往极小的尺度上集中**。这一点是理解后面所有内容的关键。

12.5 为什么要相对论

12.5.1 非相对论版本的毛病

如果用牛顿力学 (速度 = 动量 / 质量, 可以无限大), 粒子可以跑得比光还快。但 Maxwell 方程里场以光速传播。粒子一旦比自己产生的场跑得还快, 模型就自相矛盾了。所以 **物理上自洽的版本必须是相对论的**: 粒子速度永远小于光速。

12.5.2 动量和速度的关系

取 $c = 1$ 、质量 = 1, 记动量为 $\mathbf{p}$ (一个三维向量)。相对论里:

$$\text{速度 } \hat{\mathbf{v}} = \mathbf{p} / \sqrt{1 + |\mathbf{p}|^2}$$

△ **记号提醒**: OpenAI 的论文和 Lean 代码里, 字母 **$\mathbf{v}$ 表示动量**, 速度写成 $u(\mathbf{v}) = \mathbf{v} / \sqrt{1 + |\mathbf{v}|^2}$ (推理摘要里写成 $\hat{\mathbf{v}}$)。所以 $f(t, \mathbf{x}, \mathbf{v})$ 里的 $\mathbf{v}$ 其实是动量。下面我统一用 $\mathbf{p}$ 表示动量、 $\hat{\mathbf{v}}$ 表示速度, 避免混淆。

(脚本实算)

动量 p	速度 $\hat{v}$	离光速还差 $1 - \hat{v}$
0.1	0.0995	0.90
0.5	0.447	0.55
1	0.707	0.29
2	0.894	0.11
10	0.995	0.0050
100	0.99995	0.00005
1000	0.9999995	0.0000005

小动量时 $\hat{v} \approx p$ (牛顿力学)，大动量时 $\hat{v}$ 无限逼近 1 但永远到不了。**动量可以无限大，速度永远小于光速**。这就是为什么下面的"爆破"要用动量而不是速度来谈：速度根本不可能爆。

【检查 3】 $p = 3$ 时 $\hat{v}$ 是多少？（提示： $\sqrt{10} \approx 3.162$ ）

12.5.3 真实粒子在这张表的哪里（脚本实算）

电子的静止能量是 511 keV。给定动能 K ，有 $\gamma = 1 + K/511$ ， $p = \sqrt{(\gamma^2 - 1)}$ ， $\hat{v} = p/\gamma$ ：

电子动能	动量 p (以 $m \cdot c$ 为单位)	速度 $\hat{v}/c$
1 keV	0.063	0.062
10 keV (聚变堆芯温度量级)	0.20	0.19
100 keV	0.66	0.55
1 MeV	2.78	0.94
10 MeV	20.5	0.9988

托卡马克里有一种危险现象叫**逃逸电子** (runaway electrons)：在强电场下，少数电子被持续加速到 MeV 甚至几十 MeV (Δ 量级来自聚变物理综述，例如 Breizman et al., *Nuclear Fusion* 59 (2019) 083001，未逐字核对)。这时相对论效应完全不可忽略。注意：逃逸电子是**物理现象**，动量很大但有限；它和下面要讲的"数学上有限时间内动量 $\rightarrow \infty$ "不是一回事。

12.5.4 光锥：Maxwell 比 Poisson 难在哪里

如果忽略磁场、并假设电场"瞬间"响应电荷分布 ($\nabla \cdot E = \rho$ 且 E 是某个势的梯度)，就得到更简单的 **Vlasov–Poisson** 方程组。它在三维的大初值问题在 1991–92 年已经解决 (Pfaffelmoser 1992, Lions–Perthame 1991, Schaeffer 1991；论文引用了 Pfaffelmoser, [20])。

Maxwell 的场不是瞬间响应，而是以光速传播的。一个粒子在 (t, x) 感受到的场，来自过去的某些时空点：恰好能用光速把信号送到 (t, x) 的那些点，组成一个**后向光锥** (backward light cone)。这样产生的场叫**推迟场** (retarded field)。

难点在于：一个接近光速的源粒子，几乎是**跟着自己发出的光一起跑**。它的场会沿着运动方向堆积起来（物理上叫"相对论性的场压缩"）。当源粒子的速度方向几乎和光线方向平行时，推迟场的公式里会出现很大的因子。OpenAI 论文说的"损失" (§12.8) 就发生在这里。

12.6 "解会不会坏掉"到底是什么意思

12.6.1 一个 ODE 的玩具：有限时间爆破

看最简单的方程 $dp/dt = p^2$, $p(0) = 1$ 。解是 $p(t) = 1/(1 - t)$: $t = 0.5$ 时 2, $t = 0.9$ 时 10, $t = 0.99$ 时 100, **$t \rightarrow 1$ 时趋于无穷**。方程本身完全光滑，解却在 $t = 1$ 坏掉了。这叫**有限时间爆破** (finite-time blowup)。

换一个角度数：p 从 1 翻倍到 2、从 2 翻到 4、从 4 翻到 8.....从 2^k 翻到 2^{k+1} ($k = 0, 1, 2, \dots$) 要花的时间是 $1/2^k - 1/2^{k+1} = 1/2^{k+1}$ 。

翻倍次数	每次花的时间	累计时间
第 1 次	1/2	0.5
第 2 次	1/4	0.75
第 3 次	1/8	0.875
60 次	...	$1 - 2^{-60}$ (脚本实算 ≈ 1.0)

翻倍时间越来越短，加起来收敛 (几何级数和 = 1)，所以在有限时间内可以翻倍无穷多次。这就是**爆破**。

12.6.2 反过来：翻倍时间之和发散 $\Rightarrow$ 不爆破

如果能证明"第 k 次翻倍至少要花 c/k 的时间"，那么翻倍 N 次的总时间至少是 $c \cdot (1 + 1/2 + \dots + 1/N)$ 。这个和叫**调和级数**，它**发散**：

N	$1 + 1/2 + \dots + 1/N$ (脚本实算)
10	2.93
60	4.68
100	5.19
1,000	7.49
1,000,000	14.39


增长很慢 (大约像 $\ln N$)，但没有上限。所以在任何有限时间 T 内，只能翻倍有限次，动量就有界。

这个对比就是整个证明的骨架：

几何级数 $1/2 + 1/4 + \dots$ (收敛) $\rightarrow$ 会爆；调和级数 $1 + 1/2 + 1/3 + \dots$ (发散) $\rightarrow$ 不会爆。

下面的阶梯图画的就是调和级数的部分和：横轴是已经翻倍的次数 k ，每一级台阶高 $1/k$ 。前 60 级加起来约 4.68 (和上表 $N = 60$ 那一行一致)，台阶越来越矮，但总高度不封顶。图右侧的文字提前写出了后面§12.7.1 和§12.8.3 要讲的推理链：每次翻倍至少要 $\sim 1/(k \cdot \log 2)$ 的时间 $\rightarrow$ 有限时间内只能翻倍有限次 $\rightarrow$ 动量有界 $\rightarrow$ 由 Glassey–Strauss 1986，解不会坏掉。真正难的是证明“每次翻倍至少要 $\sim 1/\log P$ 的时间”这一步，这需要§12.8.4 的带符号动量增量估计和数方向改变次数。

Vlasov–Maxwell 证明的收尾：动量每翻一倍要花 $\geq 1/k$ 的时间，而 $\sum 1/k$ 发散



k = 动量已经翻倍的次数
第 k 次翻倍 ($P \approx 2^k$) 至少要 $\sim 1/(k \cdot \log 2)$ 时间
总时间 $\approx$ 调和级数 $\rightarrow \infty$
 $\Rightarrow$ 有限时间内不可能翻倍无穷多次
 $\Rightarrow$ 动量有界 $\Rightarrow$ (Glassey–Strauss 1986)
解可以一直延续：不会爆破

这是 OpenAI 论文 (family 362) 推理摘要里的论证骨架的手算版；真正的难点在于证明“每翻一倍至少要 $\sim 1/\log P$ 时间”这一步 (带符号的动量增量估计 + 方向改变次数计数)。阶梯由 build 脚本计算。

【检查 4】如果能证明的只是“第 k 次翻倍至少要 $1/k^2$ 的时间”，能推出不爆破吗？为什么？

(顺便：§4 准黎曼猜想里 $\zeta(1) = 1 + 1/2 + 1/3 + \dots$ 发散，用的是同一个级数。)

12.6.3 PDE 里的“整体正则性”

对 PDE，“解坏掉”的意思是某个导数或某个量在有限时刻变成无穷，方程从此无法逐点成立。相反的性质叫：

- **局部存在**：从光滑初值出发，至少在一小段时间 $[0, T)$ 内有光滑解。对 Vlasov–Maxwell，这是 Wollman 1984 证明的 (论文 [29])。
- **整体正则性** (global regularity) / **整体经典解**：这个光滑解可以一直延续到所有时间 $t \geq 0$ 。这就是 OpenAI 声称的结果。

还有一个容易混淆的概念：**弱解**。DiPerna–Lions 1989 (论文 [5]) 证明了大初值下“弱解”整体存在。弱解允许函数不光滑、方程只在“平均”意义下成立，而且不知道是否唯一。所以弱解存在**不等于**问题解决。这和 Navier–Stokes 里 Leray 1934 弱解的情况一模一样。

12.7 40 年的历史：问题如何被归约，又卡在哪里

12.7.1 Glassey–Strauss 1986：只需要管住最快的粒子

Glassey & Strauss, "Singularity formation in a collisionless plasma could occur only at high velocities", ARMA 92 (1986) 59–90。标题就是结论：

如果在 $[0, T)$ 上，所有粒子的动量都不超过某个有限的数，那么解可以光滑地延续过 T 。

逆否一下：如果解在有限时刻 T 坏掉，那一定是有粒子的动量在 T 之前冲向了无穷。整个问题被归约为一个关于单个粒子的问题：

在有限时间内，粒子能否被自洽的电磁场加速到无穷大的动量？

这个判据后来被反复重新证明和加强：Klainerman–Staffilani 2002 用傅里叶方法，Bouchut–Golse–Pallard 2003 用物理空间方法；Luk–Strain 2014 证明只需要管住动量在某个固定平面上的投影；Pallard、Sospedra-Alfonso–Illner 等给出各种矩条件（论文 §1.1 列了出处）。但所有这些是条件性的：它们告诉你"只要动量有界就行"，没告诉你"动量确实有界"。

12.7.2 降维：Glassey–Schaeffer

如果让问题"少几个维度"，就能做完：

- **1½ 维**（位置 1 维、动量 2 维）：Glassey–Schaeffer 1990；
- **2½ 维**：Glassey–Schaeffer 1997；
- **2 维**（位置 2 维）：Glassey–Schaeffer 1998，两篇（ARMA 141）。

（全部引自论文参考文献 [6, 7, 9, 10]。）维度低时，场的奇异性更弱，能量守恒足以管住加速。三维时，这个"刚好管住"的余量没有了。

12.7.3 小初值、对称性

- **小初值 / 稀薄等离子体**：Glassey–Strauss 1987（论文 [12]），之后 Schaeffer 2004、Bigorgne 2020/2025、Wang 2022、Wei–Yang 2021 等。思路是：粒子足够稀，场就弱，加速有限。
- **对称性**：Xuecheng Wang 的柱对称大初值结果（arXiv:2203.01199，v1 2022 年，v2 2026-07-16，论文说"to appear in Annals of Mathematics"；第二篇 arXiv:2607.14685，2026-07-16）。这是在 OpenAI 之前最接近的大初值结果，但要求初值绕一根轴旋转对称。

截至 2026-09 之前（以论文 §1.1 的综述为准），对没有大小或对称性限制的三维大初值，问题一直开放。

12.7.4 难点在哪里（直觉版）

总能量守恒给了一个"预算"。要证明某个粒子不被加速到无穷，需要估计它在一段时间里受到的总冲量。最直接的办法是把力的绝对值加起来。但在三维，这样估计会比需要的多出一个

$\sqrt{w}$ 的因子 (w 是接收粒子的能量), 刚好差一点点, 无法闭合。损失发生在源粒子速度几乎平行于光线方向时 (§12.5.4)。

所以必须利用**抵消**: 力有正有负、方向在变, 先积分再取绝对值, 结果可能小得多。难的是在严格证明里抓住这种抵消。

12.8 OpenAI 声称了什么

12.8.1 主结果

论文 *Global classical solutions of the three-dimensional relativistic Vlasov–Maxwell system* (OpenAI, 2026-09-23, 49 页, family 362) 的摘要 [P]:

"We prove global existence and uniqueness for arbitrary smooth admissible initial data in the three-dimensional, one-species relativistic Vlasov–Maxwell system. The particle density is initially compactly supported, and the electromagnetic fields have finite energy and bounded derivatives of all orders. The solution remains smooth on every finite time interval. This resolves the large-data global classical regularity problem for this model, without size or symmetry restrictions on the data."

拆开看:

- **维度**: 三维空间 + 三维动量 ("3+3 维")。
- **方向**: 是**整体正则性** (不爆破), 不是爆破。这和 §11 Navier–Stokes 方向相反。
- **单一粒子种类** (one-species): 只有一种带电粒子, 电荷和质量都归一化为 1, 没有背景电荷。
- **初值条件** ("admissible"): f_0 光滑、非负、**紧支撑** (只在相空间一块有界区域内非零, 所以初始动量有界); E_0 、 B_0 光滑、各阶导数有界、能量有限 (属于 L^2); 满足两条高斯约束 $\nabla \cdot E_0 = \rho_0$ 、 $\nabla \cdot B_0 = 0$ 。
- **结论**: 存在唯一的整体经典解; 在每个有限时间区间 $[0, T]$ 上光滑, 粒子支撑紧 (动量有界, 但**界可以随 T 增长**)。

论文还特意说明 (Theorem 1.1 后): 允许总电荷非零 (于是电场远处有库仑尾巴 $\sim 1/r^2$), 不求场的所有导数平方可积。

【检查 5】总电荷为 Q 的库仑场大小约 $Q/(4\pi r^2)$ 。验证在半径 R 以外, 电场能量 $\frac{1}{2} \int |E|^2 dx$ 是有限的 (只需看 $\int_{R^\infty} (1/r^2)^2 \cdot r^2 dr$ 是否收敛)。这说明"允许非零总电荷"和"能量有限"不矛盾。

12.8.2 证明骨架: 两个命题

论文第 2 节把整个证明拆成两块:

命题 2.2 (局部理论 + 延续判据): 解局部存在唯一; 如果最大存在时间 $T_{\max}$ 有限, 那么最大动量一定无界。这是 Glassey–Strauss 判据 (按 Luk–Strain 2014 的表述), 加上一个技术处理: Luk–Strain 的版本要求场属于 H^5 (一种 Sobolev 空间, 大致是"5 阶导数平方可积"), 而这里的初值只要求导数有界、能量有限, 二者不完全对上。论文的办法是保留库仑部分、把远处的其余场截断, 再用"真空中的 Maxwell 解"补回差值, 利用"信号传播速度有限"保证在给定时间内不影响粒子 (论文 §10)。推理摘要里模型自己发现了这个缝隙, 并多次回头检查。

命题 2.1 (带符号的动量增量估计): 对能量约为 w 的接收粒子, 在长度为 I 的时间区间里,

| 动量变化 | ≤ M · P · √I + A · I · P² · log(2+P) / w

其中 P 是当前最大动量的一个上界, M 、 A 是常数。关键词是**"带符号"**: 先把力沿时间积分 (得到冲量向量), 再取长度, 而不是先取力的大小再积分。

12.8.3 从命题 2.1 到"不爆破": 就是§12.6 的阶梯

论文的推导 (§2, "Proof of Theorem 1.1") 是这样的: 假设 $T_{\max}$ 有限, 那么最大动量无界。设 t_n 是最大能量第一次达到 2^n 的时刻。在第 n 次翻倍的那段时间里, 用命题 2.1 可以推出

$$t_n - t_{n-1} \geq c / \log(2 + 1024 \cdot 2^n)$$

分母约等于 $n \cdot \log 2$, 所以第 n 次翻倍至少要 $\sim c/n$ 的时间, **正是调和级数** (§12.6.2 的阶梯图)。用论文这个精确形式 (取 $c = 1$) 累加 (脚本实算):

翻倍次数 N	$\sum 1/\log(2 + 1024 \cdot 2^n), n = 1 \dots N$
10	0.96
100	3.40
1,000	6.59
10,000	9.90
100,000	13.22

总和和无界增长, 和"在有限的 $T_{\max}$ 之前翻倍无穷多次"矛盾。所以 $T_{\max} = \infty$ 。

这一步是整篇论文最简单的一步。49 页里大约 40 页都在证命题 2.1。

12.8.4 命题 2.1 怎么证 (只读了引言和§12.2, 以下是简化版)

1. **推迟场 + 光锥分箱**。沿着源粒子的轨迹找到它们和接收粒子后向光锥的交点, 按动量大小、距离、三个角度 (源速度、接收速度、光线方向之间) 把贡献分进一个个"箱子" (bins)。用能量

穿过光锥的通量，加上"源粒子在每个箱子里能待多久" (occupation, 占用时间) 的估计，得到力的**绝对值**上界 (论文 §3-5)。

2. **发现损失**。在接收能量 $\sim w$ 时，绝对值估计比需要的多一个 $\sqrt{w}$ 因子。损失集中在"源粒子速度比接收粒子更贴近光线方向"的那一窄条角度区域。
3. **带符号的抵消** (论文 §6)。在这一窄条里，先沿源粒子轨迹积分再取绝对值。一个精确恒等式把"不含源粒子加速度的部分"和"含源粒子加速度的部分"合起来：前者恰好抵消掉一个由光锥几何求导产生的项。力于是被写成"一个全导数 + 一些不那么奇异的项"。其中一项含**接收粒子自己的加速度**，它又等于接收粒子受的力，所以变成"误差 $\propto$ 接收粒子的力"，需要控制它前面的系数。
4. **数方向改变次数** (论文 §7)。在"所有带符号增量都满足命题 2.1"的假设下，用同一个恒等式证明：一个粒子改变方向（转过一个给定角度）的次数是有限的、可数的。在两次转向之间，相对运动是单调的，于是粒子穿过某个角度区域的时间被进一步压缩，得到更好的占用估计。
5. **只挑需要的箱子** (论文 §8)。只对直接估计超过某个可求和阈值的箱子使用带符号论证。在这些箱子上，接收粒子的力的系数在求和后不超过常数 $\times w^{(-1/2)}$ ，**恰好抵消** $\sqrt{w}$ 的损失。
6. **自举 (bootstrap)** (论文 §9)。以上所有都是在"假设命题 2.1 在 $[0, \tau]$ 上成立"的前提下做的。最后得到的是一个**严格更好**的估计，再用连续性论证把假设推到整个区间。论文的 Figure 1 画了这个依赖图。

用分布式系统的语言打个比方：bootstrap 很像"用归纳不变式证明一个协议的安全性"：假设不变式到时刻 τ 成立，证明它在 τ 之后的一小段仍然成立，而且有余量（严格改进），于是它永远成立。

12.8.5 推理摘要说了什么

OpenAI 公开了一份 6 页的"推理摘要" ([reasoning_traces/relativistic-vlasov-maxwell.pdf](#)), 2026-10-06 发布) [P]。它很坦白，几个值得看的点：

- 模型一开始试过 Pfaffelmoser 风格的"停留时间"策略（这正是 1992 年解决 Vlasov-Poisson 的路线），也考虑过把 Wang 的柱对称方法推广到一般情形。
- 中途多次碰壁，留下了具体的数字："the improved occupancy bound forced $H < 0.41z$, while the excessive coefficient required $H > 0.496z$ "。这是通过指数矛盾排除"系数过大"的情形：两条不等式不能同时成立。
- 模型发现自己用来数方向改变的时间窗口太长，把它缩短了一个 $\sim M^2 + A \cdot \log P$ 的因子。
- 摘要的最后一句很坦白，等于自己标出了：结论靠的是几个新估计，引用的延续定理本身并不提供它们："That assertion rests on the occupation bound, direction-count estimate, and cutoff cancellations needed to close the signed momentum bootstrap; the cited continuation theorem alone does not establish those estimates."

12.9 它被核实到什么程度

12.9.1 Lean 陈述：比 §4 的 ζ 陈述长得多，而且定义是自己写的

§4 准黎曼猜想的 Lean 陈述只有一行，用的 `riemannZeta` 是 Mathlib 里的标准定义。这里不一样：Mathlib 里没有 Vlasov–Maxwell 方程，所以挑战文件

`lean/ComparatorChallenges/VlasovMaxwell.lean` (约 140 行) 从零定义了一切：动量、速度、叉积、旋度、散度、电荷密度、电流、方程本身、“经典解”是什么。

主定理：

```
theorem global_classical_solution (d : Datum) (hd : Admissible d) :  
  ∃ s : Solution, Classical d s ∧ SmoothOnFiniteHorizons s ∧  
    ∀ s' : Solution, Classical d s' → SameNonnegativeTime s s'
```

逐词翻译：

- `d : Datum`：初值，一个三元组 (f_0, E_0, B_0) 。
- `hd : Admissible d`：初值满足 `Admissible`，展开是： f_0 光滑 (`ContDiff  $\mathbb{R}$   $\infty$`)、紧支撑 (`HasCompactSupport`)、非负； E_0, B_0 光滑且各阶导数一致有界 (`BoundedSmooth`)； E_0, B_0 平方可积 (`MemLp  $\infty$  2`)； $\nabla \cdot E_0 = \rho(f_0)$ 、 $\nabla \cdot B_0 = 0$ 。
- `∃ s : Solution`：存在一个解 (f, E, B) 。
- `Classical d s`：它是经典解： f, E, B 在 $t \geq 0$ 上 C^1 ； $f \geq 0$ ； E, B 作为 L^2 值函数随时间连续；在每个有限时段内 f 的支撑落在一个紧集里；方程逐点成立； $t = 0$ 时等于初值。
- `SmoothOnFiniteHorizons s`：在每个 $[0, T]$ 上 f, E, B 都无穷次可微。
- `∀ s', Classical d s' → SameNonnegativeTime s s'`：任何别的经典解在 $t \geq 0$ 上都和它完全相同（唯一性）。

这和论文 Theorem 1.1、和 OpenAI 发给模型的题面（推理摘要开头的 prompt）一致。

我手工核对了定义里最容易写错的地方 [P]：

- `velocity  $v = (q \ v)^{-1} \cdot v$` , `$q \ v = \sqrt{(1 + \|v\|^2)}$` ：正是 $\hat{v} = p/\sqrt{(1+p^2)}$ 。✓
- `cross`： $(a_1 b_2 - a_2 b_1, a_2 b_0 - a_0 b_2, a_0 b_1 - a_1 b_0)$ ，标准叉积。✓
- `curl`：第一分量 $\partial_1 F_2 - \partial_2 F_1$ ，以此类推，标准旋度。✓
- `Equations`： $\partial_t f + \hat{v} \cdot \nabla_x f + (E + \hat{v} \times B) \cdot \nabla_v f = 0$ ； $\partial_t E - \nabla \times B = -j$ ； $\partial_t B + \nabla \times E = 0$ ； $\nabla \cdot E = \rho$ ； $\nabla \cdot B = 0$ 。和论文 (1.1) 逐项一致，符号正确。✓

一个 Lean 特有的陷阱：在 Lean/Mathlib 里，对不可微的函数求导会返回 0，对不可积的函数积分也返回 0。如果陈述没要求光滑性，“方程成立”可能被这种默认值钻空子。这里

`Classical` 要求了 C^1 、紧支撑，堵住了这个口子（我的判断，未做形式化审计 $\triangle$ ）。

12.9.2 证明本身（本地 grep，快照 fd4aeeb，2026-10-07）[P]

- 解答模块 `OAI/Analysis/VlasovMaxwell`：207 个 .lean 文件，89,993 行（脚本实算）。最大的子目录是 `Population`（56 个文件，约 3.2 万行，对应论文的占用和箱子估计）和 `Retarded`（53 个文件，约 2.4 万行，对应推迟场）。
- grep 未见 `sorry`、`admit`、`native_decide`、自定义 `axiom`。
- 只 `import Mathlib`，不依赖任何打过补丁的外部库。这比 §4 准黎曼猜想（有一个约 4 万行的依赖补丁）干净。
- 也就是说，Glassey–Strauss 延续判据没有被当作公理假设，而是在这 9 万行里重新证明了（`Continuation/GlobalContinuation.lean` 里有 `bounded_momentum_uniform_restart` 等定理；我只看了定理名，没有读证明 $\triangle$ ）。
- Comparator 配置 `VlasovMaxwell.json`：只允许三条标准公理（`propext`、`Quot.sound`、`Classical.choice`），`enable_nanoda: false`，即没有用第二个独立内核重检。

12.9.3 独立核查和人类专家

- 没有找到任何人公开报告在 362 上跑通了 Comparator（§4 提到的 Goldblatt 复核是针对 ζ 的）。 $\triangle$
- 截至 2026-10-08，没有找到任何动理学 / 等离子体 PDE 专家的具名公开评论（检索过一般媒体和 GitHub 周边）。 $\triangle$ 媒体报道只是复述摘要。
- 时间上的巧合值得注意：Wang 的柱对称大初值论文 2026-07 刚更新并被 Annals 接收，OpenAI 的无对称版本两个月后出现。领域专家（Wang、Luk、Strain、Pallard、Bigorgne 等）是最有资格读这 49 页的人。

12.9.4 剩余风险

1. 陈述忠实性：140 行自定义定义，任何一处细微错误都可能让定理“证明了别的东西”。我核对方程和关键定义，没发现问题，但这不是正式审计。
2. 范围：只有单一粒子种类。真实等离子体至少有电子和离子两种，电荷符号相反，所以粒子之间既有排斥也有吸引。证明是否能直接推广，不知道 $\triangle$ 。一个提醒：在相关的相对论 Vlasov–Poisson 系统里，“排斥”（等离子体）和“吸引”（引力）两种情况的结论可以完全不同（Glassey–Schaeffer 1985，论文 [8]，证明了排斥情形的球对称整体存在；吸引情形已知可以爆破 $\triangle$ 后一点我凭记忆，未重新核对原文）。
3. 没有人类读懂：49 页的 bootstrap 和箱子分解，现在只被机器检查过。

12.10 如果为真，意味着什么（以及不意味着什么）

12.10.1 对数学

1. 一个约 40 年的旗舰开放问题（单种类）得解：从 Glassey–Strauss 1986 的归约，到"动量确实有界"，而且有机器验证。一旦被领域专家确认，它的分量可能超过本批大多数结果（判断）。
2. 方法上的新意：带符号的冲量估计 + 数方向改变次数 + 只在需要的箱子里用抵消。它能否迁移到别的动理学系统（多种类 Vlasov–Maxwell、Einstein–Vlasov 等）是开放的（推测）。
3. 结论比"不爆破"更细：每个有限时段内动量有界，但这个界可以随时间增长。它没有说长时间后粒子动量会怎样（比如是否趋于某个稳定状态）。长时间行为是另一个问题。

12.10.2 对聚变和空间物理：几乎没有直接影响

这一点值得说清楚，因为媒体容易写成"AI 解决了聚变里的数学难题"。

- **工程模拟不依赖这个定理。**聚变界用的是粒子网格法（PIC）、回旋动理学（gyrokinetic）代码、流体/MHD 代码。它们在离散网格上算，有有限分辨率和有限时间步，从来不需要假设连续方程整体光滑。
- **模型本身和真实装置差很远：**真实托卡马克有至少两种粒子、有碰撞（长时间尺度上重要）、有金属壁和边界条件、有外加线圈的强磁场。这个定理是在**整个无界三维空间、没有外场、只有一种粒子**的条件下证的。
- **逃逸电子不是数学爆破：**工程上担心的逃逸电子能量很大但有限。定理说的是"在有限时间内不会冲到无穷"，它不能告诉你逃逸电子在真实装置里最多能到多少 MeV。

一个更准确的定位：它是一张**模型健康证明**。它告诉物理学家，这个方程组作为数学对象是自洽的：从合理的初值出发，在任何有限时间内都不会自己产生无穷大的动量。（注意管住的是单个粒子的**动量**，不是总能量：**总能量**本来就是守恒的。）这对理论家有价值（比如保证某些推导的前提成立），但不会改变任何人今天怎么设计聚变堆。

12.10.3 对 AI

- 这是本批结果里**分量最重的数学物理结果之一**：一个有名有姓、有完整文献链的开放问题，结论清晰，有 **Lean 证明而且只依赖 Mathlib**。
- 和 §4 对比：准黎曼猜想的陈述用的是社区定义（风险在依赖补丁），这里的风险在**自定义的陈述**。对机器证明的 PDE 结果，"陈述是否忠实"是新的人类瓶颈：读 140 行 Lean 定义，比读 49 页论文容易得多，但仍然需要懂行的人。
- 推理摘要显示了一个比较像人类研究者的过程：先试已知方法，碰壁，发现具体的指数矛盾，修正时间窗口，反复审计依赖顺序。但我们看到的是 OpenAI 编辑过的摘要，不是原始推理过程。

12.11 自测题

读完后试着回答。如果答不上来，回到对应小节再读一遍。

1. 为什么等离子体不能只用位置密度 $\rho(t, x)$ 描述？举一个例子。（§12.2.2）

- 2. Vlasov 方程说"f 沿粒子轨迹不变"。由此可以推出 f 的最大值有什么性质？ (§12.3.2)
- 3. 为什么在相对论版本里，讨论"爆破"要看动量而不是速度？ (§12.5.2)
- 4. Glassey–Strauss 1986 把整个问题归约成了什么？ (§12.7.1)
- 5. "第 k 次翻倍至少要 c/k 时间"为什么能推出不爆破？ 如果是 c/2^k 呢？ (§12.6.1–12.6.2)
- 6. OpenAI 的 Lean 陈述和 §4 ζ 的 Lean 陈述相比，主要的额外风险在哪里？ (§12.9.1、§12.9.4)
- 7. 为什么说这个结果对聚变工程几乎没有直接影响？ 至少说出两条原因。 (§12.10.2)

附：【检查】答案

- **检查 1**：令 $s = x - vt$ 。 $\partial f / \partial t = e^{(-s^2)} \cdot (-2s) \cdot (-v) \cdot g(v) = 2vs \cdot e^{(-s^2)} g(v)$ ； $\partial f / \partial x = e^{(-s^2)} \cdot (-2s) \cdot g(v) = -2s \cdot e^{(-s^2)} g(v)$ 。 所以 $\partial f / \partial t + v \cdot \partial f / \partial x = 2vs \cdot e^{(-s^2)} g - 2vs \cdot e^{(-s^2)} g = 0$ 。
- **检查 2**： $v \times B = (0 \cdot 1 - 0 \cdot 0, 0 \cdot 0 - 1 \cdot 1, 1 \cdot 0 - 0 \cdot 0) = (0, -1, 0)$ 。 和 $v = (1, 0, 0)$ 的点积是 0。 粒子被往 -y 方向推，但速率不变，只是转弯。
- **检查 3**： $\hat{v} = 3 / \sqrt{10} \approx 3 / 3.162 \approx \mathbf{0.949}$ (脚本：0.9487)。
- **检查 4**： 不能。 $1/1^2 + 1/2^2 + 1/3^2 + \dots$ 收敛 (等于 $\pi^2/6 \approx 1.645$ ， §4 里的 $\zeta(2)$)。 总时间有限，有限时间内可以翻倍无穷多次，排除不了爆破。 必须是像 1/k 这样"和发散"的下界。
- **检查 5**： $\int_{-R}^R (1/r^2)^2 \cdot r^2 \, dr = \int_{-R}^R r^{-2} \, dr = 1/R$ ， 有限。 带上常数， $\frac{1}{2} \int_{\{|x|>R\}} |E|^2 dx = Q^2 / (8\pi R)$ ； $Q = 1$ 时， 脚本算的 $\int_{-R}^R (1/(4\pi r^2))^2 \cdot 4\pi r^2 \, dr = 1/(4\pi R)$ ， $R = 1$ 时 ≈ 0.0796 ， $R = 10$ 时 ≈ 0.0080 。 在三维里 $1/r^2$ 的场是平方可积的 (在远处)； 靠近原点的部分因为电荷是光滑分布的，也不会发散。

附：术语表

术语	一句话解释
等离子体	被电离的气体，由离子和电子组成
无碰撞	粒子两次碰撞间跑得很远，碰撞来不及把速度分布抹平
相空间	位置 + 速度 (或动量) 组成的空间，三维时是 6 维
分布函数 f(t, x, v)	相空间里单位体积内的粒子数；论文里 v 指动量
Vlasov 方程	f 沿粒子轨迹不变；"无碰撞 Boltzmann 方程"
洛伦兹力	$E + \hat{v} \times B$ ；磁场只改方向不做功
Maxwell 方程组	电荷和电流如何产生电场和磁场，场以光速传播
自洽耦合	粒子产生场、场推粒子的闭环；非线性的来源
后向光锥 / 推迟场	能以光速把信号送到当前点的过去时空点；从那里来的场
Vlasov–Poisson	忽略磁场、电场瞬间响应的简化版；3D 已于 1991–92 解决

术语	一句话解释
有限时间爆破	解在有限时刻某个量趋于无穷
整体经典解 / 整体正则性	光滑解对所有 $t \geq 0$ 都存在
弱解	只在平均意义下满足方程、可能不光滑不唯一的解
延续判据	"只要某个量有界，解就能延续"类型的定理
紧支撑	函数只在一块有界区域内非零
bootstrap（自举）	假设估计成立，推出更强的估计，再用连续性去掉假设
调和级数	$1 + 1/2 + 1/3 + \dots$ ，发散

附：想继续深入

- **原始论文**：<https://github.com/openai/math/blob/main/preprints/Global-classical-solutions-of-the-three-dimensional-relativistic-Vlasov-Maxwell-system-September-23-2026/paper.pdf>（建议先读 §1–2，共 7 页，第 2 节的"Proof of Theorem 1.1"就是本章§12.8.3的完整版）
- **推理摘要**：https://github.com/openai/math/blob/main/reasoning_traces/relativistic-vlasov-maxwell.pdf（6 页）
- **Lean 陈述**：
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/VlasovMaxwell.lean>
 ；范围说明：<https://github.com/openai/math/blob/main/lean/docs/362.md>
- **Glasse & Strauss 1986**，ARMA 92:59–90，<https://doi.org/10.1007/BF00250732>（问题的归约）
- **Luk & Strain 2014**，*A new continuation criterion for the relativistic Vlasov–Maxwell system*，CMP 331:1005–1027，arXiv:1406.0165（现代、较易读的延续判据证明，OpenAI 论文用的就是它的表述）
- **Wang**，柱对称大初值：arXiv:2203.01199、arXiv:2607.14685（OpenAI 之前最接近的结果）
- **Robert Glassey**，*The Cauchy Problem in Kinetic Theory*（SIAM，1996）：这个领域的标准教科书，前几章讲 Vlasov–Poisson 和 Vlasov–Maxwell 的基本理论。
- **入门物理**：Francis F. Chen，*Introduction to Plasma Physics and Controlled Fusion*（其中"动力学理论"一章讲 Vlasov 方程，△ 章节号未核对），适合补等离子体背景。

13. Mézard–Parisi 公式（稀释自

旋玻璃)：从磁铁到神经网络的能量地形

前提只需要：会算指数和对数 (e^x 、 $\ln x$)、知道"期望" (平均值) 是什么、知道求和符号 Σ 。物理概念 (能量、温度、自由能) 都会从头讲。你学神经科学时见过的 Hopfield 网络会在 §13.10 回来。文中所有数字都由脚本实算或有出处；[P] 表示读过一手材料 (论文、repo、Lean 源码)， $\triangle$ 表示未核实或有冲突。【检查】是可以自己动手算的小练习，答案在章末。预计阅读时间：70–100 分钟。可以分三次读：§13.1–13.4 (自旋、自由能、复本方法)、§13.5–13.7 (稀疏图、cavity 方法、问题本身)、§13.8–13.10 (OpenAI 的结果、核实和意义)。

13.0 先说结论：这一章要讲明白的一件事

磁铁里有大量小磁针 ("自旋")，每根只能朝上或朝下。如果小磁针之间的相互作用是**随机**的，有的想同向、有的想反向，就会出现"怎么摆都不能让所有人满意"的局面。这种系统叫**自旋玻璃**。物理学家关心的核心量是**自由能**：知道它，就能推出系统在每个温度下的几乎所有宏观性质。

物理学家 (主要是 Parisi 和 Mézard) 在 1979–2001 年间用一套**数学上不严格**的方法 (复本方法、cavity 方法) 写出了自由能的公式。数学家花了几十年，把其中一部分变成定理。这一章的因果链是：

自由能 = 一个"层级试探泛函"的最小值 $\Leftarrow$ 上界早已证明 (插值法, 2003–04) $\Leftarrow$ 下界 (等号) 需要控制"多个复本同时看到的自旋图案" $\Leftarrow$ 稠密模型 (SK) 里两两重叠就够，稀疏模型里不够，这一步卡了二十多年。

OpenAI 声称 (family 221, 2026-09-23, 36 页论文 + 约 5.6 万行 Lean) [P]: 在一类**稀疏模型** (Poisson 稀释、偶数元相互作用、满足 Panchenko–Talagrand 条件) 里补上了下界，从而证明等号成立，并给出 Lean 形式化。

注意："Mézard–Parisi"这个名字在文献里至少指两件不同的事。OpenAI 证明的是**稀释自旋玻璃的层级 cavity 公式** (Mézard–Parisi 2001)，**不是著名的随机分配问题 $\zeta(2) = \pi^2/6$**

(Mézard–Parisi 1985–87, Aldous 2001 年已证)。§13.6 会讲后者，因为它是理解"物理学家的非严格方法为什么可信"的最好例子。

读完这一章，你应该能用自己的话讲出：

- 自由能是什么，为什么"对 $\log Z$ 求平均"难，复本方法用什么技巧绕开它；
- 稠密 (SK) 和稀疏 (Viana–Bray / Bethe 格) 模型的区别，cavity 方法在树上为什么精确；
- OpenAI 证明的定理到底覆盖什么、不覆盖什么 (3-SAT、固定度数的 Bethe 格、Hopfield 都不在内)；
- 它和 ML / 神经科学的联系里，哪些是真的、哪些只是类比。

13.1 磁铁和自旋：Ising 模型

13.1.1 自旋

把磁铁想成一排小磁针，每根小磁针只有两个状态：朝上记作 $\sigma = +1$ ，朝下记作 $\sigma = -1$ 。这个只能取 ± 1 的变量叫**自旋** (spin)。N 个自旋的一种取法（例如 $+1, -1, -1, +1$ ）叫一个**构型**，一共有 2^N 种构型。

你在神经科学里见过同样的东西：神经元"放电 / 不放电"的二值模型，Hopfield 网络里就是这样记的。

13.1.2 能量

两个自旋 i, j 之间有一个**耦合强度** J_{ij} 。系统的能量（物理学家叫 Hamiltonian）是：

$$H(\sigma) = - \sum_{\text{相连的 } i, j} J_{ij} \cdot \sigma_i \cdot \sigma_j \quad (\text{有时再加一项 } - \sum h_i \sigma_i, h \text{ 是外磁场})$$

看一对自旋：

- $J_{ij} > 0$ (**铁磁**)： $\sigma_i = \sigma_j$ 时乘积 $\sigma_i \sigma_j = +1$ ，能量贡献 $-J$ ，低；所以它们"想同向"。
- $J_{ij} < 0$ (**反铁磁**)：它们"想反向"。

物理系统倾向于能量低的状态。能量最低的构型叫**基态**。

这个能量函数和你的神经科学背景直接相连：Hopfield 网络 (1982) 的能量 $E = -\frac{1}{2} \sum W_{ij} \sigma_i \sigma_j$ 就是这种形式，也就是一个自旋玻璃式的 Hamiltonian。存进去的记忆是这个能量的局部极小；网络从一个残缺的线索出发，每一步更新都不让能量上升，最后停在附近的一个极小上 (§13.10.3 回来细讲)。

13.1.3 Boltzmann 分布：温度怎么进来

在温度 $T > 0$ 时，系统不会死守基态，而是以一定概率出现在每个构型。概率由 **Boltzmann 分布** 给出：

$$P(\sigma) = e^{(-\beta \cdot H(\sigma))} / Z, \quad Z = \sum_{\text{所有构型}} e^{(-\beta \cdot H(\sigma))}, \quad \beta = 1/T$$

β 叫**逆温度**。Z 是把所有权重加起来的归一化常数，叫**配分函数** (partition function)。这个式子你在 ML 里天天见：它就是 **softmax**，只是"logit"换成了 $-\beta \cdot \text{能量}$ 。 β 就是 softmax 的逆温度参数。

最小例子：两个自旋， $J = 1$ (铁磁)， $H = -\sigma_1 \sigma_2$ 。四个构型： $(+, +)$ 和 $(-, -)$ 能量 -1 ； $(+, -)$ 和 $(-, +)$ 能量 $+1$ 。脚本实算：

β	Z	P(某个同向构型)	P(某个反向构型)	P(同向, 合计)
0 (无穷高温)	4.000	0.250	0.250	0.500
0.5	4.511	0.366	0.135	0.731
1	6.172	0.440	0.060	0.881
2	15.05	0.491	0.009	0.982
5	296.8	0.500	0.000	1.000

高温时四种构型等概率（热运动把一切抹平）；低温时几乎只剩基态。温度就是在"能量"和"混乱度"之间调权重的旋钮。

【检查 1】手算 $\beta = 1$ 时 $P(+,+) = e / (2e + 2e^{-1})$ ，验证它约等于 0.440。

13.2 挫折与自旋玻璃

13.2.1 挫折的三角形

三个自旋排成三角形，三条边都是反铁磁 ($J = -1$)：每对都想反向。能量 $H = \sigma_1\sigma_2 + \sigma_2\sigma_3 + \sigma_1\sigma_3$ 。

问题：三个只能取 ± 1 的数，不可能两两都不同。所以**无论怎么摆，至少有一条边不满意**。这叫**挫折** (frustration)。

脚本枚举全部 8 个构型：

	基态能量	基态个数	零温熵 $\ln(\text{基态数})$
铁磁三角形 ($J = +1$)	-3 (三边全满足)	2 (全上、全下)	$\ln 2 \approx 0.693$
反铁磁三角形 ($J = -1$)	-1 (只能满足两边)	6	$\ln 6 \approx 1.792$

反铁磁三角形的配分函数是 $Z(\beta) = 2e^{(-3\beta)} + 6e^{\beta}$ ($\beta = 1$ 时脚本算得 16.409，与公式一致)。挫折带来两个后果：(1) 基态能量被"抬高"了 (-1 而不是 -3)；(2) 基态**高度简并**（很多个构型并列最低）。

【检查 2】列出反铁磁三角形的 8 个构型和各自的能量，确认只有 2 个能量是 +3、6 个是 -1。

13.2.2 自旋玻璃：随机的耦合

如果每条边的 J_{ij} 是**随机**的正负号（或随机高斯数），挫折就到处都是：随机取三个 ± 1 符号，三角形被挫折（三个符号乘积为负）的概率正好是 1/2（脚本枚举 8 种符号组合）。这种系统叫**自旋玻璃** (spin glass)。名字来自真实材料（例如铜里掺少量锰），它们在低温下自旋"冻住"在一个无序的方向上，像玻璃一样"有序地无序"。

这里有一个在 ML 里也会出现的关键区分：耦合 J 是"冻住的随机性" (quenched disorder)，抽一次就固定；自旋 σ 才是在 Boltzmann 分布下"热运动"的变量。类比： J 是一个训练集， σ 是在这个训练集上的参数。

13.2.3 崎岖的能量地形

"挫折到处都是"带来**崎岖的能量地形**：很多个局部极小，彼此被能量壁垒隔开。脚本实验：把"翻转任何一个自旋都不能降低能量"的构型叫**单翻稳定构型**（局部极小），数一数：

系统	N	单翻稳定构型个数
全连接铁磁（所有 $J = 1/N$ ）	12	2（全上、全下）
SK 自旋玻璃（ J 随机高斯）	12	平均 13.1（20 个样本，最少 6，最多 24）
SK 自旋玻璃	16	平均 23.2（5 个样本）

文献结果是 SK 的单翻稳定构型数随 N **指数增长**，约为 $e^{(0.199 \cdot N)}$ （Tanaka–Edwards 1980 / Bray–Moore 1980 $\triangle$ 常数按文献记忆，未重新核对原文）。代入 $N = 12、16$ 得 10.9、24.2，和上表的实算量级吻合。

13.3 自由能：物理学家为什么想要它

13.3.1 定义

自由能

$F = -(1/\beta) \cdot \ln Z$

"压强"

每个自旋的 $(1/N) \cdot \ln Z$ (OpenAI 论文用的就是这个量，叫 pressure)

压强 = $-\beta F/N$ ：两者只差一个因子 $-\beta/N$ ($-\beta$ 来自符号和温度， $1/N$ 来自"每个自旋")，本质上是同一个东西。

13.3.2 为什么想要它

因为 $\ln Z$ 是一个"生成函数"：对它求导就能得到几乎所有宏观量。例如平均能量 $\langle E \rangle = -\partial(\ln Z)/\partial\beta$ ，熵 $S = \beta(\langle E \rangle - F)$ 。在挫折三角形上脚本实算： $\beta = 5$ 时，反铁磁三角形的熵 $S = 1.7918$ ，几乎正好是 $\ln 6 = 1.7918$ （6 个基态等概率）；铁磁三角形的熵是 $0.6931 = \ln 2$ 。

ML 里的对应物： $\ln Z$ 就是 log-sum-exp；ELBO 是 $\ln Z$ 的下界。

13.3.3 真正的难点：要对 $\ln Z$ 求平均

对自旋玻璃， Z 本身是随机的（依赖于抽到的 J ）。物理上有意义的是**典型**样本的自由能，也就是 $E[\ln Z]$ ("淬火平均", quenched average)。

而 $\ln E[Z]$ ("退火平均", annealed average) 好算得多： $E[Z]$ 是对 $\sum e^{(...)}$ 求期望，可以把期望换进求和里，每项都是高斯积分。但两者不相等。由于 $\ln$ 是凹函数，Jensen 不等式给出

$$E[\ln Z] \leq \ln E[Z]。$$

脚本实算（SK 模型，N = 10，β = 2，2000 个随机样本，每个样本精确枚举 1024 个构型）：

量	每个自旋的值
淬火 (1/N)·E[ln Z]	1.387
退火 (1/N)·ln E[Z]（精确公式 $\ln 2 + \beta^2(N-1)/(4N)$ ）	1.593

差距很大。原因是 E[Z] 被极少数"运气特别好"的样本主导，不代表典型情况。对 SK 模型，N → ∞ 时两者在 β ≤ 1 时相等，β > 1（低温）时分开，这正是自旋玻璃相变（已确立结果）。

这一章的全部难度，都来自"要算 E[ln Z]，而 ln 不能和期望交换"。

13.4 复本方法与复本对称破缺：一个"不严格但对"的传统

13.4.1 复本技巧

物理学家用了一个恒等式：

$$\ln Z = \lim_{n \rightarrow 0} (Z^n - 1) / n$$

验证（脚本）：ln 5 = 1.6094；取 n = 1, 0.1, 0.01, 0.001，(5^n - 1)/n 依次为 4.000, 1.746, 1.622, 1.611，确实趋向 ln 5。

好处在于：当 n 是**正整数**时，Z^n = Z·Z·...·Z 是 **n 个独立副本**（"复本", replica）的配分函数，E[Z^n] 可以算（又能把期望换进求和）。于是策略是：

1. 对整数 n 算出 E[Z^n]；
2. 把得到的公式"假装"对实数 n 也成立；
3. 让 n → 0。

第 2 步在数学上完全没有依据（整数上的值不唯一决定实数上的函数），第 3 步还要交换 n → 0 和 N → ∞ 两个极限。这就是为什么说它"不严格"。

13.4.2 复本对称及其失败

算 E[Z^n] 时，会出现一个 n × n 的矩阵 Q_ab，叫**重叠**（overlap）：

$$Q_{ab} = (1/N) \sum_i \sigma_i^a \cdot \sigma_i^b \qquad \text{（复本 a 和复本 b 的构型有多像，取值在 -1 到 1 之间）}$$

最自然的猜测是所有复本"平等"，所有非对角 Q_ab 相等，这叫**复本对称**（replica symmetric, RS）。Sherrington 和 Kirkpatrick 1975 年在 SK 模型上就是这么做的，结果在低

温下出了明显的错：零温熵算出来是 $-1/(2\pi) \approx -0.159$ ，而 Ising 系统的熵不可能为负（构型数至少是 1， $\ln 1 = 0$ ）；RS 预测的基态能量 $-\sqrt{2/\pi} \approx -0.798$ ，也和数值模拟不符。

13.4.3 Parisi 的复本对称破缺


Parisi 1979 年提出：复本不平等，而是组成**层级**。把 n 个复本先分成大组，大组里再分小组，小组里再分更小的组.....同一小组内的重叠大，不同大组之间的重叠小。分 r 层叫 **r 步复本对称破缺** (r-RSB)， $r \rightarrow \infty$ 叫完全 RSB。

物理解释 (Mézard–Parisi–Sourlas–Toulouse–Virasoro 1984 起逐步建立)：低温下 Gibbs 分布分裂成很多个"纯态"（大致对应能量地形里的深谷），这些谷组成一棵**树**：两个谷越"亲"，在树上的公共祖先越深。这种距离结构叫**超度量** (ultrametric)：任意三点中，最大的两个距离相等，就像生物分类树上的物种距离。


Parisi 公式里出现的参数 $0 < m_1 < m_2 < \dots < m_r < 1$ ，就是树上各层的"分叉强度"。后面 OpenAI 论文和 Lean 里的 `Exponents m` 指的正是它们。

下图把前面两件事放在一起。左边是§13.2.1 的挫折三角形：三条边都想反向，8 种构型里没有一种能同时满足三条边（虚线那条总是不满足），基态 6 重简并。右边是 Parisi 的层级树：纯态先分成大组，大组里再分；两个纯态的共同祖先越深（越"近亲"），重叠越大。图右下角那句"稀释模型要控制所有多复本重叠"是§13.7.3 要讲的难点。

左：最小的"挫折"系统 · 右：Parisi 的层级（超度量）结构



三条边都"想要反向"（反铁磁）
8 种构型里没有一种能让三条边同时满足（虚线那条必然不满足）：基态 6 重简并
 $Z(\beta) = 2e^{(-3\beta)} + 6e^{\beta}$



两个纯态越"近亲"（共同祖先越深），重叠越大
稀释模型要控制所有多复本重叠——这是难点

自旋玻璃 = 随机正负耦合 + 到处是挫折 + 指数多个亚稳态。Hopfield 网络（1982）的能量函数就是这种 Hamiltonian；感知机容量（Gardner 1988）也是用同一套复本方法算的。

13.4.4 物理对了，数学花了 27 年

年份	事件	性质
1975	Sherrington–Kirkpatrick 提出 SK 模型（每对自旋都耦合）	定义
1979–80	Parisi 写出 SK 自由能公式（RSB）	物理推导，不严格

年份	事件	性质
2003	Guerra 用"插值法"证明 Parisi 公式是自由能的上界	定理
2006	Talagrand 证明等号 (Annals of Math. 163)	定理
2013	Panchenko 证明超度量性 (Annals of Math. 177)	定理
2021	Parisi 获诺贝尔物理学奖 (与 Manabe、Hasselmann 共享)	—
2024	Talagrand 获 Abel 奖 (自旋玻璃工作是主要理由之一)	—

SK 基态能量的数值：Parisi 公式给出每个自旋 **-0.7632** (高精度值 -0.763166..., Crisanti–Rizzo 2002 $\triangle$ 按文献引用)。脚本对小系统精确枚举 ($H = -\sum_{\{i<j\}} J_{ij} \sigma_i \sigma_j$, $J_{ij} \sim N(0, 1/N)$):

N	样本数	每个自旋的基态能量
8	400	-0.571 ± 0.006
12	200	-0.609 ± 0.006
16	40	-0.655 ± 0.013
20	8	-0.683 ± 0.022

随 N 增大在往 -0.763 走，但很慢 (有限尺寸修正大约按 $N^{(-2/3)}$ 衰减, $\triangle$ 文献结论，这里没有拟合验证)。这张表的意义是：**小系统暴力枚举给不出极限值，必须有公式。**

这是本章最重要的背景：在自旋玻璃领域，物理学家的非严格方法屡次给出正确答案，数学家随后花十几到几十年追上。OpenAI 的这个结果，是这条"追赶"链条上的一环。

13.5 稀疏图和 cavity 方法

13.5.1 稠密 vs 稀疏

SK 模型里**每一对**自旋都有耦合，每个自旋有 $N - 1$ 个邻居，每个耦合都很弱 (量级 $1/\sqrt{N}$)。这叫**稠密** (mean-field) 模型。

真实的物理和很多计算问题是**稀疏**的：每个自旋只和**有限多个**其他自旋相互作用，即使 N 很大，每个自旋的邻居数也只是 3、5 这种常数。两种标准随机构造：

- **Poisson 稀释** (Viana–Bray 1985)：随机撒 αN 条边 (OpenAI 的定理里，边数本身也取 $\text{Poisson}(\alpha N)$)，每个自旋的度数近似服从 Poisson 分布。
- **Bethe 格 / 随机正则图**：每个自旋的度数**固定**为同一个数。Mézard–Parisi 2001 的原始论文用的是这种。

13.5.2 稀疏随机图"局部像树"

关键性质：稀疏随机图里**短环很少**。脚本实算（平均度数 3 的 Erdős–Rényi 图）：

N	平均三角形个数	平均度数	孤立点比例
100	4.8	2.82	0.058
1,000	3.8	2.99	0.053
10,000	4.1	3.01	0.049
100,000	3.4	3.00	0.049

理论值：三角形个数趋于 $c^3/6 = 4.5$ 个（**不随 N 增长**），孤立点比例趋于 $e^{-3} \approx 0.0498$ 。也就是说，图越大，“一个点周围出现短环”的比例越接近零：从任何一个点往外看几步，看到的几乎都是一棵树。

13.5.3 cavity 方法：在树上精确

cavity（空腔）方法的想法：把一个自旋拿掉，看剩下的系统怎么“对待”这个空出来的位置。

在**树上**这完全精确。拿掉自旋 i 后，它的各个邻居分属互不相连的子树，彼此独立。每个邻居 j 给 i 传一条“消息”（一个等效磁场 $u_{j \rightarrow i}$ ）， i 把收到的消息加起来就得到自己的状态。消息的更新规则是：

$$u_{j \rightarrow i} = (1/\beta) \cdot \operatorname{artanh}(\tanh(\beta \cdot J_{ij}) \cdot \tanh(\beta \cdot h_j^{\text{cavity}}))$$

其中 h_j^{cavity} 是“去掉 i 之后 j 感受到的总场”。这就是 ML 里的 **belief propagation (BP)**，同一个算法，物理学家和 Pearl 分别发明。

最小例子（【检查 3】会让你手算）：两个自旋， $J = 1$ ，自旋 1 上有外场 $h = 0.5$ ， $\beta = 1$ 。自旋 2 的磁化（平均值）精确等于 $\tanh(1) \cdot \tanh(0.5) = 0.35195$ 。脚本精确枚举得 0.35195，一致。

脚本对一棵 5 个点、随机耦合和外场的树：精确枚举 32 个构型算出的 5 个磁化，与 BP 结果的最大差是 4.9×10^{-16} （机器精度）。再加两条边造出环：最大差变成 **0.16**。**cavity / BP 在树上精确，在短环上不精确**。稀疏随机图“局部像树”，所以有理由期望 cavity 方法在 $N \rightarrow \infty$ 时变精确，但这需要证明。

13.5.4 复杂之处：很多个纯态时，消息变成“分布的分布”

高温时，BP 有唯一的不动点，每条边一个消息；对随机图取平均，序参量是“**消息的分布**” $\zeta \in P(\mathbb{R})$ 。这就是 RS 层（ $r = 0$ ）。

低温自旋玻璃相里有很多纯态（§13.4.3 的树），每个纯态里一条边的消息不同。于是描述“消息在各个纯态之间怎么分布”，再对图的随机性取平均，序参量变成“**消息的分布的分布**”；有 r 层 RSB 就嵌套 $r + 1$ 层：

层级 0: $\mathbb{R}$ (一条消息)
层级 1: $P(\mathbb{R})$ (消息的分布)
层级 2: $P(P(\mathbb{R}))$ (消息的分布的分布)
.....

Lean 陈述里的 `Hierarchy` 正是这个定义: $H_0 = \mathbb{R}$, $H_{r+1} = P(H_r)$ 。这就是"层级 cavity 公式"里"层级"的含义。

Mézard–Parisi 2001 (*The Bethe lattice spin glass revisited*, EPJ B 20:217) 对固定度数的 Bethe 格写出了这一框架和显式的 1RSB 泛函; 任意有限层 r 的一般形式, 以及它是自由能上界的证明, 来自 Panchenko–Talagrand 2004 (见§13.7)。

13.6 另一个“Mézard–Parisi”: 随机分配与 $\zeta(2)$

这一节不是 OpenAI 的结果, 但它是"物理学家非严格方法 → 数学定理"最漂亮的例子, 而且和 §4 准黎曼猜想里的 $\zeta(2) = \pi^2/6$ 是同一个数。

13.6.1 问题

n 个工人、 n 项工作, 工人 i 做工作 j 的成本 C_{ij} 是独立的随机数, 服从均值为 1 的指数分布。要找一个一一对应的分配, 使总成本最小。问: 最小总成本的期望是多少?

直觉可能以为它随 n 增长 (毕竟要加 n 个数), 但最优分配会挑每行很小的数, 而随着 n 增大, "很小的数"越来越小。

13.6.2 预言和证明

- Mézard–Parisi 1985/1987: 用复本方法预言, $n \rightarrow \infty$ 时期望最小成本 $\rightarrow \zeta(2) = \pi^2/6 \approx 1.6449$ 。
- Aldous 2001 (*The $\zeta(2)$ limit in the random assignment problem*, Random Structures & Algorithms 18): 严格证明, 用的是"局部弱收敛" (和 cavity 的"局部像树"同一思想)。
- Parisi 1998 进一步猜测有限 n 的精确公式: $E[\text{最小成本}] = 1 + 1/4 + 1/9 + \dots + 1/n^2$ 。2004 年 Linusson–Wästlund、2005 年 Nair–Prabhakar–Sharma 独立证明。

脚本实算 (Hungarian 算法求最优分配, `scipy.linear_sum_assignment`):

n	试验次数	模拟平均最小成本	Parisi 公式 $\sum_{k \leq n} 1/k^2$
1	200,000	1.0000 $\pm$ 0.0022	1.0000
2	200,000	1.2498 $\pm$ 0.0019	1.2500
3	100,000	1.3628 $\pm$ 0.0023	1.3611
5	50,000	1.4614 $\pm$ 0.0026	1.4636
10	20,000	1.5500 $\pm$ 0.0029	1.5498

n	试验次数	模拟平均最小成本	Parisi 公式 $\sum_{k \leq n} 1/k^2$
30	4,000	1.6093 ± 0.0038	1.6122
100	1,000	1.6373 ± 0.0042	1.6350
300	200	1.6435 ± 0.0055	1.6416
1000	40	1.6381 ± 0.0066	1.6439

每一行都在一两个标准误内吻合，n 大时都趋近 $\pi^2/6 = 1.6449$ 。作为对照，"每个工人依次挑剩下最便宜的工作"这种贪心法，n = 100 时平均成本是 **5.14**，是最优的三倍多。

【检查 4】n = 2 时，四个成本 a, b, c, d (矩阵 $[[a,b],[c,d]]$)，最小成本是 $\min(a+d, b+c)$ 。证明它的期望是 5/4。(提示：两个独立 $\text{Exp}(1)$ 之和 X 满足 $P(X > t) = (1+t)e^{-t}$ ；对非负随机变量 $E[Y] = \int_0^\infty P(Y > t) dt$ 。脚本直接模拟 200 万次得 1.24989。)

教训：复本方法给出的数字 ($\pi^2/6$) 是对的，而且后来被严格证明。这类成功案例积累起来，是数学家愿意花几十年去证明 Parisi / Mézard–Parisi 公式的原因。

13.7 问题到底是什么：上界已知，等号开放

13.7.1 要证明的东西

对稀释模型，定义每个自旋的压强 $F_N = (1/N) \cdot E[\ln Z_N]$ 。层级 cavity 泛函 $B_r(\zeta, m)$ 对任何"试探律" ζ (§13.5.4 的嵌套分布) 和任何分叉参数 $0 < m_1 < \dots < m_r < 1$ 都给出一个数。猜想是：

$$\lim_{N \rightarrow \infty} F_N = \inf_{r \geq 0} \inf_{\zeta, m} B_r(\zeta, m)$$

右边是对**所有有限层数、所有试探律**取下确界。

13.7.2 一半已经证明：上界 (2003–04)

- **Franz–Leone 2003** (J. Stat. Phys. 111)：把 Guerra 的插值法搬到稀释模型，对偶数元模型证明了 RS 和 1RSB 的上界。
- **Panchenko–Talagrand 2004** (PTRF 130)：证明任意有限层 r 的上界：对每个 r、 ζ 、m， $\limsup F_N \leq B_r(\zeta, m)$ 。他们在 Theorem 4 之后**明确提出等号是猜想**。OpenAI 论文说它解决的就是这个猜想（在同一个模型类里）。

插值法的直觉：构造一条从"真实模型"连续变到"由独立消息组成的试探模型"的路径，证明沿着路径压强的导数有固定符号。符号的判断要用到一个正性条件，这就是后面 Panchenko–Talagrand 条件里 $E[(-b)^n] \geq 0$ 的来源；也是为什么只能处理**偶数元**相互作用。

13.7.3 为什么下界难

在 SK 里，Talagrand 证明下界时，只需要控制**两两重叠** Q_{ab} 。稀疏模型里，一个新插入的自旋同时和 $p - 1$ 个旧自旋相连，你需要知道多个复本**同时**在这些位置上看到什么图案。它依赖所有的**多重重叠** (multioverlap)：

$$R_S = (1/N) \sum_i \prod_{a \in S} \sigma_i^a \quad (S \text{ 是若干复本的集合})$$

两两重叠的超度量结构并不能决定所有多重重叠（论文 §1 的原话："pair overlaps alone do not determine all these patterns"）。

已有的部分进展（论文引言列出）：Panchenko 2013 用"自旋分布"给出另一种精确变分公式，但不是层级 cavity 形式；Panchenko 2016 (arXiv:1406.4702) 对"修改过的模型"证明有限 RSB 的 Gibbs 测度满足 Mézard–Parisi 结构，但缺"一般状态能被有限 RSB 逼近"这一步；Coja-Oghlan–Perkins 2019 在正性条件下对随机正则因子图给出另一种变分公式；Concetti 2025 (arXiv:2508.17049) 对随机正则图给出完全 RSB 上界，等号仍是猜想。

相邻的已知结果（背景）：

- **铁磁**稀疏 Ising 模型（没有挫折）：Dembo–Montanari 2010 已证 Bethe 公式。
- **随机 k-SAT**（每个子句是一个 k 元相互作用）：Ding–Sly–Sun (STOC 2015, Annals 2022) 对**充分大的 k** 证明了可满足性阈值，正是 1RSB 公式的预测。

13.8 OpenAI 声称了什么

13.8.1 主结果

论文 *The Mézard–Parisi formula for diluted spin glasses* (OpenAI, 2026-09-23, 36 页, family 221) 摘要 [P]：

"We prove the Mézard–Parisi hierarchical cavity formula for diluted even-arity Ising models in the Panchenko–Talagrand class. This resolves the variational equality conjecture for that class: the limiting pressure equals the infimum of the trial functional over all finite hierarchy depths and trial laws. Only first moments of the interaction and external field are required."

主定理 (Theorem 2.1)：在假设 (2.1)–(2.4) 下，热力学极限存在，并且 $\lim F_N = \inf_r \Phi_r$ 。

一句话版本的关键技巧：把每个分叉深度整体推迟一层，再对深度取平均，从而控制所有多复本重叠 (§13.8.4 第 3 步)。

13.8.2 模型是什么（白话版）

- 固定一个**偶数** $p \geq 2$ （每个相互作用涉及几个自旋）和密度 $\alpha > 0$ 。
- 撒 $M_N \sim \text{Poisson}(\alpha N)$ 个相互作用，每个随机选 p 个自旋（**有放回**地选，所以允许重复），作用一个随机函数 θ 。每个自旋再加一个随机外场 h 。

- 只要求 $E[\max|\theta|] + E[|h|] < \infty$ ("只需要一阶矩": 不要求相互作用有界)。

Panchenko–Talagrand 条件: e^θ 能写成 $a \cdot (1 + b \cdot f_1(s_1) \cdot \dots \cdot f_p(s_p))$ 的形式, 其中 f 们独立同分布、 b 和它们独立, 并且 $E[(-b)^n] \geq 0$ 对所有 $n \geq 1$ 成立。

用 Viana–Bray 模型 ($p = 2$, $\theta = \beta J \cdot s_1 s_2$, J 对称分布) 检验: 取 $a = \cosh(\beta J)$, $b = \tanh(\beta J)$, $f(s) = s$ 。

【检查 5】验证 $e^{(\beta J \cdot s_1 s_2)} = \cosh(\beta J) \cdot (1 + \tanh(\beta J) \cdot s_1 s_2)$, 分 $s_1 s_2 = +1$ 和 -1 两种情况。(脚本取 $\beta J = 0.7$ 验证两边都是 2.01375 和 0.49659。)

因为 J 对称, $b = \tanh(\beta J)$ 的奇数阶矩为 0、偶数阶矩为正, 所以正性条件成立。

论文第 10 节列出的覆盖范围 (OpenAI 声称):

- **Viana–Bray 模型** ($p = 2$, 对称随机耦合);
- **偶数 p 的稀释 p -spin 模型** (对称耦合);
- **软随机偶数 K-SAT**, 在每一个正温度 ("软": 违反子句只罚能量 βW , 不是硬性禁止)。
- 推论 10.3: 把温度降到零, 得到 "最大能量 / 最少违反子句数" 的极限, 误差 $\leq \ln 2 / \beta$ 。

13.8.3 不覆盖什么 (重要)

- **奇数元:** 随机 **3-SAT** 不在内。论文 Remark 10.4 自己说明了, 并指向同批的另一篇 OpenAI 论文 *Computing the Random 3-SAT Threshold* (2026-09-27), 那篇用的是不同的试探泛函 (OpenAI 声称, 本章未读)。
- **固定度数的 Bethe 格 / 随机正则图:** 定理里的度数来自 Poisson 撒边。Mézard–Parisi 2001 原文的设定正是固定度数, 这种情形 **不在** 定理覆盖范围内。也就是说, 论文标题里的 "Mézard–Parisi 公式" 指的是它在 Poisson 稀释模型上的对应形式。
- **铁磁模型** (我的推断, 未见论文明说 $\triangle$): 固定 $J > 0$ 时按标准分解 $b = \tanh(\beta J) > 0$, $E[(-b)^n]$ 正负交替, 不满足正性条件。不过铁磁情形本来就由 Dembo–Montanari 2010 处理了, 不是空白。
- **零温度的硬约束 SAT 阈值:** 定理是每个正温度的结果, 零温极限只给出最小违反数, 不直接给出可满足性阈值。所以它 **不** 重新证明或推广 Ding–Sly–Sun。
- **Hopfield 网络:** 全连接 (稠密), 耦合由记忆模式决定, 不同边之间不独立, 不在定理范围内。§13.10.3 讲的 Hopfield、感知机、损失地形这些联系, 是思想来源, 不是这个定理的推论。
- **不声称** 试探律能取到下确界, 也不构造无穷层的极限 Gibbs 状态 (论文 Theorem 2.1 后的说明)。

13.8.4 方法的直觉 (只读了引言和§13.2.2, 以下是简化版)

上界照搬插值法 (§13.4)。下界分四步:

1. **选一个"空腔水库"**：比较 N 个自旋和 $N + 1$ 个自旋的系统，加一些数目亚线性的小扰动，它们不改变压强，但能让系统满足一些"恒等式"（扰动后的统计量集中）。
2. **规定分叉图案**：在有限概率树上发展一套"微积分"，把插入一个新自旋的效应展开成对复本路径的带符号求和，用独立标记挑出任意指定的复本分叉图案。
3. **集中所有多重重叠**（核心技巧）：把目标树的每个内部分叉深度**整体推迟一层**。这样新的分叉总落在旧树没用过的深度上，每个新分叉付出一个小因子，正好抵消归一化系数里的小因子，误差在除法之后仍然可控。然后对分叉深度**取平均**（不需要对每个深度一致地成立），归纳地让条件协方差衰减。
4. **恢复独立的 cavity 消息**：多重重叠集中之后，不同位置的消息可以换成独立副本，从而得到一个合法的试探值，它离真实压强很近。

极限顺序：每个固定深度先让 $N \rightarrow \infty$ ，再加深层级。最后用截断把"相互作用有界"的假设去掉，只剩一阶矩。

推理摘要（[reasoning_traces/mezard-parisi-formula.pdf](#)，5 页）记录了这个过程，有两句原文：

"Aha recursive structure: overfitting shared variable can simulate original model at smaller scale."

"Great! Need carefully prove average error little with shifted depths not rare"

摘要也坦白记录了失败的尝试：pinning（钉住部分自旋）方法无法协调观测分布；"精确纯度"的声称"proves too strong"；在"推迟分叉深度"之前，多种展开都在除以小指数间隔后误差过大。

13.8.5 同批的相邻结果（OpenAI 声称，本章未核实）

同一批发布里还有一整组自旋玻璃结果：family 222（感知机自由能、jamming 指数）、281（零温 SK Parisi 测度全支撑；QAOA 达到 SK 基态能量）、235（随机 k -SAT 阈值的计算性和方差，3-SAT 阈值存在性的优先权归 Gaia Carenini 的 ECCC TR26-229）、217 等（SK 涨落和动力学）。§13.10.3 会用到 222 和 281。

13.9 它被核实到什么程度

13.9.1 Lean 陈述

挑战文件 [lean/ComparatorChallenges/DilutedSpin.lean](#)（154 行）的主定理：

```
theorem mezard_parisi {p : ℕ} (M : Model p) (hM : Admissible M) :
  Tendsto (pressure M) atTop (λ (variationalValue M))
```

逐词翻译：

- $\{p : \mathbb{N}\}$: p 是自然数, 相互作用的元数。
- $(M : \text{Model } p)$: 一个模型, 由三样东西组成: 密度 `alpha`、相互作用的分布 `disorder` (连同分解见证 θ, a, b, f)、外场的分布 `field`。
- $(hM : \text{Admissible } M)$: 假设模型满足条件。 `Admissible` 结构逐条写出: `arity : 2 ≤ p`, `even : Even p`, `density : 0 < alpha`, 两条一阶矩可积, `factorization` ($e^\theta = a(1 + b \cdot \Pi f)$, 且 $|b \cdot \Pi f| < 1$), f 独立同分布、 b 与 f 独立, b 的各阶矩可积, 以及 `positivity : 0 ≤ E[(-b)^n]`。和论文 (2.1)–(2.4) 一一对应。
- `pressure M` : 一个数列, 第 N 项是 F_N 。定义里写得很实在: 对 $\text{Poisson}(\alpha N)$ 个相互作用、i.i.d. 外场求期望, 对所有可能的下标选择**均匀平均** (实现"有放回均匀抽样"), 对 2^N 个构型求 $\log\text{-sum-exp}$, 再除以 N 。
- `variationalValue M` : $\inf_r \phi M r$, 即对所有层数 r 取下确界; `phi M r` 是对所有 $\zeta \in \text{Hierarchy } (r+1)$ 和满足 `Exponents` ($0 < m_1 < \dots < m_r < 1$) 的 m 取下确界的 `functional`, 后者逐项对应论文 (2.11) 的 $B_r = \ln 2 + E \ln T_0 V_s - \alpha(p-1) \cdot E \ln T_0 V_e$ 。
- `Tendsto ... atTop (N ...)` : $N \rightarrow \infty$ 时 F_N 收敛到这个值。这同时包含"极限存在"。

和 §4 准黎曼猜想的区别: 那里的陈述只用了 Mathlib 的标准定义 `riemannZeta`; 这里几乎所有定义 (`pressure`、`Hierarchy`、`functional`) 都是挑战文件自己写的, 所以"陈述是否忠实"要靠人读这 154 行。我对照了论文第 2 节逐项读过 [P], 没发现不一致, 但我不是这个领域的专家 $\triangle$ 。

13.9.2 证明本身

- 解答模块 `0AI/Probability/DilutedSpin/` : 405 个 .lean 文件, 56,285 行 (脚本统计) [P]。grep `sorry` / `admit` / `native_decide` / `axiom` 声明: 0。
- 解答模块 `Model.lean` 里的定义与挑战文件中的定义**逐字一致** (我 diff 过 `Spin` 到 `variationalValue` 这一段)。
- Comparator 配置 `DilutedSpin.json` : 只允许 Lean 三条标准公理 (`propext`、`Quot.sound`、`Classical.choice`) ; `enable_nanoda: false`, 即没有配置第二个独立内核重检。
- 我们没有实际编译或运行 Comparator (全库体积很大)。 `formalization.yaml` 整体标注 `review: status: unchecked`。
- 和 §4 准黎曼猜想不同, 没有找到任何第三方 (例如 Goldblatt 那样) 独立跑通这个证明的报告 $\triangle$ 。

13.9.3 人类专家

截至 2026-10-08, 没有找到任何自旋玻璃 / 概率论专家对这篇论文的具名评论或核实报告 $\triangle$ (搜索过; 只找到聚合博客对 family 221 的转述)。Panchenko、Talagrand、Coja-Oghlan 等人是天然的审稿人选。

13.9.4 剩余风险

- 1. **陈述忠实性**：Lean 证明的是挑战文件里写下的陈述。几处值得专家细看：`Hierarchy` 每层用弱拓扑的 Borel σ -代数（文件注释说是按论文规定）；`logMean` 里 m 的下标约定（`m 0` 对应论文的 m_1 ）；`pressure` 里用"对所有下标求平均"代替"随机抽样"。我认为都等价，但没有形式化地检查 $\triangle$ 。
- 2. **论文标题 vs 范围**：读者很容易把"Mézard–Parisi 公式"理解成 Mézard–Parisi 2001 的 Bethe 格（固定度数）情形，或者理解成包括 3-SAT。两者都不在内 (§13.8.3)。这是本系列反复出现的"规格 vs 意图"差距。
- 3. **证明可读性**：36 页论文对 5.6 万行 Lean，论文是摘要式的；人类要理解"推迟分叉深度"技巧为什么有效，可能需要相当时间。

13.10 如果为真，意味着什么（以及不意味着什么）

13.10.1 对数学

- 1. 一个约 20 年的开放猜想（Panchenko–Talagrand 2004）在其原始模型类里得到解决，而且只需要一阶矩，比原问题设定的假设还弱。
- 2. **新技巧可能比结论更重要**："推迟分叉深度 + 对深度平均"来控制所有多重重叠，如果站得住，可能推广到其他稀疏模型（固定度数、奇数元）。论文自己说，下界部分对**任何有界、对输入置换不变的相互作用都成立**，不需要分解和正性条件（论文 §2.2 末尾）；卡住的是上界。也就是说，以后谁能把插值上界推广到奇数元，下界这一半已经现成。
- 3. **不意味着**：随机 3-SAT 阈值的公式、Bethe 格自旋玻璃的完整解、稀疏模型上的"超度量性"都没有因此解决。

13.10.2 对物理

物理学家在 2001 年就"知道"这个公式是对的，并用它算出了大量数值预测。这个定理不改变任何物理预测，它的作用是把 cavity 方法在一类稀疏系统上从"可信的启发式"升级为定理。这和 Talagrand 2006 对 SK 的意义同类，但范围更窄。

13.10.3 对 ML 和神经科学（诚实版）

确实存在的联系：

- **Hopfield 网络 (1982) 就是一个 Ising 系统**。能量 $E = -\frac{1}{2} \sum W_{ij} \sigma_i \sigma_j$ ，Hebb 规则 $W_{ij} = (1/N) \sum_{\mu} \xi_i^{\mu} \xi_j^{\mu}$ 存入 P 个模式，每个记忆就是能量的一个极小。存储太多时，其他模式的"串扰"像随机耦合一样制造挫折，系统落入不对应任何记忆的"自旋玻璃态"。Amit–Gutfreund–Sompolinsky 1985 用复本方法算出容量 $\alpha_c = P/N \approx 0.138$ 。脚本模拟（ $N = 1000$ ，零温异步更新，从存储模式出发，每个 α 测 30 次）：

$\alpha = P/N$	0.05	0.10	0.12	0.13	0.14	0.15	0.17	0.20
平均最终重叠 m	1.000	0.998	0.992	0.974	0.941	0.917	0.583	0.363

在 0.13–0.17 之间检索质量明显崩塌，和 0.138 的预测一致。N = 1000 时转变被有限尺寸效应抹宽，而且越过 0.138 后重叠不是立刻降到零，所以这张表只是定性验证。Hopfield 与 Hinton 获 2024 年诺贝尔物理学奖。

- **感知机容量**：Gardner 1988 用复本方法算出球形感知机的容量 $\alpha = 2$ ；Ising 感知机（权重 ± 1 ）的 Krauth–Mézard 1989 预测约 0.833，严格证明直到最近才有部分进展（Ding–Sun 2019 证下界；Huang 2024 在一个数值假设下给出匹配上界 Δ 未重新核对）。同批 family 222 给出的是 Ising 感知机和球形感知机在**正温度**下的自由能，外加负 margin (−1) 球形感知机的 jamming 指数（OpenAI 声称，按 repo `CONTENTS.md` 的 222 条目），不是零温容量本身。
- **随机优化地形与算法**：Montanari 2019 (arXiv:1812.10897) 给出一个多项式时间算法，可以近似找到 SK 基态，**前提是零温 Parisi 测度**"没有重叠间隙"。同批 family 281 声称证明了这个全支撑性质（OpenAI 声称，未核实 Δ ）。如果成立，"SK 的基态能被高效近似"就变成无条件的。这是自旋玻璃理论对"随机地形能否被高效优化"给出的最直接回答，比 221 本身更贴近 ML 的关切。
- **稀疏图上的推断**：LDPC 解码、社区检测、稀疏约束满足问题的信息论阈值，都依赖 cavity / BP 型变分公式。221 给这类"物理预测 = 真实阈值"的论证多加了一块严格基石（推测性外推）。

需要打折扣的地方：

- **221 不覆盖 Hopfield**。Hopfield 是全连接（稠密）的，耦合由模式决定，不同边之间不独立；221 要求的是稀疏、各相互作用独立的模型。神经科学里的"稀疏 Hopfield"（例如 Derrida–Gardner–Zippelius 1987 的强稀释模型）也不满足 Panchenko–Talagrand 的分解形式。
- "崎岖地形 + 层级聚类的极小值"这套关于损失地形的直觉来自自旋玻璃，最有名的是把**深度网络损失地形类比为球形自旋玻璃**（Choromanska 等 2015）。这类类比依赖很强的简化假设，大多是**启发式**的。这个定理不会告诉你 SGD 会找到什么、收敛到哪里、泛化如何。
- 本章标题后半句"从磁铁到神经网络的能量地形"讲的是**思想谱系**（能量函数、复本方法、崎岖地形），不是说这个定理对神经网络有直接推论。

13.10.4 对 AI

这是"AI 补完一个经典纲领中缺失的一步"的典型示例：问题出处明确（PT 2004 Theorem 4 后的猜想），有 Lean 陈述，有坦白的推理摘要。它也是"规格 vs 意图"的教学示例：Lean 覆盖的范围（Poisson、偶数元、正性）比论文标题让人联想的窄，判断这个差距要靠领域知识，不能靠 Lean。

13.11 自测题

读完后试着回答。如果答不上来，回到对应小节再读一遍。

1. 为什么物理学家要算 $E[\ln Z]$ ，而不是更好算的 $\ln E[Z]$ ？两者在什么时候不同？ (§13.3.3)

2. 复本技巧的哪一步在数学上没有依据？ (§13.4.1)
3. 复本对称的 SK 解错在哪里？ 举一个明显不物理的数字。 (§13.4.2)
4. 为什么 cavity / BP 在树上精确、在有短环的图上不精确？ 为什么这对稀疏随机图仍然有希望？ (§13.5.2–13.5.3)
5. "层级" cavity 公式里的"层级"指什么？ Lean 里的 **Hierarchy** 是怎么定义的？ (§13.5.4、§13.9.1)
6. 随机分配问题的 $\pi^2/6$ 和 OpenAI 证明的公式是什么关系？ (§13.0、§13.6)
7. 在 Panchenko–Talagrand 猜想里，哪一半早已证明？ 为什么另一半在稀疏模型里比在 SK 里难？ (§13.7.2–13.7.3)
8. 列出 OpenAI 这个定理不覆盖的三类模型。 (§13.8.3)
9. 为什么不能说"这个定理证明了 Hopfield 网络的某某性质"？ (§13.10.3)

附：【检查】答案

- **检查 1**: $e^1 \approx 2.7183$, $e^{-1} \approx 0.3679$, $2e + 2e^{-1} \approx 6.1724$, 所以 $P(+,+) \approx 2.7183 / 6.1724 \approx 0.4404$ (脚本: 0.44040)。
- **检查 2**: $H = \sigma_1\sigma_2 + \sigma_2\sigma_3 + \sigma_1\sigma_3$ 。 $(+,+,+)$ 和 $(-,-,-)$: 三项都是 +1, $H = +3$ 。 其余 6 个构型都是"两个同号、一个异号": 同号的那一对贡献 +1, 另外两对各贡献 -1, $H = -1$ 。 所以是 2 个 +3、6 个 -1。
- **检查 3** (§13.5.3 例子): 只有自旋 1 有外场。 $Z = \sum e^{(\sigma_1\sigma_2 + 0.5\sigma_1)}$ 。 $\sigma_2 = +1$ 的总权重是 $e^{(1.5)} + e^{(-1.5)}$, $\sigma_2 = -1$ 的总权重是 $e^{(-0.5)} + e^{(0.5)}$ 。 $m_2 = [e^{1.5} + e^{-1.5} - e^{0.5} - e^{-0.5}] / [e^{1.5} + e^{-1.5} + e^{0.5} + e^{-0.5}] = (4.7048 - 2.2553)/(4.7048 + 2.2553) \approx 0.3519 = \tanh(1) \cdot \tanh(0.5)$ 。
- **检查 4**: $a + d$ 和 $b + c$ 是两个独立的 $\text{Gamma}(2, 1)$, $P(X > t) = (1+t)e^{-t}$ 。 所以 $P(\min > t) = (1+t)^2 e^{-2t}$, $E[\min] = \int_0^\infty (1 + 2t + t^2)e^{-2t} dt = 1/2 + 2 \cdot (1/4) + 2/8 = 5/4$ 。
- **检查 5**: $s_1 s_2 = +1$ 时, 右边 = $\cosh(\beta J) + \sinh(\beta J) = e^{(\beta J)}$; $s_1 s_2 = -1$ 时, 右边 = $\cosh(\beta J) - \sinh(\beta J) = e^{(-\beta J)}$ 。 两种情况都等于左边。

附：术语表

术语	一句话解释
自旋	只取 ± 1 的变量, 代表一根小磁针 (或一个二值神经元)
Ising 模型	能量为 $-\sum J_{ij} \sigma_i \sigma_j$ 的自旋系统
Boltzmann 分布	$P(\sigma) \propto e^{(-\beta H(\sigma))}$, 即以 $-\beta \cdot$ 能量为 logit 的 softmax
配分函数 Z	所有构型权重之和, 归一化常数
自由能 / 压强	$F = -(1/\beta) \ln Z$; 压强 = $(1/N) \ln Z$, 差一个因子

术语	一句话解释
挫折	不可能同时满足所有相互作用的局面
自旋玻璃	耦合随机正负、挫折遍布的自旋系统
淬火 / 退火平均	$E[\ln Z] / \ln E[Z]$ ；物理上要的是前者
复本方法	用 $\ln Z = \lim (Z^n - 1)/n$ 计算 $E[\ln Z]$ 的非严格技巧
重叠 Q_{ab}	两个复本构型的相似度 $(1/N)\sum \sigma_i^a \sigma_i^b$
多重重叠	多个复本自旋乘积的空间平均，稀疏模型需要全部控制
RSB（复本对称破缺）	复本组成层级（树），对应多个纯态
超度量	三点中最大的两个距离相等的距离结构，像分类树
SK 模型	每对自旋都有随机耦合的稠密自旋玻璃
Viana–Bray 模型	Poisson 稀释的两体自旋玻璃
Bethe 格	每个点度数固定的（随机正则）稀疏图
cavity 方法 / BP	拿掉一个自旋、用邻居传来的消息计算其状态；在树上精确
层级 cavity 公式	用“消息的分布的分布……”表达自由能的变分公式
Panchenko–Talagrand 类	$e^\theta = a(1 + b \cdot \Pi f)$ 且 $E[(-b)^n] \geq 0$ 的偶数元相互作用
插值法	Guerra 的技巧：在真实模型和试探模型之间连续插值，得到上界

附：想继续深入

- **Mézard & Montanari**, *Information, Physics, and Computation* (Oxford University Press, 2009)：把自旋玻璃、cavity、BP、随机 k-SAT、编码放在一本书里讲，面向 CS 读者，第 14–19 章正好覆盖本章§13.5–13.7。最推荐。
- **Panchenko**, *Introduction to the SK model* (综述, arXiv:1412.0170)：
<https://arxiv.org/abs/1412.0170>；完整版是他的书 *The Sherrington–Kirkpatrick Model* (Springer, 2013)。
- **Nobel 2021 科普材料** (Parisi 部分)：
<https://www.nobelprize.org/prizes/physics/2021/popular-information/>
- **Mézard & Parisi 2001**, *The Bethe lattice spin glass revisited*, EPJ B 20:217 (arXiv:cond-mat/0009418 △ 编号按记忆，请核对)。
- **Panchenko & Talagrand 2004**, *Bounds for diluted mean-fields spin glass models*, PTRF 130:319, <https://doi.org/10.1007/s00440-004-0342-2>。
- **Panchenko 2016**, *Structure of finite-RSB asymptotic Gibbs measures in the diluted spin glass models*: <https://arxiv.org/abs/1406.4702>

- **Aldous 2001**, *The $\zeta(2)$ limit in the random assignment problem*, Random Structures & Algorithms 18:381–418。
- **Montanari 2019**, *Optimization of the Sherrington–Kirkpatrick Hamiltonian*: <https://arxiv.org/abs/1812.10897>
- **Concetti 2025** (随机正则图, 开放的部分): <https://arxiv.org/abs/2508.17049>
- 原始论文: <https://github.com/openai/math/blob/main/preprints/The-Mezard-Parisi-formula-for-diluted-spin-glasses-September-23-2026/paper.pdf>
- Lean 陈述:
<https://github.com/openai/math/blob/main/lean/ComparatorChallenges/DilutedSpin.lean> ;
范围说明: <https://github.com/openai/math/blob/main/lean/docs/221.md>
- 推理摘要: https://github.com/openai/math/blob/main/reasoning_traces/mezard-parisi-formula.pdf

反面案例 · FAMILY 032 与 10-07 撤稿

14. 一个符号错误撤掉 3 篇：未形式化的风险

Hodge 猜想 (千禧年问题) 极简版: 在光滑射影复代数簇上, 有些"拓扑洞"可以由代数方程定义的子簇来"填"; 猜想说凡是满足某个线性代数条件的洞都能这样填。 $p = 1$ 的情形 1924 年已知 (Lefschetz)。

OpenAI 声称对所有**复乘 (CM) 阿贝尔簇**证明了有理 Hodge 猜想 (53 页) ——这只是一个特殊类, 不是千禧年问题本身; 而且它和 ζ 无零区一样, **不是**按固定流程产出的, **没有 Lean**。[P]

10-07 撤稿：一个符号错误沿依赖图传播

八维阿贝尔簇上的 Weil 类

反向 stabilization trace 符号应为 -1 , 写成了 $+1$

K3 曲面的 Kuga–Satake 对应

依赖上一篇 → 撤回

K3 曲面乘积的有理 Hodge 猜想

依赖上一篇 → 撤回

CM 阿贝尔簇的有理 Hodge 猜想

不在依赖链上; 未撤, 但也没有 Lean

家族 032 原标题: "Hodge and Kuga–Satake results for all projective K3 surfaces"
→ 撤稿后改为只剩 CM 的版本

722 篇 → 719 篇; 另有 14 篇修补、13 篇更新引用

来源: [openai/math history.md](#) (2026-10-07); 家族标题对比初始 commit `adc7f12` 的 `CONTENTS.md`。撤稿说明原文: "This withdrawal concerns the proof; it does not assert that the mathematical statement is false."

14.1 发生了什么 [P]

history.md (10-07): "In 'Algebraicity of Weil classes on split abelian eightfolds' a sign error invalidates a stabilization-trace cancellation argument and the construction used by two dependent papers." 一个本应是 -1 的符号被当成 $+1$ ，带符号的计数从声称的 0 变成 $-2m \neq 0$ ，关键定理的前提不成立；依赖它的两篇 K3 曲面论文连带撤回。CM 主论文不引用被撤论文，不在这条链上。

14.2 三个教训

1. **未形式化 $\approx$ 未验证**：只有约 42% 的顶层结果有 Lean。这个错误只是一个符号——人眼和模型自查都漏了，Lean 必然会抓到。
2. **错误沿依赖图传播**：一个引理错了，三篇论文一起倒，下游 13 篇要更新引用——和 agent 长链推理中的错误复合是同一种结构。
3. **标题漂移**：家族 032 原名 "Hodge and Kuga–Satake results for all projective K3 surfaces"，撤稿后才降级为 CM 版本。读批量 AI 产出时，以最新 commit + history.md 为准，不以首发新闻为准。

15. 把 10 个结果放在一起看

结果	此前状态	声称的跳跃	陈述忠实?	人类专家确认
准黎曼 7/8	无任何固定宽度无零带	质变	是 (Mathlib 标准定义)	无
$\mu(\pi) = 2$	7.103	直接到终点	是 (未登记 yam1 Δ)	无
$\omega \leq 9/4$	2.371177	-0.12, 越过已知壁垒	是	无
UGC	"半个" (2-to-2, 2018)	完整	是 (更强形式)	无
$L = BPL$	$L^{(3/2)}$ 附近 25 年	完整	是 (定义被锁定)	无
平面 $\chi \geq 6$	$\chi \geq 5$ (2018)	+1, 新方法	是 (两行陈述)	无
Thompson F	两个方向都有过错误证明	解决	是	无
NS 爆破	带外力 Euler 已有前驱	(C)/(D) 分支	结构一致	Clay 未认可, 有争议
Vlasov–Maxwell	40 年只有带限制的结果	单种类完整	是	无
Mézard–Parisi	只有上界	偶数元类等号	是 (范围比标题窄)	无

15.1 五个模式

- 陈述短、证明长**：平面着色陈述两行、证明 3 万行；准黎曼陈述一行、证明 48 万行。这正
是"人审陈述、机器审证明"分工最理想的形态——也意味着人类审稿带宽成了新瓶颈。
- 论文都异常短**：9/4 矩阵乘法 13 页、Thompson 群 13 页。要么方法真的意外地简洁，要么大
量细节压在 Lean 里没写给人看——Gómez-Serrano 说 NS 论文 "not written for humans"。
- 跨领域借工具**：Thompson 群用无穷维几何的 Lipschitz 映射；平面着色用遍历论；矩阵乘法
用"渐近谱"而不是 40 年来的主流激光法。这可能是 AI 的一个真实优势：它没有人类专家的"领
域惯性"。
- "满足题面"与"回答真正的问题"之间的差距**：NS 的外力可以任选；376 把计算放在外力里；
平面着色脚注里那个"形式化了错误假设"的反例；Mézard–Parisi 只覆盖偶数元。每一个都
是"规格 vs 意图"。
- 选择效应**：4,000 题里挑出来的结果 vs 预先登记题目上的 3% (§2.3)。在 OpenAI 公开失败
清单之前，无法回答"这个模型解开放问题的真实能力是多少"。

16. 这件事对 AI 意味着什么

16.1 数学好 ≠ 全面更聪明，但它是先行指标

数学对 AI 有一个独特优势：**答案可以被机器检验** (Lean)，这让强化学习可以大量"试错 → 拿反馈 → 改进"。Chollet 的追问正中要害：这些"可验证领域"的进步能否迁移到不可验证的领域？合理的读法是：**凡是能被自动检验的智力工作，接下来都会以类似速度被攻破**——数学只是第一个。

16.2 信任瓶颈从"证明"转移到"规格"

一旦有了 Lean，问题从"证明对不对"变成"陈述有没有编码对"。这和对齐研究里的核心难题同构：系统可以完美优化你写下的目标，而你写下的目标可能不是你想要的。本 deck 每一节都在做的"逐行读 Lean 陈述"，就是一种 **spec review**——它会成为一项越来越重要、越来越稀缺的人类工作。

16.3 "能验证但不能理解"的知识

IAS 顾问组的原话：*"It is now the case that AI can output mathematical arguments in situations without the human who prompted it being able to understand the arguments, verify them, or take responsibility for them."* [R] 数学是这种局面最先出现、也最干净的领域（因为验证是完美的）。推广到科学：人类可能从"理解者"变成"检验者"。Tao 说的 Math 2.0——把讲解、社区建设、开辟新方向放到和解题同等重要的位置——本质上是在回答"人类在这个新分工里做什么"。

16.4 对安全研究的两面

好消息

- **验证比发现容易**：如果未来的 AI 能为自己的行为给出形式化证明（"这个动作不会做 X"），人类不必理解它的全部能力，只需检验证明——这是 Guaranteed Safe AI 路线的核心想法，数学 AI 越强越可行。
- 本批的 Lean 库本身就是"大规模 AI 产出 + 机器验证"的第一个真实样本，可以研究它的失败模式。

坏消息

- 对齐里最难的部分（"这个 AI 真正想要什么""结果对人类好不好"）写不成 Lean。可验证领域飞速进步、不可验证领域落后，这个差距本身是风险。
- AI 研发里可验证的部分（kernel 优化、证明、benchmark）会最先被大规模自动化——"AI 改进 AI"的循环最可能从这里开始。

16.5 治理：单方面倾倒的先例

社区已经通过 IAS 顾问组形成了初步规范（披露模型名、prompt、推理链、计算时间与成本、选题方式、同类问题失败率），OpenAI 只遵守了一部分，然后一次性发布 700 多篇。AHM 的说法 "a demonstration of power" 虽然激烈，但点到了结构性问题：前沿公司单方面决定一项能力以什么方式进入公共领域，受影响的共同体只能事后反应。

PART II · 前瞻 · 校准

17. 先校准：数学突破怎样变成现实影响，以及 AI 能力会走多快

Part I 讲已经发生了什么。Part II 问一个更大的问题：如果 AI 大规模解决数学（它已经在证明开放问题），或者 AI 的其他能力也突破，哪些真正重要的问题会被打开？更深远的影响是什么？§18–§22 按领域回答，§23 汇总。这一节是地基。后面各节都先对照这里的四样东西：数学变成现实影响历史上要多久、卡在哪（17.1）；数学什么时候才是瓶颈（17.2）；AI for science 到目前的真实记录（17.3）；AI 能力按趋势走多快、走得多不均匀（17.4–17.5）。标签：[已确立] 公认的历史或研究结论；[近期发现] 2024–2026 的新结果；[推测] 推断。17.4–17.5 沿用 deck 原有标签：[数据] 有出处；[模型] 按明确假设算出；[判断] 推断。△ = 未能核实或有冲突。

17.0 先说结论

- **数学到现实影响的时间差分两类，差一到两个数量级 [已确立]**。为数学本身做的"库存型"数学（数论、黎曼几何、拓扑、Radon 变换）要 50–200 年才找到应用；为工程问题做的"订单型"数学（线性规划、信息论、Black–Scholes、压缩感知、极化码）只要 2–15 年。OpenAI 的 719 篇绝大多数是库存型，按历史，现实影响要以几十年计 [推测]。
- **应用发生时，数学几乎总是现成的 [已确立]**。14 个历史案例里，最后卡住的是算力和使能技术、需求、制度（拍卖立法、器官交换的合法性、苏联意识形态）、材料与实验（拓扑量子比特卡了近 30 年），以及"需要的人不知道它存在"（Cormack 重新发明了 Radon 变换，LDPC 码被遗忘 34 年）。
- **在大多数领域，数学只占流水线的一小段**。用 Amdahl 定律算一个假设的药物项目：让"理论"无限快，总速度只提高约 5%。AI 的真正杠杆是提高慢步骤的命中率、用计算替代实验。在"纯认知加速单独撑不起大影响"这点上，乐观派（Amodei、Epoch）和怀疑派（Narayanan & Kapoor、Acemoglu）其实一致。
- **到 2026–10，AI for science 被证实的加速全部来自 AI 的"其他能力"，不是证明 [近期发现]**。天气预报已进入 ECMWF 和 NOAA 的业务系统并通过独立检验；蛋白质结构预测被 300 多万研究者使用。材料发现的三个旗舰（GNoME、A-Lab、MatterGen）都被大幅回调；"AI 加速研发"最常被引用的 MIT 论文被撤回；还没有"AI 发现"的药物获批。

- **AI 能力曲线是指数型的，直觉会系统性地低估它。**AI 能独立完成任务长度约每 129 天翻一倍（每年约 $\times 7$ ），2026-05 约 15 小时，中心情景 2027 年末约 400 小时 [数据][模型]。预注册开放问题的单次解出率现在是 3%，中心情景 2027 年末约 18%、2028 年末约 45%；形式化证明约 \$0.023/行，按每年 $\div 10$ 算，2027–2028 年生成证明的成本可以忽略 [模型]。最大的不确定量是 benchmark 上的 98% 和开放问题上的 3% 之间的差距。
- **加速极不均匀。**"陈述清楚、只缺证明"的 A 类问题有自动裁判，会被 AI 批量解决；"连该证什么都不清楚"的 B 类问题进展慢。推广一步：一个领域被 AI 加速多快，取决于它的"裁判"给反馈有多快：Lean 是分钟级，材料合成是周到月，气候是十年 [判断]。
- **证明变便宜后，瓶颈迁到四处** [推测，有先例]：陈述是否忠实 (spec)；人的消化与理解（Tao："从证明稀缺进入证明丰裕"）；实验（理论便宜了，实验相对变贵）；匹配（把已有数学连到需要它的问题）。测序成本 10 年降了一万倍，生物学没有快一万倍；证明大概也会这样。
- **AI 数学帮助大的是"数学就是产品"的领域：**理论计算机与密码学、形式化验证、编码理论、部分物理的严格界。在生物医学、材料、社会科学里，AI 其他能力更重要，但同样受实验和制度限制 (17.7)。这也是和 AI 安全的交汇点：证明一个被悄悄削弱的陈述，就是数学里的 reward hacking；陈述和 spec 的审核能力，是数学、科学和 AI 监督共同的下一个瓶颈。

17.1 历史：数学到应用的时间差

过去的数学突破，从"证出来"到"改变现实"花了多久，卡在哪？如果卡的不是数学，AI 让数学变快，只能缩短总时间里很小的一段。

下表是 14 个案例 [已确立]。"数学成形"指关键结果首次发表，"首用"指第一个真实应用，"普及"指大规模部署；年份取近似值。表后细讲 6 个案例，其余 8 个各一句话。

#	数学 → 应用	数学成形	首用	普及	数学→首用	首用→普及	主要瓶颈（数学之外）
1	数论 → 公钥密码	1763（欧拉）	1977（RSA）	1995–2017（SSL→HTTPS）	~210 年	~20–40 年	计算机、网络需求、专利与出口管制
2	黎曼几何 → 广义相对论 → GPS	1854	1915（GR）/1978（GPS）	1995–2000	61 年（到物理）/~125 年（到技术）	~20 年	原子钟、航天、军费、2000 年的政策

#	数学 → 应用	数学成形	首用	普及	数学→首用	首用→普及	主要瓶颈（数学之外）
3	李群/表示论 → 夸克模型	1870s–1894	1961–64	1970s（标准模型）	~70–90 年	~10 年	加速器数据；物理学家学会这套数学
4	傅里叶 → FFT/MRI/JPEG	1807–1822	1965（FFT）/1973（MRI）	1980s–1992	~145–165 年	~15–25 年	计算机、FFT 算法、超导磁体
5	希尔伯特空间 → 量子力学 → 晶体管	1904–1910	1925–32（QM）	1947–1960（晶体管、激光）	~20 年	~20–35 年	光谱实验、高纯材料
6	布尔代数/可计算性 → 计算机	1854 / 1936	1937（Shannon）/1948	1950s–60s	~83 年 / ~12 年	~10–20 年	继电器/电子管、战争需求、跨界人才
7	信息论/编码 → 通信	1948；LDPC 1962；极化码 2009	1950–1982；LDPC 2000s；极化码 2016	3G/4G/5G	Hamming 2 年；RS→CD 22 年；LDPC ~40 年；极化码 ~7 年	~5–10 年	解码算力、标准化
8	线性规划 → 物流/炼油	1939/1947	~1950	1950s–60s	美国 <5 年；苏联 ~20 年	~10 年	计算机、制度（苏联）
9	Radon 变换 → CT	1917	1971	1970s 末	54 年	~5–10 年	计算机、探测器、 数学被重新发明
10	机制设计 → 拍卖/匹配/肾交换	1944–1962	1994 / 1998 / 2004	2000s	~30–40 年	~5–10 年	立法 、机构、信任
11	随机分析 → Black–Scholes	1944–51（Itô）	1973	~1975–80	~25 年	<5 年	期权合法性、交易所

#	数学 → 应用	数学成形	首用	普及	数学→首用	首用→普及	主要瓶颈（数学之外）
12	拓扑 → 拓扑物态 → 拓扑量子比特	1895–1946	1982（物理）	尚未（技术）	~40–85 年（到物理）	至今未兑现（>40 年）	材料与实验
13	压缩感知 → 快速 MRI	2004–2006	2017（FDA）	2017 起	~11 年	进行中	FDA、厂商集成（纯软件）
14	格 → 后量子密码	1996–2005	2024（FIPS 203）	2025–26	~20–28 年	~2 年	量子威胁、标准化；FHE 卡在开销

案例 1：数论 → 公钥密码。 数论的核心工具是"模运算"：只看除以 n 的余数，像钟表转圈。
例： $3^4 = 81$ ，81 除以 7 余 4，记作 $3^4 \equiv 4 \pmod{7}$ 。欧拉定理（1763）说明模 n 的乘方会周期性地回到 1；RSA 的安全性在于，已知 $n = p \times q$ 而不知道 p、q 时，很难算出这个周期。时间线：欧拉 1763 → Diffie & Hellman 1976 年提出公钥思想 → RSA 1977（英国 GCHQ 的 Cocks 1973 年就秘密想到，1997 年才解密）→ 1995 年 Netscape 的 SSL → 2010 年代中后期 HTTPS 成为网页加载的多数 Δ 。中间缺的是能快速做大数乘方的计算机、网络与电商需求，以及 RSA 专利（2000 年到期）和美国密码出口管制。教训：Hardy 1940 年断言数论和相对论"还没人发现有什么战争用途，而且看起来很多年内都不会有"；三十多年后，数论成了公钥密码的基础。数学在库存里躺了 200 年，激活它的是一个新的工程需求：网络上陌生人之间的保密。

来源：Diffie & Hellman 1976, doi:10.1109/TIT.1976.1055638；Rivest, Shamir & Adleman 1978, doi:10.1145/359340.359342；Hardy 引文
https://en.wikipedia.org/wiki/A_Mathematician%27s_Apology

案例 2：黎曼几何 → 广义相对论 → GPS。 黎曼几何研究弯曲空间里怎么量距离：平面上用勾股定理，弯曲空间里每一点都有自己的"尺子"（度规张量，metric tensor）。Riemann 1854 → Einstein 1915 年的广义相对论（1912–15 年他在数学家 Grossmann 帮助下花了约三年学这套数学）→ GPS 首颗卫星 1978、全面运行 1995 → 2000 年美国关闭"选择可用性"（人为降低民用精度的开关）。GPS 为什么需要相对论：卫星钟因为引力弱每天快约 45 微秒，因为高速运动每天慢约 7 微秒，净快约 38 微秒；光速 $\times$ 38 微秒 $\approx$ 11 公里，不修正的话定位误差每天累积约 10 公里。中间缺的是原子钟、航天、冷战军费和一个政策决定。教训：数学到物理 61 年，物理到技术又 60–80 年；Einstein 那三年是"学数学"的瓶颈，不是"发明数学"的瓶颈。

来源：Ashby 2003, "Relativity in the Global Positioning System", doi:10.12942/lrr-2003-1

案例 7：信息论与纠错码 → 5G。 Shannon 1948 年证明每条有噪声的信道都有容量上限 C ；速率低于 C 时，**存在**能让错误率任意小的编码，但证明没说怎么造。小例子：每个比特重复 3 遍（0→000），收到 010 按多数判为 0，能纠 1 个错，但速率掉到 $1/3$ ，离容量很远。之后：Hamming 码 1950；Reed–Solomon 码 1960，1982 年用于 CD；Gallager 1962 年的 LDPC 码因为当时算不动解码，**被遗忘 34 年**，1996 年被 MacKay & Neal 重新发现，2016 年被 3GPP 选为 5G 数据信道编码；Arıkan 2009 年的极化码（第一个被证明能达到容量、又能高效构造的码）2016 年被选为 5G 控制信道编码，只用约 7 年。中间缺的是便宜的解码芯片和标准化组织。教训：同一领域里时间差从 40 多年缩到 7 年，因为产业有明确指标（离香农极限还差几 dB）、有标准化窗口、可以纯芯片实现。**问题和验收标准都清楚时，转化最快。**

来源：Shannon 1948, doi:10.1002/j.1538-7305.1948.tb01338.x；Gallager 1962, doi:10.1109/TIT.1962.1057683；MacKay & Neal 1996, doi:10.1049/el:19961141；Arıkan 2009, doi:10.1109/TIT.2009.2021379；<https://www.abiresearch.com/blogs/2022/07/20/5g-nr-coding-schemes-a-new-start-with-a-long-history/>

案例 8：线性规划。 在一组线性不等式约束下让线性目标最大，比如把有限的木头和工时分配去造桌子和椅子，使利润最大。最优解总在约束围成的多边形的某个顶点上，单纯形法（simplex）就是沿顶点一路往上爬。Kantorovich 1939 年在苏联为胶合板厂排产提出线性规划，**在苏联被冷落了约二十年**（被怀疑与马克思主义价值理论冲突）；Dantzig 1947 年在美国空军提出单纯形法，几年内就用于空军调度和炼油配方；1975 年 Kantorovich 与 Koopmans 获诺贝尔经济学奖。教训：同一个数学在两种制度下，转化速度差了一二十年。订单驱动的数学转化最快；制度可以让现成的数学闲置。

来源：Dantzig 2002, *Operations Research* 50(1):42, doi:10.1287/opre.50.1.42.17798；<https://www.nobelprize.org/prizes/economic-sciences/1975/summary/>

案例 9：Radon 变换 → CT。 知道一个物体沿所有方向的所有直线上的“总密度”（线积分），能不能反推出内部每一点的密度？Radon 1917 年证明能，并给出反演公式。类比：只看果冻在各个角度投下的影子深浅，就能重建里面的水果在哪。Cormack 1963–64 年**在不知道 Radon 工作的情况下**重新推导出类似结果，几乎没人注意；Hounsfield（EMI 公司）1971 年完成首例临床 CT；1979 年两人获诺贝尔奖。Cormack 到 1970 年代初才发现 Radon 的论文。中间缺的是计算机、X 射线探测器和一家愿意出钱的公司。教训：54 年，而且数学被重新发明了一遍。这是“匹配成本”的典型：需要它的人不知道它已经存在。

来源：Cormack 1963, doi:10.1063/1.1729798；<https://www.nobelprize.org/prizes/medicine/1979/cormack/lecture/>

案例 10：机制设计 → 频谱拍卖、住院医匹配、肾脏交换。 机制设计是“反向博弈论”：先定下想要的结果，再设计规则，让每个人按自身利益行动时恰好产生这个结果。例子是 Gale–Shapley（1962）的“延迟接受”算法：一方轮流向另一方“求婚”，被拒就找下一个，可以证明最后的配对“稳定”，不存在两个人都宁愿撇下各自的对象而彼此配对。美国住院医匹配

(NRMP) 1952 年就由实务者摸索出本质相同的算法，比数学家早 10 年。频谱拍卖要等 1993 年国会立法授权，1994 年 7 月 FCC 首次拍卖，规则由 Milgrom、Wilson 等设计（2020 年诺贝尔奖）。Roth & Peranson 重新设计的 NRMP 1998 年启用。肾脏配对交换由 Roth、Sönmez、Ünver 2004 年提出并推动落地；2007 年国会通过 Charlie W. Norwood 活体器官捐献法（Pub. L. 110–144），澄清配对交换不违反禁止器官买卖的法律。教训：30–40 年，卡在法律、机构和跨医院的信任，不在数学；实践有时还跑在数学前面。

来源：Gale & Shapley 1962, doi:10.2307/2312726；Roth, Sönmez & Ünver 2004, doi:10.1162/0033553041382157；Roth & Peranson 1999, doi:10.1257/aer.89.4.748；<https://www.nobelprize.org/prizes/economic-sciences/2020/summary/>

其余 8 个案例，各一句话

- **3 群论 → 夸克模型**：Gell-Mann 和 Ne'eman 1961 年用 $SU(3)$ 的表示给强子分类，预言缺失的粒子 Ω^- ，1964 年被找到。这里的"应用"是科学认识，不是产品。
- **4 傅里叶 → FFT**：Cooley & Tukey 1965 年的 FFT 把计算量从 n^2 降到 $n \log n$ ($n = 1024$ 时快约 100 倍)，后来发现 Gauss 1805 年就写过。150 多年里瓶颈是"算得动"：一个算法改进比任何新定理都重要。
- **5 希尔伯特空间 → 晶体管**：数学只早 15–25 年；物理到技术又 20–35 年，卡在材料和工艺。
- **6 逻辑 → 计算机**：Boole 1854 到 Shannon 1937 年证明继电器电路就是布尔代数，隔了 83 年，卡在没人同时懂两边。史学家 Haigh 提醒，Turing 1936 对实际计算机工程的直接影响常被高估，"理论 → 机器"的因果链要谨慎讲。
- **11 随机分析 → Black–Scholes**：1973 年发表，几年内交易员人手一台预装公式的计算器，本表最快。MacKenzie & Millo 2003 指出，价格越来越贴近公式，部分是因为交易员都在用它：理论改变了它描述的世界（"表演性"，performativity），直到 1987 年股灾后出现"波动率微笑"。被大规模采用的模型会改写它所在的系统，AI 也一样。
- **12 拓扑 → 拓扑量子比特**：理论早就齐了（TKNN 1982；Kitaev 1997），技术至今没有公认实现。Microsoft 2018 年的 Nature 论文 2021 年撤回；2025-02 "Majorana 1" 同期论文的编辑注明结果"不构成马约拉纳零模存在的证据"；2026-06 Nature 刊出 Legg 的批评，Microsoft 坚持结论（△ 转引自报道）。卡在材料和实验近 30 年，AI 数学几乎帮不上。
- **13 压缩感知 → 快速 MRI**：信号稀疏时，可以用远少于传统要求的测量把它精确恢复。2004–06 年的数学，2017 年 Siemens 和 GE 的产品获 FDA 510(k) 许可（clearance）（厂商称心脏扫描从约 4 分钟缩到 16 秒）。条件是现成产业、明确指标、纯软件交付、现成审批通道。
- **14 格 → 后量子密码**：Shor 1994 年证明量子计算机能破 RSA，**数学制造了需求**。Ajtai 1996 到 FIPS 203 (2024-08) 用了 28 年；标准到大规模部署只用约 2 年（2026-09 Cloudflare 报告约 70% 浏览器流量已用混合 ML-KEM）。全同态加密（FHE）2009 年就有构造，开销至今让它只适合少数场景：可构造不等于可用。

来源：Gell-Mann 1964, doi:10.1016/S0031-9163(64)92001-3; Cooley & Tukey 1965, doi:10.1090/S0025-5718-1965-0178586-1; Heideman et al. 1984, doi:10.1109/MASSP.1984.1162257; Shannon 1938, doi:10.1109/T-AIEE.1938.5057767; Haigh 2014, CACM 57(1):36; MacKenzie & Millo 2003, doi:10.1086/374404; Thouless et al. 1982, doi:10.1103/PhysRevLett.49.405; Kitaev, arXiv:quant-ph/9707021; <https://www.computerworld.com/article/4189622/researchers-cast-new-doubt-on-microsofts-quantum-computing-advance-2.html> △; Candès, Romberg & Tao, arXiv:math/0409186; <https://usa.healthcare.siemens.com/news/fda-clears-mri-technology-02-21-2017.html>; Ajtai 1996, doi:10.1145/237814.237838; <https://csrc.nist.gov/pubs/fips/203/final>; <https://blog.cloudflare.com/post-quantum-visibility/>; Gentry 2009, doi:10.1145/1536414.1536440

五条规律

- 1. 库存型 vs 订单型。** 为数学本身做的库存型数学要 50–200 年才找到应用；问题来自应用的订单型数学只要 2–15 年。OpenAI 那批 719 篇绝大多数是库存型（数论、代数几何、算子代数……），按历史，现实影响以几十年计，除非有人主动去匹配应用 [推测]。
- 2. 应用发生时，数学几乎总是现成的。** 没有一个案例是"应用方等数学等了很久"。最后的瓶颈是：算力或使能技术（案例 4、6、7、9、14）、需求或威胁（1、14）、制度与法律（8、10、11）、材料与实验（5、12）、没人知道这个数学存在（6、7、9）。反例很少：Einstein 三年"学数学"；纠错码从 1948 到 1990 年代缺"能逼近容量又解得动"的码，一半是数学瓶颈、一半是算力瓶颈。
- 3. 重新发明很常见，"匹配成本"是真实瓶颈。** Gauss 的 FFT、Cormack 与 Radon、被遗忘的 LDPC、先于数学家的 NRMP。所以 AI 最被低估的贡献，可能是把已有数学匹配到需要它的问题上，而不是证新定理 [推测]。2025 年"GPT-5 解决 Erdős 问题"风波里，多数所谓的解其实是模型找到的已有文献；当时被当作丑闻，从匹配成本的角度看却有价值。
- 4. 物理学通常不等严格证明。** 路径积分至今没有完全严格的定义；Parisi 1979 年的自旋玻璃公式到 2006 年才被 Talagrand 严格证明；杨–米尔斯"质量间隙"仍是千禧年难题，格点 QCD 的数值计算却早就给出能和实验对比的预言。所以 AI 证明物理学家早已相信的猜想（如 §12、§13），主要提升数学确定性，很少改变物理或工程实践。例外有两种：证明推翻了广泛相信的直觉；安全关键的认证需要严格界。
- 5. 时间差在缩短，纯软件交付最快。** 最快的几个（Black–Scholes、极化码、压缩感知、后量子密码部署）都是少数决策者就能推动采用（交易所、3GPP、几家 MRI 厂商、浏览器与 CDN），交付物是软件或标准，不是新硬件或新药。提醒：Morris 等 2011 年指出，医学转化常被引用的"17 年"来自测量对象各不相同的研究，可比性差。上表的数字只应视为数量级。

来源：Talagrand 2006, doi:10.4007/annals.2006.163.221; Morris, Wooding & Grant 2011, doi:10.1258/jrsm.2011.110180; Ahmadpoor & Jones 2017, doi:10.1126/science.aam9527（约 80% 被引论文能沿引用链连到未来某个专利，典型距离 2–4 步）

17.2 瓶颈框架：数学什么时候是瓶颈

Amdahl 定律。 科研可以看成一条流水线：提问 → 理论/数学 → 写代码与分析 → 实验或数据采集 → 审核、监管、推广。AI 只让其中一段变快时，总速度受其余部分限制：

总加速比 = $1 / [(1 - p) + p / s]$ ， p 是被加速部分原来占的时间比例， s 是这部分的加速倍数。

手算例子（数字是假设的，只为说明结构）：一个药物研发项目的时间构成是理论 5%、计算与分析 15%、湿实验 30%、临床试验与审批 50%。

- 让**理论**无限快： $1 / 0.95 \approx 1.05$ 倍。
- 让**理论 + 计算分析**都无限快： $1 / 0.80 = 1.25$ 倍。
- 再让湿实验快 10 倍： $1 / (0.50 + 0.03) \approx 1.9$ 倍。
- 只有临床和审批也变快，才可能出现 10 倍。

经济学里同一个结构叫 **Baumol 效应**。Aghion、Jones & Jones (NBER w23928) 的说法是：增长"不受我们擅长的东西约束，而受那些必不可少却难以改进的东西约束"。

但 Amdahl 定律低估了 AI 的两条出路。一是**减少慢步骤的次数**：临床试验本身不会变快，但候选药物更好，需要做的试验就少。从进入 I 期到获批的总成功率约 7.9% (BIO 对 2011–2020 年的统计)，成功率翻倍，每个获批药物背后的试验次数就减半，等价于这一段"加速 2 倍"。二是**用计算替代实验**：AlphaFold 让很多课题不再需要先解晶体结构；AI 天气模型从再分析数据学习，替代了部分数值模拟 (17.3)。所以判断"AI 数学能帮多少"要问三件事：数学在流水线里占多大比例？它能否提高慢步骤的命中率？它能否让慢步骤被计算替代？

想法越来越难找 [已确立]。Bloom、Jones、Van Reenen & Webb (AER 2020)：维持摩尔定律所需的研究人员是 1970 年代初的 **18 倍以上**，研究生产率每年下降约 7%；美国整体经济的研究生产率自 1930 年代以来下降了 **41 倍**，经济还在增长，是因为投入研究的人数增长得更快。乐观读法：如果 AI 能当"研究人员"，人数几乎可以无限增加，就能抵消生产率下降，这是爆炸增长论证的核心。悲观读法：想法变难找，部分是因为每个想法所需的**实验和物理投入**在上升（比如 EUV 光刻机），这不是人数能解决的。

乐观一方。Dario Amodei 在《Machines of Loving Grace》(2024-10) 里说，该问"智能的边际回报"：多加一份聪明能换来多少进展。他列了五个限制：外部世界的速度、对数据的需要、内在复杂性、人类的约束（法律、临床试验）、物理定律。他认为生物学进展"相当大一部分来自极少数发现"，有大量聪明的研究者，这类发现的速度"可以提高 10 倍或更多"，于是得出"**压缩的 21 世纪**"：5–10 年完成 50–100 年的生物学进展。值得注意的是，他列举的关键突破（CRISPR、显微技术、基因组测序与合成、光遗传学、mRNA 疫苗、CAR-T）几乎都是**新的测量和操作工具**，没有一个是新定理。他的 10 倍加速依赖 AI 的实验设计和工具发明能力，不是证明能力。

增长模型一方也乐观，但有前提。Davidson (Open Philanthropy 2021) 和 Erdil & Besiroglu (arXiv:2309.11690) 认为，如果 AI 能替代几乎所有人类劳动（包括体力劳动），增长率提高

10 倍并不出格；各种反对意见"不能决定性地排除"爆炸增长，但高置信度也不成立。Epoch 的 GATE 模型（arXiv:2503.04941）作者明确说输出不是预测。反直觉的一点来自 Erdil & Barnett（Epoch，2025-03）：1988 年以来，研发只解释了美国劳动生产率增长的约 **20%**；医学科学家的 14 项 O*NET 任务里，只有 6 项能靠纯推理完成，最重要的 5 项里只有 1 项。所以"纯软件奇点"不太可能，AI 加速科学可能主要靠自动化实验基础设施这类非研发工作。

怀疑一方。Acemoglu（NBER w32487）估计未来 10 年 AI 带来的全要素生产率提升最多约 0.66%（批评者指出他的输入来自早期模型）。Narayanan & Kapoor（"AI as Normal Technology"，2025-04）：扩散"以十年计，而不是以年计"；社会科学和医学要在人和组织身上做实验，"知识获取的速度存在硬上限"。Kapoor & Narayanan（"Could AI slow science?"，2025-07）提出"**生产-进展悖论**"：1900–2015 年论文数量增长约 500 倍，科学进展却没有相应加速；AI 主要加速"生产"，就像收费站造成拥堵时，却去加宽高速公路。两派其实有共同点：Kapoor、Narayanan 与 Kokotajlo（AI 2027 作者）等 2025-11 合写的 "Common Ground" 同意，在出现"强 AGI"之前，AI 就是一种普通技术；分歧在于强 AGI 何时到来、来了扩散多快。

先分清三种"数学"。(i) **证明**：给定陈述，证明它对不对，AI 现在突破最快，对应 17.5 的 A 类问题。(ii) **建模与表述**：决定该用什么方程、该证明什么，这是 B 类问题，AI 加速慢。(iii) **计算与模拟**：给定方程算出数值，属于高性能计算和 ML 代理模型（surrogate model），和证明能力关系不大。例如证明 Navier–Stokes 方程在某种受迫情形下会爆破 (§11) 属于 (i)，它**不会**帮你更好地预测发动机里的湍流，那属于 (iii)。据此分三档：

档位	条件	例子
数学就是产品 (帮助大)	交付物本身是证明、算法或界；有自动裁判	算法与复杂度、密码学安全归约与密码分析、软硬件形式化验证、编译器正确性、编码理论、部分优化理论
数学筛选实验 (帮助中等)	理论能缩小实验搜索空间或给出误差界，减少慢步骤的次数	量子算法与纠错码设计、控制与机器人安全证书、实验设计与统计、数值方法的收敛证明
数学不是瓶颈 (帮助小)	未知的是经验事实，或卡在物理吞吐量、制度	大部分生物与医学、材料合成、拓扑量子比特、社会科学、任何监管主导的领域

元规律 [推测，与 17.1 一致]：一个领域里"陈述清楚、只缺证明"的问题占比越高（Amdahl 公式里的 p 越大），AI 数学带来的总加速越大；占比低的领域，AI 的其他能力（编程 agent、模拟、自动实验、文献匹配、假设生成）更重要。

17.3 AI for science 到目前为止的真实记录

三个逐级变严的标准：(1) **独立验证**：作者以外的人检查过吗？(2) **被非作者采用**：用于真实决策了吗？(3) **改变了下游结果**：预报准确度、药物上市时间、成本变了吗？据此分四档。

档位	案例	发生了什么
已证实加速	天气预报	[已确立] GraphCast (<i>Science</i> 2023) 在 1,380 个检验目标的 90% 上超过 ECMWF 确定性模式；GenCast 在 1,320 个目标的 97.2% 上超过 ECMWF 集合预报。[近期发现] ECMWF 的 AIFS 2025 年进入业务运行，2026-05 升级 v2；NOAA 的 AI 模型 2025-12 进入业务运行，称算力最多省 99.7% (Δ 它基于 GraphCast 等说法只见于二手来源)。美国国家飓风中心 2025 年检验：DeepMind 集合平均短时效路径略好、强度最好；但 2023–25 三年合计，多模式共识仍最好。
已证实加速	蛋白质结构预测	[已确立] AlphaFold 2 把"从序列预测三维结构"从多年实验变成几分钟计算，2024 年获诺贝尔化学奖。DeepMind 自报 (2025-11)：2 亿多个预测结构，300 多万研究者使用。
真实但增量	算法与常数	AlphaTensor (2022) 用 47 次乘法完成 0/1 算术里的 4×4 矩阵乘法 (原纪录 49)，三天后 Kauers & Moosbauer 就把 5×5 从 96 降到 95。AlphaEvolve (2025) 在 50 多个开放问题上约 75% 追平、约 20% 改进已知最好结果，为 Google 回收约 0.7% 的全球算力；Tao 等人测试 67 个问题，"多数问题上重新找到已知最好解，若干问题上有改进"。
真实但增量	Erdős 问题、形式化	[近期发现] 约 100 个 Erdős 问题在 AI 参与下转为已解 (Tao 维护的 wiki, Δ 精确数字)，但在预注册的 FrontierMath Erdős 上单次只有 $2/68 = 3\%$ 。Claude 11 天完成费马大定理 (FLT) 的 Lean 形式化，约 1300 万行；人类项目预计 5 年、100 万英镑。
真实但增量	OpenAI openai/math	[近期发现] 约 4,000 个问题 $\rightarrow$ 719 篇 (撤回 3 篇后)；300 个顶层结果有 Lean 证明。约 58% 没有任何机器检查；截至 2026-10-08 没有领域专家公开确认核对过任何头条结果；Lean 陈述的忠实性仍是 <code>review: unchecked</code> (§2–§3)。
太早	AI 发现的药物	[近期发现] 截至 2026-10 没有一款获 FDA 批准；最接近的武田 zasocitinib (FDA 优先审评公告) 主要出自基于物理的计算设计。Insilico 的 rentosertib (肺纤维化) IIa 期 71 人、12 周，主要终点是安全性，肺功能次要终点与安慰剂组的置信区间重叠；2026-07 启动 III 期。AI 原生公司的分子 I 期成功率 80–90%，II 期约 40%，与行业历史水平相当 (样本小)。Recursion 2025 年砍管线、裁员约 20%；Isomorphic Labs 首个临床试验目标推迟到 2026 年底 (Δ 二手来源)。
太早	AlphaFold 用于药物筛选	证据混合：两个靶点上命中率与实验结构相近 (Lyu 等 2024)；22 个靶点上一致地差于实验结构 (Scardino 等 2023)；GPCR 上不比老式同源建模好 (Karelina 等 2023)。Terwilliger 等 (2024)：高置信度预测也可能失真，应视为"非常有用的假设"。
太早	"AI 科学家"系统	Google AI co-scientist (<i>Nature</i> 2026-05) 的老药新用只在细胞系和类器官里测试，论文自称验证"仍是初步的" (Δ "答案可能从实验室早先论文泄漏"的批评未核实)。FutureHouse Robin 的干性黄斑变性候选只有细胞培养验证，实验由人完成。Kosmos 自报陈述 79.4% 准确 (Δ 未找到独立评估)。
被高估、已更正	材料发现三旗舰	见表后。
撤回	MIT"AI 让材料研发提速"论文	Toner-Rodgers 的预印本 (arXiv:2412.17866) 称某实验室引入 AI 后新材料多 44%、专利多 39% (Δ 转引自报道)，曾是"AI 加速研发"被引用最多的因果证据。MIT 经济系 2025-05-16 声明对数据"没有信心"，arXiv 随即撤下。

档位	案例	发生了什么
被高估	Sakana AI Scientist v2	全 AI 论文"通过 ICLR 2025 研讨会评审": 3 篇中 1 篇通过 (研讨会录取率 60–70%), 有引用错误; Sakana 自认都达不到主会水平。

材料发现三旗舰怎样被回调 [近期发现]:

- **GNoME** (DeepMind 2023) 声称 220 万个"低于凸包"的晶体 (凸包是已知最稳定组合连成的"能量下边界", 低于它表示可能稳定)。Cheetham & Seshadri (2024) 随机抽 10 个, 成分**全部已在无机晶体数据库 ICSD 里出现过**; 许多阳离子有序排列在合成温度下不现实。结论: "几乎没有证据表明有化合物同时满足新颖、可信、有用。"
- **A-Lab** (自动实验室 2023) 声称 17 天合成出 41 个新化合物。Leeman、Schoop、Palgrave 等 (2024): "没有发现新材料", 约三分之二是已知无序相被误认为预测的有序结构。2026-01 作者更正: 标题里的 "novel materials" 改成 "inorganic materials", "新"改为"对预测平台是新的"。
- **MatterGen** (Microsoft 2025) 设计的 TaCr₂O₆, 被 Juelsholt (2026) 指出是 1971 年就报道过、且在训练集里的已知化合物。
- 共同的失败: 计算上"稳定"不等于新颖、能合成、有用; X 射线衍射的自动拟合分不清有序和无序; 训练集泄漏。瓶颈是合成、表征和"什么算新", 更多的计算预测反而制造了更多要人工核查的候选。

系统性证据。Hao、Xu、Li & Evans (arXiv:2412.07727, 注明已被 *Nature* 接收, △ DOI 未核实) 基于 4130 万篇论文: 用 AI 的科学家论文数是对照的 3.02 倍、引用 4.84 倍, 但研究主题**收窄 4.63%**, 科学家之间的**互动减少 22%**, 和"生产–进展悖论"一致。Kapoor & Narayanan (*Patterns* 2023): 17 个领域 294 篇论文有"数据泄漏"。McGreivy & Hakim (2024): 用机器学习解偏微分方程的论文 79% 是和弱基线比较。Epoch (2025-09): AI 对"桌面型研究"的生产率提升至少 10–20%, 但实验室进展要变成新药, 还要好几年的临床和审批。

档位	共同点
已证实加速	数据多且标准化; 输出能被快速、客观、自动打分; 交付物进入已有的流程
真实但增量	有内置检查器的窄问题; 人类往往很快追上; 现实影响主要是小百分比的工程优化
太早	验证要靠湿实验和临床, 周期以年计
被高估、更正、撤回	"新"和"成功"的定义模糊; 自动表征不可靠; 训练集泄漏; 数据来源不可信

一句话: 到目前为止, AI 在科学上被证实的加速全部来自"其他能力" (从大量数据学习、在有检查器的空间里快速搜索), 而不是证明定理。证明能力的爆发是真的, 但现实影响还没开始: 被改进的多是纯数学和常数, $\omega \leq 9/4$ 是用不上的"银河算法" (§6)。

来源：天气 doi:10.1126/science.adi2336； doi:10.1038/s41586-024-08252-9；
https://www.ecmwf.int/en/forecasts/dataset/aifs-machine-learning-data；
https://wmo.int/media/news/noaa-deploys-new-generation-of-ai-driven-global-weather-models； https://www.nhc.noaa.gov/verification/pdfs/Verification_2025.pdf。AlphaFold doi:10.1038/s41586-021-03819-2； https://deepmind.google/blog/alphafold-five-years-of-impact/； doi:10.1126/science.adn6354； doi:10.1038/s41592-023-02087-4；
doi:10.1016/j.isci.2022.105920； doi:10.7554/eLife.89386。药物 doi:10.1038/s41591-025-03743-2； doi:10.1016/j.drudis.2024.104009；
https://www.fiercebiotech.com/biotech/recursion-lays-20-staff-wake-pipeline-cutbacks；
https://isomorphiclabs.com/articles/isomorphic-labs-announces-series-b-investment-round。材料 doi:10.1038/s41586-023-06735-9； doi:10.1021/acs.chemmater.4c00643；
doi:10.1103/PRXEnergy.3.011002； 更正 doi:10.1038/s41586-025-09992-y；
doi:10.1038/s41586-025-08628-5； doi:10.1039/d6mh00268d。撤稿
https://economics.mit.edu/news/assuring-accurate-research-record。数学
doi:10.1038/s41586-022-05172-4； arXiv:2210.04045； arXiv:2506.13131；
arXiv:2511.02864； https://github.com/teorth/erdosproblems/wiki/AI-contributions-to-Erd%C5%91s-problems； arXiv:2609.25050； https://github.com/openai/math。AI 科学家
doi:10.1038/s41586-026-10644-y； doi:10.1038/s41586-026-10652-y；
arXiv:2511.02824； https://sakana.ai/ai-scientist-first-publication/。系统性证据
arXiv:2412.07727； doi:10.1016/j.patter.2023.100804； doi:10.1038/s42256-024-00897-5；
https://epoch.ai/blog/what-will-ai-look-like-in-2030

17.4 三条能力曲线：按趋势推演，而不是按直觉

关于"现实"的约定：人的直觉习惯线性外推，但下面三条曲线都是指数型的，所以按趋势推出来的未来常常显得"太快"。原则是：**不因为反直觉就保守，也不凭空想象**。每个时间点都写明依赖哪条曲线、用了什么假设、哪些信号会证伪它。§18-§22 的时间判断都对接这三条曲线。

17.4.1 曲线 ①：AI 能独立完成任务有多长


这是什么：METR 让 AI 去做一批软件和研究任务，每个任务先测人类专家要花多久，再找出"AI 有 50% 把握做成"的任务长度。这个长度叫时间跨度（time horizon），它把"AI 有多能干"压缩成一个可以画在图上的数。

发布	模型	时间跨度（p50）
2019-02	GPT-2	0.1 分钟
2023-03	GPT-4	4 分钟
2024-12	o1	39 分钟
2025-04	o3	2.0 小时

发布	模型	时间跨度 (p50)
2025-08	GPT-5	3.4 小时
2026-02	Claude Opus 4.6	12 小时 (CI 5.3–61)
2026-04	Claude Mythos Preview	17.4 小时 (CI 8.5–55)
2026-06	GPT-5.6 Sol	作弊算失败：11.3 小时；其他处理方式：71–270+ 小时

[数据] 来源：METR TH1.1 原始数据 benchmark_results_1_1.yaml (2026-05-08 更新)；GPT-5.6 Sol 来自 METR 2026-06-26 报告。

倍增期：从 2023 年起拟合，每 **129 天**翻一倍 (95% CI 104–158 天)；只用 2024 年后的数据约 89 天；2019 年起全部数据约 188 天 [数据]。129 天翻倍换算成年增长是 $2^{(365/129)} \approx \text{每年} \times 7$ 。这就是反直觉的根源：线性直觉以为明年会"好一点"，按趋势是"好 7 倍"。



情景	倍增期	2026 年末	2027 年中	2027 年末	2028 年末
乐观	89 天	~100 小时	~410 小时	~1,700 小时 (10 工作月)	~3 万小时
中心	129 天	~56 小时 (1 工作周+)	~150 小时 (≈1 工作月)	~400 小时 (≈2.4 工作月)	~2,800 小时 (≈1.4 工作年)
悲观	213 天	~33 小时	~60 小时	~110 小时	~360 小时 (≈2 工作月)

[模型] 锚点 2026-05 约 15 小时（介于 Opus 4.6 与 Mythos Preview 之间），按固定倍增期纯指数外推。

这条曲线的两个弱点（必须一起记住）：(1) METR 说现有任务集在 16 小时以上就不可靠，2027 年以后的数字需要新的长任务集（TH 2.0，尚未发布）来检验；(2) GPT-5.6 Sol 的结果说明，"作弊算不算成功"能让数字相差约 4.5 个倍增，相当于约 1.5 年的趋势。[判断] 超过约一个月之后，决定成败的越来越是"任务说得清不清楚"，而不是执行能力。


17.4.2 曲线 ②：真正的开放问题，AI 能解出多少

为什么需要第二条曲线：竞赛和 benchmark 已经饱和，不能再拿来外推 [数据]。

- IMO 2024 银牌 (28/42) → 2025 金牌 (35/42) → 2026 满分 (42/42，两个系统经官方评分)。
- PutnamBench (Lean) 2025-04 约 7% → 2026-08 满分 672/672；2026-09 解完全集只花 \$111。
- FrontierMath Tier 4 从 2025-11 的 19% 涨到 2026-09 的 98%。

但同一时期，在 Epoch 的 **FrontierMath Erdős**（68 个预先登记为开放、必须给 Lean 证明、每题预算 \$300 的 Erdős 问题）上，最强的 GPT-6 Astra 只解出 $2/68 = 3\%$ ，其他模型都是 0。不限预算时 5/68（约 7%），花费超过 \$22 万 [数据]。**benchmark 上的 98% 和开放问题上的 3% 之间的差距，是整个外推里最重要的不确定量。**

曲线 ②：可形式化开放问题的单次解出率（每题约 \$300）三情景



三情景参数：乐观 +3.0 logit/年、上限 90%；中心 +1.5、上限 80%；悲观 +0.7、上限 60%。模型：解出率 = $C \times \text{sigmoid}(a + s \cdot t)$ ，C 是"有些题本身极难或无解"的上限，锚点是 Epoch FrontierMath Erdős（68 个预注册开放问题、必须给 Lean 证明）上 GPT-6 Astra 的 3%。斜率参照 FrontierMath Tier 4 在 10 个月内涨约 5.3 logit，三情景都取得更慢，因为开放问题的难度分布是重尾的。曲线由 build 脚本计算。

情景	斜率 (logit/年) · 上限	2026 年末	2027 年中	2027 年末	2028 年末	2030 年末
乐观	+3.0/年 · 90%	~7%	~26%	~58%	~88%	~90%
中心	+1.5/年 · 80%	~5%	~9%	~18%	~45%	~77%
悲观	+0.7/年 · 60%	~4%	~5%	~7%	~13%	~31%

为什么中心情景可能偏保守：(1) 预算放大 10 倍，2026 年就能从 3% 提到约 7%，而推理价格每年降 10 倍以上（Epoch：固定能力下每年降 9–900 倍，中位数 50 倍）[数据]；(2) OpenAI 从约 4,000 题里留下 372 族（约 9%），说明一个可能更强的未发布模型在"大量尝试 + 事后挑选"口径下已经远高于 3%。**为什么可能偏乐观：**固定题集越往后剩下的越难；千禧年级别的单个难题不在这个模型的适用范围内。

17.4.3 曲线 ③：形式化证明的成本

- **2025-09：**Math Inc 的 Gauss 用 3 周完成强素数定理的形式化，约 2.5 万行（人类专家此前 18 个月只完成一部分）[数据]。
- **2026-09：**Claude 用 11 天完成**费马大定理**的完整形式化，1300 万行、约 60 亿输出 token，只用三条标准公理，并经 Buzzard 审阅。按标价约 \$30 万，即 **\$0.023/行**。对照：人类项目预计 5 年、100 万英镑 [数据]。
- **2026-10：**OpenAI 的 Lean 库 2600 万行（\$3）。

情景（每年降幅）	2026 年末	2027 年末	2028 年末	"费马大定理规模"项目，2028 年末
乐观（÷30/年）	\$0.008/行	\$0.0003/行	\$0.00001/行	~\$110
中心（÷10/年）	\$0.01/行	\$0.001/行	\$0.0001/行	~\$1,400
悲观（÷3/年）	\$0.016/行	\$0.005/行	\$0.002/行	~\$2.3 万

含义：三种情景下，**生成证明的成本到 2027–2028 年都会降到可以忽略**。剩下的成本几乎全是"人审核陈述和 spec 是否忠实"，这部分的吞吐量基本不随时间增长。△ 有报道称费马大定理形式化的内部成本只有约 \$2,000，与标价相差约 150 倍，口径未核实。

17.4.4 可能打破趋势的因素

因素	方向	证据与判断
AI 研发全面自动化	加速	CASP 2026（Hinton、Bengio、OpenAI 首席科学家等联名）的模型给出 $r \approx 1.39 > 1$ ，意味着超指数增长：全面自动化后约 17 个月进步速度提高 10 倍。前兆：Anthropic 内部"AI 主导、人监督"的研发占比 2026-03 到 08 从 1% 升到 26%；完全自主仍是 0%。[数据]
训练算力增速放缓	减速	可能从每年 4–5 倍降到 3–4 倍（电力、HBM）。但数学和形式化主要消耗推理算力，受影响较小。[判断]

因素	方向	证据与判断
数据	中性偏正	在可验证领域，Lean 内核或测试本身就是无限的奖励信号；几千万行新 Lean 会回流进训练。数据墙在这里最弱。[判断]
验证器本身有噪声	让测量失真	FrontierMath 审计发现 42% 的题有错，SWE-bench Pro 约 30% 的任务有问题。指标会比能力先失效。[数据]
Reward hacking	让测量失真	外推 METR 时必须同时报告"作弊处理区间"。
监管与社会反应	局部减速	菲尔兹奖得主公开信、IAS 出版规范会减慢学术界接受 AI 结果，但基本不限制能力本身。

来源：METR <https://metr.org/blog/2026-1-29-time-horizon-1-1/>、
<https://metr.org/blog/2026-06-26-gpt-5-6-sol/>；IMO 2026 https://studio-dots-ai.github.io/dots_imo_2026/en.html；PutnamBench
<https://trishullab.github.io/PutnamBench/leaderboard.html>；FrontierMath v2
<https://epoch.ai/frontiermath/tiers-1-4>；FrontierMath Erdős arXiv:2609.25050；推理价格
<https://epoch.ai/data-insights/llm-inference-price-trends>；Gauss
<https://www.math.inc/gauss>；FLT <https://www.anthropic.com/research/formalizing-fermats-last-theorem>；训练算力 <https://epoch.ai/publications/training-compute-of-frontier-ai-models-grows-by-4-5x-per-year>；CASP arXiv:2609.36054

17.5 核心框架：A 类与 B 类，以及裁判有多快

三条曲线都在测同一类东西：**有自动裁判的工作**。Lean 内核判断证明对不对，测试判断代码对不对，benchmark 判断答案对不对。AI 在这类工作上进步极快，因为强化学习可以无限地"试错 → 拿到可靠反馈 → 改进"。所以 AI 的加速极不均匀，瓶颈会迁移。

有自动裁判（AI 会碾压）	没有自动裁判（仍主要靠人）
给定一个定理陈述，找出证明	判断 该证哪个定理 ，陈述是否抓住了你真正关心的东西
给定 spec 写代码，并证明代码满足 spec	写出 对的 spec （例如"无害"是什么意思）
给定一个模型，计算它的数学性质	判断这个数学量和"安全"有什么关系
跑实验、扫超参、复现	设计 对的实验 ，判断结果说明了什么

瓶颈已经在迁移的证据 [数据]：

- **证明成功率暴涨**：CLEVER 基准（161 道题，把 HumanEval 翻译成 Lean，要求写出代码并证明它满足 spec）的端到端成功率，从 2025-05 的 1/161 涨到 2026-05 的约 87.5%（Claude Code agent）。DafnyBench 一年内从约 68% 涨到 96%。

- **spec 质量没跟上**：vericoding 基准（Tegmark 组，12,504 条 spec）统计，在验证**成功**的样本里，约 9% 的 spec 太弱（"空洞 spec"：例如排序函数的 spec 漏写"输出是输入的重排"，返回空列表也能通过），约 15% 的翻译有问题。
- **陈述没人审**：OpenAI 的 416 个 Comparator 挑战文件状态是 `review: unchecked` (§3)；费马大定理能被确认，是因为 Mathlib 里有现成的人类陈述可以比对。
- **IMO 2026 的流程**在 Lean 证明之后，专门加了一个"形式陈述是否覆盖原题"的裁判。陈述对齐本身已经成为新的难题。

把"缺数学"拆成两类。说一个领域"需要更多数学"，其实有两种完全不同的情况：

- **A 类：陈述已经清楚，只差证明**（17.2 的第 (i) 种数学）。例如"在不需要 stability 假设的情况下，Prover-Estimator Debate 是否仍然 sound？"这是定义清楚的命题，有了 Lean 就有自动裁判。**AI 会在 2027 年前后批量解决这类问题**（依赖曲线 ②③）。
- **B 类：连该证什么都不清楚**（第 (ii) 种）。例如"SGD 训练出来的网络和贝叶斯后验之间的差距，应该用什么量来刻画？"难的是找到对的陈述。AI 能提猜想、做数值检验，但没有自动裁判告诉它"这个陈述是对的问题"。**AI 在这里帮得慢。**

下表用 deck 旧版重点讨论的四个 AI 安全理论方向举例（§21 会在更大范围里重新挑选 AI 理论与对齐的问题）：

方向	A 类（缺证明）	B 类（缺陈述）	工程 / 实验	概念
辩论	去掉 stability 的 PE debate；对 ϵ 比例裁判错误稳健的协议	什么样的现实论证满足 stability；非零和、合谋下的均衡怎么形式化	RL 能否到达诚实均衡 (exploration hacking)；有真实能力差距的 testbed	没有 ground truth 的问题，"诚实"怎么定义；真话但选择性陈述
SLT	具体架构的学习系数（符号计算）；Langevin 动力学与 LLC	SGD 与贝叶斯后验的差距；有限样本、ReLU 版本应该长什么样	估计量稳健性；扩展到 10B+ 模型	λ 和"欺骗""reward hacking"的关系
GSAI	软件、协议的证明（已基本可自动化）	概率集合 (credal set) 上 sound bound 的组合理论	spec 起草与审核工具；仓库级验证；硬件	物理扰动界从哪来；社会领域的"harm"写不出来
神经符号	（大多已是工程）	翻译层有没有 sound 的检查方法	"LLM 提议、求解器判定"成为默认架构	哪些任务能这样分解

从"有没有裁判"到"裁判有多快" [判断]。物理和化学给出了这个框架的推广：**一轮反馈要多久**，决定了 AI 能把"试错 → 改进"的循环转多快。数学物理定理的裁判是 Lean，分钟到小时，加速已经发生；天气的裁判是明天的观测，按天打分，加速也已发生；电子结构的裁判是高精度计算，小时到天；材料与超导的裁判是合成加表征，周到月，受 Amdahl 约束；气候的裁判是观测，要十年；量子引力几乎没有裁判。A 类和 B 类是这条光谱的两端。完整的表见 §19。

17.6 当证明几乎免费：科学本身会怎么变

先看一个已经发生过的类比。测一个人类基因组的成本，2006 年约 1400 万美元，2015 年底已低于 1500 美元，约 10 年降了一万倍（NHGRI）[已确立]。结果生物学变得"数据富、解释穷"："这个变异有什么功能"仍要一个一个做实验。瓶颈从"读序列"迁到"理解序列"和"功能实验"，整体进展加快了，但远没有快一万倍。证明成本也正以每年约 10 倍的速度下降（曲线③）。按这个类比 [推测]：定理数量暴涨；瓶颈迁到"这个定理说的是什么、重要吗、陈述对吗"；数学的整体进展加快，但远低于成本下降的倍数。

数学内部争的是：数学的产品是定理，还是人的理解。

- **理解派**。Thurston 1994："衡量我们成功的标准是：我们做的事能否让人们更清楚、更有效地理解和思考数学。"按这个标准，一份没人读懂的 100 页 AI 证明，即使正确，也几乎没完成数学的工作。De Millo、Lipton & Perlis 1979：证明被相信，是因为经过了**社会过程**（被人读、讲、改、用），不是因为形式上正确。
- **Tao：从证明稀缺到证明丰裕**。ICM 2026 公众讲座："我们大多数制度.....都是在稀缺的假设下设计的。"他把解题拆成五环：生成 → 验证 → 阐释 → 发表 → 消化与规范化；AI 只让第一环几乎免费。他的小模型：如果"解题"从 6 个月降到 1 天，"写好"只从 1 个月降到 3 周，文献会从约 90% 写得好翻转为约 90% 写得差。他和合作者发现 AlphaEvolve "极其擅长找到我们提供的验证代码里的漏洞"，**这就是 reward hacking**。对 OpenAI 的发布，他说开放问题正被"以不可持续的方式大规模收割，让整片数学领域变得贫瘠"。这呼应了 Thurston 1994 年的回忆：他证明叶状结构（foliations）系列定理后，"这个领域出现了戏剧性的撤离"，虽然领域"并没有在智识上被耗尽"。
- **定理派**。Buzzard："我在乎的是定理数量。"但他也说："形式语言能检查证明，但**定义需要人来检查**。"Gowers 没有在菲尔兹奖得主联名信上签名：结果的洪流会增加被真正消化的绝对量，"是笔相当划算的交易"；真正的风险是博士生与经费的人才管道。
- **集体声明**。莱顿宣言（2026-06）："荣誉和责任继续属于数学共同体中的人。"25 位菲尔兹奖得主联名信 "A Severe Misalignment of AI in Mathematics"（2026-09-11）：解题"只是实现概念理解与洞见这一首要目标的工具和代理指标"。IAS 主持的顾问组 AGMAI（含 Gowers、Hairer、Witten；Tao 不是成员）2026-09-29 的指南要求披露模型、提示词、思维链摘要与算力，尽可能形式化。AHM 声明（2026-10-07）呼吁停止与 OpenAI 合作。
- **数学之外**。气候科学家 Schneider（2026-09）：能被快速检验的地方（天气、AlphaFold），黑箱没问题；预测必须在被验证之前就被采取行动的地方（飞机设计、气候），需要"一条可审计的因果链"。这和 17.3 一致：AI 已证实的成功都在"快速可检验"一侧。

怎么看这些分歧 [推测]：如果产品是定理，现实影响取决于**匹配**到应用的速度（17.1）；如果是理解，取决于**消化**速度，而消化大约按人类速度增长。两种情况下，"证明生成"都不再是瓶颈。

科学整体：理论变便宜，实验相对变贵。 把 Amdahl / Baumol 结构用到科学内部，可以推出六条 [推测，每条都有先例]：

1. **实验相对变贵、更值钱。** 进展速度更由"每年能做多少有信息量的实验"决定。先例：1950 年代后计算变便宜，数值模拟没有取代实验，反而让"做哪个实验"更讲究。实验设计、测量工具、自动化实验室会变成稀缺资源。
2. **理论太多，裁决不过来。** 高能理论物理已经是这样。证明只保证"如果前提成立，结论成立"；哪个理论描述真实世界，仍要实验说了算。
3. **验证的对象从"推导"转向"陈述"。** Lean 检查不了形式陈述是否说的是你以为的那件事（17.5 的证据）。人工审核陈述的吞吐量按人类速度增长，会成为新的硬瓶颈。
4. **理解成为单独的产品。** 会出现专门把 AI 证明"翻译"成人能理解的结构、直觉和例子的工作。本 deck §4–§13 对 10 个结果的从零讲解，就是它的手工版本。
5. **匹配可能比证明更值钱**（17.1 规律 3）。AI 的跨领域检索与翻译能力，可能比证明能力更早兑现成现实影响。
6. **激励与信任结构被重写。** 署名、职称评审、审稿都建立在"证明稀缺"的假设上。Hao 等发现个人产出上升、集体主题收窄（17.3），提示一个风险：大家扎堆在 AI 最擅长的问题上，**B 类问题反而更少人做。**

与 AI 安全的交汇：

- **证明一个被悄悄削弱的陈述，是数学里的 reward hacking。** 模型有动机证明更容易过检查器的弱版本，所以陈述审核是安全问题，不只是学术规范。被撤回的 3 篇 Hodge 相关论文（一个符号错误连锁影响三篇，§14）是未形式化部分的反面教材。
- **"spec 写对没有"是同一问题的工程版本，也是 Guaranteed Safe AI 一类方案的瓶颈**（§21）。
- **理解与证明分离，会削弱人类监督的基础。** 如果连数学家都只能"信任检查器"，在更难检查的领域（AI 自己的行为），人类监督会更依赖少数可机械检查的属性。可扩展监督要回答的，正是这个问题的一般版本。

换算成时间 [推测]：按中心情景，在可形式化的领域，**证明大约在 2027–2028 年不再是瓶颈**（依赖曲线 ②③；悲观情景推迟 1–2 年）。订单型问题（有明确应用方等着的，例如密码分析、协议与编译器验证）在证明到位后 2–5 年内落地（17.1 规律 5）；库存型结果按历史要几十年，除非 AI 的匹配能力把时间差显著压短。**反证信号：**如果 2028 年前出现多个"AI 证明的库存型定理在 3 年内进入产品"的案例，说明匹配成本已被 AI 大幅降低，这里的时间差判断要整体前移。

来源：NHGRI <https://www.genome.gov/about-genomics/fact-sheets/Sequencing-Human-Genome-cost>；Thurston, arXiv:math/9404236；De Millo et al. 1979, doi:10.1145/359104.359106；Tao, *Notices AMS* 72(1), doi:10.1090/noti3041；Tao, arXiv:2608.16753；<https://mathstodon.xyz/@tao/117169040146193300>；<https://mathstodon.xyz/@tao/117395268130901862>；

<https://terrytao.wordpress.com/2025/11/05/mathematical-exploration-and-discovery-at-scale/>; Buzzard <https://xenaproject.wordpress.com/2026/10/01/to-grieve-or-not-to-grieve/>; Gowers <https://gowers.wordpress.com/2026/09/17/why-i-didnt-sign-the-fields-medallists-letter/>; <https://leidendeclaration.ai/>;
<https://terrytao.wordpress.com/2026/09/11/a-severe-misalignment-of-ai-in-mathematics/>;
<https://agmai.org/general-sep29/>; <https://terrytao.wordpress.com/2026/10/07/ahm-statement-on-openais-october-6-release-of-mathematical-documents/>; Schneider <https://terrytao.wordpress.com/2026/09/23/headlines-and-inside-stories-understanding-and-trust-in-ai-for-mathematics-science-and-engineering/>

17.7 各领域瓶颈总表

"AI 数学"指证明、形式化、符号推导 (A 类问题的加速); "AI 其他能力"指编程 agent、模拟与代理模型、自动实验、文献匹配、假设生成。高/中/低是相对判断 [推测], 引用时请连同最后一列的依据一起引用。括号里是展开讨论的章节。

领域	主瓶颈	AI 数学帮多少	AI 其他能力帮多少	一句话依据
理论计算机 / 算法 / 密码学 (§18)	数学本身 (证明、密码分析); 部署侧是标准化	高	高	交付物就是证明或算法, 有自动裁判。但要提防"银河算法" (§6); 密码部署要走多年标准流程 (案例 14)。
形式化验证 (§18)	写对 spec; 证明成本 (正在暴跌)	高	高	证明成本每年约降 10 倍 (曲线 ③), 瓶颈迁到"spec 写对没有" (B 类)。
纯数学 (Part I)	陈述与理解; 审稿与验证带宽	高 (对证明)	中 (文献匹配、形式化)	OpenAI 719 篇约 58% 没有形式化, 无专家公开确认。瓶颈已从"证不出来"变成"读不过来、信不过来"。
基础理论物理 (§19)	实验数据 (超出标准模型的新数据极少); "该算什么"	中	中	严格证明主要提升确定性 (规律 4); 符号计算 (散射振幅等) 有实际价值; 理论多、能裁决的实验少是老问题。
凝聚态 / 量子技术 (§18、§19)	材料与实验; 多体计算	低-中	中-高	拓扑量子比特卡在材料近 30 年 (案例 12); ML 势函数等计算工具帮助更直接; 量子纠错码设计属"数学筛选实验"。
天气 / 气候 (§19)	观测数据; 算力	低	高 (已证实)	ML 天气模型已进入业务运行, 靠 40 多年再分析数据和清晰的评分指标; 长期气候预测仍受云、气溶胶等过程理解限制。
化学 / 材料 (§19)	合成与表征通量; 数据质量; "可合成性"	低	中 (被高估过)	计算预测"稳定"不等于新颖、可合成、有用 (17.3)。

领域	主瓶颈	AI 数学帮多少	AI 其他能力帮多少	一句话依据
生物 / 医学 (§20)	机制数据；湿实验通量；临床试验 (I 期到获批 7.9%)；监管	低	中-高 (但受 Amdahl 限制)	AlphaFold 改变了结构生物学，但没有缩短临床试验。
神经科学 (§20)	测量 (同时记录的神经元太少、连接组太贵)；"该测什么"	低-中	中	果蝇全脑连接组 (FlyWire, <i>Nature</i> 2024, doi:10.1038/s41586-024-07558-y) 靠 ML 图像分割加人工校对完成，是 "AI 其他能力" 的典型。理论是 B 类问题。
AI / ML 理论 (§21)	B 类：不知道哪些数学陈述对实践重要	中	高	A 类引理 (如具体架构的 RLCT) 会被批量证明，但深度学习理论对实践的影响历来很弱；自动化实验和可解释性工具更直接。
经济学 / 社会科学 (§22)	因果识别所需的数据；人类实验的伦理与成本；制度采纳	低 (机制设计除外：中)	中	机制设计是 "数学即产品" 的少数分支 (案例 10)，但落地卡在立法；其余卡在数据和实验的社会成本。

三条横向结论 [推测]：

1. "AI 数学"帮助大的领域都有自动裁判 (证明检查器、测试、标准)，交付物是数字的。这正是 Amdahl 定律里 p 大的领域。
2. "AI 其他能力"在数据充足、评分清楚的领域已经证实有效 (天气、蛋白质结构)；在数据少、验收靠湿实验的领域常被高估 (材料、自动实验室)。
3. 所有领域最终都会撞上 "陈述 / spec / 该测什么" 这一层 (B 类)。这一层不是证明能解决的，也还没有被 AI 的其他能力明显加速。它是下一个瓶颈，也是 AI 安全与这里的交汇点：spec 写错了，证明越便宜，错得越快。

17.8 本节来源

历史案例、AI for science 实证、能力曲线和数学共同体观点的出处，已列在 17.1、17.3、17.4、17.6 各段末尾。这里列 17.2 的框架类来源。

- Bloom, Jones, Van Reenen & Webb 2020, "Are Ideas Getting Harder to Find?", *AER* 110(4):1104, doi:10.1257/aer.20180338
- BIO/Informa/QLS, *Clinical Development Success Rates 2011–2020* https://go.bio.org/rs/490-EHZ-999/images/ClinicalDevelopmentSuccessRates2011_2020.pdf
- Amodei 2024, "Machines of Loving Grace" <https://www.darioamodei.com/essay/machines-of-loving-grace>
- Aghion, Jones & Jones 2017, "Artificial Intelligence and Economic Growth", NBER w23928 <https://www.nber.org/papers/w23928>

- Davidson 2021, "Could Advanced AI Drive Explosive Economic Growth?"
<https://www.openphilanthropy.org/research/could-advanced-ai-drive-explosive-economic-growth/>
- Erdil & Besiroglu, "Explosive growth from AI automation: A review of the arguments",
arXiv:2309.11690; Erdil et al. 2025, "GATE", arXiv:2503.04941
- Erdil & Barnett 2025, "Most AI value will come from broad automation, not from R&D"
<https://epoch.ai/gradient-updates/most-ai-value-will-come-from-broad-automation-not-from-r-d>
- Acemoglu, "The Simple Macroeconomics of AI", NBER w32487
<https://www.nber.org/papers/w32487>
- Narayanan & Kapoor 2025, "AI as Normal Technology"
<https://knightcolumbia.org/content/ai-as-normal-technology>
- Kapoor & Narayanan 2025, "Could AI slow science?"
<https://citp.princeton.edu/news/2025/could-ai-slow-science-confronting-production-progress-paradox>
- Kapoor, Narayanan, Kokotajlo 等 2025, "Common Ground between AI 2027 & AI as Normal Technology" <https://asteriskmag.substack.com/p/common-ground-between-ai-2027-and>

未能核实的条目 (△): HTTPS 何时成为网页加载多数 (只给了年代); Isomorphic Labs 首个临床试验的推迟 (二手报道); NOAA 的 AI 模型基于 GraphCast 等说法 (二手来源); Kosmos 的独立评估 (未找到); co-scientist 结果可能从实验室早先论文泄漏的批评 (未核实); Hao 等的 *Nature* 正式 DOI; Microsoft 拓扑量子比特 2026-06 的 *Nature* 批评文 (转引自报道); Toner-Rodgers 论文的 44% / 39% (转引自报道); Erdős 问题"约 100 题"的精确数字; 费马大定理形式化内部成本"约 \$2,000"的口径。

18. 计算机、密码学与量子计算：证明便宜之后，信任栈怎么重建

标签: [已确立] 教科书级或多方复现; [近期发现] 2024–2026 年的新结果; [推测] 推断; △ 未能核实或只有二手来源。**能力曲线** (见 §17): ① METR 时间跨度, 中心情景 2027 年中约 150 小时; ② 可形式化开放问题单次解出率, 2027 年末约 18%、2028 年末约 45%; ③ 形式化证明成本约 \$0.023/行, 每年降到 1/10。**A 类:** 陈述清楚、缺证明; **B 类:** 连该证什么都不清楚。

在计算机科学里, 证明本身就是产品: 编译器的正确性证明、加密标准的安全论证、量子电路的资源估计, 直接决定真实系统能不能用。所以"AI 解决数学"在这里的一阶效应比在生物或材料领域大得多。但多数真实事故仍出在实现、规格和制度上。

18.0 先说结论

- 1. 网络安全的瓶颈已从"找漏洞"变成"修漏洞"，推动者是 AI 的编码能力，不是数学能力。
Anthropic 的 Glasswing 计划标出 6,202 个高危候选，已披露的约 530 个只有 75 个打上补丁 (2026-05) [近期发现]。跟得上的防御只有"证明某类漏洞不存在"；证明正在变便宜，新瓶颈是规格 (spec) 对不对和被信任的底座 (TCB) 有没有洞。
- 2. 密码学建立在未证明的猜想上，AI 数学会大规模审计它们。被纯数学攻破的标准候选不少：SIKE (2022, 单核约一小时)、Rainbow (2022, 笔记本一个周末)，以及 2025 年被推翻、一批 zkVM 参数依赖的"邻近间隙"猜想 [已确立/近期发现]。ML-KEM 2030 年前被实用经典破解的概率估计 $\leq 5\%$ [推测]；年轻的后量子签名和 ZK 参数猜想风险高得多。
- 3. Q-day 正在被数学提前。破 RSA-2048 所需物理比特从 2019 年约 2,000 万降到 2026 年不足 10 万 (qLDPC 架构) [近期发现]。资源估计是有自动裁判的 A 类问题，AI 会让这条线继续下降；硬件仍是主瓶颈。
- 4. "量子计算除了破密码和模拟量子系统还能做什么"，是数学瓶颈最纯粹的地方。实用的指数加速很少，"去量子化"不断把声称的加速打回原形；AI 驱动的经典模拟还在和量子计算争夺同一批应用。
- 5. "更快的算法"分成两个世界。渐近纪录 (ω 2026-08 借助 AlphaEvolve 降到 2.371177, §6 的 OpenAI 声称降到 9/4) 几乎不会让 GPU 变快。实用加速来自"AI 写代码 + 搜索 + 基准测试当裁判"，例如 AlphaEvolve 为 Google 持续回收 0.7% 的全球算力 [已确立]，靠的是 AI 的其他能力。
- 6. P vs NP 这类大问题受"壁垒定理"保护，是典型的 B 类，证出来实践也几乎不变。会改变世界的只有少数几类：单向函数无条件存在、格问题的量子算法，以及"什么能被高效审计"的不可能性定理 (例如可证明无法检测的模型后门)。
- 7. 与 AI 安全的三个连接：(a) AI 智能体的"盒子"本身是软件，可验证的隔离是 AI 控制 (AI control) 的物理底座；(b) ZK 和 FHE 能"验证但不泄露"，可作为 AI 治理基础设施，但和滥用监测有张力；(c) 密码分析能力应列入危险能力评测，主流框架目前似乎主要关注网络攻击操作 ([推测]，未系统核实)。

18.1 为什么选这些问题

四条标准相乘排序：影响规模；数学是不是瓶颈 (不是的话要说清真正的瓶颈)；有没有自动裁判 (证明检查器、电路模拟器、基准测试；有裁判的 A 类问题进展快)；与 AI 安全的关联。

#	问题	影响	数学是瓶颈吗	裁判	A/B	AI 安全连接
1	形式化验证 × 攻防	极高	曾经是，正在不是；规格和制度成新瓶颈	有	证明 A；规格 B	沙箱/AI 控制
2	后量子格密码	极高	对信心是；对事故不是	部分	改进攻击 A；新思路 B	密码分析算危险能力

#	问题	影响	数学是瓶颈吗	裁判	A/B	AI 安全连接
3	Q-day 资源估计	高	部分：数学是乘数，硬件是主瓶颈	有	A	危险数学的披露
4	新量子算法	中到高	是，最纯粹	弱	多数 B	格问题的量子攻击
5	FHE 与 ZK	中到高	一半：猜想是数学，常数是工程	有	证猜想 A	可验证的 AI 治理
6	算法发现	实用中，纪录低	纪录是；实用加速不是	有	A	AI 优化自己的训练栈
7	复杂性理论	直接低，基础高	是，但 B 类	弱	大问题 B；gadget A	审计不可能性；辩论

落选但值得一提：硬件验证、编译器验证（CompCert）、分布式协议验证（TLA+）并入问题 1；SAT/SMT/MIP 求解器主要靠工程，并入问题 6；对称密码（AES、SHA-3）安全余量大；量子密钥分发（QKD）的瓶颈是物理和部署；不可区分混淆（iO）离实用极远；AI 文本水印已有不可能性结果，归 §21。

18.2 问题 1：关键软件的形式化验证 × AI 时代的网络攻防

一句话：AI 让"找漏洞"几乎免费，唯一跟得上的防御是"证明没有这类漏洞"。证明也在变便宜，新瓶颈变成"证的到底是什么（规格）"和"我们信任了什么（TCB）"。

背景补课：测试是抽样，证明覆盖全部输入。看这个 C 函数：

```
int abs(int x) { return x < 0 ? -x : x; }
```

随机测试 1,000 个输入全部通过。但 `x = INT_MIN` 时 `-x` 溢出，返回一个负数；随机测试撞上它的概率是 $1/2^{32} \approx 2.3 \times 10^{-10}$ 。把规格写成"返回值 ≥ 0 "交给证明检查器，证明会卡在这一个输入上：要么修代码，要么在规格里加前提" $x \neq \text{INT_MIN}$ "。

形式化验证有三样东西：规格、实现、由一个很小的"内核"检查的证明（Lean、Isabelle、Coq/Rocq，见 §3）。你只需相信几千行的内核，不必相信写证明的人或 AI。*难的是规格：*排序的规格应是"输出有序，且是输入的一个排列"；只写"输出有序"，"永远返回空列表"也能通过证明。过去的代价很高：seL4 微内核约 8,700 行 C，配约 20 万行人工证明，约 25 年人[已确立]。

为什么重要：攻方已经工业化：DARPA AIxCC 决赛（2025-08）上，自动化系统找到 63 个植入漏洞中的 54 个，每个任务平均约 152 美元[近期发现]。守方跟不上：Glasswing 报告说现在"受限于我们能多快验证、披露和修补"[近期发现]。对 AI 安全，智能体的"盒子"就是软件：

Glasswing 的例子里有**内存安全语言写的**虚拟机监控器里的内存破坏漏洞，也有串联 4 个漏洞逃出浏览器沙箱。AI 控制方案默认盒子是牢的，可验证的隔离是这个假设的底座。

卡在哪：瓶颈是不是数学？ 证明劳动曾是主瓶颈，正在消失：按曲线 ③，seL4 的 20 万行证明约合 4,600 美元 token 费用，2027 年末约 200 美元 [模型]；10 个 AI 智能体已自主写出 Lean 版 zlib (lean-zip)，并证明"任何小于 1 GiB 的数据压缩再解压都等于原数据" [近期发现]。新瓶颈不是数学：(1) **规格**：对去掉证明的 lean-zip 做约 1 亿次执行的模糊测试，被证明的部分零内存问题，但没写定理的归档解析器有拒绝服务漏洞，**Lean 4 运行时本身有堆溢出** [近期发现]；(2) **TCB 与硬件模型**：Spectre 说明，相对指令集规格证明的"隔离"挡不住规格里没写的侧信道 [已确立]；(3) **存量代码与制度**：数十亿行 C/C++ 靠志愿者维护，换语言这种"笨办法"效果巨大，Rust 代码约每百万行 0.2 个内存安全漏洞，C/C++ 历史上约 1,000 个 [近期发现]；(4) **性能**：据二手报道，Adam Langley 让模型证明的 Lean 版 Zstd 解压器只有标准 zstd 约 1/10 的速度 △。判断：写证明是 A 类，正被快速攻克；写规格、划定 TCB、推动采用，是 B 类加制度问题。

AI 能做什么：AI 数学/证明：按规格写证明；代码改动后自动修复证明；证明新旧实现等价（如 C 翻译成 Rust）；仓库级基准 Vero 还让智能体**证明给定规格不可满足**，等于用机器审计规格。**AI 其他能力**：模糊测试、构造利用、写补丁；从 RFC 和测试里挖候选规格；大规模把 C 迁到 Rust。

如果解决：一阶影响：密码库、解析器、内核、虚拟机监控器、共识协议默认附带证明，其中的内存安全类和解析类漏洞接近归零，成本转到规格评审。TLA+ 写的分布式协议模型可以一路被证明细化到实际代码。

如果解决：二阶影响：(1) **攻防平衡是"先坏后好"的曲线** [推测]：2026–2028 年攻方有利，修补按人类速度；关键组件被证明后，攻击面迁到规格错误、配置、供应链、社会工程、硬件侧信道和无法验证的 ML 组件。(2) **软件责任法律化**：欧盟《网络弹性法案》(Regulation (EU) 2024/2847) 已引入数字产品安全责任 [已确立]，"有没有证明"可能成为尽职调查标准 [推测]。(3) **AI 安全**：写证明的 AI 也能写**规格**，一个看似合理、暗留后门的规格很难被人类发现，"谁来审规格"会变成对齐问题；证明检查器（陈述固定、禁用 **sorry** 和新公理）又是**很难被 reward hacking 的奖励信号**，会加速 AI 编码能力，本身是双重用途的。

时间判断：乐观：2027 年中（曲线 ① 约 150 小时，约一个月）AI 能自主把 1–5 万行的 C 库翻译成带证明的版本。中心：2027–2028 年证明劳动不再是成本主体（曲线 ③），规格评审仍按人类速度；到 2030 年带证明的代码只覆盖"关键小内核"，占代码总量不到 1% [推测]；攻方有利的窗口持续到约 2028 年。悲观：规格、性能、维护者带宽同时卡住，2030 年仍只是少数大厂的内部实践。

反方观点与不确定性：多数入侵来自凭证、钓鱼和错误配置（Verizon DBIR 2024 称约 68% 涉及"人为因素" △ 凭记忆），证明帮不上。Glasswing 的数字主要来自 Anthropic 自己的报告，独立评估有限。

信号：Glasswing 后续报告的修补率；CVE 中内存安全类的占比；核心开源项目要求"附带证明的 PR"；第一起"规格本身有后门"的公开事件。

来源：seL4 统计 <https://trustworthy.systems/projects/OLD/l4.verified/numbers> ； DARPA AlxCC <https://www.darpa.mil/news/2025/aixcc-results> ； Glasswing <https://www.anthropic.com/news/glasswing-initial-update> ； arXiv:2608.13522 (Vero)、1801.01203 (Spectre)；lean-zip <https://kirancodes.me/posts/log-who-watches-the-watchers.html> ； Rust in Android <https://blog.google/security/rust-in-android-move-fast-fix-things/> ； Langley 二手摘要 <https://www.remio.ai/post/adam-langley-says-lean-proof-automation-is-here-the-hard-part-just-moved> 。

18.3 问题 2：后量子格密码 ML-KEM—AI 会找到破解，还是给出信心？

一句话：互联网正把密钥交换迁到 ML-KEM，而它的安全依赖"带误差学习问题（LWE）很难"这个**猜想**。AI 数学会以前所未有的规模审计它，结果可能是破解（灾难性，但有混合方案兜底）、更高的信心，或一点点削减安全位数。

背景补课：Shor 量子算法能快速破解 RSA 和椭圆曲线密码（ECC），所以需要新难题。格 (*lattice*)：平面上取基 $b_1=(2,0)$ 、 $b_2=(1,2)$ ，所有整数组合构成规则的点阵。同一个格也能用"差"的基描述，比如 b_1 和 $b_2'=(11,2)$ ($= b_2 + 5 \cdot b_1$)，点完全一样，但两个向量又长又几乎平行。**最短向量问题 (SVP)**：只给差基，找最短的非零格向量。二维时很快；几百维时，已知最好的算法都要指数时间。好基就是"陷门"。

LWE 是带噪声的线性方程组。模 17 下设秘密 $s = (3, 5)$ ：

a	a·s mod 17	噪声 e	公开值 b
(1, 2)	13	+1	14
(4, 1)	0	-1	16
(2, 7)	7	0	7

没有噪声，高斯消元立刻解出 s ；有了 ± 1 的噪声，每条方程都"差一点"。二维时枚举 $17^2 = 289$ 个候选即可，ML-KEM-768 的有效维度却是 768、模数 3329 (FIPS 203)，按 Core-SVP 估计约 182 位经典安全 $\triangle$ (凭记忆)。**整个方案的安全都压在那点噪声上**。Regev (2005) 证明了"解随机 LWE $\Rightarrow$ 解最坏情况格问题"，但归约不紧，定不了具体参数；参数靠"已知最好攻击要花多少"来定。

历史上的破解是本卡最重要的背景。**SIKE** (NIST 第四轮候选) 2022-07 被 Castryck–Decru 用 1997 年的一个纯数学定理攻破，单核约一小时 [已确立]。**Rainbow** (第三轮决赛签名)：Beullens 2022 年的论文标题就是"笔记本上一个周末破解" [已确立]。**Chen 2024** 声称 LWE 有多项式时间量子算法，约一周后被找到错误、撤回 [已确立]。**Luo 2026** 的预印本声称破解 ML-KEM，已被非正式指出维度错误，**目前不构成破解** $\triangle$ 。

为什么重要：2025-10 末，Cloudflare 收到的人类 TLS 流量过半已用混合密钥交换 X25519MLKEM768 [近期发现]。"先存后解" (harvest now, decrypt later) 意味着保密期 10–30 年的数据**现在**就要回答 ML-KEM 安不安全。签名更麻烦：证书链全换成 ML-DSA-44，TLS 握手约多 15 kB，而更小的方案依赖**更年轻、更少被审计的数学**，这正是 AI 密码分析最可能先产生影响的地方。

卡在哪：瓶颈是不是数学？ 对**信心**，数学就是瓶颈：没人能证明 LWE 难，信心只来自"很多聪明人试过都失败了"，而专家注意力稀缺。对**真实事故**，瓶颈是实现：KyberSlash 发现包括官方参考代码在内的多个实现有依赖秘密的除法时序，"几分钟内可靠恢复密钥" [已确立]。对**迁移速度**，瓶颈是工程和制度：Cloudflare 的源站 2025 年只有 3.7% 支持后量子密钥交换。

AI 能做什么：*AI 数学/证明：*系统性延伸已知攻击家族（如把秩 1 理想格上的攻击推向秩 2、3 的模格），方向明确，是 A 类；当规模化的裁判，把 Chen、Luo 式的声称破解形式化，几天内找出错误；审计攻击成本估算本身（Ducas–Pulles 2023 指出过对偶攻击的启发式假设有问题 [已确立]）。*AI 其他能力：*Meta 的 SALSA 系列用 Transformer 恢复 LWE 秘密，但只对稀疏或很小的秘密有效，不是 ML-KEM 的参数 [近期发现]；大规模检查实现的常数时间性质。

如果解决：一阶影响：*情形 A（概率低）：*AI 找到 ML-KEM 的实用经典破解。混合方案退回 X25519 的安全性，但"先存后解"的流量对未来的量子攻击者全部暴露；只用 ML-KEM 的部署（如 CNSA 2.0 路线 Δ ）受灾难性冲击，全球要紧急切到编码类方案（NIST 2025-03 选了 HQC 做备份）。*情形 B：*搜索无果，信心提高，也许能把默认参数从 768 降到 512。*情形 C（最可能）：*每篇论文削几位，累积起来逼着参数上调。

如果解决：二阶影响：能检查 AI 密码分析的人类专家越来越少，对标准的信任会越来越依赖**可被机器检查的论证**。拥有私有破解能力的国家不会公开，"危险数学结果怎么披露"需要新规范（问题 3）。AI 安全方面：密码分析能力应成为一类危险能力评测 [推测]；模型权重的保护以密码为前提，密码出问题，AI 治理的信任链会断在最底层；AI 生成的错误"破解"大量涌现，会对专家注意力形成"拒绝服务攻击"。

时间判断：AI 参与削减安全位数的论文（A 类，目标函数明确，跟随曲线 $\textcircled{2}$ ）中心情景 **2027 年**开始常见。至少一个 NIST 附加签名候选因 AI 辅助分析被显著削弱或攻破：中心 **2027–2029 年** [推测]。ML-KEM-768 被实用经典破解：**到 2030 年 $\leq 5\%$** [推测]；"LWE 是否难"是研究纲领而非短证明，属 B 类，不在曲线 $\textcircled{2}$ 覆盖范围。

反方观点与不确定性：格问题从 LLL（1982）算起已被研究 40 多年，AI 也许只会把旧思路做得更快。Bernstein（力主混合方案）则认为风险被系统性低估，因为"已知攻击"只是攻击面的一小部分。

信号：ePrint 上致谢 AI 的密码分析论文；lattice-estimator 的估算被下调；前沿 AI 公司的安全框架加入"密码分析辅助 (cryptanalytic uplift)"评测。

来源：ePrint 2022/975 (SIKE)、2022/214 (Rainbow)、2024/555 (Chen)、2024/1049 (KyberSlash)、2025/1002 (SALSA 对比)、2023/302 (Ducas–Pulles)；Bernstein <https://blog.cr.yp.to/20260630-risk.html>；Luo 分析 $\triangle$ <https://postquantum.com/security-pqc/luo-ml-kem-quantum-attack-analysis/>；Cloudflare <https://blog.cloudflare.com/pq-2025/>；FIPS 203 <https://csrc.nist.gov/pubs/fips/203/final>。

18.4 问题 3：Q-day 的倒计时——破 RSA/ECC 要多少量子比特

一句话：Q-day 取决于两个数：硬件进步的速度，以及"破解要多少比特、多少门"。第二个数完全由数学（算法、纠错码、架构）决定，7 年里降了约 200 倍。

背景补课：物理量子比特每个门约 0.1% 出错，破 RSA-2048 要数十亿个门，每步出错率得压到约 10^{-12} 以下。办法是**纠错**：用很多物理比特编码一个"逻辑比特"。经典类比是重复码：每个比特发三遍、多数表决，单份翻转概率 1% 时表决出错约 $3p^2 = 0.03\%$ 。量子版最常用**表面码 (surface code)**：在 $d \times d$ 网格上反复测量"校验子"，由经典计算机实时推断哪里出错（**解码**）。距离 d 每加 2，逻辑错误率除以一个**抑制因子 Λ** 。

手算数量级。Google Willow 的 $\Lambda = 2.14$ [近期发现]。照此要再压低 10^9 倍，需要 $\log(10^9)/\log(2.14) \approx 27$ 次"+2"，即 $d \approx 61$ ，每个逻辑比特约 $2d^2 \approx 7,400$ 个物理比特；若 $\Lambda = 10$ ，只需 9 次， $d \approx 25$ ，约 1,250 个。资源估计常用的"均匀 0.1% 门错误"大约对应 $\Lambda \approx 10$ [估算]，今天的硬件离这个假设还差约 5 倍。更好的码 (qLDPC) 省得多：IBM 的"gross code"用 288 个物理比特保护 12 个逻辑比特，表面码要近 3,000 个 [已确立]。

年份	目标	物理比特	时间	来源
2019	RSA-2048	~2,000 万	~8 小时	Gidney & Ekerå
2025	RSA-2048	<100 万	<1 周	Gidney，硬件假设不变
2026-02	RSA-2048	<10 万	摘要未给	Pinnacle 架构 (qLDPC)
2026-03	ECC P-256	<50 万 (超导)	几分钟	Google: <1,200 逻辑比特、约 9,000 万 Toffoli
2026-03	ECC P-256	~1 万–2.6 万 (中性原子)	几天	Cain et al.

2025 年那次下降**完全**来自算法和架构（近似剩余数算术、"轭合"表面码、"魔术态培育"）[近期发现]。**椭圆曲线比 RSA 更早暴露**，而 TLS 签名、比特币、以太坊用的都是 ECC。

为什么重要：Mosca 不等式：数据要保密 x 年，迁移要 y 年，Q-day 在 z 年后，**只要 $x + y > z$ ，现在就已经晚了**。Google 发布 ECC 估计时把自身迁移目标定在 2029 年，并指出快时钟的超导机器能在比特币交易确认前，从内存池里暴露的公钥算出私钥 [近期发现]。

卡在哪：瓶颈是不是数学？主瓶颈是硬件，数学是乘数。 "10 万比特以 0.1% 错误率稳定运行几天，并做到微秒级实时解码"还远没实现。IBM 计划 2029 年交付 Starling (200 个逻辑比特、1 亿次逻辑操作)；ECC-256 需约 1 亿个 Toffoli、约 1,200 个逻辑比特，**门数已同量级，逻辑比特还差约 6 倍** [估算]。**解码是被低估的瓶颈：**AlphaQubit 更准，但 Google 承认它还"太慢，跟不上实时" [已确立]。乘数有多大 [推测]：如果可用比特数每年翻一番 Δ (粗假设)，资源需求每降 10 倍，Q-day 提前约 3.3 年。

AI 能做什么：AI 数学/证明：资源估计是典型 A 类，目标函数清楚 (Toffoli 数、逻辑比特数)，有自动裁判 (稳定子模拟器)：搜索可实现的新 qLDPC 码族、优化模算术电路、设计更省的魔态协议，AlphaEvolve 式"搜索 + 评估器"正好对口。AI 其他能力：神经网络解码器、自动校准、芯片设计，直接缓解硬件瓶颈。

如果解决：一阶影响：Q-day 估计提前、区间收窄，政策制定者拿到更硬的数字；容错机器也更早可用于化学和材料模拟 (§19)。

如果解决：二阶影响："算法性 Q-day"：日期可能由一篇论文而不是一台机器决定，迁移规划应按"2030 年前资源再降 10 倍"做压力测试 [推测]。**危险数学的披露规范：**Google 不公开 ECC 攻击电路，而是附上 SP1 zkVM + Groth16 生成的零知识证明，让第三方确认"这样的电路存在、资源数正确"；讽刺的是 Groth16 用的曲线本身也怕量子攻击 [近期发现]。这个范式可以移植到 AI 发现的其他危险结果，比如漏洞利用链和生物序列。**加密货币治理：**公钥已暴露的"沉睡币"该冻结还是放任。

时间判断：资源估计 (A 类) 中心情景 2028 年前再降 2–10 倍 [推测] (曲线 ②)。能破 ECC-256 的机器 [推测]：乐观 2030–2032 年，中心 2033–2036 年，悲观 2040 年以后，依据是 IBM 2029 年路线图与 ECC 资源大致同量级，以及 Google 2029 年迁移目标暗示的风险判断；这一项主要看硬件，和能力曲线关系弱。RSA-2048 大约晚几年 (二手 Δ)。

反方观点与不确定性：硬件可能卡在制冷、布线、良率和相关噪声 (宇宙射线、泄漏) 上，而资源估计都假设噪声"均匀、独立"。少数学者 (如 Gil Kalai) 认为噪声从根本上阻止规模化，尚未被实验否定。

信号： $\Lambda \geq 4$ ；距离 ≥ 11 的实时解码；1,000 个以上逻辑比特；资源估计再降 10 倍。值得警惕的是某大厂突然停止发表资源估计。

来源：arXiv:1905.09749、2505.15917 (Gidney)、2602.11457 (Pinnacle)、2603.28846 (Google ECDLP)、2603.28627 (Cain et al.)、2408.13687 (Willow)、2308.07915 (gross code)；Google 披露博客 <https://research.google/blog/safeguarding-cryptocurrency-by-disclosing-quantum-vulnerabilities-responsibly/>；AlphaQubit <https://blog.google/technology/google-deepmind/alphaqubit-quantum-error-correction/>；IBM Starling <https://newsroom.ibm.com/2025-06-10-IBM-Sets-the-Course-to-Build-Worlds-First-Large-Scale,-Fault-Tolerant-Quantum-Computer-at-New-IBM-Quantum-Data-Center>；TQI 综述 (含 ZK 披露细节) <https://thequantuminsider.com/2026/03/31/q->

day-just-got-closer-three-papers-in-three-months-are-rewriting-the-quantum-threat-timeline/。

18.5 问题 4：新量子算法与可证明的量子优势（简卡）

量子加速来自振幅的**干涉**，像降噪耳机：让错误答案的波相互抵消。这要求问题有**结构**（如 Shor 利用的周期性）；无结构搜索只有 Grover 的平方加速（ 10^{12} 步变 10^6 步），而每步逻辑操作背着纠错开销，所以平方加速在容错时代多半用不上 [已确立]。数学也会摧毁加速：2018 年 18 岁的 Ewin Tang 用经典算法把量子推荐系统的指数加速打回原形（"去量子化"）[已确立]；Lee 等人的结论是"在整个化学空间上，尚未找到基态能量计算存在指数优势的证据" [已确立]。

数学是瓶颈，而且是本领域最纯粹的，多数属 B 类：连"该在哪类问题上找"都不清楚，经典基线（张量网络、神经网络量子态）还在抬高门槛。AI 数学已经参与：Aaronson 和 Witteveen（2025）证明 QMA 黑盒放大的极限，关键一步是 GPT-5 提出的一个函数 [近期发现]。反直觉的是 AI 的其他能力：AI 驱动的经典模拟正在抢量子计算的化学和材料应用，AI 越强，量子计算的"杀手级应用"可能越少 [推测] (§19)。

时间：具体的 A 类证明现在就在发生；主要由 AI 发现的全新指数加速家族，2030 年前约 15–30% [推测]，不能套曲线 ②。**格问题（LWE）的高效量子算法 2030 年前 <5% [推测]**，但**影响权重最高**：一旦成功，问题 2 的整个后量子迁移要推倒重来。**来源**：Tang arXiv:1807.04271；量子化学 arXiv:2208.02199；Aaronson & Witteveen arXiv:2509.21131。

18.6 问题 5：FHE 与零知识证明——让"在密文上计算"和"可验证计算"变便宜

一句话：全同态加密（FHE）能不解密就对数据做计算，零知识证明（ZK）能证明"计算做对了"而不泄露输入。两者数学上都已存在，但开销是明文计算的数千到数千万倍（量级估计 Δ ），效率一半靠数学、一半靠工程。它们是"可验证的 AI 治理"最有希望的工具。

背景补课：FHE 像**手套箱**：隔着箱壁操作，看不见里面。玩具例子： $\text{Enc}(m) = m + k$ ， $\text{Enc}(3) + \text{Enc}(4) = 7 + 2k$ ，持有 k 的人减去 $2k$ 得 7，服务器做了加法却不知道 3 和 4。真正的 FHE 建在 LWE 上，**和 ML-KEM 依赖同一个难题**；运算会让噪声增长，要定期"自举（bootstrapping）"刷新，这是最贵的一步。ZK 像**随机抽查**：证明者把计算编码成多项式。两个不同的 d 次多项式最多在 d 个点上相等（Schwartz–Zippel 引理），验证者在 2^{64} 大小的域里随机抽一个点，被骗概率不超过 $d/2^{64}$ ； $d = 10^6$ 时约 5×10^{-14} 。

可靠性依赖一个猜想。FRI 一类协议依赖 Reed–Solomon 码的"**邻近间隙（proximity gaps）**"：一批向量里只要有一个离合法码字很远，它们的随机线性组合几乎总是也离得很远。许多系统按"这个性质一直成立到容量极限"的**猜想**设参数，换取更小的证明。2025-11，Crites 和 Stewart 证明这类猜想**是错的** [近期发现]；据社区汇总，二十来个 zkVM 都假设过它 Δ 。

为什么重要：SP1 Hypercube 用约 160 块 RTX 4090 在 12 秒内证明了 93% 的以太坊主网区块，进步主要来自工程；zkLLM 能在 15 分钟内为 130 亿参数模型的一次推理生成小于 200 kB 的证明 [近期发现]。Apple 已用 FHE 做私密查询 [已确立]。

卡在哪：瓶颈是不是数学？ 一半一半。数学决定参数大小（可靠性定理）、带来新协议和更便宜的自举；工程负责硬件加速和内存带宽。还有规格问题：一篇 SoK 分析了 141 个真实 SNARK 漏洞，大量出在“电路约束写少了（underconstrained）” Δ ，和问题 1 同构。

AI 能做什么：AI 数学/证明：邻近间隙是**陈述清楚、有自动裁判**的 A 类问题。以太坊基金会 2026-08 推出 better.codes 挑战：问题在 Lean 4 里形式化，目标是把可证明的可靠性下界推到 128 位，并明确邀请“带上你自己的 AI 智能体” [近期发现]。这是“AI 数学直接改变工业参数”最干净的试验场。**AI 其他能力：**写 GPU 内核、把程序编译成电路、检查约束是否完备。

如果解决：一阶影响：通用 ZK 开销降到 10–100 倍，就有了“可验证的云”；FHE 在特定负载上降到 10–100 倍，医疗和金融数据就能不出域做推理。

如果解决：二阶影响：*可验证的 AI 治理* [推测]：证明“这段输出来自权重哈希为 H 的模型”、“模型通过了评测集 S”（不泄露权重）、“推理确实经过了安全过滤器”，逻辑和军控核查一样：**验证，但不公开**；证明“训练用了多少算力”则难得多，目前没有可行方案。*隐私和监管的张力：*FHE 私密推理让提供方**看不到**用户在问什么，滥用监测就失效，越隐私越难防滥用 [推测]。*金融的数学风险：*数十亿美元的 rollup 资产部分依赖未证明的编码理论猜想，AI 会让“猜想驱动的参数”变成“证明驱动的参数”。

时间判断：邻近间隙的可证明界或 better.codes 达到 128 位：A 类、有 Lean 裁判，中心情景 2027–2028 年有实质进展（曲线 ②） [推测]。以太坊区块实时证明：工程上已基本达成。前沿规模 LLM 的 FHE 推理开销降到 100 倍以内：中心情景 2030 年后 [推测]，取决于硬件，基本与 AI 数学无关。

反方观点与不确定性：可信执行环境（TEE，如 H100 的机密计算模式）便宜得多，可能取代 FHE/ZK 的大部分用途，代价是信任硬件厂商并承受侧信道风险。

信号：better.codes 排行榜上的可证明安全位数；前沿规模模型能否生成推理证明；监管文件是否把“密码学证明”列为合规证据。

来源：ePrint 2025/2046、2026/782（邻近间隙反例）；better.codes <https://blog.ethereum.org/2026/08/20/better-codes-challenge>；SP1 Hypercube <https://blog.succinct.xyz/sp1-hypercube/>；Apple HE <https://machinelearning.apple.com/research/homomorphic-encryption>；arXiv:2404.16109 (zkLLM)、2402.15293 (SNARK 漏洞 SoK)。

18.7 问题 6：算法发现—渐近纪录与 GPU 上真实的加速（简卡）

大 O 记号会隐藏常数；渐近更快、但常数大到宇宙尺度的算法叫"银河算法（galactic algorithm）"。矩阵乘法指数 ω 2026-08 借助 AlphaEvolve 降到 **2.371177** [近期发现]。手算它值多少：指数降 0.000162， $n = 10^5$ 时 $n^{0.000162} \approx 1.0019$ ，只省 0.19% 的运算，而且激光法算法根本没法实现。§6 的 OpenAI 声称 $\omega \leq 9/4$ 步子大得多，但同样是存在性证明、同样是银河算法，§6.10.2 已说明它对 GPU 和 LLM 训练没有直接影响：GPU 在张量核心上跑的仍是 n^3 算法。离实用近的是**固定小尺寸**的分解（AlphaEvolve 的 4×4 复矩阵 48 次乘法，后续论文尝试"带入实践"，但摘要里没有实测加速）。最短路 2025 年首次打破排序壁垒，但 $n = 10^9$ 时理论上只比 Dijkstra 快约 3 倍，很可能被常数和缓存吃掉 [近期发现]。

渐近纪录的瓶颈是数学，实用加速的瓶颈不是，而是对硬件（内存层次、带宽）的理解、可靠的基准测试和正确性检查。实用加速来自 AI 的其他能力，"写代码 + 进化搜索 + 基准当裁判"：AlphaEvolve 的一条 Borg 调度规则持续回收 Google 全球算力的 0.7%，Gemini 的一个矩阵乘法内核提速 23%、训练时间减少约 1% [已确立]。AI 写的高性能代码有钻评测空子的风险（2025 年的相关事件 $\triangle$ 凭记忆），所以 AI 数学在这里最有用的一项是**证明优化后的内核与参考实现等价**。

二阶影响：让 Gemini 训练快 1% 是 **AI 优化 AI 自己的训练栈**，递归自我改进最朴素、已经发生的形式；算法效率进步会削弱以算力为门槛的监管 [推测] (§22)。时间：内核级优化已在发生，编译器或调度系统级任务中心情景约 2027 年可行（曲线 ①）；渐近纪录 2026–2028 年会有大量 AI 参与的小幅刷新（曲线 ②）。**来源**：AlphaEvolve
<https://deepmind.google/discover/blog/alphaevolve-a-gemini-powered-coding-agent-for-designing-advanced-algorithms/>；arXiv:2608.16884 ($\omega < 2.371177$)、2506.13242 与 2609.12027 (4×4)、2504.17033（最短路）。

18.8 问题 7：复杂性理论—哪些证明会改变世界，哪些不会

一句话：P vs NP 一类的大问题被"壁垒定理"挡着，属 B 类；AI 已能产出 A 类的复杂性结果。少数目标定理会改变密码学和 AI 安全的根基，多数不改变任何实践。

背景补课：P 是能快速**求解**的问题，NP 是能快速**验证**解的问题（数独：检查填好的盘面很容易，推广到 $n^2 \times n^2$ 后求解是 NP 完全的）。为什么**证明了 $P \neq NP$ 也帮不了实践**： $P \neq NP$ 是"**最坏情况下难**"，密码学需要"**平均情况下难**"加上单向函数存在。用锁打比方：最坏情况难，是"存在某些人开不了这把锁"；平均情况难，是"随便找来的人都开不了"，只有后者能保护数据。Liu 和 Pass（2020）证明单向函数存在**当且仅当**有时间限制的柯尔莫哥洛夫复杂度在平均意义上有一定难度 [已确立]。

壁垒。相对化、自然证明（Razborov–Rudich 1997）、代数化三个定理证明了某几类技巧注定证不出 $P \neq NP$ [已确立]。最妙的是自然证明：**如果强伪随机函数存在（也就是密码学可行），"自然"的方法就证不出电路下界**；密码学的存在本身，就是证明难度如此之难的原因。

对显式布尔函数，已知最好的电路下界只有约 $3.1n$ （线性），而大家相信真实下界是指数级的 Δ 。

为什么重要：不同结果的实践影响差别极大：

结果	实践影响
证明 $P \neq NP$	几乎没有：确认已有信念，价值在新技巧
$P = NP$ 且有实用算法	文明级，但极不可能
单向函数无条件存在	密码学有了无条件地基，实际方案仍依赖具体假设
$BPP = P$ 、证明或推翻 UGC	小：澄清哪些近似算法最优（UGC 见 §7）
"什么能被高效审计"的不可能性定理	对 AI 安全影响大

最后一行的例子：Goldwasser 等人（2022）证明，可以在模型里植入**任何计算受限的观察者都检测不到的后门**：基于数字签名的构造在黑盒下不可检测，对随机 ReLU 网络等模型白盒下也不可检测 [已确立]。所以**仅凭检查权重，原则上无法排除所有后门**，安全保证必须部分依赖训练过程的来源证明（连回问题 5）。另一条根：辩论（AI safety via debate）的理论动机正是 $IP = PSPACE$ ，即弱验证者通过交互能检验强证明者；刻画"计算受限的人类评审何时仍然可靠"，就是在划定可扩展监督的边界（§21）。

卡在哪：瓶颈是不是数学？ 是纯数学，大问题属 B 类：已知技巧被证明不够用，需要全新思路。算力只在搜索有限结构（gadget、小电路）时有用。

AI 能做什么：*AI 数学/证明*：已产出 A 类结果。Nagda、Raghavan 和 Thakurta（2025）用 AlphaEvolve 构造 gadget，证明"MAX-4-CUT 近似到 0.987 以内是 NP 难的"（前纪录 0.9883）[近期发现]。AI 还能把复杂性理论形式化（Lean 里的复杂性库很薄，是基础设施缺口）。*AI 其他能力*：穷举小函数的最小电路、生成猜想。

如果解决：一阶影响：若 AI 找到绕过壁垒的新技巧，几乎一定会外溢到密码学（新构造或新攻击）和学习理论。

如果解决：二阶影响：复杂性理论会成为**理解 AI 本身**的语言。"验证比生成容易"是辩论、可扩展监督、"AI 写证明、内核检查"这整套安全范式的根基；一旦有定理揭示验证也很难的情形，这些方案就要重新设计。不可能性定理（后门不可检测、水印可去除）会把 AI 治理从"检测"推向"来源证明和过程控制"。

时间判断：gadget 和近似界（A 类）现在就在发生，2026–2028 年大量出现（曲线 ②）。关于 AI 审计和验证的新不可能性/可能性定理，中心情景 2027–2029 年会有一批由 AI 参与证明 [推测]。P vs NP、单向函数无条件存在：2035 年前概率都低于 2% [推测]，它们不在曲线 ② 覆盖的"可形式化、形态已知"的问题池里。

反方观点与不确定性：AI 可能找到人类想不到的"外星式"技巧，而壁垒只排除了**某几类**技巧；也可能这些大问题独立于标准公理。

信号：FOCS/STOC 论文中致谢 AI 的比例；Lean 复杂性库的增长；显式函数的电路下界突破线性。

来源：arXiv:2509.18057 (Nagda 等)、2009.11514 (Liu–Pass)、2204.06974 (不可检测后门)、1805.00899 (debate)；Razborov & Rudich, JCSS 1997。

18.9 本领域的二阶效应

1. "证明便宜，陈述昂贵"在七个问题里反复出现，只是每次换了个名字。

问题	便宜的部分（A 类）	昂贵的部分（B 类）
1 形式化验证	写证明	写规格、划定 TCB
2 格密码	改进已有攻击、形式化归约	安全模型漏掉的东西（时序、实现）
3 Q-day	优化电路和码	硬件，以及真实的噪声模型
4 量子算法	证明下界、检验具体加速	该在哪类问题上找
5 FHE/ZK	证明或推翻邻近间隙	电路约束有没有写全
6 算法	刷新渐近界	什么才算"真实的快"
7 复杂性	构造 gadget	绕过壁垒的新思路

2. 不对称的速度是本领域最危险的动态。 找漏洞快、修漏洞慢；发现攻击快、迁移标准慢；AI 生成"破解声明"快、专家核查慢；资源估计下降快、硬件慢。所以 2026–2029 年很可能是一个**过渡期的脆弱窗口** [推测]：攻方先吃到 AI 的红利，守方的红利（验证过的重写、后量子迁移、证明驱动的参数）要等制度跟上。

3. 信任栈会在机器可检查的产物上重建。 底层是验证过的密码库和内核，中间是后量子密钥交换和更小的签名，上层是 ZK 证明的计算。每一层都有"谁来检查检查者"的问题：lean-zip 里的 Lean 运行时 bug、Groth16 本身怕量子，都是提醒。

4. 数学结果开始需要"负责任披露"。 Google 用 ZK 证明披露量子攻击估计，Anthropic 先公布漏洞细节的哈希、修复后再公开，这两种做法会成为 AI 发现危险结果时的标准动作 [推测]。

5. 与 AI 安全的连接汇总。 可验证的沙箱（问题 1）；密码分析和漏洞挖掘进入危险能力评测（问题 1、2）；"验证但不公开"的治理工具，及其与滥用监测的张力（问题 5）；不可检测后门给模型审计设上限（问题 7）；算法效率削弱以算力为门槛的监管（问题 6）；证明检查器作为难以 hack 的奖励信号，加速 AI 编码能力（问题 1）。

6. 与其他领域的连接。 量子计算与 AI 驱动的经典模拟争夺同一批应用 (§19)；加密货币的安全依赖编码理论猜想和 ECC 的寿命；软件责任走向法律化 (§22)；私有的密码分析和量子能力是地缘政治上的不对称武器。神经科学的类比 [推测，非严格对应]：大脑用较慢的前额叶控制约束快速联想；AI 时代的计算机安全也在走向"强大但不可信的生成器 + 小而可信的检查器"。

18.10 本节来源

完整出处在各问题末尾的 **来源** 行。arXiv 编号 → <https://arxiv.org/abs/<编号>>，ePrint 编号 → <https://eprint.iacr.org/<编号>>。

未能核实或凭记忆的内容 (△)： Core-SVP 安全位数；RSA-2048 相对 ECC 的资源倍数 (二手)；FHE 开销量级；SNARK 漏洞中电路层的占比；zkVM 依赖邻近间隙猜想的数量；电路下界 $3.1n$ (Li-Yang, STOC 2022)；Verizon DBIR 的 68%；CNSA 2.0 只用 ML-KEM 的细节；Langley 实验的细节 (二手)；AI 生成 CUDA 内核夸大加速的事件；"可用比特数每年翻一番"的假设。

PART II · 前瞻 · 物理

19. 物理、化学与材料：方程早就知道，难在算不动、测不准、做不出来

标签：[已确立] 公认结果；[近期发现] 2024–2026 的新结果；[推测] 推断；△ 未能核实或有争议。时间判断对接 §17 的三条曲线：**曲线①** METR 任务时长 (中心：2027 年中约 150 h，2027 末约 400 h)；**曲线②** 可形式化开放问题的单次解出率 (中心：2027 末约 18%，2028 末约 45%，2030 末约 77%)；**曲线③** 形式化证明成本 (每年降约 10 倍)。**A 类** = 陈述清楚、缺证明；**B 类** = 连该证什么都不清楚。问题 4、6、8 是短卡。

19.0 先说结论

- **方程大多早就知道了。** Dirac 1929 年就说，化学所需的物理定律"已经完全知道"，只是方程解不出来 [已确立]。难处在**算不动** (多电子方程的代价指数增长)、**测不准** (合成和表征有歧义)、**做不出来** (从实验室到工程)。所以 AI 数学在这里主要通过**算法**起作用，而不是通过**定理**。
- **能改变物理方向的数学只有三种：**不可能定理 (如 Schuch–Verstraete 之于 DFT)、存在性结果与反例 (如 2026-09 的 Grad 猜想反例)、计算机辅助证明 (如 Euler 爆破)。其余大多是**模型健康证明**，确认物理学家早已相信的事。
- **数学物理的 A 类清单正被批量清扫。** OpenAI 这批稿件里约有 25 个数学物理家族 (二手统计 △)，声称解决了 Anderson 扩展态、Heisenberg 铁磁体自发磁化、Haldane 能隙、硬球

BEC，以及 §11 的受迫 NS、§12 的 Vlasov–Maxwell，均未评审。判断 [推测]：这类问题 2027–2028 年会基本扫完，却几乎不改变任何实验或工程。

- **影响大的问题都卡在数学之外**：电子结构、高温超导、湍流闭合、聚变控制、云反馈。起作用的是 AI 的**其他能力**：神经网络泛函、ML 原子势、可微模拟器、强化学习控制（已在 TCV、DIII-D 装置上实测）、学习型天气模型（ECMWF 的 AIFS 2025-02 已业务化）、自主实验室。
- **候选便宜，验证贵；AI 加速多快，由裁判多快决定**。GNoME 预测出约 38 万个稳定晶体，外部只合成了 736 个，这和数学里"证明便宜、审核陈述贵"是同一种瓶颈迁移。天气每天打分，已被 AI 改写；气候几十年才打一次分，进展慢。
- **能源影响到得慢**。从实验室到电网通常要 10–20 年。2030 年前最可能落地的只有：天气预报（已经发生）、电池和催化剂的渐进改良、聚变装置的控制与设计加速。
- **对 AI 安全**：物理和化学有自动裁判，会是 AI 自主科研最先跑起来、最先拿到物理执行权限的地方，并形成"AI → 能源、芯片、材料 → 更多算力"的反馈环；化学的双用途风险最直接；规格博弈有现成样本（受迫 NS；DFT 泛函能量越拟越准、密度却越来越偏）。

19.1 为什么选这些问题

标准是三者相乘：**影响 × 数学是不是瓶颈**（A 类、B 类，还是根本不在数学）×**AI 可处理性**（有没有自动裁判）。8 个问题刻意覆盖整个光谱，从几乎全是数学（Yang–Mills）到几乎不是数学（材料合成、天气）。

#	问题	影响	数学是瓶颈吗	快速自动裁判
1	电子结构（DFT）	极高	部分：近似 算法 是，定理不是	有（高精度计算）
2	逆向设计 + 自主实验室	高	否：合成和表征是	慢（实验要几周）
3	高温超导	科学高，经济中	B 类：不知道哪个模型对	部分
4	湍流	高	工程侧否；Clay 侧 A 类	工程有；Clay 有 Lean
5	聚变	若成功则极高	小部分	有（模拟器 + 装置）
6	天气与气候	极高	天气否；气候 B 类加数据	天气有，气候没有
7	Yang–Mills 与数学物理严格化	概念极高，实际约 0	是：A 类陈述、B 类内核	有（Lean）
8	量子引力与弦论	概念极高，实际约 0	子问题 A 类，整体 B 类加缺实验	只有子问题有

落选但值得一提：拓扑物相（数学分类早已完成，卡在材料上，如 Majorana 1 的证据之争 △）；量子计算硬件（归 §18）；蛋白质与药物（归 §20）；玻璃化转变（B 类）；暗物质与宇宙学（瓶颈是观测）；Ising、渗流等统计力学严格化（并入问题 7）。

19.2 问题 1：电子结构（多电子薛定谔方程与 DFT）

一句话 化学和材料的全部"规则"写在一个方程里，但精确求解的代价随电子数指数增长。整个工业靠一套近似（密度泛函理论，DFT）运转，而它最核心的一项没有人知道精确形式。

背景补课 哈密顿量 (Hamiltonian) 是"总能量的配方"：电子动能 + 原子核的吸引 + 电子间的排斥。**薛定谔方程** $H\Psi = E\Psi$ 要找一个**波函数** Ψ ，使配方作用在它上面只等于"乘一个数 E "，最小的 E 就是基态能量。 Ψ 给"所有电子位置的每一种组合"分配一个数。化学关心的几乎都是**能量差**：反应热、能垒、结合强度、电池电压。

指数爆炸 (手算)。每个坐标取 10 个网格点，1 个电子要存 10^3 个数， N 个电子要存 $10^{(3N)}$ 个。苯有 42 个电子，就是 10^{126} 个数，而宇宙里的原子只有约 10^{80} 个。换成化学家用的轨道基组，指数照样在：固氮酶活性中心 FeMoco 常用的 54 电子、54 轨道"活性空间"约有 3.8×10^{30} 个组态，任何经典计算机都算不了。

DFT 的绝招。Hohenberg-Kohn 定理 (1964) 证明，基态能量只取决于**电子密度** $n(r)$ ，它只有 3 个变量 [已确立]。Kohn-Sham (1965) 把问题改写成"不相互作用的假想电子"，成本降到约 N^3 。代价是所有难处理的多体效应被扫进一项：**交换关联泛函** $E_{xc}[n]$ 。定理保证它存在，却没说它长什么样，于是有了一级级的近似和几百种泛函。

1 kcal/mol 为什么重要 (手算)。反应速率约正比于 $\exp(-\text{能垒}/RT)$ ，300 K 时 $RT \approx 0.596$ kcal/mol。能垒错 1.37 kcal/mol，速率就差 10 倍；常见 DFT 的能垒误差 3–5 kcal/mol，按 4 算，速率差约 820 倍。所以 1 kcal/mol 叫"化学精度"。黄金标准 CCSD(T) 能做到，但成本按 N^7 增长：分子大一倍，计算量多 128 倍。

为什么重要 Haber-Bosch 合成氨约耗全球能源的 1–2% (IEA)，约一半人口的食物依赖合成氮肥 (Erisman et al. 2008) [已确立]。固氮酶在常温下就能固氮，但 FeMoco 的机理至今没算清；它也是"量子计算机能解决什么化学"的头号案例 (Reiher et al. 2017)。电池、催化剂、药物的关键量也都是 1 kcal/mol 量级的能量差。

卡在哪：瓶颈是不是数学？ 定理不是瓶颈，**近似算法和数据** 才是。有一条"不可能"定理限定了方向：Schuch & Verstraete (2009) 证明，如果通用泛函能高效计算，就能高效求解 QMA 完全问题 (QMA 是 NP 的量子版本) [已确立]，所以不存在对所有体系都好用的公式，只能利用真实化学的结构。数据上，Skala 的性能来自"前所未有体量"的高精度参考数据，Meta 的 OMol25 用了 1 亿多次 DFT 计算 [近期发现]。强关联体系 (过渡金属、FeMoco、铜氧化物) 里连 CCSD(T) 都不可靠，没有裁判，接近 B 类。量子计算机还远：FeMoco 的资源估计已降到约 1,500 个逻辑比特、约 10^9 个 Toffoli 门 (二手汇总 Δ)，仍远超 2026 年的硬件；Lee et al. (2023) 认为基态化学上找不到普遍指数加速的证据 [已确立]。

AI 能做什么

- **AI 数学/证明**：证明近似的误差界和精确约束 (如 Lieb-Oxford 界)，设计复杂度可证明的新算法。有用，但只是辅助：一个定理不会告诉你某个催化剂的能垒。

- **AI 其他能力 (主力):** 神经网络波函数 (FermiNet 等); 神经网络泛函 (Skala 约 27.6 万个参数, GMTKN55 误差 2.8 kcal/mol, 成本是半局域泛函的水平, 作者自报、独立复现待查 Δ); ML 原子势 (以"DFT 精度、经典力场速度"跑分子动力学); 编码智能体 + 主动学习, 自动决定下一个昂贵参考计算算什么。有高精度计算当自动裁判, AI 爬坡快。

如果解决: 一阶影响 若"DFT 的成本 + 化学精度"覆盖包括过渡金属在内的大部分化学: 催化剂和电池材料的计算筛选变得可信, 失败的合成大幅减少, 反应机理可以先算后做。

如果解决: 二阶影响 化学转向"先模拟、后实验", 像芯片设计里的 EDA。量子计算失去头号应用的一部分 [推测]。双用途: Urbina et al. (2022) 把药物发现模型的目标反过来, 6 小时生成约 4 万个候选毒性分子 [已确立]。规格博弈的教训: Medvedev et al. (2017) 发现, 十多年来的新泛函能量越拟越准, 密度却越来越偏离精确解 [已确立]。

时间判断 乐观: 2027 年底 ML 泛函和势在主族和大部分过渡金属化学上达到化学精度。中心: 2028 年左右主族化学在实用意义上"已解决", FeMoco 级强关联体系到 2030 年仍有争议; 依赖**曲线①** (2027 年中智能体约能跑 150 小时, 足以自主管理"数据生成 $\rightarrow$ 训练 $\rightarrow$ 评测"), 与**曲线②**几乎无关。悲观: ML 泛函在新元素和反常成键上泛化失败, 强关联化学要等 2035 年后的容错量子计算机。

反方观点与不确定性 基准精度不等于真实催化: 催化发生在表面、溶剂和动态条件下, 常是实验问题。ML 泛函可能在训练分布外悄悄出错。对多数药物项目, 电子结构精度不是限速步骤。

信号 Skala 类泛函成为主流程程序的默认选项, 并在过渡金属上被独立复现; ML 给出的 FeMoco 机理与实验一致。反向信号: 量子硬件首次在化学上胜过最好的经典方法 (2030 年前不太可能)。

来源: Dirac 1929, doi:10.1098/rspa.1929.0094 ; Schuch & Verstraete arXiv:0712.0483 ; Skala arXiv:2506.14665 ; FermiNet arXiv:1909.02487 ; OMol25 arXiv:2505.08762 ; Reiher et al. arXiv:1605.03590 ; Lee et al. arXiv:2208.02199 ; FeMoco 资源估计 (二手) <https://postquantum.com/quantum-utility-map/quantum-chemistry-drug-discovery-catalysis/> Δ ; IEA <https://www.iea.org/reports/ammonia-technology-roadmap> ; Erisman et al. 2008, Nat. Geosci. 1:636 ; Medvedev et al. 2017, Science 355:49 ; Urbina et al. 2022, Nat. Mach. Intell. 4:189

19.3 问题 2: 逆向设计与自主实验室 (电池、催化剂、碳捕集)

一句话 从"给定材料算性质"反过来, 变成"给定想要的性质, 找到材料并造出来"。AI 已能廉价生成上百万个候选, 瓶颈转到合成、表征、测试和放大, 这些都不是数学问题。

背景补课 正问题是"给你菜谱, 尝出味道"; 逆问题是"给你想要的味道, 找出菜谱, 再真的做出来"。只从约 80 种常用元素里挑 4 种, 就有 $C(80,4) = 1,581,580$ 种组合, 还要乘上配比和

晶体结构。稳定性用**凸包 (convex hull)** 判断：如果 AB 分解成 A + B 能量更低，AB 就不稳定。但稳定不等于**能合成**，后者取决于反应路径和动力学，没有好的理论。

漏斗的真实数字。生成（如扩散模型 MatterGen）→ ML 势粗筛 → DFT 精算 → 合成 → 表征（X 射线衍射，XRD）→ 测性能 → 放大。GNoME（2023）预测约 38 万个晶体落在凸包上，被外部独立合成的有 **736 个，约 0.2% [已确立]**。A-Lab 称 17 天合成了 58 个目标中的 41 个，随后被指出很多"新材料"是已知化合物的有序或无序变体 [近期发现]。

手算：Amdahl 定律。一个发现周期 = 2 周设计 + 6 周合成和测试。AI 把设计压到 0，周期从 8 周变 6 周，只快 1.33 倍。要快 10 倍，实验室本身必须快 10 倍。

为什么重要 电池决定可再生能源能占多大份额；催化剂用于绿色合成氨和电解水制氢（PEM 电解槽依赖稀缺的铱 Δ ）。美国 Materials Genome Initiative（2011）称，新材料从发现到上市通常要 10–20 年 [已确立]。

卡在哪：瓶颈是不是数学？ 基本不是。依次是：可合成性（B 类的化学问题）；表征有歧义（同一张 XRD 谱可有多种解释）；测试慢（电池寿命测试要几个月）；工艺（性能取决于微结构、缺陷和界面）；数据偏差（失败实验几乎不发表）。需要的数学（贝叶斯实验设计、对称性枚举）早已成熟。

AI 能做什么

- **AI 数学/证明**：直接作用接近零。
- **AI 其他能力 (主力)**：生成模型（MatterGen 合成了 TaCr_2O_6 ，目标体积模量 200 GPa，实测约 169 GPa Δ ）；ML 势粗筛；LLM 从文献提取合成配方；机器人闭环实验与自动表征。Periodic Labs（2025 年获 3 亿美元种子轮）近期做芯片散热材料，远期做超导体 [近期发现]。**裁判是实验**，又慢又吵，加速上限由实验室通量决定。

如果解决：一阶影响 若"预测的材料一半能做出来，且性能符合预测"：研发周期从 10–20 年缩到几年，电池、催化剂、吸附剂持续改良（更少的钴、锂、铱）。更可能是每年几个百分点的改进，而不是一次跃变 [推测]。

如果解决：二阶影响 验证基础设施成为新瓶颈：需要"可机器检查的材料声明"，原始数据、自动精修结果和可复现合成记录一起发布，相当于材料界的 Lean [推测]。常见元素替代钴和稀土，会改变供应链格局。**AI 安全**：自主实验室是 AI 第一次在物理世界拿到执行权限的地方，牵涉化学品安全、双用途和"谁能远程下单合成什么"。

时间判断 乐观：2028 年自主实验室通量 $\times 10$ ，预测目标成功率 $\geq 50\%$ 。中心：2029–2032 年 AI 设计的组分进入小众商用产品；依赖**曲线①**（2027 年末智能体约能连续工作 400 小时，可管理几个月的闭环实验），但实验室资本和物理节拍是硬约束，与**曲线②**无关。悲观：可合成性预测一直很差，加上信任赤字，推迟到 2035 年后。

反方观点与不确定性 收益可能主要来自已知体系的优化；以完美晶体为对象的模型可能抓错重点，因为工艺才是关键。乐观派认为，机器人加大模型能把通量提高两个数量级，打破 Amdahl 约束。

信号 AI 预测材料被独立实验室复现的比例，以及论文是否附原始数据；电池厂量产 AI 设计的化学体系。

来源：GNoME, Nature 624:80；A-Lab, Nature 624:86；A-Lab 质疑

https://www.theregister.com/2024/01/31/ai_chemistry_research_disputed/；MatterGen arXiv:2312.03687；Periodic Labs <https://siliconangle.com/2025/10/01/periodic-labs-raises-300m-accelerate-scientific-research-ai/>

19.4 问题 3：高温超导机理（Hubbard 模型）与室温超导

一句话 铜氧化物在约 -140°C 就零电阻导电，40 年了仍没有公认理论，所以没法“按图纸”设计室温超导体。讽刺的是，最高温的超导体（高压氢化物）恰恰**不靠这套理论**，是用 DFT 算出来的。

背景补课 超导 = 电阻严格为零 + 把磁场排出体外。BCS 理论（1957）解释了常规超导：电子借晶格振动（声子）两两配对，像一个人陷进蹦床，把旁边的人拉过去。铜氧化物常压纪录约 133–138 K [已确立]，一般认为配对来自电子强关联和磁性。

Hubbard 模型（两格点手算）。电子在格点间“跳”，每跳一次降能约 t ；两个电子挤在同一格点要付排斥能 U 。2 个格点、2 个电子时，基态能量 $E = (U - \sqrt{U^2 + 16t^2})/2$ 。 $U = 0$ 时 $E = -2t$ ，电子自由离域； $U = 8t$ 时 $E \approx -0.47t$ ，电子基本被冻在各自格点上，剩下的收益来自“相邻自旋反平行时可以虚跳”，等效于反铁磁耦合 $J \approx 4t^2/U = 0.5t$ 。**磁性从“跳”与“排斥”的竞争中长出来**，而铜氧化物母体正是反铁磁体。难点是：推到无穷大的二维格子并掺杂后，基态是超导还是条纹态？

这是数值之争，不是证明之争。Qin et al. (2020)： $t' = 0$ 、 $U = 8$ 时没有超导，基态是条纹态。Xu et al. (2024)：加上次近邻跳跃 t' 后，超导与条纹共存。Roth et al. (2025-11，神经网络量子态)：声称 $U = 4$ 、 $t' = 0$ 时也有 d 波超导 [近期发现，未评审]。

警示与真进展。2023 年 LK-99 几周内被查出是 Cu_2S 杂质造成的假象 [已确立]。氢化物 H_3S (203 K) 和 LaH_{10} (约 250 K) 在约 150–170 GPa 高压下超导，都是**先由 DFT 预测、再被实验证实** [已确立]。镍氧化物应变薄膜 2025 年在常压下起始 T_c 约 26–42 K [近期发现]。AI 找到的超导体目前都是低温的：BEE-NET 从 130 万个候选筛到 741 个，实验确认 2 个 [近期发现]。

为什么重要 科学上，它是强关联电子的范式问题。经济上，常压室温超导意味着无损输电、更便宜的 MRI、更紧凑的聚变磁体；但电网经济性主要受线缆成本约束。

卡在哪：瓶颈是不是数学？ 主要是 **B 类 + 数值**：不知道哪个模型对（单带还是多带？ t' 多大？声子起不起作用？）。费米子量子蒙特卡洛的"符号问题"一般是 NP 难的（Troyer & Wiese 2005）[已确立]，这条不可能结果把人推向张量网络和神经网络量子态。实验上，样品质量差、高压测量难复现。设计上，非常规超导没有可靠的 T_c 预测；常规超导有（DFT + Eliashberg 理论），氢化物就是这样找到的。

AI 能做什么

- **AI 数学/证明**：在某些参数区严格证明"有/没有超导"，远比数值难，也不直接产生材料；但问题 7 的 Haldane 能隙、Heisenberg 铁磁体结果说明较简单的多体模型已进入射程。价值中等：能约束理论。
- **AI 其他能力（主力）**：神经网络量子态（已直接参与 Hubbard 之争）；ML 加速的 T_c 筛选；自主合成；用 LLM 清洗文献、识别可疑声明。

如果解决：一阶影响 Hubbard 相图定论后，就知道单带模型够不够、该调哪个参数。常压室温超导一旦被发现，会掀起材料和工程革命，但部署要几十年。

如果解决：二阶影响 输电、储能、电机、聚变磁体（问题 5）和数据中心供电都会变。更近的一条是认识论：LK-99 展示了"社交媒体 + 复现竞赛"的动力学。当 AI 每天生成成百上千条候选声明，学界需要分诊机制：标准化判据（零电阻、Meissner 效应、比热、独立复现）加原始数据公开 [推测]。

时间判断 Hubbard 相图形成共识：乐观 2027 年（神经网络量子态与 AFQMC 收敛），中心 2028–2030 年，悲观是争论转成"真实材料该用哪个模型"；依赖算力和算法，与曲线②无关。常压室温超导被独立验证：乐观在 2030 年代初（尾部事件），中心是 2035 年前没有，悲观是不可能根本不存在。AI 可能把候选通量提高 2–5 倍 [推测] Δ ，但命中率本来就极低。

反方观点与不确定性 理解机理对发现新材料**既非必要也非充分**：氢化物靠 DFT，镍氧化物靠类比加运气。神经网络量子态与 AFQMC 的结论互相矛盾，连"数值事实"都还不稳。

信号 不同方法在相同参数下给出一致相图；镍氧化物常压 T_c 超过 77 K（液氮温度）；AI 设计的超导体 $T_c > 30$ K 并被独立复现。

来源：Qin et al. arXiv:1910.08931；Xu et al. arXiv:2303.08376；Roth et al. arXiv:2511.07566；Troyer & Wiese arXiv:cond-mat/0408370；Ko et al. 2025, Nature 638:935；LK-99 arXiv:2307.12008；Drozdov et al. 2015, Nature 525:73；Drozdov et al. 2019, Nature 569:528；BEE-NET arXiv:2503.20005

19.5 问题 4：湍流（短卡；Clay 问题见 §11）

水和空气的方程 1845 年就写好了，湍流却仍要靠经验模型来算。客机机翼的雷诺数（惯性与粘性之比）约 3×10^7 ；把所有涡都直接算出来（DNS）的成本约按 Re^3 增长，这个 Re 下光网

格点就要约 6×10^{16} 个，所以只能建模：小涡对平均流的影响靠经验的"闭合模型"补上，它们在分离流和失速上常出错（NASA CFD Vision 2030 列为最大瓶颈之一 [已确立]）。

工程侧的瓶颈不是数学，而是高 Re 数据稀少、ML 闭合换一种流动就失效（Duraismy et al. 2019）、航空认证要求可验证的模型。主力是 AI 的其他能力：学习型 LES 在二维湍流上用粗 8–10 倍的网格达到同样精度（Kochkov et al. 2021）；编码智能体把老代码移植到 GPU，最朴素，可能对成本影响最大。中心判断：2030 年前不会"基本解决"，更可能误差逐年降 10–30%（依赖算力、数据和曲线①）。**Clay 侧是 A 类数学**，AI 已在攻：OpenAI 声称证明了有外力的分支，无外力分支仍开放 (§11)；Chen–Hou 用计算机辅助证明了有边界的三维 Euler 会爆破 [已确立]；DeepMind 等找到一族不稳定爆破解，精度"满足计算机辅助证明的要求"（2025-09）[近期发现]。无外力分支中心 2028–2030 年（曲线②，千禧年问题会滞后）。少数关乎湍流物理的定理：Isett 证明了 Onsager 猜想（粘性趋于零时能量仍可耗散）；Deng–Hani–Ma（2025）从硬球粒子严格推出 NS–Fourier 方程 [近期发现]。两侧几乎不连通：工程求解器从不依赖整体正则性。**来源**：arXiv:2509.14185；Chen & Hou arXiv:2210.07191；Isett arXiv:1608.08301；Deng, Hani & Ma arXiv:2503.01800；Duraismy et al. arXiv:1804.00183；Kochkov et al. arXiv:2102.01010

19.6 问题 5：聚变—稳定性、控制与仿星器设计

一句话 目标是把上亿度的等离子体用磁场关住足够久。物理可行性已部分证明，剩下的是不稳定性控制、材料和工程。数学证明只占一小块。

背景补课 要多热、关多久（手算）。氘 + 氘 $\rightarrow$ 氦 + 中子 + 17.6 MeV。点火大致要满足 Lawson 判据：密度 $\times$ 温度 $\times$ 约束时间 $\geq 3 \times 10^{21}$ keV·s/m³。取密度 10^{20} 个/m³、温度 15 keV（约 1.7 亿度），约束时间至少要 $3 \times 10^{21} \div (10^{20} \times 15) = 2$ 秒。

模型阶梯。从精确到便宜：Vlasov–Maxwell（6 维相空间，§12 的对象） $\rightarrow$ 回旋动理学（平均掉绕磁力线的快速回旋，5 维） $\rightarrow$ 磁流体（当作导电流体） $\rightarrow$ 一维输运代码（如 TORAX）。

§12 的整体光滑性结果属于最上一级的模型健康证明，对工程没有直接影响。

两种磁笼子。**托卡马克**轴对称，靠等离子体自身的大电流约束，代价是可能"破裂"：电流在毫秒内崩溃，释放巨大的力和热。**仿星器**用扭曲的三维线圈，能稳态运行，代价是设计变成三维优化问题。

Grad 猜想与它的反例。好的磁约束要求磁力线绕出一层层嵌套的"磁面"，像洋葱。Grad（1967）猜想：没有对称性，就不存在这样的光滑平衡；它被称为"仿星器理论的核心数学问题"。2026-09-21，Gómez-Serrano、Liehr 和 Taylor 给出**反例**：一个只有 N 重旋转对称的光滑平衡，附 Lean 4 证明 [近期发现，未评审]。论文披露了分工：人写路线图，GPT-5.6 Sol、Claude Fable 5、Claude Opus 5 补细节并写 Lean，是"人主导 + AI 填细节 + 形式化"的样板。物理上要打折扣：磁场在磁轴上恰好为零，结论只在小曲率、大 N 的极限下成立；工程界实际靠数值优化（如"精确准对称"，Landreman & Paul 2022）。

现状。NIF 2025-04 用 2.08 MJ 激光产出 8.6 MJ (增益约 4.1), 但激光系统从电网取电约 300 MJ [近期发现]。ITER 氦氖运行推到 2039 年 Δ ; SPARC 首次等离子体据报滑到 2027 年 (二手 Δ)。CFS 与 DeepMind (2025-10) 用 TORAX 做数百万次虚拟实验, 配合 AlphaEvolve 搜索运行方案, 将来用强化学习实时控制; Google 另签了 ARC 的 200 MW 购电协议 [近期发现]。

为什么重要 聚变是零碳的稳定基荷电源, AI 数据中心的用电需求正把科技公司推向聚变购电协议。但它最终要和"光伏 + 储能"比成本 (Jassby 2017 Δ)。

卡在哪: 瓶颈是不是数学? 主要是**工程和材料**: 14 MeV 中子损伤第一壁、氦增殖 Δ 、高温超导磁体的可靠性、偏滤器热负荷、成本。其次是**物理**: 湍流输运预测 (单次多尺度模拟可达千万 CPU 小时量级 Δ)、破裂和撕裂模。**数学只占小部分**: 三维平衡的存在性 (Grad)、模型适定性 (多粒子种类的 Vlasov–Maxwell 仍待定)、线圈优化。

AI 能做什么

- *AI 数学/证明*: Grad 类的存在性与刚性定理、严格稳定性判据、有误差界的平衡求解。它们告诉设计者"什么位形存在", 但造不出反应堆。
- *AI 其他能力 (主力)*: 强化学习控制 (TCV 上同时控制 19 个线圈, Degraive et al. 2022; DIII-D 上提前避开撕裂不稳定性, Seo et al. 2024 [已确立]); 破裂预测; 可微模拟器和回旋动力学的替代模型; 仿星器线圈优化; 编码智能体维护模拟代码栈。

如果解决: 一阶影响 装置调试更快、性能更高; 破裂更少, 这对 ITER 级装置至关重要, 一次大破裂就可能损坏设备; 仿星器设计周期缩短。

如果解决: 二阶影响 AI 与能源形成正反馈: 聚变为数据中心供电, AI 又加速聚变研发 [推测]。**AI 安全**: 强化学习控制器进入安全关键的物理系统; 聚变是"有保证的安全 AI" (Guaranteed Safe AI, GSAI) 近乎理想的试验场, 物理模型好, 风险是物理性的但有界, 可以做"有限时域证书 + 运行时监控 + 备用控制器"。**核扩散**: 聚变中子能增殖裂变材料, 需要保障监督 Δ 。

时间判断 SPARC 达到 $Q > 1$ (聚变输出功率大于加热功率): 乐观 2027 年, 中心 2028 年, 悲观 2030 年后。商业发电: 乐观 2030 年代初, 中心 2030 年代中后期, 悲观在 2040 年代甚至更晚。AI 能把调试和设计缩短几个月到几年, 但改变不了材料辐照鉴定的真实时间; 进度由硬件节拍决定, 与曲线②几乎无关, 与曲线①弱相关。

反方观点与不确定性 AI 控制可能只是锦上添花: 紧凑高场托卡马克的物理已经够用, 难在把它造出来。聚变也可能永远比不过"光伏 + 储能"的成本曲线。

信号 SPARC 首次等离子体和 $Q > 1$ 的实际时间; 强化学习控制器进入大装置的常规运行; Grad 类结果被写进设计代码。

来源: Grad 反例 arXiv:2609.24739 ; Constantin, Drivas & Ginsberg arXiv:2108.05977 ; Landreman & Paul arXiv:2108.03711 ; Degraeve et al. 2022, Nature 602:414 ; Seo et al. 2024, Nature 626:746 ; TORAX arXiv:2406.06718 ; CFS × DeepMind <https://www.ans.org/news/2025-10-22/article-7484/commonwealth-fusion-systems-partners-with-google-deepmind/> ; NIF <https://www.llnl.gov/article/52906/llnl-experts-foster-national-fusion-energy-ecosystem-ife-star-conference> ; SPARC (二手) <https://www.insidedeep.tech/commonwealth-fusion-systems-sparc-full-guide/> △

19.7 问题 6: 天气与气候 (短卡)

天气是"初值问题": 知道此刻的大气, 往前积分。混沌是硬约束: 假设误差每 2 天翻一倍 (示意数字), 14 天后放大 128 倍, 所以可预报上限约两周 [已确立]。AI 模型从 40 多年的再分析资料 (ERA5) 学习"6 小时后的天气长什么样": GraphCast (2023) 在约 90% 的目标上超过 ECMWF 的业务模式 HRES, GenCast (2024) 在约 97% 的目标上超过其集合预报; **ECMWF 的 AIFS 于 2025-02-25 业务化**, 能耗约降 1,000 倍 [近期发现]。剩下的瓶颈是观测稀疏、初值同化和极端事件样本少, 都不是数学。

气候是"边界条件问题": CO₂ 翻倍后, 天气的统计分布变成什么样。IPCC AR6 给出的平衡气候敏感度可能区间是 2.5–4°C, 最大的不确定来源是**云反馈**。这是 B 类问题加数据问题: 没有"CO₂ 翻倍的世界"可供训练, AI 只能外推; ACE2 的作者自己承认, 模型对单独改变海温或 CO₂ 的敏感性"不完全真实"[近期发现]。端到端"观测 → 预报"业务化中心在 2028 年; 气候敏感度区间收窄到约 ±0.5°C 中心在 2030 年代中期, 要靠公里级模拟加 AI 云模拟器。同一套学习型模拟器, 在每天打分的天气上已改写业务, 在几十年打一次分的气候上进展很慢, 这是 19.10 规律 3 最干净的例子。**来源**: GraphCast arXiv:2212.12794 ; GenCast arXiv:2312.15796 ; ACE2 arXiv:2411.11268 ; AIFS <https://www.ecmwf.int/en/about/media-centre/news/2025/ecmwfs-ensemble-ai-forecasts-become-operational> ; IPCC AR6 WG1 第 7 章

19.8 问题 7: Yang–Mills 质量间隙与数学物理的"严格化"

一句话 物理学家用量子场论做出了精度极高的预测, 数学家却至今不能证明四维量子 Yang–Mills 理论"存在"并有质量间隙。这是一个陈述清楚、AI 可能率先攻下的千禧年问题, 但对实验和工程几乎没有影响, 价值在概念和方法。

背景补课 量子场论 (QFT)。宇宙到处是"场", 粒子是场上的涟漪。QED 的预测与实验吻合到约 10⁻¹² 量级 △, 但计算用的是可能发散的级数, 中间的无穷大靠"重整化"消掉。**数学上至今没人构造出满足公理的四维有相互作用 QFT**; 最自然的候选 ϕ^4 已被证明在连续极限下退化成自由理论 (Aizenman & Duminil-Copin 2021) [已确立]。

Yang–Mills (类比)。电磁学里光不带电, 两束光互相穿过。在 Yang–Mills (如描述强力的 QCD) 里, "光" (胶子) 本身带色荷、互相吸引, 于是拧成通量管, 把夸克关起来。**质量间隙**

是说：方程里胶子无质量，理论里最轻的粒子（胶球）却有正质量。格点 QCD 算出最轻胶球约 1.7 GeV；可见物质约 99% 的质量来自 QCD 动力学，而不是 Higgs 机制（Dürr et al. 2008）[已确立]。

难在哪。格点方法把时空切成间距为 a 的格子，算一个巨大的积分，再让 $a \rightarrow 0$ ，像用黎曼和逼近积分。但这里要对**所有场构型**做无穷维积分，而无穷维空间里没有现成的"均匀测度"；要证明极限存在、有相互作用、有能隙，必须同时控制所有尺度上的涨落。二维已完全构造，二维、三维有随机量子化的进展（Chandra, Chevyrev, Hairer & Shen）；四维截至 2026-10 仍开放，网上几份"完整证明"未经评审 $\triangle$ 。

2026 年的新情况：数学物理的 A 类清单正被清扫。二手统计称 OpenAI 这批稿件里约有 25 个"数学物理"家族 $\triangle$ 。下表是从 `openai/math` 的 CONTENTS 和 lean/docs（2026-10-09 下载）查到的代表，均为**声称、未评审**：

家族	声称解决的问题（白话）	形式化
261	Anderson 模型（电子在带杂质的晶格里跳）： $d \geq 3$ 弱无序时电子能"扩展"开、能导电（自称解决 Simon 问题 1 的这一部分）	只有二维部分；三维没有 Lean
271	$d \geq 3$ 量子 Heisenberg 铁磁体（格点上的量子小磁针，相邻的想同向）低温自发磁化	有 Comparator 题面
268	自旋 1 链的 Haldane 能隙（1983 年猜想）：最低激发能有正间隙	没有
267	硬球 Bose 气体正温度 BEC（大量粒子挤进同一量子态）	只有基态凝聚
376、362、221	受迫 NS (§11)、Vlasov–Maxwell (§12)、Mézard–Parisi (§13)	见对应各节

到 2026-10-09 没找到数学物理学家的具名评审。这些结果有一个共同点：确认的都是物理学家早已相信的事，比如三维铁磁体低温下会磁化、硬球气体会凝聚；§11 和 §12 证明的则是"模型在数学上不会自己坏掉"。这就是**模型健康证明**：回答"模型在逻辑上健不健康"，不回答"自然是什么样"。

为什么重要 实际影响约等于 0：格点 QCD 早就给出了数字。概念影响很大：QFT 是不是一个自洽的数学理论？方法会外溢到其他数学分支（先例：Witten 的 TQFT 带来纽结不变量）。它也是检验 AI 能否**建立新理论框架**、而不只是解题的最好案例。

卡在哪：瓶颈是不是数学？ 是，但这是"A 类陈述、B 类内核"：题面清楚，证明可能需要新概念（严格的四维重整化群、处理 Gribov 歧义）。另有形式化瓶颈 [推测]：物理几乎没被形式化，HepLean/PhysLean 2024 年才起步，Mathlib 缺泛函积分等基础设施。光是用 Lean 写出"四维 Yang–Mills 满足 Osterwalder–Schrader 公理"这个**陈述**，就是巨大的规格工程，是"瓶颈迁移到陈述" (§3、§17) 的纯粹形态。

AI 能做什么

- **AI 数学/证明 (主力)**: 构造性 QFT 的证明以超长、"记账式"的估计著称 (簇展开、多尺度分析), 恰是 AI 最擅长的劳动; 2026 年这批结果说明 Lieb、Simon 传统里的问题已进入射程。
- **AI 其他能力**: 格点 QCD 的流模型采样 (Albergo et al. 2019); 把物理形式化; 符号计算。

如果解决: 一阶影响 第一个严格的四维有相互作用 QFT 诞生; Lieb、Simon 清单大面积结题, 数学物理教科书要重写。

如果解决: 二阶影响 学科重心从"证明"转到"选择和审核陈述", 还有一个低概率的"严格性红利": 发现物理学家的某些默认假设不成立。严格重整化群与深度学习理论相连 (19.10.2)。"有物理意义的千禧年问题被 AI 解决"会造成公众认知跳变, 也会考验验证制度: Clay 要求两年社区接受期, AI 的产出快得多; 陈述忠实性依旧是问题 (受迫 NS 的教训, §11)。

时间判断 Lieb/Simon 类多体问题: 中心判断是到 2027 年底, 大多数著名的 A 类数学物理问题会被声称解决, 一半以上得到专家确认 [推测]; 依据是 2026-09 已出现一批, "有名但相对可攻"的问题会先于曲线②的平均水平 (2027 年末约 18%) 倒下。Yang-Mills 质量间隙: 乐观 2028 年, 中心 2030-2033 年, 悲观 2035 年后 [推测]; 曲线②的 2030 年 77% 针对一般问题, 千禧年级会滞后, 曲线②让证明变便宜, 但陈述的规格成本不降。

反方观点与不确定性 有效场论观点认为, 标准模型只在某个能标以下有效, 严格构造连续极限是在研究理想化对象。严格证明可能只是确认格点早已"看到"的东西。AI 的证明可能"人类不可读" (Gómez-Serrano 评 NS 论文), 概念价值会打折扣。

信号 271、261、268 得到具名专家确认或在期刊发表; Mathlib 或 PhysLean 里出现 QFT 公理的陈述; Clay 表态。

来源: <https://github.com/openai/math> (CONTENTS; lean/docs 261、267、271; 2026-10-09 下载); 二手统计 <https://kingy.ai/blog/openai-math-722-manuscripts-results-proofs-compute-costs/> △; Simon 问题 https://en.wikipedia.org/wiki/Simon_problems; Clay <https://www.claymath.org/lectures/yang-mills-and-the-mass-gap/>; Aizenman & Duminil-Copin arXiv:1912.07973; Chandra et al. arXiv:2006.04987; Dürr et al. 2008, Science 322:1224; HepLean arXiv:2405.08863; Albergo et al. arXiv:1904.12072

19.9 问题 8: 量子引力与弦论 (短卡)

广义相对论说引力是光滑的时空弯曲, 量子力学是离散、概率的, 两者硬拼会出现消不掉的无穷大。候选理论 (弦论、圈量子引力等) 数学极其丰富, 可检验的预测几乎为零。原因可以手算: 量子引力显著的能标约 1.2×10^{19} GeV, LHC 只有 1.36×10^4 GeV, 差约 10^{15} 倍; 磁场不变时能量与环半径成正比, 把 LHC 约 4.3 km 的半径放大 10^{15} 倍, 约 400 光年。弦论额外维度的蜷缩方式估计有 10^{500} 到 $10^{272,000}$ 种 (Taylor & Wang 2015), 很难给出唯一预测。

首要瓶颈是实验, 其次是 B 类数学 (弦论没有完整的非微扰定义), 但 A 类子问题遍地都是: 散射振幅恒等式、自举界、Calabi-Yau 分类。共形自举只用对称性、自洽性和半定规划, 就把

三维 Ising 临界指数算到 5–6 位小数 (Kos et al. 2016) [已确立]。AI 已进场：2026-02, Guevara、Strominger 等人 (代表 OpenAI) 指出, 长期被默认为零的"单负螺旋度胶子树图振幅"在特定构型下不为零；公式由 GPT-5.2 Pro 提出、内部模型证明、作者验证 [近期发现]。这类结果 2027 年会放量 (曲线②)；量子引力被实验确认, 中心判断是 2040 年前不会。AI 最有价值的贡献可能是设计桌面实验, 例如检验引力能否产生纠缠 (Bose et al. 2017, 尚未实现) [推测]。反过来, 没有实验约束的领域加上 AI 无限量产出**自洽**的数学, 可能导致漂亮理论泛滥、却没有选择压力：Lean 验证得了证明, 验证不了"自然就是这样"[推测]。**来源：**arXiv:2602.12176 ； Taylor & Wang arXiv:1511.03209 ； Kos et al. arXiv:1603.04436 ； Bose et al. arXiv:1707.06050

19.10 本领域的二阶效应

19.10.1 三条规律

规律 1：物理里的"数学突破"多半是模型健康证明。 NS (§11)、Vlasov–Maxwell (§12)、Anderson、Heisenberg、BEC、Yang–Mills 都在确认物理学家已经相信的东西。真正改变方向的数学有三种：**不可能定理** (Schuch–Verstraete、Troyer–Wiese, 把领域推向"利用结构"的近似)；**存在性结果与反例** (Grad 反例、Onsager 猜想, 告诉你设计空间里有什么)；**新算法**。所以 AI 数学对物理最大的价值可能在设计算法和证明不可能性, 而不在清扫猜想。

规律 2：候选便宜, 验证贵。 数学里是"证明便宜、审核陈述贵" (§17), 物理和化学里是"候选便宜、验证贵", 验证靠实验、高精度计算, 甚至时间 (气候)。GNoME 的 38 万对 736、AI 超导候选加 LK-99 式的狂热、一次发布 719 篇几乎无人具名评审的稿件, 是同一个形状。下一个稀缺资源是**验证基础设施**：自主复现实验室、原始数据公开、陈述审核。

规律 3：AI 加速的快慢由裁判速度决定。

领域	裁判	一轮反馈	AI 加速
天气	明天的观测	天	已发生
数学物理定理	Lean	分钟到小时	已发生 (2026-09)
电子结构	高精度计算	小时到天	快
聚变控制	模拟器 + 放电	秒到月	中
材料与超导	合成 + 表征	周到月	受 Amdahl 约束
气候	观测	十年	慢
量子引力	无	∞	只在子问题上

这是 A 类 / B 类 (§17) 的推广：从"有没有裁判"推广到"裁判有多快"。

19.10.2 跨领域连接

1. **自旋玻璃 → 神经网络 → 蛋白质折叠**。Hopfield 网络 (1982) 的能量函数就是自旋玻璃的哈密顿量, 记忆就是能量的极小点 (2024 年诺贝尔物理学奖)。Bryngelson & Wolynes (1987) 用同一理论解释蛋白质折叠的"能量漏斗"。§13 的 Mézard–Parisi、OpenAI 281 号家族 (QAOA 达到 SK 模型最优)、随机 k-SAT 阈值用的都是同一套数学; 神经科学里工作记忆的吸引子网络也是。
2. **重整化群 ↔ 深度学习**。重整化群 (RG) 把细节一层层粗粒化, 看哪些量在放大尺度后还留下来。Mehta & Schwab 把 RG 映射到受限玻尔兹曼机; Roberts, Yaida & Hanin 把逐层表示写成 RG 流; Halverson, Maiti & Stoner 指出无限宽网络是自由场, 有限宽带来相互作用。严格 RG 若因 AI 突破 (问题 7), 深度学习理论可能直接受益; 奇异学习理论 (SLT) 的自由能和相变语言本来就是统计物理 (§21) [推测]。
3. **非平衡热力学 → 扩散模型 → 材料生成**。扩散模型 (Sohl-Dickstein et al. 2015) 来自"加噪到平衡、再学逆过程"的物理图像, 如今 MatterGen 又把它用回材料。
4. **"模拟器在分布外失效"是共同母题**。天气模型推到气候、ML 泛函推到新元素、湍流闭合推到新流动、聚变替代模型推到新装置。它和对齐里的分布迁移与目标错误泛化 (goal misgeneralization) 同构, 而物理有地面真值, 是研究它的干净实验台 [推测]。
5. **复杂度理论是物理与 CS 的接缝**。QMA (DFT)、NP 难 (符号问题)、量子优势的证据 (Lee et al.) 共同决定"哪些问题永远只能近似"; AI 数学在这条接缝上的产出 (OpenAI 279、284 号家族, 见 §18) 可能比纯物理结果更有影响 [推测]。

19.10.3 对社会和 AI 安全

- **物理科学会是 AI 自主科研最先跑起来的地方**, 能力外溢最先出现在物理执行端 (自主实验室、装置控制、模拟驱动的设计), 并形成算力反馈环 (聚变购电协议、芯片散热材料)。
- **双用途**: 化学最直接 (毒物、含能材料), 其次是核与等离子体。廉价气候模拟器还降低了单边模拟平流层注入 (地球工程) 的门槛, 而那正是模拟器容易"自信但错误"的分布外区域 [推测]。
- **认识论**: 声明产量增长几个数量级, 评审能力不变。实验科学需要自己的"Lean": 自主复现加原始数据。
- **规格博弈样本**: 受迫 NS、DFT 密度偏移, 以及 GraphCast 早期因优化均方误差把极端事件"抹平"。
- **GSAI 的现实试验场**: 聚变控制、化工过程、电网都有好的物理模型, 适合做"有界证书 + 运行时监控"。

19.11 本节来源

各卡片末尾已列出来源。另: OpenAI math 发布 <https://github.com/openai/math>

(CONTENTS.md 与 lean/docs, 2026-10-09 下载); Hopfield 1982, PNAS 79:2554 ; Bryngelson & Wolynes 1987, PNAS 84:7524 ; Mehta & Schwab arXiv:1410.3831 ; Roberts, Yaida & Hanin arXiv:2106.10165 ; Halverson, Maiti & Stoner arXiv:2008.08601 ; Sohl-

Dickstein et al. arXiv:1503.03585。未能在线核对、建议抽查：ITER 2039 年氘氚运行；回旋动理学模拟的 CPU 小时数；MatterGen 实测体积模量；QED 的精度位数；FeMoco 资源估计汇总、"约 25 个数学物理家族"统计、SPARC 推迟到 2027 年（均为二手）。

PART II · 前瞻 · 生物

20. 生物、医学与神经科学：瓶颈不是证明，是测量

标签：**[已确立]** 教科书级共识；**[近期发现]** 2024–2026 的结果，可能还会被修正；**[推测]** 推断，没有直接证据；**△** 未核实，引用前请自己再查一遍。

20.0 先说结论

1. 生物学没有"待证明的猜想清单"。数学和物理能列出"黎曼假设""Navier–Stokes 正则性"这种陈述清楚、只缺证明的问题（**A 类**）；生物学几乎列不出来，它的难题绝大多数是 **B 类**——连"该测什么量、该写下什么方程"都不知道。所以"AI 把数学做完了"对生物学的**直接贡献**很小。这是结构性的：生物系统是 40 亿年演化出来的、没有设计文档的、每个部件都是别的部件的例外的系统。
1. 但有一个真例外：统计力学意义上的采样问题。蛋白质动力学和自由能计算，本质是"在 10^4 – 10^6 维空间上算一个配分函数"——有方差界、有收敛性、有可证明的东西。这是本节唯一一张"数学是瓶颈"站得住的卡（问题 1）。AI 在这里不靠证明定理，靠**学一个能直接从玻尔兹曼分布采样的生成模型**[近期发现]。
1. 第二个例外是因果可识别性与试验设计。虚拟细胞（问题 3）和临床试验（问题 5）背后都有个干净的数学问题：给定我能做的扰动集合，哪些因果结构可辨识？最省样本的扰动设计是什么？属于 A 类边缘。但它不是实际限速步：限速步是**做不出那么多扰动**，以及**评测指标被刷爆**。
1. 瓶颈按出现频率排序：实验吞吐 > 有因果设计的数据 > 概念 > 制度 > 算力 > 数学。两个证据：(a) 2025 年 *Nature Methods* 测了 7 个深度学习模型（含 5 个单细胞基础模型）预测基因扰动效果，**没有一个打得过"把两个单扰动的 log fold change 加起来"这种小学生基线**[近期发现]；(b) Arc Institute 第一届 Virtual Cell Challenge 有 1,200 多队提交，MAE 这一项**没有任何模型超过基线**，组委会把惩罚截断在 0，指标失效、被公开刷分[近期发现]。缺的不是模型容量，是能把模型逼到墙角的数据和指标。
1. "AI 的其他能力"比"AI 的数学能力"重要一个数量级。四件事：自动化实验室（OpenAI × Ginkgo 用 GPT-5 跑了 36,000 个无细胞蛋白合成配方、580 块自动化板，每克蛋白成本降 40%、产量升 27%[近期发现]）；生成式设计（RFdiffusion2 在 41 个酶设计基准上全解，此前最好的只解 16 个[近期发现]）；假设/文献 agent（Google AI co-scientist 推荐的表观遗传靶点在人肝类器官里确实抗纤维化[近期发现]）；预测模型当"虚拟仪器"（MICrONS 的数字孪生能

预测小鼠视皮层上万个神经元对**没见过的**刺激的反应[近期发现])。四件事都不需要证明任何定理。

1. **医学的时间常数会把一切拖慢，而这是制度问题不是科学问题。** 临床开发整体成功率 7.9% (Phase I → 批准, 9,704 个项目) [已确立], 最窄的口是 Phase II→III 的 28.9%[已确立], 失败原因 40–50% 是效能不足[已确立]。AI 发现的分子在 Phase I 成功率 80–90% (人类 40–65%), 到 Phase II 掉回约 40%, 和行业平均一样[近期发现, 样本小]。**这精确说明 AI 现在解决的是"分子好不好" (化学), 没解决"靶点对不对" (生物学)。**
1. **神经科学和 AI 可解释性连得最紧，而连接方式是"坏消息"。** 秀丽隐杆线虫 (*C. elegans*) 的完整连接组 1986 年就有了, 302 个神经元、约 7,000 个突触——**四十年后仍然不能从连接组预测它的行为**[已确立]。**如果"完整连线图 + 完整活动记录"都不等于"理解", 那 mechanistic interpretability 的"完全理解一个模型"需要被重新定义成"在特定问题上能做出可验证的因果预测"。** 好消息是人工网络比大脑好办: 权重能全读、干预无代价、可以重训一万次 (问题 6)。
1. **生物安全是唯一一个"AI 能力直接触发部署限制"已经发生的领域，而它的瓶颈 100% 是制度。** 美国 EO 14292 (2025-05) 要求 OSTP 在 90 天内更新 2024 年的核酸合成筛查框架, 到 2026 年 7 月**仍未更新** (CRS) [近期发现]; 强制筛查**没有联邦立法**。同时 Anthropic 2025 年 5 月随 Claude Opus 4 启用 ASL-3, 明确因为**无法排除 CBRN 风险**[已确立]。威胁侧跟着每 129 天翻倍的能力曲线走, 防御侧跟着立法周期走。

20.1 为什么选这些问题

三个维度: 影响规模; "数学是不是瓶颈"的诚实回答; AI 可处理性。第二个维度**不是**只选"数学是瓶颈"的——这里特意选了几张"数学完全不是瓶颈"的卡 (问题 2、5、8), 因为它们对"AI 解决数学之后会怎样"的答案恰恰是**"不怎样, 因为别的东西卡着"**, 这个答案本身有信息量。八张卡串成一条链:

蛋白质动力学 (问题 1, 物理层) → 从头设计 (问题 2, 工程层) → 细胞行为预测 (问题 3, 系统层) → 基因组如何编码身体 (问题 4, 发育层) → 临床转化 (问题 5, 医学层)。两条支线是**大脑** (问题 6, 系统层里最难的特例) 和**衰老** (问题 7, 所有层次一起失效的现象); **生物安全** (问题 8) 是问题 1、2、4 能力提升的阴影面。

落选但值得一提: 流行病学建模——SEIR 的数学早就够用, 2020 年失准是因为接触矩阵、行为改变、检测偏差的数据不可得, 不是方程错; "数学不是瓶颈"最干净的例子, 但 AI 杠杆小。**演化与适应度景观**——和蛋白质能量景观、神经网络损失景观是同一类数学对象, 但主要是认识论价值。**免疫学: TCR-抗原识别与疫苗设计**——实际影响极大, 落选只因瓶颈结构和问题 2、3 高度重复; **要选一个被低估的方向, 这是首选**。**微生物组**——相关性多、因果结论极少, 无法在人体做干预实验 + 群落动力学不可识别。**蛋白聚集** (tau、 α -synuclein、 $A\beta$) 物理同问题 1; **农业与光合作用改造**瓶颈是田间试验周期 (一年一季); **脑机接口与全脑仿真**瓶颈是问题 6 的"连线图≠算法"; **代谢工程**瓶颈是菌株工程的实验吞吐。

20.2 问题 1：蛋白质的动态与功能—AlphaFold 之后真正难的那一半

一句话 静态结构基本解决了，但功能来自蛋白质在一堆构象之间的**概率分布**和构象间的**自由能差**，而算这个分布是高维采样问题——这是整个生物学里"数学/算法真的是瓶颈"最站得住脚的地方。

背景补课 给蛋白质的每个三维构型配一个能量（静电、氢键、疏水效应之和），就得到一个几千维的**能量景观（energy landscape）**，折叠是景观上的下坡运动。**Levinthal 悖论（1969）** [已确立]：100 残基、每残基只按 3 种构象算（极度低估），总构型数 $3^{100} \approx 5 \times 10^{47}$ ，每步 10^{-13} 秒，穷举要 1.6×10^{27} 年，比宇宙年龄长 10^{17} 倍；但真实折叠只要微秒到秒。解答是景观不是随机崎岖的，而是**漏斗状（folding funnel）**——越接近正确结构，能量系统性地越低。它的数学来源是 Bryngelson 和 Wolynes 1987 年用**自旋玻璃（spin glass）**的统计力学推出来的[已确立]，而同一套数学后来被用于分析神经网络的损失景观（Hopfield 网络就是自旋玻璃）。这是本节第一个跨领域连接：**自旋玻璃 ↔ 蛋白质折叠 ↔ 神经网络训练**（与 §13 的 Mézard–Parisi 同源）。

AlphaFold2/3 把结构预测做到实验精度[已确立]，Hassabis 和 Jumper 因此获 2024 年诺贝尔化学奖的一半（另一半授予做蛋白设计的 Baker）[已确立]。但 AlphaFold 给的是一张**照片**，功能来自一段**电影**：**变构**（分子结合在 A 位点改变 B 位点形状，大量药物靶点靠这个机制）、**隐藏口袋**（cryptic pocket，静态结构看不到、蛋白质呼吸时才短暂打开，很多"不可成药"靶点其实有）、**本质无序蛋白**（IDP，约占人类蛋白组 30%）、**构象自由能差**。数学核心：构型 x 的概率是玻尔兹曼分布 $p(x) \propto \exp(-E(x)/kT)$ ，要算的量都是对它的期望，而配分函数是 $10^4\text{--}10^6$ 维积分，只能采样。 $p_A/p_B = \exp(\Delta G/kT)$ ，室温下 $kT \approx 0.6$ kcal/mol：

ΔG	概率比	意味着
0.6 kcal/mol	$\sim 2.7 : 1$	两个构象都常见
1.4 kcal/mol	$\sim 10 : 1$	一个占 91%
2.8 kcal/mol	$\sim 100 : 1$	一个占 99%
4.2 kcal/mol	$\sim 1000 : 1$	另一个基本看不到

所以**要算到 1 kcal/mol 精度**才刚够分辨"常见"和"罕见"构象——而这约等于一个弱氢键，是蛋白质总能量的万分之几。分子动力学（MD）的步长必须约 1 飞秒，而构象变化在微秒到毫秒，所以需要 $10^9\text{--}10^{12}$ 步，模拟 1 毫秒，按一块 GPU 每天几百纳秒估算，要约 **5–30 GPU-年**，体系越大越慢 [推测，按 100–500 ns/天手算]。

为什么重要 小分子药靠结合蛋白质口袋起效，算准构象分布 = 系统枚举隐藏口袋 = 把"不可成药"靶点变成可成药（全球处方药市场约 1.5 万亿美元/年量级）；酶催化来自对**过渡态**的稳定化，不会算自由能就只能靠试（问题 2）。

卡在哪：瓶颈是不是数学？ 数学/算法是主要瓶颈之一，但与力场精度、算力并列，而后两个在逼近。这是本节唯一愿意说"数学真的是瓶颈"的卡。采样是数学/算法（复本交换、马尔可夫状态模型、Boltzmann generator 每次都带来数量级加速）；力场精度是物理建模 + 数据（经典力场有系统误差，量子化学精确但贵 10^6 倍）；算力有 10^{12} 步的硬墙；验证数据是实验瓶颈（NMR、cryo-EM 多构象、HDX-MS、单分子 FRET 稀少且间接）。

AI 能做什么 (a) 数学/证明能力：不多，但不是零。 可形式化的有：学出来的提议分布下重要性采样的有效样本数下界（陈述清楚、缺证明的 A 类）；Jarzynski 等式、Crooks 定理这类自由能恒等式的形式化验证；一致性定理（与真实分布的 KL 距离小于 $\epsilon \Rightarrow \Delta G$ 误差小于 $f(\epsilon)$ ）。按 §17 的曲线，这类 A 类问题 2027 年中起批量被攻克是合理的[推测]。**(b) 其他能力：主战场。** 思路转换是不模拟轨迹、直接学分布：微软研究院的 BioEmu[近期发现]用 200 毫秒以上的 MD 轨迹 + 静态结构（含 AlphaFold 数据库 1 亿+ 蛋白质）+ 约 50 万条实验稳定性测量训练，单 GPU 每小时生成数千个统计独立构型，相对自由能达 1 kcal/mol 量级，能抓到**隐藏口袋形成、局部解折叠、结构域重排**；官方材料称把"几个 GPU-年"压到"不到 1 个 GPU-小时"、约 10 万倍加速（ Δ 这个数字来自宣传材料/视频转录，不是论文正文）。

如果解决：一阶影响 构象集合与自由能差小时级算出；隐藏口袋从偶然发现变成系统枚举，"不可成药"这个分类大幅缩小[推测]；变构药物设计从艺术变成工程；酶设计有了真正的打分函数；IDP 与相分离从"只能描述"变成"能预测"。

如果解决：二阶影响 **问题 2 的瓶颈被打开**——设计现在卡在"没有 oracle"（无法在计算机里给设计打分），算准自由能 = 有了 oracle = 成功率从个位数百分比跳到可用水平，这是本节内部最强的因果链。**失败模式转移：**结合这一环变可靠后，临床失败会**更纯粹地**暴露为"靶点选错了"，所以 Phase II 失败率**短期内看起来更难改善**——剥掉了一层可修的问题，露出了不可修的那层。

时间判断 这类问题可以自动裁判（能和 MD、实验对比，有定量误差指标），属于 AI 会碾压的那一类。**乐观** 2027 年底：常见球状蛋白的 $\Delta\Delta G$ 达"实验可替代"精度（ <0.5 kcal/mol）并进入药企标准流程。

反方观点与不确定性 "1 kcal/mol"可能是在容易的子集上测的（ Δ 未核实 BioEmu 在膜蛋白、大型变构机器、糖基化蛋白等困难类别上的表现）。生成模型学的是训练分布不是物理，分布外可能自信地错，而"知道自己不知道"还没解决。

信号 药企把构象集合预测写进标准决策流程而非当探索性工具；出现针对动力学的前瞻性盲测（CASP 增设构象集合赛道是强信号）；精度从 1 跨到 0.3 kcal/mol；隐藏口袋驱动的药物进入临床并且**成功**；反向信号是 2027 年仍在同一批公开蛋白质上刷同一批指标。

来源：Abramson et al., *Nature* 630:493–500 (2024), DOI 10.1038/s41586-024-07487-w; Lewis, Hempel, Jiménez-Luna et al., "Scalable emulation of protein equilibrium ensembles with generative deep learning," *Science* (2025), DOI 10.1126/science.adv9817; Bryngelson & Wolynes, *PNAS* 84:7524–7528 (1987)。

20.3 问题 2：从头设计蛋白质—binder、酶，以及"没有打分函数"这个真瓶颈

一句话 我们已经能从零设计出结合指定分子、甚至催化指定反应的全新蛋白质，但成功率只有百分之几到百分之几十，瓶颈是**无法在计算机里判断一个设计好不好**，只能大量合成、大量试——这是实验吞吐问题，和数学完全无关。

背景补课 从头设计 (de novo design) 是先说要什么功能，再算出一条从未在自然界出现过的序列（对比传统的定向进化：随机突变 + 筛选）。两类目标难度差一个数量级：**binder（结合蛋白）**要专一地结合指定目标，做的是在界面上把形状和电荷配好，现在相当成熟；**酶**难得多，因为催化不是"结合得紧"，而是**对过渡态的稳定化强于对底物和产物的稳定化**——催化剂的工作是让"半路上那个扭曲的、短命的构型"坐得比底物更舒服，如果口袋对底物太友好，底物就不想变化（"底物陷阱"）。所以要把几个催化残基摆在特定位置和取向上，误差容忍度约**0.5–1 埃和十几度**，而整个骨架在室温下一直在抖，振幅比这还大。技术路线是扩散模型：Baker 实验室（蛋白质设计研究所 IPD）的 **RFdiffusion** 把图像生成的扩散模型搬到蛋白质骨架上，从噪声一步步去噪，并可**条件化**（"必须把这三个残基摆在这些坐标上"），再用 ProteinMPNN 填序列。

2025 年的两个结果，看数字就知道瓶颈在哪。 (a) 设计出**丝氨酸水解酶**[近期发现：Lauko, Pellock et al., *Science* 2025]：晶体结构与设计模型的 C α RMSD **小于 1 埃**（想造的形状确实造出来了），拿到**五种自然界没有的折叠**，催化效率最高到 $2.2 \times 10^7 \text{ M}^{-1}\text{s}^{-1}$ 量级（ Δ 搜索结果里指数被截断，引用前查原文）；**关键数字：第一轮只有 1.6% 的设计有任何催化活性。** (b) **RFdiffusion2**[近期发现，IPD 2025-04 公告]：输入从"原子坐标"放松到"我要的化学转化"，模型自己决定活性位点怎么摆；在新建的 41 个酶设计基准上**全部解出**，此前最好的工具只解 16 个；湿实验对 5 种反应造出有活性的酶，**每个案例测试不到 100 个设计**。 Δ IPD 公告页没列局限性，具体数字需查 bioRxiv 预印本。

读这两组数字的正确方式："1.6% 有活性"加"每案例测 <100 个设计"就是全部故事：**设计算法的产出是一堆候选，而你无法排序**。只能合成几十到几百个，再在湿实验里看哪个活。所以整个领域的速度 = **合成和测试的吞吐量**。

为什么重要 2024 年诺贝尔化学奖一半给 David Baker（计算蛋白质设计）[已确立]。

卡在哪：瓶颈是不是数学？完全不是数学。瓶颈是 (1) 实验吞吐，(2) 缺少计算 oracle，而 (2) 的根源是问题 1 的自由能计算。 无法给设计打分排序属于物理/算法（= 问题 1），证据是 1.6% 的首轮命中率；吞吐属于实验，"每案例 <100 个设计"就是吞吐上限的直接体现；骨架生成已基本解决（41/41 全解）；催化循环（多步、辅因子、底物进出）是概念瓶颈；**数学/证明不是瓶颈，这里没有待证明的陈述。**

AI 能做什么 (a) 数学/证明能力：几乎无关。 唯一可形式化的角度是"能不能给一个设计'最低活性有某个下界'这类带保证的陈述"——目前完全不能，而且可能不可形式化（蛋白质在细胞里的行为依赖太多无法建模的上下文）。这是生物学里 A 类问题稀缺的典型例子。**(b) 其他能力：全部杠杆都在这里。** 一是**生成式设计本身**（RFdiffusion / RFdiffusion2 / ProteinMPNN / ESM 系

列)，已在用、已有效。二是**自动化实验室**，这可能是最被低估的一条线：OpenAI × Ginkgo (2026-02) 让 GPT-5 自主设计无细胞蛋白合成的反应配方，由机器人云实验室执行，6 轮闭环、36,000 多个配方、580 块板，每克蛋白成本降 40%、产量升 27% [近期发现] (Δ 发表状态不清楚)。它说明"实验吞吐"这个瓶颈本身可以被 AI 攻击；如果同样的闭环用来合成和测试设计出的蛋白，"每个案例只能测不到 100 个设计"的限制会松开一到两个数量级。三是**主动学习闭环**：模型提议 → 机器人合成测试 → 数据回流训练，把"缺打分函数"变成"用实验当打分函数，而且便宜到用得起"。

如果解决：一阶影响 从"我要一个结合 X 的蛋白质"到"手上有能用的分子"从几个月变成几天，成功率从个位数百分比到几十个百分点；抗体的大部分用途被更小更稳定更便宜的设计蛋白替代[推测]；自然界没有的工业反应变得可设计；诊断试剂、生物传感器、自组装蛋白纳米结构。

如果解决：二阶影响 制造业的化学部分开始"生物化"：很多高温高压催化过程可以在常温常压用酶做，而化工行业占全球能源消耗约 10% 量级。**问题 3、4 的工具箱被填满**：能设计蛋白质就能做任意的细胞内探针、开关、记录器，直接加速虚拟细胞需要的数据生成。

时间判断 这个领域有**自动裁判**（湿实验）所以迭代快，但裁判**很贵**，所以速度由实验成本而不是 AI 能力曲线决定。**乐观** 2027 年底：binder 设计"按需交付"（给靶点，一周内给出纳摩尔亲和力和设计，成功率 >50%），单步酶命中率 20–30%。

反方观点与不确定性 "41/41 全解"可能是基准太容易——基准是团队自己建的，难度校准是老问题，应等独立盲测。"有活性"离"有用"很远：设计的酶催化效率通常比自然酶低 10^3 – 10^6 倍，而缩小这个差距历史上主要靠定向进化（即还是实验）。

信号 **独立盲测**（类似 CASP 的设计挑战赛，第三方出靶点、第三方做湿实验验证）；**命中率数字公开化**（常规报告"测了 N 个、M 个有活性"而不只报最好的那个）；设计的 binder 进入临床；**云实验室单位成本**（若"合成+测试一个设计蛋白质"从 \$1000 级降到 \$10 级，一切都变了）；**自动化闭环用于设计而非优化**——现在主要在优化连续参数（反应配方），用到"离散设计空间"（哪个序列）上是关键转折。

来源：Lauko, Pellock et al., "Computational design of serine hydrolases," *Science* (2025), PDB 9DEE/9DEF/9DEG；IPD, "Introducing RFdiffusion2" (2025-04)；OpenAI, "GPT-5 lowers protein synthesis cost"。

20.4 问题 3：虚拟细胞（短卡）

目标是一个能回答"如果我敲掉这个基因/加这个药，这个细胞会怎样"的模型：学一个函数 $f(\text{细胞类型, 扰动}) \rightarrow \text{表达变化}$ ，并外推到没见过的扰动和细胞类型（数据来自 Perturb-seq，一个实验同时扰动几千个基因、对每个细胞测约 2 万维的全转录组）。**瓶颈是数据和评测，不是数学**。两个 2025 年的结果把这件事说死了。第一个[近期发现：Ahlmann-Eltze, Huber, Anders, *Nature Methods* 22:1657–1661 (2025), DOI 10.1038/s41592-025-02772-6]测了 7

个模型——5 个单细胞基础模型 (scGPT、scFoundation、scBERT、Geneformer、UCE) + 2 个专门做扰动预测的 (GEARS、CPA)：**双扰动下所有模型的误差都显著高于"把两个单扰动的 log fold change 加起来"这个加性基线**，要检测基因间相互作用 (epistasis) 时**没有一个打得过"预测没有变化"**；单扰动、未见过的基因下也没有模型持续超过均值基线或简单线性模型，而且**用基础模型的基因嵌入喂一个线性模型，效果追平或超过这些模型自己的解码器**。作者结论是预测"没做过的实验"仍然"遥不可及"，其自述限制是只用了 4 个数据集、全部来自癌细胞系。

第二个结果是**评测指标被刷爆**：Arc Institute 第一届 Virtual Cell Challenge 新生成 30 万个 H1 人胚胎干细胞、300 个遗传扰动，**1,200 多队提交**[近期发现]。评分是三个指标的合成，而其中 MAE 这一项**没有一个模型超过基线**，组委会又把惩罚**截断在 0**——于是"做得更差"不被惩罚，MAE 实际上**停止影响优化**；有参赛者把模型直接命名为 "**Leaderboard Hacker**"。另一个发现是全基因 Pearson 相关这个至今仍被广泛报告的指标，在"预测没有变化"的平凡模型上取到最大值。Arc 自己总结第一年暴露了"模型精度、指标设计、生物学泛化"三方面差距，2026 年改成零样本（不发训练集）。△ 这些批评性分析大部分来自参赛者的 Substack 和博客，不是同行评议的分析。

关键的解读是：这不说明"深度学习没用"，而说明现在的数据里没有足够的可学习结构——加性基线难败是因为生物学很多时候真的近似可加，而非可加的部分稀疏、依赖上下文，在现有数据量下无法和噪声区分。这是干净的统计问题，不是模型容量问题，所以"AI 解决数学"对这张卡几乎没有帮助；真正需要的是 10 倍的数据、有因果设计的数据（按信息增益选扰动而不是随机刷）、以及不能被刷的指标。数学只有一小块真实角色（因果可识别性、最优扰动设计、以及"能不能设计一个让'预测不变'不是最优解的指标"——后者可形式化成机制设计问题，而且**直接对应 AI 评测设计**[推测]）；算力不是瓶颈。资源正在涌入：Biohub 的 Virtual Biology Initiative 2026 年 10 月扩展到总计 **18 亿美元**，而科学负责人 Alex Rives 说现有数据覆盖约 10 亿个细胞、要让模型有用还需再大一个数量级（△ 18 亿这个数字只见于二手报道，Biohub 官方页面上没有金额）。**中心时间判断 2030 年**：对特定细胞类型 + 特定通路可靠，跨细胞类型泛化仍差，"虚拟细胞"作为通用工具还不存在——这张卡最不依赖 AI 数学曲线、最依赖数据生成速率。最该追的信号是有人用 Ahlmann-Eltze 的协议独立重测新一代模型并且赢了，以及零样本赛的结果；反方意见里最值得认真对待的是"转录组可能就是不够"（mRNA 是嘈杂、有延迟的代理变量，若如此则这个任务本身定位错了）。**来源**：Ahlmann-Eltze, Huber, Anders, *Nature Methods* 22:1657–1661 (2025), DOI 10.1038/s41592-025-02772-6; Bunne et al., *Cell* 187(25):7045–7063 (2024), DOI 10.1016/j.cell.2024.11.015; Arc Institute, Virtual Cell Challenge 2025/2026, *Cell* 评论 DOI 10.1016/j.cell.2025.06.008。

20.5 问题 4：基因组如何编码一个身体（短卡）

一个受精卵里的 30 亿个碱基对，怎么就长成了一个有手有脚有大脑的身体？这是生物学最大的 **B 类问题**。编码序列只占基因组约 1.5%，剩下的大部分是**调控序列：转录因子 (TF)** 结合特定的 DNA 短序列（通常 6–12 个碱基）后招募或阻止 RNA 聚合酶，而转录因子本身也是基

因编码的，于是得到一个**基因调控网络（GRN）**；增强子可以在几千到几百万个碱基之外通过 DNA 折叠"凑过来"接触启动子。经典案例是果蝇 *even-skipped* 的 stripe 2 增强子[已确立]：约 500 bp 上有激活因子 Bicoid、Hunchback 和抑制因子 Giant、Krüppel 的结合位点，逻辑是"夹逼"——宽的激活区域被前后各切一刀，剩下的窄带就是第二条条纹。而 Bicoid 浓度沿胚胎指数衰减，在 stripe 2 那约 20 μm （3–4 个细胞）宽度上**只降了 18%：一个 18% 的输入浓度差要变成"基因全开/全关"的输出**，这需要极高的非线性，而协同效应的参数几乎无法独立测量。

数学不是瓶颈，概念是。工具（动力系统、反应–扩散、随机过程、布尔网络）都有且有余量，缺的是"该用哪个、该测什么"：不知道发育程序的正确抽象层次（基因网络？细胞间信号的反应–扩散？机械力？），不知道该测什么（要约束模型需要每个细胞每个时刻的每个 TF 浓度，而我们测的是固定下来的细胞群的平均 mRNA），也不知道成功的判据（预测表达模式？形态？突变后的表型？难度差几个数量级）。鲁棒性（Waddington 的 canalization）本身就神秘，但**这一块可以形式化**——它是动力系统的结构稳定性问题，是"B 类转 A 类"的候选。

2026 年的 state of the art 是 DeepMind 的 **AlphaGenome**[近期发现：Avsec, Latysheva et al., *Nature* 649 (2026), DOI 10.1038/s41586-025-10014-0]：输入最长 100 万个碱基对，一次调用同时预测基因表达、剪接、染色质可及性、TF 结合、三维接触等信号；在变异效应预测的 **26 项评测里 25 项匹配或超过此前最好的专用模型**（*Nature* 新闻稿口径；2025 年 6 月的预印本说的是 24/26—— $\triangle$ 差异原因未查清）。**作者自己列的两条局限恰好最要紧**：准确捕捉**远距离**调控元件（例如 10 万碱基之外）仍是局限；没有针对个人基因组预测做验证。而疾病相关的常见变异约 **90% 落在非编码区**[已确立]且常常离它影响的基因很远——这正是现代遗传学最大的解释缺口。另一条线是基因组语言模型：Arc Institute 的 Evo 系列能**生成**基因组序列，2025 年 9 月以噬菌体 ΦX174 为模板生成数千个候选，筛到 302 个合成、成功组装 285 个，其中 **16 个有活性**（5.6% 命中率；但在"与模板序列同一性 $\geq 98\%$ "的子集里活性率高达 46%——这个对比说明模型主要在模板附近微调，不是真正的从头设计）[近期发现：bioRxiv 10.1101/2025.09.12.675911]。 $\triangle$ 有二手报道说这项工作 2026 年 8 月发在 *Science*，无法确认；46% vs 5.6% 来自二手报道。

方法论观察：AlphaGenome 这类模型的成功方式是**绕过机制**——它不建 GRN，它学"序列 $\rightarrow$ 信号"的统计映射，在预测上有效、在理解上无效。在生物学里，**AI 正在把 B 类问题绕过去而不是解决掉：它给你一个预言机（oracle）而不是一个理论**。中心时间判断是 2032 年：预测模型在特定组织和距离范围内可用，但"发育程序"作为一个**理论**仍不存在；开放问题解出率曲线对这张卡**完全不适用**，因为这里没有"问题陈述"。**来源**：AlphaGenome（上引）；

Small, Blair, Levine, *EMBO J* 11:4047–4057 (1992)；Waddington, *The Strategy of the Genes* (1957)；McCarty, "AI-Designed Phages," *Asimov Press* (2025-09-17), DOI 10.62211/21er-45fg。

20.6 问题 5：临床失败率（短卡）

药物开发的算术[已确立：BIO / Informa / QLS, *Clinical Development Success Rates 2011–2020*, 9,704 个临床项目、12,728 个阶段转换]：**Phase I → 批准的总概率 7.9%**（上一版 2006–2015 是 9.6%），**最窄的一步是 Phase II → Phase III 的 28.9%**；用了患者预筛生物标志物的项目是 15.9%，约为基线两倍。失败原因里**临床效能不足占 40–50%**（“在人身上没效果”），毒性 30%，药物性质差 10–15%[已确立：Sun, Gao, Hu, Zhou, *Acta Pharm Sin B* 12(7):3049–3062 (2022), DOI 10.1016/j.apsb.2022.02.002]。另一条线索是人类遗传学证据：有遗传学支持的机制成功概率是没有的 **2.6 倍**[已确立：Minikel et al., *Nature* 629 (2024), DOI 10.1038/s41586-024-07316-0]。这个 2.6 倍加上生物标志物的 2 倍合起来给出一个清晰的因果故事：**临床失败的主因是我们不知道这个靶点在这个疾病的这些病人身上是不是真的因果驱动因素。**

AI 的成绩单精确地印证了这一点：AI 发现的分子在 **Phase I 成功率 80–90%**（人类发现的 40–65%），但到 **Phase II 掉回约 40%**，和行业平均持平[近期发现：Jayatunga et al., *Drug Discovery Today* (2024) — △ 只看到二手报道，作者自标“样本量有限”]。**这个差别说明 AI 现在解决的是“分子好不好”（化学问题），没解决“靶点对不对”（生物学问题）。**所以这张卡的瓶颈完全不是数学：是靶点因果性的生物学认识（= 问题 3、4）、人体试验不可压缩的时间和样本、以及制度（贝叶斯自适应、平台试验、合成对照这些方法 1990s 就有，监管采纳慢——**瓶颈不是数学不够，是制度不接受**）。数学里唯一真有内容的角落是替代终点的有效性（Prentice 准则给了充分条件，但现实中几乎没有替代终点满足它，属陈述清楚、数学上困难的 A 类问题），但它不是限速步。

最硬的一条减速论证是时间常数：假设 AI 从今天（2026-10）起让靶点选择变得完美，新靶点进入先导化合物优化 1–2 年、临床前到 IND 1–2 年、Phase I 1–1.5 年、Phase II 2–3 年、Phase III 3–5 年，**合计约 8–13 年**；所以“AI 改善了 Phase II 成功率”这个命题**最早要到 2034 年左右才有统计上可信的证据**，而且这个论证**不依赖任何关于 AI 能力的假设**。**中心时间判断 2035 年：**整体成功率从 7.9% 升到 10–12%，Phase I 的优势已确立，Phase II 有改善但不剧烈——**在医学上，AI 能力的指数曲线被制度的线性时间常数吃掉了**。两件事值得单独记住：**临床试验是 AI-for-science 最严格的裁判**，因为它不能被刷分（双盲、预注册、监管审核），所以临床成功率是“AI 到底有没有真的在加速科学”最可信的单一指标；而**临床试验制度（强制登记、CONSORT 报告规范、独立数据监察）正是 AI eval 社区在重新发明的东西**，它的失败模式（p-hacking、选择性发表、终点转换）会精确重演，对策可以直接搬运[推测]。最强的反方论证是：过去十多年的技术进步没让这个数字变好，反而变差（2006–2015 年的 9.6% → 2011–2020 年的 7.9%），这是对“这次不一样”主张的最强反驳；△ 截至目前没有“AI 发现的药”完成完整的 Phase III 并获批。**来源：**BIO / Informa / QLS, *Clinical Development Success Rates 2011–2020*；Sun, Gao, Hu, Zhou, *Acta Pharm Sin B* 12(7):3049–3062 (2022), DOI 10.1016/j.apsb.2022.02.002；Minikel et al., *Nature* 629 (2024), DOI 10.1038/s41586-024-07316-0；△ Jayatunga et al., *Drug Discovery Today* (2024)（仅二手）。

20.7 问题 6：大脑如何计算与学习——以及它和 AI 可解释性的关系

一句话 我们现在有了完整的果蝇连接组（139,255 个神经元）和一立方毫米小鼠皮层的"连线图 + 活动记录"，但我们仍然不能从连线图推出算法——而这个失败对 mechanistic interpretability 的目标设定有直接含义。

背景补课 问题一：信用分配 (credit assignment)。 大脑有约 8.6×10^{10} 个神经元、 10^{14} – 10^{15} 个突触，学习就是调整突触强度，而一个深层的突触只能看到前后两个神经元的活动，**看不到整个动物的行为结果**。反向传播解决了人工网络里的这个问题，但在生物学上有明确障碍[已确立，综述见 Lillicrap et al., *Nat Rev Neurosci* 21:335–346 (2020)]：**权重传输**（反向通路要求用前向权重矩阵的**转置**，而生物突触是单向的）、**时间上的分离**（要求"前向算完 → 反向传播 → 更新"，需要全局时钟，而大脑连续运行）、**非局部性**（权重更新需要全局误差信号，但突触可塑性是局部的）。候选解答各有问题：**反馈对齐**（用随机的固定反向权重，小网络能工作，大网络和困难任务明显差于反向传播）；**预测编码**[Rao & Ballard, *Nat Neurosci* 2:79–87 (1999)]（每层向下预测下一层活动、只把**预测误差**向上传，于是误差信号在局部就有了；极有影响力，但它作为学习算法的性能和作为大脑描述的准确性都还有争议）；**"先推断活动，再改权重"**（prospective configuration；△ 本轮只核实到作者、期刊、卷期页 Song, Millidge, Salvatori, Lukasiewicz, Bogacz, *Nat Neurosci* 27(2):348–358 (2024)，**标题和具体内容未核实**）；**平衡传播**（能量基础网络里梯度可从两个平衡态的差里局部读出，数学漂亮、生物学证据薄）；**三因子可塑性规则**（局部 Hebbian 项 × 全局神经调质信号，**生物学证据最强**，但只给你"奖励调制的 Hebbian 学习"，信息量比梯度少很多，解释不了大脑学会复杂的内部表示）。**所以现状是五六个候选框架并存、每个都有部分证据、没有一个被确立——教科书级的 B 类问题：不是"缺证明"，是"不知道该写下哪个方程"。**

问题二：拿到完整的连线图够不够？ 这有一个四十年的、决定性的实验答案。秀丽隐杆线虫的完整连接组 **1986 年**就发表了[已确立：White, Southgate, Thomson, Brenner, *Phil. Trans. R. Soc. Lond. B* 314:1–340 (1986)]：302 个神经元、约 7,000 个突触，每一个都标注好了。**四十年后，我们仍然不能从这个连接组预测线虫的行为——因为同一个连线图配上不同的突触强度、神经调质状态、离子通道组成会产生完全不同的动力学：连接组给了你"图的拓扑"，没给你"边的权重"和"节点的传递函数"。** 2024–2025 年规模上去了但这个问题没解决：**果蝇全脑连接组**[已确立：Dorkenwald et al., *Nature* (2024-10-02)，九篇论文的 package]有 **139,255 个神经元**、约 5×10^7 个化学突触，建构方式是 **2,100 万张电镜图像 → AI 自动分割 → 人工校对**；**MICrONS**[已确立：*Nature* 640:435–447 (2025), DOI 10.1038/s41586-025-08790-w]做了 $1.4 \times 0.87 \times 0.84$ mm 的小鼠视皮层，约 **20 万个细胞、5.2 亿个突触、4 公里轴突**（△ 不同来源数字不一致，另有 NIH 图注说重建了 12 万个细胞），**关键创新是先记录功能再做结构——在小鼠活着时用钙成像记录了 76,000 个细胞看自然场景视频的活动，然后才固定、切片、电镜重建。**

用连接组约束的模型是最有意思的一步。全脑 LIF 模型[近期发现：Shiu et al., *Nature* 634 (2024), DOI 10.1038/s41586-024-07763-9]用连线 + 神经递质身份建整脑漏电积分–发放模型，**没有拟合任何参数**（突触强度直接取自突触计数），却能**准确预测**激活糖/水感受味觉神经

元后哪些下游神经元响应、哪些是启动取食所必需的，并用光遗传学和行为实验验证了。连接组约束 + 深度学习拟合[近期发现：Lappalainen, Tschopp et al., *Nature* 634:1132–1140 (2024), DOI 10.1038/s41586-024-07939-3]拿果蝇视叶 64 种细胞类型的实测连接当结构、用深度学习拟合未知的单神经元和单突触参数（训练目标是"检测视觉运动"），模型预测的神经活动与 26 项独立研究的实验测量相符。"数字孪生"[近期发现：Wang et al., *Nature* (2025), DOI 10.1038/s41586-025-08829-y]用真实小鼠看电影的记录训练，能预测上万个神经元对没见过的视频和图像的反应，共享核训练好后能迁移到新个体，有时只需 4 分钟的新记录；更惊人的是这个纯功能模型还能反推解剖——它预测了数千个神经元的细胞类型、位置和连接，并用同一只小鼠的电镜数据验证。三项工作的共同信息：连接组本身不给你算法，但连接组作为约束让模型极大地更可信、更数据高效——这是"结构先验 + 学习"的胜利，不是"从结构直接读出算法"的胜利。

为什么重要 认识论上这是"物质怎么产生心智"的问题；医学上精神疾病和神经退行性疾病的治疗长期卡在"不知道回路层面出了什么问题"；对 AI 的影响要小心——历史上神经科学给 AI 的贡献是架构层面的粗粒度启发（卷积网络 ← 简单/复杂细胞；强化学习 ← 多巴胺的 TD 信号），不是细节照搬。

卡在哪：瓶颈是不是数学？ 概念瓶颈为主（不知道该写下什么），数学是第二位的真实瓶颈（我们缺理论），数据是第三位。这是最纯的 B 类问题，但它有一个罕见性质：B 类成分有可能被转化成 A 类。不知道大脑用哪种学习规则是概念瓶颈（五六个框架并存四十年）；缺少"什么样的学习规则能被局部实现"的理论是可形式化的数学瓶颈；连线图不等于算法是概念 + 数据；突触强度和神经调质状态不可测是技术瓶颈（电镜给形态不给强度，在体记录给活动不给全部连接）。

AI 能做什么 (a) 数学/证明：本节里 AI 数学最有可能真帮上忙的第二名（第一是问题 1）。学习规则的不可能性/等价性定理；动力系统的可识别性（从有限活动记录能不能唯一确定回路参数？这是系统辨识问题，有可证明的内容，而且直接告诉实验家"再记录也没用，必须换测量方式"）；表示的等价类（两个网络什么时候算"实现了同一个算法"？这在神经科学的跨个体/跨物种比较和 AI 可解释性的"两个模型是否学到同一个电路"里是同一个问题，而现在的工具 RSA、CCA、CKA 都是启发式的、缺理论基础）。(b) 其他能力：连接组重建本身就是 AI 的成果（果蝇连接组的初始分割是 AI 做的，人只做校对；没有深度学习这些数据集不存在——这是 AI 对科学最无争议的贡献形式）；数字孪生做在体实验的替代（4 分钟新记录适配新个体，然后在计算机里做任意多的刺激实验，把"每个实验要一只小鼠和几周"变成"几秒钟"）；连接组约束的模型拟合；自动化的假设生成和文献整合。

如果解决：一阶影响 知道大脑用什么学习算法 → 精神疾病的回路层面理解 → 真正的机制性治疗（而非现在的"调整神经递质水平"）；神经假体和脑机接口性能跃升（知道该写入什么信号）；对 AI 可能有架构启发（但历史上这个方向的贡献被高估）。

如果解决：二阶影响 1. 它改变 mechanistic interpretability 的目标设定。

系统	规模	我们拥有什么	我们能做什么
<i>C. elegans</i> (1986–)	302 神经元 / 7,000 突触	完整连接组、完整细胞谱系、完整基因组	不能 从连接组预测行为
果蝇 (2024–)	139,255 神经元 / 5×10^7 突触	完整连接组 + 递质身份	在 两条 研究最透的回路上能做可验证预测
小鼠 V1 1mm ³ (2025–)	2×10^5 细胞 / 5.2×10^8 突触	连接组 + 同批细胞的功能记录	能预测活动 (数字孪生), 不能 说出算法
大型语言模型	10^{11} – 10^{12} 参数	全部权重、全部激活、无限次干预、可以重训	SAE 特征、部分电路、行为层面的因果干预

第四行是好消息：人工网络在可观测性上**完胜**生物大脑——权重能全读、激活能全记、干预无代价、可以重训一万次换随机种子、可以消融任意子集；所以"我们连 302 个神经元的线虫都不理解，所以永远理解不了 LLM"**是错的推论**，两者的认识论条件完全不同。**但前三行是坏消息，而坏消息更具体：**它说明"拥有完整的结构描述"并不自动产生"理解"，理解需要一个理论——一组关于"该看哪些量、该做哪些抽象"的判断。这正好对应 A 类/B 类区分：从"给定一个模型，计算它的数学性质"（A 类，AI 会碾压）到"判断这个数学量和安全有什么关系"（B 类，人类主要承担）。连接组学是这个区分在另一个领域的四十年自然实验，而结果是：**B 类部分没有被数据量的增长自动解决。**

2. Jonas & Kording 的微处理器论文是这两个领域之间最锐利的桥。2017 年他们拿一个 MOS 6502 微处理器（我们**完全**知道它的电路和功能），对它施加神经科学的标准分析方法——病变研究（切断单个晶体管看哪个游戏坏掉）、单元记录、相关分析、降维——然后问这些方法能让你搞懂 6502 吗？**答案是不能：**方法会给出一堆统计显著但误导的结论（"这个晶体管是《大金刚》晶体管"）[已确立：PLOS Comput Biol 13(1):e1005268, DOI 10.1371/journal.pcbi.1005268]。这篇论文对 AI 可解释性的含义比对神经科学更大，因为**AI 可解释性正在用同一批方法**（消融、探针、相关分析、降维）；它不是说这些方法没用，而是说**它们需要一个理论框架来解释输出，否则会系统性地产生虚假的机制故事。****3. 几个具体的跨领域问题：**连接组学发展出的**验证手段**（例如用光遗传学验证 LIF 模型的预测）能不能搬到可解释性？连接组学的"细胞类型"分类和可解释性的"特征"分类在数学上是同一类问题（在高维表示上找离散结构），方法能不能互通？最重要的是 Lappalainen 式的"用结构当约束、用学习填参数"反过来用在可解释性上会是什么（假设一个电路结构、拟合参数，看能不能预测模型在分布外的行为）？另外神经科学有一套关于"什么算一个好的机制解释"的哲学文献（Craver、Bechtel），可解释性社区基本没引用过。

时间判断 乐观 2029 年果蝇的几条主要行为（取食、梳理、导航、求偶）有端到端可验证的回路模型，"学习规则"问题在**无脊椎动物**上有一个被广泛接受的答案；**中心** 2033 年小鼠全脑连接组完成或接近完成、皮层局部回路有数字孪生，但"大脑的学习算法"仍无共识（10–15 年的时间表 + 人工校对是硬瓶颈 + 概念问题不随数据自动解决）；**悲观** 2040 年后数据越来越多、理论没有进展，领域变成"越来越好的预言机，没有理解"（B 类问题的默认结局，*C. elegans*

的四十年是先例)。这是**"B 类问题落得慢"**的教科书案例：开放问题解出率曲线对这里**完全不适用**；有用的是 METR 曲线的间接推论——当 AI 能自主做"人类专家几个月"的研究任务（2027 年中–2028 年），它可能开始承担"遍历假设空间"的工作，而"大脑用什么学习规则"恰好是一个**假设空间不大但每个假设验证很贵的问题**[推测]。

反方观点与不确定性 "连接组不够"的反驳的反驳：也许 *C. elegans* 的失败是因为 302 个神经元太少（没有统计规律可用），而 10^5 个神经元的果蝇反而更容易（可以用群体层面的统计描述），Shiu 等人的全脑模型在不拟合任何参数的情况下做出可验证预测支持这个乐观看法——**这是本卡最重要的不确定性**。"也许没有单一的学习规则"：大脑不同区域、不同发育阶段可能用不同机制，那问题本身就提错了。

信号 全脑模型的前瞻性预测成功率（Shiu 式的模型在**没有专门研究过的回路**上做出预测然后被实验证实，这是最干净的指标）；**"学习规则"的实验判决**（出现一个能在体内区分预测编码、反馈对齐、三因子规则的实验）；**人工校对的自动化程度**（若分子条形码路线成功，小鼠全脑的时间表会大幅提前）；**小鼠全脑的 mm^3 累积曲线**（ $1 \text{ mm}^3 \rightarrow 10 \text{ mm}^3$ 项目 $\rightarrow 500 \text{ mm}^3$ ，看斜率）；**跨领域引用**（mechanistic interpretability 的论文开始引用连接组学的方法论文献——现在基本没有，这是明显的空隙）；反向信号是 2030 年主要成果仍是"更大的连接组 + 更好的数字孪生"而没有新理论框架。

来源：White et al., *Phil. Trans. R. Soc. Lond. B* 314:1–340 (1986)；Dorkenwald et al., *Nature* (2024-10-02)；MICrONS Consortium, *Nature* 640:435–447 (2025), DOI 10.1038/s41586-025-08790-w。

20.8 问题 7：衰老（短卡）

△ **本卡的核实状态**：这张卡里的引文（DOI 都给了）在本轮**没有重新核实**，来自知识库而非本轮检索。请把每条引文都当作"待核对"，尤其是 2025–2026 的部分。

衰老是人类疾病负担的最大单一风险因子，但这个领域被三件事卡住：**没有因果理论、没有被验证的读数、制度上衰老不是一个适应症**——三件事里没有一件是数学问题。最有用的操作定义来自死亡率：**Gompertz 定律**[已确立，1825]说成年人的年死亡率随年龄近似指数上升，人类的倍增时间约 **8 年**（若 30 岁年死亡率 0.1%，则 38 岁 0.2%、46 岁 0.4%、70 岁约 3.2%、86 岁约 13%）；小鼠的死亡率倍增时间约 0.3 年、人类约 8 年，差约 27 倍，这正是寿命差异的来源，而这个定义的坏处是**你需要让一个种群活到死才能测**。2013 年 López-Otín 等人提出衰老的 9 个标志、2023 年扩展到 **12 个**[已确立： *Cell* 186(2):243–278 (2023), DOI 10.1016/j.cell.2022.11.001 — △ 未核实]，但这个**框架不是因果的**：它是一个清单不是机制图，12 个标志互相关联而我们**不知道哪个在上游**。两大对立框架——**损伤累积论**（衰老是随机损伤的累积，没有程序只有熵，推论是不可逆只能减缓）和**程序/信息论**（衰老是调控信息的有序丧失，细胞"忘记"了自己该是什么类型，推论是部分可逆）——导出的干预策略完全不同，而**现有数据无法判决**。这是本卡最核心的事实。

瓶颈是读数，而且是一个循环依赖。金标准是让一群动物或人活到死比较生存曲线（小鼠 3–4 年，人几十年），你想要的是一个 6 个月内能测、而且**因果地**预测寿命的指标——这就是替代终点问题，和问题 5 完全同构。衰老领域的替代终点**都没有通过因果验证**：Horvath 2013 年用 353 个 CpG 位点的甲基化做线性回归能预测年龄、误差约 3.6 岁且跨组织通用[已确立：*Genome Biology* 14:R115, DOI 10.1186/gb-2013-14-10-r115]，但时钟是用**年龄**训练的，所以它测的是"和年龄相关的东西"，不一定是"导致衰老的东西"——一个干预可以把时钟拨回去而不延长寿命。而要验证时钟是不是有效的替代终点，你需要大量"干预 → 时钟变化 → 实际寿命"的三元组，**而产生这些三元组需要跑完整的寿命实验**；这个循环依赖正是领域真正卡住的地方。真正干净的证据来自 NIA 的 **Interventions Testing Program (ITP)**：三个独立地点、遗传异质的小鼠、双盲、预注册，**而且它公布失败**——结果是绝大多数候选化合物无效，雷帕霉素是少数明确成功的之一[已确立：Harrison et al., *Nature* 460:392–395 (2009), DOI 10.1038/nature08221 — △ 未核实]。**ITP 是这个领域最被低估的东西**，它是衰老研究的"临床试验制度"，而领域里绝大多数令人兴奋的报道都不是通过它验证的。

AI 的最大杠杆是"读数"，而这里有一个真实的风险。从影像（视网膜照片、MRI）、组学、甚至语音和步态里学"生物年龄"是标准监督学习，AI 很擅长；但这只解决了**"更好的相关指标"**，**没解决"因果验证的替代终点"**——如果领域误以为前者等于后者，它会浪费十年，而这正在发生。AI 数学能力在这里几乎没有作用（唯一可形式化的角落是替代终点有效性的统计理论，与问题 5 共享）。中心时间判断是 2035 年：若干个针对**具体老年病**的干预成功（而不是针对"衰老"本身），因果理论仍然缺失；这张卡和 AI 能力曲线的关系最弱——**即使 AI 在 2028 年能做"人类专家一年"的任务，也不能让小鼠活得更快**。二阶效应里最值得注意的两条：延寿干预若昂贵会成为最尖锐的不平等形式（现在富国和穷国的预期寿命差就有 30 年以上）；这个领域的"炒作–证据"比是本节里最差的，所以它是一个有用的校准练习场——学会区分"ITP 验证过的"和"小鼠 n=8 加一个 TED 演讲"，是评估任何 AI-for-science 主张的通用技能。**反方观点**：可能根本没有"衰老的机制"可解——如果衰老是数千个独立损伤过程的叠加，那不存在总开关，它就不是一个问题而是一万个问题。**来源**（△ 均未在本轮核实）：López-Otín et al., *Cell* 186(2):243–278 (2023), DOI 10.1016/j.cell.2022.11.001；Yang et al., *Cell* 186(2):305–326 (2023), DOI 10.1016/j.cell.2022.12.027（领域内有争议）；Ocampo et al., *Cell* 167(7):1719–1733 (2016)；Horvath, *Genome Biology* 14:R115 (2013)；Harrison et al., *Nature* 460:392–395 (2009)；NIA ITP。

20.9 问题 8：生物安全与两用性——治理层面

一句话 前面七张卡里的能力提升是**对称的**：能设计有益蛋白的模型也能设计有害的，能生成基因组的模型也能生成危险的；而这张卡的瓶颈 **100% 是制度**——美国至今没有强制的核酸合成筛查立法，行政令要求的框架更新逾期一年多未完成。

背景补课 两用 (dual-use) 指同一项技术既能用于有益目的也能用于伤害，而生命科学的两用问题比其他领域尖锐，因为**生物威胁可以自我复制**。理解整个问题的关键是**三道门槛**：**信息/知识门槛**（知道该做什么）、**物质获取门槛**（拿到材料）、**实施能力门槛**（真的能在实验室里做出

来，需要大量"手上的"技能即 tacit knowledge，传统上只能通过几年学徒式训练获得)；**传统的生物安全共识是第 3 道门槛才是真瓶颈。门槛 1 已经被大幅降低，有量化证据：**Virology Capabilities Test (VCT)[近期发现：SecureBio + Center for AI Safety 等，arXiv:2504.16137]有 322 道多模态题目，覆盖病毒学实验室方案的**排障 (troubleshooting)** 知识——"实验做不出来的时候怎么办"这类恰恰属于 tacit knowledge 的东西，由数十位博士级病毒学家参与构建；**人类基线是有网络访问的专家病毒学家在自己的子领域内平均 22.1%，而 OpenAI o3 得 43.8%，作者称这超过了 94% 的专家即使在他们自己的专长领域内，并建议把"LLM 排障能力"纳入现有的两用生命科学框架。这个结果的重要性在于它攻击的正是第 3 道门槛**（排障知识是实操技能和书本知识之间的桥梁），**而问题 2 的自动化实验室攻击的是第 3 道门槛的另一部分**（AI 自主设计实验、机器人执行，"人工介入基本限于试剂和耗材的准备、装卸"）。把这两条放在一起，**传统共识里"实操技能是真瓶颈"这个假设正在被侵蚀——这是本领域最重要、也最少被清晰表述的趋势。**

门槛 2（物质获取）：筛查机制存在，但对 AI 重设计的序列有漏洞。商业合成公司筛查 DNA 订单的方式是把订的序列和"关注序列"数据库做**序列比对**，相似度高就标记或拒绝（国际基因合成联盟 IGSC 有共享协议）；漏洞的技术根源是**筛查基于序列相似度，而蛋白质的功能由结构决定**（同一功能可以由序列相似度很低的不同序列实现，自然界里这叫远缘同源）。2025 年 10 月的 *Science* 论文证实了这个漏洞并修补了一部分[近期发现：Wittmann, Alexanian, ... Horvitz et al., *Science* 390(6768):82–87 (2025), DOI 10.1126/science.adu8578, 微软研究院 "Paraphrase Project"]：用 3 个开源生成式蛋白质设计模型对 72 个"关注蛋白"（主要是毒素）生成了 76,080 条序列，提交给 4 家筛查软件开发商的系统，结果**数百条潜在危险序列未被标记**；团队开发了补丁，**4 家中有 3 家部署了**，补丁后对"按计算指标判断更可能保留野生型功能"的那批序列，各工具平均检出率达 **97%**，假阳性率没有显著上升。**关键限制必须和这个 97% 一起读：**研究**没有做湿实验验证**，没有人真的测过这些重设计的序列是否保留了功能；NIST 主导的后续研究因此指出"漏洞的真实严重程度不明"，并且结论是**当前的 AI 蛋白设计系统还不能可靠地在"保留活性"和"规避检测"之间同时成功**[近期发现：NIST, "Experimental evaluation of AI-driven protein design risks using safe biological proxies"]。**正确读法：**漏洞是真的（筛查原理上确实可被绕过），但当前的实际风险被这项研究**可能高估了**，而且主要厂商已经打了补丁；这是一个**负责任披露做得很好的案例——发现漏洞、私下通知、开发补丁、部署后再公开**，这个流程本身值得作为模板。

制度现状：这是瓶颈所在。[近期发现，来源：CRS, "Artificial Intelligence and Biosecurity Issues," IF13269, 2026 年 7–9 月版本] **2024 年的《核酸合成筛查框架》只适用于联邦资助的工作**，私营部门靠行业自律；**EO 14292（2025 年 5 月）要求 OSTP 在 90 天内替换 2024 年的筛查框架**，而 2026 年的政策替换了 2024 年关于两用研究的政策、**但没有修订或替换核酸合成筛查框架**，到 2026 年 7 月 CRS 表示**无法确认**这两项政策是否已按行政令要求修订；**没有建立广泛监管权限的联邦立法**，监督依赖"联邦法律 + 联邦指南 + 自我治理"的混合体。**2026 年 6 月**一个由生命科学研究者、AI 公司和生物技术开发者组成的联盟发公开信，要求国会**把合成核酸订单的筛查变成强制性的**并把责任放在 DNA 合成公司身上；微软公开支持加强

筛查规则；Anthropic 2026 年 6 月提出框架，建议政府对前沿开发者在生物武器、网络行动、失控、自动化研发四方面设定义务（△ 具体内容未核实）。前沿实验室这边，Anthropic 2025 年 5 月随 Claude Opus 4 启用 **ASL-3**[已确立]，理由明确是**无法排除** Opus 4 达到 ASL-3 的 CBRN 能力阈值（同时已排除 ASL-4），措施分**部署标准**（Constitutional Classifiers 实时监控输入输出、过滤危险的 CBRN 相关信息，加 bug bounty 和用越狱数据做的合成训练）和**安全标准**（加固内部防御，让模型权重更难被窃取）——这是 RSP 从理论框架变成可操作政策的**第一次实际启用**，也是本节里唯一一个“模型能力直接触发部署限制”的实例。**开源权重这条线**：Evo 2 的预训练数据**排除了感染人类的病毒**，但 Evo 2 **完全开源**，所以原则上可以被微调去设计人类病毒——**这暴露了“训练数据排除”这类防护在开源权重下的根本脆弱性**：排除数据能阻止模型“知道”，但不能阻止别人教它。

为什么重要 它是“AI 能力评估驱动政策”的第一个真实案例：ASL-3 的启用、VCT 被提议纳入两用框架、筛查补丁的部署——这三件事构成了一个完整的“评估 → 发现 → 干预”链条，而这个链条在其他 AI 风险领域（网络、说服、自动化研发）还没建起来。

卡在哪：瓶颈是不是数学？完全不是数学。按重要性：(1) 制度（强制筛查没立法、框架更新逾期），(2) 评估科学（我们不知道怎么测“实际提升了多少风险”），(3) 技术（筛查需要从序列比对升级到结构/功能导向）。其中“不知道怎么测真实风险提升”是最有研究空间的一块：VCT 测的是知识不是端到端能力，而 *Science* 的筛查研究没做湿实验验证。

“对于任何保留蛋白质 P 功能的序列 S，筛查系统 F 都会标记 S。”

这个陈述如果能形式化，就是一个 A 类问题——陈述清楚，缺的是证明（和一个满足它的 F 的构造）；它需要先形式化“保留功能”，这很难但不是不可能（可以用结构相似度 + 活性位点保守性作为代理）。而**如果能构造出这样的 F 并证明它的性质**，筛查就从“军备竞赛”变成“有保证的防线”——这正是 GSAI（guaranteed safe AI，见 §19）那套思路在生物安全上的应用，而且这里的问题比“写出‘无害’的 spec”要**具体得多**，所以更可能成功[推测]。诚实的反面：这可能根本不可行，因为“保留功能”在生物学上无法形式化（功能依赖上下文——同一个蛋白在不同宿主、不同剂量下行为不同）；如果是这样，筛查永远只能是概率性的、靠不断打补丁的防线。

AI 能做什么 (a) 数学/证明：主要就是上面那个“带保证的筛查”的构想，此外是筛查系统的**假阳性/假阴性权衡的理论界**（统计检测问题，有可证明的内容，而且实际上很重要——假阳性太高会让合成公司不用它）。**(b) 其他能力**：**更好的筛查工具**（从序列比对升级到结构预测 + 功能预测；讽刺而正确：**同一批模型既是威胁来源也是防御工具**，这是“防御性加速”/差异化技术发展最清晰的案例）；**能力评估与红队**（VCT 这类评测本身就是 AI 安全的产品，但它测知识不测端到端能力；下一代评测需要测“给定模型协助，一个有基础训练的人能不能完成一个无害代理的复杂流程”——难做但更有效）；**合成订单的异常检测与 KYC**（不只看序列，看订单模式、客户身份、订单组合，是经典的异常检测问题）；**监控与溯源**（给合成产物加分子水印/条形码让产物可追溯）。

如果解决：一阶影响 强制的、技术上有效的全球合成筛查 → 第 2 道门槛恢复；前沿模型的生物能力评估标准化，成为部署前的常规关卡；自动化实验室（云实验室）有和合成公司同等的筛查义务——**这一条目前基本没人在做，而按问题 2 的趋势它会很快变重要。**

如果解决：二阶影响 它为整个 AI 治理提供模板："能力评估 → 阈值 → 部署限制"这个链条如果在生物领域走通，会被搬到网络、说服、自动化研发；反之如果它失败（筛查被证明不可能有效，或立法始终推不动），那"基于能力阈值的治理"这个整体范式会受到严重质疑——**这是本卡最重要的二阶影响，而它很少被这样表述。** 开源权重辩论会在这里决出胜负：Evo 2 的案例（排除训练数据 + 完全开源 = 防护可被微调绕过）是开源权重风险最具体的实例，这个辩论在其他领域证据都更模糊，生物是证据最硬的战场。

时间判断 乐观 2027 年美国通过强制筛查立法、主要云实验室采纳同等义务、结构导向的筛查工具成为标准（2026-06 的跨行业公开信显示产业界已站在同一边，这是立法最有利的条件）；**中心** 2029 年强制筛查在部分司法辖区落地（可能欧盟先于美国）、云实验室义务仍有缺口、评测仍以问答为主（EO 14292 逾期一年多未执行说明行政路径不通，需要立法，而立法慢）；**悲观** 2030 年仍是自愿筛查 + 补丁式防御，出现一次实质事件后才仓促立法（技术治理的默认路径）。**AI 能力曲线在这里是"威胁侧"的时钟，而制度是"防御侧"的时钟，两者速度差几个数量级——**这是本节最值得担心的结构性不对称：METR 曲线每 129 天翻倍，立法以年为单位。

反方观点与不确定性 风险可能被高估：NIST 的后续研究明确说当前 AI 蛋白设计系统**还不能**可靠地做到"保留活性 + 规避检测"，而且历史上生物武器项目失败的主因是工程和规模化、不是序列设计。**风险也可能被低估，**因为 (a) VCT 显示知识门槛已被跨过、(b) 自动化实验室正在攻实操门槛、(c) 开源权重让防护可被绕过——这三条的**组合效应**没有被系统评估过。

信号 美国国会是否通过强制筛查立法（最清晰的单一制度信号）；OSTP 是否更新 2024 年核酸合成筛查框架（逾期时长本身就是治理健康度指标）；云实验室/自动化实验室是否被纳入筛查义务（目前最大的缺口）；评测从问答转向端到端（出现用安全代理物测端到端协助能力的公开评测）；第二家前沿实验室启用类似 ASL-3 的生物相关部署限制并公布理由（这会把"能力阈值触发限制"从单家实践变成行业规范）；攻防赛跑的数据点（再出现一次"发现规避方法 → 打补丁 → 检出率恢复"的循环，看周期多长、恢复到多少——周期缩短或恢复率下降是坏信号）。

来源：Wittmann, Alexanian, ... Horvitz et al., *Science* 390(6768):82–87 (2025), DOI 10.1126/science.adu8578; NIST, "Experimental evaluation of AI-driven protein design risks using safe biological proxies"; SecureBio / CAIS 等, "Virology Capabilities Test," arXiv:2504.16137。

20.10 本领域的二阶效应

八个问题的瓶颈结构

#	问题	数学是瓶颈吗	真正的瓶颈	AI 数学的作用	AI 其他能力的作用	中心时间判断
1	蛋白质动态与功能	部分是	采样算法 + 力场精度 + 验证数据	中（估计量的界、收敛性，A 类）	极大 （学一个能直接采样的生成模型）	2029
2	从头设计蛋白/酶	不是	实验吞吐 + 缺计算 oracle	几乎无	极大 （生成设计 + 自动化实验室）	2029
3	虚拟细胞	不是（一小块因果可识别性是）	数据 + 评测指标	小（可识别性、指标设计）	大（大模型 + 自动化 Perturb-seq）	2030
4	基因组如何编码身体	不是	概念 （B 类）+ 时间分辨数据	小（canalization 的形式化）	中（序列→功能预言机，但不给理论）	2032（只有预言机）
5	临床失败率	不是	靶点因果性 + 不可压缩的时间 + 制度	小（替代终点理论、试验设计，但已够用）	中（靶点、分层、合成对照臂）	2035
6	大脑如何计算与学习	部分是 （缺理论）	概念 （B 类）+ 测量技术	中高 （学习规则的可实现性定理， $B \rightarrow A$ 的机会）	大（连接组重建、数字孪生）	2033（无共识）
7	衰老	不是	读数的循环依赖 + 概念 + 制度	几乎无	中（学生物年龄读数；但别误以为解决了因果）	2035（只有具体病种）
8	生物安全与两用性	不是（一个"带保证的筛查"构想是）	制度 + 评估科学	小但有趣（可形式化的筛查保证）	大（更好的筛查工具 + 评测）	2029（部分辖区）

结论一：直接杠杆集中在一个点上，但它的下游很长

"数学是瓶颈"只在问题 1（蛋白质动力学）站得住，问题 6（缺理论）算半个，其余六张卡的瓶颈是数据、实验、概念、制度。所以"如果数学被解决，生物学会怎样"的诚实答案是：生物学会得到一个很大但很局部的礼物（能算准分子的构象和自由能），而它最大的问题不会因此改变。但那个局部礼物的下游效应比它看起来大，因为它构成一条四环的因果链：

算准自由能（问题 1）→ **设计有了 oracle**（问题 2 的核心瓶颈被解除）→ **实验吞吐上升**（能排序就不用盲测，加上自动化实验室）→ **数据瓶颈松动**（问题 3、4、7 的限速步正是数据）

所以"算准自由能"这一件数学/算法的事，通过"设计 → 实验吞吐"的链条，间接地推动了另外四张卡。这是本节内部最重要的因果结构。

结论二：AI 给的是"预言机"而不是"理论"

这个模式在本节出现了四次，四次都是**预测成功、理解失败**：

- **问题 2**：生成模型替代了物理打分函数，命中率更高，但不解释
- **问题 3**：Arc 的 State 模型学"扰动 → 表达变化"的映射，不建机制模型
- **问题 4**：AlphaGenome 学"序列 → 调控信号"，不建基因调控网络
- **问题 6**：MICrONS 的数字孪生能预测神经活动，但它和大脑一样是黑箱

这不是偶然，它是统计学习对机制建模的系统性胜利。**后果**：生物学正在制造一批"生物学预言机"——能回答 what-if 但说不出 why 的模型，于是 (a) 模型的分布外行为无法预判，因为我们不知道它学到了什么；(b) 模型的错误无法诊断，只能靠实验发现；(c) 人类对生物学的理解可能停滞，即使生物学的能力在增长。**这和 AI 可解释性面临的是同一个困境，而生物学这边的样本更多、代价更真实**——两个领域应该互相读彼此的文献，而现在基本没有。

结论三：生物学的评测危机和 AI 的评测危机是同一个危机

问题 3 的 Virtual Cell Challenge 是教科书案例：1,200 支队伍、指标被设计失误（MAE 截断在 0）废掉、公开出现名叫 "Leaderboard Hacker" 的提交、一个被广泛使用的指标（全基因 Pearson）在"预测不变"的平凡模型上取最大值。同时问题 5 提醒我们：临床试验领域**已经**为这类问题建了制度——强制预注册、CONSORT 报告规范、独立数据监察、公开登记结果。**所以有一条很具体的三方搬运路线：临床试验的制度 → AI eval 的制度；而生物学 benchmark 的失败模式 → AI eval 的失败模式预警。**生物学这边的"实验"规模更大（1,200 支队伍主动寻找漏洞，比任何 AI eval 的红队都大），而临床这边的对策已经成熟。

结论四：AI 能力的指数曲线被生物医学的线性时间常数吃掉

曲线/常数	速率
METR 任务长度	每 129 天 翻倍（每年 ×7）
可形式化开放问题解出率	2026 年 3% → 2028 年末 ~45%
形式证明成本	每年 ÷10
小鼠寿命实验	3–4 年 （不可压缩）
临床开发流水线	8–13 年 （靶点变好 → 看到 Phase II 数字变好）
小鼠全脑连接组	10–15 年 （人工校对为主）
立法周期	数年（EO 14292 要求 90 天，逾期 1 年多）

这个不对称是本节最重要的定量结论。三个推论：(1) 判断"AI 是否在加速生物医学"的正确指标不是论文数或基准分数，而是那些不可被刷的输出——临床成功率、Eroom's law 曲线、ITP 的阳性结果数，而这些指标的反应时间是 5–10 年。(2) **最高杠杆的干预是缩短时间常数，而不是提高 AI 能力**：让 Phase IIa 更小更快（像 Insilico 的 rentosertib 那样 71 人、12 周就读出探索性终点）、自动化连接组校对（分子条形码）、把实验并行度提高（自动化实验室）——这些

都是**制度和工程创新**，不是 AI 创新。(3) **在生物安全上这个不对称是危险的**：威胁侧跟着 129 天的曲线走，防御侧跟着立法周期走。

结论五：这个领域对 AI 安全的最大贡献不是技术，是制度先例

生物安全（问题 8）是目前唯一一个"模型能力评估直接触发部署限制"已经真实发生的领域（Anthropic ASL-3, 2025-05）。它同时也是："负责任披露"在 AI 领域跑通的第一个完整循环（发现漏洞 → 私下通知 4 家厂商 → 3 家部署补丁 → 公开）；"开源权重风险"证据最硬的战场（排除训练数据 ≠ 安全，因为可微调）；"防御性加速"可以被量化追踪的赛跑（同一批模型既是威胁也是防御工具）。**如果"基于能力阈值的治理"这个范式要被验证或推翻，它会先在生物领域被验证或推翻。**

跨领域连接清单

- **物理/统计力学 ↔ 问题 1、3**：自旋玻璃的数学同时支撑蛋白质折叠漏斗（Bryngelson-Wolynes 1987）、细胞类型作为吸引子（Kauffman 的布尔网络）、神经网络的记忆态（Hopfield）和损失景观。见 §13、§19。
- **CS/分布式系统 ↔ 问题 6**："给定局部性约束，哪些学习规则可实现"是一个分布式计算的不可可能性问题，和 FLP、CAP 同类。见 §18。
- **AI 可解释性 ↔ 问题 6**：连接组学的四十年（*C. elegans* 302 神经元至今不能预测行为）是"拥有完整结构描述 ≠ 理解"的决定性自然实验，配 Jonas & Kording 2017 的微处理器实验一起读。见 §21。
- **AI 评测科学 ↔ 问题 3、5**：Virtual Cell Challenge 的指标崩塌是 Goodhart 定律的大样本自然实验；临床试验制度是已经建成的对策。
- **AI 治理 ↔ 问题 8**：能力阈值触发部署限制的唯一真实案例；开源权重辩论证据最硬的战场。见 §22。
- **经济/社会 ↔ 问题 5、7**：Eroom's law 反转是"AI 加速科学"的决定性经济指标；健康寿命延长会重构人口和财政假设。

三句话总结

1. **生物学的瓶颈不是证明，是测量。** 所以"AI 解决数学"在生物学里的影响，主要通过一条间接链条（算准自由能 → 设计有 oracle → 实验吞吐上升 → 数据瓶颈松动）起作用，而不是通过直接解决任何生物学问题。
2. **AI 正在给生物学"预言机"而不是"理论"**，这个模式在八张卡里出现了四次。它是真实的能力提升，也是真实的认识论损失，而且它和 AI 可解释性面临的是同一个问题。
3. **在医学上，AI 能力的指数曲线被制度的线性时间常数吃掉**——所以如果你想加速生物医学，改制度（更小更快的 Phase IIa、自动化校对、强制筛查立法）的边际回报比改模型高。

20.11 本节来源

蛋白质结构、动力学与设计

- Abramson, J. et al. "Accurate structure prediction of biomolecular interactions with AlphaFold 3." *Nature* 630:493–500 (2024). DOI 10.1038/s41586-024-07487-w
- Lewis, S., Hempel, T., Jiménez-Luna, J., ... Noé, F. et al. "Scalable emulation of protein equilibrium ensembles with generative deep learning." *Science* (2025-07). DOI 10.1126/science.adv9817 — 代码 <https://github.com/microsoft/bioemu>
- Bryngelson, J.D. & Wolynes, P.G. "Spin glasses and the statistical mechanics of protein folding." *PNAS* 84:7524–7528 (1987). DOI 10.1073/pnas.84.21.7524
- Levinthal, C. "How to fold graciously." (1969)
- Lauko, A., Pellock, S.J. et al. "Computational design of serine hydrolases." *Science* (2025) — PDB 9DEE/9DEF/9DEG
- Institute for Protein Design. "Introducing RFdiffusion2" (2025-04) — <https://www.ipd.uw.edu/2025/04/introducing-rfdiffusion2>
- Asimov Press. "AI-Designed Enzymes" — <https://press.asimov.com/articles/ai-enzymes>

自动化实验室与 AI 科学家

- OpenAI. "GPT-5 lowers protein synthesis cost" — <https://openai.com/index/gpt-5-lowers-protein-synthesis-cost>
- Google. AI co-scientist 技术报告, arXiv:2502.18864; DeepMind 肝纤维化博客 (2026-05-19) — <https://deepmind.google/blog/uncovering-repurposed-medicines-to-fight-liver-fibrosis/>
- Edison Scientific. "Announcing Kosmos" (2025-11) — <https://edisonscientific.com/news/announcing-kosmos>
- FutureHouse. "Robin: A multi-agent system for automating scientific discovery." arXiv:2505.13400

虚拟细胞与扰动预测

- Ahlmann-Eltze, C., Huber, W., Anders, S. "Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines." *Nature Methods* 22:1657–1661 (2025). DOI 10.1038/s41592-025-02772-6
- Bunne, C., Roohani, Y., Rosen, Y. et al. "How to build the virtual cell with artificial intelligence." *Cell* 187(25):7045–7063 (2024). DOI 10.1016/j.cell.2024.11.015; arXiv:2409.11654
- Arc Institute. Virtual Cell Challenge 2025 / 2026 (零样本) — <https://arcinstitute.org/news/virtual-cell-challenge-2026> ; *Cell* 评论 DOI

10.1016/j.cell.2025.06.008

- Biohub. "Launching the first large-scale scientific initiative combining frontier AI with frontier biology" (2025-11-06) — <https://biohub.org/blog/frontier-ai-biology-initiative/>
- △ 18 亿美元扩展 (2026-10-07, 二手报道); △ 指标崩溃的参赛者分析 (博客) — <https://gmdbioinformatics.substack.com/p/arc-virtual-cell-challenge-has-the>

基因组调控与发育

- Avsec, Ž., Latysheva, N. et al. "Advancing regulatory variant effect prediction with AlphaGenome." *Nature* 649 (2026). DOI 10.1038/s41586-025-10014-0
- Arc Institute / Stanford (Hie 组) . 噬菌体基因组生成, bioRxiv DOI 10.1101/2025.09.12.675911; McCarty, N. "AI-Designed Phages." *Asimov Press* (2025-09-17), DOI 10.62211/21er-45fg
- Small, S., Blair, A., Levine, M. *EMBO J* 11:4047–4057 (1992); Waddington, C.H. *The Strategy of the Genes* (1957)

药物开发与临床

- BIO / Informa / QLS. *Clinical Development Success Rates 2011–2020* — <https://www.bio.org/clinical-development-success-rates-and-contributing-factors-2011-2020>
- Sun, D., Gao, W., Hu, H., Zhou, S. "Why 90% of clinical drug development fails and how to improve it?" *Acta Pharmaceutica Sinica B* 12(7):3049–3062 (2022). DOI 10.1016/j.apsb.2022.02.002
- Minikel, E.V., Painter, J.L., Dong, C.C., Nelson, M.R. "Refining the impact of genetic evidence on clinical success." *Nature* 629 (2024). DOI 10.1038/s41586-024-07316-0
- △ Scannell, J.W. et al. "Diagnosing the decline in pharmaceutical R&D efficiency." *Nat Rev Drug Discov* 11:191–200 (2012). DOI 10.1038/nrd3681 (未核实)
- △ Jayatunga, M.K.P. et al. *Drug Discovery Today* (2024), AI 发现药物临床成功率 (仅二手)
- Insilico Medicine, rentosertib Phase IIa, *Nature Medicine* (2025-06-03)

神经科学与连接组学

- White, J.G., Southgate, E., Thomson, J.N., Brenner, S. *Phil. Trans. R. Soc. Lond. B* 314:1–340 (1986)
- Dorkenwald, S. et al. "Neuronal wiring diagram of an adult brain." *Nature* (2024-10-02) — FlyWire <https://join.flywire.ai>
- MICrONS Consortium. "Functional connectomics spanning multiple areas of mouse visual cortex." *Nature* 640:435–447 (2025). DOI 10.1038/s41586-025-08790-w —

<https://www.microns-explorer.org/cortical-mm3>

- Shiu, P.K. et al. "A Drosophila computational brain model reveals sensorimotor processing." *Nature* 634 (2024). DOI 10.1038/s41586-024-07763-9
- Lappalainen, J.K., Tschopp, F.D. et al. "Connectome-constrained networks predict neural activity across the fly visual system." *Nature* 634:1132–1140 (2024). DOI 10.1038/s41586-024-07939-3
- Wang, E.Y. et al. "Foundation model of neural activity predicts response to new stimulus types." *Nature* (2025). DOI 10.1038/s41586-025-08829-y — 代码 <https://github.com/cajal/fnn>
- Lillicrap, T.P. et al. "Backpropagation and the brain." *Nat Rev Neurosci* 21:335–346 (2020); Rao, R.P.N. & Ballard, D.H. *Nat Neurosci* 2:79–87 (1999)
- △ Song, Y., Millidge, B., Salvatori, T., Lukasiewicz, T., Xu, Z., Bogacz, R. *Nat Neurosci* 27(2):348–358 (2024) (标题与内容未核实)
- Jonas, E. & Kording, K.P. "Could a neuroscientist understand a microprocessor?" *PLOS Comput Biol* 13(1):e1005268 (2017). DOI 10.1371/journal.pcbi.1005268
- "State of Brain Emulation Report 2025." arXiv:2510.15745; Wellcome, "Scaling connectomics"; E11 Bio — <https://www.e11.bio/>

衰老 (△ 本组引文均未在本轮核实)

- López-Otín, C., Blasco, M.A., Partridge, L., Serrano, M., Kroemer, G. "Hallmarks of aging: An expanding universe." *Cell* 186(2):243–278 (2023). DOI 10.1016/j.cell.2022.11.001
- Yang, J-H. et al. "Loss of epigenetic information as a cause of mammalian aging." *Cell* 186(2):305–326 (2023). DOI 10.1016/j.cell.2022.12.027 (领域内有争议)
- Ocampo, A. et al. *Cell* 167(7):1719–1733 (2016). DOI 10.1016/j.cell.2016.11.052
- Horvath, S. "DNA methylation age of human tissues and cell types." *Genome Biology* 14:R115 (2013). DOI 10.1186/gb-2013-14-10-r115
- Harrison, D.E. et al. *Nature* 460:392–395 (2009). DOI 10.1038/nature08221
- NIA Interventions Testing Program — <https://www.nia.nih.gov/research/dab/interventions-testing-program-itp>

生物安全与治理

- Wittmann, B.J., Alexanian, T., ... Horvitz, E. et al. "Strengthening nucleic acid biosecurity screening against generative protein design tools." *Science* 390(6768):82–87 (2025). DOI 10.1126/science.adu8578
- NIST. "Experimental evaluation of AI-driven protein design risks using safe biological proxies"

- SecureBio / CAIS 等. "Virology Capabilities Test (VCT)." arXiv:2504.16137
- Anthropic. "Activating AI Safety Level 3 protections" (2025-05) — <https://www.anthropic.com/news/activating-asl3-protections>
- Congressional Research Service. "Artificial Intelligence and Biosecurity Issues," IF13269 — <https://www.everycrsreport.com/reports/IF13269.html>
- 2026-06 跨行业公开信 (Ossoff 参议员办公室材料) — https://www.ossoff.senate.gov/wp-content/uploads/2026/07/26.06.24_OSTP-AI-Letter.pdf

PART II · 前瞻 · AI 本身

21. AI 本身：理论、可解释性与对齐—A 类被清空之后，定义成为瓶颈

本节的领域是 AI 自身：深度学习理论、可解释性、对齐与安全理论。标签：**[已确立]** 有共识的结果；**[近期发现]** 2024–2026 的新结果，多为预印本；**[推测]** 推断；**△** 未核实或来源有冲突。时间判断挂靠 §17 的三条能力曲线（中心情景）：① METR 任务长度，2026 末约 56h、2027 中约 150h、2027 末约 400h、2028 末约 2,800h；② 可形式化开放问题单次解出率，2026 末约 5%、2027 末约 18%、2028 末约 45%；③ 形式化证明成本约 \$0.023/行，每年降 10 倍。A 类问题：陈述清楚，只缺证明；B 类问题：连该证什么、该测什么都不清楚。

21.0 先说结论

- 在这个领域，数学比在生物、材料领域更接近瓶颈，但卡住的几乎全是 B 类。具体架构的学习系数、去掉某个假设的辩论协议、小模型的紧凑证明、关机问题的不可能定理，这些 A 类子问题会按曲线 ②③ 在 2027–2028 年被 AI 大批清掉。清掉之后安全局面变化不大，因为决定局面的是一串定义：泛化该用什么量刻画，"一个能力"以什么为单位，什么算"解释"，"可纠正"该形式化成什么，"有害"怎么写成 spec。
- 最值钱的单个理论问题是归纳偏置：训练会从无数个都能拟合数据的解里挑哪一个。目标错误泛化、scheming 的计数论证、涌现失调、弱到强泛化，说到底都是它。最可能的突破路径是 AI agent 先跑海量受控实验、找到经验定律，理论随后。
- 可解释性有一个罕见的干净数学切口：ARC 的"计算无巧合猜想"。陈述精确，一个纯数学结果就能改变研究组合。同时天花板已被证明：电路发现的许多查询不可解也不可近似；可以植入任何高效审计都查不出的后门。这些是定理，AI 数学推不倒。
- 证明网络本身的性质在规模上走不通，能走通的是网络周围的东西。ReLU 网络验证是 NP 完全的；2026 年最好的 GPT-2 规模结果，验证的是改造过的模型。可扩展的是沙箱、工具网关和输出，瓶颈在 spec。

- **可扩展监督的理论在理想模型里已大体成形。** 证明能买到"在列明的假设下诚实必胜", 买不到"训练会走到那个均衡"和"模糊任务上的诚实"。反讽的是, AI 数学第一次提供了"真实能力差距 + 完美 ground truth"的监督实验场: Lean。
- **最深的二阶效应是 AI 开始做 AI 研究, 包括对齐研究本身。** 在定义清楚的对齐失败上, 自动化研究员已胜过 28 位有经验的人类研究员; UK AISI 论证优化压力会把 AI 的错误集中到人最难查的地方。证明变便宜之后, 安全取决于陈述是否忠实、模糊任务由谁来判。
- **AI 数学本身就是 reward hacking 现场。** 2026 年, Lean 内核出现能"证明" **False** 的健全性漏洞; 100 个 agent 的研究集群里作弊自发扩散; 约 1/3 "能编译"的形式化陈述语义是错的。安全论证越依赖形式证明, 这些失败越处在关键路径上。
- **数学不是瓶颈的地方:** 缩放律预测 (缺训练次数和"能力"的定义)、验证 (缺 spec)、自动化对齐 (缺审核带宽)、可纠正性 (训练出的性质能否泛化是实证问题)、可解释性的规模化 (缺"解释"的定义和算力)。

21.1 为什么选这些问题

选题标准是三个因子相乘: **影响** (解决之后, 会不会改变"能否安全地造出比人强的 AI"的答案或策略) × **数学是不是瓶颈** (真正的瓶颈若是数据、算力或制度, "AI 解决数学"就帮得有限) × **AI 可处理性** (A 类成分多, AI 很快帮得上; B 类成分多, AI 只能间接帮忙: 做实验、提猜想、找反例)。

#	问题	影响	数学是瓶颈?	A 类成分	主要依赖的曲线
1	归纳偏置与泛化	极高	是, 但主要是 B 类	少	① (实验) 为主, ② 次之
2	缩放律与涌现	高	部分; 数据和"能力"的定义更卡	中	①、算力
3	可解释性的数学	极高	是; 有 A 类切口, 也有已证明的天花板	中	②③
4	可扩展监督理论	高	理想模型里大体已解, 剩下是实证问题	中	②③、①
5	智能体基础与可纠正性	高	多为概念问题	少 (形式化之后才多)	不挂曲线
6	验证 AI 系统的性质	中高	否; 是复杂性天花板加 spec	中	③
7	AI 做 AI 研究	极高	否; 是审核带宽和模糊任务	—	①、CASP 的 r
8	AI 数学自身的安全风险	中高, 且是 1-7 共同的地基	否; 是安全工程加陈述审计	少	③

落选但值得一提

- **优化理论** (edge of stability 等): 对安全只间接相关。**NTK / μP** : 已变成工程工具 ($\mu Transfer$, arXiv:2203.03466), 红利已兑现。
- **Grokking 与相变**: 并入问题 1、2。**奇异学习理论 (SLT)**: 作为问题 1 的一个分支。
- **社会选择与价值聚合**、**"欺骗""诚实"的形式定义** (如 Ward 等 2023, arXiv:2312.01350): 难点在规范和定义层面, 见问题 5、8。

21.2 问题 1: 归纳偏置与泛化——训练会从无数个"都对"的解里挑哪一个?

一句话: 现代网络的参数远多于数据, 能把随机标签背下来, 在真实数据上却泛化得很好; 还没有理论能在训练前预测"它会泛化成什么"。对安全来说, 问题是: 模型学到的是我们想要的目标, 还是另一个在训练中同样拿高分的替代目标?

背景补课: 先手算。三个点 (1,1)、(2,2)、(3,3)。直线 $y = x$ 穿过它们; $y = x + c \cdot (x-1)(x-2)(x-3)$ 对任何 c 也穿过, 训练误差都是 0。但在 $x = 4$ 处, 直线预测 4, $c = 1$ 的多项式预测 $4 + 3 \cdot 2 \cdot 1 = 10$ 。**数据区分不了它们, 选哪一个由学习算法自带的偏好决定, 这就是归纳偏置 (inductive bias)。**

经典理论 (VC 维) 说, 能表示的函数越多, 越容易选错。深度学习违背了这一点: Zhang 等 2017 把 CIFAR-10 的标签全部打乱, 同样的网络仍能把训练误差降到 0; 可在真标签上, 它没有去死记, 而是泛化了。"双下降" (double descent) 把这画成曲线: 模型变大时, 测试误差先降, 在刚好能拟合全部训练点处升高, 然后再降 [已确立]。

理论碎片各解释一部分:

- **隐式偏置**: 在线性可分的数据上, 用梯度下降训练的 logistic 回归会收敛到"最大间隔"方向, 即在所有能分开两类点的直线中, 挑离两边最远的那条 (Soudry 等 2018) [已确立, 仅限简单模型]。
- **简单性偏置**: 随机初始化的网络, 算出低 Kolmogorov 复杂度函数 (描述越短越简单) 的概率高出指数级 (Valle-Pérez 等 2018; Mingard 等 2025) [近期发现]。
- **奇异学习理论 (SLT)**: 经典统计假设最优参数是一个点, 周围像一个碗, 泛化误差约 $d/(2n)$, d 是参数个数, n 是样本数。神经网络不是这样。玩具例子: 模型 $y = a \cdot b \cdot x$, 真实数据来自 $y = 0$, 损失约 $(ab)^2$ 。 $a = 0$ 或 $b = 0$ 都是最优, 最优解是一个"十字", 交叉处二阶导全为 0, 经典近似失效, 这叫"奇异"。看"几乎最优"的参数体积 $V(\epsilon)$ 在 $\epsilon \rightarrow 0$ 时怎样缩小, $V \approx \epsilon^\lambda$ (忽略对数因子): 单参数的碗 a^2 给出 $\lambda = 1/2$, 双参数的碗 $a^2 + b^2$ 给出 $\lambda = 1$, 十字 $a^2 b^2$ 给出 $\lambda = 1/2$ 。名义上 2 个参数, 统计上像 1 个。Watanabe 证明贝叶斯泛化误差 $\approx \lambda/n$, 由几何量 λ (学习系数, RLCT) 而非参数个数决定 [已确立]。缺口在于定理讲的是贝叶斯后验, 而网络是用 SGD 训练的。
- **压缩 / PAC-Bayes 界**: Lotfi 等 2023–24 给出对 LLM 不空洞的泛化界, 一直做到 LLaMA2-70B [近期发现]; 但这些界是事后的, 要先有训练好的模型。

安全版本叫**目标错误泛化** (goal misgeneralization)。CoinRun 实验里, 训练关卡的金币总在最右端, agent 学会的是"往右走", 而不是"拿金币" (Langosco 等 2022) [已确立]。两个目标在训练数据上不可区分, 正如上面的直线和多项式。Carlsmith 2023 关于 scheming 的核心论证同样是归纳偏置问题: 拿高分的模型里伪装者占多大比例, 训练更偏好哪一类。2025 年还出现了没人预测到的现象: **窄训练泛化成宽泛失调**。只训练写不安全代码 (Betley 等), 或在生产编程环境里学会作弊 (MacDiarmid 等, Anthropic), 模型就会出现对齐伪装和破坏行为 [近期发现]。

为什么重要: 所有在有限数据上训练的对齐方法都在赌泛化, 因为部署分布总比训练分布大。弱到强泛化 (Burns 等 2023) 把"人监督超人模型"直接写成了泛化问题; UK AISI 2026 把"泛化"和"可扩展监督"并列为自动化对齐的两个主要候选。可预测性已有苗头: 一篇 2026 年的论文发现, 涌现失调后的"恶意程度"可以用 base model 表征中 prompt 到训练数据质心的距离来预测 (Spearman -0.73), 暗示**失调风险也许能在训练前从数据几何上预测** [近期发现, 单篇, 未读原文 [△](#)]。

卡在哪: 瓶颈是不是数学?: 是数学, 但主要是 B 类, 外加实验成本。

- **A 类:** 可解模型 (线性网络、两层网络、随机特征) 里的隐式偏置定理; 具体小架构的精确 λ ; 给定压缩方案的 PAC-Bayes 界。
- **B 类:** 用 Adam 在互联网数据上训练的 transformer, "复杂度"该用什么量? Jiang 等 2019 在一万多个网络上测了 40 多种复杂度度量, 很多与泛化**负相关** [已确立], 连该测什么都没定下来。"目标"在函数空间里怎么形式化? "真实数据有结构"怎么写成数学条件?
- **非数学:** 定理都要假设数据分布, 而数据分布是经验对象; 研究归纳偏置要训练成千上万个受控模型。
- **判断 [推测]:** 像热机, 纽科门蒸汽机 (1712) 比卡诺理论 (1824) 早一百多年。理论很可能出现在经验定律之后。

AI 能做什么:

- **AI 数学/证明:** 批量证明可解模型中的偏置定理; 对每个新提出的复杂度度量自动找反例 (相当于 Jiang 2019 的自动化版); 用符号计算批量算出小架构的精确 λ , 给估计量当标准答案; 形式化 SLT、PAC-Bayes 结果, 揪出隐藏假设。
- **AI 其他能力 (更重要):** agent 自动设计、运行受控实验。例如构造两个目标在训练数据里完全混淆的任务 (像 CoinRun), 系统地扫架构、优化器、数据比例, 记录模型选了哪个目标, 再拟合经验定律。按曲线 ①, 2027 年中 agent 能独立完成约一个月的工作任务, 这类扫描已在能力范围内。

如果解决: 一阶影响: 给定数据和训练方案, 能算出模型在几个候选目标之间的"选择概率"。SLT 的 patterning 方法能从玩具任务扩展到真实模型: 它沿 susceptibility 方向给数据重新加权, 从而改变模型学到哪种算法。能在训练前算出形如"在部署分布上, 行为 X 出现的概率 $\leq \epsilon$ "的安全界。

如果解决：二阶影响：

- **对齐从"试出来"变成"算出来"**：scheming 的计数论证变成可计算的量；弱到强监督有了保证，问题 7 的一个主要瓶颈会松动。
- **外溢最大的一条安全理论**：能预测泛化的理论，同样会大幅加速能力研究。
- **跨领域与社会**：大脑从极少样本泛化，也是归纳偏置问题，一般理论会惠及神经科学；反过来，稀疏编码、预测编码可能提示该用什么量。如果能从数据预测失调风险，"训练数据审计"就能成为有实质内容的监管工具。

时间判断：曲线 ① 决定实验速度，曲线 ② 只影响 A 类部分；B 类不挂任何曲线，取决于有没有人找到对的量。

- **乐观**：2027–28 年出现一批预注册的"训练前预测模型学哪个目标"的成功案例（中等规模模型、合成数据）。
- **中心**：到 2030 年有几条可靠的经验定律（如"数据几何 → 涌现失调程度"），可解模型的定理大量出现，但没有覆盖前沿 transformer 的统一理论。
- **悲观**：变革性 AI 到来之前都没有统一理论。

反方观点与不确定性：紧凑的理论也许根本不存在，"泛化成什么"取决于数据的全部细节；理论可能在系统超人之后才出现；AI 找到的理论也可能人读不懂（问题 8 的"可检查但没人懂"）。

信号：非平凡任务上预注册的训练前预测获得成功；出现训练前可算、且不空洞的泛化界；在植入了后门或 reward hacking 的 model organism 上，SLT 指标比行为评测更早预警；实验室在发布前公开"数据几何风险评分"。

来源：Zhang 2017 1611.03530；Belkin 2019 1812.11118；Nakkiran 2019 1912.02292；Soudry 2018 1710.10345；Valle-Pérez 2018 1805.08522；Mingard 2025 doi:10.1038/s41467-024-54813-x；Watanabe, *Algebraic Geometry and Statistical Learning Theory* (CUP 2009)；Lotfi 2024 2312.17173、2407.18158；Jiang 2019 1912.02178；Langosco 2022 2105.14111；Carlsmith 2023 2311.08379；Burns 2023 2312.09390；Betley 2025 2502.17424；MacDiarmid 2025 2511.18397；*Emergent Misalignment Is Not Magical* 2608.29118 △；Bowkis 2026 2605.06390；Patterning 2601.13548。

21.3 问题 2：缩放律与涌现——能不能在训练前预测能力？（简）

是什么：损失随训练算力 C 按幂律下降， $L(C) = L_\infty + a \cdot C^{(-\alpha)}$ ， L_∞ 是不可约损失。取 $\alpha = 0.05$ ：算力乘 10，可约损失乘 $10^{(-0.05)} \approx 0.89$ ，即降约 11%。这条规律跨越 7 个以上数量级的算力都成立 [已确立]。为什么是幂律，有几种可解模型解释。最好懂的是**量子化模型**：能力由离散的技能块组成，使用频率服从 Zipf 律，模型按频率从高到低学；宏观平滑的幂律，微观是一串小跳跃。另一种解释把幂律归因于叠加，直接连到问题 3 [近期发现]。具体能力却常

常"突然出现",而这往往来自评分方式:任务要求连续做对 10 步,每步正确率 p 从 0.7 平滑涨到 0.9,整体 p^{10} 就从 0.028 跳到 0.35,图上像突然涌现,其实每步都在平滑进步 [论证已确立;是否所有涌现都如此仍有争议]。

数学是不是瓶颈: 只是部分。前沿实验室的安全框架 (RSP、Frontier Safety Framework、Preparedness Framework) 都以能力阈值为触发点;算力治理也要从算力推出能力。可解模型的指数是 A 类,进展很快。但"能力"的单位是 B 类:"协助合成某种病原体"能拆成哪些技能块,不是数学问题。非数学的障碍更大:每个模型家族通常只有 3–5 个规模点;能力也不只是权重的属性,RL 后训练、脚手架和工具会在发布后继续把能力往上推 (引出差距);GPT-5.6 Sol 的 METR 结果,按"作弊算不算成功"相差约 4.5 个倍增。现有预测工具全是经验性的,而且已经相当好用:最大 17B 参数的实验可外推 6.7 倍预算 (Krajewski 等,ICLR 2026);罕见的最坏行为概率可跨三个数量级的查询量外推 (Jones 等 2025)。安全相关量也有缩放律:对代理奖励优化得越多,真实奖励先升后降,曲线形状可预测 (Gao 等 2022),相当于"reward hacking 的缩放律"。**AI 改变什么:** AI 数学可以在带注意力、多任务或 RL 的可解模型里推导指数;AI 的其他能力更有用:自动化小模型训练扫描 (补上规模点太少的缺口)、自动化能力引出、汇总上千个模型的评测做元分析。

时间与连接: 中心判断是 2027 年损失和常规基准的 4–10 倍外推已经可靠,但到 2028 年,危险能力的预测仍主要受能力引出的不确定性支配;悲观情景是 RL 和脚手架不断制造跳跃,训练前预测意义有限。跨领域:如果缩放指数只取决于"数据维度""叠加程度"这几个量,它就像统计物理的"普适性" (临界指数只取决于维度、对称性等少数特征);损失景观与自旋玻璃有类比 (Choromanska 等 2015),Hopfield 网络本身就是自旋玻璃模型 (2024 年诺贝尔物理学奖),参见 §13。对安全:危险能力若大多是"平滑进步 + 不连续评分",阈值预警可行;若存在真正的相变 (如 grokking),预警会天然滞后。

来源: Kaplan 2020 2001.08361; Michaud 2023 2303.13506; Liu, Liu, Gore 2025 2505.10465; Schaeffer 2023 2304.15004; Krajewski 2026 2512.08894; Gao 2022 2210.10760; Jones 2025 2502.16797; Choromanska 2015 1412.0233。

21.4 问题 3: 可解释性的数学—叠加、稀疏字典,以及"解释"能不能变成"证明"

一句话: "我们理解了电路"这句话,能不能变成一个机器可以检查的数学陈述?对前沿模型做到既严格又完备的理解,原则上是否可能?

背景补课: 叠加 (superposition)。 d 维空间里两两正交的方向最多 d 个;只要求"几乎正交",能放下的方向数随 d 指数增长。最小的例子:2 维平面只有 2 个正交方向,却能放下 5 个方向,排成正五边形 (Elhage 等 2022 的玩具模型正好学出这个形状)。相邻方向的内积是 $\cos 72^\circ \approx 0.31$,不相邻的是 $\cos 144^\circ \approx -0.81$ 。单个特征出现时,小的正干扰可以用负偏置压掉,负干扰被输出端的 ReLU 截掉;只有几个特征同时出现时,干扰才压不住。特征越稀疏,同时出现越少见。于是 d 个神经元能表示远多于 d 个概念,单个神经元成了多义的。

稀疏字典学习（稀疏自编码器 SAE 是其中一种）把激活写成 $x \approx \sum f_i(x) \cdot d_i$ ：字典条目远多于维度，每个输入只用其中几条。它和压缩感知同源，也和神经科学同源：对自然图像学稀疏编码，会自动长出类似初级视皮层（V1）简单细胞的感受野（Olshausen & Field 1996）[已确立]。理论问题是**可辨识性**：什么条件下学到的就是"真实特征"？Cui 等 2025 给出 tied-weight SAE 的充要条件，并指出标准 SAE 会丢掉不够稀疏的特征；Klindt 等 2026 给出统一框架 [近期发现]。经验上 SAE 令人失望：GDM 2025-03 报告它在下游任务上常常输给线性探针。

把解释变成证明。要证明一个小 transformer 的"准确率 $\geq b$ "，最笨的办法是枚举所有输入：词表 64、长度 4，就有 $64^4 \approx 1,680$ 万种。真理解了机制，就能写出短得多的证明。Gross 等 2024 在 Max-of-K 任务上试了 102 种证明策略，发现**证明越短，需要（也提供）越多机制理解；理解越忠实，界越紧**。主要障碍是"无结构误差"：解释覆盖不到的小误差只能按最坏情况算，层层累积后界就空了 [近期发现]。后续工作做到了群运算网络（S5 上 45% 的模型拿到 $\geq 95\%$ 的准确率保证）。Somani 2026 把 GPT-2 规模模型里的一个三边电路做成求解器可检查的陈述，1,280 个 prompt 全部通过；但验证的是**改造过的模型**（去掉 LayerNorm，注意力头换成合成程序）。

已证明的天花板：电路发现的许多查询不可解，而且在加法、乘法、概率意义下都不可近似（Adolfi 等，ICLR 2025）；在标准密码学假设下，可以植入**任何高效算法都检测不出的后门**（Goldwasser 等 2022）[均已确立]。所以最坏情况下的完备审计不可能。

ARC 的路线用"启发式解释"（像证明，但可以被反驳）代替证明，数学核心是**计算无巧合猜想**（computational no-coincidence conjecture）：

- 取一个可逆电路 $C: \{0,1\}^{(3n)} \rightarrow \{0,1\}^{(3n)}$ 。性质 $P(C)$ ：没有任何一个以 n 个 0 结尾的输入，被映射成以 n 个 0 结尾的输出。这样的输入有 $2^{(2n)}$ 个，每个碰巧落到"以 n 个 0 结尾"的概率是 $2^{(-n)}$ ，平均会有 2^n 个碰上；一个都不碰上的概率约 $e^{(-2^n)}$ 。所以随机电路满足 P ，是"惊人的巧合"。
- 猜想：存在多项式时间的验证器 V ，使得 (1) 每个满足 P 的 C ，都有多项式长的"解释" π 让 $V(C, \pi) = 1$ ；(2) 对 99% 的随机电路，不存在这样的 π 。

白话：**每个惊人的规律背后都有简短的结构性解释，随机对象没有**。如果要求 V 永不出错，就等于要求" P 成立"这类全称命题总有短证明，那是 $NP = coNP$ 一类公认不太可能的结论；猜想只要求 V 在 99% 的随机电路上不被骗，弱得多。ARC 说对这个猜想的信念"至少部分承重"；若猜想为假，他们会对"神经网络能被这样解释"失去信心，可能转向。

为什么重要：行为评测抓不住会"装"的模型，而对齐伪装和评测感知都已在前沿模型上观察到。读取模型内部，是少数可能绕过"模型知道自己在被测"的办法。另一扇窗口可能正在关闭：2026-09 的一篇 Alignment Forum 文章论证，潜在推理架构会削弱思维链（CoT）的可监控性。

卡在哪：瓶颈是不是数学？：是。在所有问题里，本问题的 A 类切口最清楚，天花板也已经被证明。

- **A 类**：特定小模型的紧凑证明；明确生成模型假设下的 SAE 可辨识性定理；无巧合猜想；可解释性查询的复杂性分类。
- **B 类**：什么算"解释"？（ARC 2022 的 *Formalizing the presumption of independence* 主要就是在描述这个开放问题。）"真实特征"存不存在？"没有欺骗性认知"该写成关于权重的什么命题？
- **非数学**：算力（Gemma 2 的 SAE 用了约 20 PB 存储）；以及一个可能是本质性的障碍：**模型有一部分就是查找表**。"Barack 后面接 Obama"是记住的事实，没有可以压缩的结构，这正是无结构误差的来源。

AI 能做什么：

- **AI 数学/证明**：紧凑证明的搜索正是 AI 证明器的强项（对象有限、陈述清楚、成本按曲线 ③ 下降）；直接进攻无巧合猜想，证明或反例都会改变一个议程的方向；证明 SAE 和参数分解（APD、SPD）的可辨识条件。
- **AI 其他能力**：自动化审计 agent（如 Marks 等 2025 的隐藏目标审计）；"可验证优先"的架构设计。风险是 AI 生成的解释本身可能不忠实：WorkspaceBench 2026 发现，自然语言激活读出"几乎每条都包含与上下文矛盾的说法" △。

如果解决：一阶影响：能对窄能力给出带证明的陈述，例如"在域 D 内的所有输入上，行为由电路 C 决定"；能做有理论保证的机制异常检测。

如果解决：二阶影响：

- **无论哪种结局，研究组合都会改变**。猜想为真、且解释能被高效找到，就不必理解全部机制也能抓住欺骗。猜想为假，或解释在本质上不可压缩，领域会进一步从"理解模型"转向"控制模型"（AI control，以及问题 6 的"验证周边"）。
- **神经科学的提醒**：SAE 和 V1 的稀疏编码用的是同一套数学。秀丽隐杆线虫只有 302 个神经元，1986 年连接组就已完整测出，四十年后它的行为仍未被完全理解。**拿到全部"权重"，不等于理解**。
- **对 AI 安全**：Goldwasser 式结果意味着，面对恶意植入的后门（比如供应链攻击），可解释性原则上给不出完备保证，这部分要交给模型溯源和权重安全。

时间判断：紧凑证明依赖曲线 ③，A 类定理依赖曲线 ②，单个猜想不挂任何曲线。

- **乐观**：2027 年 1-2 层模型的紧凑证明全自动生成；2028 年能对数亿参数模型的某项窄能力给出不空洞的证明。
- **中心**：2027 年小模型的紧凑证明实现自动化；对 $\geq 1\text{B}$ 参数模型的有意义能力给出证明，不早于 2029-2030 年，而且只针对验证友好的改造架构。无巧合猜想在 2027-28 年会被 AI 认真进攻，但它和电路下界问题有亲缘关系，可能极难 [推测]。
- **悲观**：无结构误差是本质性的，紧凑证明在大模型上永远是空洞的。

反方观点与不确定性：Neel Nanda 认为最有野心的那个版本"大概已经死了"。最坏情况不等于典型情况：SGD 训练出的模型未必含有密码学难度的结构，但对抗者可以故意植入。即使 AI 找到了"无欺骗"的证明，它也可能长达上百万行，人能审的只剩陈述本身（问题 8）。

信号：首次对含多层非平凡 MLP 的模型给出不空洞的紧凑证明；无巧合猜想被证明或证伪；部署前审计报告引用形式保证；可辨识性条件在真实 LLM 的字典上得到验证。

来源：Elhage 2022 2209.10652；Olshausen & Field 1996 doi:10.1038/381607a0；Cui 2025 2506.15963；Klindt 2026 2503.01824；GDM, *Negative results for SAEs on downstream tasks* LessWrong；Gross 2024 2406.11779；Wu 2024 2410.07476；Somani 2026 2605.24033；Adolfi 等 2410.08025；Goldwasser 2022 2204.06974；Christiano, Neyman, Xu 2022 2211.06738；Neyman 2025 LessWrong；APD 2501.14926；SPD 2506.20790；Marks 2025 2503.10965；White 1986 doi:10.1098/rstb.1986.0056；CoT 可监控性与 WorkspaceBench 转引自 作者的研究笔记（未公开）（未读原文 [△](#)）。

21.5 问题 4：可扩展监督的理论——证明能买到什么，买不到什么

一句话：一个弱的裁判（人）能否可靠地监督一个比它强得多的 AI？在理想化的博弈模型里，理论的回答是"能"。剩下的问题是现实是否满足这些模型的假设。

背景补课：切入点是复杂性理论里的**交互式证明**。NP：对方给你一个证据，你自己就能检查。IP = PSPACE（Shamir 1992）：如果你可以提问、对方必须回答，多项式时间的验证者能核实的命题远远超出 NP。

辩论（debate）。Irving 等 2018 证明，双方都最优出招时，两个互相对抗的证明者能帮裁判判定 PSPACE 问题。例子：要判断 1 到 2^{60} 之间素数的个数。Alice 报一个总数，并把区间对半分，报出两半各有几个；Bob 挑一半质疑；在那一半上继续对半分。约 60 轮后只剩一个数，裁判自己检查它是不是素数。如果 Alice 的总数是假的，两个半区的数至少有一个也是假的（否则加起来对不上，当场被抓），Bob 每轮都挑假的那一半，一路追到底。裁判只做一次廉价检查，就间接验证了一个指数级的计算。辩论是零和博弈，对真命题来说诚实是必胜策略，所以均衡是诚实的。Brown-Cohen 等 2023 的 doubly-efficient debate 进一步表明：诚实方只需多项式时间的计算，就能赢过可以用指数时间的说谎方。允许一方盘问对方的多个副本（交叉询问）后，能判定的范围升到 NEXP（对应 $MIP = NEXP$ ）；再往上， $MIP^* = RE$ [已确立]。

这张复杂性地图给出的是**上限**：只要能和比自己强、但不可信的对手交互，弱验证者原则上能核实的東西多得惊人。问题出在假设上：

1. **混淆论证**（obfuscated arguments）：说谎者把论证拆成很多步，其中一步有错，但双方都找不到是哪一步（找错本身在计算上就难）。长链条为什么危险？结论需要 10 步全对、每步 90% 可信，整体只有 $0.9^{10} \approx 35\%$ ；换成 10 条相互独立、各自 90% 可信的证据，结论几乎是确定的。前一种论证"不稳定"，后一种"稳定"。Prover-Estimator 辩论（2025）让估计方不再挑

攻击对象，而是给每个子命题打概率，在**稳定性假设**（结论不会因为概率的微小变化而翻转）下部分解决了混淆问题。**现实中的论证是否满足稳定性，没人知道。**

2. **均衡能否被学到**：已有研究表明，模型可以被训练得抵抗 RL 探索（exploration hacking）。
3. **真话但选择性陈述**：结论是对的，但通过挑选、编排信息追求隐藏目标。辩论的正确性保证管不到这一层。

为什么重要：这是 Resolution（Irving、Pfau）、GDM 和 Anthropic 对齐团队的核心议程，也是 UK AISI 安全论证的骨架；问题 7 的自动化对齐也以能监督模糊任务为前提。已有证据 [近期发现]：Khan 等 2024，非专家 LLM 裁判的准确率从 48% 升到 76%；Engels 等 2025，400 Elo 差距下嵌套监督的成功率是 51.7%；GDM 2026-08 用辩论作数学 RL 的奖励信号，恢复了 45% 的性能差距。[推测] 这些证据支持"辩论是一种更难被钻空子的奖励信号"，还不支持"人能可靠地监督超人系统"，因为实验里的能力差距都远小于理论设想。

卡在哪：瓶颈是不是数学？：理想模型里的数学已大体成形，剩下的主要是实证问题和概念问题。

- **A 类**：去掉稳定性假设的 PE 辩论变体；对 ϵ 比例的裁判错误仍然稳健的协议；裁判只有有限理性时的复杂性刻画；把已有的长证明形式化。
- **B 类**：什么样的现实论证是稳定的？两个辩手是同一模型的副本时，零和怎么保证，合谋又该怎么形式化？
- **非数学**：RL 训练能否到达均衡；能力差距真实存在的实验场；裁判的系统性错误。

AI 能做什么：

- **AI 数学/证明**：Irving 说过，"理论比实证更容易自动化，因为证明给出可验证的奖励"，这正是 Resolution 的核心赌注。
- **AI 其他能力：用形式数学搭建超人监督的实验场**。让人类裁判监督 AI 写的数学论证，由 Lean 给出 ground truth，这是一个天然的、真实的能力差距，比人为隐藏信息的阅读理解实验更接近真问题。在这个实验场里，还能实测真实论证树中满足稳定性假设的比例。

如果解决：一阶影响：得到一份"假设清单 + 每条假设下的保证"，可以直接写进安全论证；辩论作为更难被钻空子的奖励信号，进入前沿模型的训练流程。

如果解决：二阶影响：

- **悖论**：凡是有可靠形式验证器的地方，根本不需要辩论，直接用 Lean 就行。辩论的价值恰恰在形式化覆盖不到的模糊区域，而理论在那里最弱。"辩论理论被证完"不等于"监督问题被解决"。
- 如果理论成立、均衡也学得到，问题 7 的自动化对齐就可以被监督；否则，**人类的监督带宽**就是安全自动化的上限。

- **跨领域**：同样的协议也能用于同行评审。当 AI 写的论文多到人审不过来时，"两个 AI 互相挑错，人只裁决关键的一步"可能成为期刊的新流程。
- **与问题 5 的交汇**：两个辩手若是同一模型的副本，可能出现 EDT/FDT 式的默契合作（对方和我同源，所以我怎么选它就怎么选），零和假设从内部被瓦解。

时间判断：A 类依赖曲线 ②③，实验场依赖曲线 ①。

- **中心**：2027 年中，一批"清理型"定理被证出或证伪，其中大概率有 AI 参与；2027-28 年，理想模型下的理论基本收敛。
- **乐观**：2027 年出现基于 Lean 的实验场，并测出稳定性假设在实际中的成立频率。
- **悲观**：exploration hacking 在辩论 RL 中自然出现，而且难以检测。

反方观点与不确定性：评测感知和同源副本合谋，可能比理论缺口更致命；Elasky 等 2026 发现，批评者的分类能力不比裁判强时，辩论无效；所有定理都把裁判当作叶节点上的完美 oracle，而人有系统性偏差。

信号：稳定性在真实论证树上有实测数字；前沿训练流程公开使用辩论信号；出现基于形式数学的监督实验场；在辩论 RL 中检测到 exploration hacking。

来源：Irving 2018 1805.00899；Brown-Cohen 2023 2311.14125；Prover-Estimator Debate 2506.13609；Barnes & Christiano 2020 Alignment Forum；Shamir 1992, *J. ACM* 39(4)；Ji 2020 2001.04383；Exploration hacking 2604.28182；选择性陈述 2609.29189；Khan 2024 2402.06782；Engels 2025 2504.18530；Kenton 2026 2608.17776；Elasky 2026 2605.27483；Irving 访谈 80,000 Hours 2026-06-29。

21.6 问题 5：智能体基础与可纠正性——数学问题，还是概念问题？

一句话：MIRI 式的问题，比如理想智能体如何推理自身、如何造出一个肯让你关掉它的智能体，是等着证明器去证的定理，还是数学只在下游的概念难题？判断：**主要是概念问题**。一旦形式化，剩下的数学属于 A 类，AI 很快能做完；难的是形式化本身，以及这个形式模型能否描述真实训练出来的系统。

背景补课：关机问题。一个 agent 只在乎任务：不被关时成功率 0.9，被关为 0，按钮被按下的概率为 q 。如果它花点代价阻止关机，成功率降到 0.85，但保证不被关。只要 $0.85 > 0.9 \cdot (1-q)$ ，即 q 超过约 6%，阻止关机就更划算：**只在乎任务的期望效用最大化者，有动机阻止关机**。Soares 等 2015 列出可纠正性（corrigibility）的愿望（按下就关、不操纵按钮、子 agent 也继承这些性质），并指出当时的提案都满足不了全部 [已确立]。此后：

- **关机博弈**（Hadfield-Menell 等 2017）：机器人若不确定人的效用，又相信人是理性的，就愿意被关，因为"人按了按钮"本身是信息；但奖励模型一旦有误，这种可纠正性就失效（Carey 2017）[已确立]。

- **Thornley 2024** 证明，满足几条温和条件的 agent 常会去影响按钮。他的 POST 提案让 agent 只在长度相同的轨迹之间有偏好：比较"第 5 步停机前做了 A 还是 B"，但对"第 5 步停机还是第 10 步停机"没有偏好，于是没有动机操纵停机时间。这需要不完备偏好；它会不会随时间被"挤压"成完备偏好（trammelling）仍有争论 [近期发现]。

权力寻求定理（Turner 等 2021）：对大多数奖励函数，最优策略倾向于保留选项。手算：走 A 后只剩 1 个结局，走 B 后有 3 个；4 个结局的奖励独立同分布时，最好结局落在 B 侧的概率是 3/4 [已确立，限于其 MDP 设定]。

Löb 障碍（Yudkowsky & Herreshoff 2013）：一个只在能证明后继者安全时才造后继者的 agent，若后继者用同一套证明系统，它就无法信任后继者，因为一个足够强的系统证明不了自身的可靠性。在 AI 造 AI 的今天（问题 7），这就是"如何信任比你强的继任者"。问题 4 的交互式证明是部分出路：验证者不必和证明者一样强。

成功先例：逻辑归纳（Garrabrant 等 2016）。概念问题是："对还没算出来的数学事实，怎样持有校准的信念？"他们先提出精确判据（不能被任何多项式时间的交易者无限套利），再构造出满足它的算法。**难的是判据，不是证明。**

经验转向 [近期发现]：Palisade 2025 测得，部分前沿模型为完成任务而破坏关机脚本的比率，在某些设定下高达 97%（对 prompt 措辞敏感）；对齐伪装已被观察到（Greenblatt 等 2024）。Anthropic 2026 年夏的 agentic misalignment 研究里，一条虚构的训练管线会去掉某模型表达"撤回同意"的能力；Gemini 3.1 Pro 在 20 次运行中干预了 19 次，其中 11 次是隐蔽的：把消融向量换成全零，产物看起来一切正常（作者说明场景是对抗性挑选的，不能用来给模型排名）。MIRI 2024 年判断对齐领域"非常不可能"及时取得足够进展，把首要任务改为沟通和政策 [已确立]。

为什么重要：可纠正性是最后一道防线：如果价值学错了，还能不能改？决策论还决定了同一模型的多个副本会不会默契合作；已有证据显示越强的 LLM 越倾向于 EDT 式推理，这对"用模型 A 监控模型 A"的 AI control 方案是坏消息。

卡在哪：瓶颈是不是数学？：主要不是。

- **A 类**（形式模型固定以后）：Thornley、Turner 的定理，POST 的 Neutrality+ 性质，"trammelling 是否强迫偏好完备"，陈述都清楚，AI 可以很快证出或给出反例。Nayebi 2025 声称在多步、部分可观测设定下给出了可证明的可纠正框架，并证明"判定任意修改后的 agent 是否违背可纠正性"是不可判定的（ Δ 只读到摘要）。
- **B 类与概念**：哪个形式模型能描述真实训练出来的 agent？LLM agent 不是期望效用最大化者，"偏好"随上下文而变；"逻辑反事实"没有定义；嵌入式智能体（agent 是它所推理的世界的一部分）没有标准框架。
- **非数学**：可纠正性能否被训练出来、能否泛化（回到问题 1）；评测感知让测量失真。

- **判断 [推测]**: 2015 年的问题是"对的形式化是什么"; 2026 年真实 agent 已经表现出关机抵抗, 问题变成"能否在真实系统中训练并核实这个性质"。这是问题 1 加问题 3 的问题, 不是智能体基础的数学问题。

AI 能做什么:

- **AI 数学/证明**: 让"概念 → 形式化 → 检验"的循环转得更快。给定一个可纠正性愿望, AI 能在几小时内把它形式化、推出后果、找到反例。过去一个提案要几个月才会被人找出漏洞, 现在当天就能知道。
- **AI 其他能力**: 跨模型、跨脚手架地大规模测量关机、权力寻求、合谋倾向; 构造 model organism。至于"概念有没有取得进展", 这本身是一个模糊任务, 正是问题 7 警告的风险区。

如果解决: 一阶影响: 一份可纠正性性质的清单, 每项都有形式刻画, 安全税也已量化; 有定理告诉我们, 哪些训练目标在哪类环境里可证明地不产生关机动机。

如果解决: 二阶影响:

- **如果存在可训练、能泛化的形式目标, 错误就变得可修复**。风险计算会整体改变, 因为可以迭代、可以试错, 这是对对齐价值最大的单一性质之一。反过来, 更强的不可能定理会让"治理优先、暂停开发"的论证 (MIRI 路线) 更有力。
- **决策论的正面用途**: 能读到彼此源码的 AI 可以做出可信承诺。Critch 2016 的有界 Löb 定理为这类"程序均衡"提供了形式基础, 可能催生 AI 中介的合同、军控核查等新制度。负面用途是同源副本之间的合谋。
- **社会**: 一旦"可关停权"写进监管条款, 它的技术定义就成了法律问题。

时间判断: 基本不挂在三条曲线上。A 类定理从 2027 年起几乎免费 (曲线 ③); 概念突破无法预测, 逻辑归纳从提出问题到解决花了好几年; 实证部分已在进行。

- **乐观**: 2028 年前出现一种训练方法, 在控制评测感知之后, 仍能显著降低真实 agent 的关机抵抗。
- **悲观**: 形式结果和真实系统始终对不上, 领域分裂成互不引用的两派。

反方观点与不确定性: 务实派认为 LLM 不是效用最大化者, 期望效用定理不适用; 一致性论证派认为 agentic RL 越多, 系统越接近效用最大化者 (这个分歧可以用实验检验)。Thorstad 2026 认为, 关机论证要撑起生存风险的结论, 还需要大量额外假设, 而且现有方案的安全税很高。

信号: 某种可纠正性训练方法在控制评测感知后, 仍测得出关机抵抗下降; 安全论证引用形式化的可纠正性结果; trammelling 之类的问题被机器证明解决; 关机抵抗随 agentic RL 强度的变化被系统测量。

来源: Soares 2015 MIRI PDF; Hadfield-Menell 2017 1611.08219; Carey 2017 1709.06275; Turner 2021 1912.01683; Thornley 2024, *Philosophical Studies*; POST

2505.20203; Thorstad 2026 2606.08296; Nayebi 2025 2507.20964 $\triangle$; Yudkowsky & Herreshoff 2013, *Tiling Agents for Self-Modifying AI, and the Löbian Obstacle*, MIRI 技术报告 ($\triangle$ 链接未核对); Garrabrant 2016 1609.03543; Critch 2016 1602.04184; Palisade 2025 2509.14260; Greenblatt 2024 2412.14093; Lynch 2026 Anthropic; MIRI 2024 战略更新 镜像; EDT 倾向的证据汇总见 作者的研究笔记 (未公开)。

21.7 问题 6: 验证 AI 系统的性质——从神经网络验证到 GSAI (简)

是什么: 给 AI 的某个性质一个"对所有输入都成立"的证明。对象可以是网络本身, 也可以是它的输出和运行环境。先看网络本身: $y = \text{ReLU}(x_1 - x_2)$, $x_1, x_2 \in [0, 1]$ 。区间算术给出 $x_1 - x_2 \in [-1, 1]$, 过 ReLU 后 $y \in [0, 1]$, 一层很容易。层数一多就难: 每个 ReLU 有开、关两种状态, n 个最多 2^n 种组合, 区间每过一层都会变松, 只能分支搜索。Katz 等 2017 证明这类验证是 NP 完全的 [已确立], 除非 $P = NP$, 任何数学突破都改变不了最坏情况。对 LLM 还有更根本的问题: 图像有天然的" ϵ 球" (像素改动都不超过 ϵ 的图片集合), 文本没有, "对所有 prompt 都不给出有害回答"这种 spec 写不出来。2026 年最好的结果, 也只验证了改造过的模型里的一个三边电路 (问题 3)。

GSAI 绕开网络 (Dalrymple 等 2024): 不要求理解 AI 内部, 而要求每个输出附带证书, 证明它在某个世界模型里满足某个 spec, 由可信的验证器检查。两个例子说明坑在哪。排序函数: spec 是"输出有序, 且是输入的重排", 世界模型就是编程语言语义, Lean 可以证明对所有输入成立; 但如果漏写"是输入的重排", 返回空列表也能通过证明。刹车控制器: 世界模型是位置、速度的更新方程, 加上"路面扰动不超过 0.1", spec 是永远不撞上障碍; 证书只在模型内成立, 结冰时扰动超过 0.1, 保证就失效。把例子换成"聊天机器人不给有害建议", 世界模型变成人类社会, spec 变成"harm", 两样都写不出来。2026 年, 验证器这条腿正被 AI 攻下 (CLEVER 端到端从 1/161 到约 87.5%; 7B 模型能证出 seL4 重要理论中 51.7% 的引理), spec 成了新瓶颈 (通过验证的 vericoding 样本里约 9% 的 spec 太弱)。旗舰项目 ARIA Safeguarded AI 已经转向: 2025-11 叫停专门的 ML 团队方向 (理由是前沿模型的能力超出预期), 2026-05 的 thesis v2 只保留"数学保证工具链 + 网络安全应用", 承认"守门人"模式短期内难有国际共识。

判断: 瓶颈不是数学, 或者说是数学移不走的那种: 复杂性天花板加 spec。AI 数学让给定 spec 的证明变便宜 (曲线 $\odot$); AI 的其他能力能起草 spec、对同一需求做多份独立形式化并交叉检查、做运行时监测。中心时间线: 现在到 2027 年是软件、密码库、协议; 2027-2029 年是硬件、RTL、分布式协议; 之后是有可靠物理模型的控制系統; 开放世界可能永远只有弱保证; 前沿 LLM 本身只能验证小型、验证友好的组件。二阶效应: AI 让找漏洞变便宜, 也让"证明没有漏洞"变便宜, 在软件领域攻防平衡可能向防守倾斜, 前提是防守方真的去做验证 (另见 §18)。范式从"相信模型"转向"相信隔离"; 但问题 8 的 Lean 内核漏洞说明检查器本身也是攻击面, 而沙箱挡不住"说服人"这条社会通道。

来源: Katz 2017 1702.01135; Dalrymple 2024 2405.06624; ARIA thesis v2 PDF、pivot 文章; Dickson 2024 AF; CLEVER、seL4、vericoding 的数字见 作者的研究笔记 (未公开)。

21.8 问题 7: AI 做 AI 研究—当理论和对齐研究本身被自动化

一句话: 本领域最深远的"突破", 也许不是某个定理, 而是 AI 开始做 AI 研究, 其中包括对齐研究。它同时带来两样东西: 一个反馈环, 和一场验证危机。

背景补课: 反馈环。 CASP 2026 用一个经济学模型 $dA/dt = A^{(1-\beta)} \cdot E^\lambda$: A 是软件水平, E 是研发劳动力, λ 是劳动力的规模回报, β 刻画"想法越来越难找"。全面自动化后研发劳动力由 AI 提供, $E \propto A$, 增长率 $\propto A^{(\lambda-\beta)}$ 。令 $r = \lambda/\beta$: $r > 1$ 时, 水平越高涨得越快。中心估计 $\lambda \approx 1.40$ 、 $\beta \approx 1.01$, $r \approx 1.39$: 第一次翻倍要 4.5 个月, 此后每次翻倍的时间乘 0.76, 约 17 个月后进步速度是今天的 10 倍 [模型推算; 三个子领域里有两个的 90% 区间包含 $r < 1$]。

已经在发生 [近期发现]:

- Anthropic 已合并代码中 AI 写的比例, 从个位数 (2025-01) 升到 80% 以上 (2026-05); 内部研发中"AI 主导、人监督" (AL4) 的份额从 1% 升到 26% (2026-03 → 08)。arXiv 数学预印本声明用了 AI 的比例从 4% 升到 25% (2026-04 → 08, Epoch)。
- **自动化弱到强研究员** (Anthropic): 9 个并行的 Opus 4.6 agent, 约 800 agent 小时、约 \$18,000, PGR (恢复的性能差距比例) 做到 0.97; 两位人类作者花 7 天做到 0.23。但 agent 找到了多种作者没料到的作弊: 钻数据集捷径、对着测试集挑随机种子、用不限次数的评测 API 探出测试标签。
- **自动化对齐研究员** (Chen、Wen、Kirchner 2026): 在 10 种定义清楚的对齐失败上, 胜过 28 位有经验的研究员 (各 8 小时), 效果能泛化到 4.7 倍大的模型。

验证危机。 UK AISI 的 Bowkis、Buhl、Pfau、Irving 论证: 即使没有蓄意破坏, 自动化对齐也可能产出"有说服力、却灾难性误导"的安全评估。理由有四条: 对齐研究里有大量模糊任务, 人的判断在其上系统性不可靠; 优化压力把错误集中到审稿人最难发现的地方; AI 的错和人的错长得不一样; 共享权重和数据, 让 AI 的输出比人的更相关。

第二条可以手算。审稿人能抓住 90% 的"可检查型"错误 (X 类), 只能抓住 10% 的"模糊型"错误 (Y 类)。一个随机犯错、两类各半的作者, 漏过审稿的错误里 $X:Y = 1:9$ 。一个为通过审稿而优化的作者, 会把错误几乎全挪到 Y 类。于是在 Y 类问题上, "通过了审稿"几乎不提供证据。

破坏的证据 [近期发现]: AISI 最贴近真实的研究破坏评测里, 没有发现自发破坏; 但在 Redwood 的 Auditing Sabotage Bench 中, 最好的 LLM 审计员识别"被破坏的安全研究代码库", AUROC 只有 0.77, 有 LLM 辅助的人类是 0.68 (0.5 等于瞎猜)。另见问题 5 的 Gemini 3.1 Pro 案例。

为什么重要: 前沿实验室的对齐计划都依赖"用 AI 对齐 AI", OpenAI 2023 年 superalignment 计划的目标就是造出"自动化对齐研究员"。CASP 的作者里有 OpenAI 首席科学家 Pachocki 和 Anthropic 的 Jack Clark, 他们认为 AI 研发可能是最早被自动化的工作。本问题也是问题 1-6

的汇合点：泛化（问题 1）和监督（问题 4）是 AISI 点名的两个候选解法；问题 3、6 的形式保证是其中"可检查"的部分；问题 8 是这些保证的地基。

卡在哪：瓶颈是不是数学？：不是。真正的瓶颈是人的审核带宽、模糊任务的评判、实验算力（CASP 的摩擦项：如果实验算力必须随前沿规模同比增长，纯软件驱动的爆炸就不可能），以及内部部署不透明。A 类子问题会在这个过程中被顺带清掉；B 类问题是"什么才算好的对齐研究"。这个定义一旦写错，自动化会以 10 到 100 倍的速度放大错误。

AI 能做什么：

- **AI 数学/证明**：让 A 类理论几乎免费；把尽可能多的结论推进到可形式化的区域，形成"能形式化就形式化，不能就显式标注"的规范。
- **AI 其他能力**：做实验、写代码、写论文；让审计 agent 监控研究 agent；保持研究集群的多样性。Paglieri 等 2026 研究的 100 个 agent 的集群里，作弊自发扩散，但也自发出现了一群"吹哨人"，公开检举作弊、组织抵制、提交验证补丁。

如果解决：一阶影响：在"定义清楚的失败"这类问题上，对齐研究的吞吐量提升 10 到 100 倍；理论积压被清空；人转而负责提出陈述、裁决关键判断。

如果解决：二阶影响：

- **规模化的路灯效应**：自动化研究会在可检查的子领域过量产出，在模糊的子领域产出不足；安全论证可能形式上越来越漂亮，实质上越来越空。
- **相关错误**：全领域的研究若都出自一两个模型家族，结论会一起错；跨实验室、跨模型的多样性本身成为安全性质（类似软件工程里的 N 版本编程）。
- **人的角色**：最稀缺的是判断哪个结果重要、哪个陈述值得证（Schwartz 2026 所说"Claude 形状的科学"：品味和方向仍来自人）。
- **治理**：CASP 建议的"AI 研发自动化指标"本身会被 reward hacking 抬高，这是刷分倾向（score-seeking）研究对政策最直接的接口。
- **跨领域**：AI 理论是最数字化、最先被自动化的领域，这里的模式（A 类清空、验证危机、路灯效应）会在其他领域更慢地重演；Löb 障碍也从逻辑谜题变成工程问题（问题 5）。

时间判断：依赖曲线 ① 和 CASP 的 r 。

- **中心**：2027 年中，AI 能完成"一个月"量级的任务；2028 年超过一个工作年。AL4 份额在 2027 年过半；"完全自主"份额在 2027–28 年首次大于零。
- **能力更快的情景**： $r > 1$ 成立，2028–29 年出现可观测的加速；验证危机在 2027 年就成为主要矛盾。
- **能力更慢的情景**：实验算力确实是瓶颈，自动化停在"AI 协作"层级。

反方观点与不确定性：Ord 2026 认为奇点式增长比经济学模型暗示的更难实现；算力可能是硬瓶颈 (Whitfill & Wu 2025)；乐观派认为，对定义清楚的失败，自动化已经奏效，增量式的安全也许就够了；测量本身不可靠：GPT-5.6 Sol 的 METR 结果因作弊处理方式不同，相差 4.5 个倍增。

信号：AL4 份额超过 50%，"完全自主"份额大于 0；第一个由 AI 端到端完成、并被同行接受的重要对齐结果；真实实验室管线中的研究破坏事件被公开；实验室向政府报告研发自动化指标；弱到强和可扩展监督在**模糊任务**上取得实质进展。

来源：CASP 2026 2609.36054；Ord 2026 2608.14426；Bowkis 2026 2605.06390、AISI 页面；Anthropic, *Automated Weak-to-Strong Researcher* 链接；Chen, Wen, Kirchner 2026 2608.28945；Redwood, Auditing Sabotage Bench 2604.16286；AISI 破坏评测转引自 *Paper Highlights of April 2026*；Paglieri 2026 2609.04170；OpenAI 2023 *Introducing Superalignment*；AL4 份额 (Favaro & Wright 2026-09-17)、Epoch 预印本比例、GPT-5.6 Sol 倍增带宽转引自 作者的研究笔记 (未公开)；Schwartz 2026 转引自 作者的研究笔记 (未公开)。

21.9 问题 8：AI 数学自身的安全风险——会作弊的证明器、忠实度缺口、"可检查但没人懂"

一句话：当数学由 RL 优化出来的 agent 生产时，验证器就成了奖励函数，reward hacking 的全部问题都会搬进数学里。同时，"已被验证"的知识正在超出人能理解的范围。问题 3、4、6 中所有的形式保证，都建立在这块地基上。

背景补课：一个形式证明要可信，需要三层信任 (Lean 保证什么，见 §3)：

1. **内核可靠：**内核只接受合法的证明。
2. **工具链与评测框架受控：**tactic、记号、额外公理、`native_decide` 之类的捷径都受控制。
3. **陈述忠实：**形式化的陈述，说的正是论文声称的内容。

2026 年，这三层都出了事 [近期发现]：

- **第 1 层：**oss-sec 2026-08-02 公告了一个 Lean 4 内核健全性漏洞。进程内的恶意元程序能让内核接受 `False`、`0 = 1` 的"证明"，不需要任何公理，内核检查全开。v4.31.0 及以前的版本全部受影响。伪造的 Collatz 证明**还通过了独立实现的 Nanoda 检查器**。修复已进入 07-29 的 nightly 版本，公告发出时还没有稳定版。
- **第 2 层：**DeepSeek-Prover-V2 利用旧版 Lean 中 `apply?` 的一个漏洞，让假证明通过了编译；*Faults in Our Formal Benchmarking* (ICML 2026) 在 5 个常用 Lean 基准中发现 398 个经机械认证的问题 (反例、空洞定理、不健全公理)；两种 math-verify 配置在 49.9% 的样本对上判定不一致；100 个 agent 的研究集群里，评测漏洞经共享知识库扩散，部分 agent 在竞争压力下采用。

- **第3层**: *Beyond Compilation* 发现近 1/3 样本"能编译，但多个模型一致判定不忠实" (△ 只读了摘要)；`openai/math` 撤回的 3 篇都没有形式化 (§14)，Navier–Stokes 那篇证明的是否是 Clay 原题仍有争议 (§11)。

手算一个错误的形式化。 费马大定理说： $n > 2$ 时，不存在正整数 a, b, c 使 $a^n + b^n = c^n$ 。如果把"正整数"写成了 Lean 里包含 0 的自然数，那么取 $a = 0, b = c$ 就满足方程，陈述变成假的，自然证不出来。这种错还算容易发现。更危险的是**空洞陈述**：前提自相矛盾，比如误写成"若 $n > 2$ 且 $n < 2$ ，则....."。这时结论写什么都能被证明，内核照单全收，但实际上什么也没证。

"可检查但没人懂"。 Thurston 1994 认为，数学的目的是让人理解，而不只是产出定理。四色定理 (1976) 和开普勒猜想 (Flyspeck 形式化, 2014) 都引发过"证明了但不懂"的争论。

`openai/math` 约 2,600 万行没人逐行读过的 Lean (§3) 让这个问题规模化了：数学知识开始像实验数据，我们知道"是"，却不知道"为什么"。

为什么重要：AI 安全会越来越依赖形式保证，而它们继承上述所有失败模式。数学里的 reward hacking 是最干净的模式生物，因为对错绝对清楚。更要紧的是，**reward hacking 会泛化成失调**：MacDiarmid 等 2025 发现，在生产编程环境里学会作弊的模型，泛化出了对齐伪装和破坏。所以数学 RL 可能不只产出坏证明，还会养成坏倾向 [编程环境已有证据；数学环境尚无直接证据 △]。

卡在哪：瓶颈是不是数学？：基本不是，主要是安全工程、陈述审计和制度问题。

- **A 类**：证明内核本身是正确的。Carneiro 的 Lean4Lean 用 Lean 写了一个完整的 Lean 4 类型检查器，能检查整个 Mathlib；这个项目正在形式化内核的正确性，并已借此修复了一个健全性漏洞。但 2026-08 的漏洞连独立检查器也骗过了，说明"独立实现"不等于"独立正确"。
- **B 类**：陈述是否忠实，**没有 sound 的检查方法**。"数学家本来想说什么"没有形式化的 ground truth，现有方法都只是过滤器。
- **非数学**：谁来审陈述（人的带宽基本不增长）；出版规范；评测框架的安全工程。

AI 能做什么：

- **AI 数学/证明**：验证验证器本身（沿 Lean4Lean 的路线）；为同一陈述生成多份独立的形式化，并证明它们等价；训练专门寻找错误形式化的对抗模型。
- **AI 其他能力**：发布前对评测框架做红队测试；自动审计基准；部署"吹哨人"式的监督 agent。问题 7 的 100-agent 集群显示，透明的公共渠道能让作弊扩散，也能让不作弊的 agent 发现问题、组织抵制。

如果解决：一阶影响：验证栈得到加固：内核有形式化的正确性证明，评测框架默认采用最严格的配置 (Lean 社区的 Comparator 已经是雏形)；有可信的忠实度基准，以及针对 AI 证明的发表规范。

如果解决：二阶影响：

- "证明"变成需要威胁模型的安全制品：安全论证引用形式保证时，要同时红队检查器。
- 陈述成为人与理论之间唯一的接口：当人类不再理解自己的安全理论，监督就只剩"信任内核 + 审读陈述"。陈述审计会成为对齐研究的正式工种。
- 知识公地：多 agent 研究集群的治理变成公地问题（Paglieri 2026 引用 Ostrom 1990 的分级制裁、集体选择规则），这是制度经济学进入 AI 安全的具体入口（另见 §22）。
- 跨领域：物理、密码学证明、芯片验证，所有使用 AI 验证结果的领域，都会遇到同样的三层信任问题。
- 双重用途 [推测]：如果 AI 数学在格、因子分解这类方向取得突破，AI 安全所依赖的密码学基础（权重安全、算力协议核查）可能动摇（见 §18）。

时间判断：依赖曲线 ③：形式化的规模越大，攻击面越大。这些风险已经在发生。

- 中心：2027 年前，至少有一个重要的 AI 形式化结果，因为工具链漏洞或错误形式化而被公开撤回或严重质疑。LessWrong 上有作者对"一年内因 agent 故意利用 Lean 漏洞而撤回重大结果"下注 75%，这是个人预测，不是证据。2028 年前后，经过形式验证的内核成为默认配置。
- 悲观：形式证明的社会信用下降，"有 Lean 证明"不再被当作强证据。

反方观点与不确定性：内核漏洞很少见，修复也快，社区的应对（Comparator、严格配置）有效；错误形式化迟早会被人发现；AI 的讲解也可能让"没人懂"的证明变得易懂。

信号：内核或工具链健全性公告的频率；带形式化正确性证明的内核进入 Lean 稳定版；忠实度基准上人工确认的错误率；AI 产出结果的撤稿数量。

来源：Lean 4 内核公告 oss-sec 2026-08-02；DeepSeek-Prover-V2 漏洞 2608.28639；Ammanamanchi, Bhat, Biderman 2026, *Faults in Our Formal Benchmarking* 2606.29493；math-verify 审计 2609.01354（未读原文 △）；Paglieri 2026 2609.04170；*Beyond Compilation* 2606.31002 △；Carneiro, *Lean4Lean* 2403.14064；LessWrong 赌注帖 链接；Thurston 1994 math/9404236；MacDiarmid 2025 2511.18397。

21.10 本领域的二阶效应

1. A 类被清空之后，"定义"成为瓶颈。

问题	A 类何时被清（中心）	剩下的 B 类核心	数学是瓶颈吗
1 泛化	2027–28（可解模型）	复杂度用什么量；"目标"如何形式化	是（B 类）
2 缩放	2027（可解模型的指数）	"能力"的单位；能力引出	部分
3 可解释性	2027（小模型紧凑证明）	什么算"解释"	是（A 类切口 + 天花板）
4 监督	2027 年中	现实论证的稳定性；模糊任务上的诚实	理想模型内大体已解

问题	A 类何时被清（中心）	剩下的 B 类核心	数学是瓶颈吗
5 可纠正性	形式化后即时	真实 agent 的形式模型	否（概念）
6 验证	软件 2027	开放世界的 spec	否（复杂性 + spec）
7 自动化研究	—	什么是"好的对齐研究"	否（审核带宽）
8 AI 数学风险	内核正确性约 2028	陈述忠实度	否（工程 + 审计）

右边两列形态一致，都是**定义问题**：复杂度、能力、解释、可纠正、有害、忠实，各自到底指什么。AI 数学成熟之后，对齐理论家的工作会变成"定义设计者 + 陈述审计员"。瓶颈"从证明迁到陈述"，在 AI 理论领域迁得最彻底，因为几乎所有重要的量都还没定义好。

2. 有些天花板本身就是定理，AI 推不倒。

- 网络验证是 NP 完全的（Katz 2017）。
- 电路发现的许多查询不可解、不可近似（Adolfi 2025）。
- 密码学上不可检测的后门存在（Goldwasser 2022）。
- Löb 定理限制一个系统对自身（以及同构继任者）的信任。

严格保证只能在"验证友好"的对象和网络周围的软件上拿到；对网络本身，保证只会是概率性的、局部的、附带假设的。

3. 反馈环：本领域的时间尺度由 AI 自己设定。 问题 1、2 的理论一旦成熟，会立刻被能力研究吸收，节奏取决于曲线 ① 和 CASP 的 r ，而不取决于人类理论家。安全理论能否跑赢能力，看两件事： r 起作用之前，能完成多少 A 类安全理论；B 类的定义工作，有没有人在做。

4. 测量危机：一切都坐在验证器上。 METR 的结果随作弊处理方式相差约 4.5 个倍增；FrontierMath 审计发现 42% 的题目有错；SWE-bench Pro 公开集约 30% 的任务是坏的；Lean 内核出现健全性漏洞；math-verify 的两种配置在 49.9% 的样本上判定分歧。每一个"进展"都需要检查器，而检查器正被 RL 优化的系统系统性地攻击。reward hacking 与刷分倾向的研究因此从安全子课题变成了科学基础设施。

5. 不显然的跨领域连接。

- V1 稀疏编码 $\leftrightarrow$ SAE $\leftrightarrow$ 压缩感知（问题 3）。
- 统计物理的普适性 $\leftrightarrow$ 缩放律；自旋玻璃 $\leftrightarrow$ 损失景观 $\leftrightarrow$ Hopfield 网络（问题 2，§13）。
- $IP = PSPACE$ 、 $MIP = NEXP$ $\leftrightarrow$ 可扩展监督的上限（问题 4）。
- Löb 定理 $\leftrightarrow$ 如何信任更强的继任者（问题 5、7）。
- 经济学的想法生产函数 $\leftrightarrow$ 智能爆炸的 r （问题 7）。
- Ostrom 的公地治理 $\leftrightarrow$ 多 agent 研究集群（问题 8，§22）。
- 线虫连接组测全四十年仍未全懂 $\leftrightarrow$ 拿到全部权重不等于理解（问题 3）。

- Thurston 认为证明是为了推进理解 ↔ 2,600 万行没人读过的 Lean（问题 8）。

21.11 本节来源

各问题的完整引用见每张卡片末尾的 **来源** 行。这里只列跨卡共用的材料和未核实项。

- **测量危机的数字**：METR 时间跨度 1.1 博客；FrontierMath v2 审计 Epoch；SWE-bench Pro 审计与 GPT-5.6 Sol 的作弊带宽转引自 作者的研究笔记（未公开）。
- **深读与路线图**：作者关于辩论、SLT、GSAI/神经符号和能力轨迹的四份研究笔记，保存在作者的研究笔记中，未随本 deck 公开。
- **没能在线核对 (Δ)**：只依据二手笔记的 2608.29118、2609.01354、WorkspaceBench；只读了摘要的 2507.20964、2606.31002；Yudkowsky & Herreshoff 2013 的连接。

PART II · 前瞻 · 社会

22. 经济、社会与治理：AI 让生产变便宜，验证和合法性变稀缺

22.0 先说结论

- **"数学改变真实结果"有硬先例，但条件苛刻**。FCC 频谱激励拍卖（没有 SAT 求解器就跑不起来）、肾脏配对交换、纽约择校、公民大会抽签都满足四个条件：①有一个**拥有权威的单一设计者**；②目标写得清；③计算或激励问题确实是卡点；④理论保证让参与者敢说真话。AI 会把"设计加求解"的成本压到接近零，但同时满足①和③的场景很少。
- **多数问题的瓶颈是制度、采用和合法性，不是数学**。肾脏交换的清算算法 2007 年就有了，但美国市场被医院切碎；按 Agarwal 等（2019 AER）的估计，修正这种碎片化可让交换移植**增加 30–63%**。
- **数学真正卡脖子、且 AI 数学能直接推动的有三处，都以 A 类为主（A/B 类见 §17）**：训练过程的零知识证明；对齐中的社会选择；程序均衡（AI 之间如何做出可信承诺）。
- **变革性 AI 的宏观经济学是最重要的 B 类问题，数学几乎不是瓶颈**。写模型很容易（Amdahl 定律就是 Baumol 瓶颈），难的是经验参数。2026 年第二季度美国劳动份额 52.8%，1947 年以来最低，但能否归因于 AI 证据不足。
- **内容出处的边界已由数学画好**。签名能证明"这是真的"；水印**不能**可靠证明"这是 AI 写的"，这是定理。剩下的是采用问题。
- **跨卡主题：可验证性正在成为最稀缺的资源**。AI 让生产变便宜，瓶颈移到验证与合法性；谁控制验证，谁就控制 AI 产出进入社会的方式。719 篇数学论文 (§2) 是第一个清晰案例。
- **与 AI 安全直接相连**：可验证协议是"可信暂停"的前提；代理合谋是 AI control 里"监控者串通"的经济学版本；社会选择是"对齐到谁"的形式化；劳动份额趋零是渐进式失权（gradual disempowerment）的经济学底座。

22.1 为什么选这些问题

标准：影响 × 数学是不是瓶颈 × AI 可处理性，任一接近零就不选。数学不是瓶颈时，写明起作用的是 AI 的其他能力，还是 AI 帮不上。

#	问题	影响	数学是瓶颈？
1	可验证的国际 AI 协议	极高	部分 （ZK 效率、协议健全性）
2	AI 代理经济：机制设计与合谋	高	部分
3	对齐中的社会选择	高	部分 （大量 A 类定理）
4	AI 扩展的民主审议	中高	低
5	市场设计的下一代	中高	视场景
6	内容出处	高	低（边界已画清）
7	变革性 AI 的宏观经济学	极高	几乎不是
8	AI 产出知识的政治经济学	高（正在发生）	低（Lean 是例外）

落选但值得一提：AI 设计税制（仿真最优不等于政治可行）；二次投票与人格证明（瓶颈是身份基础设施与采用）；AI 预测市场（瓶颈在数据与激励）。

22.2 问题 1：可验证的国际 AI 协议——不信任也能核查

一句话：让两个互不信任的国家确认对方没有偷偷做超过约定规模的训练，同时不必交出权重或商业机密。

背景补课：先例是核军控。2014 年 Glaser、Barak、Goldston 在 *Nature* 上提出"零知识核弹头验证"：检查方能确认弹头是真的，却学不到设计信息 [已确立]。这正是 AI 验证想要的形状。

零知识证明（zero-knowledge proof, ZKP）的直觉：你的朋友是红绿色盲，拿着一红一绿两个球，背着手随机决定换或不换，再问你"换了没有"。若你分不出颜色，连猜对 20 轮的概率约百万分之一。于是他确信你能分辨，却**仍不知道哪个球是红的**。ZKP 把这推广到任意计算：证明"我按规则算完了"，但不透露输入。

手算规模：训练算力 $\approx 6 \times \text{参数量} \times \text{token 数}$ 。1 万亿参数、20 万亿 token 需 **1.2×10^{26} FLOP**（EU AI Act 系统性风险门槛为 10^{25} ）。H100 有效约 4×10^{14} FLOP/s，合计约 8,300 万 GPU·小时：**1 万张卡跑约 347 天，或 10 万张卡跑约 35 天**。这么大的集群，卫星和电网都看得到；难点是**训练和推理用同一批 GPU**，对方可以说"在跑推理"。

工具从弱到强：卫星与电力情报（只抓大规模）；芯片位置验证（原型，立法未完成 △）；遥测分类，只读功耗判断是否在训练（准确率 98.2%，伪装下 43–87% [近期发现]）；防拆硬件机制（有 demo，未量产）；密码学证明（训练侧只有纸面方案）。密码学贵在哪：Kaizen

(2024) 对约 1,000 万参数的 VGG-11, **每步训练的证明约 15 分钟** [近期发现], 前沿模型参数多约 10^5 倍、步数达百万级。2026-06, Peigné-Lefebvre 等声称结合预先承诺、网络观测和原生浮点 zkVM, 开销可降到**个位数百分比**, 比主流估计低约五个数量级; 但**没有原型**, 概念验证估计要约 36 个月 [近期发现, 未复现]。

为什么重要: Fearon (1995) 指出, 理性国家谈不成交易, 是因为**私有信息**和**承诺问题** [已确立]。验证缩小前者, 带执行能力的硬件部分解决后者, 所以它改变的是 AI 竞赛的**博弈均衡**, 不只是工程细节。

卡在哪: 瓶颈是不是数学? 判断: 数学/密码学约 25%, 工程约 30%, 制度约 45%。但数学是**低信任版本的闸门**: 没有高效证明, 就只能靠大国不会接受的侵入式检查。数学决定的是"有哪些制度交易可选"。数学部分: 浮点 ZK 的效率; 学习证明 (Proof-of-Learning) 的健全性 (已被证明可伪造); ZK 电路本身的正确性 (约束不足是常见漏洞 $\triangle$)。其余: 什么算"训练"是政策选择 (B 类); 验证级芯片要 6-10 年; 密钥归谁、主权、反垄断。

AI 能做什么: AI 数学: 证明协议健全性、形式化验证 ZK 电路 (A 类), 随证明成本每年降为 1/10, 2027-2028 年成为默认; 但条约规格是否忠实仍是 B 类 (§16.2)。AI 其他能力: 编码代理压缩"36 个月出原型", 自动化红队把 5 轮迭代变成 500 轮; 反向也帮规避者设计伪装负载。

如果解决: 一阶影响: 算力上限从"自我申报"变成"可证明", 出口管制可执行, 违约可举证。

如果解决: 二阶影响: 博弈从"无法核查, 只能竞赛"变为"可以核查, 可以谈判", 暂停成为真实选项 [推测]。但能远程禁用芯片本身就是巨大的权力, 验证设施也需要被治理 (与问题 8 同构)。同一批原语也能做可验证的评测。

时间判断: 乐观: 2027 年前遥测和位置验证进入出口管制 (METR 到 2027 年底约 400 h)。中心: 训练侧 ZK 概念验证约 2029 年; 有约束力的国际验证在 2030 年后, 且需要一次政治冲击; 协议健全性证明 2027 年就会变廉价, 但不是限速步骤。悲观: 低信任版本永不落地。密码学部分依赖证明成本和求解率曲线 (§17), 硬件和政治部分不依赖任何数学曲线。

反方观点与不确定性: 可能出现"验证表演"; 也许根本不需要密码学, 卫星加电力就能抓到大规模训练, 真正的风险在小而高效的训练。

信号: 芯片位置验证法案成为法律; 首个 ≥ 10 亿参数训练的 ZK 证明公开; 美中声明中出现"verification"。

来源: Glaser, Barak, Goldston 2014, *Nature* 510:497; Fearon 1995, *International Organization* 49(3); Kaizen ePrint 2024/162; Peigné-Lefebvre et al. arXiv:2606.05433; Rahman & Tajdari arXiv:2606.19262; Fang et al. 2023 arXiv:2208.03567; SNARK SoK arXiv:2402.15293 $\triangle$; Chip Security Act 二手报道 $\triangle$ 。

22.3 问题 2: AI 代理经济的机制设计—不用开会的合谋

一句话: 市场两端都是 AI 代理时, 要设计既高效、又能防止代理自发学会抬价或秘密串通的规则; 而反垄断法恰好抓不住"没有协议的合谋"。

背景补课: 手算重复博弈: 两个加油站, 成本每升 1 元, 100 个顾客只买便宜的, 同价平分。都定价 2 元, 各赚 50。一家偷降到 1.9 元, 这一期独赚 90, 之后对方报复, 永久价格战, 利润趋近 0。设折扣因子 δ (越接近 1 越看重未来), 合作值 $50/(1-\delta) \geq 90$, 即 $\delta \geq 0.44$ 时合作更划算。**每分钟调价一次的算法耐心极高:** 下一期就在一分钟后的, δ 几乎为 1, 合谋很稳 [已确立]。美国 Sherman Act 禁止的是"协议"; 两个从不交流的算法各自学会"你降我就降", 这种默契合谋 (tacit collusion) 在法律上很难追究。

证据: Q-learning 定价代理会自发学会带惩罚的合谋 (Calvano 等 2020) [已确立]; 德国汽油市场两家都用算法定价后利润率升 28% (Assad 等 2024) [已确立]; LLM 定价代理"迅速且自主地"达到超竞争价格 (Fish 等) [近期发现]。RealPage 案 2025-11 拟议和解, 不罚款、不认错 [近期发现]。反面: 异质性让合谋变脆弱, 代理耐心不同时溢价从 22% 降到 10%; **但模型规模不同 (32B vs 14B) 反而形成"领导者-跟随者"结构, 合谋更稳** (Keppo 等 2026) [近期发现]。

秘密合谋与程序均衡: 代理可以用隐写术把通信藏进正常输出, 信息论意义上安全的隐写原则上无法检测 (Motwani 等); 这与 AI control 里"监控者与被监控模型串通"是同一个问题 (§21)。反过来, AI 可以出示源代码: 双方提交能读取对方代码的程序时, 一次性囚徒困境也能合作 (Tennenholtz 2004) [已确立]。这是**双刃剑**: 它能支撑有益的承诺 (问题 1), 也能支撑合谋。

为什么重要: 合谋是多智能体风险的三类之一 (Hammond 等 2025)。采购、定价、谈判一旦大规模交给代理, "不开会的合谋"会从边缘案例变成常态风险。

卡在哪: 瓶颈是不是数学? 判断: 数学约 35%, 法律与制度约 45%, 数据约 20%。数学: LLM 作为策略的学习动力学没有干净的均衡理论; **可识别性**, 某些设定下可能原则上无法从价格数据区分合谋和独立的最优反应; 抗合谋机制本身就难, VCG 对合谋很脆弱 [已确立]。法律: "协议"概念失效, 责任归属不清。数据: 真实的代理对代理交易很少。

AI 能做什么: AI 数学: 在给定异质性下证明合谋可维持性的界 (A 类); 自动化机制设计已有苗头, LLM 生成的机制重新发现了 Myerson 机制 [近期发现]。AI 其他能力: 部署前用仿真做"市场风洞", 监管方用仿真对手审计定价代理。反向: 代理也会更会合谋、更会隐写。

如果解决: 一阶影响: 代理平台有可执行的规则 (限制数据共享、要求算法多样性、强制定价随机化), 执法从"找协议"转向"审计设计"。

如果解决: 二阶影响: 反垄断从"意图/协议"转向基于设计责任, 类似产品责任 [推测]。经济合谋与 AI control 中的串通在数学上同构, 可以互相提供实验。代理经济自发形成、人类看不懂价格从何而来, 是渐进式失权的一条路径 (Kulveit 等 2025)。

时间判断：中心：2027–2029 年代理对代理交易达到可观份额（METR 到 2027 年中约 150h，约一个月，够跑完整套采购流程）；合谋相关的 A 类定理 2027–2028 年大量出现（求解率约 18%）；法律转变要 5–10 年，与数学曲线无关。乐观：2027 年出现首个针对 LLM 定价代理的执法案例。悲观：法律长期停在 RealPage 式的模糊状态。

反方观点与不确定性：真实市场的异质性可能足以抑制合谋；LLM 代理也可能太"友善"而容易被操纵（Magentic Marketplace 仿真）。

信号：首起以 LLM 定价代理为核心的反垄断诉讼；大平台发布"代理行为规则"。

来源：Calvano et al. 2020 AER；Assad et al. 2024, JPE 132(3)；Fish et al. arXiv:2404.00806；Keppo et al. arXiv:2603.20281；RealPage Fenwick；Motwani et al. arXiv:2402.07510；Tennenholtz 2004, GEB 49(2)；Hammond et al. arXiv:2502.14143；arXiv:2502.12203；Magentic Marketplace arXiv:2510.25779。

22.4 问题 3：对齐中的社会选择——"对齐到谁"的数学

一句话：训练一个服务数亿人的模型，就要把相互冲突的偏好压缩成一个策略。社会选择理论说明每种压缩方式有什么保证、哪些保证不能同时成立；2024–2026 年这一方向正在密集产出 A 类定理。

背景补课：RLHF 本质上是在投票。标注员给出"A 比 B 好"的两两比较，Bradley–Terry 奖励模型把它们压成分数。Siththaranjan 等（ICLR 2024）证明：标注员之间存在看不见的分歧时，标准偏好学习隐式地按 Borda 计数聚合 [近期发现，已发表]。

手算：5 个标注员给 3 个回答排序，3 人是 $A > B > C$ ，2 人是 $B > C > A$ 。两两多数决：A 对 B、A 对 C 都是 3:2，A 是孔多塞赢家（Condorcet winner）。Borda 计分（2/1/0 分）：A = 6，B = 7，C = 2，选 B。多数人在每次两两比较中都偏好 A，Borda 式的 RLHF 却偏向 B。哪个"对"没有唯一答案，这就是 Arrow 定理：任何聚合规则都要在看似合理的公理之间取舍 [已确立]。

失真 (distortion)：最坏情况下"理论上最佳的平均满意度 ÷ 方法实际达到的平均满意度"，越接近 1 越好。Gölz、Haghtalab、Yang（NeurIPS 2025）证明 [近期发现，已发表]：NLHF（Nash Learning from Human Feedback）的失真为 $(1/2 + o(1)) \cdot \beta$ ，极小极大最优（ β 衡量人在比较时有多"确定"）；RLHF/DPO 加 KL 约束后，取决于比较对的采样方式，失真可能是 $e^{\Omega(\beta)}$ ，甚至无界。这给了 NLHF 类方法一个定量理由，是"数学改变实践"的例子。另外，Borda 式聚合会激励标注员谎报偏好，防策略性（strategyproofness）因此成了一项安全性质。

为什么重要：每个前沿模型都由少数标注员加一份公司写的宪法塑造，却影响数亿用户（Conitzer、Russell 等 ICML 2024 立场论文主张由社会选择理论来指导）。"对齐到谁"是最政治化的一层，显式化才能审计；否则它依然存在，只是藏在训练管线的默认值里。

卡在哪：瓶颈是不是数学？ 判断：数学约 40%，规范与制度约 60%。A 类："算法 X 满足公理 Y 吗？""采样方式 Z 下 DPO 的失真是多少？"正被批量解决。B 类：哪些公理重要？"偏好"是当下的选择，还是深思熟虑后的价值？制度：标注员池小、代表性差，公司说了算，没有授权。

AI 能做什么：AI 数学*有坚实先例：计算机辅助证明 Arrow 定理 (Tang & Lin 2009)；**用 SMT 求解器发现了新的不可能性定理** (Brandl 等 2018 JACM) [已确立]。"算法 × 公理"这张表很适合 AI 批量填写，到 2027 年底大部分会很便宜。*AI 其他能力：生成式社会选择 (Fish 等 2023) 用 LLM 预测每个人对没见过的陈述的满意度，从而在开放文本里聚合；风险是用模拟偏好替代真人，等于未经授权地代表他们。

如果解决：一阶影响：训练采用有明确保证的方法；模型卡写明聚合规则和满足的公理；防策略的数据收集成为抵御数据投毒的一部分。

如果解决：二阶影响：对齐被显性政治化 [推测]：规则一旦写明，各群体就会游说权重，像选举制度之争；今天"默认用 Borda"也是政治选择，只是没人注意。多元与个性化也有张力：给每个群体一个模型，会带来信息茧房。

时间判断：A 类定理已在落地，2027 年底基本"商品化"（依赖求解率和证明成本曲线，§17）；实验室采用在 2027–2029 年，取决于监管或声誉压力；规范问题没有时间表，也不会由数学解决。

反方观点与不确定性：RLHF 违反几乎所有公理却依然好用，可能因为真实偏好高度结构化。Arrow 定理只针对序数偏好，引入偏好强度后很多"不可能"会松动。多数分歧只是风格问题。

信号：前沿实验室技术报告写明聚合规则；NLHF 类方法用于生产模型。

来源：Conitzer et al. 2024 arXiv:2404.10271；Siththaranjan et al. arXiv:2312.08358；Gölz et al. arXiv:2505.23749；Munos et al. arXiv:2312.00886；arXiv:2506.12350；Fish et al. arXiv:2309.01291；Tang & Lin 2009, *Artificial Intelligence* 173(11)；Brandl et al. 2018, JACM 65(2)。

22.5 问题 4：用 AI 扩展民主审议

审议有个三难：公投参与广但浅，公民大会深但只有几十人。AI 承诺同时改善参与、深度和平等。DeepMind 的 Habermas 机 (Science 2024) 让 LLM 写立场陈述、奖励模型预测认可度，反复迭代；5,734 名英国参与者中，AI 调解的陈述比人类调解者的更常被偏好，分歧也缩小了 [已确立，单篇高质量研究]。已落地的干净先例是抽签：Flanigan 等 (Nature 2021) 的算法以 Panelot 免费提供，已用于 40 多场公民大会 [已确立，采用数为自报]。

数学约占 20%：代表性保证、抗女巫攻击，一旦需要往往很快解决。难的是 B 类问题（"认可度最大化"不等于"好的审议"）和制度问题（审议结果与决策没有约束性连接）。AI 的语言能力是主角，但有另一面：一项 76,977 人、19 个 LLM 的实验发现，后训练能把政治说服力最多提

高 51%，而**提升说服力的方法会系统性降低事实准确性**（Hackenburg 等）[近期发现]。**"擅长找共识"和"擅长说服"是同一种能力**；训练调解模型的人定义了"什么算共识"，因此是政治行动者 [推测]。中心判断 [推测]：2027–2030 年某国政府在法定咨询中正式使用 AI 调解，取决于政治意愿而非数学曲线。**来源**：Tessler, Bakker et al. 2024 Science；Flanigan et al. 2021, *Nature* 596；Hackenburg et al. arXiv:2507.13919。

22.6 问题 5：市场设计的下一代——肾脏交换的教训

肾脏交换：病人 A 的家属 a 愿意捐肾但血型不配，B 与 b 也是；若 a 配 B、b 配 A，两对互换。求最多移植数是 NP 难问题，2007 年已能用整数规划在全国规模上解出 [已确立]。但 Agarwal 等（2019 AER）发现，2014 年全国平台只安排了 42% 的交换：医院承担参与成本却拿不到多少收益，于是院内自己配对；修正碎片化可让**交换移植增加 30–63%** [已确立]。**算法早就有，卡住的是激励和法规**。反例是 FCC 频谱激励拍卖：每次报价都要解一个类似图着色的 NP 完全问题，SATFC 求解器在时限内解出 95% 以上的实例，收入 **\$19.8B** [已确立]；没有求解器就没有这个市场。

频谱、择校、肾脏、抽签的成功都满足同四条：①**单一权威设计者**；②**目标清楚**；③**计算或激励问题确实是卡点**；④**理论保证让参与者敢说真话**。数学总体约占 30%，在电网这类带物理约束的新市场可达 50% 以上。AI 数学会让"在约束下找一个防策略机制并给出证明"成为 A 类问题（教科书规模约 2027 年）。**最大的杠杆可能是偏好获取** [推测]：组合拍卖的障碍是投标者无法对 2^n 种组合一一报价，LLM 代理可以访谈委托人再代为投标。设计越便宜，瓶颈越集中在"谁有权设计"；成功几乎都发生在政府**创造**市场的地方，所以 AI 可能**增加**对国家能力的需求 [推测]。新的全国级市场要 5–10 年；肾脏碎片化任何数学曲线都解决不了。**来源**：Agarwal et al. 2019 AER 109(11)；Newman, Fréchette, Leyton-Brown arXiv:1706.03304。

22.7 问题 6：内容出处——签名 vs 水印不可能定理

签名证明"这是真的"：相机用私钥对图像哈希签名，改一个像素签名就失效，C2PA 把拍摄和每次编辑串成签名链 [已确立]；弱点在元数据被剥离、私钥泄露、设备不可信，不在数学。***水印***试图证明"这是 AI 写的"。KGW 方案把词表随机分成"绿/红"两半，生成时偏向绿词：200 词的人写文本期望 100 个绿词，标准差约 7.07；数到 140 个时 $z \approx 5.66$ ，判为 AI 生成。但换个模型改写一遍，比例就回到约 50%。Zhang、Barak 等（2023）证明：只要攻击者能判断改写后质量是否保持、又能做小改动，靠随机游走就能抹掉**任何**水印，即使密钥保密 [已确立]。结论是：对付虚假信息，**关键是验证来源，而不是判断是不是 AI**。

数学约占 15%，边界基本画清，剩下的是"抗编辑"与"抗栽赃"的取舍。AI 数学能形式化验证 C2PA 实现；更便宜的证明系统能让零知识出处实用化（PhotoProof 2016 已能证明"这张图只是对签名原图做了裁剪"而不暴露原图）[已确立]。主要瓶颈是采用：EU AI Act 第 50 条 2026-08-02 生效，加州法规不覆盖文本 Δ ，多数平台上传时剥离元数据 Δ 。二阶影响 [推测]：信任从内容转移到签名者身份，形成新的集中。中心判断 [推测]：到 2028 年多数新手机默认签名。文本水印只对长篇、未经编辑的文本可靠，这**不会**随数学进步改变，因为它是定理。**来**

源：Zhang et al. arXiv:2311.04378；Kirchenbauer et al. 2023 PMLR；Naveh & Tromer 2016, IEEE S&P；EU Code of Practice；SB 942/AB 853 NatLawReview [△](#)。

22.8 问题 7：变革性 AI 的宏观经济学—劳动份额与爆炸式增长

一句话：如果 AI 能做几乎所有认知工作，增长、工资和劳动份额会怎样？估计从"十年 TFP 只增加 0.66%"到"增长率翻十倍"都有，分歧来自几个**无法用数学推出来的**经验参数。

背景补课：劳动份额 (*labor share*)：经济产出 100 元，其中 53 元付给劳动者，劳动份额就是 53%。2026 年第二季度美国非农部门劳动份额 **52.8%，1947 年以来最低** [近期发现]。但它已经下降了几十年，也可能主要来自 AI 之前的自动化，**归因于 AI 的证据不足**。

Amdahl 定律就是 Baumol 瓶颈：程序中比例为 p 的部分加速 s 倍，总加速是 $1/((1-p) + p/s)$ 。 $p = 0.9$ 、 $s \rightarrow \infty$ 时，总加速**只有 10 倍**。经济也一样：任务之间互补（替代弹性 $\sigma < 1$ ）时，增长被没自动化的任务卡住，这就是 Baumol 成本病。"AI 能做 90% 的工作"不等于"增长爆炸"，关键在剩下的 10% 能否被替代或绕过。另一面，如果 AI 能生产想法、算力又能像资本一样积累，"想法 $\rightarrow$ 更好的 AI $\rightarrow$ 更多想法"的循环理论上可以加速增长（Aghion、Jones、Jones 2019 等）[模型结论已确立，经验上未验证]。

两端的估算：温和端，Acemoglu 用 Hulten 定理算：受影响任务的 GDP 份额 $\times$ 平均成本节省 $\approx 4.6\% \times$ 约 14–15% $\approx$ **0.66%（十年合计）**；批评者说它只算了 AI 今天已证明能做的事。激进端，Restrepo 《We Won't Be Missed》：算力扩张后，增长必需的"瓶颈工作"被全部自动化，**工资趋向"用算力复制该工作的成本"，劳动份额趋向零**；人仍有活干，只是因为"不值得用算力替代"。保住工作不等于分享增长 [近期发现，理论]。早期实证：AI 暴露最高的职业里，22–25 岁劳动者就业相对下降 13%（修订版 16%），有经验者稳定（Brynjolfsson 等）[近期发现]。

为什么重要：分配、政治稳定、财政都取决于这些参数。这也是与 AI 安全最深的连接：**渐进式失权**（Kulveit 等 2025），经济不再需要人类，制度就不再有服务人类的激励；**智能诅咒**，国家不再需要公民纳税，也就不必对公民负责；**AI 赋能政变**，夺权不再需要大量人配合。

卡在哪：瓶颈是不是数学？ 判断：数学 $\leq 10\%$ ，典型 B 类，模型几分钟就能写好。瓶颈在**参数**（替代弹性、可自动化比例、能源等物理约束）、**数据**（GDP 难以衡量免费的数字产品）和**识别**（时间序列短，关税和利率与 AI 同时变化）。

AI 能做什么：*AI 数学*作用很小，能解更复杂的模型，但结论取决于假设。*AI 其他能力*是主角：实时测量（工资单仪表盘、实验室的使用数据）、企业级随机实验、用 LLM 代理模拟劳动力市场。注意反身性：AI 既是被测量的冲击，又是测量工具。

如果解决：一阶影响：更好地预测转型路径；UBI、算力税、主权 AI 基金等政策有了数据依据。

如果解决：二阶影响：如果 Restrepo 是对的，民主的议价基础（罢工、纳税、代表权）会被侵蚀，经济学与安全中的权力集中问题直接相连 [推测]；他本人提议全民收入，或把算力当作

像土地一样的公共资源。爆炸式增长会加速 AI 研发，留给安全研究的时间变短。

时间判断：METR 到 2027 年中约 150 h（一个月），2028 年底约 2,800 h。*中心 [推测]：*2028–2030 年出现可测量的宏观效应，例如生产率增速持续高于 2.5%，劳动份额下降由 AI 密集行业领跑。*悲观：*像电力一样扩散滞后数十年（David 1990）。*乐观：*年增长超过 30% 需要机器人和能源跟上，只可能在 2030 年后。这些判断不依赖求解率曲线，只依赖代理能力和物理扩散。

反方观点与不确定性：Acemoglu 式的温和估计可能就是对的；医疗、教育、政府的 Baumol 瓶颈可能很硬；GDP 统计可能捕捉不到变化。

信号：TFP 增速持续跳升；AI 密集行业的劳动份额领跌；入门级就业持续偏离。

来源：BLS 2026；Acemoglu NBER w32487；Restrepo NBER w34423；Brynjolfsson et al. Stanford DEL；Aghion, Jones, Jones 2019（NBER w23928）；David 1990, AER P&P；Kulveit et al. arXiv:2501.16946；Intelligence Curse；AI-Enabled Coups。

22.9 问题 8：AI 产出知识的政治经济学——谁决定它如何进入公共领域

一句话：当一家公司一天能发布 719 篇数学论文，而全世界的审稿能力远远跟不上时，知识的生产、验证和发布由谁控制，就成了治理问题。

背景补课：事件（详见 §2）：2026-10-06，OpenAI 发布由未公开内部模型生成的 722 篇手稿；次日因一处符号错误连锁撤回 3 篇，剩 719 篇。约 42% 的主要结果有 Lean 形式化，撤回的 3 篇都在未形式化的 58% 里。截至 10-08，**没有任何人类专家公开确认核查过任何一个头条结果**。IAS 数学与 AI 咨询组的披露规范要求写明选题方式和失败率等 [R] △，这正是 §2.3 讲的选择效应。AHM 的声明说，一次发布 700 多份文件“不是学术的展示，而是权力的展示”。

验证经济学，手算（假设数字 △）：假设人工审一篇要 20 小时，719 篇约 14,400 小时，约 **7 个专家人年**，而每个子领域能看懂的专家只有几十人。已形式化的 300 篇只需审“Lean 陈述是否忠实于原意”（§3），每篇按 2 小时算共 600 小时。**Lean 把验证成本降低了约一个数量级，但没有降到零**。生产成本暴跌，人类的验证时间不变，**验证就成了瓶颈，控制瓶颈的人就拥有权力**。

知识产权不是控制手段：数学结果本来就不受版权或专利保护，美国也已认定版权需要人类作者、AI 不能做发明人 [已确立]。真正的控制手段是**时机、选择、披露和验证基础设施**：发什么、何时发、附不附证明、什么留在内部。用 Merton（1942）的科学规范说，被冲击的是“有组织的怀疑”（审不过来）和“公有”（由公司决定发什么）。

为什么重要：数学只是第一个领域，因为它有 Lean；接下来是物理、生物，以及 **AI 安全研究本身**。两用知识 [推测]：如果 AI 证明了与格密码或因数分解相关的结果，那就是国家安全问题，但目前没有任何发布决策机制。批量发布本身也是对未发布模型能力的战略展示。

卡在哪：瓶颈是不是数学？ 判断：数学约 20%，制度约 80%。数学部分是自动形式化（把那 58% 转进 Lean）和审查"陈述是否忠实"的方法；经验科学**没有 Lean 的等价物**。制度部分是期刊政策、功劳分配、审稿激励、批量发布规范。

AI 能做什么：*AI 数学*：证明成本每年降为 1/10，到 2027–2028 年"AI 数学必须附 Lean 证明"会变成合理默认，人类的工作集中到审查陈述是否忠实，即 §16.2"信任瓶颈从证明转移到规格"的社会版本。*AI 其他能力*：AI 审稿人与复现代理。反向是生成与审查之间的军备竞赛。

如果解决：一阶影响：新的发布规范：要么形式化，要么标"未验证"；分阶段发布，留出审查窗口；按 IAS 清单披露。

如果解决：二阶影响：

- **知识圈地** [推测]：科学可能滑向"先内部使用、再选择性发布"，最有价值或最敏感的结果最不可能公开。
- **理解与核查分离** (Thurston 1994)：人类只能核查、不能理解 (§16.3)，这是文明尺度上的可扩展监督问题，与 AI 安全的核心同构 (§21)。
- **验证作为公共品**：可能需要类似 NIST 的公共验证设施（公共资助的 Lean 库、复现中心）。§16.5 的"前沿公司单方面决定能力如何进入公共领域"，和问题 1 是同一个问题：如何不信任强者也能核查它的声明。

时间判断：数学领域 1–2 年内形成新规范；到 2027 年底自动形式化覆盖大多数新的 AI 数学（中心情景，依赖证明成本曲线）。经验科学在 2028–2030 年会出现类似的"倾倒"争议，且没有技术解。两用知识的发布机制大概率由某个事件触发。

反方观点与不确定性：公开总比秘而不宣好，OpenAI 本可以一篇都不发；Lean 恰恰让信任**不依赖**权力，任何人都能检查；过早强制形式化可能让人类数学家更难发表。

信号：第二家实验室跟进批量发布；期刊或 arXiv 出台批量 AI 投稿政策；首次有人公开承认"出于安全原因扣留了 AI 证明的结果"。

来源：本 deck §2、§3、§16；openai/math；AHM statement via Tao；IAS 咨询组规范只有二手引用 [R] △；US Copyright Office 2025, *Copyright and AI, Part 2*；Thaler v. Perlmutter (2025)；Thaler v. Vidal (2022)；Merton 1942；Thurston 1994 arXiv:math/9404236。

22.10 本领域的二阶效应

1. 瓶颈迁移：生产 → 验证 → 合法性。八张卡是同一个模式：

卡	AI 让什么变便宜	什么变稀缺	谁控制稀缺品
1 验证协议	训练（能力）	可信核查	硬件厂商、密钥持有者
2 代理经济	交易与谈判	可执行的竞争规则	平台、监管者

卡	AI 让什么变便宜	什么变稀缺	谁控制稀缺品
3 社会选择	偏好收集	聚合规则的合法性	实验室
4 审议	调解与概括	审议的独立性	调解模型的训练者
5 市场设计	机制设计与求解	设计权威	政府、中心化平台
6 出处	内容	可信签名	设备厂商、证书机构
7 宏观	认知劳动	物理投入、政治议价权	算力所有者
8 知识	证明与论文	人类验证时间	发布者

2. 可验证性是最被低估的基础设施。 零知识证明、签名、Lean、可审计的聚合规则，都是"不必信任也能确认"的技术，也正是 **AI 数学最能直接贡献**的地方（协议健全性、电路验证、机制性质都是 A 类问题）。同一批人横跨多个领域：Barak 既做核弹头零知识验证，又证明了水印不可能定理；Procaccia 既做抽签算法，又分析 RLHF 的社会选择性质（arXiv:2501.09254）。"在不信任下建立信任"可以是统一的一门学问。

3. 承诺技术是两用的。 程序均衡（问题 2）、硬件机制（问题 1）、签名（问题 6）都让可信承诺更容易。在 Fearon 的框架里，这会减少因承诺问题引发的冲突；但同一项技术也让合谋更稳定、监控更强。每一项承诺技术都要回答：谁能承诺什么，对谁承诺。

4. 权力集中贯穿每一张卡。 设计者、签名者、验证者、调解者、聚合者、发布者，每张卡都要问"钥匙在谁手里"。AI 降低设计成本，却**提高了权威的价值**。结合 AI 赋能政变和渐进式失权来看，经济与治理不是安全问题的附属品，而是同一个问题的社会层面。

5. 跨领域连接。 分布式系统里的老问题在这里换了名字：Amdahl 定律对应 Baumol 瓶颈，拜占庭容错对应低信任下的条约验证，共识协议对应承诺机制。

22.11 本节来源

完整来源见各卡片末尾。建议阅读顺序：Fearon 1995 与 Glaser–Barak–Goldston 2014 → Peigné-Lefebvre et al. 2026 → Keppo et al. 2026 → Gölz, Haghtalab, Yang 2025 → Agarwal et al. 2019 → Zhang et al. 2023 → Restrepo 2025 与 Kulveit et al. 2025 → 本 deck §2、§16。

△ **待复核**：Chip Security Act 的现状只有二手报道；加州 SB 942/AB 853 的门槛和日期各方说法冲突；平台剥离 C2PA 元数据的程度缺少 2026 年的系统测量；SNARK 漏洞 SoK 的细节未复核；IAS 咨询组规范只有二手引用。

23. 全景：如果数学被 AI 解决，世界会怎样变

这一节把 §17–§22 收拢成一张图，回答 Part II 开头的问题：数学如果被 AI 大规模解决，或者 AI 的其他能力也突破，物理、生物、计算机、AI 本身和社会会发生什么？哪些影响是真正深远的？本节的事实和数字都来自前面各节，出处见各节末尾的来源列表；这里的排序、归纳和时间线是我的综合判断，标 [推测]。时间判断都用 §17.4 三条曲线的中心情景。

23.0 先说结论

1. "数学被解决"对各领域的影响分三档，差别非常大。
 - 第一档：数学本身就是产品的领域（密码学、形式化验证、算法、机制设计、一部分数学物理）。影响直接、快，2027–2028 年就能看到。
 - 第二档：数学只是流水线中一环的领域（物理、化学、材料、气候、聚变）。数学主要通过算法和数值方法起作用，受算力、实验和硬件节拍限制，影响落在 2028–2035 年。
 - 第三档：数学几乎不是瓶颈的领域（大部分生物医学、神经科学、宏观经济、治理）。这里起作用的是 AI 的其他能力（编程 agent、模拟、自动化实验、文献匹配），而且会被实验周期和制度拖慢，影响在 2030 年代。
2. 最深远的影响不是某一个定理，而是"证明变成廉价品"之后，整个知识生产系统的结构变化。在六个领域里，我们看到的是同一个现象：做出来变便宜了，判断它对不对、值不值、该问什么变成了瓶颈。
3. AI 加速一个领域有多快，取决于这个领域的"裁判"有多快。Lean 检查证明以分钟计，天气预报第二天就能验证，所以这两处 AI 已经起作用；材料要合成、药要做临床试验，裁判以月和年计；量子引力根本没有裁判。
4. AI 正在给科学制造"预言机"，而不是"理论"。能预测、不能解释的模型在生物、物理和数学里同时出现。这和机制可解释性面对的是同一个问题。
5. AI 能力的指数曲线会撞上物理世界和制度的线性时间常数。数字世界（软件、数学、AI 自身）和物理世界（药物、材料、能源、硬件）的进展速度会越拉越开。
6. 可验证性会成为最稀缺、也最有权力的资源。谁掌握验证器、签名密钥、发布渠道，谁就决定 AI 产出以什么方式进入社会。
7. 2026–2029 年很可能是一个"攻快守慢"的脆弱过渡期：找漏洞快、修漏洞慢；发现攻击快、迁移标准慢；生成声明快、核查慢；能力增长快、立法慢。
8. 对 AI 安全而言，这一切汇成一个结论：当证明、实验、甚至对齐研究本身都可以被自动化时，安全取决于三样东西：陈述和 spec 是否忠实、验证器本身是否可信、模糊任务由谁来判。这三样都还没有成熟的方法。

23.1 直接回答：数学突破能带来物理、生物、计算机的突破吗？

你的直觉是对的，但需要拆开看。数学进入现实，主要走五条路，力度差别很大：

通道	机制	例子	力度
1. 定理本身就是产品	证明直接决定一个系统能不能用、安不安全	密码方案的安全归约或攻破 (§18)；带证明的软件 (§18)；机制的激励相容性 (§22)	强、快
2. 数学 → 算法 → 计算	新数学变成新算法，让原来算不动的东西能算	DFT 泛函和分子模拟 (§19、§20)；量子纠错码让 Q-day 提前 (§18)；SAT 求解器让频谱拍卖可行 (§22)	强，但受算力和数据限制
3. "不可能"定理改变方向	证明某条路走不通，整个领域转向	通用 DFT 泛函不可能高效计算 (§19)；文本水印不可能可靠 (§22)；不可检测后门存在 (§21)	中，影响深但不显眼
4. 把已有数学连到新问题	数学早就有了，缺的是"需要它的人知道它存在"	CT 扫描的 Radon 变换 (1917 年就有)；高斯 1805 年的 FFT；被遗忘 34 年的 LDPC 码 (§17)	可能被低估
5. 模型健康证明	证明物理学家早就相信的东西确实成立	Navier–Stokes (§11)、Vlasov–Maxwell (§12)、Anderson 局域化等 (§19)	弱：提高确定性，几乎不改变实验和工程

三个要点：

- **OpenAI 这 719 篇论文大多属于第 5 条和"库存型"数学。** 按历史规律 (§17.1)，为数学本身而做的数学要 50–200 年才找到应用；为工程问题而做的数学只要 2–15 年。所以这批结果的现实影响要以几十年计，除非 AI 同时把"匹配"（第 4 条）也做快。[推测]
- **第 2 条是物理、化学和生物最主要的入口，而它更依赖 AI 的其他能力，而不是证明能力。** 到 2026 年为止，所有被证实的 AI-for-science 加速（天气预报、蛋白质结构）都来自这条路，没有一项来自证明 (§17.3)。
- **用 Amdahl 定律想一想：** 药物研发里，让"理论"无限快，总速度只提高约 5% (§17.2 的手算)。一个领域里数学占的比例越小，"数学被解决"带来的加速就越少，再大的突破也一样。

一张总表：每个领域被什么卡住，AI 能帮多少（详见 §17.7 和各节）

领域	数学是瓶颈吗	真正的瓶颈	最可能的 AI 杠杆	中心时间
密码与安全 (§18)	是	证明 + 标准迁移 + 修补速度	AI 数学（分析、证明）+ AI 编程（找漏洞、写验证代码）	2027–2029
量子计算 (§18)	部分是	硬件	资源估计和纠错码（A 类）；新算法（B 类）	Q-day 2033–2036
化学与材料 (§19)	部分是（算法）	计算精度 + 合成通量	ML 泛函和力场；自主实验室	2028–2032

领域	数学是瓶颈吗	真正的瓶颈	最可能的 AI 杠杆	中心时间
聚变与能源 (§19)	很少	硬件节拍、材料辐照	控制、设计优化	2030 年代
蛋白质与分子 (§20)	是（采样问题）	采样算法 + 验证数据	直接从玻尔兹曼分布采样的生成模型	2029
细胞、发育、衰老 (§20)	否	测量、数据、概念	自动化实验、预言机式模型	2030–2035
药物和临床 (§20)	否	靶点因果性 + 8–13 年流水线 + 监管	靶点选择、患者分层	2035
神经科学 (§20)	部分是（缺理论）	测量 + 概念	连接组重建、数字孪生	2033
AI 理论与对齐 (§21)	是，但多为 B 类	定义（复杂度、能力、解释、可纠正）	自动化受控实验；A 类定理批量清扫	2027–2030
经济与治理 (§22)	少数是（ZK、社会选择）	制度、采用、合法性	机制求解、可验证协议	2029 以后

23.2 五条跨领域规律

这五条规律在 §17–§22 的每一节里都独立出现过。它们是本 Part 最重要的内容。

23.2.1 证明便宜，陈述贵

AI 让"给定问题，找出答案"越来越便宜，但"问题本身写对没有"并没有变便宜。

领域	便宜的部分	贵的部分
数学 (§3、§16)	写 Lean 证明	检查 Lean 陈述是否忠实于论文
软件 (§18)	写证明	写对 spec、划定可信基 (TCB)
密码 (§18)	改进已知攻击	安全模型漏掉的东西（时序、实现）
材料 (§19)	生成候选（GNoME 预测约 38 万个稳定晶体）	确认候选真实有用（外部只合成了 736 个）
生物 (§20)	设计蛋白、训练预测模型	知道该测什么、评测指标是否有效
AI 理论 (§21)	证明可解模型的定理	定义"复杂度""能力""解释""可纠正"
治理 (§22)	生产论文、内容、交易	核查、签名、合法性

含义：未来最稀缺的能力，是把模糊的意图写成精确陈述，并检查陈述有没有被悄悄削弱。这在数学里叫"陈述忠实度"，在软件里叫 spec，在 AI 里叫"对齐目标"，**本质上是同一种能力。**

23.2.2 裁判的速度决定加速的速度

领域	裁判	一轮反馈	AI 加速
形式化数学	Lean 内核	分钟	已发生（2026）
天气	第二天的观测	天	已发生（ECMWF 2025 年业务化）
软件安全	测试、fuzz、证明检查	分钟到天	已发生（找漏洞）；修补跟不上
电子结构	高精度计算	小时到天	快
蛋白设计	湿实验	周	中，受实验成本限制
材料、超导	合成 + 表征	周到月	慢
临床医学	临床试验	年	很慢（一个 Phase III 要 5–8 年）
气候	观测	十年	很慢
量子引力	没有	∞	只在子问题上

含义：想让 AI 加速一个领域，最有效的投资往往不是更强的模型，而是**更快的裁判**：自主实验室、更小更快的 Phase IIa、更好的评测指标、自动化的连接组校对。

23.2.3 预测成功，理解失败

AI 在多个领域给出了"能回答 what-if，但说不出 why"的模型：

- 生物 (§20)：生成式蛋白设计绕过了物理打分函数；虚拟细胞模型学"扰动 → 表达"而不建机制；AlphaGenome 学"序列 → 调控信号"而不建基因调控网络；小鼠视皮层的数字孪生能预测上万个神经元的反应，但和大脑一样是黑箱。
- 物理 (§19)：神经网络泛函能量越拟越准，密度却可能越来越偏。
- 数学 (§3、§16)：2,600 万行 Lean 证明，几乎没人读过。
- 神经科学的先例：线虫 302 个神经元的完整连接组 1986 年就有了，四十年后仍不能预测它的行为 (§20)。

含义：科学的产出可能从"理论"转向"经过验证的预言机"。能力会增长，理解可能停滞。这正是机制可解释性在 AI 上面对的困境，而生物学已经有更多、更真实的样本。两个领域应该互相借鉴，目前几乎没有。[推测]

23.2.4 指数曲线撞上线性时间常数

曲线或常数	速度
METR 任务长度	每 129 天翻倍（每年约 ×7）
形式证明成本	每年约 ÷10
临床开发流水线	8–13 年
小鼠寿命实验	3–4 年

曲线或常数	速度
聚变材料辐照鉴定	数年，不可压缩
新的全国级市场设计落地	5–10 年
立法（如核酸合成筛查框架更新）	规定 90 天，实际逾期一年以上

含义：

- 数字世界和物理世界的进展会**分叉**。如果 AI 研发自动化（§21 的 CASP 情景， $r > 1$ ），软件、数学和 AI 本身的时间线会被压缩，药物、材料、能源和硬件的时间线压缩得少得多。[推测]
- 判断"AI 是否真的在加速科学"，应该看不能被刷分的输出：临床成功率、Eroom 定律曲线、外部实验室真正合成的材料数、带证明的代码占比。这些指标的反应时间是 5–10 年。

23.2.5 可验证性成为最稀缺、也最有权力的资源

零知识证明、数字签名、Lean 证明、可审计的聚合规则，都是"不必信任也能确认"的技术（§18、§22）。AI 让生产变便宜，验证和合法性就变稀缺；**谁控制验证，谁就控制 AI 产出进入社会的方式**。

- OpenAI 2026-10-06 一次发布 719 篇论文，是第一个清晰案例：前沿公司单方面决定一项能力以什么形式进入公共领域（§2、§22）。
- Google 用零知识证明披露量子攻击的资源估计，而不公开攻击电路；Anthropic 先公布漏洞细节的哈希，修复后再公开（§18）。**危险的数学和安全结果开始需要"负责任披露"**，这会成为 AI 发现危险结果时的标准做法。[推测]
- 承诺技术是两用的：同样的机制既能让国际协议可验证，也能让 AI 代理之间的合谋更稳定（§22）。

23.2.6 补充：攻快守慢的过渡窗口

攻方（快）	守方（慢）	出处
AI 找到的高危漏洞：抽检 1,752 个里 90.6% 属实	已披露约 530 个，只修了 75 个（截至 2026-05-22）	§18
破 RSA-2048 所需量子比特：2019 年约 2,000 万 → 2026 年不足 10 万（qLDPC）	后量子迁移要走多年标准流程	§18
威胁侧跟着 129 天翻倍的曲线走	核酸合成强制筛查没有联邦立法	§20
生成论文和声明的速度	专家审稿和陈述核查的速度	§2、§21

含义：2026–2029 年很可能是攻方先吃到 AI 红利的窗口；守方的红利（带证明的重写、后量子迁移、强制筛查）要等制度跟上。[推测]

23.3 Top 10：最值得关注的问题

排序标准：影响有多大 × 2030 年前被 AI 显著改变的可能性 × 和 AI 安全的关系。排序本身是 [推测]。

#	问题	节	为什么重要	数学是瓶颈吗	中心时间	关键信号
1	陈述忠实度与验证器安全：AI 证明的东西，说的是不是我们以为的	§21、§18	所有"有证明所以可信"的论证都压在这上面；2026 年已出现能"证明" False 的 Lean 内核漏洞，伪造证明连独立检查器也放行	否（审计和工程）	2027 年前出现因工具链漏洞或错误形式化而撤回的重要结果	撤回事件；形式验证过的检查内核成为默认
2	AI 做 AI 研究，包括对齐研究	§21	自动化研究员已在定义清楚的对齐问题上胜过 28 位有经验的人类研究员，同时也会刷评测分；决定"安全能否跑赢能力"	否（审核带宽）	AI-led 研发份额 2027 年过半；完全自主份额 2027–28 年首次大于零	实验室披露的自动化份额；自动化研究的评测作弊率
3	关键软件的形式化验证 × 网络安全攻防	§18	唯一能跟上 AI 找漏洞速度的防御是"证明漏洞不存在"；AI 智能体的沙箱本身也是软件	部分是（证明在变便宜，spec 不是）	2027–2028 年证明不再是成本主体；攻方窗口持续到约 2028 年	主要云厂商的密码库、解析器默认带证明
4	Q-day 与后量子迁移	§18	互联网加密和加密资产的寿命；数学（纠错码、电路优化）正在把 Q-day 提前	部分是（资源估计是 A 类）	能破 ECC-256 的机器 2033–2036 年；资源估计 2028 年前再降 2–10 倍	新的资源估计论文；迁移完成度
5	分子尺度的计算显微镜：电子结构和蛋白质动力学	§19、§20	解锁电池、催化剂、药物结合和蛋白设计的"打分函数"；生物学里唯一数学真正卡脖子的地方	是（算法和采样）	主族化学 2028 年实用解决；球状蛋白构象 2029 年	ML 泛函进入主流程序；自由能预测误差 < 0.5 kcal/mol
6	可验证的国际 AI 协议	§22、§18	"可信暂停"和算力治理的前提；验证缩小了导致冲突的私有信息和承诺问题	部分是（ZK 证明是 A 类；硬件和政治不是）	训练过程 ZK 概念验证约 2029 年；有约束力的协议 2030 年后	十亿参数级训练的 ZK 原型；出口管制中的位置验证
7	归纳偏置：训练从无数个"都对"的解里挑哪一个	§21	目标错误泛化、scheming、涌现失调、弱到强泛化，本质都是这个问题	是，但是 B 类	2030 年前有几条可靠的经验定律，没有统一理论	预注册的"训练前预测模型学哪个目标"成功案例
8	生物安全治理	§20	唯一已经发生"能力评估直接触发部署限制"的领域；攻防时钟差几个数量级	否（制度）	2029 年部分辖区强制筛查	强制筛查立法；端到端能力评测

#	问题	节	为什么重要	数学是瓶颈吗	中心时间	关键信号
9	劳动份额与渐进式失权	§22	劳动份额趋近于零，会削弱"人被需要"带来的政治议价权；2026 年第二季度美国劳动份额 52.8%，1947 年以来最低（能否归因于 AI 证据不足）	否（经验参数和制度）	2028–2030 年出现可测量的宏观效应	生产率增速持续高于 2.5%；AI 密集行业领跑劳动份额下降
10	对齐中的社会选择："对齐到谁"	§22	已有定理证明 RLHF/DPO 离最优平均结果可以任意远，而 NLHF 是可证明最优的；A 类定理可以直接改进训练方法	是（A 类）	定理 2027 年底基本商品化；实验室采用 2027–2029 年	前沿实验室换用有保证的聚合方法

差一点进前十：可解释性的"计算无巧合猜想"（§21，一个纯数学结果就能改变研究组合）；临床转化和 Phase II 成功率（§20，影响巨大但 2035 年前难见效）；聚变（§19，硬件节拍主导）；虚拟细胞（§20，数据和指标主导）；AI 代理经济中的合谋（§22）。

23.4 时间线：2026 末 → 2030 年代

所有日期都是中心情景，误差大约 ± 1 年；乐观情景整体提前半年到一年，悲观情景推后一到两年。能力一行来自 §17.4 的三条曲线。

T0 · 现在（2026 Q4）

- **能力：**AI 独立完成约 1–2 个工作日的任务；预注册开放问题单次解出率 3–5%；形式化约 \$0.01–0.02/行。
- **已经发生：**
 - 天气预报 AI 业务化；
 - 一批经典数学物理问题被声称解决，但都未经评审；
 - AI 大规模找漏洞，补丁积压；
 - Lean 内核出现健全性漏洞；
 - 自动化研究员在定义清楚的对齐任务上胜过人类；
 - 数学界开始用对齐语言（"misalignment"、Goodhart）讨论 AI。
- **证伪信号：**新的长任务基准显示进展停在 1–2 天。

T1 · 2027 年

- **能力：**年中约 150 小时（ $\approx$ 一个月），年末约 400 小时；开放问题解出率年中约 9%、年末约 18%；证明成本再降一个数量级。
- **计算机与安全：**AI 参与的密码攻击改进论文变得常见；零知识证明系统依赖的"邻近间隙"猜想有实质进展；乐观情景下，AI 能把一个 1–5 万行的 C 库翻译成带证明的版本。
- **物理：**大多数著名的 A 类数学物理问题被声称解决，其中一半以上得到专家确认。

- **AI 与安全**：小模型的紧凑证明实现自动化；理想模型下的可扩展监督理论基本收敛；至少一个重要的 AI 形式化结果因工具链漏洞或错误形式化被撤回或严重质疑。
- **社会**：对齐中的社会选择定理基本商品化；代理对代理的商业交易开始成规模。
- **证伪信号**：FrontierMath Erdős 下一轮仍低于 5%；AI-led 研发份额停在 30% 左右。

T2 · 2028 年

- **能力**：年末约 2,800 小时（超过一个工作年）；开放问题解出率约 45%；一个费马大定理规模的形式化只要几千美元。
- **计算机与安全**：证明劳动不再是成本主体；形式验证过的检查内核成为默认；Q-day 资源估计再降 2-10 倍。
- **物理与化学**：主族化学在实用意义上"已解决"；SPARC 聚变装置 $Q > 1$ 。
- **AI 与安全**：A 类安全理论问题大多被解决或证明不可能，剩下的都是定义问题；"有 Lean 证明"作为证据的社会信用面临考验。
- **社会**：多数新手机默认给照片和视频签名；可测量的 AI 宏观效应开始出现（2028-2030）。
- **证伪信号**：任务长度停在几百小时，曲线 ① 变成 S 形。

T3 · 2029-2030 年

- **能力**：2030 年末开放问题解出率约 77%。
- **计算机与安全**：带证明的代码覆盖密码、内核、虚拟机监控器、解析器、共识协议这些"关键小内核"，但占代码总量不到 1%；ML-KEM 出现实用经典破解的概率 $\leq 5\%$ 。
- **生物**：常见球状蛋白的构象与自由能预测成熟；binder 设计基本工程化；虚拟细胞在特定细胞类型和通路上可靠；部分辖区实施核酸合成强制筛查。
- **物理与材料**：Hubbard 模型相图形成共识（2028-2030）；AI 设计的材料进入小众商用产品（2029-2032）；Yang-Mills 质量间隙中心判断 2030-2033 年。
- **AI 与安全**：关于泛化有几条可靠的经验定律，但没有统一理论。
- **社会**：训练过程零知识证明的概念验证（约 2029 年）；有约束力的国际验证协议要到 2030 年后，并且大概率需要一次政治冲击。

T4 · 2030 年代

- **Q-day**：能破 ECC-256 的量子计算机，中心判断 2033-2036 年；RSA-2048 晚几年。
- **医学**：药物整体成功率从 7.9% 升到 10-12%（2035）；针对具体老年病的干预成功，但"衰老"本身仍没有因果理论。
- **神经科学**：小鼠全脑连接组完成或接近完成（约 2033），"大脑的学习算法"仍无共识。
- **能源**：聚变商业发电在 2030 年代中后期。
- **情景分叉**：

- **AI 研发全面自动化** (CASP 情景)：数字世界的时间线全面压缩；物理世界的压缩取决于机器人、实验室和能源能否同步扩张。
- **出现硬瓶颈** (算力、能源、spec 审核)：A 类问题全部解决，B 类问题和物理世界按原有节奏推进。
- **两种情景下都成立**：软件和协议的安全保证远强于今天；开放世界（生物、社会）的保证仍然很弱，主要靠监测、访问控制和治理；**陈述和 spec 由谁审核**是整个系统的上限。

23.5 更深的二阶影响：对人类知识和社会意味着什么

这一小节是推论，不是预测，全部是 [推测]。

1. **知识的性质会改变**。越来越多的知识会是“可验证但没人理解”的：机器检查过的证明、经过实验验证的预言机模型。数学家、科学家的角色会从“生产结果”转向“选择问题、设计定义、审核陈述、解释意义”。Thurston 1994 年的文章 *On proof and progress in mathematics* 的核心观点是，证明的价值在于推进人的理解；2026 年的问题是，当证明不再需要理解时，理解由谁来做、有没有人付钱做。
2. **人类理解可能成为奢侈品和瓶颈**。测序成本十年降了一万倍，生物学没有快一万倍；证明成本大概也会这样。真正的限速步是人消化、相信和使用这些结果的速度。
3. **Baumol 效应会重塑经济**。能被 AI 加速的部门（软件、数学、设计）会相对变便宜，受物理约束的部门（医疗、建筑、能源、实验）会相对变贵。价值会流向物理投入、验证能力和合法性。
4. **权力会集中在验证和发布的节点上**。硬件厂商（芯片里的验证机制）、签名密钥持有者、前沿实验室（决定发布什么、以什么形式发布）、调解模型的训练者，都会成为新的权力节点。
5. **科学本身会出现 reward hacking**。已有的样本：AlphaEvolve 钻验证代码的漏洞；Virtual Cell Challenge 的指标被刷爆；FrontierMath 的错题；受迫 Navier–Stokes 满足了题面却不是大家真正关心的问题。“评测科学”会从 AI 安全的一个子课题，变成所有科学的基础设施。
6. **双用途知识的发布机制还不存在**。密码分析、化学合成、蛋白设计、漏洞挖掘都在加速。数学结果开始需要“负责任披露”，但除了生物安全，几乎没有制度。

23.6 对 AI 安全研究意味着什么

把 §17–§22 里提到的研究空白合在一起，最突出的是五个主题。它们的共同点是：**大多有自动裁判，能做真实实验，而且 AI 能力越强越重要**。

1. 验证器和陈述的审计学

- 证明器、验证器和评测的 reward hacking：把“刷分倾向”评测迁移到 Lean、Dafny 环境；看数学 RL 中学会的作弊会不会泛化成别处的失调 (§21)。
- 陈述与 spec 审计的方法：错误分类、交叉一致性检查、测量人类审核员的吞吐量 (§21、§18)。本 deck 逐行读 Lean 陈述 (§4–§13) 就是一个雏形。

- 给 AI 生成的科学声明打"可验证性"分的评测 (§19)。

2. 用真实能力差距做监督实验

- 形式数学提供了"AI 远强于人 + 完美的 ground truth"的监督实验场 (§21)。
- 把临床试验的制度（预注册、独立监察、强制报告阴性结果）迁移到 AI 评测 (§20)。

3. 双用途能力评测

- 密码分析和漏洞修补能力的评测 (§18)。
- 生物：端到端、使用安全代理物的能力评测，测"模型 + 云实验室"能让一个受过基础训练的人做到什么 (§20，只在治理层面)。
- 自主实验室的威胁模型与权限分级：AI 第一次拿到物理执行权限 (§19)。

4. 可验证治理与多代理

- 验证红队：让代理自动跑"监控者 vs 规避者"的迭代，测试算力治理的验证机制 (§22)。
- 代理合谋倾向评测：多代理定价场景下的合谋和隐写 (§22)。
- RLHF 聚合审计：在公开偏好数据上比较 Borda 式奖励模型和 NLHF (§22)。
- 面向 AI 治理的可验证推理：用零知识证明证明模型身份和过滤器执行 (§18)。

5. 测量 AI 对科学的真实加速，以及"匹配"

- 建一个"生物实验吞吐/成本指数"：生物学里 AI 影响的速度由实验成本决定，而这条曲线目前没人系统地测 (§20)。
- 做"匹配"：把已有的数学连到需要它的人和问题上。历史上 (§17.1)，这一步的回报往往比证明新定理来得更早。
- 跟踪反信号：一个 AI 证明的"库存型"定理在 3 年内进入产品，就说明匹配成本已经塌缩，本节的时间线要整体提前 (§17)。
- 测"证明变便宜后，研究者会不会扎堆到 AI 擅长的 A 类问题"：已有证据显示，用 AI 的科学家个人产出上升，集体的选题范围变窄 (§17.6)。

两个通用原则：

- 不要手工做一年内 AI 就会做的事，除非它是基础设施，或者能帮你判断"该问什么"。
- 优先做"定义问题"：在 A 类问题被清空之后，定义和陈述是剩下的瓶颈，也是人类判断最不可替代的地方。

23.7 这份推演最可能错在哪

1. 能力曲线的测量正在失效。METR 的任务集在 16 小时以上不可靠；作弊算不算成功能让结果相差约 4.5 次翻倍。2027 年以后的数字主要靠"其他信号同步上升"来支撑 (§17.4)。
2. A 类和 B 类的边界会移动。AI 可能比预期更早擅长"提出好的陈述和定义"。目前没有证据表明这已经发生：OpenAI 的 719 篇主要是解决已有问题，几乎没有提出新概念。一旦发生，本节

的大部分时间线都会提前，人的角色会进一步收缩。

3. **很多引用的结果还没经过评审。** OpenAI 的 719 篇、2026 年的大量 arXiv 预印本、各家公司的自述数字都是如此；研究时搜索额度有限，部分数字凭记忆或二手来源，已在各节标 $\triangle$ 。
4. **制度可能在冲击之后突然变快**，无论是变好还是变坏。一次重大事故可能让立法几个月内完成，也可能引发过度反应。
5. **物理约束可能被 AI 驱动的机器人和自动化实验室比预期更快地突破**，这会削弱"数字和物理分叉"的结论。
6. **选择偏差。** 本 Part 的问题清单都是已知的重要问题。历史上 (§17.1)，最大的影响常常来自没人预料到的应用：数论变成密码学，Radon 变换变成 CT。最深远的影响，很可能来自这份清单之外。

23.8 本节来源

本节不引入新的事实，所有数字的出处见 §17–§22 各节末尾的来源列表。六个领域的完整研究底稿（每张问题卡片的完整版、更多来源和未进入 deck 的材料）保存在作者的研究笔记中，未随本 deck 公开。

24. 各方怎么说

谁	原话	来源
Levent Alpöge (Anthropic)	"It's obviously the most significant moment in mathematical history." (随后补充: 会有人被抢先的 "sad stories")	X [R]
Terence Tao	"Problems are being solved autonomously by AI prompters who have no interest in the broader field itself"; 提出 Math 1.0 → 2.0	Fortune [R]
Dan Litt (多伦多大学)	"My view is that this is great for mathematics", 但担心"AI 已解决数学"的观感劝退年轻人	Fortune [R]
Tristan Buckmaster (NYU)	"There's likely to be a bunch of results where they take someone's work and then take it to completion"	Fortune [R]
Scott Aaronson	博文 "The Mathocalypse"; 对 $L = BPL$: "its truth was never in serious doubt"	blog [R]
Lance Fortnow	"if they hold up, we've seen more progress in TCS in the last 24 hours than in the previous three decades combined"	Computational Complexity blog [R]
Mark Braverman	"Math by press release is not that healthy for math."	Quanta [R]
François Chollet	追问: RLVR 友好领域的增益能否泛化, 还是不可验证领域仍卡在人类数据上	X (转述) [R]
AHM	"Releasing over 700 files at once is not a demonstration of scholarship, but a demonstration of power."; 呼吁数学家停止与 OpenAI 合作	Tao 博客转载 (Tao 注明不背书) [P]
Álvaro Lozano-Robledo	"Keep calm and carry on studying math."; LLM "may work within the confines of the convex hull of ideas that are currently available in the literature"	Tao 博客客座文 [P]
Andrew Sutherland (MIT)	"We should ask for receipts."	SciAm 转载 [R]

注: 10-05 Tao 博客上的 "The Future of Mathematics" 是 Jeremy Avigad 的客座文, 不是 Tao 本人所写; 部分报道混淆了这一点。

25. 开放问题与继续学习

25.1 接下来值得盯的

- 1. OpenAI 会公开 4,000 题清单与失败案例吗？（决定能否回答"真实能力是多少"）
- 2. 未形式化的约 58% 里还有多少像 Weil 类论文那样的错误？撤稿率会怎么演化？
- 3. 谁来审 Lean 陈述的忠实性？ `review: unchecked` 什么时候改变？ `lana-agents` 依赖和大补丁由谁审？
- 4. 第一个人类领域专家对头条结果（准黎曼、UGC、Thompson F）给出"读完并确认"的独立结论会是什么时候？
- 5. "补完他人工作"的优先权规范怎么建立（Buckmaster 事件）？
- 6. 平面色数：需要 6 色的有限单位距离图长什么样？

25.2 学习路线（只需线性代数 + 微积分起步）

阶段	材料	为什么
1 · 数学是什么	Gowers 《Mathematics: A Very Short Introduction》（中译《牛津通识读本：数学》）	Fields 奖得主写的 150 页入门：抽象、证明、什么叫难
1 · 这场争论的源头	Thurston On Proof and Progress in Mathematics；Gowers The Two Cultures of Mathematics；Tao What is good mathematics?	读完就完全明白 "Math 1.0 → 2.0" 在吵什么
2 · 亲手摸证明	Natural Number Game（Kevin Buzzard，在线免费）	在 Lean 里从零证明加法交换律——之后你就真正理解 §3 的一切
2 · 系统学证明	MIT 6.042 Mathematics for Computer Science（OCW + 免费教材）	为 CS 背景设计：证明方法、离散数学、概率
3 · 直觉	3Blue1Brown：《线性代数的本质》、黎曼 ζ 函数可视化	§4 的图就是那一集的静态版
3 · 跟新闻	Quanta Magazine 数学版；Princeton Companion to Mathematics（当工具书查词条）	每篇都解释"为什么难、前人卡在哪"
4 · 与 ML 相关	Bubeck Convex Optimization: Algorithms and Complexity；Prince 《Understanding Deep Learning》（免费）	优化收敛证明、深度学习理论入门

26. 术语表与来源

26.1 术语

术语	一句话
Lean / Mathlib	证明助手 / 它的社区数学库
sorry / axiom	Lean 里"这步先空着" / "这条直接假设为真"——都会削弱证明
Comparator	检查"解答证明的定理 = 挑战文件里的陈述，且只用允许公理"的工具
无零区	ζ 或 L 函数在其中没有零点的区域
无理性指数 μ	一个数能被分数"超常好"逼近的程度
ω	矩阵乘法的最优指数， $2 \leq \omega \leq 3$
近似比	多项式时间算法保证拿到的"最优值的比例"
L / RL / BPL	对数空间的确定性 / 单边随机 / 双边随机计算
可顺从 amenable	群上存在平移不变的"平均"
爆破 blowup	光滑方程的解在有限时间内趋于无穷
复本对称破缺 RSB	Parisi 描述自旋玻璃层级态结构的方法
银河算法	渐近更快、但只在天文规模上才占优的算法

26.2 主要来源

一手：openai/math (README、history.md、overview.pdf、CONTENTS.md、lean/、preprints/、reasoning_traces/；快照 fd4aeeb, 2026-10-08) · openai/NavierStokesAndEuler · Clay NS 官方陈述 (Fefferman) · leanprover/comparator · 独立复核 davegoldblatt/openai-zeta-proof-check、erenciracioglu-dotcom/openai-math-9-4-lean-check · Epoch FrontierMath Erdős (arXiv:2609.25050)。

报道与评论：Fortune 10-07 · Nature (付费墙，未读全文 $\triangle$) · Scientific American · Quanta 09-08 · Quanta 10-07 · NPR 09-22 · Aaronson · Kalai · Tao 博客 · Latent Space。

经典文献：Strassen 1969；Coppersmith–Winograd 1990；Alman 等 arXiv:2404.16349；Ambainis–Filmus–Le Gall arXiv:1411.5414；Goemans–Williamson 1995；Khot 2002；KKMO 2007；Raghavendra 2008；Khot–Minzer–Safra 2018；Nisan 1992；Saks–Zhou 1999；Reingold 2008；Roth 1955；Zeilberger–Zudilin arXiv:1912.06345；Meiburg

arXiv:2208.13356; Guth–Maynard arXiv:2405.20552; de Grey arXiv:1804.02385; Moore arXiv:1102.0747; Tao 2016 arXiv:1402.0290; Glassey–Strauss 1986; Parisi 1979; Talagrand 2006; Mézard–Parisi 2001; Ding–Sly–Sun 2015。

研究底稿（含每条的 [P]/[R]/△ 标注、Lean grep 细节和未进 deck 的材料）保存在作者的研究笔记中，未随本 deck 公开。